广 义 线 性 模 型

Generalized Linear Models



学习网站：https://fxt-gw-pb.github.io/public-health-statistics-notes/

2026 年 10 月

目录

第 1 章广义线性模型基本概念与方法 1
1.1 广义线性模型 1
1.2 连接函数 4
1.3 常用参数估计方法 5
1.4 软件实现 11
1.5 思考与练习. 13
习题与解析 广义线性模型概述 15

第 2 章Logistic 回归模型（一） 35
2.1 Logistic 回归的基本概念. 35
2.2 配对设计资料的条件 Logistic 回归模型. 48

第 3 章Logistic 回归模型（二） 54
3.1 多分类结局资料的 Logistic 回归分析 54
3.2 有序分类结局资料的 Logistic 回归分析. 58
3.3 案例讨论 61
3.4 Logistic 回归的正确应用. 66
3.5 思考与练习. 67
3.6 附录：Logistic 回归的软件实现 68
习题与解析 Logistic 回归 72

第 4 章生存分析（一） 101
4.1 生存分析的基本概念. 101
4.2 生存率的估算方法 107
4.3 生存曲线的比较方法. 114

第 5 章生存分析（二） 120
5.1 Cox 回归分析 120
5.2 Cox 回归的正确应用. 125
5.3 案例分析 132
5.4 思考与练习. 136
5.5 附录：软件实现. 137
习题与解析 生存分析与 Cox 回归 140

第 6 章对数线性模型 173
6.1 问题提出 173
6.2 对数线性模型 176
6.3 案例讨论 187
6.4 课后作业 192
6.5 附录：对数线性模型的软件实现 192

第 7 章泊松回归与负二项回归 194
7.1 泊松回归（Poisson Regression） 194
7.2 负二项回归（Negative binomial regression） 212
7.3 附 1：泊松回归的软件实现 224
7.4 附 2：负二项回归的软件实现 226
习题与解析 对数线性模型、泊松回归与负二项回归 228

第 8 章总复习与模型比较 258
8.1 广义线性模型概述 258
8.2 Logistic 回归 259
8.3 生存分析 262
8.4 对数线性模型 263
8.5 泊松回归（Poisson Regression） 264
8.6 负二项回归模型 264
8.7 模型比较总表 265
8.8 期末考试安排 266
习题与解析 总复习与模型比较：补充习题 269

附录 易错表述与更正 276

来源与选编依据 281

第 1 章

广义线性模型基本概念与方法

公共卫生研究中有大量非连续的结局变量：死亡与否、是否患病为二分类变量；病情轻、中、重为有序分类变量；一年内哮喘发作次数、某地某病新发病例数为计数变量；从确诊到死亡的时间为生存时间。这些资料不满足线性回归的条件，本课程讨论其分析方法。

本章介绍全课程的基本框架。后续各章的模型均由以下三个要素确定：

1) **结局变量的分布**。二分类资料采用二项分布，计数资料采用 Poisson 分布或负二项分布。分布决定了方差与均数之间的关系。
2) **均数与自变量的联系方式**。模型令均数的某一函数（连接函数）等于自变量的线性组合 $\beta_0 + \beta_1 x_1 + \cdots$。logit 连接下系数为对数 OR，log 连接下系数为对数 RR 或对数率比。
3) **参数估计方法**。统一采用极大似然法，计算上采用迭代加权最小二乘算法。

在这一框架下，logistic 回归、Poisson 回归与负二项回归是对上述三个要素的不同选择。Cox 回归与对数线性模型严格而言不完全属于这一框架，但思路相通。

1.1 广义线性模型

1.1.1 广义线性模型

经典的线性模型要求因变量是连续型的定量变量，但是我们所关心的因变量往往包括非连续的分类变量，比如 0–1 变量。

例 1（横断面研究） 在研究医院抢救急性心肌梗塞（AMI）患者能否成功的危险因素的调查中，某医院收集了 5 年中该院所有的 AMI 患者的抢救病史（有关危险因素很多，由于篇幅有限，本例仅列出 3 个），共 200 例。

- $Y = 0$ 表示抢救成功，$Y = 1$ 表示死亡。
- $X_1 = 1$ 表示抢救前已发生休克，$X_1 = 0$ 表示抢救前未发生过休克。
- $X_2 = 1$ 表示抢救前发生心衰，$X_2 = 0$ 表示抢救前未发生心衰。
- $X_3 = 1$ 表示患者从开始 AMI 症状到抢救时已超过 12 小时（即未能及时把患者送往医院），$X_3 = 0$ 表示未超过 12 小时。

表 6　AMI 患者的抢救危险因素资料

$Y=0$（在医院抢救成功）				$Y=1$（未能抢救成功而死亡）			
X_1	X_2	X_3	N	X_1	X_2	X_3	N
0	0	0	35	0	0	0	4
0	0	1	34	0	0	1	10
0	1	0	17	0	1	0	4
0	1	1	19	0	1	1	15
1	0	0	17	1	0	0	6
1	0	1	6	1	0	1	9
1	1	0	6	1	1	0	6
1	1	1	6	1	1	1	6

$$\widehat{Y} = b_0 + b_1 x_1 + b_2 x_2 + b_3 x_3 \qquad ? \times$$

Y 是二分类变量，服从二项分布，事件发生的概率记为 P。

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3,$$
$$\ln\left(\frac{P}{1-P}\right) = \operatorname{logit}(P) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3.$$

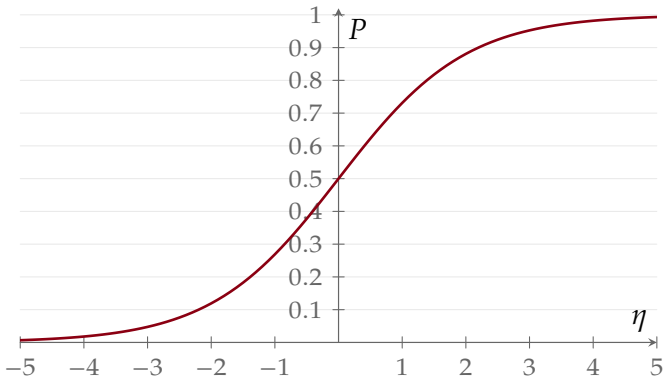


图 2　Logistic 回归中线性预测量 η（logit 值）与 P 的关系示意图

Logistic 回归模型

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_m x_m,$$
$$\operatorname{logit}(P) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_m x_m,$$
$$P = \frac{e^{\beta_0+\beta_1 x_1+\cdots+\beta_m x_m}}{1+e^{\beta_0+\beta_1 x_1+\cdots+\beta_m x_m}} = \frac{1}{1+e^{-(\beta_0+\beta_1 x_1+\cdots+\beta_m x_m)}}.$$

一般线性回归模型与 Logistic 回归模型

一般线性回归模型	$\mathrm{E}(Y \mid \mathbf{x}) = \beta_0 + \beta_1 x_1 + \cdots + \beta_m x_m$
Logistic 回归模型	$\ln\dfrac{P}{1-P} = \beta_0 + \beta_1 x_1 + \cdots + \beta_m x_m$，　$P = P(Y=1 \mid \mathbf{x})$

GLM 是一般线性模型的推广、普遍化（generalized），由 Nelder & Wedderburn 于 1972 年提出。

广义线性模型的组成

随机（因变量）部分 random component	系统（自变量）部分 systematic component	连接函数 link function
$Y_i \mid \mathbf{x}_i$ 相互独立，均值 $\mu_i = \mathrm{E}(Y_i \mid \mathbf{x}_i)$	$\eta_i = \sum_{j=0}^{m} \beta_j x_{ij} = \mathbf{x}_i^\top \boldsymbol{\beta}$	$g(\mu_i) = \eta_i$

一般线性回归模型中，$\eta = g(\mu) = \mu$；Logistic 回归模型中，$\eta = g(\mu) = \mathrm{logit}(P)$。

0/1 结局不宜直接采用线性回归

将 $Y = 0/1$ 直接作为 `lm()` 的因变量，称为线性概率模型。以下模拟说明其问题：x 在 -3 至 3 之间取 200 个值，真实发生概率为 $P = 1/(1+e^{-2x})$。

R

```r
set.seed(10)
x <- seq(-3,3,length=200); y <- rbinom(200,1,plogis(2*x))
f <- lm(y~x)
range(fitted(f))                          # 拟合“概率”的范围
mean(fitted(f)<0 | fitted(f)>1)           # 落在[0,1]之外的比例
```

```
[1] -0.2302985  1.1902985
[1] 0.3
```

30% 的拟合值超出 $[0,1]$，不能作为概率解释。此外，0/1 变量的方差为 $P(1-P)$，随均数而变化，不满足等方差假设；残差只能取两个值，也不服从正态分布。

logit 变换将 $(0,1)$ 映射至整条实轴，线性预测量 η 取任意值时，经反变换得到的 P 均位于 0 与 1 之间；方差随均数变化这一特点则由二项分布直接纳入模型。广义线性模型的基本思路即在于此：根据资料的性质选择相应的分布与连接函数，而不对数据本身作强制变换。

- 经典的线性模型要求因变量是连续性的，在 GLM 中因变量拓展到非连续性的资料，如服从二项分布、Poisson 分布、负二项分布等。
- 经典的线性模型中，条件均值本身就是线性预测量，$\mu_i = \eta_i$；在 GLM 中，条件均值经连接函数变换后才等于线性预测量，$g(\mu_i) = \eta_i$。参数估计后的拟合值为 $\hat{\mu}_i = g^{-1}(\mathbf{x}_i^\top \hat{\boldsymbol{\beta}})$。

本书区分四个量：响应 Y_i（随机变量，观测值记 y_i）；条件均值 $\mu_i = \mathrm{E}(Y_i \mid \mathbf{x}_i)$（总体量，未知）；线性预测量 $\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$（由未知参数决定）；拟合值 $\hat{\mu}_i$（由估计值 $\hat{\boldsymbol{\beta}}$ 算出）。“$\mu = \hat{y}$”的写法把总体条件均值与拟合值混为一谈，这里不再沿用。

指数族表示与条件均值、方差

假设　给定 $\mathbf{x}_i$ 时 $Y_1, \ldots, Y_n$ 条件独立，Y_i 的密度（或概率函数）属于指数散布族

$$f(y_i; \theta_i, \phi) = \exp\left\{ \frac{y_i \theta_i - b(\theta_i)}{a_i(\phi)} + c(y_i, \phi) \right\},$$

其中 θ_i 为自然参数，ϕ 为散布参数，$a_i(\phi)=\phi/w_i$（w_i 为已知权重），$b(\cdot)$ 二阶可导，且积分与求导可交换。

结论

$$\mu_i=\mathrm{E}(Y_i\mid \mathbf{x}_i)=b'(\theta_i),\qquad \mathrm{Var}(Y_i\mid \mathbf{x}_i)=a_i(\phi)\,b''(\theta_i)=a_i(\phi)V(\mu_i),$$

$V(\mu)=b''\{(b')^{-1}(\mu)\}$ 称为方差函数。

推导　记对数似然贡献 $\ell_i=\{y_i\theta_i-b(\theta_i)\}/a_i(\phi)+c(y_i,\phi)$。对 $\int f\,dy=1$ 关于 θ_i 求一阶、二阶导数，得两条恒等式

$$\mathrm{E}\left(\frac{\partial \ell_i}{\partial \theta_i}\right)=0,\qquad \mathrm{E}\left(\frac{\partial^2 \ell_i}{\partial \theta_i^2}\right)+\mathrm{E}\left[\left(\frac{\partial \ell_i}{\partial \theta_i}\right)^2\right]=0.$$

而 $\partial\ell_i/\partial\theta_i=\{Y_i-b'(\theta_i)\}/a_i(\phi)$，$\partial^2\ell_i/\partial\theta_i^2=-b''(\theta_i)/a_i(\phi)$。代入第一式得 $\mathrm{E}(Y_i)=b'(\theta_i)$；代入第二式得 $\mathrm{Var}(Y_i)/a_i(\phi)^2=b''(\theta_i)/a_i(\phi)$，即 $\mathrm{Var}(Y_i)=a_i(\phi)b''(\theta_i)$。

解释　GLM 的方差不是另行设定的，而是由分布族通过 $V(\mu)$ 与均值联系在一起：正态 $V(\mu)=1$，Poisson $V(\mu)=\mu$，Bernoulli $V(\mu)=\mu(1-\mu)$。这正是二分类、计数资料不满足“方差齐性”的原因，也是后文加权最小二乘与 IRLS 的权重来源。

1.1.2 常见的广义线性模型

Logistic 回归模型、Poisson 回归、对数线性模型、负二项回归、Probit 回归、Cox 回归。

说明 Cox 回归常与 GLM 一起介绍，但它属于半参数生存回归模型：基线风险 $h_0(t)$ 不作参数设定，参数用部分似然估计，并不是指数族响应加连接函数的标准 GLM。负二项回归在散布参数 α 固定时属于 GLM，α 一并估计时是 GLM 的推广。

1.2 连接函数

- GLM 关心一组自变量的线性组合预测因变量的条件均数或者条件均数的某种函数。
- 连接函数连接因变量的均数与自变量的线性组合。
- 连接函数是因变量均数的转化，转化后的变量为回归参数的一个线性函数。

一般线性模型，正态分布：$g(\mu)=\mu$，同一性连接、恒等连接。

Logistic 回归模型（响应为 0/1 或比例，$\mu=\pi$）：$g(\mu)=\log_e\dfrac{\mu}{1-\mu}$。

典型连接（canonical link）指使线性预测量恰为自然参数的连接，即 $\eta=\theta$，亦即 $g=(b')^{-1}$。

表 7　几种常见分布的自然参数、方差函数与典型连接

分布	取值集合	均数 μ	方差	自然参数 θ	方差函数 $V(\mu)$	典型连接 $g(\mu)$
正态 $N(\mu,\sigma^2)$	$(-\infty,\infty)$	μ	σ^2	μ	1	恒等 μ
二项计数 $B(n,\pi)$	$\{0,1,\dots,n\}$	$n\pi$	$n\pi(1-\pi)$	$\log\dfrac{\pi}{1-\pi}$	$\mu(1-\mu/n)$	$\log\dfrac{\mu}{n-\mu}$
二项比例 Y/n	$\{0,\frac{1}{n},\dots,1\}$	π	$\pi(1-\pi)/n$	$\log\dfrac{\pi}{1-\pi}$	$\mu(1-\mu)$	$\mathrm{logit}(\pi)$
Poisson $P(\lambda)$	$\{0,1,2,\dots\}$	λ	λ	$\log\lambda$	μ	$\log\mu$

- 二项计数与二项比例的线性预测量相同：$\log\{\mu/(n-\mu)\} = \log\{n\pi/(n-n\pi)\} = \operatorname{logit}(\pi)$，二者只是对同一参数 π 的两种记录方式；比例形式的权重为 n。
- 二项、Poisson 都是离散分布，取值包括端点 0（及二项的 n），常写作开区间 $(0,n)$、$(0,\infty)$ 不准确；开区间描述的是均数 μ 的取值范围，即 $0 < n\pi < n$、$\lambda > 0$。
- 典型连接有计算上的便利（得分方程化为 $\mathbf{X}^{\top}(\mathbf{y}-\boldsymbol{\mu}) = \mathbf{0}$，观测信息等于期望信息），但不是必须采用。例如二项资料也可用 probit 连接 $\Phi^{-1}(\pi) = \eta$ 或互补双对数连接 $\log\{-\log(1-\pi)\} = \eta$。

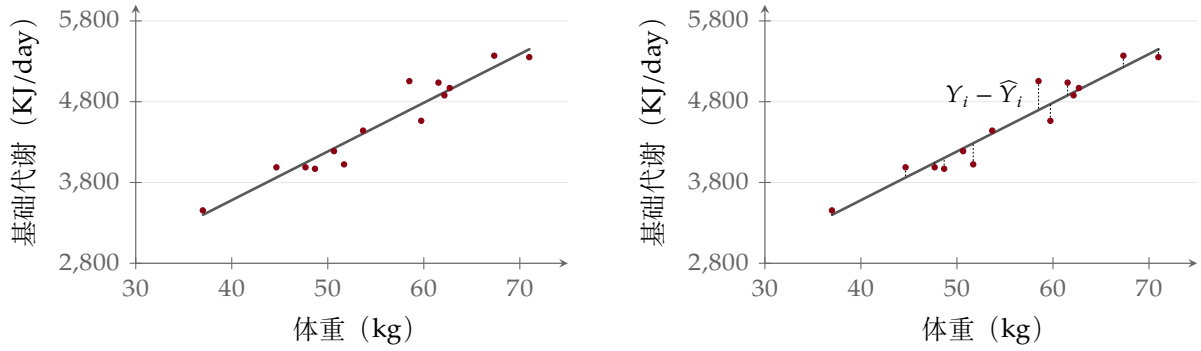
logit 与 probit 连接的比较　两者都把 $(0,1)$ 映射到整条实轴、关于 $\pi = 0.5$ 对称。logit 对应标准 Logistic 分布的分布函数（方差 $\pi^2/3$），probit 对应标准正态分布函数，故在 π 中段两者近似成比例：$\operatorname{logit}(\pi) \approx 1.6\text{–}1.8 \times \Phi^{-1}(\pi)$，系数也相应近似成比例。logit 尾部稍重，且系数可解释为对数优势比（$\exp(\beta)$ 为 OR，且在病例对照抽样下斜率不变）；probit 系数没有 OR 解释，常对应潜在正态变量的阈值模型。拟合优度上两者通常差别很小。

1.3 常用参数估计方法

最小二乘估计（least squared estimation, LS）；加权最小二乘估计（weighted least squared, WLS）；极大似然估计（maximum likelihood estimation, MLE）。

1.3.1 最小二乘估计

简单线性回归。



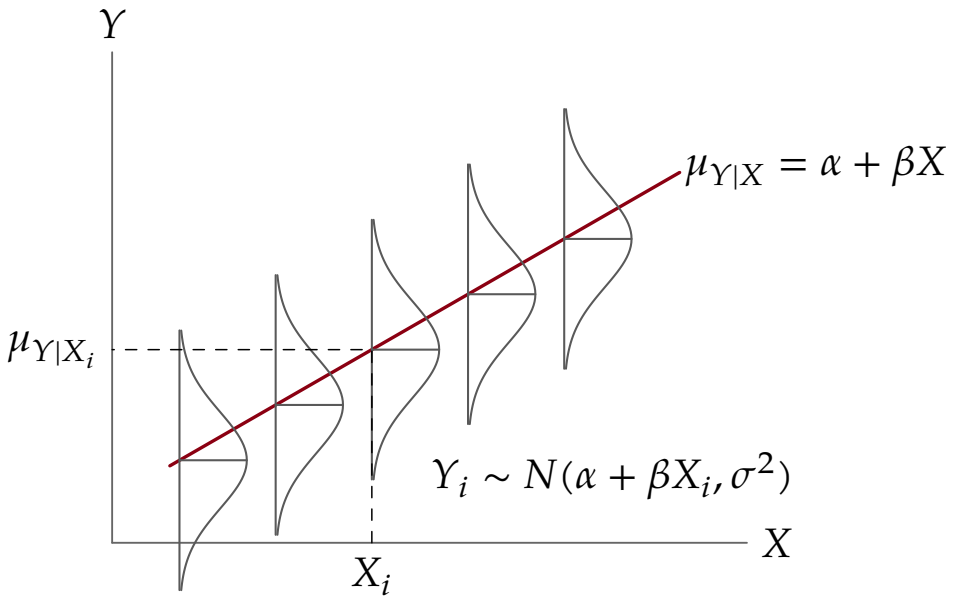


图 8　基础代谢与体重间回归直线的散点图、条件、最小二乘原则的直观表达

$$\sum_{i=1}^{n}(y_i-\hat{y}_i)^2 \quad\longrightarrow\quad \sum_{i=1}^{n}\left(y_i-\beta_0-\sum_{j=1}^{m}\beta_j X_{ij}\right)^2.$$

- 满足一般线性模型的条件（LINE）的资料，可以用最小二乘法估计参数。
- 对于线性模型，LS 估计是方差最小线性无偏估计（best linear unbiased estimate），且是唯一的。　　Gauss–Markov 定理

OLS 的矩阵解与 Gauss–Markov 定理

假设　$\mathbf{y}=\mathbf{X}\boldsymbol{\beta}+\boldsymbol{\varepsilon}$，$\mathbf{X}$ 为 $n\times p$ 已知设计矩阵（p 含截距），且列满秩 $\operatorname{rank}(\mathbf{X})=p$；$\mathrm{E}(\boldsymbol{\varepsilon}\mid\mathbf{X})=\mathbf{0}$；$\operatorname{Cov}(\boldsymbol{\varepsilon}\mid\mathbf{X})=\sigma^2\mathbf{I}_n$（同方差且不相关）。此处不要求正态。

关键等式　最小化 $Q(\boldsymbol{\beta})=(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})^{\top}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})$，令 $\partial Q/\partial\boldsymbol{\beta}=-2\mathbf{X}^{\top}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})=\mathbf{0}$，得正规方程 $\mathbf{X}^{\top}\mathbf{X}\boldsymbol{\beta}=\mathbf{X}^{\top}\mathbf{y}$。满秩时 $\mathbf{X}^{\top}\mathbf{X}$ 可逆，

$$\hat{\boldsymbol{\beta}}_{\mathrm{OLS}}=(\mathbf{X}^{\top}\mathbf{X})^{-1}\mathbf{X}^{\top}\mathbf{y},\qquad \mathrm{E}(\hat{\boldsymbol{\beta}}\mid\mathbf{X})=\boldsymbol{\beta},\qquad \operatorname{Cov}(\hat{\boldsymbol{\beta}}\mid\mathbf{X})=\sigma^2(\mathbf{X}^{\top}\mathbf{X})^{-1}.$$

设 $\tilde{\boldsymbol{\beta}}=\mathbf{C}\mathbf{y}$ 是任一线性无偏估计，则 $\mathbf{C}\mathbf{X}=\mathbf{I}$。记 $\mathbf{D}=\mathbf{C}-(\mathbf{X}^{\top}\mathbf{X})^{-1}\mathbf{X}^{\top}$，有 $\mathbf{D}\mathbf{X}=\mathbf{0}$，于是

$$\operatorname{Cov}(\tilde{\boldsymbol{\beta}})=\sigma^2\mathbf{C}\mathbf{C}^{\top}=\sigma^2(\mathbf{X}^{\top}\mathbf{X})^{-1}+\sigma^2\mathbf{D}\mathbf{D}^{\top}.$$

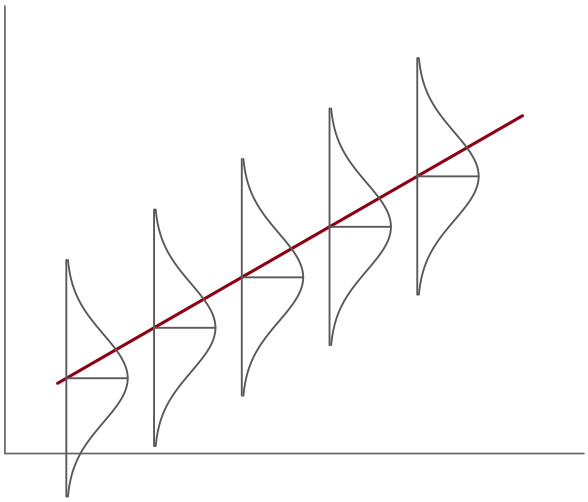
结论　$\operatorname{Cov}(\tilde{\boldsymbol{\beta}})-\operatorname{Cov}(\hat{\boldsymbol{\beta}})=\sigma^2\mathbf{D}\mathbf{D}^{\top}$ 半正定，故对任意 $\mathbf{c}$，$\operatorname{Var}(\mathbf{c}^{\top}\hat{\boldsymbol{\beta}})\le\operatorname{Var}(\mathbf{c}^{\top}\tilde{\boldsymbol{\beta}})$。“最优”只在线性且无偏的估计量中比较；有偏估计（如岭回归）或非线性估计可能有更小的均方误差。

解释　不满秩（完全共线性）时正规方程有无穷多解，单个系数不可识别，但拟合值 $\mathbf{X}\hat{\boldsymbol{\beta}}$ 唯一。正态性不是 Gauss–Markov 定理的条件，它只用于得到 t、F 统计量的精确分布。

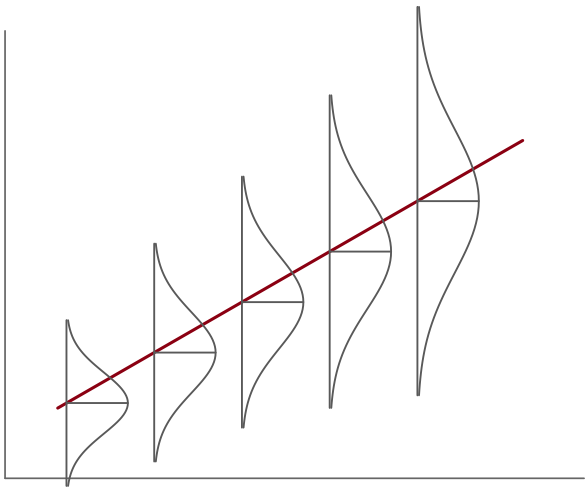
1.3.2 加权最小二乘估计

如果资料不满足“方差齐性”的条件，则 LS 不适宜。

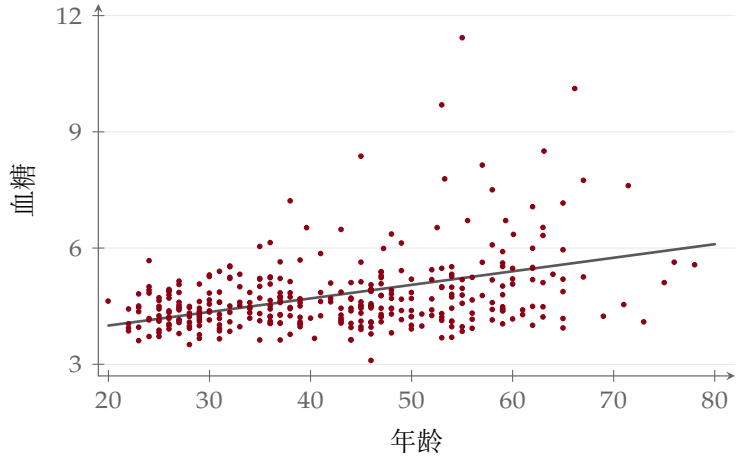
- **对无偏性**：只要均值结构 $\mathrm{E}(\mathbf{y} \mid \mathbf{X}) = \mathbf{X}\boldsymbol{\beta}$ 设定正确，异方差时 OLS 仍然无偏、一致。
- **对效率**：OLS 不再是方差最小的线性无偏估计，按方差倒数加权的 WLS 才是。
- **对标准误**：常规公式 $s^2(\mathbf{X}^\top\mathbf{X})^{-1}$ 不再正确，基于它的 t 检验、置信区间可能偏于宽松或保守；可改用 WLS，或保留 OLS 点估计而采用稳健（夹心）标准误。
- **对精确推断**：即使用对了权重，t、F 的精确分布仍依赖误差正态；非正态时只有大样本下的近似。



给定 X 时，Y 是正态分布、等方差示意图



给定 X 时，Y 是正态分布、不等方差示意图



男性年龄与血糖的关系（方差随自变量的增加而增加）

加权最小二乘估计（weighted least squared, WLS），其权重是方差的倒数，方差越大权重越小，方差越小权重越大。

$$\sum_{i=1}^{n} \frac{1}{V_i}(y_i - \hat{y}_i)^2.$$

写成矩阵形式：若 $\mathrm{Cov}(\boldsymbol{\varepsilon} \mid \mathbf{X}) = \sigma^2 \mathbf{V}$，$\mathbf{V} = \mathrm{diag}(V_1, \dots, V_n)$ 已知，令权重阵 $\mathbf{W} = \mathbf{V}^{-1}$，最小化 $(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^{\top} \mathbf{W} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$，得

$$\hat{\boldsymbol{\beta}}_{\mathrm{WLS}} = (\mathbf{X}^{\top}\mathbf{W}\mathbf{X})^{-1}\mathbf{X}^{\top}\mathbf{W}\mathbf{y}, \qquad \mathrm{Cov}(\hat{\boldsymbol{\beta}}_{\mathrm{WLS}} \mid \mathbf{X}) = \sigma^2 (\mathbf{X}^{\top}\mathbf{W}\mathbf{X})^{-1}.$$

这等价于对变换后的资料 $\mathbf{W}^{1/2}\mathbf{y} = \mathbf{W}^{1/2}\mathbf{X}\boldsymbol{\beta} + \mathbf{W}^{1/2}\boldsymbol{\varepsilon}$ 作 OLS，后者误差同方差，故 Gauss–Markov 定理保证 WLS 在 $\mathbf{V}$ 已知时是 BLUE。实际中 V_i 往往依赖未知参数（如二项方差 $n_i P_i(1-P_i)$），只能用估计值代入或反复迭代。**例题** 请采用 WLS 方法建立下面四格表资料的 Logistic 回归模型，并估计 OR。

表 8　四格表资料的一般格式

	暴露，$x=1$	非暴露，$x=0$	合计
发病，$y=1$	a	b	$a+b$
不发病，$y=0$	c	d	$c+d$
合计	$a+c$	$b+d$	$a+b+c+d$

$$\mathrm{OR} = \frac{ad}{bc}.$$

以 P_1 表示暴露者中病例的比例，P_0 表示非暴露者中病例的比例。

$$P_1 = \frac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}}, \qquad P_0 = \frac{e^{\alpha}}{1+e^{\alpha}}.$$

$$\begin{aligned}\sum \frac{1}{V_i}(y_i - \hat{y}_i)^2 = {} & \frac{[a-(a+c)P_1]^2}{(a+c)P_1(1-P_1)} + \frac{[c-(a+c)(1-P_1)]^2}{(a+c)P_1(1-P_1)} \\ & + \frac{[b-(b+d)P_0]^2}{(b+d)P_0(1-P_0)} + \frac{[d-(b+d)(1-P_0)]^2}{(b+d)P_0(1-P_0)}.\end{aligned}$$

$$\begin{aligned}&(b+d)[a^2 - 2ace^{\alpha+\beta} + c^2 e^{2\alpha+2\beta}] \\ &\quad + (a+c)[b^2 e^{\beta} - 2bde^{\alpha+\beta} + d^2 e^{2\alpha+\beta}] \longrightarrow \text{最小}.\end{aligned}$$

分别对 α, β 取导数，并令其等于 0，得：

$$\begin{aligned}&(b+d)[-2ace^{\alpha+\beta} + 2c^2 e^{2\alpha+2\beta}] \\ &\quad + (a+c)[-2bde^{\alpha+\beta} + 2d^2 e^{2\alpha+\beta}] = 0, \\ &(b+d)[-2ace^{\alpha+\beta} + 2c^2 e^{2\alpha+2\beta}] \\ &\quad + (a+c)[b^2 e^{\beta} - 2bde^{\alpha+\beta} + d^2 e^{2\alpha+\beta}] = 0.\end{aligned}$$

解得：

$$\hat{\alpha} = \ln \frac{b}{d}, \qquad \hat{\beta} = \ln \frac{ad}{bc} = \ln(\mathrm{OR}).$$

说明 本例的加权平方和中权重 $1/\{(a+c)P_1(1-P_1)\}$ 等含待估参数，严格说是“最小 χ^2”估计。本例只有两组（暴露、非暴露）、两个参数，模型是饱和的：参数恰好可以使 $\widehat{P}_1 = a/(a+c)$、$\widehat{P}_0 = b/(b+d)$，各项残差全为 0，因此无论权重取什么正值，最小值都在同一点达到，结果与下面的 MLE 完全一致。这种一致性不能推广：模型不饱和（如多个协变量、连续协变量）时，固定权重的 WLS 一般不等于 MLE；只有在每一步用当前估计更新权重、迭代至收敛（IRLS，见第 2 章）时，所得才是 MLE。

1.3.3 极大似然估计

- 根据样本数据，极大似然估计会找到最有可能产生样本观察值的参数值。
- 极大似然估计需要指明假设被用来描绘样本数据的一个概率密度函数。

批注 关键是如何写出这个似然函数。

基于正态分布的极大似然估计

$$
\begin{aligned}
f(y \mid \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\frac{(y-\mu)^2}{\sigma^2}}, \\
f(y_i \mid \mu_i, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\frac{(y_i-\mu_i)^2}{\sigma^2}}, \qquad \mu_i = \beta_0 + \sum_{j=1}^{m} \beta_j X_{ij}, \\
f(y_i \mid \beta_0, \dots, \beta_m, \sigma^2) &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\frac{(y_i-(\beta_0+\sum_{j=1}^{m}\beta_j X_{ij}))^2}{\sigma^2}}.
\end{aligned}
$$

y_i 被假设为相互独立的，样本观察值的联合分布可以表示为：

$$
\begin{aligned}
f(y_1, \dots, y_n \mid \boldsymbol{\beta}, \sigma^2) &= f(y_1 \mid \boldsymbol{\beta}, \sigma^2) \cdots f(y_n \mid \boldsymbol{\beta}, \sigma^2) \\
&= \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\frac{(y_i-(\beta_0+\sum_{j=1}^{m}\beta_j X_{ij}))^2}{\sigma^2}} \\
&= \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{1}{2}\sum_{i=1}^{n}\frac{(y_i-(\beta_0+\sum_{j=1}^{m}\beta_j X_{ij}))^2}{\sigma^2}}, \\
f(\mathbf{y} \mid \boldsymbol{\beta}, \sigma^2) &= \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})}{2\sigma^2}}.
\end{aligned}
$$

$\mathbf{X}$ 是 $n \times (m+1)$ 的设计矩阵：n 行对应观察对象，第 1 列为截距列（全为 1），其余 m 列为自变量取值；回归参数个数 $p = m + 1$。

概率密度函数与似然函数

$f(\mathbf{y} \mid \boldsymbol{\beta}, \sigma^2)$	参数固定时，作为 $\mathbf{y}$ 的函数，是样本的联合密度
$L(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y})$	样本 $\mathbf{y}$ 固定时，同一表达式作为参数的函数，称似然函数

$$
L(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}) = f(\mathbf{y} \mid \boldsymbol{\beta}, \sigma^2).
$$

似然函数不是参数的概率密度：它对参数积分一般不等于 1，参数在频率学派框架下也不是随机变量。有的表格中“$f(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y})$：给定样本 $\mathbf{y}$，参数 $\boldsymbol{\beta}$ 的一个函数”的写法易被误读为参数的条件密度（那是贝叶斯后验，需另设先验），故删去。

我们可以估计最大化似然函数 $L(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y})$ 的回归参数 $\boldsymbol{\beta}$，以 $\hat{\boldsymbol{\beta}}$ 表示。这些估计值被称为极大似然估计（MLE）；它们是使观测到的样本 $\mathbf{y} = (y_1, y_2, \dots, y_n)^\top$ 出现的可能性（似然）最大的参数值。

> **批注** 由样本的联合密度写出似然函数，是极大似然估计的第一步。

对数似然函数

$$
\begin{aligned}
l(\boldsymbol{\beta}, \sigma^2) = \log_e L(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}) &= -\frac{n}{2}\log_e(2\pi\sigma^2) - \frac{1}{2}\sum_{i=1}^{n}\frac{(y_i - (\beta_0 + \sum_{j=1}^{m}\beta_j X_{ij}))^2}{\sigma^2} \\
&= -\frac{n}{2}\log_e(2\pi\sigma^2) - \frac{(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})}{2\sigma^2}.
\end{aligned}
$$

$l(\beta_0, \beta_1, \dots, \beta_m, \sigma^2)$ 为对数似然函数。对任意固定的 σ^2，最大化 l 等价于最小化残差平方和，故 $\boldsymbol{\beta}$ 的 MLE 与最小二乘估计相同：

$$
\frac{\partial l}{\partial \boldsymbol{\beta}} = \frac{\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})}{\sigma^2} = \mathbf{0}, \qquad (\mathbf{X}^\top\mathbf{X})\boldsymbol{\beta} - \mathbf{X}^\top\mathbf{y} = \mathbf{0}, \qquad \hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}.
$$

再对 σ^2 求导：$\partial l/\partial\sigma^2 = -n/(2\sigma^2) + \mathrm{SSE}/(2\sigma^4) = 0$，其中 $\mathrm{SSE} = (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})$，得

$$
\widehat{\sigma}^2_{\mathrm{MLE}} = \frac{\mathrm{SSE}}{n}, \qquad s^2 = \frac{\mathrm{SSE}}{n-p}, \qquad p = m + 1 \text{ (含截距)}.
$$

由 $\mathrm{E}(\mathrm{SSE}) = (n-p)\sigma^2$（残差落在 $n-p$ 维空间中），s^2 是 σ^2 的无偏估计，而 $\widehat{\sigma}^2_{\mathrm{MLE}}$ 偏小，其期望为 $(n-p)\sigma^2/n$；n 远大于 p 时两者几乎相同。回归输出中的 “均方误差” 和系数标准误用的都是 s^2。

四格表资料 Logistic 回归的 MLE

表 9　四格表资料的一般格式

	暴露，$x=1$	非暴露，$x=0$	合计
发病，$y=1$	a	b	$a+b$
不发病，$y=0$	c	d	$c+d$
合计	$a+c$	$b+d$	$a+b+c+d$

$$
\mathrm{OR} = \frac{ad}{bc}, \qquad P_1 = \frac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}}, \qquad P_0 = \frac{e^{\alpha}}{1+e^{\alpha}}.
$$

P_1 表示暴露者中病例的比例，P_0 表示非暴露者中病例的比例。

表 10　暴露者与非暴露者发病与不发病的概率

	暴露，$x=1$	非暴露，$x=0$
发病，$y=1$	$P_1 = \dfrac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}}$	$P_0 = \dfrac{e^{\alpha}}{1+e^{\alpha}}$
不发病，$y=0$	$1-P_1 = \dfrac{1}{1+e^{\alpha+\beta}}$	$1-P_0 = \dfrac{1}{1+e^{\alpha}}$

$$
\begin{aligned}
L &= \left(\frac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}}\right)^{a}\left(\frac{e^{\alpha}}{1+e^{\alpha}}\right)^{b}\left(\frac{1}{1+e^{\alpha+\beta}}\right)^{c}\left(\frac{1}{1+e^{\alpha}}\right)^{d},\\
\ln L &= a(\alpha+\beta) - a\ln(1+e^{\alpha+\beta}) + b\alpha - b\ln(1+e^{\alpha})\\
&\quad - c\ln(1+e^{\alpha+\beta}) - d\ln(1+e^{\alpha})\\
&= a(\alpha+\beta) + b\alpha - (a+c)\ln(1+e^{\alpha+\beta}) - (b+d)\ln(1+e^{\alpha}),\\
\frac{\partial \ln L}{\partial \alpha} &= a + b - \frac{(a+c)e^{\alpha+\beta}}{1+e^{\alpha+\beta}} - \frac{(b+d)e^{\alpha}}{1+e^{\alpha}},\\
\frac{\partial \ln L}{\partial \beta} &= a - \frac{(a+c)e^{\alpha+\beta}}{1+e^{\alpha+\beta}}.
\end{aligned}
$$

令 $\partial \ln L/\partial\alpha = 0$，$\partial \ln L/\partial\beta = 0$，得：

$$
\hat{\alpha} = \ln\frac{b}{d}, \qquad \hat{\beta} = \ln\frac{ad}{bc}, \qquad \operatorname{logit}(P) = \alpha + \beta x = \ln\frac{b}{d} + \ln\frac{ad}{bc}\,x.
$$

以表 6 的数据验证。仅考虑休克 X_1，将 8 行合并为四格表：休克者死亡 27 例、存活 35 例，未休克者死亡 33 例、存活 105 例。

R

```r
ami <- data.frame(x1=rep(c(0,1),each=4), x2=rep(rep(c(0,1),each=2),2), x3=rep(c(0,1),4),
                  alive=c(35,34,17,19,17,6,6,6), dead=c(4,10,4,15,6,9,6,6))
tab <- aggregate(cbind(dead,alive)~x1, data=ami, sum)   # 按休克合并
a <- 27; c <- 35; b <- 33; d <- 105
c(log(b/d), log(a*d/(b*c)))                              # 公式
coef(glm(cbind(dead,alive)~x1, family=binomial, data=tab))   # 软件
```

```
[1] -1.1574528  0.8979416
(Intercept)          x1
 -1.1574528   0.8979416
```

公式与软件结果完全一致，OR $= e^{0.898} = 2.45$。第 2 章在模型中同时纳入 X_1、X_2、X_3 后，休克的 OR 为 3.03。两个数值的含义不同：2.45 为不考虑其他因素时休克者与未休克者死亡优势之比；3.03 为心衰状况及抢救是否及时均相同条件下的比较。由单因素到多因素分析时系数的变化，表明其他因素在两组间分布不均衡，多因素模型的作用即在于处理这一问题。

1.4 软件实现

1.4.1 SPSS 实现

- Compare means：方差分析。
- General linear model。
- Regression：线性回归、Logistic 回归。
- Survival：Cox 回归。

1.4.2 SAS 实现

PROC ANOVA、PROC REG、PROC LOGISTIC、PROC GLM、PROC GENMOD、PROC PHREG。

SAS

```
PROC GENMOD data = 数据名称;
  CLASS 分类变量的名称;
  MODEL 因变量 = 自变量 /
    dist = normal (binomial, poisson)
    link = identity (logit, log);
Run;
```

1.4.3 STATA 实现

1）导入数据。

2）Statistics、Generalized Linear models（GLM）。

3）Dependent Variables、Independent Variables。

4）family 和 link：线性回归（family: Gaussian; link: Identity）、Logistic（family: binomial; link: logit）、泊松回归（family: poisson; link: log）。

5）提交。

1.4.4 R 实现

glm() 函数。

R

```
glm(formula, family=familyname(link=function), data= )
glm(Y ~ X1+X2+X3, family=gaussian(link='identity'), data=mydata)
glm(Y ~ X1+X2+X3, family=binomial(link='logit'), data=mydata)
glm(Y ~ X1+X2+X3, family=poisson(link='log'), data=mydata)
```

以表 6 的全部三个因素为例，summary() 的输出如下，各部分的含义见后续各章。

R

```
fit <- glm(cbind(dead,alive)~x1+x2+x3, family=binomial, data=ami)
summary(fit)
exp(cbind(OR=coef(fit), confint.default(fit)))   # OR及其Wald 95%CI
```

```
Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -2.0858     0.3513  -5.938 2.88e-09 ***
x1            1.1098     0.3485   3.185  0.00145 **
x2            0.7028     0.3292   2.135  0.03275 *
x3            0.9751     0.3440   2.835  0.00458 **
(Dispersion parameter for binomial family taken to be 1)
    Null deviance: 24.4117  on 7  degrees of freedom
```

```
Residual deviance:  2.6821  on 4  degrees of freedom
AIC: 37.244
Number of Fisher Scoring iterations: 3

               OR 2.5 % 97.5 %
(Intercept) 0.124 0.062  0.247
x1          3.034 1.532  6.006
x2          2.019 1.059  3.850
x3          2.651 1.351  5.203
```

与线性回归的输出相比，有以下不同：检验统计量为 z（Wald 检验，基于大样本近似）；不报告 R^2，而报告偏差（deviance）；`Dispersion parameter ... taken to be 1` 表示二项分布的方差完全由均数决定，不另行估计；最后一行表明参数由迭代求得，本例迭代 3 次收敛。

R 公式用“~”连接响应与自变量（“=”是参数赋值，写成 `Y=X1+X2+X3` 会报错）；分布族名为 `gaussian`。二项资料可以是 0/1 向量，也可以用 `cbind(事件数，非事件数)` 作响应。

1.5 思考与练习

为了研究有关糖尿病患者体内脂联素水平的影响因素，某医师测定了 30 名患者的体重指数 BMI（kg/m^2）、病程 DY（年）、瘦素 LEP（ng/mL）、空腹血糖 FPG（mmol/L）及脂联素 ADI（ng/mL）水平，数据如表 11 所示（数据文件：glmdata1）。

表 11　脂联素水平与相关因素的测量数据

体重指数 X_1	病程 X_2	瘦素 X_3	空腹血糖 X_4	脂联素 Y	体重指数 X_1	病程 X_2	瘦素 X_3	空腹血糖 X_4	脂联素 Y
24.22	10.0	5.75	13.6	29.36	24.14	5.0	10.21	7.4	16.01
24.22	3.0	9.32	6.2	14.31	26.45	4.0	19.31	5.1	19.03
19.03	15.0	2.50	11.1	26.08	25.22	2.3	8.65	7.6	17.46
23.39	3.0	5.66	9.7	19.62	27.22	3.0	8.54	8.6	20.36
19.49	4.0	2.83	7.3	42.82	25.93	6.0	7.21	8.9	15.92
24.38	6.0	6.86	7.3	22.76	26.99	12.0	8.75	7.0	15.34
19.03	2.9	3.22	7.7	31.00	25.71	7.0	13.07	13.5	8.05
21.11	9.0	4.90	6.0	17.28	28.41	4.0	8.90	13.5	12.31
23.32	5.0	3.54	6.7	30.25	26.39	4.0	23.26	8.2	5.59
24.34	2.0	4.51	7.2	24.28	28.73	10.0	19.05	6.9	8.59
23.82	8.0	8.47	9.1	18.94	27.46	16.0	19.44	6.5	8.89
22.86	20.0	9.92	8.1	16.08	27.99	10.0	17.33	6.1	14.10
24.49	12.0	6.01	7.0	29.50	28.41	2.0	14.59	6.8	11.74
23.37	6.0	4.31	6.3	25.64	30.69	1.5	22.06	8.1	5.18
20.81	7.0	3.46	7.1	32.26	29.39	3.0	20.56	7.5	6.12

1）如何定量描述脂联素与各个影响因素之间的关系?

2）哪些因素对脂联素的影响具有统计学意义?

3）对脂联素影响最大的因素是谁?

4）如何评价模型拟合效果?

5）采用广义线性模型分析时，如何定义其因变量的分布和连接函数?

6）可以采用哪些方法进行参数估计?

阅读文献：Dekkers IA, Jansen PR, Lamb HJ. *Obesity, Brain Volume, and White Matter Microstructure at MRI: A Cross-sectional UK Biobank Study*. Radiology. 2019 Jun;291(3):763–771。并回答以下问题:

1）请阐述该研究的研究设计及分析思路。

2）总脑容量、皮质下灰质体积分别与 Total body fat（TBF）有何关系（Table 3/4）?

补充练习（推导题）

问　设 $Y \sim \text{Poisson}(\lambda)$。(1) 把概率函数写成指数族形式，指出 θ、$b(\theta)$、$a(\phi)$；(2) 由 $b(\theta)$ 求均值、方差和典型连接；(3) 若实际资料的方差约为均值的 2 倍，Poisson GLM 的点估计和标准误各受什么影响?

答　(1) $P(Y=y)=\exp\{y\log\lambda-\lambda-\log y!\}$，故 $\theta=\log\lambda$，$b(\theta)=e^{\theta}$，$a(\phi)=1$。(2) $\mathrm{E}(Y)=b'(\theta)=e^{\theta}=\lambda$，$\mathrm{Var}(Y)=b''(\theta)=\lambda$，典型连接 $g(\mu)=\log\mu$。(3) 只要均值结构 $\log\mu=\mathbf{x}^{\top}\boldsymbol{\beta}$ 正确，$\hat{\boldsymbol{\beta}}$ 仍一致（得分方程只依赖均值）；但模型方差低估了真实方差，常规标准误约偏小 $\sqrt{2}$ 倍，检验偏于宽松。可用准 Poisson（以 $\widehat{\varphi}$ 放大标准误）、稳健标准误或负二项模型（第 7 章）处理。

小结

广义线性模型的基本概念；常用的连接函数；常用的参数估计方法。

复习题

1）写出广义线性模型的三个组成部分，并分别写出 logistic 回归与 Poisson 回归中的相应内容。
答：随机部分（二项 / *Poisson* 分布）、系统部分 $\eta=\mathbf{x}^{\top}\boldsymbol{\beta}$、连接函数（*logit* / *log*）。

2）写出 Poisson 分布的方差函数，并说明其对方差齐性的意义。
答：$V(\mu)=\mu$，方差随均数增大而增大，计数资料一般不满足方差齐性。

3）四格表中 $a=27$、$b=33$、$c=35$、$d=105$，计算 logistic 回归的 $\hat{\beta}$ 与截距。
答：$\hat{\beta}=\ln(ad/bc)=0.898$，$\hat{\alpha}=\ln(b/d)=-1.157$。

4）比较正态线性模型中 σ^2 的极大似然估计与 s^2。
答：前者分母为 n，有偏（偏小）；后者分母为 $n-p$，无偏。

5）说明 Cox 回归不属于标准广义线性模型的原因。
答：其基线风险不作参数设定，采用部分似然估计，不具有“指数族分布加连接函数”的形式。

第 1 章　习题与解析

广义线性模型概述

作业题

简答题

题 1.1　标准化、共线性与正态性诊断

原反馈中的问题一并保留，供纠错练习：

1. 比较影响大小时为什么要标准化？标准化前后的 β 如何解释？
2. 什么是复相关系数？
3. 除决定系数外，如何用残差和交叉验证评价模型？
4. “考虑到变量间的强相关性，对去除 LEP 或去除 BMI 进行了相同的回归分析”，意义何在？
5. “正态性进行 K–S 检验，结果 $P < 0.001$，说明 Y 的分布为连续型变量的正态分布”，这句话有何错误？H_0 是什么？

数据分析题

题 1.2　脂联素水平的影响因素

为了研究有关糖尿病患者体内脂联素水平的影响因素，某医师测定了 30 名患者的体重指数 BMI（kg/m^2）、病程 DY（年）、瘦素 LEP（ng/mL）、空腹血糖 FPG（mmol/L）及脂联素 ADI（ng/mL）水平，数据如表 11 所示（数据文件：glmdata1）。**共 8 分**。

BMI	DY	LEP	FPG	ADI	BMI	DY	LEP	FPG	ADI
24.22	10.00	5.75	13.60	29.36	24.14	5.00	10.21	7.40	16.01
24.22	3.00	9.32	6.20	14.31	26.45	4.00	19.31	5.10	19.03
19.03	15.00	2.50	11.10	26.08	25.22	2.30	8.65	7.60	17.46
23.39	3.00	5.66	9.70	19.62	27.22	3.00	8.54	8.60	20.36
19.49	4.00	2.83	7.30	42.82	25.93	6.00	7.21	8.90	15.92
24.38	6.00	6.86	7.30	22.76	26.99	12.00	8.75	7.00	15.34
19.03	2.90	3.22	7.70	31.00	25.71	7.00	13.07	13.50	8.05
21.11	9.00	4.90	6.00	17.28	28.41	4.00	8.90	13.50	12.31
23.32	5.00	3.54	6.70	30.25	26.39	4.00	23.26	8.20	5.59
24.34	2.00	4.51	7.20	24.28	28.73	10.00	19.05	6.90	8.59
23.82	8.00	8.47	9.10	18.94	27.46	16.00	19.44	6.50	8.89
22.86	20.00	9.92	8.10	16.08	27.99	10.00	17.33	6.10	14.10
24.49	12.00	6.01	7.00	29.50	28.41	2.00	14.59	6.80	11.74
23.37	6.00	4.31	6.30	25.64	30.69	1.50	22.06	8.10	5.18
20.81	7.00	3.46	7.10	32.26	29.39	3.00	20.56	7.50	6.12

1. 如何定量描述脂联素与各个影响因素之间的关系?
2. 哪些因素对脂联素的影响具有统计学意义?
3. 对脂联素影响最大的因素是谁?
4. 如何评价模型拟合效果?
5. 采用广义线性模型分析时，如何定义其因变量的分布和连接函数?
6. 可以采用哪些方法进行参数估计?

文献分析题

题 1.3　肥胖与脑结构：文献分析

阅读 Dekkers IA, Jansen PR, Lamb HJ. *Obesity, Brain Volume, and White Matter Microstructure at MRI: A Cross-sectional UK Biobank Study*. Radiology. 2019;291(3):763–771。**共 2 分**。

1. 请阐述该研究的研究设计及分析思路。（1 分）
2. 总脑容量、皮质下灰质体积分别与 Total body fat（TBF）有何关系（Table 3/4）？（1 分）

Table 3: Multiple Linear Regression Results for Total Body Fat and Global Brain Volumes

	Brain Volume		Gray Matter		White Matter		Brain Stem		CSF	
Adjusted TBF	β Value	*P* Value	β Value	*P* Value	β Value	*P* Value	β Value	*P* Value	β Value	*P* Value
Women	.04 (.02, .06)	.001	.03 (.01, .05)	.02	.05 (.02, .07)	≤.001*	−.01 (−.04, .02)	.36	−.02 (−.05, 0)	.07
Men	−.01 (−.04, .02)	.52	−.06 (−.09, −.03)	<.001*	.03 (0, .06)	.05	−.10 (−.13, -.06)	<.001*	.07 (.04, .11)	.001*

Note.—Data in parentheses are 95% confidence intervals; *P* values are uncorrected. Study sample consisted of 12 087 participants (6381 women and 5706 men). Standardized regression coefficients reflect the standard deviation change in regional brain volume per standard deviation (6.5% in women and 5.5% in men) change in total body fat. *P* for interaction of total body fat and sex, in adjusted model, <.001. Adjusted model included age, ethnicity, Townsend deprivation index, assessment center (baseline visit and imaging visit), smoking status, alcohol use, diabetes, cardiovascular disease, and intracranial volume. CSF = cerebral spinal fluid, TBF = total body fat.

* Significant after false discovery rate correction (threshold false discovery rate *P* = .02).

Table 4: Multiple Linear Regression Results for Total Body Fat and Subcortical Gray Matter Volumes

	All		Thalamus		Caudate Nucleus		Putamen		Globus Pallidus		Hippocampus		Amygdala		Nucleus Accumbens	
Adjusted TBF	β Value	*P* Value	β Value	*P* Value	β Value	*P* Value	β Value	*P* Value	β Value	*P* Value	β Value	*P* Value	β Value	*P* Value	β Value	*P* Value
Women	−.01 (−.04, .02)	.23	−.01 (−.03, .02)	.55	−.01 (−.04, .02)	.38	−.03 (−.05, 0)	.03	−.06 (−.09, −.03)	<.001*	0 (−.03, .03)	.93	.03 (0, .06)	.06	.01 (−.02, .03)	.69
Men	−.11 (−.14, −.07)	<.001*	−.10 (−.13, −.06)	<.001*	−.07 (−.11, −.03)	<.001*	−.08 (−.11, −.04)	<.001*	−.13 (−.17, −.10)	<.001*	−.07 (−.11, −.04)	<. 001*	−.02 (−.06, .02)	.38	−.13 (−.17, −.10)	.001*

Note.—Data in parentheses are 95% confidence intervals; *P* values are uncorrected. Study sample consisted of 12 087 participants (6381 women and 5706 men). Standardized regression coefficients reflect the standard deviation change in regional brain volume per standard deviation (6.5% in women and 5.5% in men) change in total body fat. *P* for interaction of total body fat and sex, in adjusted model, <.001. Adjusted model included age, ethnicity, Townsend deprivation index, assessment center (baseline visit and imaging visit), smoking status, alcohol use, diabetes, cardiovascular disease, and intracranial volume. TBF = total body fat.

* Significant after false discovery rate correction (threshold false discovery rate *P* = .023).

往年题

单项选择题

题 1.4　自变量缩放与回归系数

在含截距的多重线性回归中，将每个自变量 X_j 改写为 $X_j^* = cX_j$，其中 $c > 0$。重新拟合后，偏回归系数与标准化偏回归系数如何变化？

A. 偏回归系数乘以 c，标准化偏回归系数不变。

B. 偏回归系数除以 c，标准化偏回归系数不变。

C. 二者均除以 c。

D. 二者均保持不变。

E. 偏回归系数不变，标准化偏回归系数乘以 c。

题 1.5　复相关系数等于 1

在含截距且总平方和非零的多重线性回归中，复相关系数为 1，以下哪项成立？

A. $SS_{\text{残差}} = SS_{\text{总}}$。

B. $SS_{\text{回归}} = SS_{\text{总}}$。

C. $MS_{\text{残差}} = MS_{\text{总}}$。

D. $SS_{\text{回归}} = 0$。

E. $SS_{\text{残差}} < 0$。

题 1.6　连接函数的作用对象

广义线性模型中，连接函数 g 通常将哪一项与线性预测子 $X_i^T\beta$ 联系起来？

A. 每一个观测值 Y_i 本身。

B. 条件均值 $\mu_i = E(Y_i \mid X_i)$。

C. 每一个残差的平方。

D. 所有自变量的算术均数。

E. 回归系数的样本方差。

名词解释

题 1.7　连接函数

解释：连接函数。

题 1.8　拟合优度检验

解释：拟合优度检验。

题 1.9　广义线性模型（Generalized Linear Models, GLM）

名词解释：广义线性模型（Generalized Linear Models, GLM）。

题 1.10　连接函数（Link function）

名词解释：连接函数（Link function）。

题 1.11　拟合优度检验（Goodness of Fit Test）

名词解释：拟合优度检验（Goodness of Fit Test）。

简答题

题 1.12　共线性的影响与识别

什么是共线性？在进行广义线性模型分析时如果存在较严重的共线性，对分析结果会有什么影响？在进行 Cox 回归分析时，如何识别是否存在严重的共线性？

题 1.13　三种参数估计方法

列举广义线性模型常用的 3 种参数估计方法，并简述其基本思想。

题 1.14　GLM 的三个组成部分

简述广义线性模型（GLM）的三个组成部分及其作用。

文献分析题

题 1.15　自选文献评述

每次都留了作业文献评述的作业，请你自选一篇提交。

补充练习

> **说明**
>
> 以下为配合正文新编的补充练习，按题型编排。教学设定的数据不代表真实研究结果；解析见章末。

单项选择题

题 1.16　加权最小二乘的权重

某线性回归的均值结构设定正确，各观察相互独立，但误差方差不齐。已知甲、乙两条观察的条件误差方差分别为 4 和 9。按正文的加权最小二乘原则，甲与乙的权重之比应为：

A. 4/9。

B. 2/3。

C. 3/2。

D. 9/4。

E. 1。

名词解释

题 1.17　似然函数

名词解释：似然函数（Likelihood function）。

简答题

题 1.18　正态线性模型中的两种估计

设各观察相互独立，$Y_i \mid X_i \sim N(X_i^T\beta, \sigma^2)$，其中 σ^2 为共同方差，设计矩阵满列秩。简述为什么极大似然估计与最小二乘估计给出相同的回归系数。若改为已知且不相等的方差 σ_i^2，相应目标函数如何变化？

计算与综合分析题

题 1.19　从四格表写出似然与模型

一项教学队列的固定随访期内，某二分类结局的频数如下。假定个体相互独立，同一暴露组内事件概率相同。

	发生事件	未发生事件
暴露组（$X=1$）	30	70
非暴露组（$X=0$）	10	90

设 $\operatorname{logit}(p_x)=\alpha+\beta x$。

1）写出似然函数及对数似然函数，可略去与参数无关的常数。

2）求 $\hat{p}_0,\hat{p}_1,\hat{\alpha},\hat{\beta}$，并写出拟合方程。

3）分别求 OR 与两组事件概率之比，说明二者是否相同。

本次补充习题

本组按正文章节补充 10 题，题型沿用原笔记；解析及来源与新增题号对应。

第 1 章补充：广义线性模型基本概念与方法

单项选择题

每题只有一个最佳答案，请从 A—E 中选择。

题 1.20　比例响应中的试验次数权重

甲、乙两组分别有 20 人和 80 人，各人独立发生某事件的概率均为 $p = 0.25$。令 S_i 为组内事件数，$Y_i = S_i/n_i$ 为比例。以 Y_i 作为二项 GLM 的响应时，下列哪项正确？

A. 甲、乙比例的条件方差相同，均为 0.1875。

B. 甲的比例方差为乙的 4 倍；比例响应应分别给权重 20 和 80。

C. 乙的比例方差为甲的 4 倍；人数应作为待估协变量。

D. 只要使用 logit 连接，软件不需要知道 n_i。

E. 把两个组的比例各重复一次，即可保留全部 100 人的二项信息。

题 1.21　线性预测子中的二次项

设相互独立的计数 $Y_i \mid x_i \sim \text{Poisson}(\mu_i)$，并指定 $\log \mu_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2$。关于该模型，下列哪项正确？

A. 含 x^2，所以必定不属于 GLM。

B. 必须先检验 x^2 服从正态分布。

C. 只要 $\beta_2 \neq 0$，就没有线性预测子。

D. $\exp(\beta_1)$ 始终是任意起点增加 1 单位的均值比。

E. 它属于 GLM；对参数线性与对原始 x 呈曲线并不矛盾。

题 1.22　由累积量函数恢复均值和方差

某指数分布族写为 $f(y;\theta,\phi) = \exp\{[y\theta - b(\theta)]/\phi + c(y,\phi)\}$，其中 $b(\theta) = -\log(-\theta)$、$\theta < 0$、$\phi > 0$。已知 $\mu = b'(\theta)$、$\text{Var}(Y) = \phi b''(\theta)$。以下哪组结论正确？

A. $\mu = 1/\theta$，$\text{Var}(Y) = \phi\mu^2$。

B. $\mu = -1/\theta$，$\text{Var}(Y) = \phi\mu$。

C. $\mu = -1/\theta$，典型连接为 $\log\mu$。

D. $\mu = -1/\theta$，$\text{Var}(Y) = \phi\mu^2$，典型连接为 $-1/\mu$。

E. $\mu = -1/\theta$，$\text{Var}(Y) = \phi/\mu^2$。

题 1.23　统一缩放相对精度权重

设 $\mathrm{Var}(Y_i \mid X) = \sigma^2 / w_i$，$w_i > 0$ 仅给出相对精度，σ^2 未知。均值为 $X\beta$，采用加权最小二乘拟合。设计矩阵 X 满列秩，p 为含截距的参数数目，且 $n > p$；拟合后用 $\hat{\sigma}^2 = \sum_i w_i (y_i - \hat{\mu}_i)^2 / (n - p)$ 及 $\widehat{\mathrm{Cov}}(\hat{\beta}) = \hat{\sigma}^2 (X^T W X)^{-1}$。若把所有 w_i 同时乘以 7 并重新估计尺度，下列哪项正确？

A. 回归系数和上述协方差估计均不变。

B. 回归系数不变，协方差必定缩小为 1/7。

C. 回归系数缩小为 1/7，协方差不变。

D. 回归系数和协方差均乘以 7。

E. 样本量和残差自由度都自动乘以 7。

题 1.24　相同线性预测值与不同逆连接

甲、乙分别使用二项 logit 和 probit 连接。对某一协变量组合，两模型都给出 $\hat{\eta} = 1$。已知 $\Phi(1) = 0.8413$。下列解释正确的是：

A. 两模型的事件概率均为 1。

B. 两模型的事件概率均为 0.7311。

C. 甲约 0.7311、乙约 0.8413；两模型的同名系数不能直接按同一种 OR 解释。

D. 甲约 0.8413、乙约 0.7311。

E. 两者均可不经逆连接，直接把 e^1 解释为事件概率。

题 1.25　含截距 Poisson 模型的得分性质

对相互独立的计数拟合普通、无惩罚的 Poisson log 连接模型；先验权重均为 1，包含可自由估计的截距，MLE 有限且处于参数空间内部。判断：

I. 拟合后 $\sum_i (y_i - \hat{\mu}_i) = 0$。

II. 拟合后 Pearson 残差之和 $\sum_i (y_i - \hat{\mu}_i) / \sqrt{\hat{\mu}_i} = 0$ 必成立。

III. 加入已知 offset、仍保留自由截距时，命题 I 仍成立。

A. 仅 I。

B. 仅 II。

C. I 和 II。

D. II 和 III。

E. I 和 III。

简答、计算与案例分析

题 1.26　先验权重与工作权重为何不同

对二项比例 $Y_i = S_i/n_i$ 拟合 logit 模型。一位同学发现软件保存了两组权重：试验次数 n_i，以及迭代中的 $n_i\pi_i(1-\pi_i)$。他认为‘比例方差在 π_i 接近 0 或 1 时较小，所以第二组权重反而变小一定是程序错误’。请说明两组权重的对象和作用，并解释上述推断为什么不成立。可以使用 Delta 近似，不必证明算法收敛。

题 1.27　Dobson 案例：由 glm 输出还原模型

R 官方 `glm` 示例给出 Dobson（1990，第 93 页）的以下 9 格频数。此题按官方示例将格数作为 Poisson 响应；讨论的是该拟合的参数化，不另行改变抽样方案。

处理组	结局类别 1	结局类别 2	结局类别 3
1	18	17	15
2	20	10	20
3	25	13	12

以两个因子的第 1 水平为参照，按下列调用的定义独立复算，系数整理如下（非本机 R 运行截图）：

```
fit <- glm(counts ~ outcome + treatment,
           family = poisson("log"), data = d)
```

参数	估计	标准误
截距	3.044522	0.170899
outcome2	-0.454255	0.202171
outcome3	-0.292987	0.192742
treatment2	0.000000	0.200000
treatment3	0.000000	0.200000

1) 写出随机部分、系统部分和连接函数，说明此处一条响应记录是什么。
2) 求‘处理组 2、结局类别 2’的线性预测值、条件均值及模型条件方差。
3) 计算设计矩阵秩和残差自由度，解释为什么不能以 150 减参数数目来填该调用的残差自由度。
4) 所有处理系数为 0 能否推出每个观察格数等于拟合格数？求该格的响应残差，并说明 `predict(fit)` 与 `predict(fit,type="response")` 的区别。

题 1.28　完成一次二项 IRLS 更新

教学数据如下，各组内个体独立、组间独立。设 $S_i \sim \mathrm{Bin}(n_i, \pi_i)$，$\mathrm{logit}(\pi_i) = \beta_0 + \beta_1 x_i$。

组别	x_i	n_i	S_i
1	0	10	1
2	1	10	4
3	2	10	8

从 $\beta^{(0)} = (0,0)^T$ 开始，记 $Y_i = S_i/n_i$，使用

$$z_i = \eta_i + \frac{Y_i - \pi_i}{\pi_i(1-\pi_i)}, \quad w_i = n_i \pi_i (1-\pi_i), \quad \beta^{\text{new}} = (X^T W X)^{-1} X^T W z.$$

1) 求初始 π_i、z_i 及 W。
2) 写出 $X^T W X$ 与 $X^T W z$，求第一次更新的 $\beta^{(1)}$。
3) 求更新后的三个概率，并计算得分 $U = X^T(S - n\pi^{(1)})$。此次更新是否已经达到 MLE？下一轮应更新什么？

题 1.29　对数响应回归与 log 连接 GLM

某研究者用教学设定说明正值连续生物标志物的回归，模型为

$$\log Y = 1 + 0.4x + \varepsilon, \qquad \varepsilon \mid x \sim N(0, 0.36), \quad x \in \{0,1\}.$$

他写道：‘连接函数是 log，因此 $E(Y \mid x) = \exp(1 + 0.4x)$；这与任意 log 连接 GLM 完全相同。由于 Y 均为正数，也可以直接指定 Poisson 分布。’已知正态变量满足 $E(e^{\varepsilon}) = e^{0.36/2}$。

1) 指出响应变换与均值连接的区别，分别求 $x = 0, 1$ 时 Y 的条件均值和中位数。
2) 在本题方差设定下，$e^{0.4}$ 是否等于两个条件均值之比？若对数尺度方差随 x 变化，结论是否仍必然成立？
3) 评价‘正数即可用 Poisson’及‘任意 log 连接 GLM 完全相同’两句，并说明应补报哪些模型信息。

习题解析

核对方式

按题号核对。缺失选项的补写及新编练习均在对应解析末尾说明。

作业题

解析 题 1.1　标准化、共线性与正态性诊断

返回题目

（1）标准化消除计量单位影响；$\beta_j^* = \beta_j s_{X_j}/s_Y$，表示控制其他变量时 X_j 增加 1 个标准差，Y 均值改变多少个标准差。比较幅度看绝对值。（2）$R = \sqrt{R^2}$，衡量 Y 与一组解释变量的线性关联。（3）检查残差模式、极端点及模型前提；交叉验证评估样本外预测误差。（4）检查共线性造成的系数不稳定与敏感性，但删变量应结合研究目标和混杂控制。（5）若 H_0 为服从所检验的正态分布，$P < 0.001$ 反而提供反对 H_0 的证据。回归中正态假定通常针对条件误差；估计了分布参数时不能直接套用普通 K–S 的临界分布。

解析 题 1.2　脂联素水平的影响因素

返回题目

(1) 建模与解释，1.5 分。令 X_1 为 BMI，X_2 为 DY，X_3 为 LEP，X_4 为 FPG，以 ADI 为因变量：

$$\widehat{\mathrm{ADI}} = 58.199 - 1.030X_1 - 0.131X_2 - 0.811X_3 - 0.579X_4.$$

偏回归系数表示其他自变量固定时，该自变量增加一个单位所对应的 ADI 条件均值改变量。

（2）系数检验，1.5 分；（3）影响幅度，1 分。 原评分表如下：

变量	系数	标准误	t	P	标准化系数
BMI	−1.02978	0.530217	−1.94	0.063	−0.34312
DY	−0.13113	0.211292	−0.62	0.540	−0.06653
LEP	−0.81130	0.252699	−3.21	0.004	−0.56620
FPG	−0.57873	0.447498	−1.29	0.208	−0.13939

在 $\alpha = 0.05$ 下，仅 LEP 系数有统计学意义。标准化系数**绝对值**以 LEP 最大；不能直接比较带不同量纲的原始系数。

（4）拟合，1.5 分。 $R^2 = 0.7312$，$R = 0.8551$，$R^2_{\mathrm{adj}} = 0.6882$；

$$R^2_{\mathrm{adj}} = 1 - (1 - R^2)\frac{n-1}{n-p-1}.$$

还应检查线性、独立性、残差正态性和方差齐性，必要时以交叉验证评估预测误差。

(5) 随机部分与连接，1 分。本例可先采用正态条件分布和恒等连接 $g(\mu) = \mu$；须用诊断评价是否合适。常见组合：正态—恒等、二项—logit、泊松—log、Gamma—倒数、逆高斯—$1/\mu^2$（典型连接的常数/符号可吸收到参数中）。变量连续并不自动意味着正态。

（6）估计，1.5 分。最小二乘使残差平方和最小；加权最小二乘使 $\sum w_i(y_i-\mu_i)^2$ 最小，常取 $w_i \propto 1/\sigma_i^2$；极大似然使观测数据的似然最大。原评分稿根据残差图建议加权最小二乘或极大似然。

校正。图形只能提示异方差；极大似然本身不会自动消除异方差，需正确指定方差结构。Gauss–Markov 最优线性无偏性并不要求误差正态。

解析 题 1.3　肥胖与脑结构：文献分析

返回题目

（1） 横断面研究；数据来自 UK Biobank，并不因此成为此分析的前瞻性研究。暴露为肥胖指标 BMI/TBF，结局为 MRI 脑容量和结构指标。描述连续变量的均值、标准差或四分位数，分类变量用百分比；采用多重线性回归，报告标准化系数，调整年龄、种族、社会剥夺、中心、吸烟、饮酒、糖尿病和心血管病等因素，并检验 TBF 与性别的交互作用。

（2） Table 3 中女性总脑容量、灰质和白质体积与 TBF 呈正向关联；男性灰质和脑干体积呈负向关联，脑脊液体积呈正向关联。必须结合表中 P 值和多重比较阈值，而不是只看系数正负。Table 4 中男性除杏仁核外多项皮质下灰质体积均呈负向关联；女性以苍白球负向关联最明确。苍白球关联的性别差异 $P < 0.001$（原评分稿）。

答题边界。这是调整后的统计关联，不宜写成“脂肪增加导致脑体积改变”。对每项结果均说明性别、参照/单位、方向及统计学证据。

往年题

解析 题 1.4　自变量缩放与回归系数

返回题目

答案：B。

对 $X_j' = cX_j$ 且 $c \neq 0$，$b_j' = b_j/c$。若 $c > 0$，标准化偏回归系数不变；若 $c < 0$，其符号反转而绝对值不变。$c = 0$ 时丢失变量信息，不适用上述等价变换。通常选择题默认 $c > 0$。

补写说明。原稿未记选项；选项为补写，并明确了常数为正的条件。

解析 题 1.5　复相关系数等于 1

返回题目

答案：B。

在含截距且总平方和非零的通常回归情形下，$R^2 = 1$，所以残差平方和为 0，回归平方和等于总平方和。

补写说明。原稿 A—C 保留；D、E 为补写，并明确总平方和非零。

解析 题 1.6　连接函数的作用对象

返回题目

答案：B。

GLM 满足 $g(\mu_i) = X_i^T\beta$，连接作用于条件均值，而不是直接作用于观测值。

补写说明。原稿第 11 题整题缺失；本题为围绕课程知识点新编的练习，并非恢复的往年原题。

解析　题 1.7　连接函数　　返回题目

将因变量的条件均值 $\mu_i = E(Y_i \mid X_i)$ 与线性预测子 $\eta_i = X_i^T\beta$ 联系起来的函数：$g(\mu_i) = \eta_i$。连接作用于均值，不是对观测值直接作同样变换。

解析　题 1.8　拟合优度检验　　返回题目

评价所指定模型与观测数据之间的不一致是否超出随机变异可以解释的范围。例如分组 Logistic 的 Pearson/偏差检验、Hosmer–Lemeshow 检验。P 值大只能表示未发现明显失拟；总体回归系数检验是比较含协变量模型与零模型，不能直接等同于绝对拟合优度检验。

解析　题 1.9　广义线性模型（Generalized Linear Models, GLM）　　返回题目

用随机部分、系统部分与连接函数推广普通线性回归的模型框架。随机部分通常为指数分布族；$\eta = X^T\beta$；$g\{E(Y \mid X)\} = \eta$。

解析　题 1.10　连接函数（Link function）　　返回题目

连接条件均值 μ 与线性预测子 η 的函数 g，满足 $g(\mu) = \eta$，例如 logit、log 与恒等连接。

解析　题 1.11　拟合优度检验（Goodness of Fit Test）　　返回题目

检验模型预测与观测的不一致是否超过随机变异可以解释的范围。模型与饱和模型的偏差、分组 Pearson 或 HL 检验可用于特定情形。拟合优度与协变量的总体显著性、预测区分度应区分。

解析　题 1.12　共线性的影响与识别　　返回题目

共线性指解释变量之间存在精确或近似线性关系。完全共线性使参数不能唯一估计；严重近似共线性会放大标准误、扩大置信区间，使系数大小和符号对数据或变量组合敏感，个别检验效能下降。

Cox 模型中检查设计矩阵的相关结构、秩、条件数和 VIF/GVIF。对一个数值变量，$\mathrm{VIF}_j = 1/(1 - R_j^2)$，其中 R_j^2 来自该变量对其余解释变量的辅助回归。多自由度因子应结合 $\mathrm{GVIF}^{1/(2df)}$，不能将未调整 GVIF 与单一 VIF 混用。5 或 10 是经验警戒值，不是严格判据。PH 检验与共线性诊断解决不同问题。

解析　题 1.13　三种参数估计方法　　返回题目

按课程口径：最小二乘、加权最小二乘、极大似然。分别最小化残差平方和、带权残差平方和，以及最大化似然。普通 GLM 通常以极大似然估计，并通过迭代加权最小二乘求解；Cox 模型通常使用偏似然。详见题 1.2（6）。

解析　题 1.14　GLM 的三个组成部分　　返回题目

随机部分指定 $Y \mid X$ 的概率分布及方差结构；系统部分为 $\eta_i = \beta_0 + \sum_j \beta_j x_{ij}$；连接函数令 $g(\mu_i) = \eta_i$，使不同类型结局的条件均值能用线性预测子描述。

解析 题 1.15　自选文献评述

返回题目

开放题，无唯一标准答案。可选本章题 1.3 的文献，依次写研究问题、人群与设计、暴露/结局/协变量、模型选择依据、关键估计值及置信区间、偏倚与局限。也可选题 2.2 或题 3.2，但须围绕所选文章展开，而非拼接模型定义。原材料对本题只有题干，未附评述正文。

补充练习

解析 题 1.16　加权最小二乘的权重

返回题目

答案：D。权重与条件误差方差的倒数成正比，故

$$\frac{w_{\text{甲}}}{w_{\text{乙}}} = \frac{1/4}{1/9} = \frac{9}{4}.$$

这里取的是**方差**的倒数，不是标准差的倒数；方差较大的观察获得较小权重。

解析 题 1.17　似然函数

返回题目

给定已经观察到的样本，将其联合概率质量函数或联合概率密度函数看成未知参数的函数，称为似然函数。独立观察时，

$$L(\theta; y_1, \dots, y_n) = \prod_{i=1}^{n} f(y_i; \theta).$$

样本值固定，参数变化；使该函数最大的参数值为极大似然估计。似然函数不应解释为“给定样本后参数的概率分布”。

解析 题 1.18　正态线性模型中的两种估计

返回题目

同方差正态模型的对数似然为

$$\ell(\beta, \sigma^2) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(y_i - X_i^T\beta)^2.$$

对任一固定的正方差，最大化对数似然等价于最小化残差平方和；共同方差未知时，联合极大化所得 $\hat{\beta}$ 也相同。满列秩保证通常最小二乘解唯一。

若各 σ_i^2 已知且不等，关于 β 需最小化的部分变为

$$\sum_i \frac{(y_i - X_i^T\beta)^2}{\sigma_i^2},$$

即以 $1/\sigma_i^2$ 为权重的加权最小二乘。这里比较的是**回归系数**的估计，不是在说方差的极大似然估计与无偏估计相同。

解析　题 1.19　从四格表写出似然与模型　　返回题目

(1) 令 $p_0 = e^{\alpha}/(1+e^{\alpha})$、$p_1 = e^{\alpha+\beta}/(1+e^{\alpha+\beta})$，则

$$L \propto p_1^{30}(1-p_1)^{70}p_0^{10}(1-p_0)^{90},$$

$$\ell = 30(\alpha+\beta) + 10\alpha - 100\log(1+e^{\alpha+\beta}) - 100\log(1+e^{\alpha}) + C.$$

(2) 两组各有一个可自由估计的概率，因此 $\hat{p}_0 = 0.10$、$\hat{p}_1 = 0.30$。

$$\hat{\alpha} = \log\frac{10}{90} = -2.1972, \qquad \hat{\beta} = \log\frac{30\times 90}{70\times 10} = 1.3499.$$

拟合方程为 $\operatorname{logit}(\hat{p}_x) = -2.1972 + 1.3499x$。

(3) $\widehat{\mathrm{OR}} = 27/7 = 3.8571$，事件概率之比为 $0.30/0.10 = 3$。两者不同，因为 OR 比较的是 $p/(1-p)$。本题为固定随访期队列的完整频数，可直接算概率；不能把同样做法无条件套到按病例、对照抽样的研究。

本次补充习题解析

第 1 章补充解析

解析　题 1.20　比例响应中的试验次数权重

返回题目

答案：B。 比例的条件方差为 $p(1-p)/n_i$，故甲、乙分别为 0.009375 和 0.00234375，前者是后者的 4 倍。采用比例响应时，试验次数 n_i 应作为二项模型的先验权重；也可使用两列事件数和非事件数响应。事件数的方差则为 $n_i p(1-p)$，方向恰与比例方差的比较相反。不能把每组都当作一次 Bernoulli 观察。

来源与改编：知识点配套。题干与设问为新编；参考依据[1]、[2]、[3]。

解析　题 1.21　线性预测子中的二次项

返回题目

答案：E。 系统部分对未知参数 $(\beta_0, \beta_1, \beta_2)$ 仍为线性，设计矩阵的三列是 $1, x, x^2$，故属于 Poisson GLM。GLM 的‘线性’不要求均值是 x 的直线，也不要求 x 或 x^2 服从正态分布。包含二次项时，x 增加 1 的均值比为 $\exp\{\beta_1 + \beta_2(2x+1)\}$，一般随起始 x 变化。

来源与改编：知识点配套。题干与设问为新编；参考依据[1]、[2]。

解析　题 1.22　由累积量函数恢复均值和方差

返回题目

答案：D。 求导得 $b'(\theta) = -1/\theta$、$b''(\theta) = 1/\theta^2$，故 $\mu = -1/\theta > 0$，$\mathrm{Var}(Y) = \phi\mu^2$。按题干的自然参数约定，典型连接为 $g(\mu) = \theta = -1/\mu$；负号可吸收入回归系数，教材常写作倒数连接。例如 $\theta = -0.5, \phi = 0.25$ 时，均值为 2、方差为 1。log 连接也可用于 Gamma 均值建模，但不因此成为本参数化的典型连接。

来源与改编：知识点配套。题干与设问为新编；参考依据[1]、[3]。

解析　题 1.23　统一缩放相对精度权重

返回题目

答案：A。 新估计为 $(X^T 7WX)^{-1} X^T 7Wy = \hat{\beta}$；新的残差尺度估计变为 $7\hat{\sigma}^2$，而逆信息矩阵变为 $(X^T WX)^{-1}/7$，两者相抵，所以协方差估计不变。这是相对精度的归一化变化，并未增加独立受试者。若已知绝对方差并固定尺度，或把权重解释为真正复制观测，结论需要另行讨论。

来源与改编：知识点配套。题干与设问为新编；参考依据[1]、[4]。

解析　题 1.24　相同线性预测值与不同逆连接

返回题目

答案：C。 甲的概率为 $e/(1+e) = 0.7311$，乙的概率为 $\Phi(1) = 0.8413$。相同线性预测值只有在相同连接函数下才对应相同概率。$\exp(\beta)$ 的 OR 解释来自 logit 连接；probit 系数的指数一般不是固定的优势比，也不能把 η 本身当概率。

来源与改编：知识点配套。题干与设问为新编；参考依据[1]、[3]、[5]。

解析　题 1.25　含截距 Poisson 模型的得分性质

返回题目

答案：E。截距的得分为 $\partial \ell/\partial \beta_0 = \sum_i (y_i - \mu_i)$，内部极大点令其为 0。已知 offset 只改变 μ_i 的数值，不改变线性预测子对截距的导数 1，故 III 也正确。Pearson 残差额外除以不等的 $\sqrt{\hat{\mu}_i}$，其和没有一般的零约束。加惩罚、去掉截距或使用不同先验权重时，应重新写得分方程，不能机械套用。

来源与改编：知识点配套。题干与设问为新编；参考依据[1]、[2]。

解析　题 1.26　先验权重与工作权重为何不同

返回题目

n_i 是二项比例表示中的先验权重，保存试验次数，使 $\mathrm{Var}(Y_i) = \pi_i(1-\pi_i)/n_i$。IRLS 拟合的是当前工作响应

$$z_i = \eta_i + \frac{Y_i - \pi_i}{\pi_i(1-\pi_i)},$$

不是直接对原比例作固定权重回归。按局部线性化，

$$\mathrm{Var}(z_i) \approx \frac{1}{n_i \pi_i (1-\pi_i)}, \qquad w_i^{\mathrm{work}} = n_i \pi_i (1-\pi_i).$$

在概率边界附近，logit 变换的导数绝对值很大，放大了概率尺度上的波动；工作权重下降与原比例方差下降并不矛盾。先验权重由已知组大小决定，工作权重随当前拟合概率更新。R 中可分别查看 `weights(fit,type="prior")` 和 `weights(fit,type="working")`。

来源与改编：知识点配套。题干与设问为新编；参考依据[1]、[2]、[3]。

解析　题 1.27　Dobson 案例：由 glm 输出还原模型

返回题目

(1) 模型。 按题设的 Poisson 拟合，$N_{ot} \sim \mathrm{Poisson}(\mu_{ot})$，

$$\log \mu_{ot} = \beta_0 + \beta_{O2} I(o=2) + \beta_{O3} I(o=3) + \beta_{T2} I(t=2) + \beta_{T3} I(t=3).$$

随机部分为 Poisson 分布、系统部分为上述五列设计、连接为 log。每条响应是一个处理 × 结局组合的格数；150 是总频数。

(2) 预测。 该格 $\hat{\eta} = 3.044522 - 0.454255 + 0 = 2.590267$，$\hat{\mu} = e^{2.590267} \approx 13.3333$。Poisson 模型条件方差也为 13.3333，模型条件标准差为 $\sqrt{13.3333} \approx 3.6515$；它们不等于回归系数的标准误。

(3) 自由度。 9 个格数响应、设计矩阵秩 $1+2+2=5$，故残差自由度 $9-5=4$。150 不能替代该 Poisson 调用的响应记录数；改变个体/汇总数据的表示及似然后，必须重新说明统计对象。

(4) 残差与尺度。 该格观察值为 10，响应残差 $10 - 13.3333 = -3.3333$。处理系数为 0 表示模型中处理组间的拟合格数比为 1，并不保证每格残差为 0；拟合后的三个结局格数分别为 21、40/3 和 47/3，各处理组相同。默认 `predict(fit)` 返回 $\hat{\eta}$，`type="response"` 返回 $\hat{\mu}$。

来源与改编：案例改编。材料及改编范围见[2]、[5]、[1]。

解析 题 1.28　完成一次二项 IRLS 更新

返回题目

（1）工作量。 初始 $\eta_i = 0$，所以 $\pi_i = 0.5$；$z = (-1.6, -0.4, 1.2)^T$，$W = 2.5 I_3$。

（2）更新。 X 的三行为 $(1,0), (1,1), (1,2)$，从而

$$X^T W X = \begin{pmatrix} 7.5 & 7.5 \\ 7.5 & 12.5 \end{pmatrix}, \quad X^T W z = \begin{pmatrix} -2 \\ 5 \end{pmatrix}, \quad \beta^{(1)} = \begin{pmatrix} -1.6667 \\ 1.4000 \end{pmatrix}.$$

（3）尚未收敛。 更新后的线性预测值与概率约为

$$\eta^{(1)} = (-1.6667, -0.2667, 1.1333)^T,$$

$$\pi^{(1)} = (0.158869, 0.433726, 0.756454)^T.$$

代入得 $U \approx (-0.49048, 0.53367)^T \neq 0$，故不能把第一次 WLS 更新当成最终 MLE。下一轮使用新的 η, π 重新计算 z, W 并继续求解，直到数值收敛。所附脚本的最终 $\hat\beta = (-2.197225, 1.791759)^T$，并核对最终得分为 0。本数据的三个经验概率恰可落在同一条 logit 直线上，这只是本组数值的巧合，不意味着两参数模型总能拟合任意三个比例。

来源与改编：知识点配套。题干与设问为新编；参考依据[1]、[2]、[3]。

解析 题 1.29　对数响应回归与 log 连接 GLM

返回题目

（1）反变换。 给出的式子建模的是 $\log Y$ 的条件均值；不能交换期望与非线性指数函数。条件中位数为 $e^{1+0.4x}$，条件均值为 $e^{1+0.4x+0.18}$。$x = 0$ 时二者分别为 2.7183 和 3.2544；$x = 1$ 时分别为 4.0552 和 4.8550。log 连接 GLM 直接指定的是 $\log E(Y \mid x) = \eta(x)$，还必须另给条件分布/方差结构。

（2）均值比。 本题共同对数方差为 0.36，反变换因子相消，所以均值比仍为 $e^{0.4} = 1.4918$。若 $\mathrm{Var}(\varepsilon \mid x) = \sigma_x^2$，均值比应为 $\exp\{0.4 + (\sigma_1^2 - \sigma_0^2)/2\}$，未必仍等于 $e^{0.4}$。

（3）模型信息。 Poisson 响应是非负整数计数；正值连续浓度不满足这个取值范围，不能只因‘正数’采用它。例如 Gamma log 连接与对数正态回归可拥有相似的均值形式，但完整条件分布和似然不同。应报告原始响应及单位、是否先取对数、条件分布、连接、方差/尺度设定、反变换方法，并用适当残差和预测表现评价拟合。

来源与改编：知识点配套。题干与设问为新编；参考依据[1]、[3]、[6]。

第 2 章

Logistic 回归模型（一）

主要内容

1）Logistic 回归的基本概念、非条件 Logistic 回归。
2）配比设计资料的条件 Logistic 回归分析。
3）多分类结局资料的 Logistic 回归分析。
4）有序分类结局资料的 Logistic 回归分析。
5）Logistic 回归模型的正确应用及软件实现。

2.1 Logistic 回归的基本概念

Logistic 回归是医学研究中最常用的多因素分析方法之一。理解该模型的关键在于对数优势尺度：模型在 logit 尺度上是线性、可加的，系数为对数 OR；换算到概率尺度后，同一 OR 对应的概率差随基线水平而变化。将 OR 等同于 RR、将 OR 为 3 表述为死亡率增加 3 倍等常见错误，均源于两种尺度的混淆。

本章另一重点是统计推断。参数由迭代求得，检验与区间估计依赖大样本近似，Wald 检验、似然比检验与比分检验三者并存，了解其来源有助于在小样本或稀疏数据时作出选择。最后一节的条件 logistic 回归用于配对设计，其基本思想是通过条件化消去对子参数，这一思想在第 5 章的 Cox 回归中再次出现。

2.1.1 Logistic 回归模型

例 1（横断面研究） 在研究医院抢救急性心肌梗塞（AMI）患者能否成功的危险因素的调查中，某医院收集了 5 年中该院所有的 AMI 患者的抢救病史（有关危险因素很多，由于篇幅有限，本例仅列出 3 个），共 200 例。

- $Y = 0$ 表示抢救成功，$Y = 1$ 表示死亡。
- $X_1 = 1$ 表示抢救前已发生休克，$X_1 = 0$ 表示抢救前未发生过休克。
- $X_2 = 1$ 表示抢救前发生心衰，$X_2 = 0$ 表示抢救前未发生心衰。
- $X_3 = 1$ 表示患者从开始 AMI 症状到抢救时已超过 12 小时（即未能及时把患者送往医院），$X_3 = 0$ 表示未超过 12 小时。

表 1　AMI 患者的抢救危险因素资料

$Y=0$（在医院抢救成功）				$Y=1$（未能抢救成功而死亡）			
X_1	X_2	X_3	N	X_1	X_2	X_3	N
0	0	0	35	0	0	0	4
0	0	1	34	0	0	1	10
0	1	0	17	0	1	0	4
0	1	1	19	0	1	1	15
1	0	0	17	1	0	0	6
1	0	1	6	1	0	1	9
1	1	0	6	1	1	0	6
1	1	1	6	1	1	1	6

Y 是二分类变量，服从二项分布，事件发生的概率记为 P。

$$\ln\left(\frac{P}{1-P}\right)=\beta_0+\beta_1x_1+\beta_2x_2+\beta_3x_3,$$
$$\ln\left(\frac{P}{1-P}\right)=\operatorname{logit}(P)=\beta_0+\beta_1x_1+\beta_2x_2+\beta_3x_3.$$

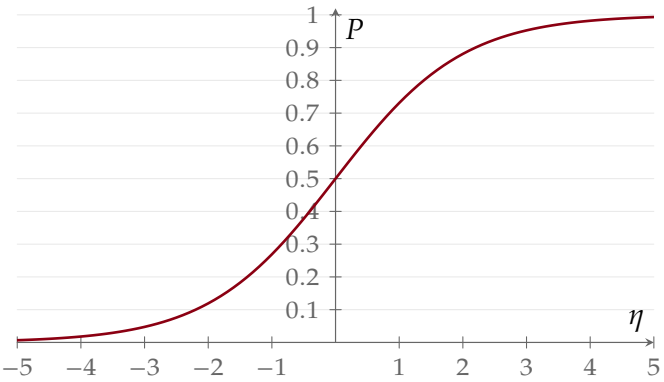


图 1　Logistic 回归中线性预测量 η（logit 值）与 P 的关系示意图

Logistic 回归模型

$$\ln\left(\frac{P}{1-P}\right)=\beta_0+\beta_1x_1+\beta_2x_2+\cdots+\beta_mx_m,$$
$$\operatorname{logit}(P)=\beta_0+\beta_1x_1+\beta_2x_2+\cdots+\beta_mx_m,$$
$$P=\frac{e^{\beta_0+\beta_1x_1+\cdots+\beta_mx_m}}{1+e^{\beta_0+\beta_1x_1+\cdots+\beta_mx_m}}=\frac{1}{1+e^{-(\beta_0+\beta_1x_1+\cdots+\beta_mx_m)}}.$$

> **批注**　$P/(1-P)$ 称为优势（odds）；$\eta=\beta_0+\beta_1x_1+\beta_2x_2+\beta_3x_3$ 为线性预测量。图 1 横轴是 $\eta=\operatorname{logit}(P)$，取值 $(-\infty,\infty)$；纵轴是概率 $P\in(0,1)$，二者由单调的 Logistic 曲线一一对应。
> logit 形式与概率形式是同一模型的两种写法：前者在 logit 尺度上是线性的，系数直接对应对数优势比，便于解释影响因素；后者把 η 反变换回概率，便于给出个体的预测概率。选用哪种写法取决于报告目的，不改变模型本身。

Logistic 回归模型的连接函数

- 分布族 family：二项分布 binomial。
- 连接函数 link：logit。

$$\eta = g(\mu) = \operatorname{logit}(P), \qquad \operatorname{logit}(P) = \ln\left(\frac{P}{1-P}\right).$$

批注 这种变换称为 logit 变换。

2.1.2 参数的估计方法

- 因为资料不满足“方差齐性”的条件，故 LSE 不适宜。
- 加权最小二乘估计（weighted least squared, WLS），其权重是方差的倒数，方差越大权重越小，方差越小权重越大。
- 极大似然估计（maximum likelihood estimation, MLE），构建似然函数，根据样本数据，找到最有可能产生样本观察值的参数值。

批注 β 的估计值可写作 $\hat{\beta}$ 或英文字母 b。

$$\begin{aligned} L(\theta \mid y_1, y_2, \cdots, y_n) &= f(y_1, y_2, \cdots, y_n \mid \theta) \\ &= f(y_1 \mid \theta) f(y_2 \mid \theta) \cdots f(y_n \mid \theta) = \prod_{i=1}^{n} f(y_i \mid \theta). \end{aligned}$$

$$\text{对数似然函数：} \quad \ln L(\theta \mid y_1, y_2, \cdots, y_n),$$

$$\max L(\theta \mid y_1, y_2, \cdots, y_n), \qquad \frac{\partial \ln L(\theta \mid y_1, y_2, \cdots, y_n)}{\partial \theta} = 0.$$

批注 θ 是参数，y_i 是第 i 个观测值。似然函数与联合概率函数是同一表达式，区别在于把谁看作变量：固定参数看 $\mathbf{y}$ 是概率，固定 $\mathbf{y}$ 看参数是似然。独立观测的似然是连乘，取对数后变为连加；令一阶导数（得分）为 0 求驻点，再由二阶导数判断是否为最大值。

一般 Logistic 回归的得分、信息阵与 IRLS

假设　$Y_i \mid \mathbf{x}_i \sim \text{Bernoulli}(\pi_i)$，$i = 1, \ldots, n$ 条件独立，$\operatorname{logit}(\pi_i) = \eta_i = \mathbf{x}_i^{\top}\boldsymbol{\beta}$，$\mathbf{X}$ 为 $n \times p$ 列满秩设计矩阵。

关键等式　对数似然

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \{y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)\} = \sum_{i=1}^{n} \{y_i \eta_i - \log(1 + e^{\eta_i})\}.$$

由 $\partial \log(1 + e^{\eta})/\partial \eta = \pi$、$\partial \pi / \partial \eta = \pi(1 - \pi)$，得

$$\mathbf{U}(\boldsymbol{\beta}) = \frac{\partial \ell}{\partial \boldsymbol{\beta}} = \sum_i (y_i - \pi_i)\mathbf{x}_i = \mathbf{X}^{\top}(\mathbf{y} - \boldsymbol{\pi}),$$

$$\frac{\partial^2 \ell}{\partial \boldsymbol{\beta}\, \partial \boldsymbol{\beta}^{\top}} = -\sum_i \pi_i(1 - \pi_i)\mathbf{x}_i \mathbf{x}_i^{\top} = -\mathbf{X}^{\top}\mathbf{W}\mathbf{X},$$

其中 $\mathbf{W}=\mathrm{diag}\{\pi_i(1-\pi_i)\}$。Hessian 不含 y_i，故观测信息等于期望（Fisher）信息 $\mathbf{I}(\boldsymbol{\beta})=\mathbf{X}^\top\mathbf{W}\mathbf{X}$。

结论　(1) 当 $0<\pi_i<1$、$\mathbf{X}$ 列满秩时 $\mathbf{X}^\top\mathbf{W}\mathbf{X}$ 正定，ℓ 是严格凹函数，若有限的最大值点存在则唯一。(2) MLE 满足 $\mathbf{X}^\top(\mathbf{y}-\widehat{\boldsymbol{\pi}})=\mathbf{0}$；含截距时 $\sum_i y_i=\sum_i \widehat{\pi}_i$。(3) 大样本下 $\hat{\boldsymbol{\beta}}\approx N\{\boldsymbol{\beta},\mathbf{I}(\boldsymbol{\beta})^{-1}\}$，用 $\widehat{\mathrm{Cov}}(\hat{\boldsymbol{\beta}})=(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}$，其对角元开方即软件输出的标准误。

迭代算法　Fisher scoring（对典型连接即 Newton–Raphson）：

$$\boldsymbol{\beta}^{(t+1)}=\boldsymbol{\beta}^{(t)}+(\mathbf{X}^\top\mathbf{W}^{(t)}\mathbf{X})^{-1}\mathbf{X}^\top(\mathbf{y}-\boldsymbol{\pi}^{(t)}).$$

定义工作响应 $z_i^{(t)}=\eta_i^{(t)}+\dfrac{y_i-\pi_i^{(t)}}{\pi_i^{(t)}(1-\pi_i^{(t)})}$，上式可改写为

$$\boldsymbol{\beta}^{(t+1)}=(\mathbf{X}^\top\mathbf{W}^{(t)}\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{W}^{(t)}\mathbf{z}^{(t)},$$

即以 $\mathbf{W}^{(t)}$ 为权重、$\mathbf{z}^{(t)}$ 为响应的一次加权最小二乘；权重随 $\boldsymbol{\pi}$ 更新、反复迭代，故称迭代加权最小二乘（IRLS）。分组资料（第 i 组 n_i 例、y_i 例发生）只需把 π_i 换成 $n_i\pi_i$、权重换成 $n_i\pi_i(1-\pi_i)$。

解释　以例 1 的 8 个协变量组合为分组资料，从 $\boldsymbol{\beta}^{(0)}=\mathbf{0}$ 起迭代，数步即收敛到表 2 的估计值（$-2.0858, 1.1098, 0.7028, 0.9751$），标准误取自 $(\mathbf{X}^\top\widehat{\mathbf{W}}\mathbf{X})^{-1}$。

将上述迭代公式写成 R 代码，对例 1 的分组资料自 $\boldsymbol{\beta}^{(0)}=\mathbf{0}$ 开始迭代：

R

```r
ami <- data.frame(x1=rep(c(0,1),each=4), x2=rep(rep(c(0,1),each=2),2), x3=rep(c(0,1),4),
                  alive=c(35,34,17,19,17,6,6,6), dead=c(4,10,4,15,6,9,6,6))
X <- cbind(1, as.matrix(ami[,1:3])); y <- ami$dead; n <- ami$dead+ami$alive
beta <- rep(0,4)
for(t in 1:5){
  p <- plogis(drop(X%*%beta)); W <- n*p*(1-p)            # 当前的概率和权重
  beta <- beta + solve(t(X)%*%(W*X), t(X)%*%(y-n*p))     # Fisher scoring一步
  cat("第",t,"次:",sprintf("%9.5f",beta),"\n")
}
sqrt(diag(solve(t(X)%*%(W*X))))                          # 标准误
```

```
第 1 次:  -1.67585   0.88648   0.55088   0.73037
第 2 次:  -2.04856   1.08991   0.68962   0.95113
第 3 次:  -2.08550   1.10964   0.70273   0.97486
第 4 次:  -2.08584   1.10982   0.70285   0.97509
第 5 次:  -2.08584   1.10982   0.70285   0.97509
                x1        x2        x3
0.3512559 0.3484879 0.3291858 0.3439633
```

第 4 次迭代后，估计值小数点后 5 位不再变化，结果与 `glm()` 相同（`glm()` 报告迭代 3 次，是因为其收敛判据为偏差的相对变化）。标准误为信息阵逆矩阵对角元的平方根。该算法的每一步依次为：由当前估计计算概率与权重，求解一次加权最小二乘，重复直至收敛。

有限 MLE 的存在性　上面的严格凹性只保证“若有最大值点则唯一”，并不保证最大值点有限。

- **完全分离**：存在 $\mathbf{b}$ 使 $y_i = 1$ 时 $\mathbf{x}_i^\top \mathbf{b} > 0$、$y_i = 0$ 时 $\mathbf{x}_i^\top \mathbf{b} < 0$。沿 $\mathbf{b}$ 方向放大系数，似然单调增至 1，MLE 不存在（某些系数趋于 $\pm\infty$）。
- **准完全分离**：上述不等式中允许等号，且至少一侧有等号成立。似然仍有上确界而达不到，相应系数发散。
- **四格表的情形**：$\hat\beta = \ln\{ad/(bc)\}$ 要求四个格子都为正。任一格为 0（如暴露组无病例），$\hat\beta = \pm\infty$，正是准完全分离。
- **识别与处理**：软件常给出“拟合概率为 0 或 1”的警告，系数和标准误异常大、迭代不收敛。可合并稀疏类别、检查编码，或改用 Firth 惩罚似然、精确 Logistic 回归。不能简单删去引起分离的变量后照常解释。

四格表资料的极大似然估计

表 10　暴露者与非暴露者发病与不发病的概率

	暴露，$x=1$	非暴露，$x=0$
发病，$y=1$	$P_1 = \dfrac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}}$	$P_0 = \dfrac{e^{\alpha}}{1+e^{\alpha}}$
不发病，$y=0$	$1-P_1 = \dfrac{1}{1+e^{\alpha+\beta}}$	$1-P_0 = \dfrac{1}{1+e^{\alpha}}$

$$
\begin{aligned}
L &= \left(\frac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}}\right)^{a}\left(\frac{e^{\alpha}}{1+e^{\alpha}}\right)^{b}\left(\frac{1}{1+e^{\alpha+\beta}}\right)^{c}\left(\frac{1}{1+e^{\alpha}}\right)^{d},\\
\ln L &= a(\alpha+\beta) - a\ln(1+e^{\alpha+\beta}) + b\alpha - b\ln(1+e^{\alpha})\\
&\quad - c\ln(1+e^{\alpha+\beta}) - d\ln(1+e^{\alpha})\\
&= a(\alpha+\beta) + b\alpha - (a+c)\ln(1+e^{\alpha+\beta}) - (b+d)\ln(1+e^{\alpha}),\\
\frac{\partial \ln L}{\partial \alpha} &= a + b - \frac{(a+c)e^{\alpha+\beta}}{1+e^{\alpha+\beta}} - \frac{(b+d)e^{\alpha}}{1+e^{\alpha}},\\
\frac{\partial \ln L}{\partial \beta} &= a - \frac{(a+c)e^{\alpha+\beta}}{1+e^{\alpha+\beta}}.
\end{aligned}
$$

令 $\partial \ln L/\partial\alpha = 0$，$\partial \ln L/\partial\beta = 0$，得：

$$
\hat\alpha = \ln\frac{b}{d}, \qquad \hat\beta = \ln\frac{ad}{bc}, \qquad \operatorname{logit}(P) = \alpha + \beta x = \ln\frac{b}{d} + \ln\frac{ad}{bc}\,x.
$$

> **批注**　由样本资料和极大似然估计得到回归方程。四格表是饱和模型，MLE 等于观察比例对应的 logit：$\hat\alpha$ 为非暴露组的对数优势，$\hat\beta$ 为对数 OR。

表 2　例 1 的参数估计与 Wald 检验结果

变量名	$\hat{\beta}$	SE($\hat{\beta}$)	Wald χ^2	P 值	OR
常数项	−2.0858	0.3513	35.2632	0.0001	—
X_1	1.1098	0.3485	10.1422	0.0014	3.034
X_2	0.7028	0.3292	4.5587	0.0328	2.019
X_3	0.9751	0.3440	8.0365	0.0046	2.651

$$\operatorname{logit}(P) = -2.0858 + 1.1098X_1 + 0.7028X_2 + 0.9751X_3.$$

2.1.3 回归系数的意义

如何正确理解回归系数 $\beta(b)$ 的意义?

> **批注** β 是总体参数，b（或 $\hat{\beta}$）是它的估计值。线性回归中，β_j 是其他变量固定时 x_j 每增加 1 个单位 E(Y) 的改变量，在概率尺度上是常数；Logistic 回归中 β_j 是 logit（对数优势）尺度上的改变量，换算到概率尺度后不再是常数（见下文）。

$$\begin{aligned}
\text{发生休克：}\quad & \ln\frac{P^*}{1-P^*} = -2.0858 + 1.1098\times 1 + 0.7028X_2 + 0.9751X_3,\\
\text{无休克：}\quad & \ln\frac{P}{1-P} = -2.0858 + 1.1098\times 0 + 0.7028X_2 + 0.9751X_3,\\
\text{两式相减：}\quad & \ln\left(\frac{P^*}{1-P^*}\Big/\frac{P}{1-P}\right) = \ln(\mathrm{OR}) = 1.1098,\\
& \mathrm{OR} = e^{1.1098} = 3.034.
\end{aligned}$$

> **批注** 优势（odds）是同一组内事件发生概率与不发生概率之比 $P/(1-P)$；优势比（OR）是两组优势之比。在心衰、抢救是否及时相同的条件下，发生休克者死亡的优势是未休克者的 3.034 倍。

常数项的含义

- 常数项 $\hat{\beta}_0 = -2.0858$，表示在其它自变量均为零时死亡与不死亡优势的自然对数值。
- $\exp(\hat{\beta}_0) = 0.1242$ 是无休克、无心衰和抢救及时组死亡与不死亡的比值。当死亡概率很低时，不死亡的概率接近 1，该值近似等于死亡率。

> **批注** 当 P 很小时，$P/(1-P) \approx P$。本例该组的模型死亡概率为 $\exp(\hat{\beta}_0)/\{1+\exp(\hat{\beta}_0)\} = 0.1105$，与 0.1242 已有差别，故“优势近似概率”只适用于罕见结局。截距的这种解释还要求研究设计能估计绝对风险（横断面或队列资料）；病例对照资料的截距受抽样比例影响，不能这样解释。

β_i 表示当其它因素被控制后，X 每改变一个单位，优势比（比值比，OR）的对数值（LnOR）。

$$\beta = \ln\left[\frac{P(D=1\mid X^*)/P(D=0\mid X^*)}{P(D=1\mid X)/P(D=0\mid X)}\right] = \ln \mathrm{OR}, \qquad e^{\beta} = \mathrm{OR}.$$

当结局变量赋值为 1 表示死亡等危险事件时：

- 如果回归系数为正值，$\exp(\hat{\beta}) > 1$，该因素是危险因素。
- 如果回归系数为负值，$\exp(\hat{\beta}) < 1$，该因素是保护因素。

- 本例中 3 个因素的回归系数均为正值，说明休克、心衰和未能及时抢救都是增加死亡优势的危险因素。

OR 与 RR 的区别

“休克者死亡的优势是未休克者的 3.03 倍”不能表述为“休克者的死亡风险是未休克者的 3 倍”。以第 1 章合并后的四格表为例（未调整其他因素）：

	死亡率	优势 $P/(1-P)$
休克（62 例）	$27/62 = 0.435$	0.771
无休克（138 例）	$33/138 = 0.239$	0.314
比值	RR= 1.82	OR= 2.45

死亡率之比为 1.82，而 OR 为 2.45。由 $\text{OR} = \text{RR} \times \dfrac{1-P_0}{1-P_1}$ 可知，结局越常见，二者差别越大；仅当两组发生率均很低（一般低于 10%）时，$\text{OR} \approx \text{RR}$。本例死亡率在 20%–45% 之间，OR 明显夸大了相对风险。

OR 的广泛使用有两方面原因：logit 连接保证概率位于 $(0,1)$ 内，具有良好的数学性质；病例对照研究只能估计 OR，且 OR 在病例对照抽样下保持不变，条件 logistic 回归即以此为基础。报告时应表述为“优势是……倍”；结局常见且需要 RR 时，可采用 log 连接的二项回归或稳健 Poisson 回归另行估计。

自变量可以是连续型的定量变量、两分类或多分类的定性变量。

1）对于连续型的定量变量，β_i 表示当其它因素被控制后，X 每改变一个单位，优势比的对数值（LnOR）。

2）对于两分类的定性变量，类别间互相的比较。

3）对于多分类的定性变量，采用哑变量变换，与参照组的比较。

> **批注** 例如母乳喂养知识得分的 OR 为 1.10：其他因素不变时，得分每增加 1 分，长时间母乳喂养的优势乘以 1.10（增加 10%），并不是概率增加 10% 或 10 个百分点。

OR 与概率尺度上的效应

假设　$\operatorname{logit}\pi(\mathbf{x}) = \beta_0 + \beta_j x_j + \sum_{k\neq j}\beta_k x_k$，$x_j$ 以线性项进入模型，且不与其他变量构成交互项。

关键等式　其他变量固定，x_j 由 x 变为 $x+\Delta x$，两优势之比

$$\text{OR}(\Delta x) = \frac{\pi(x+\Delta x)/\{1-\pi(x+\Delta x)\}}{\pi(x)/\{1-\pi(x)\}} = \exp(\beta_j \Delta x),$$

与 x 和其他变量的取值无关。而在概率尺度上，

$$\frac{\partial \pi}{\partial x_j} = \beta_j\, \pi(1-\pi).$$

结论　OR 对所有个体相同（这是模型假设），但概率的改变量随基线概率而变：$\pi = 0.5$ 时最大（$\beta_j/4$），π 接近 0 或 1 时很小。以休克为例（OR=3.034），无心衰、抢救及时者死亡概率由 0.110 升至 0.274，增加 16.4 个百分点；已有心衰且抢救不及时者由 0.399 升至 0.669，增加 26.9 个百分点。

解释　若 x_j 有交互项或非线性项（如 x_j^2、样条），$\exp(\beta_j)$ 本身不再是 “x_j 每增加 1 单位的 OR”，需按完整的线性预测量计算指定比较的 OR。

条件 OR 与边际 OR　模型中的 OR 是*调整其他协变量后*的条件 OR。即使没有混杂，条件 OR 与边际（总体平均）OR 也可以不同，这称为 OR 的不可折叠性（第 6 章）。例：Z 取 0、1 各半且与 X 独立，$\operatorname{logit}\pi = -1.5 + \ln 4 \cdot x + 3z$。$Z=0$ 层 $\pi(1)=0.472$、$\pi(0)=0.182$，$Z=1$ 层 $\pi(1)=0.947$、$\pi(0)=0.818$，两层 OR 都是 4；合并后 $\pi(1)=0.709$、$\pi(0)=0.500$，边际 OR 为 2.44。因此不同模型（调整变量不同）的 OR 不能简单比较大小，比较前要说明各自的调整集合。例 1 中休克的粗 OR 为 2.455，调整心衰、抢救是否及时后为 3.034，这一差别同时包含混杂与不可折叠性。

病例对照抽样　若病例与对照的抽样比例分别为 s_1、s_0，且抽样只依赖结局 Y、不依赖 $\mathbf{x}$，则样本中

$$\operatorname{logit} P(Y=1 \mid \mathbf{x}, \text{被抽中}) = \underbrace{\beta_0 + \ln(s_1/s_0)}_{\text{截距改变}} + \mathbf{x}^{\top}\boldsymbol{\beta}.$$

斜率 $\boldsymbol{\beta}$（从而 OR）不变，可以照常估计；截距被抽样比例平移，故病例对照资料不能由模型直接得到绝对风险或预测概率，除非另有外部信息（如人群发病率）校正截距。若抽样还依赖 $\mathbf{x}$（如按暴露选对照），斜率也会有偏。

2.1.4 回归系数的假设检验

检验模型中一个或者几个总体回归系数是否等于 0。

$$H_0 : \beta_i = 0 \quad (\text{或联合地} H_0 : \beta_{j_1} = \cdots = \beta_{j_q} = 0).$$

假设是对未知的总体参数作出的约束；$\hat{\beta}_i$ 是由样本算出的估计值，检验的正是它与 0 的差别能否用抽样误差解释，故 H_0 中不应写 $\hat{\beta}_i$。有三种检验方法：Wald 检验、似然比检验、比分检验。

Wald 检验

$$z = \frac{\hat{\beta} - 0}{\mathrm{SE}(\hat{\beta})}, \qquad \text{Wald } \chi^2 = z^2 = \frac{(\hat{\beta}-0)^2}{\mathrm{Var}(\hat{\beta})}.$$

回归系数估计值的 95%CI：

$$\hat{\beta} - 1.96\,\mathrm{SE}(\hat{\beta}) \;\sim\; \hat{\beta} + 1.96\,\mathrm{SE}(\hat{\beta}).$$

OR 值的 95%CI：

$$e^{\hat{\beta} - 1.96\,\mathrm{SE}(\hat{\beta})} \;\sim\; e^{\hat{\beta} + 1.96\,\mathrm{SE}(\hat{\beta})}.$$

> **批注** 依据是 MLE 的大样本正态性：$H_0:\beta=0$ 成立时 z 近似服从标准正态分布，z^2 近似服从 χ^2_1，临界值 $1.96^2=3.84$。这是渐近结论，小样本或系数很大（接近分离）时 Wald 检验可能不可靠。OR 的置信区间由系数区间取指数得到，因此关于 OR 不对称。报告时应同时给出 OR、95% 置信区间和 P 值。

休克变量的 Wald 检验与区间估计

变量	回归系数	标准误	系数下限	系数上限	Wald 统计量
休克	1.110	0.349	0.427	1.793	10.142

变量	自由度	P 值	OR	OR 下限	OR 上限
休克	1	0.001	3.034	1.532	6.007

似然比检验

通过比较两个相嵌套模型的对数似然函数值进行，统计量 G 等于两模型偏差（deviance）之差。

$$\begin{aligned} G &= D_P - D_K \\ &= -2(\text{模型 } P \text{ 的对数似然函数} - \text{模型 } K \text{ 的对数似然函数}). \end{aligned}$$

其中，模型 P 中的变量是模型 K 中的一部分，模型 K 中剩余的就是我们要检验的变量。H_0 成立时 G 近似服从自由度为 $K-P$ 的 χ^2 分布。

> **批注** 模型 P 含 P 个参数，模型 K 含 K 个参数，$K>P$。自由度 $K-P$ 等于 H_0 施加的独立约束个数，即被检验的参数个数（一个多分类变量的 $c-1$ 个哑变量要合起来检验时，自由度为 $c-1$）。

表 3　拟合的 Logistic 回归模型的对数似然函数值

编号	模型中的变量	对数似然函数值	参数个数
1	常数项	−122.172	1
2	常数项 + 休克	−118.367	2
3	常数项 + 心衰	−119.549	2
4	常数项 + 及时	−118.667	2
5	常数项 + 休克 + 心衰	−115.557	3
6	常数项 + 休克 + 及时	−113.599	3
7	常数项 + 心衰 + 及时	−116.491	3
8	常数项 + 休克 + 心衰 + 及时	−111.308	4

> **批注** 模型 5 嵌套于模型 8，两者只差变量“及时”。H_0：调整休克与心衰后，“及时”的系数为 0。若加入该变量后对数似然增加较多，G 就大；$G>\chi^2_{0.05,1}=3.84$ 对应 $P<0.05$，拒绝 H_0。

$$G=-2\times[-115.557-(-111.308)]=8.49,\qquad \chi^2_{0.05,1}=3.84,\qquad P<0.05.$$

抢救是否及时：✓。

R 中用 `anova()` 比较两个嵌套模型，`test="LRT"` 给出似然比检验，`test="Rao"` 给出比分检验：

R

```r
f5 <- glm(cbind(dead,alive)~x1+x2,    binomial, ami)    # 模型5
f8 <- glm(cbind(dead,alive)~x1+x2+x3, binomial, ami)    # 模型8
anova(f5, f8, test="LRT")
anova(f5, f8, test="Rao")
```

```
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1         5    11.1811
2         4     2.6821  1    8.499 0.003553 **

  Resid. Df Resid. Dev Df Deviance    Rao Pr(>Chi)
1         5    11.1811
2         4     2.6821  1    8.499 8.3041 0.003955 **
```

偏差之差 $11.1811 - 2.6821 = 8.499$ 即 G。以分组资料拟合时，偏差与对数似然的数值与个体资料相差一个常数，但两模型之差不变，检验结果完全相同。

比分（score）检验

$$H_0 : \theta = \theta_0, \qquad U(\theta) = \frac{\partial \log L(\theta \mid y)}{\partial \theta},$$

$$I(\theta) = -E\left(\frac{\partial^2}{\partial \theta^2} \log f(Y;\theta) \middle| \theta \right), \qquad S(\theta_0) = \frac{U(\theta_0)^2}{I(\theta_0)}, \qquad S(\theta_0) \sim \chi^2_1.$$

> **批注** $U(\theta)$ 是得分函数，即对数似然对参数的一阶导数（不是“均数”或对数似然本身）；$I(\theta)$ 是 Fisher 信息，等于负的二阶导数的期望。在 $H_0 : \theta = \theta_0$ 下，$\mathrm{E}\{U(\theta_0)\} = 0$，$\mathrm{Var}\{U(\theta_0)\} = I(\theta_0)$，大样本下 $U(\theta_0)/\sqrt{I(\theta_0)}$ 近似标准正态，平方后近似 χ^2_1。比分检验只需拟合 H_0 下的约束模型，在约束点处求导，不必拟合含被检验参数的模型。

以例 1 检验“及时”（调整休克、心衰）为例：比分检验 $\chi^2 = 8.30$，Wald 检验 $\chi^2 = 8.04$，似然比检验 $G = 8.50$，均为 $\mathrm{df} = 1$、$P < 0.005$，三者接近。

三个检验的比较

- 三个检验在大样本下渐近等价；小样本或估计值靠近参数空间边界、接近分离时，似然比检验通常更可靠。
- Wald 检验只用无约束模型，比分检验只用约束模型，似然比检验两个模型都要拟合。
- 三者检验的是同一个 H_0，调整的协变量也相同。“Wald 检验未考虑各因素间的综合作用”的说法不成立：多变量模型中的 Wald 检验同样是在其他变量已在模型中的条件下进行的。

三种检验的渐近联系

假设　正则条件成立：模型可识别，真值 θ_0 是参数空间的内点（不在边界上），对数似然在 θ_0 附近三阶可导且可交换求导与积分，信息量 $I(\theta)$ 随 n 增大而增大。下面以一维参数说明。

关键等式　在 MLE $\hat\theta$ 处作二阶 Taylor 展开，注意 $\ell'(\hat\theta)=0$：

$$\ell(\theta_0)\approx\ell(\hat\theta)-\tfrac{1}{2}I(\hat\theta)\,(\hat\theta-\theta_0)^2.$$

又在 θ_0 处展开得分函数：$0=U(\hat\theta)\approx U(\theta_0)-I(\theta_0)(\hat\theta-\theta_0)$，即 $\hat\theta-\theta_0\approx U(\theta_0)/I(\theta_0)$。

结论

$$\underbrace{2\{\ell(\hat\theta)-\ell(\theta_0)\}}_{\text{似然比}}\approx\underbrace{(\hat\theta-\theta_0)^2I(\hat\theta)}_{\text{Wald}}\approx\underbrace{U(\theta_0)^2/I(\theta_0)}_{\text{比分}},$$

在 H_0 下三者都渐近服从 χ^2_1。多维时，若 $\boldsymbol\theta=(\boldsymbol\psi,\boldsymbol\lambda)$，检验 $H_0:\boldsymbol\psi=\boldsymbol\psi_0$（$q$ 维），干扰参数 $\boldsymbol\lambda$ 在似然比检验中分别在两个模型里取各自的 MLE，在比分检验中取约束 MLE，在 Wald 检验中用信息阵逆的 $\boldsymbol\psi$ 子块 $[\mathbf{I}^{-1}]_{\psi\psi}$（它已扣除估计 $\boldsymbol\lambda$ 带来的不确定性）。三者渐近服从 χ^2_q，q 为 H_0 中独立约束的个数。

解释　三者的差别来自对数似然偏离二次型的程度，样本量越大差别越小。这些都是渐近结论，P 值是近似的；若需要精确推断（如很小的样本、稀疏格子），应改用精确条件检验或置换方法。

2.1.5 拟合优度检验

模型拟合结果与实际数据的比较分析（goodness of fit）。

- 零模型（null model）：只包含一个参数（常数项）的模型，对应于 y 的均数。
- 饱和模型（saturated model；也有称“全模型”的）：每个观察单位（个体或协变量组合）对应一个参数，拟合值与观察值完全相等。注意它不是“包含全部候选自变量的模型”，后者在本书中称完整模型。
- 好的模型应该是用尽量少的参数达到最大的拟合。

三类指标回答不同的问题，不能互相替代：(1) 相对零模型的改进（似然比 χ^2、Pseudo R^2）——自变量整体上是否有作用；(2) 整体拟合（偏差、Pearson χ^2、Hosmer–Lemeshow）——模型与资料是否有系统偏离；(3) 预测表现（区分度如 ROC 曲线下面积/C 统计量，校准度如校准曲线）——模型能否准确预测新个体。

λ 统计量

饱和模型的似然函数：$L(b_{\max};y)$。候选模型的似然函数：$L(b;y)$。

$$\lambda=\frac{L(b_{\max};y)}{L(b;y)}\ge 1.$$

λ 越接近 1，候选模型与饱和模型越接近，拟合越好。

Deviance 偏差统计量

$$D=2\ln\lambda=2(\ln L(b_{\max};y)-\ln L(b;y)).$$

D 值越大，说明模型拟合值与实际观察值差别越大，拟合效果越差。

> **批注** 以饱和模型为基准：候选模型的似然越接近饱和模型，D 越小；$D=0$ 即候选模型本身就是饱和模型。

χ^2 近似的条件　对分组二项资料（共 G 个协变量组合，第 g 组 n_g 例、y_g 例发生、拟合概率 $\widehat{\pi}_g$），

$$D = 2\sum_{g=1}^{G}\left\{y_g \ln\frac{y_g}{n_g\widehat{\pi}_g} + (n_g - y_g)\ln\frac{n_g - y_g}{n_g(1-\widehat{\pi}_g)}\right\}, \qquad \mathrm{df} = G - p,$$

在 G 固定、各组 n_g 足够大（期望频数 $n_g\widehat{\pi}_g$、$n_g(1-\widehat{\pi}_g)$ 大多不小于 5）时，D 在模型正确的前提下近似服从 χ^2_{G-p}。个体 Bernoulli 资料（每个协变量组合只有 1 例，如含连续自变量）中，饱和模型参数个数随 n 增长，D 只依赖拟合概率，不再近似 χ^2_{n-p}，不能用它作拟合优度检验；此时可用 Hosmer–Lemeshow 检验（按预测概率分组，第 3 章软件附录中的 SAS 选项 `lackfit`）或残差、校准图。例 1 只有 8 个协变量组合、每组例数较多：$D=2.68$，$\mathrm{df}=8-4=4$，$P=0.61$，未发现模型与资料有系统偏离。

广义的 χ^2 统计量

$$\chi^2_G = \sum_{g=1}^{G}\frac{(y_g - n_g\widehat{\pi}_g)^2}{n_g\widehat{\pi}_g(1-\widehat{\pi}_g)}.$$

分母是模型给出的响应方差 $\widehat{\mathrm{Var}}(Y_g) = n_g\widehat{\pi}_g(1-\widehat{\pi}_g)$，而不是拟合值的抽样方差 $\mathrm{Var}(\hat{y})$。χ^2_G 即 Pearson χ^2，自由度与适用条件同偏差。χ^2_G 值越大，说明模型估计值与实际观察值差别大，拟合效果差。例 1 中 $\chi^2_G=2.77$，$\mathrm{df}=4$，$P=0.60$。

> **批注** 每一项是 Pearson 残差的平方，相当于把“观察值减期望值”按模型标准差标准化后再平方。

似然比 χ^2 统计量

Likelihood ratio chi-square statistics。

$$C = 2(\ln L(b;y) - \ln L(b_{\min};y)).$$

C 值越大，说明所选模型比零模型改进程度越大。它检验的是“全部自变量的系数同时为 0”，$\mathrm{df}=p-1$；C 大只说明自变量整体有作用，不说明模型拟合良好。例 1：$C = 2\times(-111.308+122.173) = 21.73$，$\mathrm{df}=3$，$P<0.001$。

Pseudo R^2

$$\text{Pseudo } R^2_{\text{McFadden}} = \frac{\ln L(b_{\min};y) - \ln L(b;y)}{\ln L(b_{\min};y)} = 1 - \frac{\ln L(b;y)}{\ln L(b_{\min};y)}.$$

这是 McFadden 定义；软件中还有 Cox–Snell、Nagelkerke 等定义，数值不同，报告时要注明。它取值于 $[0,1)$，越大表示相对零模型改进越多，但不是“解释的方差比例”，数值通常远小于线性回归的 R^2。例 1：$1-(-111.308)/(-122.173) = 0.089$。

AIC 与 BIC

赤池信息准则（Akaike information criterion, AIC）；贝叶斯信息准则（Bayesian information criterion, BIC）。综合考虑对数似然和参数个数，数值小表示在拟合与简约之间权衡得更好：

$$\mathrm{AIC} = -2\ln L(b;y) + 2k, \qquad \mathrm{BIC} = -2\ln L(b;y) + k\ln n,$$

k 为估计的参数个数（含截距），n 为样本量（个体数）。例 1 完整模型 AIC = 230.62，BIC = 243.81（$n = 200$，$k = 4$）。

> **批注** 可比条件：只有用同一批观察、同一响应（及同一响应变换和同一种似然写法，如个体资料与分组资料的似然相差常数）拟合的模型，AIC、BIC 才能相互比较；不要求模型嵌套。AIC、BIC 的单个数值没有绝对意义。BIC 对参数的惩罚更重，倾向于选择更简单的模型。线性回归中的 R^2 不惩罚变量个数，加变量只增不减。

2.1.6 建模策略

1）从单因素分析开始：统计描述、统计推断。
2）部分多因素分析：变量的类型、变量的变换。
3）多因素分析：自变量的筛选、模型的选择（通过对比、嵌套）。
4）深入思考：交互作用项、共线性、条件的检验、拟合优度。

统计学意义与专业意义。最优模型：不同的角度、不同的目的、不同的条件。

补充：按研究目的确定建模方案

1）**先定问题，再定模型**。明确结局（定义、测量时点）、分析单位（个体、配对、家庭、地区）和研究目的。病因推断关注某一暴露的调整效应；预测关注整体预测准确性；二者的变量选择原则不同。
2）**调整变量依据专业知识确定**。病因研究中，混杂因素（同时影响暴露与结局、且不在因果通路上）应事先根据文献或因果图列出并纳入模型；中介变量、暴露的结果和碰撞变量不应调整。
3）**单因素 P 值筛选的局限**。单因素无统计学意义的混杂因素仍可能造成明显的混杂偏倚；单因素有意义的变量可能只是暴露的替身。逐步筛选会使最终模型的标准误偏小、系数偏大（选择偏倚），且结果对样本波动敏感。筛选可以辅助探索，但不应替代事先设定的调整集合。
4）**区分三个概念**。混杂：第三变量使暴露与结局的粗关联偏离真实效应，处理方法是调整；交互作用（效应修饰）：暴露的效应随第三变量的水平而不同，应在模型中加交互项并分层报告，不能当作混杂“调整掉”；共线性：自变量之间高度相关，使单个系数的标准误增大、估计不稳定，但不影响整体预测。
5）**连续变量的函数形式**。模型假定的是 *logit* 尺度上的线性：$\mathrm{logit}\,\pi$ 随 x 线性变化，而不是 π 随 x 线性变化。可用分组后的经验 logit 作图、加二次项或限制性立方样条（第 5 章）检查；随意把连续变量二分会损失信息。
6）**信息量与参数个数**。有效样本量取决于较少一类结局的例数（事件数），而不是总例数。需要估计的参数个数要按实际参数计：一个 c 类分类变量占 $c-1$ 个，样条占结点数减 1 个，交互项另计。常用经验是每个参数至少 10–20 个事件（第 3 章“20 倍”同理，按参数而非变量计）；稀疏类别（某类事件很少或为 0）会导致系数不稳定甚至分离，可考虑合并类别或惩罚估计。

7）**预测模型的评价**。区分度（ROC 曲线下面积/C 统计量）、校准度（预测概率与观察比例是否一致，用校准曲线、校准斜率）；在建模样本上评价会过于乐观，至少应做内部验证（Bootstrap 或交叉验证），有条件时做外部验证。

2.2 配对设计资料的条件 Logistic 回归模型

2.2.1 配对设计

从统计学的角度看，控制混杂因素的主要方法有两种。

- 在设计阶段：采取配对或匹配（match）的设计，1 : 1 配对、1 : m 匹配。
- 在数据分析阶段：采用多因素分析方法（前提条件是收集到混杂因素的信息）。

匹配资料的分析：配对资料比较的 t 检验；配伍组设计资料的方差分析；配对设计和配伍组设计资料的秩和检验；配对设计四格表资料的卡方检验；……。

2.2.2 条件 Logistic 回归的基本思想

例 2 研究某注射剂的不良反应的影响因素。重点探讨药物剂量、用药时间和合并用药种类是否为不良反应的影响因素。采用 1 : 1 配对设计，配对因素为注射剂的相同批次、患者的性别、年龄和病情轻重。收集过去两年某综合性医院发生不良反应的 40 例患者为病例，选择该院同期符合匹配条件的患者为对照。部分数据见表 4。

表 4　注射剂不良反应影响因素的 1 : 1 配对病例对照资料

配对号 i	病例对照 j	药物剂量 X_1	用药天数 X_2	合并药物 X_3
1	1	0.9	3	4
1	0	0.6	6	7
2	1	0.5	1	5
2	0	0.6	4	2
3	1	0.6	4	3
3	0	1.2	3	4
4	1	0.9	4	13
4	0	0.6	4	5
5	1	1.5	3	6
5	0	1.2	6	3
…	…	…	…	…
40	1	0.5	2	6
40	0	0.6	6	3

批注 第 i 个配对（$i = 1, \ldots, 40$）由病例 A_i 和对照 B_i 组成。

配对的模型　配对使同一对的两人在批次、性别、年龄、病情上相同，这些匹配因素对基线风险的影响用对子专有的截距 α_i 表示：

$$\operatorname{logit} P(Y=1 \mid \mathbf{x}, \text{第} i \text{ 对}) = \alpha_i + \sum_j \beta_j x_j, \qquad i = 1, \dots, 40.$$

β_j 对所有对子相同（见“模型假设”）。若直接用非条件 Logistic 回归估计 40 个 α_i 和 β，每对只有 2 人，参数个数随对子数增长，$\hat{\beta}$ 会严重偏大（1 : 1 配对时约为真值的 2 倍）。条件似然的办法是以“每对中恰有 1 例病例”为条件，把 α_i 消去。

$$\begin{aligned} &P(A_i\text{发生不良反应} \mid A_i\text{和}B_i\text{中恰有一人发生不良反应}) \\ &= \frac{P(Y=1 \mid \mathbf{x}_{A_i})P(Y=0 \mid \mathbf{x}_{B_i})}{P(Y=1 \mid \mathbf{x}_{A_i})P(Y=0 \mid \mathbf{x}_{B_i}) + P(Y=0 \mid \mathbf{x}_{A_i})P(Y=1 \mid \mathbf{x}_{B_i})} \\ &= \frac{1}{1 + \dfrac{P(Y=0 \mid \mathbf{x}_{A_i})P(Y=1 \mid \mathbf{x}_{B_i})}{P(Y=1 \mid \mathbf{x}_{A_i})P(Y=0 \mid \mathbf{x}_{B_i})}}. \end{aligned}$$

分母中的比值是两人优势（odds）之比：

$$\begin{aligned} \frac{P(Y=0 \mid \mathbf{x}_{A_i})P(Y=1 \mid \mathbf{x}_{B_i})}{P(Y=1 \mid \mathbf{x}_{A_i})P(Y=0 \mid \mathbf{x}_{B_i})} &= \frac{\text{odds}_{B_i}}{\text{odds}_{A_i}} = \frac{\exp(\alpha_i + \sum_j \beta_j x_{jB_i})}{\exp(\alpha_i + \sum_j \beta_j x_{jA_i})} \\ &= \exp\left[\sum_j \beta_j (x_{jB_i} - x_{jA_i})\right], \end{aligned}$$

对子截距 α_i 在分子分母中相消。于是

$$\begin{aligned} &P(A_i\text{发生不良反应} \mid A_i\text{和}B_i\text{中恰有一人发生不良反应}) \\ &= \frac{1}{1 + \exp[-\sum_j \beta_j (x_{jA_i} - x_{jB_i})]}, \end{aligned}$$

条件似然为 40 对的乘积 $L_c(\boldsymbol{\beta}) = \prod_{i=1}^{40} \{1 + \exp[-\sum_j \beta_j (x_{jA_i} - x_{jB_i})]\}^{-1}$，其中不含 α_i。一般的 $1:M$ 匹配同理，以“组内病例数等于实际病例数”为条件，各组贡献 $\exp(\mathbf{x}_{\text{病例}}^{\top}\boldsymbol{\beta}) / \sum_{l \in \text{组}} \exp(\mathbf{x}_l^{\top}\boldsymbol{\beta})$，形式与 Cox 部分似然相同（故软件可用分层 Cox 实现，见附录）。

> **批注**　条件 Logistic 回归只利用同一对内病例与对照在各因素上的差别 $\mathbf{x}_{A_i} - \mathbf{x}_{B_i}$ 来估计 $\boldsymbol{\beta}$，匹配因素的作用被 α_i 吸收而不需要估计。

> **对子参数不能直接估计的原因**
>
> 如前所述，采用非条件 logistic 回归并为每个对子设一个哑变量时，$\hat{\beta}$ 约为真值的 2 倍。以下用模拟验证：设真实 $\beta = 1$，100 个 1 : 1 配对，重复 200 次，比较两种方法的平均估计值：

R

```r
library(survival)
set.seed(5)
sim <- function(){
  np <- 100; x <- rnorm(2*np); pair <- rep(1:np,each=2)
  d <- x[seq(1,2*np,2)] - x[seq(2,2*np,2)]          # 对子内两人的暴露差
  first_case <- rbinom(np,1,plogis(1*d))            # 按条件模型决定谁是病例
  y <- as.vector(rbind(first_case,1-first_case))
  c(uncond=coef(glm(y~x+factor(pair),family=binomial))["x"],
    cond=coef(clogit(y~x+strata(pair))))
}
r <- replicate(200, sim()); rowMeans(r)
```

```
uncond.x   cond.x
2.123086 1.061543
```

非条件估计的均数为 2.12，约为真值的 2 倍；条件估计的均数为 1.06，接近真值。原因在于每对仅 2 人，却需多估计 1 个对子参数，参数个数随样本量同步增长，极大似然估计的大样本性质不再成立。这种偏倚不随对子数增加而消失，因此配对资料必须采用条件似然。

由此得到的几点性质

- **组内恒定的变量无法估计**。对子内取值相同的变量（包括匹配因素本身）在 $\mathbf{x}_{A_i} - \mathbf{x}_{B_i}$ 中为 0，其主效应不可估计；但它与暴露的交互项可以估计。
- **暴露一致的对子不提供信息**。若某对在全部自变量上取值相同，该对的条件概率恒为 1/2，与 $\boldsymbol{\beta}$ 无关（见下文配对四格表的 a、d 格）；参数估计的信息来自暴露不一致的对子。
- **不能直接估计绝对发病概率**。α_i 已被消去，模型只给出 OR；且病例对照抽样本身也不能提供发病率。若要预测个体的发病概率，需要额外的基线风险信息。

1）用途：估计并检验影响因素的 OR（调整匹配因素），不能直接用于预测绝对风险。
2）优点：节约样本量，提高研究的效率。
3）缺点：若需控制的因素较多，则实施难度大。

表 5　3 个自变量的 1 : 1 配对资料条件 Logistic 回归参数估计结果

自变量	b	SE	Wald	df	P	exp(b)
X_1	−2.079	2.078	1.002	1	0.317	0.125
X_2	−0.738	0.259	8.123	1	0.004	0.478
X_3	0.368	0.146	6.328	1	0.012	1.444

用药天数、合并药物的作用有统计学意义；药物剂量的作用无统计学意义（$P = 0.317$），其 OR 的置信区间很宽（$e^{-2.079 \pm 1.96 \times 2.078}$，约 0.002–7.3），说明资料对剂量效应几乎没有信息。

- **用药天数（X_2）**：在剂量、合并药物种数相同的条件下，用药天数每增加 1 天，发生不良反应的优势乘以 0.478，即降低约 52%（OR = 0.478，95%CI $e^{-0.738 \pm 1.96 \times 0.259} = 0.29$–0.79）。“天

数越长，不良反应越多”的说法与系数符号相反。解释时还要注意：若病例的用药天数统计到发生不良反应为止，结局本身会截短病例的用药天数，这一负关联可能部分来自测量方式，而非用药时间的保护作用。

- **合并药物（X_3）**：在其他两个因素相同的条件下，合并用药每增加 1 种，发生不良反应的优势乘以 1.444，即增加约 44%（95%CI 1.08–1.92）。0.012 是 P 值，不是效应大小。

2.2.3 配对四格表资料的条件 Logistic 回归

比较由配对四格表资料直接计算的 OR 值和通过条件 Logistic 回归估计的 OR 值之间的关系。

表 6　配对四格表资料的一般格式

对照	病例	
	暴露	非暴露
暴露	a	b
非暴露	c	d

$$\mathrm{OR}=\frac{c}{b}.$$

记同一配比组中，暴露者中病例的比例为 P_1，非暴露者中病例的比例为 P_0。根据条件 Logistic 回归，有：

$$P_1=\frac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}},\qquad P_0=\frac{e^{\alpha}}{1+e^{\alpha}}.$$

> **批注** α 是该配比组的截距（不同对子可以不同，下面的推导中会消去），β 是暴露因素的回归系数。非暴露者 $X=0$，所以 P_0 中不含 β。

考虑两个人中一人患病、另一人不患病的情况：

1）两人均暴露，则一人患病、一人不患病的条件概率为 1/2（对应四格表的 a）。

2）两人均未暴露，则一人患病、一人不患病的条件概率亦为 1/2（对应四格表的 d）。

3）一人暴露、一人未暴露，则暴露者患病、非暴露者不患病的条件概率为：

$$\begin{aligned}&\frac{P_1(1-P_0)}{P_1(1-P_0)+(1-P_1)P_0}\\&=\frac{\dfrac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}}\dfrac{1}{1+e^{\alpha}}}{\dfrac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}}\dfrac{1}{1+e^{\alpha}}+\dfrac{1}{1+e^{\alpha+\beta}}\dfrac{e^{\alpha}}{1+e^{\alpha}}}=\frac{e^{\beta}}{1+e^{\beta}}.\end{aligned}$$

> **批注** 对应四格表的 c 格（病例暴露、对照未暴露）。α 已消去。

4）一人暴露、一人未暴露，则暴露者不患病、非暴露者患病的条件概率为：

$$\frac{(1-P_1)P_0}{(1-P_1)P_0+P_1(1-P_0)}$$

$$= \frac{\dfrac{1}{1+e^{\alpha+\beta}}\dfrac{e^{\alpha}}{1+e^{\alpha}}}{\dfrac{1}{1+e^{\alpha+\beta}}\dfrac{e^{\alpha}}{1+e^{\alpha}} + \dfrac{e^{\alpha+\beta}}{1+e^{\alpha+\beta}}\dfrac{1}{1+e^{\alpha}}} = \frac{1}{1+e^{\beta}}.$$

> **批注** 对应四格表的 b 格（病例未暴露、对照暴露）。

配对四格表资料的条件似然函数为：

$$\begin{aligned} L &= \left(\frac{1}{2}\right)^{a}\left(\frac{1}{2}\right)^{d}\left(\frac{e^{\beta}}{1+e^{\beta}}\right)^{c}\left(\frac{1}{1+e^{\beta}}\right)^{b}, \\ \ln L &= -a\ln 2 - d\ln 2 + c\beta - (c+b)\ln(1+e^{\beta}), \\ \frac{\partial \ln L}{\partial \beta} &= c - (c+b)\frac{e^{\beta}}{1+e^{\beta}} = 0, \\ \hat{\beta} &= \ln\frac{c}{b} = \ln(\mathrm{OR}). \end{aligned}$$

> **批注** a 格的 a 个对子各贡献因子 $1/2$，b、c、d 格类似。a、d 格（暴露一致的对子）的贡献是与 β 无关的常数，对估计没有作用；$\hat{\beta}$ 只由不一致对子数 b、c 决定，$\exp(\hat{\beta}) = c/b$ 即配对资料的 OR。其检验 $H_0 : \beta = 0$ 的比分检验就是 McNemar 检验。

2.2.4 模型假设

- 自变量在各个配比组对结局变量（因变量）的作用是相同的，即自变量的回归系数与匹配组无关。
- 模型中的常数项 β_{0i} 与该匹配组的因素有关，是该匹配组特有的，指该匹配组的自变量均为 0 时的基线风险。
- 常数项对自变量的解释没有帮助，且不包含在似然函数中，故常不考虑。

> **批注** 不同对子的基线风险可以不同（例如一对是两名老年男性，另一对是两名年轻女性），由 β_{0i} 吸收；但同一危险因素的 OR 被假定在所有对子中相同。若怀疑 OR 随匹配因素变化，可加入暴露与匹配因素的交互项来检验。

补充练习（诊断题）

问　某病例对照研究中，暴露组 40 例全为病例、非暴露组有病例 30 例和对照 50 例。用 Logistic 回归估计暴露的 OR，软件提示 “fitted probabilities numerically 0 or 1 occurred”，系数为 18.6、标准误为 1400。请解释原因并提出处理办法。

答　暴露组中无对照，四格表中 $c = 0$，$\widehat{\mathrm{OR}} = ad/(bc)$ 的分母为 0，这是准完全分离：沿暴露系数增大的方向似然不断增大，有限的 MLE 不存在，软件在达到收敛标准时停在一个很大的数值上，标准误随之膨胀，Wald 检验失效。处理：核对资料与编码；报告精确条件 OR 的置信下限或采用 Firth 惩罚似然；必要时合并类别。不能把 18.6 当作效应估计值解释。

小结

Logistic 回归分析的基本思想与步骤；非条件的 Logistic 回归；用于配对设计资料的条件 Logistic 回归模型。

复习题

1) logistic 回归中 $\hat{\beta}_1 = 1.1098$，写出 OR 及其 95% 置信区间的计算式（SE = 0.3485）。
答：OR $= e^{1.1098} = 3.03$；*95%CI* 为 $e^{1.1098 \pm 1.96 \times 0.3485} = (1.53, 6.01)$。

2) 写出 OR 近似等于 RR 的条件。
答：两组发生率均很低（罕见结局）。

3) 模型 5 的对数似然为 −115.557，模型 8 为 −111.308，两者仅相差一个变量，计算似然比统计量及其自由度。
答：$G = 2 \times (115.557 - 111.308) = 8.50$，df $= 1$。

4) 说明个体 0/1 资料（含连续自变量）能否以偏差 D 对照 χ^2_{n-p} 作拟合优度检验。
答：不能。此时应采用 *Hosmer–Lemeshow* 检验、残差分析或校准图。

5) 配对四格表中 $b = 10$、$c = 25$，计算条件 logistic 回归给出的 OR，并说明 a、d 格对子的作用。
答：OR $= c/b = 2.5$；暴露一致的对子不提供估计 β 的信息。

6) 软件提示拟合概率为 0 或 1，系数与标准误异常大，说明可能的原因。
答：存在完全分离或准完全分离，有限的极大似然估计不存在。

第 3 章

Logistic 回归模型（二）

主要内容

Logistic 回归的基本概念、非条件 Logistic 回归；配比设计资料的条件 Logistic 回归分析；多分类结局资料的 Logistic 回归分析；有序分类结局资料的 Logistic 回归分析；Logistic 回归模型的正确应用及软件实现。第 2 章讨论的结局为二分类。实际资料中结局常多于两类，此时首先需区分类别之间是否有序。各类结局对应的常用模型如下：

结局类型	例子	常用模型
二分类	死亡 / 存活	二分类 logistic 回归（第 2 章）
无序多分类	肺癌的病理类型、出行方式	多项 logit 模型
有序多分类	疗效（无效 / 好转 / 显效 / 治愈）、病情分级	累积 logit（比例优势）模型
配对或匹配的二分类	1 : 1 配对病例对照	条件 logistic 回归（第 2 章）

有序资料也可采用多项 logit 模型分析，但会损失顺序信息并增加待估参数；无序资料则不能采用有序模型。模型的选择应依据结局变量的测量尺度，而不应依据 P 值的大小。本章后半部分的案例讨论即围绕这一选择展开。

3.1　多分类结局资料的 Logistic 回归分析

3.1.1　多分类结局的 Logistic 回归模型

结局变量是无序多分类的情形。例如疾病的不同类型、同一种肿瘤的不同病理分型、交通方式与影响因素（公交/地铁/出租，距离/收入/环境）。Multinomial logistic model（Daniel L. McFadden，1974 年）。

模型构建

假设结局变量 y 是无序三分类变量，类别包括 A、B、C 三类。把类别 C 作为参照（control, base category），赋值 $A=1$、$B=2$、$C=0$。分别以 C 作为参照，建立 A 与 B 的 Logistic 回归模型。

$$\operatorname{logit} P_{1/0} = \ln \frac{P(y=1)}{P(y=0)} = \alpha_1 + \beta_{11}x_1 + \beta_{12}x_2 + \cdots + \beta_{1p}x_p = g_1(\mathbf{x}),$$

$$\operatorname{logit} P_{2/0} = \ln \frac{P(y=2)}{P(y=0)} = \alpha_2 + \beta_{21}x_1 + \beta_{22}x_2 + \cdots + \beta_{2p}x_p = g_2(\mathbf{x}),$$

$$\begin{aligned}\operatorname{logit} P_{1/2} &= \ln\frac{P(y=1)}{P(y=2)} = \ln\frac{P(y=1)}{P(y=0)}\frac{P(y=0)}{P(y=2)}\\ &= \ln\frac{P(y=1)}{P(y=0)} - \ln\frac{P(y=2)}{P(y=0)} = g_1(\mathbf{x}) - g_2(\mathbf{x}).\end{aligned}$$

$$P_0 + P_1 + P_2 = 1.$$

$$\begin{aligned}\ln\frac{P_1}{P_0} &= g_1(\mathbf{x}), & P_1 &= P_0\exp(g_1),\\ \ln\frac{P_2}{P_0} &= g_2(\mathbf{x}), & P_2 &= P_0\exp(g_2),\\ P_1 + P_2 &= P_0[\exp(g_1)+\exp(g_2)] = 1 - P_0,\\ P_0 &= \frac{1}{1+\exp(g_1)+\exp(g_2)}, & P_1 &= \frac{\exp(g_1)}{1+\exp(g_1)+\exp(g_2)}.\end{aligned}$$

一般地：

$$\begin{aligned}\operatorname{logit} P_k &= \ln\frac{P(y=k)}{P(y=0)} = \alpha_k + \beta_{k1}x_1 + \beta_{k2}x_2 + \cdots + \beta_{kp}x_p = g_k(\mathbf{x}),\\ P_k &= \frac{\exp(g_k)}{1+\sum_{k=1}^{K}\exp(g_k)} = \frac{\exp(g_k)}{\sum_{k=0}^{K}\exp(g_k)}, \qquad g_0 = 0.\end{aligned}$$

> **批注** 概率归一化 $P_0 + P_1 + \cdots + P_K = 1$ 是推导的前提。每个非参照类别 k 都有一套以 k 为角标的截距和回归系数；参照类别的 $g_0 \equiv 0$，两种写法等价。

联合似然与参数个数　设结局有 $K+1$ 个类别（参照类别记 0），第 i 个体的类别指示为 $y_{ik} = I(Y_i = k)$。个体结局服从多项分布，联合对数似然为

$$\ell = \sum_{i=1}^{n}\sum_{k=0}^{K} y_{ik}\ln P_k(\mathbf{x}_i) = \sum_{i=1}^{n}\left\{\sum_{k=1}^{K} y_{ik}g_k(\mathbf{x}_i) - \ln\Big(1+\sum_{k=1}^{K} e^{g_k(\mathbf{x}_i)}\Big)\right\}.$$

全部 K 个 logit 方程在同一似然中同时估计，参数共 $K(p+1)$ 个（p 个自变量加截距）。检验“x_j 与结局无关”应检验它在所有方程中的系数同时为 0，$H_0: \beta_{1j} = \cdots = \beta_{Kj} = 0$，为 K 个约束的联合检验（$\mathrm{df} = K$），而不是逐个看单个方程的 P 值。

系数解释　由 $\ln(P_k/P_0) = g_k(\mathbf{x})$，其他协变量固定时，$x_j$ 每增加 1 个单位，

$$\frac{P_k(x_j+1)/P_0(x_j+1)}{P_k(x_j)/P_0(x_j)} = e^{\beta_{kj}},$$

即“属于类别 k 与属于参照类别的概率之比”乘以 $e^{\beta_{kj}}$。这一比值常称相对风险比（relative risk ratio, RRR），它是类别 k 相对参照类别的“条件优势比”，并不是一般意义上的相对危险度 $P_k(x+1)/P_k(x)$。

更换参照类别　系数只取决于对比的两个类别：$\ln(P_k/P_l) = g_k - g_l$，故以类别 l 为参照时，类别 k 的系数为 $\beta_{kj} - \beta_{lj}$，原参照类别 0 的系数为 $-\beta_{lj}$。拟合值、似然和联合检验都不随参照类别改变。

3.1.2 例题

例 3 诊断或预测恶性肿瘤的三种组织学类型。

表 7　无序多分类结局 Logistic 回归分析数据

分化程度 X_1	染色结果 X_2	组织类型 Y		
		鳞癌 1	腺癌 2	泡状细胞癌 3
1	+	10	17	26
1	−	5	12	50
2	+	21	17	26
2	−	16	12	26*
3	+	15	15	16
3	−	12	12	20

* 原表为 36。用 26 时，下表 8 的全部估计值、标准误和 Wald χ^2 均能精确复现（$n = 328$）；用 36 则不能，故按 26 更正。表 8 的编码为：染色结果“+” = 1、“−” = 2，分化程度按 1、2、3 作数值变量，参照类别为泡状细胞癌。

> **批注** 多项 Logistic 回归的概率形式（softmax）也是许多机器学习多分类器的输出层。

表 8　无序多分类结局 Logistic 回归分析结果

Variable	Parameter	估计值	Standard error	Wald χ^2	P-value	RRR $\exp(\beta)$
Intercept	$\hat{\beta}_0^{(1)}$	−0.9826	0.5707	2.96	0.0851	
	$\hat{\beta}_0^{(2)}$	−0.3461	0.5413	0.41	0.5226	
X_1	$\hat{\beta}_1^{(1)}$	0.6281	0.1799	12.19	0.0005	1.874
	$\hat{\beta}_1^{(2)}$	0.3454	0.1728	4.00	0.0456	1.413
X_2	$\hat{\beta}_2^{(1)}$	−0.6494	0.2833	5.26	0.0219	0.522
	$\hat{\beta}_2^{(2)}$	−0.6352	0.2725	5.43	0.0197	0.530

$$\ln\frac{P_1}{P_3} = -0.9826 + 0.6281x_1 - 0.6494x_2, \qquad \ln\frac{P_2}{P_3} = -0.3461 + 0.3454x_1 - 0.6352x_2.$$

结果解释（上标 (1) 为鳞癌对泡状细胞癌，(2) 为腺癌对泡状细胞癌）

- 染色结果相同时，分化程度每高 1 级，“鳞癌与泡状细胞癌的概率之比”乘以 1.874，“腺癌与泡状细胞癌的概率之比”乘以 1.413。末列应理解为相对风险比（RRR），原表标作“RR”，但它不是某一类别概率本身的比值。
- 分化程度相同时，染色“−”（$x_2 = 2$）与“+”（$x_2 = 1$）相比，两个概率之比分别乘以 0.522、0.530。
- 分化程度对组织类型的总体作用应作 2 个自由度的联合检验：似然比 $\chi^2 = 13.29$，$P = 0.0013$；染色结果的联合检验 $\chi^2 = 8.03$，$P = 0.018$。
- 改以鳞癌为参照：腺癌对鳞癌的分化程度系数为 $0.3454 - 0.6281 = -0.2826$，泡状细胞癌对鳞癌为 -0.6281。

R 中用 `nnet::multinom()` 拟合，频数表资料以 `weights` 给出各格例数：

R

```r
library(nnet)
d3 <- expand.grid(y=c("鳞癌","腺癌","泡状"), x2=c(1,2), x1=1:3)
d3$n <- c(10,17,26, 5,12,50, 21,17,26, 16,12,26, 15,15,16, 12,12,20)
d3$y <- relevel(factor(d3$y), ref="泡状")              # 指定参照类别
m <- multinom(y~x1+x2, weights=n, data=d3, trace=FALSE)
round(summary(m)$coefficients,4); round(summary(m)$standard.errors,4)
m0 <- multinom(y~x2, weights=n, data=d3, trace=FALSE)
anova(m0, m)                                          # 分化程度的2自由度联合检验
```

```
     (Intercept)     x1      x2
鳞癌     -0.9826 0.6281 -0.6494
腺癌     -0.3461 0.3454 -0.6352
     (Intercept)     x1     x2
鳞癌      0.5707 0.1799 0.2833
腺癌      0.5413 0.1728 0.2725

    Model Resid. df Resid. Dev   Test    Df LR stat.     Pr(Chi)
1      x2        32   672.9004
2 x1 + x2        30   659.6105 1 vs 2     2 13.28992 0.001300561
```

所得系数与表 8 完全一致。输出中每个非参照类别各占一行，即各对应一个方程；分化程度 x_1 在两个方程中各有一个系数，检验其总体作用应采用 2 个自由度的似然比检验（$\chi^2 = 13.29$），不宜分别依据两行的 P 值下结论。

Logistic Regression Table

Predictor	Coef	SE Coef	Z	P	Odds Ratio	95%CI	
						Lower	Upper
Logit 1: (Car/Walking)							
Constant	−37.9929	20.7069	−1.83	0.067			
Distance	1.69724	0.634966	2.67	0.008	5.46	1.57	18.95
Income	0.215653	0.182070	1.18	0.236	1.24	0.87	1.77
Logit 2: (Bus/Walking)							
Constant	2.12543	1.53808	1.38	0.167			
Distance	0.653565	0.254944	2.56	0.010	1.92	1.17	3.17
Income	−0.138963	0.0566681	−2.45	0.014	0.87	0.78	0.97
Logit 3: (Bike/Walking)							
Constant	−3.27498	3.36553	−0.97	0.331			
Distance	0.708729	0.272113	2.60	0.009	2.03	1.19	3.46
Income	−0.0736886	0.0648364	−1.14	0.256	0.93	0.82	1.05

3.1.3 注意事项

不同的回归方程，自变量的偏回归系数不同。多分类结局变量的 Logistic 回归与分别做两类比较的回归模型存在差异。

> **批注** 联合多项模型在同一似然中满足 $P_1+P_2+P_3=1$，全部样本同时参与估计。分别拟合二分类模型时，“鳞癌对泡状”只用这两类患者，模型化的是条件概率 $P(Y=1\mid Y\in\{1,3\})=P_1/(P_1+P_3)$，并非 $P_1+P_3=1$。由于 $\ln(P_1/P_3)$ 在两种做法下形式相同，分别拟合也能得到一致的系数估计，但它们只用了部分资料、彼此独立估计，效率较低，各方程的估计不能保证互相协调，也无法直接作跨方程的联合检验。本例分别拟合：鳞癌对泡状 x_1 系数 0.634（SE 0.183），腺癌对泡状 0.319（SE 0.169），与联合拟合的 0.628、0.345 接近但不相同。

3.2 有序分类结局资料的 Logistic 回归分析

3.2.1 有序多分类结局的 Logistic 回归模型

结局变量是有序多分类的情形。例如临床疗效（无效、好转、显效、治愈）、疾病的严重程度（轻、中、重）、考试成绩的等级（A、B、C）、满意度的等级（不满意、一般满意、很满意）。Cumulative logistic regression model。

设结果变量 y 为 K 个等级的有序变量，K 个等级分别用 $1,2,\dots,K$ 表示。记等级为 j（$j=1,2,\dots,K$）的概率为 $P(y=j)$。等级小于等于 j 的概率（cumulative probability）记为：

$$P(y\le j)=P(y=1)+P(y=2)+\cdots+P(y=j),\qquad P(y>j)=1-P(y\le j).$$

有序分类结果的 Logistic 回归定义为：

$$\operatorname{logit}P_j=\operatorname{logit}(y>j)=\ln\frac{P(y>j)}{1-P(y>j)}=-\alpha_j+\sum_{i=1}^{m}\beta_i x_i,\qquad j=1,2,\dots,K-1,$$

$$P(y\le j)=\frac{1}{1+\exp(-\alpha_j+\sum_{i=1}^{m}\beta_i x_i)}.$$

估计参数的个数：$(K-1)+m$。

> **批注** 模型针对累积概率。m 是自变量个数，K 是结局等级数；截距（阈值）α_j 有 $K-1$ 个，斜率 β_i 对所有分界点共用。

阈值顺序、类别概率与似然

假设　$Y\in\{1,\dots,K\}$ 有序；各个体条件独立；对 $j=1,\dots,K-1$，$\operatorname{logit}P(Y\le j\mid\mathbf{x})=\alpha_j-\mathbf{x}^{\top}\boldsymbol{\beta}$（与上式 $\operatorname{logit}P(Y>j)=-\alpha_j+\mathbf{x}^{\top}\boldsymbol{\beta}$ 等价）。

关键等式　累积概率必须随 j 单调不减，故阈值满足 $\alpha_1<\alpha_2<\cdots<\alpha_{K-1}$（记 $\alpha_0=-\infty$，$\alpha_K=+\infty$）。各类别概率由相邻累积概率相减得到：

$$P(Y=j\mid\mathbf{x})=P(Y\le j\mid\mathbf{x})-P(Y\le j-1\mid\mathbf{x})=\frac{1}{1+e^{-(\alpha_j-\mathbf{x}^{\top}\boldsymbol{\beta})}}-\frac{1}{1+e^{-(\alpha_{j-1}-\mathbf{x}^{\top}\boldsymbol{\beta})}}.$$

对数似然 $\ell(\boldsymbol{\alpha}, \boldsymbol{\beta}) = \sum_i \sum_{j=1}^{K} I(y_i = j) \ln P(Y = j \mid \mathbf{x}_i)$，用 Newton–Raphson 等方法求极大值。

结论　对任一固定分界点 j，比较 $\mathbf{x} + \mathbf{e}_i$ 与 $\mathbf{x}$（x_i 增加 1 单位、其余不变）：

$$\frac{\text{odds}(Y > j \mid \mathbf{x} + \mathbf{e}_i)}{\text{odds}(Y > j \mid \mathbf{x})} = e^{\beta_i},$$

与 j 无关。即把等级在 j 处一分为二（“高于 j” 对 “不高于 j”）时，无论在哪一处切分，OR 都相同，这就是比例优势假设。

解释　它可以理解为潜在连续变量模型：$Y^* = \mathbf{x}^\top \boldsymbol{\beta} + \varepsilon$，$\varepsilon$ 服从标准 Logistic 分布，$Y = j$ 当且仅当 $\alpha_{j-1} < Y^* \le \alpha_j$。$\mathbf{x}$ 使整个分布平移，各阈值处的 logit 改变量相同。

3.2.2 回归系数的解释

- $-\alpha_j$ 是自变量均为 0 时，$\ln\{P(Y > j)/P(Y \le j)\}$，即在分界点 j 处 “等级高于 j” 对 “不高于 j” 的对数优势。
- β_i：其他自变量不变，x_i 每增加一个单位，对任一分界点 j，“等级高于 j” 相对于 “不高于 j” 的优势比的对数值，ln(OR)。
- β_i 与 j 无关（比例优势假设，用平行线检验考察）。

> **批注** 比例优势假设说的是：无论在哪个等级处把结局切分为 “高”“低” 两类，某因素的 OR 都相同；在 logit 尺度上，各累积 logit 随 x 变化的直线互相平行。它不是说 “从 1 级升到 2 级、从 2 级升到 3 级的作用相同” ——后者是相邻类别 logit 模型的假设，比较的是相邻两级，而累积 logit 比较的是分界点两侧的全部等级。

比例优势假定

比例优势假定（Proportional Odds Assumption, POA；有的资料称 “等比例风险假定”，易与生存分析的比例风险假定混淆，本书统一称比例优势假设）：自变量在不同分界点上的 OR 相同。只有在此假定下，才能用一个 OR 概括自变量与 “等级更高” 的关联。若假定不成立，可改用部分比例优势模型（只让违背假定的变量的系数随 j 变化）、广义有序 logit 模型（所有系数随 j 变化），或不利用顺序信息的多项 Logit 模型。有序 Probit 模型同样要求各阈值处斜率相同（平行假设），只是把 Logistic 分布换成正态分布，不能解决不平行问题。

平行线检验（Test of Parallel Lines）

H_0：所有分界点的 β 相同（满足假定）。H_1：至少一个分界点的 β 不同（不满足假定）。比较 “约束模型（强制所有 β 相同）” 与 “非约束模型（允许 β 随 j 变化）” 的似然比卡方（LR χ^2），$\text{df} = m(K-2)$。若 $P > 0.05$，只能说未发现违背假设的充分证据，不等于证明了假设成立：样本小时检验效能低，样本很大时又会把无实际意义的微小差别判为显著。应同时比较各分界点分别拟合的二分类 OR 是否接近。

3.2.3 举例

例 4 母亲文化程度与儿童智力水平的关系。

> **批注** 自变量 X；因变量 Y，有序 4 分类。

表 9　有序多分类结局 Logistic 回归分析数据

智商等级 y	母亲文化程度 x				合计
	小学 0	初中 1	高中 2	大专以上 3	
1	22	57	11	1	91
2	81	236	112	4	433
3	30	135	105	10	280
4	3	26	17	7	53
合计	136	454	245	22	857

表 10　儿童智力等级与母亲文化程度的累积优势 Logistic 回归

变量	回归系数	标准误	Z	P
x	0.6373	0.0934	6.824	0.000
常数项 α_1	−1.4578	0.1454		
常数项 α_2	1.2254	0.1358		
常数项 α_3	3.5630	0.1935		

$$\operatorname{logit} P_j = -\alpha_j + 0.6373x, \qquad \mathrm{OR} = e^{0.6373} = 1.89.$$

母亲的文化程度每提高一个等级，无论以哪个智商等级为分界，儿童智商等级高于该分界相对于不高于该分界的优势均乘以 1.89（增加 89%）。注意增加的是优势而非概率。

> **说明** 用 R 的 `MASS::polr` 复算（$n = 857$）：$\hat{\beta} = 0.6374$（SE 0.0934），阈值 −1.4579、1.2254、3.5636，与表 10 一致（α_3 末位差别为舍入）。平行线检验：允许三个分界点斜率不同的模型与本模型比较，LR $\chi^2 = 0.16$，df $= 2$，$P = 0.92$；三个分界点分别作二分类 Logistic 回归的斜率为 0.631、0.628、0.720，彼此接近，未见违背比例优势假设的证据。

相应的 R 代码与输出如下：

R

```r
library(MASS)
d4 <- data.frame(y=factor(rep(1:4,4),ordered=TRUE), x=rep(0:3,each=4),
                 n=c(22,81,30,3, 57,236,135,26, 11,112,105,17, 1,4,10,7))
p <- polr(y~x, weights=n, data=d4, Hess=TRUE); summary(p)
sapply(1:3, function(j)          # 在三个分界点分别作二分类logistic回归
  coef(glm(I(as.integer(y)>j)~x, weights=n, family=binomial, data=d4))["x"])
```

```
Coefficients:
   Value Std. Error t value
```

```
x 0.6374     0.0934   6.824

Intercepts:
    Value    Std. Error t value
1|2  -1.4579   0.1454   -10.0279
2|3   1.2254   0.1358     9.0232
3|4   3.5636   0.1935    18.4175

Residual Deviance: 1873.039
AIC: 1881.039
        x         x         x
0.6308933 0.6278775 0.7197457
```

`polr()` 的参数化为 $\text{logit}\,P(Y \le j) = \zeta_j - \beta x$，输出中的 `1|2`、`2|3`、`3|4` 为三个阈值 α_j。最后一行给出检查比例优势假设的简便方法：在各分界点将等级一分为二，分别拟合二分类 logistic 模型。三个斜率 0.631、0.628、0.720 相差不大，与平行线检验的结论一致。

> **有序模型与多项 logit 模型的比较**
>
> 同一资料若采用多项 logit 模型（`multinom(y x, weights=n, data=d4)`），需 3 个方程，每个方程含 1 个截距和 1 个斜率，共 6 个参数；累积 logit 模型仅含 3 个阈值与 1 个斜率，共 4 个参数。两者的 AIC 分别为 1884.9 和 1881.0，有序模型较优。
>
> 有序模型减少的两个参数，以一个较强的假设为代价：母亲文化程度对儿童智商等级的作用在各分界点上相同。该假设成立时，有序模型合并三个分界点的信息估计一个 OR，结果更稳定，解释也更简明（母亲文化程度每提高一级，儿童智商等级较高的优势乘以 1.89）。该假设明显不成立时，应改用部分比例优势模型或多项 logit 模型。

3.3 案例讨论

3.3.1 案例 1

研究目标：糖尿病患者糖化血红蛋白（HbA1c）水平对视网膜病变严重程度的影响。

结局变量：视网膜病变的严重程度（1= 无病变，2= 轻度，3= 中度，4= 重度）。

影响因素：糖化血红蛋白 X_1（HbA1c），单位：%，取值范围：4%–12%。

混杂因素：病程 X_2（年），年龄 X_3（岁），性别 X_4（0，1）。

1) 如何开展此项研究？采用什么研究设计？
2) 如何对数据进行统计分析？

模型参数估计结果（核心输出）

变量	系数 β	SE	Z	P	OR	95%CI
截距（$j=1$）	−1.82	0.35	−5.20	<0.001	—	—
截距（$j=2$）	0.56	0.38	1.47	0.141	—	—
截距（$j=3$）	2.91	0.45	6.47	<0.001	—	—
HbA1c（X_1）	0.63	0.12	5.25	<0.001	1.88	(1.53, 2.31)
糖尿病病程（X_2）	0.15	0.06	2.50	0.012	1.16	(1.03, 1.31)
年龄（X_3）	0.02	0.01	1.98	0.048	1.02	(1.00, 1.04)
性别（X_4，男 =1）	0.21	0.18	1.17	0.242	1.23	(0.87, 1.75)

请解读上表中的结果。

答　在病程、年龄、性别相同的条件下，HbA1c 每升高 1 个百分点，视网膜病变“更重一级及以上”相对于“不更重”的优势乘以 1.88（95%CI 1.53–2.31），对任一分级切点都相同（比例优势假设）。病程每增加 1 年 OR 为 1.16，年龄每增加 1 岁 OR 为 1.02；性别的作用无统计学意义。三个截距对应三个分界点，依次增大，本身没有专业意义。表中没有给出平行线检验，解读前应补充。

问题 在“糖尿病患者 HbA1c 水平对视网膜病变严重程度的影响”研究中，若将原本的有序因变量（视网膜病变分级：1= 无病变 → 4= 重度病变）视为无序多分类因变量，并采用多项 Logit 模型（Multinomial Logistic Model, MNL）分析，其模型设定、结果输出及医学解释会与 Cumulative logistic regression model 分析产生哪些差异？

多项 Logit 模型的参数估计

对比关系	变量	系数 β	标准误	P 值	OR	95%CI
轻度病变（2）vs 无病变（1）						
	HbA1c	0.42	0.15	0.006	1.52	(1.15, 2.02)
	病程	0.10	0.07	0.168	1.11	(0.97, 1.27)
	年龄	0.01	0.01	0.325	1.01	(0.99, 1.03)
	性别（男 =1）	0.18	0.20	0.367	1.20	(0.82, 1.75)
	截距	−2.53	0.48	<0.001	—	—
中度病变（3）vs 无病变（1）						
	HbA1c	0.71	0.16	<0.001	2.03	(1.52, 2.71)
	病程	0.18	0.07	0.008	1.20	(1.04, 1.38)
	年龄	0.03	0.01	0.021	1.03	(1.01, 1.05)
	性别（男 =1）	0.25	0.21	0.235	1.28	(0.86, 1.89)
	截距	−1.12	0.51	0.029	—	—
重度病变（4）vs 无病变（1）						
	HbA1c	1.05	0.18	<0.001	2.86	(2.05, 3.99)
	病程	0.22	0.08	0.005	1.25	(1.07, 1.46)
	年龄	0.04	0.02	0.015	1.04	(1.01, 1.07)
	性别（男 =1）	0.30	0.23	0.192	1.35	(0.88, 2.08)
	截距	0.85	0.55	0.124	—	—

累积 Logit 模型与多项 Logit 模型

对比维度	累积 Logit 模型（比例优势模型）	多项 Logit 模型（MNL）
因变量属性假设	视为有序分类变量（无病变 → 轻度 → 中度 → 重度是递进关系，需保留“程度高低”信息）	不利用类别顺序（把 4 个级别当作无序类别；这不等于假定类别“相互独立”，只是模型不使用顺序信息）
建模对象	针对“累积概率”（如 $P(Y \le 1)$、$P(Y \le 2)$、$P(Y \le 3)$），通过 logit 链接建立自变量与“有序升级风险”的关系	针对“单个类别概率”，需指定一个参照类别（如“无病变 =1”），建模其他类别（2/3/4）相对于参照类别的概率比
核心假设	比例优势假设（自变量在所有累积分界点上的 OR 相同，即斜率系数 β 唯一）	无关选项独立性（IIA）：任意两类的概率之比只取决于这两类的线性预测量，不受其他类别影响
参数个数（本例 4 个自变量）	$3 + 4 = 7$	$3 \times (1 + 4) = 15$

累积 Logit 模型与多项 Logit 模型的评价

评价维度	累积 Logit 模型	多项 Logit 模型
贴合医学认知	高：视网膜病变是“从无到有、从轻到重”的渐进过程，模型保留有序性，结论与病理机制一致	较低：不使用等级顺序，各级别与无病变分别比较，趋势需由多个 OR 另行归纳
结论简洁性	高：1 组系数即可概括自变量对“有序升级风险”的整体影响，临床医生易理解	低：需解读多组系数（如 3 组），且结果分散，不易形成统一的核心结论
解决核心医学问题	能用一个 OR 回答“HbA1c 越高，病变是否越可能处于更重的分级”	分别回答“各病变级别相对无病变的概率之比”；可以描述剂量趋势，但需综合 3 个 OR
信息利用效率	比例优势假设成立时参数少、估计更精确，统计效能更高	参数多、效率较低；但不依赖比例优势假设，当该假设明显不成立时反而更合适

本例为横断面资料，分级是某一时点的病变严重程度，两种模型都只能描述严重程度与 HbA1c 的关联，不能回答“病变进展速度”或“延缓升级”这类纵向问题；后者需要随访资料（如重复测量的有序结局或多状态模型）。

问题：为何本案例不适合用多项 Logit 模型？

1) 未利用顺序信息：多项 Logit 模型对有序结局仍然是有效的模型，但它不使用等级顺序，参数个数（15 个）是累积 Logit 模型（7 个）的两倍多，估计精度较低。
2) 结论分散：需要分别解释 3 组对比，不能用一个 OR 概括“分级更重”的关联。
3) 比较的前提：上述优势以比例优势假设成立为前提。应先作平行线检验并比较各分界点的 OR；若假设明显不成立，可用部分比例优势模型，或改用多项 Logit 模型。

因此，“有序结局不适用多项模型”的说法不准确：比例优势假设成立时首选累积 Logit 模型（更简约、更有效率）；不成立时，多项 Logit 或部分比例优势模型是合理的选择。两种模型在本例中都只描述横断面关联，因果推断还需考虑混杂与时间顺序。

3.3.2 案例 2

背景 既往研究显示抑郁症会增加痴呆的风险，认知障碍是晚年抑郁症的常见表现，并且两者经常同时发生。然而，抑郁症是痴呆的危险因素还是前驱阶段仍存在争议。

目的 本研究从生命历程的角度研究抑郁症与痴呆风险之间的关联等。

> **Association of life-course depression with the risk of dementia in late life: A nationwide twin study**
>
> Wenzhe Yang, Xuerui Li, Kuan-Yu Pan, Rongrong Yang, Ruixue Song, Xiuying Qi, Nancy L Pedersen, Weili Xu.
>
> Alzheimers Dement. 2021 Aug;17(8):1383–1390. doi:10.1002/alz.12303. Epub 2021 Mar 3. PMID:33656267.
>
> **Introduction:** Whether depression is a prodromal phase or risk factor for dementia is under debate. We aimed to unveil the nature of depression-dementia association by looking into the time window of depression occurrence.
>
> **Methods:** Dementia-free twins ($n = 41,727$) from the Swedish Twin Registry were followed-up for 18 years. Data were analyzed using generalized estimating equation (GEE) for all individuals and conditional logistic regression for co-twin matched pairs.
>
> **Results:** In the GEE model, multi-adjusted odds ratios (ORs; 95% confidence intervals [CIs]) of dementia were 1.46 (1.09–1.95) for mid-life, 2.16 (1.82–2.56) for late-life, 2.24 (1.49–3.36) for mid- to late-life, and 2.65 (1.17–5.98) for lifelong depression. The ORs in conditional logistic regression and in GEE did not differ significantly ($P = 0.60$). Education ≥ 8 years attenuated dementia risk associated with mid-life depression.
>
> **Discussion:** Not only late-life depression, but also mid-life depression is associated with dementia. Genetic and early-life environmental factors could not account for this association. Education ≥ 8 years might buffer the impact of mid-life depression on dementia.

研究设计

- 研究对象：来源于瑞典双胞胎登记系统，基线无痴呆的 41727 名双胞胎，随访 18 年。
- 研究设计：全队列为前瞻性双生子队列（用 GEE 分析全部个体）；条件 Logistic 回归部分是在队列内选取痴呆不一致的双生子对，进行共同双生子配对分析（co-twin matched case-control analysis），形式上相当于 1：1 配对病例对照研究，同对双生子共享遗传和早年环境，相当于被“匹配”。
- 样本量：1439 对痴呆不一致的双生子，共 2878 人，其中 1439 人在随访中发生痴呆（病例），1439 人为其未发生痴呆的同胞（对照）。原资料写“2848 个研究对象”，与 $1439 \times 2 = 2878$ 及 TABLE 3 中四格表合计 $1224 + 140 + 60 + 15 = 1439$ 对不符，按 2878 更正。
- 结局：随访期间新发痴呆（依据登记系统的诊断记录判定），而不是“因痴呆死亡”。
- 暴露：在整个生命周期中是否确诊抑郁症。

> **批注** 配对（共同双生子）分析用条件 Logistic 回归；对子内一致的遗传与早年环境因素被对子截距吸收，因而得到控制。

数据特点

暴露变量：是否患抑郁症；分类变量。

1）终身无抑郁症。
2）仅有早年：最后一次抑郁发生在 45 岁之前。
3）仅有中年：第一次和最后一次抑郁发生在 45 至 64 岁之间。
4）仅有晚年：第一次抑郁确诊发生在 65 岁以后。
5）早年至中年：早年和中年都有抑郁症确诊。
6）中年至晚年：中年和晚年都有抑郁症确诊。
7）终身：在早、中、晚年都有抑郁确诊。

结局变量：新发痴呆（$Y = 1$），未发生痴呆的同胞对照（$Y = 0$）。协变量：年龄、性别等……。

> **批注** 暴露变量：无序多分类；结局变量：二分类。

方法应用

统计方法：描述性分析，定量资料，均值标准差；定性资料，频数构成比。方法：Conditional logistic regression models。报告：OR，95%CI。其他……。

结果及解释

TABLE 1　Baseline characteristics of the study population ($N = 41,727$) by incident dementia status

Characteristics	Dementia		*P*
	No ($n = 38,469$)	Yes ($n = 3258$)	
Age (years)	59.34 ± 10.25	71.90 ± 8.27	< 0.001
Sex			< 0.001
Male	18,074 (46.98)§	1309 (40.18)	
Female	20,395 (53.02)	1949 (59.82)	
Education			< 0.001
< 8 years	13,146 (34.17)§	1873 (57.49)	
≥ 8 years	25,323 (65.83)	1385 (42.51)	
Smoking status			< 0.001
Never	18,470 (48.01)	1983 (60.87)	
Former/current smoking	19,999 (51.99)	1275 (39.13)	
Alcohol consumption			< 0.001
No/mild drinking	35,579 (92.49)	3121 (95.79)	
Heavy drinking	2890 (7.51)	137 (4.21)	
...			

§ 原表分别印作“1804”“131,46”。按 $38469 - 20395 = 18074$、$38469 \times 0.3417 \approx 13145$ 更正。

TABLE 3　Odds ratios (95% confidence intervals) for the association between depression (including mid- or/and late-life, and lifelong depression) and dementia in co-twin matched analysis in dementia-discordant twin pairs ($n = 1439$ pairs): Results from conditional logistic regression

Dementia-free co-twin	Dementia	
	Depression-free	Depression
Depression-free	1224	140
Depression	60	15
Basic-adjusted OR (95%CI)*	2.34 (1.73–3.17)	
Multi-adjusted OR (95%CI)†	2.36 (1.74–3.20)	

* Adjusted for sex and education.

† Adjusted for sex, education, smoking, alcohol consumption, marital status, body mass index, type 2 diabetes mellitus, hypertension, heart disease, stroke, and cancer.

Abbreviations: CI, confidence interval; OR, odds ratio.

定量资料：均数和标准差；分类资料：频数和构成比。组间差异：定量资料——独立样本 t 检验；分类资料——卡方检验。研究对象：基于总的样本量进行描述。

多因素分析：在痴呆不一致的双生子对内比较，患有抑郁症（晚年确诊、中年至晚年和终身确诊）者发生痴呆的优势是终身没有患抑郁症者的 2.36 倍（多因素调整 OR，95%CI 1.74–3.20）。备注：剔除早年或者中年期间确诊抑郁症的研究对象。

> **批注** TABLE 3 中的四格表按对子计数。条件 Logistic 回归只用暴露不一致的对子：病例有抑郁、同胞无抑郁的 140 对，病例无抑郁、同胞有抑郁的 60 对，粗配对 OR = 140/60 = 2.33，与基本调整 OR 2.34（1.73–3.17）接近；两人都无或都有抑郁的 1224 对、15 对不提供信息。原文转述的区间“1.74–2.30”不含点估计 2.36，系将上限 3.20 误作 2.30。

注意事项

病例对照研究：给出明确的匹配因素。暴露的定义和赋值：分类变量。回归系数的解释：OR > 1 或 OR < 1，要明确暴露的参照组。统计方法的应用：Conditional logistic regression models。

3.4 Logistic 回归的正确应用

3.4.1 实际应用中的注意事项：数据

1) 数据的来源：设计类型（横断面研究、病例对照研究、队列研究）；样本量（估算方法；经验方法：较少一类结局的例数应达到模型参数个数的 10–20 倍，参数按哑变量、交互项、样条项的实际个数计算，而不是按原始变量个数或总例数计算）。
2) 数据内容：变量类型。
3) 数据质量。

> **批注** 队列研究中如果有时间变量，常用生存分析。

3.4.2 实际应用中的注意事项：模型

1）模型的应用条件：连续自变量在 logit 尺度上的线性；有序模型的比例优势假设。
2）建模的基本步骤：参数估计、假设检验、拟合优度。
3）建模的策略：认识数据、认识模型、最优模型。
4）注意事项：交互作用、共线性、变量的处理。

3.4.3 实际应用中的注意事项：解释

1）建模的目的：筛选危险因素、预测、分类；根据设计类型（横断面、病例对照、队列研究）；根据模型特点。
2）回归系数的解释。
3）统计学的解释与专业的解释。

3.5 思考与练习

在食管癌与饮酒关系分析中，年龄可能是混杂因素。请采用非条件 Logistic 回归方法分析下表资料，了解饮酒与食管癌的关系。

表 11　按年龄分层后食管癌与饮酒关系

每日饮酒量（g/天）	25–44		45–54		55–64		65+		合计	
	病例	对照	病例	对照	病例	对照	病例	对照	病例	对照
0–79	5	35	25	29	42	27	24	18	96	109
80+	5	270	21	138	34	139	44	119	104	666

> **批注** 结局：食管癌病例 $Y=1$，对照 $Y=0$。年龄组宜以哑变量进入模型（不宜直接用 1–4 的等级赋值，否则强加了 logit 尺度上的等距线性关系）。资料按年龄分层后汇总，可用 `cbind(病例数，对照数)` 作为分组二项响应。

1）构建 Logistic 回归模型。
2）解释回归系数的含义。
3）如何检验总体回归系数是否为零?
4）如何评价模型的好坏?

案例分析 阅读文献：Ma XQ, Jiang CQ, Xu L, Zhang WS, Zhu F, Jin YL, Thomas GN, Lam TH. *Sleep quality and cognitive impairment in older Chinese: Guangzhou Biobank Cohort Study*. Age Ageing. 2019 Dec 1;49(1):119–124. doi:10.1093/ageing/afz120。并回答以下问题：

1）请阐述本研究的研究设计。
2）本研究的结局变量是如何测量及定义的?
3）请阐述 Table 2 中睡眠相关因素与记忆障碍的相关关系。

补充练习（推导题）

问　例 3 以泡状细胞癌为参照得到 $\ln(P_1/P_3) = -0.9826 + 0.6281x_1 - 0.6494x_2$，$\ln(P_2/P_3) = -0.3461 + 0.3454x_1 - 0.6352x_2$。(1) 写出以鳞癌为参照时腺癌的方程；(2) 分化程度为 2、染色“+”时，三种组织类型的预测概率各是多少?

答　(1) $\ln(P_2/P_1) = \ln(P_2/P_3) - \ln(P_1/P_3) = 0.6365 - 0.2827x_1 + 0.0142x_2$。(2) $x_1 = 2$、$x_2 = 1$ 时 $g_1 = -0.9826 + 1.2562 - 0.6494 = -0.3758$，$g_2 = -0.3461 + 0.6908 - 0.6352 = -0.2905$，$P_3 = 1/(1 + e^{-0.3758} + e^{-0.2905}) = 0.411$，$P_1 = 0.282$，$P_2 = 0.307$（观察比例为 21/64 = 0.33、17/64 = 0.27、26/64 = 0.41）。

小结

非条件 Logistic 回归；条件 Logistic 回归；无序多分类结局资料的 Logistic 回归；有序多分类结局资料的 Logistic 回归；Logistic 回归分析的思路与策略、基本步骤、注意事项、软件实现。

3.6 附录：Logistic 回归的软件实现

3.6.1 R 语言的实现

非条件 Logistic 回归：

R

```r
glm(Y ~ X1+X2+X3, family=binomial(link='logit'), data=mydata)
```

Y 取 0/1 时，模型化的是 $P(Y = 1)$；若 Y 为因子，模型化的是第二个水平的概率，应先用 `factor(Y, levels=c("未发生","发生"))` 明确顺序。分类自变量用 `factor()` 并以 `relevel(x, ref=)` 指定参照组。以例 1 的分组资料验证，用

```
glm(cbind(死亡数, 存活数) ~ x1+x2+x3, family=binomial)
```

得到与表 2 相同的系数。

条件 Logistic 回归：

R

```r
library(survival)
fit.full <- clogit(y ~ x1 + x2 + x3 + strata(id), data=mydata)
```

> **批注** y 为 1（病例）/0（对照），`strata(id)` 指定配对号，每个配对一个层；层内截距被条件似然消去，故输出中没有截距。资料为每人一行（每对两行）。例 2 只列出 5 对的记录，表 5 无法据此复算；可用配对四格表验证：只含一个 0/1 暴露时，`clogit` 的 $\exp(\hat{\beta}) = c/b$。

有序分类结局的 Logistic 回归：

R

```r
library(MASS)
mydata2$y <- factor(mydata2$y, levels=1:4, ordered=TRUE)
m <- polr(y ~ x, data=mydata2, weights=freq, Hess=TRUE)
summary(m)
```

包名为 MASS（区分大小写，mass 无法加载）。响应必须是按等级顺序排列的有序因子；`weights=freq` 为频数权重。`polr` 的参数化为 $\operatorname{logit} P(Y \le j) = \zeta_j - \mathbf{x}^\top \boldsymbol{\beta}$，与本章的 $\operatorname{logit} P(Y > j) = -\alpha_j + \mathbf{x}^\top \boldsymbol{\beta}$ 一致（$\zeta_j = \alpha_j$）。以例 4 验证：$\hat{\beta} = 0.6374$，阈值 -1.4579、1.2254、3.5636。

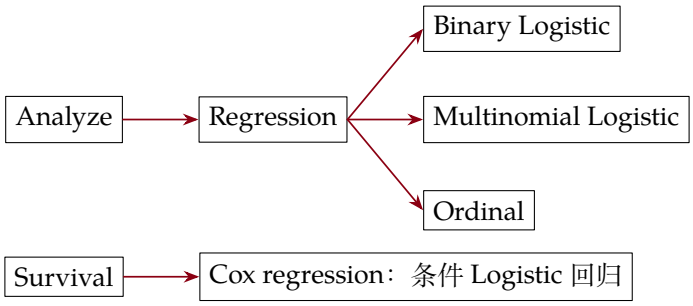
无序多分类结局的 Logistic 回归：

R

```r
library(nnet)
mydata$y <- relevel(factor(mydata$y), ref="3")    # 指定参照类别
model <- multinom(y ~ x1 + x2, data=mydata, weights=freq)
summary(model)
```

以例 3（更正后的表 7，染色 $+ = 1$、$- = 2$，参照类别为泡状细胞癌）验证，可精确得到表 8 的系数和标准误。

3.6.2 SPSS 软件实现



SPSS 菜单路径

条件 Logistic 回归：

SPSS

```
COXREG time #产生新变量，病例赋值1，对照赋值2（对照的时间晚于病例）
 /STATUS=y(1) #结局变量，病例1，对照0；y(1)表示取值1为“事件”
 /STRATA=id #分层变量，对子号
 /METHOD=ENTER x1 x2 x3 x4 x5
 /PRINT=CI(95)
 /CRITERIA=PIN(.05) POUT(.10) ITERATE(20).
```

3.6.3 SAS 软件实现

SAS

```
PROC LOGISTIC data= ;
MODEL y(event='1')=x1 x2 x3 x4 /cl rl lackfit selection=stepwise;
```

cl：输出参数估计值的置信区间；rl：输出 OR 的可信区间；lackfit：输出 Hosmer–Lemeshow 拟合优度指标；selection：可以指定自变量选择的方法。PROC LOGISTIC 默认对排序在前的取值（0/1 编码时为 0）建模，因此要用 `y(event='1')` 或 `descending` 指定事件，否则系数符号全部相反。

有序多分类结局：

SAS

```
PROC LOGISTIC data= ;
CLASS x1 (ref=first) / param=ref;
MODEL y(descending)=x1 x2 x3 /link=clogit;
ODDSRATIO x1;
RUN;
```

有序结局用累积 logit 连接（`link=clogit`，有序响应时为默认），输出中的比例优势假设比分检验（Score Test for the Proportional Odds Assumption）即平行线检验。把 `link=glogit` 写在有序模型中是错误的：`glogit`（广义 logit）是无序多分类的多项 Logit 模型。`descending` 使模型化的是较高等级的累积概率 $P(Y \geq j)$，与本章 logit $P(Y > j)$ 的方向一致；不加时 SAS 对 $P(Y \leq j)$ 建模，斜率符号相反。频数资料加 `FREQ freq;`。

无序多分类结局：

SAS

```
PROC SORT;
BY descending y;
PROC CATMOD order=data;
DIRECT x;
MODEL y=x;
RUN;
```

CATMOD 以排序后的最后一个类别为参照，故需先排序以控制参照类别。也可用 `PROC LOGISTIC; MODEL y(ref='3')=x1 x2 / link=glogit;`，以 `ref=` 直接指定参照类别。

条件 Logistic 回归：

SAS

```
PROC PHREG;
MODEL time*case(0)=x1-x7/ties= selection= risklimits;
STRATA id;
RUN;
```

3.6.4 STATA 软件实现

STATA 有一组命令用于 Logistic 回归分析：`logistic`、`logit`、`clogit`、`mlogit`、`ologit`。

复习题

1) 结局为 4 类无序变量，模型含 3 个自变量，计算多项 logit 模型的参数个数，以及检验某一自变量总体作用的自由度。
   答：$3 \times (3+1) = 12$ 个；自由度为 3。
2) 解释多项 logit 模型中 $\exp(\beta_{kj})$ 的含义。
   答：其他变量不变时，x_j 每增加 1 个单位，“属于类别 k 与属于参照类别的概率之比”乘以 $\exp(\beta_{kj})$（相对风险比 RRR）。
3) 结局为 4 个等级、含 2 个自变量的累积 logit 模型，计算参数个数及平行线检验的自由度。
   答：$3+2=5$ 个；$m(K-2) = 2 \times 2 = 4$。
4) 解释比例优势假设的含义。
   答：在任一等级处将结局分为“高”“低”两类，某因素的 OR 均相同。
5) 平行线检验 $P = 0.92$，说明能否据此认为比例优势假设成立。
   答：只能说明未发现违背该假设的证据，还应比较各分界点分别拟合的 OR 是否接近。

第 3 章　习题与解析

Logistic 回归

作业题

数据分析题

题 3.1　食管癌与饮酒：分层频数资料

表 11 按年龄分层后食管癌与饮酒关系。每日饮酒量单位为 g/天。**共 7 分**。

年龄组	0–79 病例	0–79 对照	80+ 病例	80+ 对照
25–44	5	35	5	270
45–54	25	29	21	138
55–64	42	27	34	139
65+	24	18	44	119
合计	96	109	104	666

1. 构建 Logistic 回归模型。（1 分）
2. 解释回归系数的含义。（2 分）
3. 如何检验总体回归系数是否为零？（2 分）
4. 如何评价模型的好坏？（2 分）

文献分析题

题 3.2　睡眠质量与认知功能：文献分析

阅读 *Sleep quality and cognitive impairment in older Chinese: Guangzhou Biobank Cohort Study*（本包“数据与代码”附原文）。**共 3 分**。

1. 请阐述本研究的研究设计。（0.5 分）
2. 本研究的结局变量是如何测量及定义的？（1 分）
3. 请阐述 Table 2 中睡眠相关因素与记忆障碍的相关关系。（1.5 分）

Table 2（记忆障碍部分，保留全部因素；下列为 OR 及 95% CI）：

因素及比较	Model 1	Model 2
主观睡眠差 vs 好	1.09 (0.93–1.29)	1.01 (0.85–1.19)
入睡 31–60 vs ≤ 30 min	1.09 (0.93–1.28)	1.04 (0.89–1.22)
入睡 > 60 vs ≤ 30 min	1.23 (1.00–1.51)*	1.13 (0.92–1.40)
入睡时间趋势 P	0.04	0.24
睡眠 < 5 vs 7–8 h	1.16 (0.90–1.48)	1.12 (0.87–1.44)
睡眠 5–6 vs 7–8 h	0.99 (0.87–1.13)	0.99 (0.87–1.13)
睡眠 > 8 vs 7–8 h	0.88 (0.63–1.22)	0.90 (0.65–1.26)
睡眠时长趋势 P	0.65	0.70
效率 75–85% vs ≥ 85%	1.08 (0.92–1.27)	1.09 (0.93–1.28)
效率 65–75% vs ≥ 85%	1.04 (0.84–1.29)	1.02 (0.82–1.26)
效率 < 65% vs ≥ 85%	1.26 (1.03–1.54)*	1.23 (1.00–1.50)*
睡眠效率趋势 P	0.04	0.08
睡眠干扰每周至少 1 次	1.11 (0.77–1.59)	0.89 (0.61–1.29)
使用睡眠药物 vs 不使用	1.02 (0.76–1.37)	0.99 (0.73–1.33)
日间障碍每周至少 1 次	1.26 (1.02–1.56)*	1.05 (0.85–1.31)
PSQI 整体睡眠差 vs 好	1.10 (0.97–1.26)	1.03 (0.90–1.18)

睡眠干扰、日间障碍的参照均为“没有或每周不足 1 次”。* 为原文标注的 $P < 0.05$。Model 1 调整年龄、性别、教育、职业、BMI、吸烟、饮酒、午睡、打鼾、自评健康、体力活动、冠心病史、卒中史及糖尿病；Model 2 再调整抑郁症状。

往年题

单项选择题

题 3.3　Logistic 回归系数与优势比

某二分类 Logistic 模型没有交互项，自变量 X 的回归系数为 $\log 2$。控制其他变量不变，X 增加 1 单位时，下列解释正确的是：

A. 事件发生概率一定变为原来的 2 倍。

B. 事件发生概率一定增加 0.5。

C. 事件发生优势变为原来的 2 倍。

D. 生存时间一定变为原来的 2 倍。

E. 事件发生优势减少一半。

题 3.4　总体回归系数检验

Logistic 回归中，检验除截距外所有总体偏回归系数是否同时为 0，常用下列哪种检验？

A. t 检验。

B. F 检验。

C. 似然比检验。

D. Z 检验。

E. Hosmer–Lemeshow 检验。

名词解释

题 3.5　优势比（Odds Ratio, OR）

名词解释：优势比（Odds Ratio, OR）。

简答题

题 3.6　有序 Logistic 的阈值与斜率

如何解释有序分类结局资料的 Logistic 回归分析中的 α_i 和 X_j 的偏回归系数 β_j？

题 3.7　Logistic 偏回归系数的含义

在 Logistic 回归中，偏回归系数 β_j 的统计学意义是什么?

题 3.8　有序结局的共同斜率

在有序多分类结局的 Logistic 回归中，偏回归系数 β_j 的解释有何特殊之处?

计算与综合分析题

题 3.9　吸烟与饮酒的交互作用（2020）

表 1 心血管疾病的危险因素分析（Logistic 回归）:

因素	B	SE(B)	CHISQ	P	OR
吸烟 vs 不吸烟	0.693	0.323	4.605	0.032	2.0
饮酒 vs 不饮酒	1.099	0.551	3.975	0.046	3.0
吸烟 × 饮酒	0.405	0.186	4.752	0.029	1.5

利用表 1 估计:（1）相对于不吸烟、不饮酒者，同时吸烟、饮酒者的发病风险；（2）对于饮酒者，吸烟的发病风险。

题 3.10　吸烟与饮酒的交互作用（2021）

表 1 心血管疾病的危险因素分析（Logistic 回归）：

因素	B	SE(B)	CHISQ	P	OR
吸烟 vs 不吸烟	0.693	0.323	4.605	0.032	2.0
饮酒 vs 不饮酒	1.099	0.551	3.975	0.046	3.0
吸烟 × 饮酒	0.405	0.186	4.752	0.029	1.5

利用表 1 估计：（1）相对于不吸烟、不饮酒者，同时吸烟、饮酒者的发病风险；（2）对于饮酒者，吸烟的发病风险。

题 3.11　分层分析与年龄混杂

分析暴露与发病是否有关，判断年龄是否是混杂因素并提供依据。

结局	70–岁暴露	70–岁未暴露	50–岁暴露	50–岁未暴露	合计
发病	89	59	80	20	248
不发病	11	41	120	180	352

年龄组标签按原卷 “70–岁” “50–岁” 保留。

题 3.12　380 对配比病例对照研究

选了 380 例病例，按照年龄及另外两个未记明的因素选了 380 例对照，以表的形式报告了 β、P 值、OR 及置信区间。

1. 本研究的研究设计类型是什么，统计分析方法是什么？（2 分）
2. 该统计分析方法的优点、缺点及用途。（2 分）
3. 模型中没有给出常数项 β_0，需要考虑 β_0 吗？为什么？（2 分）
4. 解释表格中的偏回归系数。（4 分）

原稿缺失： 除年龄外的配比因素、全部结果表数值。

数据分析题

题 3.13　低出生体重的影响因素

利用数据 1（原题称 DATA1.sav，目录实际提供 data1.xls 与 data1.csv）分析 18 岁及以上的母亲所产婴儿是否发生低出生体重的影响因素，并对结果做简单解释。

变量	说明	变量	说明
low	低出生体重：1 是、0 否	ftv	随访次数
age	产妇年龄（岁）	bwt	出生体重（g）
lwt	产妇体重（磅）	ui	应激性：1 是、0 否
race	1 white、2 black、3 other	ht	高血压：1 是、0 否
smoke	孕期吸烟：1 是、0 否	ptl	此前早产次数

数据文件保留了缺失值；请说明分析样本的确定过程。

补充练习

> **说明**
>
> 以下为配合正文新编的补充练习，按题型编排。教学设定的数据不代表真实研究结果；解析见章末。

单项选择题

题 3.14　根据结局与设计选择 Logistic 模型

正文的双胞胎配对案例中，结局为随访期间是否新发痴呆（1/0），暴露按抑郁症发生的生命阶段分为 7 类，并以“终身无抑郁症”为参照。拟控制配对因素，分析暴露与结局的关联，最恰当的方法是：

A. 因暴露有 7 类，采用无序多分类结局的 Logistic 回归。

B. 按配对组分层的条件 Logistic 回归，并对暴露设置哑变量。

C. 将暴露编码 1—7 后，采用有序结局的 Logistic 回归。

D. 忽略配对关系，把全部个体作为无配对资料直接分析。

E. 以配对编号为连续因变量，作一般线性回归。

名词解释

题 3.15　比例优势假设

名词解释：比例优势假设（Proportional Odds Assumption）。请结合有序 Logistic 模型说明。

简答题

题 3.16　总体检验、增量检验与拟合评价

正文 AMI 病例的 Logistic 分析报告：仅含截距模型的对数似然为 −122.172；含休克、心衰、抢救是否及时三个二分类变量的模型为 −111.308；仅含休克与心衰的模型为 −115.557。各模型使用同一批资料、相同的似然定义。

1）写出三个协变量的总体检验原假设、似然比统计量及自由度。

2）控制休克和心衰后，检验抢救是否及时的关联，应比较哪两个模型？

3）上述检验显著，能否据此认定模型已通过拟合优度检验？说明理由。

可用 $\chi^2_{0.05,1}=3.841$、$\chi^2_{0.05,3}=7.815$。

计算与综合分析题

题 3.17　配对四格表中的有效信息

某 1:1 配对病例对照研究共 80 对，只研究一个二分类暴露因素。表中每个数均为**配对数**。

	对照暴露	对照未暴露
病例暴露	18	30
病例未暴露	10	22

1）写出暴露系数 β 的条件似然，求 $\hat{\beta}$ 和配对 OR。

2）为什么两人暴露状态相同的对子不为该暴露系数提供信息？

3）若忽略配对，把病例、对照分别合并后按普通四格表求 OR，结果是多少？应采用哪个结果？

4）为什么此处不需估计每一配对组的截距？

题 3.18　无序多分类的概率与参照变换

正文以泡状细胞癌（$Y=3$）为参照，给出的三类肿瘤模型为

$$\log(P_1/P_3) = -0.9826 + 0.6281X_1 - 0.6494X_2,$$
$$\log(P_2/P_3) = -0.3461 + 0.3454X_1 - 0.6352X_2,$$

其中 $Y=1$ 为鳞癌，$Y=2$ 为腺癌；X_1, X_2 沿用正文方程中的数值编码。

1）对 $X_1 = 2, X_2 = 1$ 的对象，计算三类结局概率。

2）保持 X_2 不变，X_1 增加 1 单位时，腺癌相对鳞癌的概率比 P_2/P_1 乘以多少？

3）若分别把两个线性预测子代入二分类公式 $e^g/(1+e^g)$，能否直接当成 P_1, P_2？

题 3.19　有序结局的参数个数与解释

正文的视网膜病变案例将结局记为 1 无病变、2 轻度、3 中度、4 重度，采用

$$\log \frac{P(Y > j \mid X)}{P(Y \le j \mid X)} = -\alpha_j + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4.$$

四个自变量为 HbA1c（以% 为单位，如 7 表示 7%）、病程、年龄和性别；均各用一个系数，无交互项。正文报告 HbA1c 的 $\hat{\beta}_1 = 0.63$、$SE = 0.12$。

1) 模型需要估计几个阈值、几个斜率？若改用无序四分类 Logistic，共需几个参数？
2) 控制其他变量，HbA1c 从 7% 升到 9%，处于较高病变等级的累计 OR 是多少？计算其 Wald 近似 95% 置信区间，并明确比较的两类。
3) 补充设定平行线检验 $P = 0.018$。在 $\alpha = 0.05$ 下能否继续不加说明地用一个共同 OR 概括所有切点？

文献分析题

题 3.20　联合暴露结果表能回答什么

第 8 章样题称“某农村队列研究团队发表的一篇文章”，讨论空气污染、BMI 与中风。其 $PM_{2.5}$ 部分如下，所有 OR 均以“低暴露且 BMI 正常”为共同参照，并调整婚姻、教育、收入、饮酒、饮食和体力活动。

$PM_{2.5}$	BMI 正常：OR（95% CI）	BMI 偏高：OR（95% CI）
低暴露	1（参照）	1.25（1.09–1.42）
高暴露	1.93（1.75–2.12）	3.08（2.67–3.54）

1) 仅凭“队列研究团队”和此表，能否确定本篇分析属于前瞻性队列分析？还需核对什么？
2) 若采用含二分类暴露 E、BMI 分组 B 及 EB 交互项的 Logistic 模型，写出模型，并求 BMI 偏高者中高暴露相对低暴露的 OR。
3) 求乘法交互 OR 的点估计。仅据三个置信区间均未跨 1，能否认为交互作用有统计学意义？

本次补充习题

本组按正文章节补充 20 题，题型沿用原笔记；解析及来源与新增题号对应。

第 2 章补充：Logistic 回归模型（一）

单项选择题

每题只有一个最佳答案，请从 A—E 中选择。

题 3.21　同一 OR 与不同概率差

以下为教学设定。某二分类 Logistic 模型不含交互项，二分类暴露的调整 OR 为 3。在两个不同协变量层中，未暴露者的事件概率分别为 0.10 和 0.50。各层其他协变量保持不变时，暴露对应的概率增加量依次为（　）。

A. 0.30，0.30

B. 0.20，0.20

C. 0.20，0.50

D. 0.15，0.25

E. 0.10，0.50

题 3.22　病例对照抽样后的概率校正

以下为教学设定。人群中病例与非病例分别以概率 s_1、s_0 被抽入研究，$s_1/s_0 = 12$，且抽样只依赖结局。某协变量组合在样本 Logistic 模型中的预测病例概率为 0.60。若模型设定正确，该组合对应的人群事件概率为（　）。

A. 0.0500

B. 0.1111

C. 0.1250

D. 0.6000

E. 0.9474

题 3.23　分组二项响应的事件方向

对同一分组二项资料，用相同设计矩阵分别拟合

```
m1 <- glm(cbind(event, nonevent) ~ x1+x2,
          family=binomial, data=d)
m2 <- glm(cbind(nonevent, event) ~ x1+x2,
          family=binomial, data=d)
```

两模型均采用 logit 连接、含截距、没有惩罚项，并有唯一有限极大似然估计。下列结论正确的是（　）。

A. 只有截距变号，斜率保持不变。

B. 只有斜率变号，截距保持不变。

C. 全部系数与拟合概率均保持不变。

D. 第二个模型的残差偏差是第一个的相反数。

E. 全部系数变号，拟合概率互为补数，残差偏差相同。

题 3.24　三种检验分别需要哪些拟合

在多变量 Logistic 模型中检验 $H_0 : \beta_x = 0$，其他协变量的系数为干扰参数。正则条件成立。下列说法正确的是（　）。

A. 比分检验只需拟合 H_0 成立时的约束模型。

B. Wald 检验只需拟合 H_0 成立时的约束模型。

C. 似然比检验只需拟合含 x 的完整模型。

D. 比分检验要求把其他协变量的系数也全部置零。

E. 多变量 Wald 检验不能调整其他协变量。

题 3.25　1:2 匹配组的条件概率

以下为教学设定。一个 1:2 匹配组内三人的暴露值为 $x_A = 1$、$x_B = x_C = 0$。模型只有该暴露，$\beta = \log 2$。给定组内恰有 1 例病例，A 为病例的条件概率为（　）。

A. $1/3$

B. $2/3$

C. $1/2$

D. $1/4$

E. $4/5$

题 3.26　条件 Logistic 可估计的内容

关于按匹配组条件化的 Logistic 回归，有下列说法：

I. 在各组内取值恒定的协变量，其主效应从条件似然中消去。

II. 上述变量与一个组内变化暴露的交互项，也必定不能估计。

III. 组内谁成为病例的条件概率，一般不等于人群中的绝对发病概率。

正确的组合是（　）。

A. 仅 I。

B. I、III。

C. II、III。

D. I、II、III。

E. 仅 II。

简答、计算与案例分析

题 3.27　二次项与指定区间的 OR

某二分类 Logistic 模型为 $\operatorname{logit} p = \beta_0 + \beta_1 x + \beta_2 x^2 + \gamma^{\mathsf{T}} z$。

1）固定 z，写出 x 从 x_0 增加 Δ 时的 OR。能否用 e^{β_1} 统一表示每增加 1 单位的 OR?

2）以下系数为教学设定：$\beta_1 = 0.40$, $\beta_2 = -0.05$。比较 $x : 0 \to 1$ 与 $x : 4 \to 5$ 的 OR。

3）若检验 x 与结局是否有关，写出对该模型适用的联合原假设及自由度。

题 3.28　食管癌公开资料中的饮酒评分约束

法国食管癌病例对照公开资料有 200 例病例和 775 例对照，共 88 个年龄、饮酒、吸烟组合。年龄分 6 组，吸烟分 4 组；饮酒分 0–39、40–79、80–119、120+ g/天。以病例为成功结局，年龄和吸烟均按分类哑变量调整，比较以下三个模型，均含截距、不含交互项，并使用全部 88 行和同一分组二项似然。

饮酒项设定	最大对数似然
M_0：不含饮酒项	−162.662323
M_s：四组依次评分 $0,1,2,3$，含一个评分系数	−101.646905
M_f：以 0–39 为参照，含三个饮酒哑变量	−98.695896

M_f 中三个饮酒系数依次为 $\hat{b}_1 = 1.434629$, $\hat{b}_2 = 1.980717$, $\hat{b}_3 = 3.602869$。并有

$$\operatorname{Var}(\hat{b}_1) = 0.06253113, \quad \operatorname{Var}(\hat{b}_2) = 0.08108937, \quad \operatorname{Cov}(\hat{b}_1, \hat{b}_2) = 0.04266069.$$

1）求饮酒整体关联的似然比统计量和自由度。

2）写出 M_s 对 (b_1, b_2, b_3) 施加的约束，检验评分线性设定是否相对 M_f 造成显著拟合损失。

3）计算 80–119 相对 40–79 组的调整 OR 及 Wald 近似 95% 置信区间。

4）第（2）问若未拒绝，能否说已证明每日饮酒克数与 logit 成线性关系?

可用 $\chi^2_{0.05,2} = 5.991$、$\chi^2_{0.05,3} = 7.815$ 及 $z_{0.975} = 1.96$。

题 3.29　1:2 匹配六种模式的完整条件似然

以下为教学构造资料。36 个独立匹配组各有 1 例病例和 2 例对照，仅分析二分类暴露 x。c 为病例的暴露值，k 为两名对照中暴露者人数，表中频数按匹配组计。

c	k	组数
0	0	4
0	1	5
0	2	5
1	0	9
1	1	10
1	2	3

设 $r = e^{\beta}$，以每组病例数为 1 作条件化。按完整条件似然计算有 $\ell_c(0) = -39.550042$；在极大似然估计处，β 的观测信息为 $I(\hat{\beta}) = 5.9000$。

1）写出六种模式合并后的条件似然，求 $\hat{r}$ 与 $\hat{\beta}$。

2）哪些组不为 β 提供信息？有效信息来自多少组？

3）求 OR 的 Wald 近似 95% 置信区间，并用似然比检验 $H_0 : \beta = 0$。

4）说明这里的 OR 能否直接给出暴露者的人群发病概率。

可用 $z_{0.975} = 1.96$、$\chi^2_{0.05,1} = 3.841$。

题 3.30　平均预测正确是否足够

以下为教学设定。某二分类 Logistic 预测模型在独立验证资料中的结果如下；同组内所有人的预测概率均等于表中数值。

组别	人数	预测概率	观察事件数
A	50	0.10	15
B	50	0.30	5
C	50	0.50	25
D	50	0.70	35

研究者写道：“平均预测概率等于实际事件比例，且 $\sum_i (y_i - \hat{p}_i) = 0$，所以模型已得到充分校准；无需再比较各组预测与观察情况。”请评议这段结论，并说明应补充的分析。

第 3 章补充：Logistic 回归模型（二）

单项选择题

每题只有一个最佳答案，请从 A—E 中选择。

题 3.31　跨方程对比的方差

以下为教学设定。三分类多项 Logit 模型以 C 为参照；同一自变量在 A/C 和 B/C 方程中的系数估计为 $\hat{b}_A, \hat{b}_B$，标准误分别为 0.30、0.40，二者协方差为 0.08。改用 B 作参照后，A/B 方程该系数的标准误为（　）。

A. 0.10

B. 0.25

C. 0.30

D. 0.50

E. 0.70

题 3.32　正系数与类别概率的方向

以下为教学设定。三分类结局 A、B、C 的模型为 $\log(P_A/P_C) = x$、$\log(P_B/P_C) = 3x$。当 x 从 0 变为 1 时，P_A 的变化最接近（　）。

A. 从 0.3333 降为 0.1142。

B. 从 0.3333 升为 0.7311。

C. 从 0.3333 升为 0.9061。

D. 保持 0.3333 不变。

E. 不能归一化为三类概率。

题 3.33　有序等级反向编码

以下为教学设定。$Y \in \{1,2,3\}$ 满足 $\operatorname{logit} P(Y \le j \mid x) = \alpha_j - \beta x$，其中 $(\alpha_1, \alpha_2) = (-0.5, 1.0)$、$\beta = 0.8$。改记 $Y^* = 4 - Y$，并沿用 $\operatorname{logit} P(Y^* \le j \mid x) = \alpha_j^* - \beta^* x$，则新参数为（　）。

A. $(\alpha_1^*, \alpha_2^*) = (-0.5, 1.0)$，$\beta^* = -0.8$。

B. $(0.5, -1.0)$，$\beta^* = -0.8$。

C. $(-1.0, 0.5)$，$\beta^* = 0.8$。

D. $(1.0, -0.5)$，$\beta^* = 0.8$。

E. $(-1.0, 0.5)$，$\beta^* = -0.8$。

题 3.34　累积概率的合法次序

以下为教学设定。对一个三等级结局，同一协变量组合的两份独立二分类拟合分别给出 $\widehat{P}(Y \le 1) = 0.65$、$\widehat{P}(Y \le 2) = 0.55$。若把这两数直接用作同一个有序结局模型的累积概率，下列判断正确的是（　）。

A. $P(Y = 2) = 0.10$，取两数之差的绝对值即可。

B. $P(Y = 3) = 0.65$。

C. 两数各自在 0 和 1 之间，故一定对应合法分布。

D. 会得到 $P(Y = 2) = -0.10$，不能对应同一合法有序分布。

E. 因为两份模型都含截距，累积概率无须递增。

题 3.35　多类别预测因子的联合检验

无序结局有 4 类，某预测因子有 3 类，以其中一类为参照设置哑变量。完整模型允许该预测因子在每个非参照结局方程中有不同系数；其余模型项不变。用似然比检验该预测因子与结局是否有关，通常的自由度为（　）。

A. 2

B. 6

C. 3

D. 9

E. 12

题 3.36　比例优势的比较对象

某三等级比例优势模型采用 $\operatorname{logit} P(Y > j \mid x) = -\alpha_j + \beta x$，并有 $e^{\beta} = 2$。其他条件不变，x 增加 1 单位。有下列说法：

I. 对 $j = 1, 2$，高于切点相对不高于切点的优势都乘以 2。

II. 对 $j = 1, 2$，不高于切点相对高于切点的优势都乘以 $1/2$。

III. 相邻类别的概率比 $P(Y = 2)/P(Y = 1)$ 也必定乘以 2。

正确的组合是（　）。

A. 仅 I。

B. 仅 II。

C. I、II。

D. II、III。

E. I、II、III。

简答、计算与案例分析

题 3.37　分别二分拟合能做什么

对三级有序结局，研究者分别拟合 $Y > 1$ 和 $Y > 2$ 的二分类 Logistic 模型，比较两个斜率后，又拟把两模型的最大对数似然相加，作为一个有序模型的最大对数似然，用来进行正式的平行线似然比检验。请说明分别二分拟合的合理用途、这一相加做法的问题，以及正式比较应使用怎样的似然。

题 3.38　住宅满意度多项模型的联合与跨方程检验

Copenhagen 住宅调查的公开频数资料记录满意度 Sat（Low、Medium、High）、管理影响程度 Infl（3 类）、住宅类型 Type（4 类）、住户接触程度 Cont（Low、High）。以 Sat 的 Low 为参照，按人数 Freq 作权重，联合拟合

$$\log(P_k/P_{\text{Low}}) = a_k + b_k^{\mathsf{T}} x, \qquad k \in \{\text{Medium}, \text{High}\}.$$

其中 x 包含 Infl、Type 的分类哑变量及 Cont=High 指标，不含交互项。全部资料共 1681 名被调查者。完整模型的最大对数似然为 -1735.041933，删除全部 Type 哑变量后的模型为 -1766.155394；其余设定和分析集相同。Cont=High 相对 Low 的部分输出为

方程	系数	方差
Medium/Low	0.36085188	0.01752911
High/Low	0.48182700	0.01541001

这两个系数的协方差为 0.00810855。

1) 写出检验住宅类型整体关联的原假设、LR 统计量和自由度。
2) 调整 Infl 和 Type，求 Cont 从 Low 变为 High 时，High 相对 Medium 的概率比变化倍数及 Wald 近似 95% 置信区间。
3) 仅凭 High/Low 方程中的 Cont 系数较大，能否说其效应显著大于 Medium/Low 方程？

可用 $\chi^2_{0.05,6} = 12.592$ 和 $z_{0.975} = 1.96$。

题 3.39　住宅满意度的共同斜率模型

使用同一 Copenhagen 公开资料，按 Low<Medium<High 的次序拟合累积 Logit：

$$\operatorname{logit} P(Y \le j \mid x) = \alpha_j - \eta(x), \qquad j = 1, 2.$$

Infl 以 Low、Type 以 Tower、Cont 以 Low 为参照，均用分类哑变量，不含交互项。共同斜率模型部分输出为

参数	估计值
Low|Medium 阈值 α_1	−0.49613514
Medium|High 阈值 α_2	0.69070826
Cont=High 的共同斜率	0.36028400

以同一有序类别联合似然拟合的结果如下。非平行模型让每个切点有其自己的全部 6 个斜率，且在全部 24 个设计组合上约束累积概率合法递增。

模型	参数个数	最大对数似然
共同斜率	8	−1739.574650
非平行累积 Logit	14	−1735.289350

1）在 Infl=Low、Type=Tower 条件下，分别计算 Cont=Low 和 High 时的三类预测概率。

2）解释 Cont 共同斜率的指数，并核对“Medium 类别概率也必须上升”是否成立。

3）完成平行线似然比检验。能否将未拒绝原假设表述为已证明比例优势假设？

可用 $\chi^2_{0.05,6} = 12.592$。

题 3.40　遗漏频数权重后分析了什么

Copenhagen 住宅调查的 housing 数据有 72 行：每个 Infl×Type×Cont 组合恰好列出 Low、Medium、High 三个满意度类别各一行，共 24 个组合。Freq 记录对应的人数，按满意度合计如下。

满意度	表中行数	Freq 合计
Low	24	567
Medium	24	446
High	24	668

研究者执行

```
m <- nnet::multinom(Sat ~ Infl + Type + Cont,
                    data=housing, trace=FALSE)
```

得到接近 0 的斜率和各类约 1/3 的预测概率，写道：“72 名被调查者在三个满意度等级间均匀分布，所有因素均无关联。”请评议资料单位、这一输出为何出现，以及应如何改正分析。

习题解析

核对方式

按题号核对。缺失选项的补写及新编练习均在对应解析末尾说明。

作业题

解析 题 3.1　食管癌与饮酒：分层频数资料

返回题目

令 $D=1$ 表示饮酒 80+，以 0–79 为参照；年龄哑变量 A_2, A_3, A_4 分别表示 45–54、55–64、65+，以 25–44 为参照。按原题频数复算：

$$\operatorname{logit}(p) = -2.1515 - 1.6803D + 1.9719A_2 + 2.4871A_3 + 2.7409A_4.$$

变量	$\hat{\beta}$	SE	OR
饮酒 80+	−1.6803	0.1893	0.1863
45–54 岁	1.9719	0.3705	7.1845
55–64 岁	2.4871	0.3579	12.0269
65+ 岁	2.7409	0.3627	15.5014

这些系数的 Wald 检验均 $P<0.001$。控制年龄后，饮酒 80+ 组食管癌**优势**为参照组的 0.1863 倍；其余系数按同样方式解释。结果方向来自给定频数，不应凭常识改写数据。

总体检验：$H_0:\beta_D=\beta_{A_2}=\beta_{A_3}=\beta_{A_4}=0$。用似然比、联合 Wald 或 Score 检验；似然比 $G^2=2(\ell_{\text{full}}-\ell_{\text{null}})=197.53$，$df=4$，$P<0.001$。逐个检验不能替代严格的联合 Wald 检验。

评价可包括分组 Pearson/偏差、Hosmer–Lemeshow、校准、区分度及 AIC/BIC。原稿报告 HL $\chi^2=0.740, df=4, P=0.946$；伪 $R^2=0.1996$，逐人展开时 AIC 约 802。**分组频数与逐人展开的似然常数不同，AIC 和残差偏差不可跨编码直接对比；嵌套模型的似然比差值一致**。

校正。 OR 不是患病概率之比；BIC 应为 $-2\ell+k\log n$。原材料的逐项偏差表与其自身全模型输出不一致，以复算为准。

解析 题 3.2　睡眠质量与认知功能：文献分析

返回题目

（1）原评分口径与原文核对。 原材料写“前瞻性随访”；但原文使用 2008—2012 年第二次体检的 15,246 名 50 岁以上参加者，同次评价睡眠与认知。就本篇分析而言，应表述为**依托队列的横断面分析**，不能把队列平台名称等同于分析设计。

（2） DWRT 与 MMSE 分别为 0–10、0–30 分的连续评分；DWRT< 4 定义记忆障碍，MMSE< 25 定义认知功能差。DWRT 依次读 10 词并即时回忆，重复 3 次，第三次后延迟 5 分钟回忆，以正确词数计分。原文每词间隔**1 秒**，原评分稿写 15 秒有误。MMSE 涵盖定向、记忆、注意/计算、回忆与语言。

（3） Model 1 中入睡 > 60 分钟、效率 < 65% 及每周至少一次日间障碍的 OR 分别为 1.23、1.26、1.26，有统计学证据；前两类趋势 P 均为 0.04。Model 2 中入睡时间与日间障碍关联减弱

且区间跨 1。效率 $< 65\%$ 的分类对比原文仍标星，但其**记忆障碍趋势检验 $P = 0.08$，不再达到 0.05**，不能像原材料那样写趋势仍显著。其他因素均未显示明确关联。应同时说明 OR、区间、趋势与调整层次，避免把优势增幅写成风险增幅。

往年题

解析 题 3.3　Logistic 回归系数与优势比

返回题目

答案：C。

指数系数 $e^{\log 2} = 2$ 是优势比。给定基线概率 p，变换后的概率为 $2p/(1+p)$，通常不等于 $2p$。

补写说明。原稿第 12 题整题缺失；本题为新编练习，并非恢复的往年原题。

解析 题 3.4　总体回归系数检验

返回题目

答案：C。

总体原假设为除截距外所有回归系数同时为 0。

补写说明。原稿 A—D 保留；E 原记为 “H**** 检验”，此处补为 Hosmer–Lemeshow 检验，不能视为原选项的确证。

解析 题 3.5　优势比（Odds Ratio, OR）

返回题目

两个比较条件下事件优势 $p/(1-p)$ 的比。无交互的 Logistic 模型中，其他变量固定，X_j 增 1 单位对应 OR=e^{β_j}。

解析 题 3.6　有序 Logistic 的阈值与斜率

返回题目

必须先写模型方向。例如

$$\log \frac{P(Y \le i \mid X)}{P(Y > i \mid X)} = \alpha_i + \sum_j \beta_j X_j.$$

α_i 为 $X = 0$ 时第 i 个切点的累计对数优势；通常有 $K-1$ 个阈值。其他变量固定时，X_j 增加 1 单位，位于 “$\le i$” 而非 “$> i$” 的累计优势乘以 e^{β_j}，此 OR 对所有切点相同（比例优势假设）。若写成 $\alpha_i - X^T\beta$，正系数对应向高等级移动，解释方向应同步改变。不能笼统说 “每升一级的 OR”。

解析 题 3.7　Logistic 偏回归系数的含义

返回题目

其他变量固定时，X_j 增 1 单位所对应的条件对数优势改变量为 β_j，OR 为 e^{β_j}。存在交互时，效应还依赖交互变量水平；不能将 OR 直接解释为概率比。

解析 题 3.8　有序结局的共同斜率

返回题目

比例优势模型对所有累计切点使用共同斜率。先规定 $\log\{P(Y \le k)/P(Y > k)\} = \alpha_k + X^T\beta$，则增 1 单位的累计 OR 为 e^{β_j}，与切点无关；若使用减号参数化则方向反转。不能解释为固定 “上升一级” 的概率比。

解析 题 3.9　吸烟与饮酒的交互作用（2020）

返回题目

令吸烟 S、饮酒 D 为 0/1，$\operatorname{logit} p = \beta_0 + 0.693S + 1.099D + 0.405SD$。

（1）$\mathrm{OR}_{11:00} = e^{0.693+1.099+0.405} \approx 2 \times 3 \times 1.5 = 9$。

（2）在 $D = 1$ 中比较吸烟与不吸烟：$\mathrm{OR}_{S|D=1} = e^{0.693+0.405} \approx 3$。

原题用语校正。模型能给出优势比，不能据此直接求绝对发病风险；缺少截距时不能计算个体概率。原材料（1）漏掉交互项，写成 6，应改为 9。

解析 题 3.10　吸烟与饮酒的交互作用（2021）

返回题目

令吸烟 S、饮酒 D 为 0/1，$\operatorname{logit} p = \beta_0 + 0.693S + 1.099D + 0.405SD$。

（1）$\mathrm{OR}_{11:00} = e^{0.693+1.099+0.405} \approx 2 \times 3 \times 1.5 = 9$。

（2）在 $D = 1$ 中比较吸烟与不吸烟：$\mathrm{OR}_{S|D=1} = e^{0.693+0.405} \approx 3$。

原题用语校正。模型能给出优势比，不能据此直接求绝对发病风险；缺少截距时不能计算个体概率。原材料（1）漏掉交互项，写成 6，应改为 9。

解析 题 3.11　分层分析与年龄混杂

返回题目

粗表为暴露发病 169、不发病 131；未暴露发病 79、不发病 221。

$$\mathrm{OR}_{\mathrm{crude}} = \frac{169 \times 221}{131 \times 79} = 3.609.$$

两个年龄层的 OR 分别为 $89 \times 41/(11 \times 59) = 5.622$、$80 \times 180/(120 \times 20) = 6.000$，相近。

$$\mathrm{OR}_{\mathrm{MH}} = \frac{89 \times 41/200 + 80 \times 180/400}{11 \times 59/200 + 120 \times 20/400} = 5.867.$$

R 复算的连续性校正 MH 检验 $\chi^2 = 69.567$，$P < 0.001$，95% CI 为 3.788–9.088；年龄调整后仍有关联。

两层暴露各 100、200 人，未暴露也各 100、200 人，因此年龄在暴露组与未暴露组的分布完全相同！在风险比尺度，粗 RR=[169/300]/[79/300] = 2.139；按相同年龄权重标准化仍为 2.139。粗 OR 与条件 OR 不同可由 **OR 非可折叠性** 导致，不能仅凭 3.609 与 5.867 差异宣布年龄是混杂因素。

答题建议。年龄是结局的强预测因素，但此表中与暴露独立，按常见混杂定义没有证据认为年龄混杂了暴露—发病关系。说明效应尺度与非可折叠性；若课程按“粗 OR 与分层 OR 差异”判断，应指出该经验标准在本表的局限。

解析 题 3.12　380 对配比病例对照研究

返回题目

若 380 对为个体 1:1 匹配，则为配比病例对照研究，常用条件 Logistic 回归；若只是频数匹配，应据原设计决定分析，回忆稿不足以绝对确认。

条件 Logistic 按匹配组条件化，可控制组层面的匹配因素并估计其他因素调整 OR；不能估计组内不变的匹配因素效应，信息主要来自组内暴露不一致的组合，且不能直接得到人群绝对发病概率。

各组截距是干扰参数，通过条件似然消去，因此无需另外估计公共 β_0。控制其他协变量及匹配组后，β_j 是 X_j 增加 1 单位的对数 OR，e^{β_j} 是相应 OR；结合 95% CI 是否跨 1 和 P 值报告。原表缺失，不能给出具体数值解释。

解析 题 3.13　低出生体重的影响因素

返回题目

整理者复算示例，非原卷标准答案。 先筛选 $age \geq 18$，按题目以 low 为结局；不将用于定义结局的 bwt 作为解释变量。分类变量设置参照组，使用二项分布、logit 连接。原始 189 条记录中 183 条满足年龄条件；采用所列协变量与结局的完整记录分析，最终 108 条、44 个事件。未依据出生体重推填缺失 low，也未擅自删除测量值相同的不同编号记录。

模型：$\operatorname{logit} p = \beta_0 + \beta_1 age + \beta_2 lwt +$ 种族哑变量 + 吸烟 $+ ptl +$ 高血压 + 应激性 $+ ftv$。

该设定下 lwt 系数 -0.0183（$P = 0.048$）；种族 2、3 相对 1 的系数分别 1.8377、1.1117（$P = 0.0108, 0.0474$）；吸烟系数 1.1530，OR 约 3.168（$P = 0.039$）。其余变量在 0.05 水平无明确证据。缺失比例高，完整记录结果可能受选择偏倚影响，不应当作唯一答案。还应检查共线性、连续变量在 logit 尺度的函数形式、影响点及拟合。完整 R 代码和参数表随包提供。

补充练习

解析 题 3.14　根据结局与设计选择 Logistic 模型

返回题目

答案：B。结局是二分类，且采用个体配对设计，应按配对组建立条件 Logistic 模型。七分类的是**暴露变量**，可设 6 个哑变量；这不使结局变成多分类。模型类别不能只看自变量有几个水平。

解析 题 3.15　比例优势假设

返回题目

按正文方向写为

$$\log \frac{P(Y > j \mid X)}{P(Y \leq j \mid X)} = -\alpha_j + X^T \beta, \quad j = 1, \ldots, K-1.$$

比例优势假设指同一自变量在所有累计分界点使用同一个斜率。其他条件相同，X_i 增加 1 单位，对任意切点 j，处于高于该切点的累计优势均乘以 e^{β_i}。阈值 α_j 可以不同。有的资料将其称为“等比例风险假定”，但这里的英文是**proportional odds**，应与 Cox 的比例风险假设区分。

解析 题 3.16　总体检验、增量检验与拟合评价

返回题目

(1) $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$，不包括截距。

$$G^2 = 2[-111.308 - (-122.172)] = 21.728, \quad df = 3.$$

拒绝 H_0，三个协变量整体上改善了相对零模型的拟合。

(2) 比较三变量模型与只含休克、心衰的模型：

$$\Delta G^2 = 2[-111.308 - (-115.557)] = 8.498, \quad df = 1.$$

拒绝 $H_0 : \beta_{\text{及时}} = 0$，提示该变量在控制另外两项后仍有统计学关联。

(3) 不能。与零模型相比有改进、增加一项有价值，均不等于所选模型与实际数据足够一致。绝对拟合评价可用适用条件下的分组 Pearson、偏差或 Hosmer–Lemeshow 检验，并检查残差。偏差 $D = 2(\ell_{\text{sat}} - \ell_{\text{fit}})$ 以饱和模型为参照；总体似然比检验以零模型为参照。

解析　题 3.17　配对四格表中的有效信息　　返回题目

(1) 暴露不一致的对子中，病例暴露的条件概率为 $e^{\beta}/(1+e^{\beta})$。因此

$$L_c(\beta)=\left(\frac{1}{2}\right)^{40}\left(\frac{e^{\beta}}{1+e^{\beta}}\right)^{30}\left(\frac{1}{1+e^{\beta}}\right)^{10}.$$

忽略常数，$\ell_c = 30\beta - 40\log(1+e^{\beta})$，求导为零得

$$e^{\hat\beta}=\frac{30}{10}=3,\qquad \hat\beta=\log 3=1.0986.$$

(2) 暴露一致时组内暴露差为 0，该对子贡献为 1/2，与 β 无关。本题中 40 对暴露不一致的对子提供暴露效应信息。

(3) 合并后病例暴露 48、未暴露 32；对照暴露 28、未暴露 52，所得 $\mathrm{OR}_{\text{忽略配对}} = 48\times 52/(32\times 28) = 2.7857$。本设计应采用利用配对关系的估计 3，不能用忽略配对的结果替代。

(4) 给定每对恰有 1 例病例，组截距在病例与对照的优势比较中消去，条件似然不含这些干扰参数。

解析　题 3.18　无序多分类的概率与参照变换　　返回题目

(1) $g_1 = -0.3758$、$g_2 = -0.2905$。三类概率必须共同归一化：

$$P_3=\frac{1}{1+e^{g_1}+e^{g_2}},\quad P_1=\frac{e^{g_1}}{1+e^{g_1}+e^{g_2}},\quad P_2=\frac{e^{g_2}}{1+e^{g_1}+e^{g_2}}.$$

所得数值约为 $P_1 = 0.2821$、$P_2 = 0.3072$、$P_3 = 0.4107$，四舍五入前总和为 1。

(2) 两式相减可得 $\log(P_2/P_1) = g_2 - g_1$，故相应概率比乘以

$$\exp(0.3454-0.6281)=\exp(-0.2827)=0.7537.$$

这是 P_2/P_1 的变化倍数，不是腺癌自身概率 P_2 的变化倍数。

(3) 不能。$e^{g_1}/(1+e^{g_1}) = P_1/(P_1+P_3)$，它是在只考虑类别 1 与 3 条件下的概率，并非三分类总体中的 P_1。正文的多分类模型要求 $P_1+P_2+P_3=1$。

解析　题 3.19　有序结局的参数个数与解释　　返回题目

(1) 有序模型有 3 个阈值和 4 个共同斜率，共 7 个参数。无序模型以一类为参照，需 3 套“截距 +4 个斜率”，共 $3(1+4)=15$ 个参数。

(2) HbA1c 增加的是**2 个百分点**，即 $\Delta X_1 = 2$。

$$\widehat{\mathrm{OR}}=e^{2\times 0.63}=3.5254,\qquad 95\%\,CI=\exp\{2(0.63\pm 1.96\times 0.12)\}\approx(2.2025,5.6429).$$

分别比较 $Y>1$ 与 $Y\le 1$、$Y>2$ 与 $Y\le 2$、$Y>3$ 与 $Y\le 3$。在比例优势假设下，三种切分对应相同 OR。不能写成“恰好升高一级的概率增加到 3.53 倍”。

(3) 平行线检验的 H_0 是各切点斜率相同。$P=0.018$ 提示不满足这一约束，应检查模型设定，考虑允许切点效应不同的模型并据其结果解释。第（2）问是在共同斜率模型成立条件下的计算，不能忽略本项诊断直接作为最终结论。检验值为本题教学设定，并非实测结果。

解析 题 3.20　联合暴露结果表能回答什么

返回题目

(1) 不能确定。需看暴露与结局测量的先后、是否排除基线已有中风者、是否随访新发中风，以及本次分析实际使用的资料。队列团队也可能发表基线横断面分析，表中 OR 不能唯一确定研究设计。

(2) 令 $E = 1$ 为高暴露、$B = 1$ 为 BMI 偏高，Z 为调整变量：

$$\operatorname{logit} p = \beta_0 + \beta_E E + \beta_B B + \beta_{EB} EB + \gamma^T Z.$$

在同一模型及相同调整条件下，BMI 偏高者中高暴露相对低暴露的 OR 为

$$e^{\beta_E + \beta_{EB}} = \frac{3.08}{1.25} = 2.464.$$

表中 3.08 比较的是“双重暴露”与共同参照，不能直接当作 BMI 偏高层内的空气污染 OR。

(3) $e^{\hat{\beta}_{EB}} = 3.08/(1.93 \times 1.25) = 1.2767$。它是两层空气污染 OR 之比。检验交互需检验 $H_0 : \beta_{EB} = 0$，使用交互项标准误或含、无交互项的似然比检验。现表未给参数协方差或模型似然，不能求其准确标准误、置信区间或显著性；不能直接相除置信区间端点。

本次补充习题解析

第 2 章补充解析

解析　题 3.21　同一 OR 与不同概率差

返回题目

答案：D。设未暴露者概率为 p_0，由 $\{p_1/(1-p_1)\}/\{p_0/(1-p_0)\} = 3$，得 $p_1 = 3p_0/(1-p_0+3p_0)$。两层的暴露者概率分别为 0.25 和 0.75，故概率差分别为 0.15 和 0.25。共同 OR 约束的是优势尺度上的倍数，不能据此要求各层有相同概率差，也不能把基线概率直接乘 3。

来源与改编：知识点配套。题干与设问为新编；参考依据[7]。

解析　题 3.22　病例对照抽样后的概率校正

返回题目

答案：B。样本优势为 $0.60/0.40 = 1.5$。结局依赖抽样使样本优势等于人群优势乘 s_1/s_0，因此人群优势为 $1.5/12 = 0.125$，概率为 $0.125/(1+0.125) = 1/9 \approx 0.1111$。等价地，从样本线性预测子中减去 $\log 12$ 后取逆 logit。直接把样本概率除以 12 得到 0.05 并不正确；校正发生在优势或 logit 尺度。

来源与改编：知识点配套。题干与设问为新编；参考依据[7]。

解析　题 3.23　分组二项响应的事件方向

返回题目

答案：E。交换成功与失败两列后，模型化的概率变为 $1-p$。由于 $\operatorname{logit}(1-p) = -\operatorname{logit}(p)$，同一设计矩阵下全部系数（含截距）均变号，拟合概率互为补数。分组二项似然及其饱和模型也相应交换成功、失败，最大似然值和残差偏差不变。此结论依赖两次拟合使用相同资料和模型空间；不能只把斜率或只把截距变号。

来源与改编：知识点配套。题干与设问为新编；参考依据[7]、[2]。

解析　题 3.24　三种检验分别需要哪些拟合

返回题目

答案：A。有效比分检验在 H_0 约束下拟合干扰参数，再用约束点的得分和扣除干扰参数影响后的信息构造统计量，因此只需约束模型。Wald 检验使用完整模型的估计及协方差；似然比检验须分别极大化约束和非约束模型。比分检验不是把其余系数也全部置零；多变量 Wald 检验同样可以调整模型中的其他协变量。

来源与改编：知识点配套。题干与设问为新编；参考依据[7]、[10]。

解析　题 3.25　1:2 匹配组的条件概率

返回题目

答案：C。给定组内病例数为 1，A 的条件概率为 $\exp(\beta x_A)/\{\exp(\beta x_A) + \exp(\beta x_B) + \exp(\beta x_C)\} = 2/(2+1+1) = 0.5$。组截距在条件化时消去。$2/(1+2)$ 只适用于本例中有 1 名暴露者和 1 名未暴露者的两人比较，没有计入第二名对照；这里计算的也不是 A 在人群中的绝对发病概率。

来源与改编：知识点配套。题干与设问为新编；参考依据[7]、[11]。

解析　题 3.26　条件 Logistic 可估计的内容

返回题目

答案：B。I 正确：同组公共项在条件概率的分子、分母中相消。II 错误：若匹配因素 Z 在组内恒定，交互项的组内差仍为 $Z_i(x_{Ai}-x_{Bi})$；当不同 Z 层均有足够组内暴露变异、设计矩阵可识别时，可以估计暴露效应是否随 Z 改变。III 正确：条件概率以组内病例数为条件，组截距已消去，不能直接恢复人群绝对风险。

来源与改编：知识点配套。题干与设问为新编；参考依据[7]、[11]。

解析　题 3.27　二次项与指定区间的 OR

返回题目

固定其他协变量，两点的线性预测子之差为

$$\Delta\eta=\beta_1\Delta+\beta_2\{(x_0+\Delta)^2-x_0^2\}=\beta_1\Delta+\beta_2(2x_0\Delta+\Delta^2).$$

因此 $\mathrm{OR}=\exp(\Delta\eta)$。当 $\Delta=1$ 时，OR 为 $\exp\{\beta_1+\beta_2(2x_0+1)\}$，随起点 x_0 变化；只解释 e^{β_1} 会漏掉二次项贡献。教学系数下，$0\to1$ 对应 $\exp(0.40-0.05)=1.4191$，而 $4\to5$ 对应 $\exp(0.40-0.45)=0.9512$。这反映 logit 曲线在不同区间的变化方向可能不同，不宜用单个“每单位效应”概括全部取值。

若要检验整个 x 项，应检验 $H_0:\beta_1=\beta_2=0$，在通常正则条件下用 2 个自由度的联合检验。只检验 $\beta_1=0$ 并不能排除二次关联；若检验是否需要二次项，则另用 1 个自由度检验 $\beta_2=0$。

来源与改编：知识点配套。题干与设问为新编；参考依据[7]。

解析　题 3.28　食管癌公开资料中的饮酒评分约束

返回题目

M_0、M_s、M_f 分别有 $1+5+3=9$、10 和 12 个参数。饮酒整体检验为 $H_0:b_1=b_2=b_3=0$，

$$G^2=2[-98.695896-(-162.662323)]=127.9329,\qquad df=3,$$

提示调整年龄和吸烟后饮酒组与病例状态有关。

评分模型要求 $(b_1,b_2,b_3)=(\theta,2\theta,3\theta)$，相当于 $b_2-2b_1=0$、$b_3-3b_1=0$ 两个独立约束。

$$G_s^2=2[-98.695896-(-101.646905)]=5.9020,\qquad df=2.$$

在 0.05 水平未拒绝这些约束，$P=0.0523$，但这一接近阈值的结果并不能证明线性设定成立。

两个非参照饮酒组的比较必须使用系数差及其协方差：

$$\begin{aligned}\hat d&=\hat b_2-\hat b_1=0.546089,\\ \mathrm{SE}(\hat d)&=\sqrt{0.08108937+0.06253113-2(0.04266069)}=0.241452,\\ \widehat{\mathrm{OR}}&=e^{\hat d}=1.7265,\qquad 95\%\,CI=\exp\{\hat d\pm1.96(0.241452)\}=(1.0756,2.7714).\end{aligned}$$

这是同年龄、同吸烟组条件下的病例优势比。评分的 1 单位表示跨一个人为排列的类别；最高组还是开放区间。没有个体实际饮酒克数，不能把评分约束解释为每增加固定克数的剂量线性关系，更不能仅凭未拒绝原假设加以证明。

来源与改编：案例改编。材料及改编范围见[7]、[8]、[9]、[10]。

解析　题 3.29　1:2 匹配六种模式的完整条件似然

返回题目

一组中共 $c+k$ 名暴露者，病例的条件概率为 $r^c/\{(c+k)r+3-c-k\}$。合并各模式，

$$L_c(\beta)=3^{-7}\frac{r^{19}}{(r+2)^{14}(2r+1)^{15}},\qquad r=e^{\beta}.$$

因此 $U(\beta)=19-14r/(r+2)-30r/(2r+1)$。令得分为 0，整理得 $20r^2-21r-38=0$；唯一正根为 $\hat r=2$，故 $\hat\beta=\log 2=0.693147$。所有人都未暴露的 4 组和都暴露的 3 组各贡献 1/3，其贡献与 β 无关；剩余 $36-7=29$ 组提供暴露效应信息。

信息给出 $\mathrm{SE}(\hat\beta)=1/\sqrt{5.9}=0.411693$，

$$95\%\,CI_{\mathrm{OR}}=\exp\{0.693147\pm 1.96(0.411693)\}=(0.8925,4.4820).$$

将 $\hat r=2$ 代回完整条件似然，$\ell_c(\hat\beta)=-38.070179$，故

$$G^2=2[-38.070179-(-39.550042)]=2.9597,\qquad df=1,\quad P=0.0854.$$

在 0.05 水平未拒绝无关联假设，但区间较宽，不能据此认定暴露毫无作用。以上 Wald 和 LR 推断都是渐近近似。OR=2 描述匹配条件下的优势比较；组截距已消去，且设计只固定组内病例数，因此不能从该 OR 或条件分配概率直接恢复人群绝对发病概率。

来源与改编：知识点配套。题干与设问为新编；参考依据[7]、[11]。

解析　题 3.30　平均预测正确是否足够

返回题目

全样本观察到 $15+5+25+35=80$ 个事件，模型期望事件数为 $50(0.10+0.30+0.50+0.70)=80$，两者总体比例均为 0.40，故残差总和确为 0。但这一等式只约束整体平均水平：A 组观察比例 0.30 而预测 0.10，低估 10 个事件；B 组观察比例 0.10 而预测 0.30，高估 10 个事件，两项误差恰好抵消。C、D 组的观察比例分别为 0.50、0.70，与预测相同。

在含截距、未惩罚且有限 MLE 存在的普通二项 logit 模型中，训练样本的截距得分方程本来就可导致预测与观察事件总数相等；它从不保证每个风险层均校准良好。本题是独立验证资料，这个总量等式即使仍成立，也不能升级为逐组校准的证明。

应报告各组观察比例和相应不确定性，绘制观察比例对预测概率的校准图，检查 A、B 组是否存在系统偏离及其协变量构成，必要时重新评估函数形式或校准。组内样本比例本身也有抽样波动，不能只凭差值就断言总体偏差的精确大小。若调整模型，仍需另外验证；平均比例相等不能替代这些检查，也不能评价全部预测性能。

来源与改编：知识点配套。题干与设问为新编；参考依据[7]、[2]。

第 3 章补充解析

解析　题 3.31　跨方程对比的方差

返回题目

答案：C。 新系数为 $\hat b_A-\hat b_B$，应使用其联合估计协方差：$\mathrm{Var}(\hat b_A-\hat b_B)=0.30^2+0.40^2-2(0.08)=0.09$，标准误为 0.30。原两方程在同一联合似然中估计，系数一般不独立。把两个方差直接相加得到 0.50，或把两个标准误直接相减，均不正确。本题给定的 2×2 协方差矩阵正定。

来源与改编：知识点配套。题干与设问为新编；参考依据[12]、[17]。

解析　题 3.32　正系数与类别概率的方向

返回题目

答案：A。$x=0$ 时三类概率均为 1/3。$x=1$ 时 $P_A=e/(1+e+e^3)=0.1142$，而 P_A/P_C 的确乘以 e。A/C 方程正斜率描述 A 相对 C 的概率比上升；B 的线性预测子增长更快，归一化分母增大得更多，仍可使 A 本身的概率下降。因此不能把多项 Logit 的正系数直接解释为该类别绝对概率一定上升。

来源与改编：知识点配套。题干与设问为新编；参考依据[12]、[17]。

解析　题 3.33　有序等级反向编码

返回题目

答案：E。$P(Y^*\le j)=P(Y\ge 4-j)=1-P(Y\le 3-j)$，故 $\operatorname{logit}P(Y^*\le j)=-\alpha_{3-j}+\beta x$。新阈值应先倒序再变号，得到 $(-1.0,0.5)$；新共同斜率为 -0.8。只给斜率变号而保留原阈值不够，直接逐个阈值变号也会破坏阈值次序。反向编码改变高低方向，原类别对应的预测概率并未改变。

来源与改编：知识点配套。题干与设问为新编；参考依据[12]、[16]。

解析　题 3.34　累积概率的合法次序

返回题目

答案：D。有序结局必须满足 $P(Y\le 1)\le P(Y\le 2)$，且 $P(Y=2)=P(Y\le 2)-P(Y\le 1)$。给定值相减为 -0.10，不可能是类别概率。两个数各自都落在 $(0,1)$ 内并不够；它们还须彼此满足同一分布的次序约束。事后取绝对值或任意重新归一化会改变原模型，不能当作其合法预测。

来源与改编：知识点配套。题干与设问为新编；参考依据[12]、[16]。

解析　题 3.35　多类别预测因子的联合检验

返回题目

答案：B。预测因子需要 $3-1=2$ 个哑变量，无序结局有 $4-1=3$ 个非参照方程，需同时约束 $2\times 3=6$ 个系数为 0。这里按实际系数数目计数，不能只数原始变量 1 个、结局方程 3 个或预测因子水平 3 个。该结论要求比较同一分析集的嵌套、可识别模型并满足通常的大样本正则条件。

来源与改编：知识点配套。题干与设问为新编；参考依据[12]、[17]。

解析　题 3.36　比例优势的比较对象

返回题目

答案：C。I 为比例优势模型在题设方向下的定义。II 将同一比较倒置，因此 OR 取倒数。III 把累计切点两侧的比较换成了相邻类别比较，后者不是比例优势模型施加的约束。例如取阈值 $(-0.5,1)$、$\beta=\log 2$，x 从 0 到 1 时，相邻概率比 $P(Y=2)/P(Y=1)$ 的变化倍数约为 1.5761，并非 2。

来源与改编：知识点配套。题干与设问为新编；参考依据[12]、[16]。

解析　题 3.37　分别二分拟合能做什么

返回题目

分别二分拟合可作为诊断：在同一方向下比较两个切点的斜率或 OR，查看差异是否提示比例优势假设需要进一步检查。但两个响应来自同一个 Y，如 $Y>2$ 必然意味着 $Y>1$，并非两份独立样本。其二项似然相乘会重复计算同一受试者的信息，不能直接作为原有序结局的联合似然；斜率估计也不能默认相互独立。

正式似然应先定义同一协变量组合下两个合法递增的累积概率 F_1,F_2，再使用

$$P(Y=1)=F_1,\quad P(Y=2)=F_2-F_1,\quad P(Y=3)=1-F_2.$$

每个个体只按其实际类别贡献相应概率；频数资料则将类别对数概率乘以频数。共同斜率模型与允许切点斜率不同的模型，必须在同一合法有序模型族及同一批资料中分别最大化这个联合似然，再按独立约束数计算 LR 检验自由度。分别拟合的累计概率还可能交叉，产生负的中间类别概率，因而不能不经检查就相减作为最终预测。

来源与改编：知识点配套。题干与设问为新编；参考依据[12]、[16]。

解析　题 3.38　住宅满意度多项模型的联合与跨方程检验

返回题目

Type 在每个非参照方程中各占 3 个哑变量，原假设是这两套共 6 个 Type 系数同时为 0。完整模型有 $2(1+2+3+1)=14$ 个参数，删除 Type 后为 8 个。

$$G^2 = 2[-1735.041933-(-1766.155394)] = 62.2269, \qquad df = 6.$$

$P \approx 1.59\times10^{-11}$，提示控制 Infl、Cont 后，住宅类型与满意度类别分布有关；这不代表每一种住宅类型的每个对比均显著。

High 与 Medium 直接比较，系数为两个原方程 Cont 系数之差：

$$\begin{aligned}
\hat{d} &= 0.48182700 - 0.36085188 = 0.12097512,\\
\mathrm{SE}(\hat{d}) &= \sqrt{0.01541001 + 0.01752911 - 2(0.00810855)} = 0.129314,\\
\widehat{\mathrm{RRR}} &= e^{\hat{d}} = 1.1286,\\
95\%\,CI &= \exp\{\hat{d} \pm 1.96\,\mathrm{SE}(\hat{d})\} = (0.8759, 1.4542).
\end{aligned}$$

因此，在调整条件相同的情况下，Cont=High 与 Low 相比，$P_{\mathrm{High}}/P_{\mathrm{Medium}}$ 的点估计约增加 12.9%；区间包含 1，没有充分证据说明两原方程 Cont 效应存在差别。分别看两个系数是否显著、或只比较点估计大小，都不能替代这个使用联合协方差的差异检验。

来源与改编：案例改编。材料及改编范围见[12]、[13]、[14]、[15]、[17]。

解析　题 3.39　住宅满意度的共同斜率模型

返回题目

给定 Infl=Low、Type=Tower，其他哑变量均为 0，两种 Cont 条件的线性预测子分别为 $\eta=0$ 与 0.360284。记 $F_j = \mathrm{logit}^{-1}(\alpha_j-\eta)$，则三类概率为 $(F_1, F_2-F_1, 1-F_2)$，得到

Cont	Low	Medium	High
Low	0.3784	0.2877	0.3339
High	0.2981	0.2838	0.4181

$e^{0.360284}=1.4337$，即控制 Infl、Type 后，较高接触程度相对较低接触程度，对任一切点“高于该切点”相对“不高于该切点”的优势乘以 1.4337。这里 Medium 的概率从 0.2877 略降到 0.2838，足以说明共同正斜率不要求每一类别的概率都上升；中间类别由两个同时变化的累积概率相减得到。

平行线原假设要求两切点的 6 个对应斜率分别相同，故有 6 个约束：

$$G^2 = 2[-1735.289350-(-1739.574650)] = 8.5706, \qquad df=6, \quad P=0.1992.$$

在 0.05 水平未发现违背共同斜率约束的充分证据，不能说已证明该假设。题中备择是合法、嵌套的非平行累积 Logit；不能把第 08 题无序多项模型的对数似然代入此处，后者与比例优势模型一般不是这种嵌套关系。预测和诊断仍应结合实际设计组合及样本信息解释。

来源与改编：案例改编。材料及改编范围见[12]、[13]、[14]、[15]、[16]。

解析 题 3.40　遗漏频数权重后分析了什么

返回题目

72 是列联表的行数，不是被调查者人数；实际频数总和为 $567+446+668=1681$。真实三类构成分别为 $567/1681=0.3373$、$446/1681=0.2653$ 和 $668/1681=0.3974$，并不各占 $1/3$。

代码没有使用 Freq，每一行被当成一个等权观测。由于每个自变量组合恰好含三类各一行，软件看到的是一个人为构造的完全平衡数据集：每种组合的三类频数均为 $(1,1,1)$。因此首类为参照时，零截距、零斜率就给出各类概率 $1/3$ 并达到该人工资料的最大似然。这个输出是遗漏频数的结果，不能用于宣布原调查没有关联。

应明确满意度类别与自变量参照，使用 `weights=Freq` 拟合联合多项模型，或先把频数表按人数展开后拟合；两者使用相同的个体类别对数似然，系数和适当的模型比较应一致。若利用等级顺序，可以另拟合有序模型并检查共同斜率条件。这里首先需纠正资料单位和似然贡献，不能仅凭错误模型的输出去删掉预测因子。

来源与改编：案例改编。材料及改编范围见[12]、[13]、[14]、[15]、[17]。

第 4 章

生存分析（一）

主要内容

生存分析的基本概念；生存率的估计方法（统计描述）；生存曲线比较的方法（统计推断：单因素分析）；Cox 回归分析（多因素分析）；生存分析方法的正确应用。若所有研究对象均随访至死亡，生存时间即为普通的连续变量，可计算均数，进行 t 检验或回归分析。生存资料的特殊性在于删失：随访结束时仍存活者与中途失访者，其生存时间仅知道不短于观察时间。这部分对象不能剔除（剔除后只剩死亡较早者，生存被低估），不能按死亡处理，也不能视为存活至随访结束以后。

生存分析的各种方法均围绕如何利用删失数据所提供的部分信息展开。本章的主要内容为：Kaplan–Meier 法将删失者纳入风险集以估计生存率；log-rank 检验在每个死亡时刻比较实际死亡数与期望死亡数。第 5 章的 Cox 回归将这一思路推广至多因素分析。

本章需注意区分以下几组概念：生存概率与生存率，风险函数与死亡概率，累积风险与累积发生概率。

4.1 生存分析的基本概念

4.1.1 生存分析

在许多医学研究中，我们不仅关心终点事件（terminal event）是否发生，还关心发生终点事件经历了多长时间，如恶性肿瘤治疗随访：复发与否、死亡与否（5 年生存率）。

生存分析（survival analysis）是将终点事件的发生与否和到达终点所经历的时间结合起来分析的一类统计方法。源于古老的寿命表，是现代统计学的一个重要分支。

例 1 某医院胸外科的研究人员选择了在 1996 年至 2010 年间接受手术治疗的胃癌患者作为研究对象，对可能影响胃癌术后生存的因素进行了调查。关注是否出现了感兴趣的终点事件或结局（死亡），还关注出现该结局所经历的时间长短。研究因素及分组见表 1。

随访截止日期为 2010 年 12 月 30 日，患者的生存结局（死亡与否）通过查阅病历、电话和信访的方式获得，其中 6 例随访记录见表 2。

表 1　胃癌患者生存资料变量赋值表

变量	因素	分组及赋值
age	年龄	岁
grade	肿瘤分级	I 级：1；II 级：2；III 级：3
size	肿瘤大小（cm）	<3.0：0；≥ 3.0：1
relapse	是否复发	未复发：0；复发：1
start	手术日期	月/日/年
end	终止观察日期	月/日/年
t	生存时间	月
status	生存结局	删失：0；死亡：1

批注 死亡/失访/研究结束。

表 2　6 例胃癌患者生存资料原始记录表

id	age	grade	size	relapse	start	end	t	status	结局
1	76	3	0	1	1996/03/27	1996/08/24	5	0	失访
2	23	2	1	0	1997/12/17	2000/08/03	32	1	死亡
3	52	2	1	0	1998/09/16	2001/02/02	29	1	死亡
4	74	2	1	1	1996/04/29	1997/02/23	10	1	死亡
5	67	3	0	1	1998/01/16	1998/04/16	3	0	死于其他
6	47	1	0	0	1997/02/10	2010/12/30	167	0	存活

4.1.2 完全数据

随访研究中，在规定的观察期内，观察到了终点事件的发生，从起点到终点事件发生所经历的时间，称为生存时间的完全数据（complete data）。表 2 中患者 2 号、3 号和 4 号患者的随访结局都是死于胃癌，属生存时间的完全数据；完全数据提供的是准确的生存时间。

4.1.3 删失数据

在规定的观察期内，对于某些观察对象，由于某种原因未能观察到终点事件发生，并不知道确切的生存时间，称为生存时间的删失数据（censored data）；包含删失的数据称不完全数据（incomplete data）。

删失的原因：研究结束时终点事件尚未发生；失访（lost to follow-up）；死于其它原因。

删失生存时间的计算为规定的起点至删失点所经历的时间。删失数据常在其右上角标记“+”。本章着重讨论右删失（right censoring），即从时间轴上看，终点事件发生在最后一次随访时间的右方，其真实的生存时间只能长于观察到的时间而不会短于这个时间。

生存时间通常不服从正态分布（一般为正偏态，指数分布、Weibull 分布等）。

批注 正偏态即分布向右拖尾：多数人生存时间较短，少数人很长。

删失数据的记号　记个体的真实事件时间为 T，删失时间为 C（研究结束、失访等使观察中止的时间）。实际观察到的是

$$\widetilde{T} = \min(T, C), \qquad \delta = I(T \le C),$$

$\delta = 1$ 表示观察到事件（完全数据），$\delta = 0$ 表示删失（只知道 $T > \widetilde{T}$）。

独立删失与个体似然贡献

假设　(1) 独立删失：同一比较组内（或给定协变量 $\mathbf{x}$ 后）T 与 C 相互独立，即删失的人与仍在观察的人具有相同的后续事件风险；Kaplan–Meier 法、log-rank 检验要求组内独立删失，Cox 回归要求给定协变量后独立删失。(2) 非信息删失：C 的分布不含 T 的分布参数。

关键等式　设 T 的密度为 f、生存函数为 S，C 的密度为 g、生存函数为 G。在独立性下

$$\begin{aligned}
\delta = 1: &\quad P(\widetilde{T} \in [t, t+dt),\ \delta = 1) = P(T \in [t, t+dt),\ C \ge t) = f(t)G(t)\,dt, \\
\delta = 0: &\quad P(\widetilde{T} \in [t, t+dt),\ \delta = 0) = P(C \in [t, t+dt),\ T > t) = g(t)S(t)\,dt.
\end{aligned}$$

结论　个体的似然贡献为 $\{f(\tilde{t})G(\tilde{t})\}^{\delta}\{g(\tilde{t})S(\tilde{t})\}^{1-\delta}$。在非信息删失下 G、g 与 T 的参数无关，可从似然中略去，得

$$L_i \propto f(\tilde{t}_i)^{\delta_i} S(\tilde{t}_i)^{1-\delta_i} = h(\tilde{t}_i)^{\delta_i} S(\tilde{t}_i).$$

解释　完全数据贡献“恰在 $\tilde{t}$ 发生事件”的密度，删失数据贡献“活过 $\tilde{t}$”的概率，删失者的信息并未丢弃。若删失与预后有关（如病情恶化者更易失访），独立删失不成立，KM 会高估生存率。“死于其他原因”按删失处理时，若关心的是该病的实际累积发生概率，需改用竞争风险方法（第 5 章）。

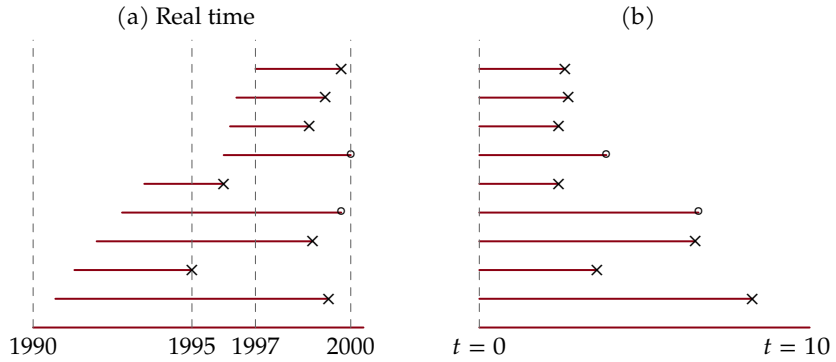


图 1　随访时间示意图（9 名观察对象）

计算生存时间三要素：起点时间；时间尺度；失效时间。

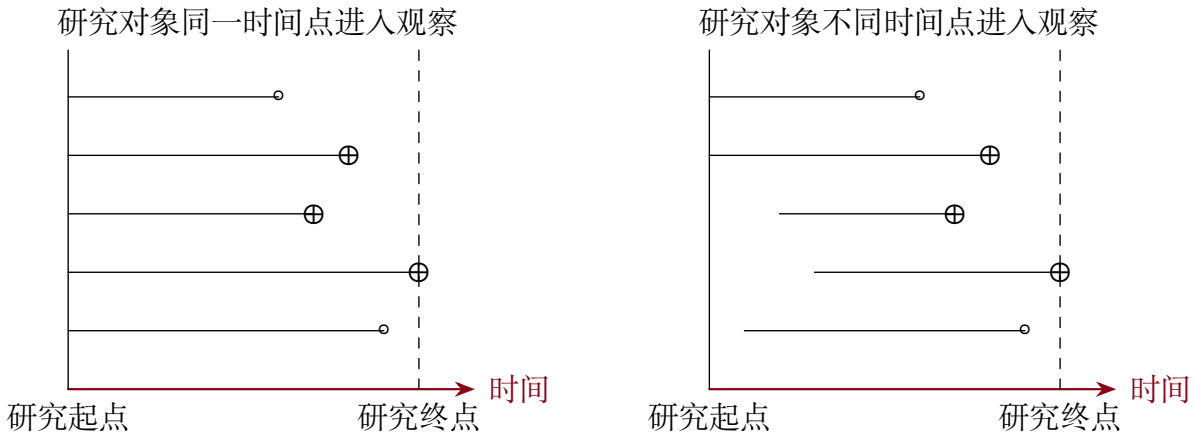


图 2　两种不同研究对象纳入形式示意图

> **批注** 左图同时入组常见于动物实验；右图分批入组（日历时间上不同时间进入）常见于临床试验和队列研究。分析时把每个人的时间起点对齐到各自入组（或确诊、手术）时刻，即图 1(b)，两种情形的方法相同。
> 需要与分批入组区分的是**左截断（延迟入组）**：若时间尺度的起点早于开始观察的时刻（例如以确诊为起点，但患者在确诊后一段时间 a_i 才被纳入研究），在 a_i 之前死亡的人根本不会进入样本。此时个体只在 $t > a_i$ 时属于风险集，似然贡献要除以 $S(a_i)$，即 $f(\tilde{t}_i)^{\delta_i} S(\tilde{t}_i)^{1-\delta_i} / S(a_i)$；若照常从 0 开始计算风险集，会高估早期生存率（不朽时间偏倚）。分批入组本身不造成截断，因为时间是从各自入组时开始计的。

4.1.4　死亡概率

死亡概率（probability of death）：表示某时段开始时存活的个体，在该时段内死亡的可能性。例如，年死亡概率表示年初尚存人口在今后 1 年内死亡的可能性。

$$q = \frac{\text{某年内死亡人数}}{\text{某年年初人口数}}, \qquad \text{分母校正例数} = \text{年初人口数} - \frac{1}{2}\text{删失例数}.$$

> **批注** 这里假设所有删失的人平均观察了半年。

4.1.5　生存概率

生存概率（probability of survival）：表示某时段开始时存活的个体，到该时段结束时仍存活的可能性。例如，年生存概率表示年初尚存人口存活满一年的可能性。

$$p = \frac{\text{某年活满一年人数}}{\text{某年年初人口数}}, \qquad p = 1 - q.$$

$$\text{分母校正例数} = \text{年初人口数} - \frac{1}{2}\text{删失例数}.$$

4.1.6 生存函数

生存函数（survival function）或生存率（survival rate）指观察对象经历 t 个时段后仍存活的可能性。

$$S(t) = P(T > t), \qquad \hat{S}(t) = \frac{t\text{时刻仍存活的例数}}{\text{观察总例数}} \quad \text{（无删失时）.}$$

$S(t)$ 是总体的生存函数（未知参数）；右边的人数比例是它在无删失资料中的估计。有删失时，t 之前删失者的生存状态未知，不能放进分子或分母，须用下面的分时段乘积估计。

> **批注** 生存率和生存概率完全不同，记住！生存概率是 1 年；生存率是 t 个时段：3 年生存率是观察对象要活满 3 年。
>
> 3 年生存率 = 第 1 年生存概率 × 第 2 年生存概率 × 第 3 年生存概率.

若含有删失数据，须分时段计算生存概率。把时间轴分为 $0 = t_0 < t_1 < \cdots < t_k$，记第 j 时段的条件生存概率

$$p_j = P(T > t_j \mid T > t_{j-1}).$$

由条件概率的定义，$P(T > t_j) = P(T > t_j \mid T > t_{j-1})P(T > t_{j-1})$（因为活过 t_j 必然先活过 t_{j-1}），逐段递推得

$$S(t_k) = P(T > t_k) = p_1 p_2 \cdots p_k = S(t_{k-1})p_k.$$

这是概率的乘法公式（链式法则），不需要假定“各时段的生存事件相互独立”——各时段事件本来就不独立（活过前一时段是进入后一时段的前提），条件概率已经体现了这种依赖。估计时需要的是独立删失假设：每个 p_j 用该时段开始时仍在观察的人估计。故生存率又称累积生存概率（cumulative probability of survival）。

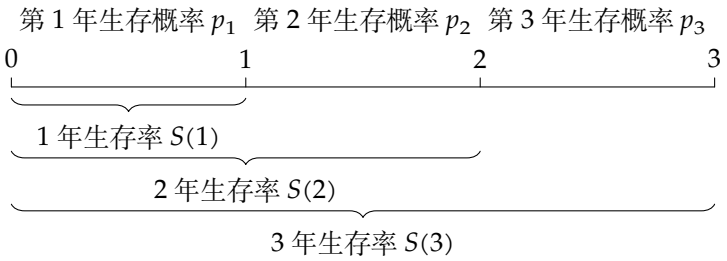


图 3　生存概率与生存率关系示意图

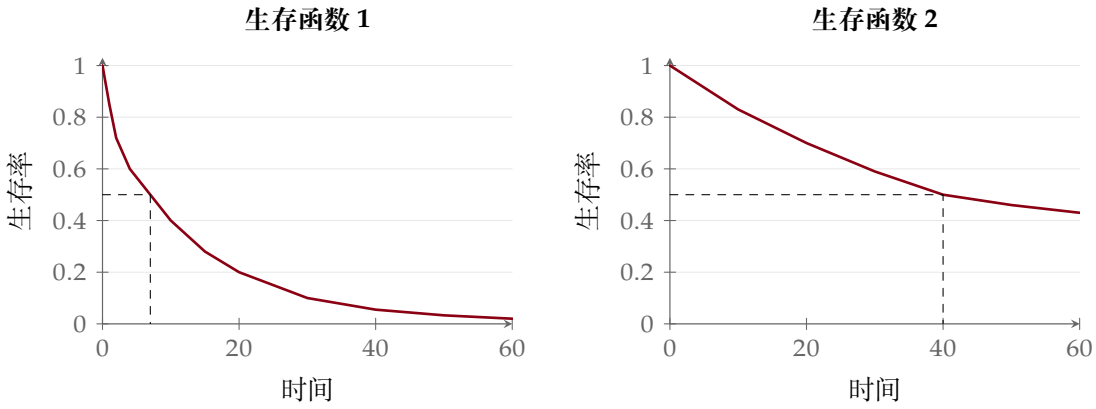


图 4　生存函数（生存曲线）示意图

中位生存期（median survival time）：又称半数生存期，生存函数为 0.5 时对应的时间，表示有 50% 的个体可活这么长时间，用于描述生存期的平均水平。

> **批注** 右图生存情况好于左图。

4.1.7 风险函数

假如终点事件为死亡，风险函数（hazard function）表示 t 时刻存活的个体在 t 时刻的瞬时死亡风险，记为 $h(t)$，描述了某个体的瞬时死亡风险随时间变化的情况。表示 t 时刻的死亡速率。

$$h(t) = \lim_{\Delta t \to 0} \frac{P(t \le T < t + \Delta t \mid T \ge t)}{\Delta t}.$$

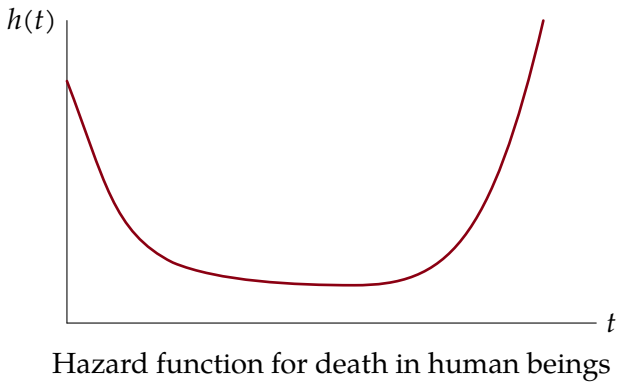


图 5　人类死亡的风险函数

> **批注** 幼年和老年风险大。

生存函数与风险函数的关系：

$$S(t) = \exp\left[-\int_0^t h(u)\,du\right], \qquad h(t) = -\frac{dS(t)/dt}{S(t)}.$$

h、H、S、F 之间的关系

假设　$T \ge 0$ 为连续型随机变量，密度 $f(t)$，分布函数 $F(t) = P(T \le t)$，生存函数 $S(t) = 1 - F(t)$。

关键等式　由风险函数的定义及条件概率，

$$h(t)=\lim_{\Delta t\to 0}\frac{P(t\le T<t+\Delta t)}{\Delta t\,P(T\ge t)}=\frac{f(t)}{S(t)}.$$

又 $f(t)=F'(t)=-S'(t)$，故 $h(t)=-S'(t)/S(t)=-\dfrac{d}{dt}\ln S(t)$。定义累积风险函数

$$H(t)=\int_0^t h(u)\,du,$$

两边从 0 到 t 积分，并利用 $S(0)=1$，得 $-\ln S(t)=H(t)$。

结论

$$h(t)=\frac{f(t)}{S(t)},\qquad S(t)=e^{-H(t)},\qquad F(t)=1-e^{-H(t)},\qquad H(t)=-\ln S(t).$$

解释　$H(t)$ 是风险的累积量，取值 $[0,\infty)$，可以大于 1；$F(t)$ 是 t 之前发生事件的概率，取值 $[0,1]$。二者不同：$F=1-e^{-H}$，只有 H 很小时才有 $F\approx H$。下图的 $\hat F(t)$ 是生存时间的分布函数（累积发生概率），不是累积风险函数。

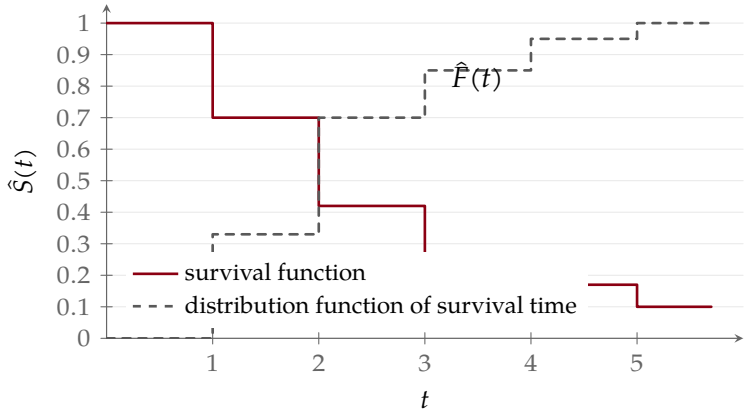


图 6　生存函数与风险函数的关系示意图

$$\hat F(t)=1-\hat S(t).$$

批注　$\hat F(t)=1-\hat S(t)$ 是 t 之前发生事件的累积概率。它与 $h(t)$ 的关系是 $F(t)=1-\exp\{-\int_0^t h(u)\,du\}$，而累积风险函数是 $H(t)=\int_0^t h(u)\,du=-\ln S(t)$。有的说法把 F 称为“累积的风险函数”，应更正为“累积发生概率（分布函数）”。

4.2　生存率的估算方法

寿命表法（life table method）；乘积极限法（Kaplan–Meier）。

4.2.1　寿命表法（life table method）

某些队列研究，并不知道个体确定的死亡时间或删失时间，例如肿瘤登记等大型监测系统。随访中某些个体死亡或删失发生在两次随访之间，寿命表法是分析分组生存资料的经典方法。

例 2 收集 374 名食管癌患者随访资料，取时间区间均为 1 年，整理结果见表 3 中（1）–（5）栏，试估计各年生存率。

表 3　寿命表法估计生存率计算表

序号 i	确诊后年数	期内死亡数 d_i	期内删失数 c_i	期初病例数 n_i'	期初有效例数 n_i
1	0–	90	0	374	374.0
2	1–	76	0	284	284.0
3	2–	51	0	208	208.0
4	3–	25	12	157	151.0
5	4–	20	5	120	117.5
6	5–	7	9	95	90.5
7	6–	4	9	79	74.5
8	7–	1	3	66	64.5
9	8–	3	5	62	59.5
10	9–10	2	5	54	51.5

注：生存时间长于 10 年者 47 例。

表 3（续）　死亡概率、生存概率、生存率及标准误

序号 i	死亡概率 $\hat{q}_i$	生存概率 $\hat{p}_i$	生存率 $\widehat{S}(t_i)$	SE$[\widehat{S}(t_i)]$
1	90/374.0=0.2406	0.7594	0.7594	0.0221
2	76/284.0=0.2676	0.7324	0.7594×0.7324=0.5562	0.0257
3	51/208.0=0.2452	0.7548	0.5562×0.7548=0.4198	0.0255
4	25/151.0=0.1656	0.8344	0.4198×0.8344=0.3503	0.0248
5	20/117.5=0.1702	0.8298	0.3503×0.8298=0.2907	0.0239
6	7/90.5=0.0773	0.9227	0.2907×0.9227=0.2682	0.0235
7	4/74.5=0.0537	0.9463	0.2682×0.9463=0.2538	0.0233
8	1/64.5=0.0155	0.9845	0.2538×0.9845=0.2499	0.0233
9	3/59.5=0.0504	0.9496	0.2499×0.9496=0.2373	0.0232
10	2/51.5=0.0388	0.9612	0.2373×0.9612=0.2281	0.0232

计算步骤

1) 计算期初有效例数：$n_i = n_i' - c_i/2$。这里假定删失在区间内均匀分布，删失者平均在区间中点退出，因而只按半个区间计入风险人数（精算法假定）；若区间内删失集中在区间开始或末尾，这一校正会有偏差。

2) 计算各时间区间上的死亡概率和生存概率：

$$\hat{q}_i = \frac{d_i}{n_i' - c_i/2} = \frac{d_i}{n_i}, \qquad \hat{p}_i = 1 - \hat{q}_i.$$

3) 计算生存率：

$$S(t_k) = P(T > t_k) = p_1 p_2 \cdots p_k = S(t_{k-1}) p_k.$$

4）计算生存率的标准误和置信区间（Greenwood，1926）：

$$\mathrm{SE}[\hat{S}(t_i)] = \hat{S}(t_i)\sqrt{\sum_{j=1}^{i}\frac{d_j}{n_j(n_j-d_j)}}, \qquad \hat{S}(t_i) \pm z_{\alpha/2}\,\mathrm{SE}[\hat{S}(t_i)].$$

这是基于大样本正态近似的区间；$\hat{S}$ 接近 0 或 1、或风险人数少时，区间可能超出 $[0,1]$，覆盖率也不足。

5）计算生存率的标准误和置信区间（双对数变换法，$\hat{S}$ 接近 0 或 1 时）：

$$G(t_i) = \ln\{-\ln[\hat{S}(t_i)]\},$$

$$\mathrm{SE}[G(t_i)] = \sqrt{\frac{\displaystyle\sum_{j=1}^{i}\frac{d_j}{n_j(n_j-d_j)}}{\left(\displaystyle\sum_{j=1}^{i}\ln\frac{n_j-d_j}{n_j}\right)^2}},$$

$$\exp\{-\exp[G(t_i) \pm z_{\alpha/2}\,\mathrm{SE}(G(t_i))]\}.$$

反变换是单调递减的：$G + z\,\mathrm{SE}(G)$ 对应生存率的下限，$G - z\,\mathrm{SE}(G)$ 对应上限，即

$$\Big(\exp\{-\exp[G(t_i) + z_{\alpha/2}\,\mathrm{SE}(G)]\},\ \exp\{-\exp[G(t_i) - z_{\alpha/2}\,\mathrm{SE}(G)]\}\Big),$$

所得区间一定落在 $(0,1)$ 内且不对称。

> **批注** 生存率 $S(t)$ 是总体参数，$\hat{S}(t_i)$ 是它的估计，置信区间用于推断总体。d_j 为死亡例数，n_j 为有效例数。两种区间都依据大样本正态近似：直接法假定 $\hat{S}$ 近似正态；双对数变换法假定 $G = \ln\{-\ln\hat{S}\}$ 近似正态，变换后的分布通常更接近正态、且区间不会越界，但仍是近似而非“严格服从正态”。上表的生存率是用四舍五入后的值逐步相乘得到的，与全精度计算在第四位小数上可能差 1（如第 2 年全精度为 0.5561）。

6. 生存曲线 将随访时间作横坐标，生存率作纵坐标，将各个时间点生存率连接在一起绘制生存曲线（survival curve）。随时间的增加，该曲线一般呈下降趋势。下降速度快、曲线陡峭，意味着较低的生存率或较短的生存期；下降速度慢、曲线平缓，意味着较高的生存率或较长的生存期。

7. 中位生存期（median survival time） 也称半数生存期，表示当且仅当 50% 个体尚存活的时间。中位生存期越长，表示疾病预后越好；中位生存期越短，表示疾病预后越差。可借助生存曲线进行图法估计或用线性内插法求得。

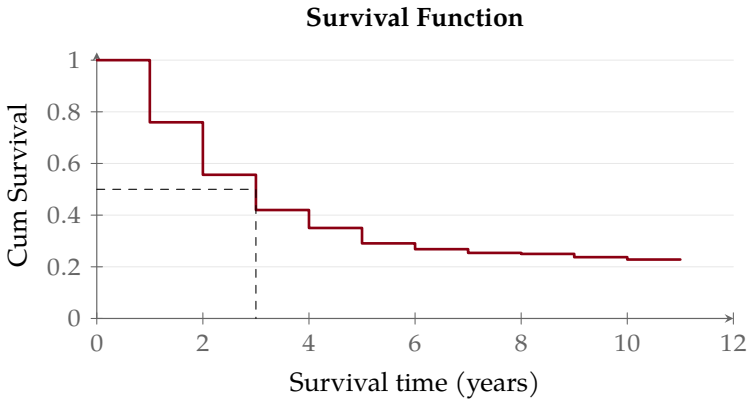


图 7　某恶性肿瘤生存曲线

4.2.2　乘积极限法（Kaplan–Meier）

基本思想：将所有观察对象的生存时间（包括删失数据）由小到大依次排列，对每个时间点进行死亡概率、生存概率和生存率的估计。适用于有每个个体确切生存时间的资料，无论样本大小，都能充分利用每条记录的信息，估计不同生存时间点的生存率。Product limit method。

> **批注** K–M 法：你拥有每一个个体确切的生存时间数据，而寿命表法只能知道死亡发生在某一个时间段中，这是两者的差异。
> 补充：Kaplan–Meier 法由 Kaplan 和 Meier 于 1958 年提出，又称乘积极限法（product limit method）。乘积的含义：生存率等于生存概率的乘积；极限的含义：标准寿命表法中时间区间长度趋近于 0。

例 3 18 例胃癌肿瘤小于 3.0cm 患者和 12 例胃癌肿瘤大于或等于 3.0cm 患者的生存时间（月）如下，试估计两组生存率。

- 肿瘤小于 3.0cm：$3^+, 5^+, 6^+, 10^+, 15, 16^+, 20, 21, 24, 29, 30^+, 52, 72, 94, 136, 144, 167^+, 177$。
- 肿瘤大于或等于 3.0cm：$1, 2, 7^+, 10, 12, 13^+, 24, 29, 30, 32, 61, 62$。

> **说明** 原列表中的“167”未标“+”，按删失（167^+）处理，理由有三：图 9 在 167 月处画的是删失标记，KM 曲线在该处不下降；表 2 中 6 号患者 $t = 167$、status $= 0$（随访截止时存活）；表 5 中小于 3.0cm 组的实际死亡数为 11，而列表中的完全数据恰为 11 个的前提是 167 为删失。两组死亡数合计 $11 + 10 = 21$。

计算方法和步骤

1) 将生存时间 t_i 由小到大顺序排列，完全数据与删失数据相同者，删失数据排在完全数据的后面。
2) 列出时间区间 $[t_i, t_{i+1})$ 上的死亡数 d_i 和删失数 c_i。
3) 计算恰在每一时刻 t_i 之前的生存人数 n_i。计算时应减去小于 t_i 的死亡数和删失数，即 $n_i = n_{i-1} - d_{i-1} - c_{i-1}$。
4) 计算死亡概率 q_i 和生存概率 p_i。
5) 计算生存率 $\hat{S}(t_i)$ 及其标准误。
6) 绘制生存曲线。

> **批注** 同一时刻既有死亡又有删失时，约定删失发生在死亡之后：删失者在该时刻仍然存活，应计入该时刻的风险人数 n_i，只在之后退出。

KM 乘积估计与 Greenwood 方差

假设　独立删失；不同的事件时间点为 $t_{(1)} < t_{(2)} < \cdots < t_{(k)}$，$t_{(i)}$ 时刻前一瞬间的风险人数为 n_i，该时刻死亡 d_i 例。

关键等式　把生存函数写成事件时点上条件生存概率的连乘：$S(t) = \prod_{t_{(i)} \le t}(1 - q_i)$，$q_i = P(T = t_{(i)} \mid T \ge t_{(i)})$ 为该时点的条件死亡概率。给定风险集，$t_{(i)}$ 时刻的死亡数 $d_i \sim B(n_i, q_i)$，各时点的条件似然相乘：

$$L(q_1, \dots, q_k) = \prod_{i=1}^{k} q_i^{d_i}(1 - q_i)^{n_i - d_i},$$

对每个 q_i 分别求最大值得 $\hat{q}_i = d_i / n_i$，故

$$\hat{S}(t) = \prod_{t_{(i)} \le t} \left(1 - \frac{d_i}{n_i}\right).$$

删失者的作用体现在 n_i 中：他们在删失前一直计入风险集，删失后退出。

方差　取对数 $\ln \hat{S}(t) = \sum \ln(1 - \hat{q}_i)$。各 $\hat{q}_i$ 渐近不相关，$\mathrm{Var}(\hat{q}_i) \approx q_i(1-q_i)/n_i$，由 Delta 方法 $\mathrm{Var}\{\ln(1-\hat{q}_i)\} \approx \mathrm{Var}(\hat{q}_i)/(1-q_i)^2 = q_i/\{n_i(1-q_i)\}$，以 $\hat{q}_i = d_i/n_i$ 代入得 $d_i/\{n_i(n_i - d_i)\}$。再由 $\mathrm{Var}(\hat{S}) \approx S^2 \mathrm{Var}(\ln \hat{S})$：

$$\widehat{\mathrm{Var}}[\hat{S}(t)] = \hat{S}(t)^2 \sum_{t_{(i)} \le t} \frac{d_i}{n_i(n_i - d_i)} \qquad \text{(Greenwood 公式)}.$$

解释　(1) 尾部 n_i 很小，每个事件都使曲线大幅下降、标准误增大，曲线尾部的形状不可靠，作图时常同时标出风险人数。(2) 若最后一个观察是死亡，$\hat{S}$ 降为 0（如表 4）；若是删失，$\hat{S}$ 停在大于 0 的水平，此后无定义。(3) 若 $\hat{S}(t)$ 始终未降到 0.5，中位生存期 “未达到”，只能报告其置信下限或某时点生存率，不能用最大观察时间代替。

表 4　胃癌肿瘤大于或等于 3.0cm 组生存率计算表

序号 i	时间 t_i（月）	死亡数 d_i	删失数 c_i	期初例数 n_i
1	1	1	0	12
2	2	1	0	11
3	7	0	1	10
4	10	1	0	9
5	12	1	0	8
6	13	0	1	7
7	24	1	0	6
8	29	1	0	5
9	30	1	0	4
10	32	1	0	3
11	61	1	0	2
12	62	1	0	1

表 4（续）　概率、生存率与标准误

t_i（月）	死亡概率 q_i	生存概率 p_i	生存率 $\widehat{S}(t_i)$	SE$[\widehat{S}(t_i)]$
1	1/12=0.0833	0.9167	0.9167	0.0798
2	1/11=0.0909	0.9091	0.9167×0.9091=0.8333	0.1076
7	0/10=0.0000	1.0000	0.8333×1.0000=0.8333	0.1076
10	1/9=0.1111	0.8889	0.8333×0.8889=0.7407	0.1295
12	1/8=0.1250	0.8750	0.7407×0.8750=0.6481	0.1426
13	0/7=0.0000	1.0000	0.6481×1.0000=0.6481	0.1426
24	1/6=0.1667	0.8333	0.6481×0.8333=0.5401	0.1544
29	1/5=0.2000	0.8000	0.5401×0.8000=0.4321	0.1568
30	1/4=0.2500	0.7500	0.4321×0.7500=0.3241	0.1503
32	1/3=0.3333	0.6667	0.3240×0.6667=0.2160	0.1335
61	1/2=0.5000	0.5000	0.2160×0.5000=0.1080	0.1014
62	1/1=1.0000	0.0000	0.1080×0.0000=0.0000	—

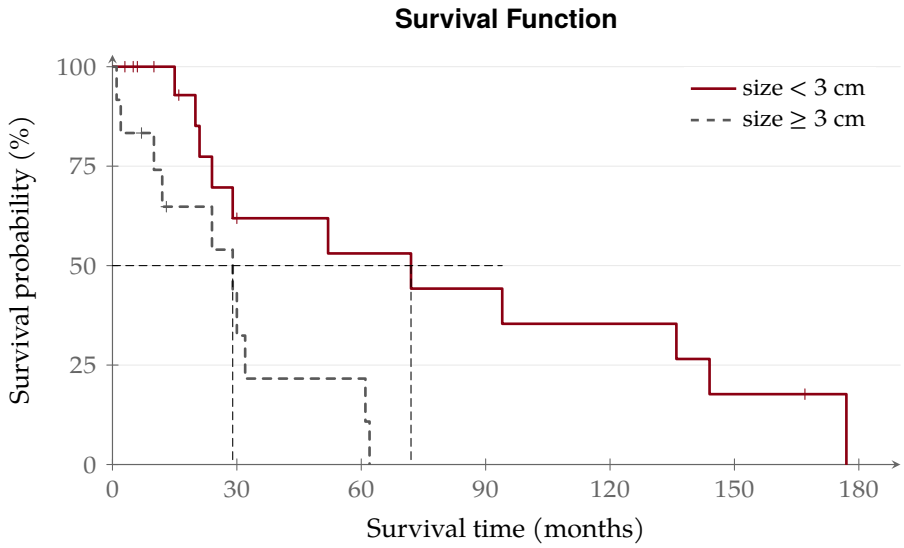


图 9　两组患者的生存曲线对比

> **批注** 图中看觉得肿瘤越大，生存时间越短，预后越差。但这仍需要假设检验。

R 中用 `survival` 包完成 KM 估计，`Surv(time,status)` 将时间与结局合成为生存对象：

R

```r
library(survival)
t1 <- c(3,5,6,10,15,16,20,21,24,29,30,52,72,94,136,144,167,177)    # <3cm
s1 <- c(0,0,0,0, 1,0, 1,1,1,1,0,1,1,1,1,1,0,1)                      # 1=死亡，0=删失
t2 <- c(1,2,7,10,12,13,24,29,30,32,61,62)                           # >=3cm
s2 <- c(1,1,0,1,1,0,1,1,1,1,1,1)
d <- data.frame(time=c(t1,t2), status=c(s1,s2), size=rep(c("<3cm",">=3cm"),c(18,12)))
km <- survfit(Surv(time,status)~size, data=d)
km                          # 各组例数、事件数、中位生存期
```

R（续）

```r
summary(km[2])              # >=3cm组的生存率表
plot(km, lty=1:2, mark.time=TRUE)
```

```
            n events median 0.95LCL 0.95UCL
size=<3cm  18     11     72      24      NA
size=>=3cm 12     10     29      12      NA

 time n.risk n.event survival std.err lower 95% CI upper 95% CI
    1     12       1    0.917  0.0798        0.7729        1.000
    2     11       1    0.833  0.1076        0.6470        1.000
   10      9       1    0.741  0.1295        0.5259        1.000
   12      8       1    0.648  0.1426        0.4211        0.998
   24      6       1    0.540  0.1544        0.3084        0.946
   29      5       1    0.432  0.1568        0.2121        0.880
   30      4       1    0.324  0.1503        0.1306        0.804
   32      3       1    0.216  0.1335        0.0644        0.725
   61      2       1    0.108  0.1014        0.0171        0.680
   62      1       1    0.000     NaN            NA           NA
```

所得生存率与标准误与表 4 一致，标准误按 Greenwood 公式计算。R 默认的置信区间在 $\log S$ 尺度上构造，与前述直接法、双对数法均不相同，报告时应注明。两组中位生存期分别为 72 个月和 29 个月，其置信上限均为 `NA`，即生存曲线下降幅度不足，上限无法确定。

删失数据处理方式的比较

以肿瘤 < 3 cm 组为例，将几种简化处理方法与 KM 估计作比较：

做法	24 个月生存率	中位生存期（月）
Kaplan–Meier	0.696	72
删失者均按存活超过 24 个月计	$14/18 = 0.778$	—
删失者均按死亡计	$9/18 = 0.500$	—
仅用死亡者的生存时间	—	52

将 24 个月前删失的 4 人按存活超过 24 个月处理，生存率被高估；按死亡处理，生存率被低估；仅以死亡者的生存时间计算中位数，排除了生存时间较长、尚未死亡的对象，中位生存期由 72 个月降至 52 个月。KM 法中，删失者在删失前始终计入风险集，作为各死亡时刻条件死亡概率的分母，删失后退出，不对其此后的结局作任何推断。该方法成立的前提是独立删失，即删失者与继续随访者此后的风险相同。

4.3 生存曲线的比较方法

4.3.1 log-rank 检验

例 3（续） 试比较胃癌肿瘤小于 3.0cm 患者和肿瘤大于或等于 3.0cm 患者的生存曲线，就总体而言，两条生存曲线是否有差别。

$$H_0 : S_1(t) = S_2(t), \quad \text{两总体生存曲线相同;}$$

$$H_1 : S_1(t) \neq S_2(t), \quad \text{两总体生存曲线不同;} \qquad \alpha = 0.05.$$

> **批注** 这是整条曲线的比较，而不是某一时点的比较。

log-rank 检验是比较生存曲线的非参数方法之一。基本思想：当 H_0 成立时，将两组资料合并统一按生存时间由小到大排序。根据 t_i 时点的死亡率，可计算出 t_i 时点上各组的理论死亡数；将所有时点各组的理论死亡数累加，便得到各组的理论死亡总数 T_g；将 T_g 和各组的实际死亡总数 A_g 作比较，就形成 log-rank 检验的 χ^2 统计量。下面的近似公式形式简单，精确（方差）公式见后。

$$\chi^2 \approx \sum_{g=1}^{k} \frac{(A_g - T_g)^2}{T_g}, \qquad \nu = k - 1.$$

表 5　肿瘤 <3.0cm 和肿瘤 ≥ 3.0cm 患者生存曲线比较的 log-rank 检验计算表

i	t_i（月）	肿瘤 <3.0cm 组			肿瘤 ≥ 3.0cm 组			合计		V_{1i}
		n_{1i}	d_{1i}	T_{1i}	n_{2i}	d_{2i}	T_{2i}	n_i	d_i	
1	1	18	0	0.6000	12	1	0.4000	30	1	0.2400
2	2	18	0	0.6207	11	1	0.3793	29	1	0.2354
3	10	15	0	0.6250	9	1	0.3750	24	1	0.2344
…										
8	24	10	1	1.2500	6	1	0.7500	16	2	0.4375
…										
合计		—	—	11	15.7831	—	10	5.2169	—	21	3.3782

表中只列有死亡发生的时点（共 19 个，24、29 月各有 2 例死亡）。原表第 3 行为删失时点 $t = 3$，该处 $d_i = 0$，理论死亡数应为 0，不应列出；原表合计死亡数 22 有误，应为 $11 + 10 = 21$。合计按全精度计算，原表为 15.7842、5.2170。

$$T_{gi} = \frac{n_{gi} d_i}{n_i}.$$

$$\begin{aligned} \chi^2 &\approx \sum_{g=1}^{k} \frac{(A_g - T_g)^2}{T_g} \\ &= \frac{(11 - 15.7831)^2}{15.7831} + \frac{(10 - 5.2169)^2}{5.2169} = 5.835, \end{aligned}$$

$$0.01 < P < 0.025.$$

批注 A_g 为实际死亡总数，T_g 为理论死亡总数，自由度为组数减 1。$\chi^2 = 5.835 > 3.84$，按近似公式拒绝 H_0。

log-rank 统计量的超几何分布推导

假设　H_0：两组的风险函数相同，$h_1(t) = h_2(t)$；组内独立删失。

关键等式　在每个事件时点 t_i，把风险集按“组别 × 是否死亡”列成 2×2 表，行合计 n_{1i}、n_{2i}，列合计 d_i、$n_i - d_i$。在 H_0 下，给定这些边际合计，d_i 例死亡在 n_i 人中的分配与组别无关，第 1 组的死亡数 d_{1i} 服从超几何分布：

$$\mathrm{E}(d_{1i}) = \frac{n_{1i}d_i}{n_i} = T_{1i}, \qquad V_{1i} = \mathrm{Var}(d_{1i}) = \frac{n_{1i}n_{2i}d_i(n_i - d_i)}{n_i^2(n_i - 1)}.$$

把各时点的 2×2 表累加（与 Mantel–Haenszel 检验相同），$U = \sum_i (d_{1i} - T_{1i}) = A_1 - T_1$。各时点在给定过去的条件下依次成立，$U$ 的方差为 $V_1 = \sum_i V_{1i}$。

结论

$$\chi^2_{\text{log-rank}} = \frac{(A_1 - T_1)^2}{V_1} \mathrel{\dot\sim} \chi^2_1.$$

两组时 $A_1 - T_1 = -(A_2 - T_2)$，$V_1 = V_2$，只需算一组，不能把两组的项再相加。k 组时用 $k-1$ 维向量 $\mathbf{U}$ 及其协方差阵 $\mathbf{V}$，$\chi^2 = \mathbf{U}^\top \mathbf{V}^{-1}\mathbf{U}$，$\mathrm{df} = k - 1$。$\chi^2$ 参照分布是大样本近似，事件数很少时只是近似。

解释　近似公式 $\sum (A_g - T_g)^2/T_g$ 用 T_g 代替方差，两组时其值总不大于上式，是保守的近似。

log-rank 检验精确法（方差法）的统计量计算公式为：

$$\chi^2 = \frac{[\sum_i d_{1i} - \sum_i T_{1i}]^2}{\sum_i V_{1i}},$$

$$V_{1i} = \frac{n_{1i}(n_i - n_{1i})(n_i - d_i)d_i}{n_i^2(n_i - 1)} = \frac{n_{1i}d_i}{n_i}\frac{(n_i - n_{1i})(n_i - d_i)}{n_i(n_i - 1)},$$

$$\chi^2 = \frac{(11 - 15.7831)^2}{3.3782} = 6.772, \qquad P = 0.009.$$

批注 有的算法把两组的 $(A_g - T_g)^2$ 都除以 6.7578 后相加，数值上等于 $(A_1 - T_1)^2$ 除以 $6.7578/2 \approx 3.378$，结果 6.7722 正确，但写法与上面的公式不一致：方差应取单组的 $\sum_i V_{1i} = 3.3782$，分子只取一组的 $(A_1 - T_1)^2$。方差法的值大于近似公式的值，这是因为近似公式本来就偏保守，而不是“方差校正使检验更容易拒绝 H_0”。

4.3.2 Breslow 检验

Breslow 检验（Gehan–Wilcoxon 检验）：

$$\chi^2 = \frac{[\sum_i w_i(d_{1i} - T_{1i})]^2}{\sum_i w_i^2 V_{1i}}, \qquad w_i = n_i.$$

Log-rank 检验：

$$\chi^2 = \frac{[\sum_i d_{1i} - \sum_i T_{1i}]^2}{\sum_i V_{1i}} \qquad (w_i \equiv 1).$$

两者都是“加权的 $(O-E)$”，区别只在各事件时点的权重。log-rank 检验对每个事件时点等权，在比例风险（两组风险之比恒定）时检验效能最高；Breslow 检验以风险人数 n_i 为权，早期（风险人数多时）的差别权重大，当两组差别主要出现在早期、后来消失时效能更高。其权重还受删失分布影响，两组删失模式不同时解释要谨慎。本例 Breslow 检验 $\chi^2 = 5.50$，$P = 0.019$；log-rank 检验 $\chi^2 = 6.77$，$P = 0.009$。

> **批注** 有的资料把两者概括为“Breslow 针对短期效应、log-rank 针对长期效应”，不准确。log-rank 并不偏重后期，它对所有事件时点等权，只是在后期风险人数少时，Breslow 给后期的权重相对更小。选择检验方法应在分析前根据预期的效应模式确定，不能两种都做后挑 P 值小的报告。

R 中用 `survdiff()` 作 log-rank 检验，其结果为方差法的统计量：

R

```r
survdiff(Surv(time,status)~size, data=d)          # log-rank
survdiff(Surv(time,status)~size, data=d, rho=1)   # Peto-Peto加权
```

```
            N Observed Expected (O-E)^2/E (O-E)^2/V
size=<3cm  18       11    15.78      1.45      6.77
size=>=3cm 12       10     5.22      4.39      6.77

 Chisq= 6.8  on 1 degrees of freedom, p= 0.009

            N Observed Expected (O-E)^2/E (O-E)^2/V
size=<3cm  18     5.22     8.34      1.17      5.19
size=>=3cm 12     6.93     3.81      2.56      5.19

 Chisq= 5.2  on 1 degrees of freedom, p= 0.02
```

输出中 `(O-E)^2/E` 两列之和 1.45 + 4.39 = 5.84 即近似公式的结果，`(O-E)^2/V` 即方差法的 6.77。`rho=1` 按各时刻的 KM 生存率加权（Peto–Peto 法），与 Breslow 法按风险人数加权的思路相同，均侧重早期差别，但权重不完全相同，故结果（5.19）与 Breslow 检验的 5.50 略有差异。

当检验结果是拒绝 H_0 时，如何下结论？

1）比较不同组的生存曲线，高低、距离、下降速度等。

2）中位生存时间的比较，结合多个时间点的生存率的比较。

3）相对危险度：$\widehat{\mathrm{RR}} = (A_1/T_1)/(A_2/T_2)$。

> **批注** A 为实际死亡数，T 为理论死亡数。$(A_1/T_1)/(A_2/T_2)$ 是两组风险比（HR）的近似估计，在比例风险时才有单一的解释。

4.3.3 趋势检验

多组生存率（生存曲线）比较时，若分组变量是等级变量，如肿瘤分期为 I 期、II 期、III 期，或连续变量等级化分组，如不同年龄段，若 log-rank 检验发现组间生存率差别有统计学意义，还可作趋势检验（trend test）。分析生存率的差别是否有随分组等级变化而变化的趋势，即是否有肿瘤分期越高，预后越差，或年龄越大（或越小），预后越差的情况。

例 4 就下表分析多发性骨髓瘤患者血尿素氮与预后的关系。

表 6　多发性骨髓瘤患者血尿素氮与预后的关系

血尿素氮（mg/100ml）	病例数	实际死亡数 A	期望死亡数 T	相对死亡比 A/T
0–39	113	79	122.06	0.65
40–79	92	81	74.60	1.09
≥ 80	53	53	16.34	3.24

Log-rank 检验：

$$\chi^2 = \frac{(79-122.06)^2}{122.06} + \frac{(81-74.60)^2}{74.60} + \frac{(53-16.34)^2}{16.34} = 97.99.$$

> **批注** log-rank 只能说明三组间有区别，但不能说明存在趋势。

表 7　趋势检验卡方统计量计算表

血尿素氮（mg/100ml）	记分 S	A	T	$S(A-T)$	ST	S^2T
0–39	1	79	122.06	−43.06	122.06	122.06
40–79	2	81	74.60	12.80	149.20	298.40
≥ 80	3	53	16.34	109.98	49.02	147.06
合计	—	213	213.00	79.72	320.28	567.52

$$\chi^2 = \frac{[\sum S(A-T)]^2}{\sum S^2T - (\sum ST)^2/\sum T} = \frac{79.72^2}{567.52 - 320.28^2/213} = 73.96, \qquad P < 0.005.$$

> **批注** 血尿素氮越低，生存率越高，预后越好。

4.3.4 注意事项

1）log-rank 检验和 Breslow 检验也适用于寿命表资料及多组生存曲线的比较。

2）实际死亡总数 A 与理论死亡总数 T 之比称为相对死亡比（relative death ratio），$R = A/T$，则相对危险度（relative risk, RR）估计值为两组相对死亡比之比：

$$\widehat{\mathrm{RR}} = \frac{A_1/T_1}{A_2/T_2} = \frac{11/15.7842}{10/5.2170} = 0.36.$$

胃癌肿瘤小于 3.0cm 患者的生存情况较优。

3) log-rank 检验用于整条生存曲线的比较，若比较两条生存曲线某时间点处的生存率，如 2 年生存率或 5 年生存率，可按两个率比较的正态近似法：

$$Z = \frac{\hat{S}_1(t) - \hat{S}_2(t)}{\sqrt{\mathrm{SE}^2[\hat{S}_1(t)] + \mathrm{SE}^2[\hat{S}_2(t)]}}.$$

4) 生存曲线交叉时的解释：曲线交叉并不使 log-rank 检验失效（H_0 为两条曲线完全相同，检验的第一类错误仍能控制），但交叉说明两组风险之比随时间改变，早期与后期的差别方向相反、在 $(O-E)$ 中相互抵消，log-rank 检验的效能会明显下降，“差异无统计学意义”不能解释为两组生存无差别。交叉本身提示非比例风险（效应随时间变化），不一定是混杂所致。可分时段比较、采用对不同时期加权的检验（如 Fleming–Harrington 族），或比较限制性平均生存时间（RMST）。

5) log-rank 检验属单因素分析方法，应用条件是除比较因素外，影响生存率的各协变量组间均衡可比。

> **批注** $\widehat{\mathrm{RR}} = 0.36$ 说明肿瘤小于 3.0cm 组的死亡风险约为大于等于 3.0cm 组的 0.36 倍。（同一资料用 Cox 回归估计的 HR 为 1/3.58 = 0.28，两者都是近似估计。）固定时点生存率的比较是两个率的比较，Z 近似服从标准正态分布；应在分析前指定比较的时点。

补充练习（诊断题）

问　某肿瘤随访研究中，病情恶化的患者常转往外院而失访，研究者把这些人按删失处理后用 Kaplan–Meier 法估计 5 年生存率为 62%。(1) 这一估计可能偏向哪个方向？为什么？(2) 若失访与病情无关、只与居住地远近有关，结论有何不同？

答　(1) 偏高。KM 法要求独立删失：删失者此后的死亡风险应与仍在随访者相同。病情恶化者失访，意味着留在风险集中的人预后较好，各时点的条件死亡概率被低估，生存率被高估。(2) 若失访只与居住地有关、而居住地与预后无关，独立删失近似成立，KM 估计无偏，只是删失使样本信息减少、标准误增大。若居住地本身与预后有关，则只有在给定居住地后删失独立，需分层估计或在 Cox 模型中调整居住地。

小结

生存分析的目的、资料特点、基本概念；生存率的估计方法（寿命表法、Kaplan–Meier）；生存曲线比较的方法（log-rank 法）。

复习题

1) 比较生存概率与生存率，并写出由各年生存概率计算 3 年生存率的公式。
答：生存概率为活过某一时段的条件概率；生存率为自起点活过 t 的累积概率。3 年生存率 $= p_1 p_2 p_3$。

2) 说明寿命表法中期初有效例数取 $n_i' - c_i/2$ 的依据。
答：假定删失在区间内均匀发生，删失者平均只暴露半个区间。

3) KM 法中同一时刻既有死亡又有删失时，说明删失者是否计入该时刻的风险人数。
答：计入，按约定删失发生在死亡之后。

4) $S(t) = 0.6$ 时，计算累积风险 $H(t)$ 与累积发生概率 $F(t)$。
答：$H = -\ln 0.6 = 0.51$，$F = 0.4$。

5) 两条生存曲线交叉，log-rank 检验 $P = 0.40$，说明能否据此认为两组生存无差别。
答：不能。曲线交叉提示风险比随时间变化，早期与后期的差别相互抵消，*log-rank* 检验效能降低；应分时段比较，或采用 *RMST* 等方法。

6) 比较 log-rank 检验与 Breslow 检验。
答：前者对各死亡时刻等权，比例风险时效能最高；后者以风险人数为权，对早期差别更为敏感。

第 5 章

生存分析（二）

主要内容

生存分析的基本概念；生存率的估计方法；生存曲线比较的方法；Cox 回归分析；生存分析方法的正确应用。第 4 章的 KM 法与 log-rank 检验只能处理一个分组因素，同时考虑肿瘤分级、大小与是否复发等多个因素时，需采用回归模型。Cox 模型仅对风险之比建模，对风险随时间的变化（基线风险 $h_0(t)$）不作任何分布假设。估计时，在每个死亡时刻考虑风险集中恰为该个体发生事件的条件概率，$h_0(t)$ 在分子与分母中相消。以条件化消去冗余参数的方法，与第 2 章的条件 logistic 回归相同。

Cox 模型的关键假设是比例风险，即任意两个个体的风险之比不随时间变化。本章后半部分的比例风险检验、时依协变量与竞争风险，均针对该假设不成立或问题更为复杂的情形。本章应掌握 HR 的含义，以及单一 HR 能够概括效应的条件。

5.1 Cox 回归分析

5.1.1 问题的提出

log-rank 检验属单因素分析方法，用于不同组间生存曲线的比较，应用条件是影响生存率的各协变量组间均衡可比。如何分析多个因素对生存率（生存曲线）的影响?

- Logistic 回归? 不仅考虑结局，还考虑时间。
- 一般线性模型? 生存时间的分布非正态、删失数据。

常用的回归模型：指数分布回归模型、Weibull 分布回归模型、Cox 比例风险回归模型。

5.1.2 Cox 回归

Cox 比例风险回归模型（Cox's proportional hazards regression model），简称 Cox 回归。以生存结局和生存时间为因变量，可同时分析众多因素对生存期的影响，分析带有删失生存时间的资料，且不要求资料服从特定的分布类型。英国统计学家 D. R. Cox 于 1972 年提出。

> **批注** 三大回归：一般线性回归、Logistics 回归、Cox 回归。

Cox 回归模型结构

$$\underbrace{h(t)}_{t\text{时刻的风险函数}} = \underbrace{h_0(t)}_{\substack{t\text{时刻的基线风险函数}\\ \text{非参数部分}}} \times \underbrace{\exp(\beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p)}_{\text{风险比，未知参数}}.$$

半参数模型（semi-parametric model）。

$$h(t) = h_0(t) \times \exp(\beta_1 X_1) \exp(\beta_2 X_2) \cdots \exp(\beta_p X_p).$$

乘法模型。

> **批注** 只关心风险比；每个危险因素效应的乘积。

模型的假定

任两个个体在同一时刻的风险函数之比，称为风险比（hazard ratio, HR）。

$$\begin{aligned}\text{HR} = \frac{h_i(t)}{h_j(t)} &= \frac{h_0(t)\exp(\beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip})}{h_0(t)\exp(\beta_1 X_{j1} + \beta_2 X_{j2} + \cdots + \beta_p X_{jp})} \\ &= \exp[\beta_1(X_{i1} - X_{j1}) + \beta_2(X_{i2} - X_{j2}) + \cdots + \beta_p(X_{ip} - X_{jp})].\end{aligned}$$

自变量的效应不随时间而改变，称为比例风险（proportional hazard）假定，简称 PH 假定。

$$\ln h_i(t) - \ln h_j(t) = \beta_1(X_{i1} - X_{j1}) + \beta_2(X_{i2} - X_{j2}) + \cdots + \beta_p(X_{ip} - X_{jp}).$$

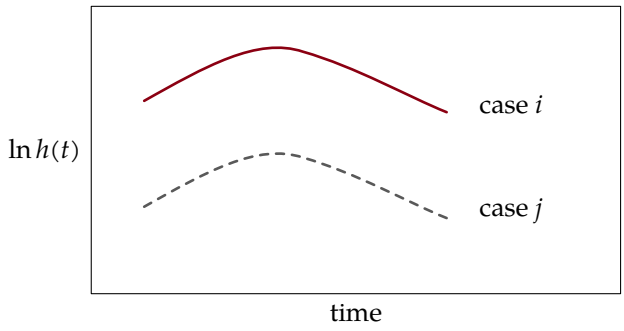


图 13　比例风险假定示意图

> **批注** i, j 代表两个个体。PH 假定下，两人的 $\ln h(t)$ 曲线随时间平行，间距为 $\sum_k \beta_k(X_{ik} - X_{jk})$。三个效应指标的区别：OR 是优势之比（Logistic 回归，病例对照、横断面资料）；RR（risk ratio）是固定时间内累积发生概率之比，$\text{RR}(t) = F_i(t)/F_j(t)$（固定随访期的队列、试验）；HR 是瞬时风险之比（生存分析）。即使 HR 恒定，$\text{RR}(t)$ 也随 t 变化，且当事件不罕见时 $\text{RR}(t)$ 比 HR 更接近 1。三者只有在事件罕见时才近似相等，不能混用。

参数的解释

β_j：在其它自变量不变条件下，变量 X_j 每增加一个单位所引起的风险比的自然对数。

$$\ln \text{HR}_j = \beta_j, \qquad \text{HR}_j = \exp(\beta_j).$$

有的资料同时写作 $\mathrm{RR}_j = \exp(\beta_j)$，这里的“RR”只能理解为风险率之比（rate/hazard ratio），不是固定时点的累积风险之比；本书统一记为 HR。

> **批注** 解释方式与 Logistic 回归系数类似（对数尺度上的加法、原尺度上的乘法），但对象不同：Logistic 的 $\exp(\beta)$ 是 OR，Cox 的 $\exp(\beta)$ 是 HR，在 PH 假定下对所有时刻成立。

参数的估计和假设检验

借助部分似然函数（partial likelihood function）用最大似然法估计回归系数。

> **批注** 只关心 β，不关心基线。

部分似然函数的构建

部分似然函数（Partial Likelihood Function）：不包含基线风险的信息，仅聚焦于事件发生的顺序和协变量的关系。构建部分似然函数的核心思路是“条件风险”：在某一事件发生时间点 t_k，考虑所有此时仍处于“风险集”（即尚未发生事件且未删失）的个体，计算实际发生事件的个体恰好是该个体的概率。

对第 k 个事件时间 t_k，风险集 $R(t_k)$ 表示在 t_k 前一瞬间仍处于观察中（尚未发生事件、也尚未删失，即 $\widetilde{T}_l \geq t_k$）的所有个体的集合；恰在 t_k 发生事件或删失的人都包括在内。

$$P(\text{个体}i\text{ 在}t_k\text{ 发生事件} \mid R(t_k)\text{ 中某个个体发生事件}) = \frac{\exp(\beta X_i)}{\sum_{l\in R(t_k)} \exp(\beta X_l)}.$$

整个样本的部分似然函数就是所有事件发生时间点上该概率的乘积。

$$L(\beta) = \prod_{k=1}^{m} \frac{\exp(\beta X_{i_k})}{\sum_{l\in R(t_k)} \exp(\beta X_l)}.$$

设样本中有 n 个个体，事件发生的时间点按从小到大排序为 $t_1 < t_2 < t_3 < \cdots < t_m$（$m \leq n$）。

$$\ln L(\beta) = \sum_{k=1}^{m} \left[\beta X_{i_k} - \ln\left(\sum_{l\in R(t_k)} \exp(\beta X_l) \right) \right].$$

求导并令导数为 0，数值求解似然方程组。

部分似然的得分函数与并列事件

假设　PH 模型 $h(t \mid \mathbf{x}) = h_0(t)\exp(\mathbf{x}^\top\boldsymbol{\beta})$；给定协变量后独立删失；各事件时间互不相同（无并列）。

关键等式　在 t_k 时刻，风险集中某人发生事件的条件概率里 $h_0(t_k)$ 在分子分母中相消，部分似然 $L(\boldsymbol{\beta}) = \prod_k e^{\mathbf{x}_{i_k}^\top\boldsymbol{\beta}} / \sum_{l\in R(t_k)} e^{\mathbf{x}_l^\top\boldsymbol{\beta}}$。对 $\boldsymbol{\beta}$ 求导：

$$\mathbf{U}(\boldsymbol{\beta}) = \frac{\partial \ln L}{\partial \boldsymbol{\beta}} = \sum_{k=1}^{m} \left\{ \mathbf{x}_{i_k} - \bar{\mathbf{x}}(t_k;\boldsymbol{\beta}) \right\}, \qquad \bar{\mathbf{x}}(t_k;\boldsymbol{\beta}) = \frac{\sum_{l\in R(t_k)} \mathbf{x}_l\, e^{\mathbf{x}_l^\top\boldsymbol{\beta}}}{\sum_{l\in R(t_k)} e^{\mathbf{x}_l^\top\boldsymbol{\beta}}}.$$

$\bar{\mathbf{x}}(t_k;\boldsymbol{\beta})$ 是风险集内以 $e^{\mathbf{x}_l^\top\boldsymbol{\beta}}$ 为权的协变量加权均值，即模型下“谁会发生事件”的期望协变量值。信息阵为风险集内的加权协方差阵之和：$\mathbf{I}(\boldsymbol{\beta}) = \sum_k \sum_{l\in R(t_k)} w_{kl}\{\mathbf{x}_l - \bar{\mathbf{x}}(t_k)\}\{\mathbf{x}_l - \bar{\mathbf{x}}(t_k)\}^\top$，$w_{kl} = e^{\mathbf{x}_l^\top\boldsymbol{\beta}} / \sum_{r\in R(t_k)} e^{\mathbf{x}_r^\top\boldsymbol{\beta}}$。

结论　得分方程 $\mathbf{U}(\hat{\boldsymbol{\beta}}) = \mathbf{0}$ 表示：各事件时点上“实际发生事件者的协变量”与“风险集加权均值”之差的总和为 0。模型只含一个分组变量时，在 $\boldsymbol{\beta} = \mathbf{0}$ 处的比分检验就是 log-rank 检验（无并列事件时完全相同）。

并列事件　若 t_k 时刻有 $d_k > 1$ 人同时发生事件，上式不再精确。常用近似：Breslow 法（分母用 $\{\sum_{l\in R} e^{\mathbf{x}_l^\top\boldsymbol{\beta}}\}^{d_k}$，SAS PHREG、SPSS 默认）、Efron 法（逐个扣除已发生者的平均贡献，R `coxph` 默认，更精确）；精确法（exact/discrete）计算量大，适用于并列很多或配对资料（条件 Logistic 回归即用 discrete）。并列少时几种方法结果接近；不同软件的系数可能因此略有差别。

假设检验方法类似于 Logistic 回归，有似然比检验、Wald 检验和 Score 检验，检验统计量在大样本下近似服从卡方分布，自由度为待检验的独立约束个数（参数个数）。

以第 4 章例 3 的两组资料拟合仅含肿瘤大小（≥ 3 cm 记为 1）的 Cox 模型，输出如下：

R

```r
library(survival)
d <- data.frame(time=c(t1,t2), status=c(s1,s2), size=rep(0:1,c(18,12)))  # t1, s1,t2,s2见第4章
summary(coxph(Surv(time,status)~size, data=d))
```

```
  n= 30, number of events= 21

       coef exp(coef) se(coef)     z Pr(>|z|)
size 1.2752    3.5793   0.5242 2.433    0.015 *

     exp(coef) exp(-coef) lower .95 upper .95
size     3.579     0.2794     1.281     9.999

Concordance= 0.654  (se = 0.055 )
Likelihood ratio test= 6.18  on 1 df,   p=0.01
Wald test            = 5.92  on 1 df,   p=0.01
Score (logrank) test = 6.71  on 1 df,   p=0.01
```

结果解释：肿瘤 ≥ 3 cm 者的死亡风险为 < 3 cm 者的 3.58 倍（95%CI 1.28–10.0）；`exp(-coef)` 为反向比较的 HR（0.279）。最后三行为同一假设 $H_0: \beta = 0$ 的三种检验，与第 2 章所述三种检验方法对应。比分检验标注为“logrank”，因为仅含一个分组变量时，比分检验即 log-rank 检验；此处 6.71 与 `survdiff` 的 6.77 略有差别，源于 24 月与 29 月两处并列死亡的处理方式不同。`Concordance` 为 C 指数，即随机抽取两人时风险评分较高者先发生死亡的概率，0.5 表示无区分能力。

第 4 章由 $(A_1/T_1)/(A_2/T_2)$ 得到的相对危险度为 0.36，其倒数为 2.8，与 HR 3.58 方向一致、大小相近，但仅为粗略近似。

自变量的筛选策略

确定筛选的指标、标准。结合研究目的、专业知识、既往经验：前进法、后退法、逐步回归法；其他：最优组合、结合专业知识的不同模型及其比较。

Cox 回归的主要用途

影响因素分析、筛选危险因素；校正协变量后的组间比较；多变量生存预测；生存率估计。

实例

例 5 30 例胃癌患者的随访记录见表 8，试进行胃癌肿瘤患者生存情况的影响因素分析。

表 8　30 例胃癌患者生存资料原始记录表

id	age	grade	size	relapse	start	end	t	status	PI	$S(t)$
1	76	3	0	1	1996/03/27	1996/08/24	5	0	6.174	0.899
2	23	2	1	0	1997/12/17	2000/08/03	32	1	5.605	0.102
3	52	2	1	0	1998/09/16	2001/02/02	29	1	5.605	0.233
4	74	2	1	1	1996/04/29	1997/02/23	10	1	7.040	0.624
5[a]	67	3	0	1	1998/01/16	1998/04/16	3	0	6.174[a]	0.899[a]
6	47	1	0	0	1997/02/10	2010/12/30	167	0	1.580	0.570
7	37	3	0	0	1997/11/14	1998/05/13	6	0	4.739	0.975
8[b]	67	3	0	1	1998/01/16	1998/04/16	3	0	6.174	0.899
9	45	3	0	0	1996/05/16	2000/09/22	52	1	4.739	0.276
10	73	2	1	1	1996/10/16	1997/05/14	7	0	7.040	0.777
…	…	…	…	…	…	…	…	…	…	…
30	29	2	1	0	1996/11/12	1999/05/01	30	1	5.605	0.169

[a] 原表此行印作 id 8、PI 4.739、$S(t)$ 0.767。按表 2，这一记录是 5 号患者；其协变量（grade 3、size 0、relapse 1）与 1 号相同，按本表其他各行所用系数，PI 应为 6.174。原值与 7 号（PI 4.739、$t = 6$、$S = 0.975$）矛盾：同一 PI 下 $S(t)$ 不可能在 $t = 3$ 时为 0.767、到 $t = 6$ 时反而升至 0.975。$S(t)$ 按与 1 号、8 号的一致性改为 0.899。

[b] 8 号的记录与 5 号完全相同，可能是原表抄录重复，原始资料无法核实。

PI 列由系数约$(1.580, 2.446, 1.435)$算得（如 $3\times1.5797 = 4.739$，$2\times1.5797+2.4456 = 5.605$，$5.605+1.435 = 7.040$），与表 9 的系数（1.572，2.431，1.431）略有出入；按表 9 系数，1 号患者 PI 为 6.147。两组系数可能来自并列事件处理不同的两次拟合。原资料未提供 30 例的完整资料，表 9 无法复算。

表 9　30 例胃癌患者多变量 Cox 回归分析结果

Variable	b	S_b	Wald χ^2	P	HR	HR 95%CI
grade	1.572	0.470	11.193	0.001	4.816	(1.918, 12.097)
size	2.431	0.712	11.645	0.001	11.367	(2.814, 45.918)
relapse	1.431	0.786	3.311	0.069	4.183	(0.896, 19.537)

$$h(t) = h_0(t) \times \exp(1.572\,\text{grade} + 2.431\,\text{size} + 1.431\,\text{relapse}).$$

预后指数（prognostic index, PI）：$1.572\,\text{grade} + 2.431\,\text{size} + 1.431\,\text{relapse}$。

> **批注** HR = $\exp(\beta)$。在肿瘤大小、复发情况相同的条件下，肿瘤分级每增加 1 级，死亡风险（瞬时风险）变为原来的 4.816 倍（95%CI 1.918–12.097）。原资料写作 “5.357 倍”，与表 9 中 $\exp(1.572) = 4.816$

> 不符，予以更正。注意 grade 是以 1、2、3 赋值的数值变量，这一写法假定 II 级对 I 级、III 级对 II 级的 HR 相同（均为 4.816，III 级对 I 级为 $4.816^2 = 23.2$）；如不愿作此假定，应以哑变量进入模型。size 的 HR 为 11.367（95%CI 2.814–45.918），区间很宽，反映样本只有 30 例。
> 预后指数 PI 越大，死亡风险越高，预后越差，可按 PI 对患者分层。relapse（是否复发）是随访期间才发生的事件，作为基线变量进入模型有引入未来信息的问题，见“时依协变量”一节。

t 时刻生存率的估计

$$\hat{S}(t) = [\hat{S}_0(t)]^{\exp(\sum b_j X_j)},$$

$$\hat{S}_0(t) = \prod_{t_{(i)} \le t} \left[\exp \frac{-d_i}{\sum_{s \in R_i} \exp(\sum b_j X_j)} \right].$$

$t_{(i)}$ 为排序的生存时间（不含删失值），d_i 为 $t_{(i)}$ 时刻死亡数，R_i 为 $t_{(i)}$ 时刻前一瞬间的风险集，分母中的 $\sum b_j X_j$ 按风险集中每个人 s 各自的协变量计算。

累积基线风险与个体生存率预测

假设　PH 模型成立，$h(t \mid \mathbf{x}) = h_0(t) \exp(\mathbf{x}^\top \boldsymbol{\beta})$；给定协变量后独立删失。

关键等式　对风险函数积分：

$$H(t \mid \mathbf{x}) = \int_0^t h_0(u) e^{\mathbf{x}^\top \boldsymbol{\beta}} \, du = H_0(t)\, e^{\mathbf{x}^\top \boldsymbol{\beta}},$$
$$S(t \mid \mathbf{x}) = e^{-H(t|\mathbf{x})} = \{e^{-H_0(t)}\}^{e^{\mathbf{x}^\top \boldsymbol{\beta}}} = S_0(t)^{e^{\mathbf{x}^\top \boldsymbol{\beta}}}.$$

累积基线风险用 Breslow 估计：在每个事件时点，把 d_i 例事件按风险集中各人的相对风险 $e^{\mathbf{x}_s^\top \hat{\boldsymbol{\beta}}}$ 分摊，

$$\widehat{H}_0(t) = \sum_{t_{(i)} \le t} \frac{d_i}{\sum_{s \in R_i} \exp(\mathbf{x}_s^\top \hat{\boldsymbol{\beta}})}, \qquad \hat{S}_0(t) = \exp\{-\widehat{H}_0(t)\} = \prod_{t_{(i)} \le t} \exp\left\{ \frac{-d_i}{\sum_{s \in R_i} \exp(\mathbf{x}_s^\top \hat{\boldsymbol{\beta}})} \right\},$$

即上面的公式。

结论　$\hat{S}(t \mid \mathbf{x}) = \hat{S}_0(t)^{\exp(\mathbf{x}^\top \hat{\boldsymbol{\beta}})}$，其中 $\mathbf{x}^\top \hat{\boldsymbol{\beta}}$ 就是预后指数 PI。$\hat{S}_0$ 对应“所有协变量取 0”的个体；许多软件把协变量中心化，输出的基线生存对应“协变量取均值”的个体，使用时须与 PI 的计算方式一致。

解释　只有 $\hat{\boldsymbol{\beta}}$ 只能比较相对风险；要预测某人的绝对生存率，还需要估计的基线风险 $\widehat{H}_0(t)$、该人的协变量值，且只在观察到的随访时间范围内、对与样本相似的人群才可靠。用于临床预测时还应评价区分度和校准度。

5.2 Cox 回归的正确应用

5.2.1 满足比例风险假定（PH 假定）

Cox 模型的基本假定是比例风险假定。

1）最简单的方法是观察按该变量分组的 Kaplan–Meier 生存曲线，若生存曲线明显交叉，提示不满足 PH 假定。

2）绘制按该变量分组的累积风险函数 $H(t)=\int_0^t h(u)\,du$ 对生存时间 t 的关系图。PH 假定下 $H_1(t)=H_2(t)\,e^{\beta}$，两条曲线应成比例（任一时刻纵坐标之比恒定），而不是平行或等距。比例关系不便目测，故常取对数作图。

3）专门的假设检验方法。

log–log 图　由 $S(t\mid x)=S_0(t)^{e^{\beta x}}$ 得

$$\ln\{-\ln S(t\mid x)\}=\ln H(t\mid x)=\ln H_0(t)+\beta x.$$

以 $\ln t$（或 t）为横轴、按组绘制 $\ln\{-\ln\hat S(t)\}$，PH 假定成立时各组曲线平行，垂直距离约为 β；曲线交叉或间距随时间明显变化提示违背 PH 假定。

Schoenfeld 残差　对第 k 个事件，$\mathbf{r}_k=\mathbf{x}_{i_k}-\bar{\mathbf{x}}(t_k;\hat{\boldsymbol\beta})$，即发生事件者的协变量减去风险集的加权均值（得分函数中的各项）。若某变量的真实系数随时间变化，$\beta_j(t)$，则标准化 Schoenfeld 残差对时间作图大致沿 $\beta_j(t)-\hat\beta_j$ 的形状变化；PH 假定下应在 0 附近水平分布。以残差与时间（或其函数）的相关性作检验，即 R 的 `cox.zph`、Stata 的 `estat phtest`，可逐个变量和整体检验。$P>0.05$ 只表示未发现违背 PH 的证据。

违背比例风险假定的实例

`survival` 包自带的 `veteran` 数据为 137 例晚期肺癌患者的临床试验资料，协变量包括治疗方式 `trt`、Karnofsky 体能评分 `karno`（0–100，越高越好）与年龄：

R

```
f <- coxph(Surv(time,status)~trt+karno+age, data=veteran)
cox.zph(f)                          # Schoenfeld残差检验
f2 <- coxph(Surv(time,status)~trt+karno+age+tt(karno), data=veteran,
            tt=function(x,t,...) x*log(t))       # karno的效应随log(t)变化
round(summary(f2)$coefficients,4)
exp(coef(f2)["karno"]*10 + coef(f2)["tt(karno)"]*10*log(c(10,100,300)))
```

```
        chisq df       p
trt     0.284  1 0.59439
karno  12.003  1 0.00053
age     2.100  1 0.14735
GLOBAL 19.102  3 0.00026

              coef exp(coef) se(coef)       z Pr(>|z|)
trt         0.0437    1.0447   0.1924  0.2273   0.8202
karno      -0.0839    0.9195   0.0173 -4.8364   0.0000
age        -0.0040    0.9960   0.0092 -0.4322   0.6656
tt(karno)   0.0133    1.0134   0.0044  3.0500   0.0023
[1] 0.5870032 0.7974291 0.9229409
```

> karno 的比例风险检验 $P = 0.0005$，比例风险假定不成立。加入 karno $\times \log t$ 项后，交互项有统计学意义（$P = 0.002$），表明体能评分的作用随时间减弱：评分高 10 分对应的 HR，第 10 天为 0.59，第 100 天为 0.80，第 300 天为 0.92，作用已接近消失。
>
> 原模型给出的单一 HR（$e^{-0.0344\times 10} = 0.71$）是这一变化过程的某种平均，既不代表早期，也不代表后期的效应。这一结果在临床上可以解释：入组时的体能状态对近期死亡有较强的预测作用，随时间推移，病情变化使基线评分的预测作用逐渐减弱。

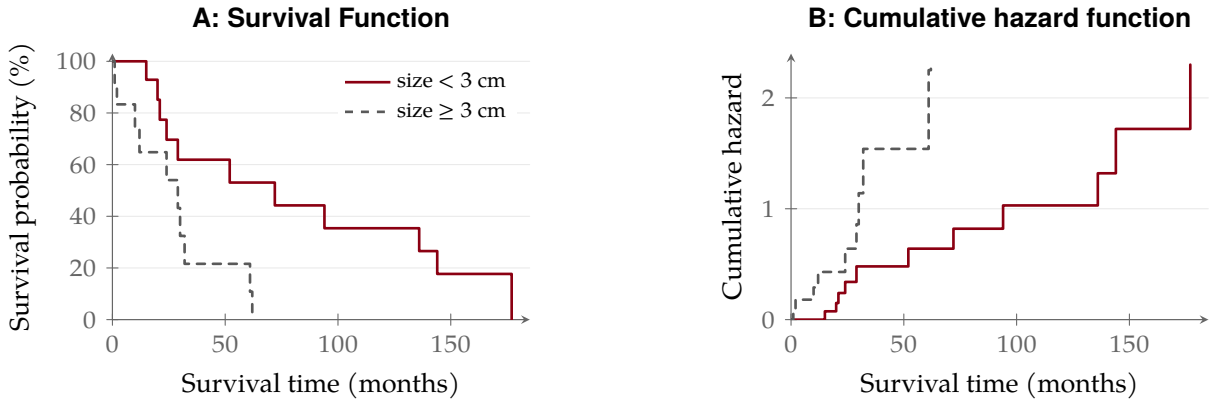


图 14　胃癌数据肿瘤大小（size）的 PH 假定判定（A：生存曲线图；B：累积风险图）

5.2.2 时依协变量

当资料不满足比例风险（PH）假定时：分段拟合 Cox 回归模型；或扩展模型，让协变量或系数随时间变化。应区分两种扩展：

- **时依协变量** $X(t)$：协变量的取值随时间变化，系数不变，$h(t) = h_0(t)\exp\{\beta X(t)\}$。$t$ 时刻的风险只取决于当时（或之前）的 X 值。
- **时变系数** $\beta(t)$：协变量取值固定，其效应随时间变化，$h(t) = h_0(t)\exp\{\beta(t)X\}$，常用 $\beta(t) = \beta_0 + \beta_1 g(t)$ 形式，即在模型中加入 $X \times g(t)$ 交互项。它是检验和处理违背 PH 假定的直接方法。

时依协变量又分为外在（external，又称外生）和内在（internal，又称内生）两类：外在时依协变量的变化路径不受个体自身事件过程的影响，与个体是否存活无关，如年龄、日历时间、环境污染水平、预先安排的治疗剂量；内在时依协变量是在个体身上测得、只有个体存活并在随访中才有定义的指标，如血压、肿瘤复发、实验室检查结果，它们本身可能处于暴露与结局的因果通路上，解释时要谨慎。有的资料把“取值不随时间改变、HR 随时间改变”称为外在时依协变量，实际描述的是时变系数。

例 6 研究 1945 年后接触核辐射的妇女患乳腺癌的风险。

$$h(t) = h_0(t)e^{1.05x_E - 0.05x_E t}.$$

$x_E = 1, 0$（暴露与否）是固定的协变量，HR $= \exp(1.05 - 0.05t)$ 随时间下降，属于时变系数模型（x_E 与 t 的交互）：$t = 0$ 时 HR 为 2.86，$t = 1, 2, 3$ 年时依次为 2.72、2.59、2.46、……。

> **批注**　只有在 PH 假定成立时，才能用一个 HR 概括暴露效应；本例的 HR 随时间变化，应报告 HR 随 t 的变化或分时段的 HR。

例 7 随访开始时是吸烟的（$X_E(t)=1$，当 $t<t_0$ 时），随访到某时刻 t_0 开始戒烟（$X_E(t)=0$，当 $t\geq t_0$ 时）。吸烟状态是时依协变量（个体行为，属内在协变量），系数 β 不随时间变化，而同一个人在 t_0 前后的风险不同；两个吸烟史不同的人的风险之比随时间变化，在这个意义上不再满足“比例风险”。

> **批注** 实现方法是把每个人的随访拆成若干段 (start, stop]，每段内协变量取值固定。

避免引入未来信息　表 8 中的 relapse（是否复发）是手术后随访期间才发生的事件，表 1 只记录了“是否复发”，没有复发日期，无法核实其记录时点。若把“随访中曾复发”当作手术时就已存在的基线协变量，复发者在复发前的那段时间也被当作“已复发”，而能够复发的人必须先活到复发，这段“必然存活”的时间会使复发组显得风险偏低（不朽时间偏倚），HR 有偏。正确的做法是记录复发时间，把 relapse 作为时依协变量。例如 4 号患者（$t=10$ 月死亡）若在第 6 个月复发，应拆为两行：

id	start	stop	relapse	status	说明
4	0	6	0	0	复发前，未发生死亡
4	6	10	1	1	复发后，第 10 个月死亡

R 中用 `coxph(Surv(start, stop, status) ~ grade + size + relapse)` 拟合，每个时刻只使用当时已知的复发状态。“第 6 个月复发”只是示例，原始资料需补充复发时间后才能重新分析。

5.2.3 样本量估算

1）经验估算方法：阳性结局事件数至少为模型参数个数的 10–20 倍。这是经验规则而非由检验效能推出的结果；参数按实际自由度计数（c 类分类变量计 $c-1$ 个，样条、交互项另计），而不是按原始变量个数计。

2）考察某感兴趣变量 X_1 主效应的情况，即检验 β_1 是否等于 0。

Cox 回归的检验效能由事件数决定，而不是由总例数决定。先算所需事件数

$$D=\frac{(Z_{\alpha/2}+Z_{\beta})^2}{(1-R^2)\sigma^2(\ln \mathrm{HR})^2},$$

再按研究结束时的预期事件发生率 P 换算为总样本量

$$n=\frac{D}{P}=\frac{(Z_{\alpha/2}+Z_{\beta})^2}{P(1-R^2)\sigma^2(\ln \mathrm{HR})^2}.$$

P 为研究结束时终点事件发生率；R^2 为主效应变量 X_1 对其他协变量作回归分析时的决定系数（$1/(1-R^2)$ 即方差膨胀因子）；σ^2 为 X_1 的方差；$\ln \mathrm{HR}$ 为 X_1 每增加 1 个单位的对数风险比，即回归系数 β_1。σ^2 与 $\ln \mathrm{HR}$ 必须按同一编码计算。

例 8 拟进行一项临床试验对一新药与标准药的抗肺癌疗效进行比较。假定研究结束时死亡率 $P=70\%$，服用药物的标准差为 0.8，对数风险比为 0.5（即标准药死亡风险是新药的 $e^{0.5}=1.65$ 倍），服用药物对其他协变量作回归分析时的决定系数估计值为 0.30，试问按照检验水准 0.05、检验功效 0.90，需要观察多少例肺癌患者？

原题解法：

$$n = \frac{(1.96 + 1.282)^2}{0.70 \times (1 - 0.30) \times 0.8^2 \times 0.5^2} \approx 135.$$

说明　“服用药物”是 0/1 二分类变量（标准药 0、新药 1），若服新药的比例为 p，则 $\mathrm{Var}(X) = p(1-p) \le 1/4$，标准差最大为 0.5，不可能为 0.8，故上式不成立。按 1 : 1 分配，$p = 0.5$，$\sigma^2 = 0.25$：

$$D = \frac{(1.96 + 1.282)^2}{(1 - 0.30) \times 0.25 \times 0.5^2} = 240.2 \approx 241 \text{ 例死亡}, \qquad n = \frac{240.2}{0.70} = 343.1 \approx 344 \text{ 例}.$$

若按 2 : 1 分配（$p = 2/3$），$\sigma^2 = 2/9$，所需例数增至约 386。此外，随机分组时处理与基线协变量独立，R^2 应接近 0；取 $R^2 = 0$ 时 $D \approx 169$，$n \approx 241$。题设 $R^2 = 0.30$ 更符合观察性研究中暴露与协变量相关的情形。

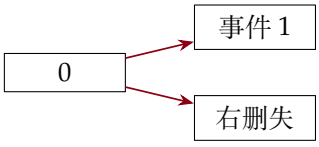
5.2.4　其他模型

竞争风险模型（competing risk model）

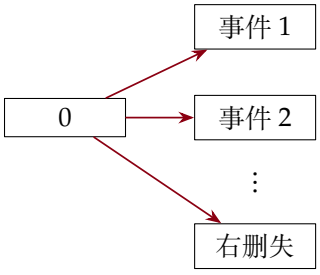
结局包括多种状态，不仅仅是生存和死亡，或者死亡原因有多种。例如，$Y = 1$（癌症）、2（心血管疾病）、0（删失）。分析危险因素对患者死于不同原因的影响大小。Fine & Gray 模型（1999 年）。

例子 某研究人员收集了 2000 年确诊为轻度认知损害（MCI）的 518 例老年患者资料，包括基本人口学特征、生活方式、体格检查和合并疾病信息等，并于 2025 年签完成 25 次随访调查，主要观察结局为是否发生阿尔兹海默病（AD）。问题：影响 MCI 向 AD 转归的因素有哪些？

如果 MCI 患者在观察期间死于癌症、心血管疾病等原因而未发生 AD，就不能为 AD 的发病做出贡献，即死亡“竞争”了 AD 的发生。传统统计方法将发生 AD 前死亡的个体、失访个体和未发生 AD 个体均按删失数据（censored data）处理：用来估计 AD 的原因别风险是可以的，但用 1 − KM 估计“实际有多少人会发生 AD”会偏高（见下）。



一般生存过程



竞争风险过程

一般生存过程与竞争风险过程

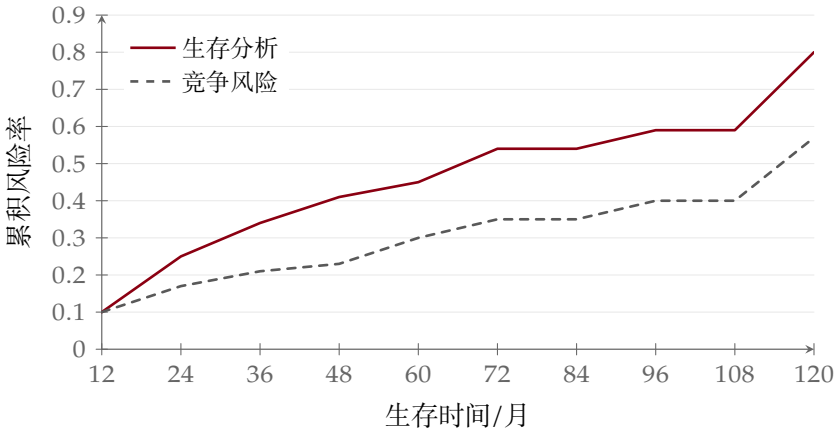


图 2　两种方法估计的复发累积发生率比较（1 − KM 与 CIF）

删失只是阻止了你观察到目标结局事件，而竞争事件则是阻止了目标结局事件的发生，所以删失并不是竞争事件。在竞争风险模型中，一个关键点是，一个受试者只能发生一个结局事件类型，这样该事件的发生就排除了后续再发生其他类型事件。

累积发生函数（CIF）与两类回归模型

记号　T 为首个事件的时间，$J \in \{1, \dots, K\}$ 为事件类型。原因别风险 $h_k(t) = \lim_{\Delta t \to 0} P(t \le T < t + \Delta t, J = k \mid T \ge t)/\Delta t$；总风险 $h(t) = \sum_k h_k(t)$，无任何事件的生存函数 $S(t) = \exp\{-\int_0^t h(u)\,du\}$。

关键等式　第 k 类事件的累积发生函数

$$F_k(t) = P(T \le t,\, J = k) = \int_0^t S(u^-)\, h_k(u)\, du, \qquad \sum_k F_k(t) = 1 - S(t).$$

在 u 时刻发生第 k 类事件，要求此前未发生任何事件（$S(u^-)$），且在 u 时刻发生的是第 k 类（$h_k(u)$）。

结论　(1) 把其他类事件当删失，KM 法估计的是 $S_k^*(t) = \exp\{-\int_0^t h_k(u)\,du\}$，$1 - S_k^*(t)$ 只在“竞争事件不存在”的假想世界中才是发生概率。由于 $S(u) \le S_k^*(u)$，$1 - S_k^*(t) \ge F_k(t)$，即 1 − KM 高估实际的累积发生率，竞争事件越多高估越严重（上图“生存分析”曲线高于“竞争风险”曲线即此）。F_k 应用 Aalen–Johansen 估计（R `cmprsk::cuminc`、`survfit` 的多状态形式）。(2) 回归模型有两类：

原因别 Cox 模型与 Fine–Gray 模型

	原因别 Cox 模型（cause-specific hazard）	Fine–Gray 模型（subdistribution hazard）
建模对象	原因别风险 $h_k(t \mid \mathbf{x})$	子分布风险 $\lambda_k(t) = -\dfrac{d}{dt}\ln\{1 - F_k(t)\}$
风险集	尚未发生任何事件且仍在观察的人；发生竞争事件者退出（按删失处理）	除尚未发生事件者外，已发生竞争事件者仍保留在风险集中（权重按删失分布调整）
$\exp(\beta)$ 的含义	原因别 HR：在仍未发生任何事件的人中，协变量对第 k 类事件瞬时发生率的作用	子分布 HR：协变量对第 k 类事件累积发生率 $F_k(t)$ 的作用方向和大小
适用问题	病因研究（暴露是否直接影响该事件的发生速率）	预测与卫生决策（某类人最终有多少会发生该事件）

同一变量的两类 HR 可以方向不同：例如某因素提高死亡风险，即使它不影响 AD 的原因别风险，也会因“死得早”而降低 AD 的累积发生率。报告时宜同时给出两类模型，或说明选择依据。若研究关心的是全因死亡，则各种死因都是同一终点事件，不存在竞争风险；只有区分死因、关心特定死因时才需要竞争风险方法。

限制性立方样条函数

限制性立方样条函数（Restricted Cubic Spline, RCS）。分析暴露因素（连续型定量变量）和结局之间是否存在非线性关系、剂量反应关系。分段多项式，强制要求立方样条函数在连续性自变量 x 的两端区间内成线性函数。

R

```r
library(rms)
dd <- datadist(data); options(datadist="dd")
fit <- cph(Surv(time,death) ~ rcs(age,4) + sex, data=data)
anova(fit)                              # 总体关联与非线性的检验
plot(Predict(fit, age, ref.zero=TRUE, fun=exp))    # HR(age)，参照值默认为中位数
```

RCS 的基函数、自由度与 HR 曲线

构造　取 k 个结点 $t_1 < \cdots < t_k$（常按 x 的分位数放置，$k = 4$ 时取 5%、35%、65%、95% 分位数）。记 $(u)_+ = \max(u, 0)$，RCS 为

$$f(x) = \beta_1 x + \sum_{j=1}^{k-2} \beta_{j+1} S_j(x), \quad S_j(x) = (x - t_j)_+^3 - (x - t_{k-1})_+^3 \frac{t_k - t_j}{t_k - t_{k-1}} + (x - t_k)_+^3 \frac{t_{k-1} - t_j}{t_k - t_{k-1}}.$$

各段是三次多项式，在结点处函数值、一阶、二阶导数连续；在 t_1 以左和 t_k 以右，三次项和二次项相互抵消，f 为直线（“限制性”即指两端线性），避免尾部数据少时曲线剧烈摆动。

自由度　k 个结点的 RCS 在 Cox 模型中占 $k - 1$ 个参数（x 的线性项 1 个、非线性基函数 $k - 2$ 个；Cox 模型无截距）。代码中 `rcs(age,4)` 即 4 个结点、3 个参数。

两种检验　(1) 总体关联：$H_0 : \beta_1 = \cdots = \beta_{k-1} = 0$，$\mathrm{df} = k - 1$，检验 x 与风险是否有关；(2) 非线性：$H_0 : \beta_2 = \cdots = \beta_{k-1} = 0$，$\mathrm{df} = k - 2$，检验关系是否偏离线性。非线性检验 $P > 0.05$ 只说明没有偏离线性的充分证据，此时可考虑用线性项；总体关联不显著时，曲线的形状不宜解释。

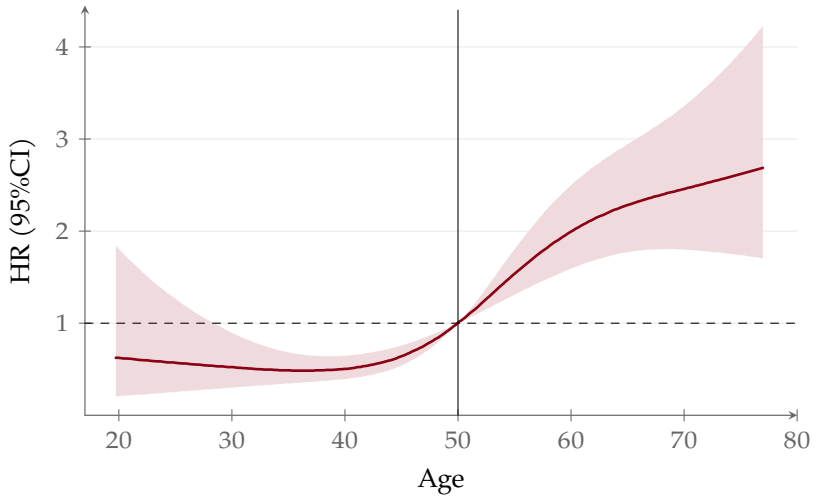
HR 曲线　以 x_{ref} 为参照，

$$\mathrm{HR}(x) = \exp\{f(x) - f(x_{\mathrm{ref}})\} = \exp(\mathbf{c}^\top \hat{\boldsymbol{\beta}}), \qquad \mathbf{c} = \mathbf{b}(x) - \mathbf{b}(x_{\mathrm{ref}}),$$

$\mathbf{b}(x) = (x, S_1(x), \ldots, S_{k-2}(x))^\top$ 为基函数向量。由系数协方差阵 $\widehat{\mathbf{V}}$ 得 $\mathrm{Var}\{\ln \widehat{\mathrm{HR}}(x)\} = \mathbf{c}^\top \widehat{\mathbf{V}} \mathbf{c}$，95%CI 为 $\exp\{\mathbf{c}^\top \hat{\boldsymbol{\beta}} \pm 1.96 \sqrt{\mathbf{c}^\top \widehat{\mathbf{V}} \mathbf{c}}\}$。

解释　(1) 参照值决定曲线的上下位置：$x = x_{\mathrm{ref}}$ 处 HR 恒为 1、置信区间宽度为 0，越远离参照值区间越宽；改变参照值会使整条曲线上下平移，但形状不变。参照值应事先说明（如中位数、临床正常值，图中竖线 50 岁即参照值的位置）。(2) 两端数据稀少，置信区间

很宽，尾部的“上翘”“下降”可能只是随机波动，应结合数据分布（如叠加直方图）解释。(3) 结点个数宜事先确定（3–5 个），不应反复试换以求显著。



Death Risk

5.2.5 建模步骤与策略

1）模型的选择：Cox 模型、其他模型（指数模型、Weibull 模型）。
2）建模的步骤：参数估计、假设检验、模型评估、模型筛选。
3）从单因素分析开始——部分多因素——多因素。
4）深入思考：变量类型、条件的检验、变量间的关系、拟合优度。
5）结果解释：统计学意义与专业意义、设计的好坏。

第 2 章“按研究目的确定建模方案”中的原则同样适用于 Cox 回归，另需注意：(1) 有效样本量是事件数，每个参数约需 10–20 个事件；(2) 连续变量的函数形式在 $\ln h$ 尺度上检查（鞅残差图、样条）；(3) 对每个主要变量检查 PH 假定（log–log 图、Schoenfeld 残差），违背时采用分层、时变系数或分时段模型；(4) 协变量必须在时间起点已知，随访中才发生的事件（如复发）应作时依协变量；(5) 预测模型用 C 统计量评价区分度，用校准曲线评价校准度，并作内部验证。

5.3 案例分析

5.3.1 案例介绍与研究设计

队列研究中，探讨危险因素（risk factor）对死亡风险（mortality risk）的影响：长期业余时间体育锻炼强度和全死亡及死因别死亡的关联，一项前瞻性队列研究。

Long-Term Leisure-Time Physical Activity Intensity and All-Cause and Cause-Specific Mortality: A Prospective Cohort of US Adults。

Dong Hoon Lee, Leandro F M Rezende, Hee-Kyung Joh, NaNa Keum, Gerson Ferrari, Juan Pablo Rey-Lopez, Eric B Rimm, Fred K Tabung, Edward L Giovannucci. Circulation. 2022 Aug 16;146(7):523–534. doi:10.1161/CIRCULATIONAHA.121.058162. Epub 2022 Jul 25. PMID:35876019. PMCID:PMC9378548。

题目解析：暴露？结局？对照？设计方法？体育锻炼强度；全死亡/死因别死亡；对照（内对照/外对照/总人口对照/多重对照）；前瞻性队列研究。

背景与目的 目前指南建议的运动水平为每周 150 到 300 分钟的中等强度运动（MPA），或每周 75 至 150 分钟的剧烈运动（VPA），或等量的中等强度和高强度有氧活动组合。问题：每周运动多长时间，死亡风险最低?

5.3.2 数据特点

本研究数据来自两项大型前瞻性队列研究，一个为护士健康研究（NHS），另一个为医疗专业人员随访研究（HPFS）。NHS 研究始于 1976 年，有 121701 名女性（年龄 30–55 岁）登记参与了研究；HPFS 研究始于 1986 年，有 51529 名男性（年龄 40–76 岁）登记参与了研究。参与者每两年完成一次关于人口统计学、生活方式和病史信息的问卷调查。

根据代谢当量（MET）将运动分为中等强度运动（< 6 MET）和剧烈运动（≥ 6 MET）。中等强度运动包括散步、举重和健美操；剧烈运动包括慢跑、游泳、骑自行车和其他有氧运动。

参与者每 2 年完成一份随访研究问卷，随访率均超过 90%。本研究对以上两个队列的数据进行了分析，随访时间为 1988–2018 年，对 116221 名成年人的运动数据进行分析。



5.3.3 方法应用

Cox 回归模型的建立

- 人年的计算：从基线 1988 开始，到死亡或随访结束。结果：在 2984545 人年的随访中（中位随访 26 年），共有 47596 名参与者死亡。
- 使用 Cox 比例风险回归模型估计体育运动强度与全因死亡率以及特定原因死亡率（CVD 死亡和非 CVD 死亡）之间的关联。
- 计算关联强度：风险比（HR）和 95%CI。
- 多因素 Cox 回归模型：协变量调整种族、CVD 家族史、肿瘤家族史、绝经后激素使用、饮酒、能量摄入、吸烟、睡眠、膳食指数、BMI。

Cox 回归中，采用限制性立方样条函数（Restricted cubic spline, RCS），拟合连续性自变量和事件风险之间的剂量反应关系、非线性关系。

> **批注** 增加一个非线性项，可以研究危险因素和结局有没有线性关系/剂量反应关系。

5.3.4 结果及解释

Table 3　Associations Between Long-Term Leisure-Time VPA and All-Cause and Cause-Specific Mortality (Pooled Results of HPFS and NHS, 1988–2018)

Outcome	Deaths	Person-years	Age-adjusted HR (95%CI)	Multivariable-adjusted HR (95%CI)*
All-cause mortality				
VPA, min/wk				
0	1194	91 573	1 (Reference)	1 (Reference)
1–74	31 297	1 776 378	0.63 (0.59–0.67)	0.87 (0.82–0.93)
75–149	7907	539 846	0.50 (0.47–0.53)	0.81 (0.76–0.87)
150–224	3494	269 767	0.48 (0.45–0.52)	0.79 (0.74–0.85)
225–299	1595	122 439	0.46 (0.43–0.50)	0.77 (0.72–0.84)
300–374	937	79 642	0.47 (0.43–0.51)	0.78 (0.72–0.85)
375–449	459	39 875	0.43 (0.38–0.48)	0.73 (0.65–0.81)
450–599	444	38 387	0.45 (0.40–0.50)	0.76 (0.68–0.85)
≥ 600	269	26 638	0.45 (0.39–0.51)	0.74 (0.65–0.85)
CVD mortality				
VPA, min/wk				
0	285	92 503	1 (Reference)	1 (Reference)
1–74	6896	1 805 615	0.56 (0.50–0.64)	0.76 (0.67–0.86)
75–149	1625	547 572	0.44 (0.39–0.50)	0.69 (0.60–0.78)
150–224	788	273 018	0.45 (0.40–0.52)	0.73 (0.64–0.85)
225–299	341	123 927	0.40 (0.34–0.47)	0.67 (0.57–0.79)
300–374	203	80 485	0.39 (0.33–0.47)	0.68 (0.56–0.82)
375–449	105	40 288	0.38 (0.31–0.48)	0.65 (0.52–0.82)
450–599	99	38 787	0.37 (0.29–0.47)	0.67 (0.53–0.84)

与没有进行剧烈运动的参与者相比，符合指南推荐强度的参与者（即 75–149 分钟/周），全因死亡率降低 19%（HR=0.81；95%CI 0.76–0.87），心血管疾病死亡率降低 31%（HR=0.69；95%CI 0.60–0.78）。

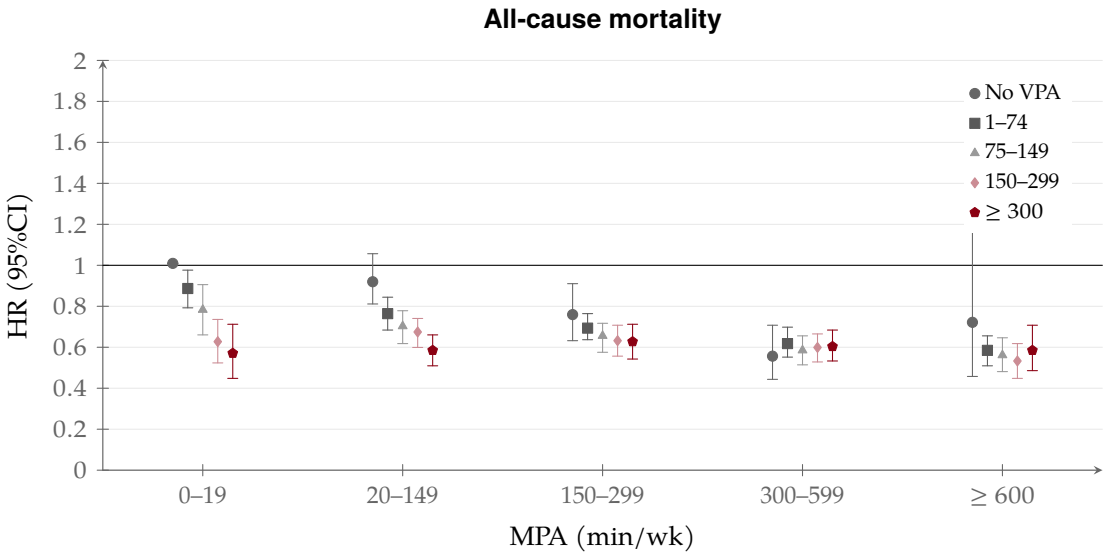


Fig. Joint association of long-term leisure-time VPA and MPA with all-cause and cause-specific mortality

剧烈运动 ≥ 300 分钟/周的参与者，死亡率没有再进一步降低。更长时间的 MPA（≥ 600 分钟/周）与死亡率的相关性，与 300–599 分钟/周与死亡率的相关性结果类似。

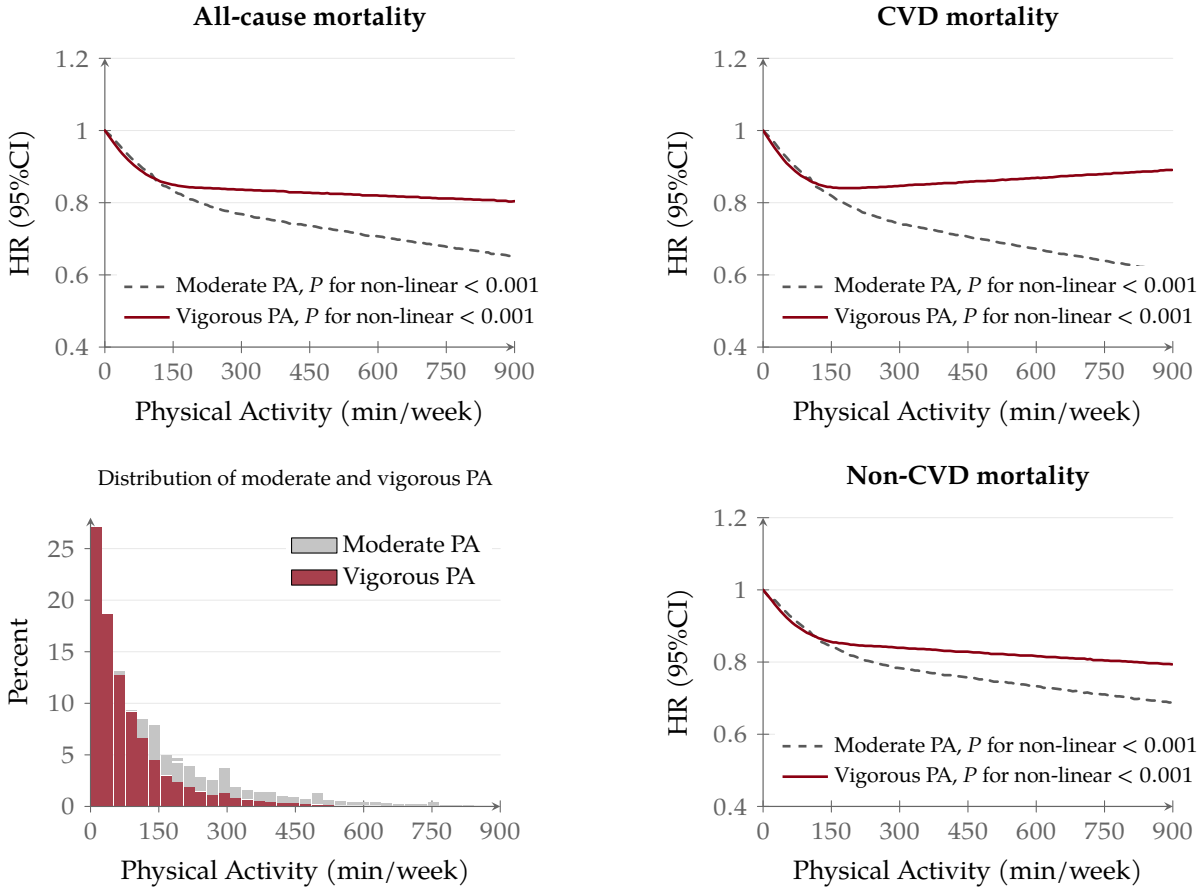


Figure 1. Dose-response relationship of long-term leisure-time MPA and VPA with all-cause mortality (pooled results of HPFS and NHS, 1988–2018)

限制性立方样条模型显示，VPA 与全因死亡、心血管疾病和非心血管疾病的死亡风险显著降低相关，但当 VPA 达到更长时间时，相关性趋于平稳（图中实线；原文图中为黑实线）。限制性立方样条模型显示，MPA 与全因死亡、心血管疾病和非心血管疾病的死亡风险显著降低相关，随着时长的增加，相关性在增强（图中虚线；原文图中为灰实线）。

批注 以“不运动”（0 min/wk）为参照读图：全因死亡中，VPA 的 HR 在约 150 min/wk 以内下降较快（约 0.85），之后几乎持平（900 min/wk 时约 0.80），即超过指南推荐量后增加剧烈运动的额外获益很小；MPA 的 HR 在整个观察范围内持续下降（150 min/wk 约 0.84，900 min/wk 约 0.65）。CVD 死亡中，VPA 曲线在 150–300 min/wk 处最低（约 0.84），之后略有回升（900 min/wk 约 0.89），但该段观察人数少、区间宽，不足以断定剧烈运动过多会减弱保护作用。两条曲线的非线性检验均 $P < 0.001$，说明剂量反应关系不是对数线性的。时长很大处观察人数少（见左下直方图），曲线尾部的精度较低。

5.3.5 英文表达

方法

METHODS: A total of 116 221 adults from 2 large prospective US cohorts (Nurses' Health Study and Health Professionals Follow-up Study, 1988–2018) were analyzed. Detailed self-reported leisure-time physical activity was assessed with a validated questionnaire, repeated up to 15 times during the follow-up. Cox regression was used to estimate the hazard ratio and 95% CI of the association between long-term leisure-time physical activity intensity and all-cause and cause-specific mortality.

结果

During 30 years of follow-up, we identified 47 596 deaths.

Compared with those with no long-term leisure-time VPA, participants who met the long-term leisure-time physical activity guidelines (75–149 min/wk of VPA) had 19% lower all-cause mortality (HR, 0.81 [95% CI, 0.76–0.87]), 31% lower CVD mortality (HR, 0.69 [95% CI, 0.60–0.78]), and 15% lower non-CVD mortality (HR, 0.85 [95% CI, 0.79–0.92]; Table 3).

In the restricted cubic spline models, long-term leisure-time MPA was associated with substantially lower risk of all-cause, CVD, and non-CVD mortality, and the inverse association for long-term leisure-time MPA continued to strengthen over the entire range of activity assessed in the cohort (Figure 1).

5.3.6 注意事项

效应值的计算和解释；前提假定（比例风险假定）；人年的计算。

5.4 思考与练习

1. 比较两种治疗疗法对延长肺癌患者存活时间的效果。观察了 40 例接受标准治疗和试验疗法的病人，同时记录了患者的年龄、病程、病理类型等信息。具体数据见 survivalhomework1。

变量信息：time（生存时间，天），status（结局死亡 1，删失 0），treat（标准疗法 0，试验疗法 1），age（年龄），coursetime（病程），type（病理类型，1 鳞状、2 小型、3 腺状、4 大型）。

1）绘制并比较两个治疗组的生存曲线。

2）在控制了年龄、病程和病理类型之后，比较两个治疗组的疗效。

3）哪些因素影响患者的存活时间？

4）如何评价所使用的模型是否合适？所构建的模型是较优的？

5）如何解释结果？不同治疗方法的疗效比较结果为差别没有统计学意义时，如何理解？

2. 综合分析题

Mortality risk prediction of high-sensitivity C-reactive protein in suspected acute coronary syndrome: A cohort study。

Amit Kaura, Adam Hartley, Vasileios Panoulas, Ben Glampson, Anoop S V Shah, Jim Davies, Abdulrahim Mulla, Kerrie Woods, Joe Omigie, Anoop D Shah, Mark R Thursz, Paul Elliott, Harry Hemingway, Bryan Williams, Folkert W Asselbergs, Michael O'Sullivan, Graham M Lord, Adam Trickey, Jonathan A C Sterne, Dorian O Haskard, Narbeh Melikian, Darrel P Francis, Wolfgang Koenig, Ajay M Shah, Rajesh Kharbanda, Divaka Perera, Riyaz S Patel, Keith M Channon, Jamil Mayet, Ramzi Khamis.

PLoS Med. 2022 Feb 22;19(2):e1003911. doi:10.1371/journal.pmed.1003911. eCollection 2022 Feb. PMID:35192610. PMCID:PMC8863282。

1）请凝练本篇文章要解决的科学问题。
2）原始数据结构主要包括了哪些变量？变量类型如何？
3）这篇文章的流行病学设计是什么？基于此设计，请简述如何用统计模型（Cox 回归模型）来解决科学问题。

补充练习（诊断题）

问　某研究比较心脏移植对生存的影响：以进入移植等待名单为时间起点，把“随访中接受过移植”作为基线 0/1 变量放入 Cox 模型，得到 HR = 0.40。这一分析有什么问题？应如何改正？

答　接受移植的人必须先在等待期内存活到移植那一天，这段时间被错误地归入“移植组”，形成不朽时间偏倚，使移植组显得风险更低。应把移植作为时依协变量：移植前的随访时间计入未移植状态，移植后计入移植状态，用 $(\text{start}, \text{stop}]$ 计数过程数据拟合 Cox 模型；也可用界标分析（landmark analysis）。本章表 8 中的 relapse 存在同样的问题。

小结

生存分析的目的、资料特点、基本概念；生存率的估计方法（寿命表法、Kaplan–Meier）；生存曲线比较的方法（log-rank 法）；Cox 回归分析；生存分析方法的正确应用。

5.5 附录：软件实现

5.5.1 R 语言的实现

R

```r
library(survival)
fit.cox <- coxph(Surv(time, status) ~ x1+x2+x3+x4, data=mydata)
summary(fit.cox)
basehaz(fit.cox, centered=FALSE)    # 协变量取0时的累积基线风险
phtest <- cox.zph(fit.cox)
```

批注 函数名为 Surv（首字母大写，surv 不存在）。status 中 1 为事件、0 为删失（也可用 TRUE/FALSE）；分类变量用 factor()，以 relevel() 指定参照组。coxph 默认用 Efron 法处理并列事件，可用 ties="breslow" 与 SAS/SPSS 对齐。cox.zph 用 Schoenfeld 残差检验比例风险假设；时依协变量用 Surv(start, stop, status) 形式的计数过程数据。以第 4 章例 3 验证：coxph(Surv(t, e) ~ size) 得 $\hat{\beta} = 1.275$（HR 3.58），survdiff 得 log-rank $\chi^2 = 6.77$，均与正文一致。

5.5.2 SPSS 软件实现

Analyze → Survival：Life table、Kaplan–Meier、Cox regression、Cox w/Time-Dep Cov。

5.5.3 SAS 软件实现

SAS

```
PROC PHREG;
MODEL t*status(0)=age grade size relapse/
  SELECTION=STEPWISE SLE=0.05 SLS=0.05;
RUN;
```

5.5.4 STATA 软件实现

Stata

```
stset TIME, failure(STATUS==1) // 定义时间和结局变量，STATUS为1表示事件
stcox x1 x2 x3 x4              // 定义模型中的自变量（默认输出HR）
stcurve, survival              // 绘制生存曲线
estat phtest, detail           // 基于Schoenfeld残差检验PH假定
```

复习题

1) 说明 Cox 模型称为半参数模型的原因。
   答：协变量部分 $\exp(\mathbf{x}^\top\boldsymbol{\beta})$ 有参数形式，基线风险 $h_0(t)$ 不作任何分布假设。
2) 肿瘤分级按 1、2、3 赋值，$\hat{\beta} = 1.572$，解释 HR 的含义。
   答：其他因素不变时，分级每提高 1 级，死亡风险为原来的 $e^{1.572} = 4.82$ 倍；该解释假定相邻两级之间的 HR 相同。

3) 说明部分似然中不出现 $h_0(t)$ 的原因。
   答：在每个事件时刻，风险集中恰为该个体发生事件的条件概率中，$h_0(t)$ 在分子与分母中相消。
4) 列出检查比例风险假定的方法。
   答：观察 *KM* 曲线是否交叉，*log–log* 图是否平行；*Schoenfeld* 残差检验（`cox.zph`）；在模型中加入协变量与时间的交互项。
5) 列出比例风险假定不成立时的处理方法。
   答：分层 *Cox* 模型，分时段拟合，加入协变量与时间函数的交互项（时变系数）。
6) 患者在随访中复发，说明能否将是否复发作为基线协变量纳入 Cox 模型。
   答：不能，否则会产生不朽时间偏倚；应记录复发时间，按时依协变量处理。

第 5 章　习题与解析

生存分析与 Cox 回归

作业题

数据分析题

题 5.1　肺癌治疗的生存分析

比较两种治疗疗法对延长肺癌患者存活时间的效果。观察了 40 例接受标准治疗和试验疗法的病人，同时记录患者年龄、病程、病理类型等信息。具体数据见 survivalhomework1。**共 7 分**。

变量：time（生存时间，天），status（死亡 1、删失 0），treat（标准疗法 0、试验疗法 1），age（年龄），coursetime（病程），type（病理类型：1 鳞状、2 小型、3 腺状、4 大型）。

1. 绘制并比较两个治疗组的生存曲线。（1 分）
2. 在控制年龄、病程和病理类型之后，比较两个治疗组的疗效。（1.5 分）
3. 哪些因素影响患者的存活时间？（1 分）
4. 如何评价所使用的模型是否合适？所构建的模型是较优的？（2 分）
5. 如何解释结果？不同治疗方法的疗效比较结果为差异没有统计学意义时，如何理解？（1.5 分）

文献分析题

题 5.2　hsCRP 与死亡风险：文献分析

阅读 *Mortality risk prediction of high-sensitivity C-reactive protein in suspected acute coronary syndrome: A cohort study*（附原文 pmed.1003911）。**共 3 分**。

1. 请凝练本篇文章要解决的科学问题。（0.5 分）
2. 原始数据结构主要包括了哪些变量？变量类型如何？（1 分）
3. 这篇文章的流行病学设计是什么？基于此设计，请简述如何用统计模型（Cox 回归模型）来解决科学问题。（1.5 分）

往年题

单项选择题

题 5.3　乘积极限法的计算

某随访资料在两个事件时刻的风险人数分别为 5 人、3 人，事件数分别为 2 人、1 人。在第二个事件时刻之后，Kaplan–Meier 生存率估计为多少?

A. 0.20。

B. 0.30。

C. 0.40。

D. 0.60。

E. 0.80。

题 5.4　事件与删失的排序

采用 Kaplan–Meier 法估计生存率时，下列说法错误的是:

A. 将生存时间由小到大排序，完全数据与删失数据同一时刻发生时，删失数据排在完全数据前面。

B. 按不同事件时刻确定风险集。

C. 同一记录时刻既有事件又有右删失时，常规约定先计事件，再移除删失者。

D. 未发生事件的右删失者，其删失前的观察信息可以利用。

E. 估计生存率时，不需要先指定生存时间服从某个参数分布。

题 5.5　生存曲线检验的权重

按课程中对 Log-rank 检验与 Breslow 广义 Wilcoxon 检验的相对比较，下列哪项正确?

A. Log-rank 检验对近期效应更敏感。

B. Log-rank 检验对远期效应更敏感。

C. Breslow 检验对远期效应更敏感。

D. 两者对近期效应同样敏感。

E. 两者对远期效应同样敏感。

题 5.6　比例风险与时间

同一未分层 Cox 比例风险模型中，两个个体的协变量均不随时间变化，且模型满足 PH 假设。在风险函数有定义的时刻，两者风险函数之比与时间的关系是:

A. 随时间线性增大。

B. 随时间指数减小。

C. 必定始终等于 1。

D. 是与时间无关的常数，但不一定等于 1。

E. 只要基线风险随时间变化，风险比就一定随时间变化。

题 5.7　删失与终点事件

以肝癌死亡为研究终点，进行肝癌患者随访研究时，下列情况不属于删失数据的是：

A. 随访期内死于肝癌。

B. 随访期内死于心血管疾病。

C. 随访结束时仍存活。

D. 随访期内失访。

E. 随访期内死于意外。

名词解释

题 5.8　比例风险假设

解释：比例风险假设。

题 5.9　删失数据

解释：删失数据。

题 5.10　删失数据 / 截尾数据（Censored data）

名词解释：删失数据 / 截尾数据（Censored data）。

题 5.11　比例风险假设（PH Assumption）

名词解释：比例风险假设（PH Assumption）。

题 5.12　风险比（Hazard Ratio, HR）

名词解释：风险比（Hazard Ratio, HR）。

简答题

题 5.13　乘积极限法

估算生存率时，什么时候考虑乘积极限法？其基本思想是什么？有什么优点？

题 5.14　Cox 系数与用途

Cox 回归中，如何解释 X_j 的偏回归系数 β_j？Cox 回归的用途？

题 5.15　删失的常见原因

什么是生存分析中的“删失”？请举出至少三种常见原因。

题 5.16　KM 法与寿命表法

比较 Kaplan–Meier 法（乘积极限法）与寿命表法的适用条件。

题 5.17　两种生存曲线检验

简述 Log-rank 检验与 Breslow 检验在生存曲线比较中的异同。

题 5.18　PH 假设及其评价

Cox 比例风险模型中，“比例风险”假设的具体含义是什么？如何评价该假设是否成立？

计算与综合分析题

题 5.19　删失、非比例风险与交互作用

什么是截尾数据？当使用 Cox 回归模型时，如果自变量不满足比例风险的假定时应如何考虑？利用表 1 的分析结果估计相对于不吸烟、不饮酒的人，某人同时吸烟、饮酒的发病风险；对于饮酒的人吸烟的发病风险。

表 1 心血管疾病的危险因素分析（Cox 回归）：

因素	B	SE(B)	CHISQ	P	RR（原表标题）
吸烟 vs 不吸烟	0.693	0.323	4.605	0.032	2.0
饮酒 vs 不饮酒	1.099	0.551	3.975	0.046	3.0
吸烟 × 饮酒	0.405	0.186	4.752	0.029	1.5

题 5.20　心肌梗死风险因素的性别差异

前瞻性队列研究，比较男性和女性心肌梗塞的危险因素是否相同，以图的形式报告男性和女性各自不同因素的 Hazard ratio 及置信区间。

1. 统计分析方法是什么？以何为因变量？有何特点？（4 分）
2. 结合研究目的解释图中结果。（6 分）

原稿未附森林图、因素名称与数值。

数据分析题

题 5.21　戒毒方式与复吸时间

利用数据 2（原题称 DATA2.sav，目录实际提供 data2.xls 与 data2.csv）分析不同戒毒方式对复吸的影响，并对结果做简单解释。

变量：treat（0 短期方案，1 长期方案）；age（岁）；ndrugtx（既往戒毒次数）；site（戒毒机构）；herco（过去 3 个月毒品种类：1 heroin and cocaine；2 either heroin or cocaine；3 neither）；time（治疗后到复吸的时间，天）；censor（截尾 0、复吸 1）。

题 5.22　冠心病数据分析（2020）

数据 test.xls 为一项冠心病研究的基线数据，变量说明见 Sheet1。利用该数据分析影响冠心病死亡的危险因素。提交时附带 R 程序。

原工作簿 Sheet1 变量说明：Status（是否存活）；AgeCHDdiag（冠心病诊断年龄）；Sex；AgeAtStart（基线年龄）；Height（cm）；Weight（kg）；Diastolic/Systolic（mmHg）；Smoking（每日支数）；AgeAtDeath（岁）；Cholesterol；Chol_Status；BP_Status；Weight_Status；Smoking_Status。后 5 项分别为胆固醇及胆固醇、血压、体重、吸烟状态，空白说明按原文件保留并在分析中核对取值。

题 5.23　冠心病数据分析（2021）

数据 test.xls 为一项冠心病研究的数据，1948 年收集了 5209 名 28–62 岁成年人的基线数据，随访至 1980 年底，变量说明见 Sheet1。利用该数据分析影响冠心病死亡的危险因素。提交时附带 R 程序。

原工作簿 Sheet1 变量说明：Status（是否存活）；AgeCHDdiag（冠心病诊断年龄）；Sex；AgeAtStart（基线年龄）；Height（cm）；Weight（kg）；Diastolic/Systolic（mmHg）；Smoking（每日支数）；AgeAtDeath（岁）；Cholesterol；Chol_Status；BP_Status；Weight_Status；Smoking_Status。后 5 项分别为胆固醇及胆固醇、血压、体重、吸烟状态，空白说明按原文件保留并在分析中核对取值。

补充练习

> **说明**
>
> 以下为配合正文新编的补充练习，按题型编排。教学设定的数据不代表真实研究结果；解析见章末。

单项选择题

题 5.24　时段生存概率与累计生存率

某人群的生存函数满足 $S(2)=0.80$、$S(5)=0.60$。以下哪项正确？

A. 活过 2 年的人继续活过 5 年的条件概率为 0.60。

B. 前 5 年的累计死亡概率为 0.20。

C. 活过 2 年的人继续活过 5 年的条件概率为 0.75。

D. 第 5 年的瞬时死亡风险一定为 0.40。

E. $S(5)=S(2)+P(T>5\mid T>2)$。

名词解释

题 5.25　中位生存期

名词解释：中位生存期（Median survival time）。若观察期内 Kaplan–Meier 曲线始终高于 0.5，应如何报告？

简答题

题 5.26　删失者如何参与部分似然

四名对象自时刻 0 进入随访，只有一个不随时间变化的二分类协变量 X。记录为：甲 $(X=0,t=1,\text{事件})$，乙 $(X=1,t=2,\text{删失})$，丙 $(X=1,t=3,\text{事件})$，丁 $(X=0,t=4,\text{删失})$。

有人说：“Cox 回归只在事件时刻构建部分似然，所以可先删除乙、丁再建模。”此说法是否正确？请列出两个事件时刻的风险集，写出部分似然，说明基线风险为什么消去。不要求求解回归系数。

计算与综合分析题

题 5.27　有并列时间的 KM 计算

8 名对象均从时刻 0 开始随访，以死亡为终点。观察时间（月）为

$$1,\quad 2,\quad 2^{+},\quad 3^{+},\quad 4,\quad 4,\quad 5^{+},\quad 6^{+}.$$

“+”表示右删失。同一记录时刻先计事件，再移除删失者。

1) 列出所有事件时刻的风险人数 n_i、死亡数 d_i 和 $\hat{S}(t_i)$。

2) 求 $\hat{S}(3)$、$\hat{S}(4)$ 及中位生存期。删失时刻生存曲线是否下降？

3) 按 Greenwood 公式求 $\hat{S}(4)$ 的标准误。

题 5.28　寿命表与中位生存期的内插

某随访仅提供按年分组的资料。假定各区间内删失均匀发生，采用正文寿命表法。

时间区间（年）	期初人数	死亡数	区间内删失数
0–1	100	18	20
1–2	62	10	24
2–3	28	7	0

1) 求各区间的有效人数、条件生存概率及 1、2、3 年累计生存率。

2) 按正文的线性内插法估计中位生存期。

3) 为什么第 3 个区间的条件生存概率不等于 3 年累计生存率？为什么不能仅据此表精确重建 KM 曲线？

题 5.29　从预后指数计算生存率

某教学 Cox 比例风险模型为

$$h(t \mid X) = h_0(t)\exp\left\{(\log 0.5)Z + (\log 1.5)\frac{A-50}{10}\right\},$$

其中 $Z=1$ 为试验疗法、$Z=0$ 为标准疗法，A 为年龄（岁）。设协变量固定，PH 假设成立，基线生存率 $\hat{S}_0(3)=0.64$。

1) 说明本模型的基线人群。求 60 岁试验组患者的预后指数 PI 及其相对基线人群的 HR。
2) 求该患者的 3 年生存率。是否可用 $0.64 \times HR$ 计算?
3) 求该患者相对 60 岁标准组患者的 HR。两名患者的 3 年累计死亡概率之比是否必等于这个 HR?

文献分析题

题 5.30　体育活动、死亡终点与剂量反应

依据正文的体育活动案例：两项美国前瞻性队列共纳入 116 221 名成年人，1988—2018 年随访。研究用多变量 Cox 模型分析长期业余时间体育活动与死亡的关联。相对没有剧烈运动者，75–149 分钟/周组的结果为：

结局	HR	95% CI
全因死亡	0.81	0.76–0.87
心血管疾病死亡	0.69	0.60–0.78

1) 个体生存结局应由哪两个变量构成？以全因死亡为终点时，死于癌症者如何编码?
2) 用规范语言解释表中两项结果。“30 年死亡概率下降 19 个百分点”是否正确?
3) 正文用限制性立方样条研究运动时长。它主要解决非线性关系还是 PH 假设问题？曲线高运动量端趋平可说明什么?

本次补充习题

本组按正文章节补充 20 题，题型沿用原笔记；解析及来源与新增题号对应。

第 4 章补充：生存分析（一）

单项选择题

每题只有一个最佳答案，请从 A—E 中选择。

题 5.31　延迟入组与风险集

某教学资料以确诊为时间起点，记录进入观察的时间 a 和退出观察的时间 t（月）。采用 $(a, t]$ 约定，即个体只在 $a < u \le t$ 时属于时刻 u 的风险集。

对象	a	t	事件指示
A	0	2	1
B	1	4	1
C	3	5	0
D	4	6	1

第 4 个月事件发生前的风险集为（　）。

A. A、B、C、D

B. B、C、D

C. B、C

D. C、D

E. 只有 B

题 5.32　独立删失的条件

某队列中轻症与重症各占一半。已知在每个严重程度组内，事件时间 T 与删失时间 C 相互独立；但重症者的事件时间和删失时间总体上都较短。关于不分严重程度而直接计算全队列 KM 曲线，下列哪项正确（　）？

A. 组内独立必然推出全队列 T 与 C 独立，因此直接合并一定适当

B. 组内独立不足以保证合并后的独立删失，应考虑按基线严重程度分层估计并明确目标人群

C. 只要两组人数相同，删失机制就不会影响合并 KM 估计

D. 将所有重症删失者改记为事件即可消除偏倚

E. 先删除所有删失者，再按严重程度合并就能得到无偏估计

题 5.33　分组记录与区间内顺序

一份教学随访资料只保留某时间区间的汇总：期初 20 人，区间内死亡 5 人、右删失 10 人，区间末仍有 5 人。区间内没有新入组者，也没有记录精确事件/删失时间。设本区间开始时的生存率为 1。关于本区间末的生存率，下列哪项正确（　）？

A. KM 估计只能为 $15/20 = 0.75$

B. KM 估计只能为 $5/20 = 0.25$

C. 寿命表估计为 0.50，与删失发生时间无关

D. 只凭这些汇总数就能唯一确定 KM 估计为 2/3

E. 可能的 KM 估计最小为 0.50、最大为 0.75；寿命表按半数删失修正得到 2/3

题 5.34　生存率区间的反变换

某教学 KM 估计为 $\hat{S} = 0.90$，Greenwood 求和项为 $G = \sum_i d_i/\{n_i(n_i - d_i)\} = 1/90$。采用对数负对数变换

$$g = \log(-\log \hat{S}), \qquad SE(g) = \frac{\sqrt{G}}{|\log \hat{S}|}.$$

将 $g \pm 1.96SE(g)$ 反变换得到的 95% 置信区间最接近（　）。

A. (0.985, 0.473)

B. (0.714, 1.086)

C. (0.800, 1.000)

D. (0.473, 0.985)

E. (0.100, 0.900)

题 5.35　并列事件时的期望与方差

某教学比较中，一个事件时刻之前 A、B 两组分别有 6 人和 4 人在风险集中，该时刻共发生 3 个事件。在两组生存分布相同的原假设下，给定风险人数和总事件数，A 组事件数的期望 E_A 与超几何方差 V_A 分别为（　）。

A. 1.80 与 0.56

B. 1.80 与 0.72

C. 1.80 与 1.80

D. 3.00 与 0.56

E. 0.60 与 0.24

题 5.36　检验权重与软件选项

关于两组生存曲线比较，判断以下命题：

I. 普通 logrank 检验对各事件时刻的 $O_i - E_i$ 贡献采用权重 1。

II. R 中 `survdiff(..., rho=1)` 在任何资料上都与以总风险人数 n_i 为权重的 Breslow 广义 Wilcoxon 检验相同。

III. 应根据预先关心的生存差异选择检验；两种检验都计算后只报告较小的 P 值，会改变原来宣称的检验程序。

正确的组合是（　）。

A. 仅 I

B. 仅 II

C. I、III

D. II、III

E. I、II、III

简答、计算与案例分析

题 5.37　相同中位数能说明什么

一组新编教学资料得到如下 KM 汇总，按 $\inf\{t : \hat{S}(t) \le 0.5\}$ 定义，两组中位生存期均为 12 个月：

组别	$\hat{S}(6)$	$\hat{S}(12)$	$\hat{S}(24)$
A	0.750	0.500	0.250
B	0.875	0.500	0.125

研究者说：“中位数相同，说明两组生存经历相同；即使 logrank 显著，也只是与中位数结论相矛盾。”请评议，并说明若科学问题是“24 个月生存率是否不同”，应明确什么检验目标。

题 5.38　公开肺癌资料的生存输出

使用公开的 `survival::veteran` 完整 137 例肺癌试验资料，以入组后的时间（天）为时间轴，status = 1 表示死亡、0 表示右删失。以下按细胞类型分组的结果由完整资料重新计算：

细胞类型	人数	死亡数	KM 中位数（天）
鳞状细胞	35	31	118
小细胞	48	45	51
腺癌	27	26	51
大细胞	27	26	156

细胞类型	$n(90)$	$\hat{S}(90)$	$SE\{\hat{S}(90)\}$	$n(365)$
鳞状细胞	20	0.622222	0.082839	6
小细胞	14	0.291667	0.065606	2
腺癌	8	0.288066	0.088652	0
大细胞	20	0.740741	0.084337	2

$n(t)$ 为时刻 t 之前的风险人数，$\hat{S}(t)$ 计入 t 时刻事件后的估计。四组总体 logrank 统计量为 25.4037。

1) 给出总体检验的自由度及 H_0，在 $\alpha = 0.05$ 下作结论。能否据此断言任意两种细胞类型都有显著差异？

2) 若事先指定比较大细胞与小细胞的 90 天生存率，按

$$Z = \frac{\hat{S}_{\mathrm{L}}(90) - \hat{S}_{\mathrm{S}}(90)}{\sqrt{SE_{\mathrm{L}}^2 + SE_{\mathrm{S}}^2}}$$

   求差值、Z 及近似结论。它与总体 logrank 检验的目标有何不同？

3) 结合 $n(365)$，说明报告远期生存结果时还需注意什么。不同类型之间的差异可直接解释为随机化的治疗效应吗？

供查用：$\chi^2_{3,0.95} = 7.815$，$z_{0.975} = 1.96$。

题 5.39　两种生存检验的计算

以下为新编教学资料。A、B 两组各 50 人，均从第 0 天开始随访；事件只出现在表列的四个记录时刻，此前无删失。最后存活的 18 名 A 组对象和 2 名 B 组对象均在第 365 天右删失。

时间（天）	n_{Ai}	n_{Bi}	d_{Ai}	d_{Bi}
30	50	50	20	0
90	30	50	12	8
180	18	42	0	20
270	18	22	0	20

记 $n_i = n_{Ai} + n_{Bi}$、$d_i = d_{Ai} + d_{Bi}$，

$$E_{Ai} = \frac{n_{Ai} d_i}{n_i}, \qquad V_i = \frac{n_{Ai} n_{Bi} d_i (n_i - d_i)}{n_i^2 (n_i - 1)}.$$

1) 列出各时刻 $O_{Ai} - E_{Ai}$，求普通 logrank 的 $U = \sum (O - E)$、$V = \sum V_i$ 与 $\chi^2 = U^2 / V$。
2) 按课程中的 Breslow 广义 Wilcoxon 定义，取 $w_i = n_i$，计算 $U_w = \sum w_i (O - E)$、$V_w = \sum w_i^2 V_i$ 及 $\chi^2_w = U_w^2 / V_w$。
3) 已知 $\chi^2_{1,0.95} = 3.841$，比较两项大样本近似检验的结论。结合 30 天和 270 天 KM 生存率，说明这些结果能否支持某组在整个随访期始终更好。

题 5.40　诊断后登记的生存报告

某新编登记案例只纳入确诊后满 6 个月仍存活并完成登记的 120 人，此后开始正式随访。部分患者因病情恶化而停止来院。分析者将所有人确诊至登记之间的 6 个月补作“已观察、无事件”，从确诊日画 KM 曲线，报告“全体初诊患者 5 年生存率为 80%”。5 年前风险集仅余 3 人，最后一段曲线保持水平；他进一步解释“远期风险已降为 0”。

请指出这份报告在目标人群、观察起点、删失和尾部解释上的主要问题，并提出可实施的修改。仅改用含延迟入组的程序，能否从这批资料补出确诊后前 6 个月的生存概率？

第 5 章补充：生存分析（二）

单项选择题

每题只有一个最佳答案，请从 A—E 中选择。

题 5.41　改变协变量的参照点

某教学 Cox 模型写为

$$h(t \mid A) = h_0(t)\exp\{0.04(A-60)\},$$

其中 A 为年龄（岁）。现将同一个拟合模型改写为 $h(t \mid A) = h_0^*(t)\exp\{0.04(A-70)\}$。哪项正确（　）?

A. $h_0^*(t) = h_0(t)$，所有个体的预测风险都降低

B. $h_0^*(t) = e^{0.4}h_0(t)$，所有个体的预测风险及相同年龄差对应的 HR 保持不变

C. $h_0^*(t) = e^{-0.4}h_0(t)$，各个体预测风险保持不变

D. 只有重新估计年龄系数才能保证两种写法等价

E. 改变中心点后，年龄系数必须变为 0.4

题 5.42　并列事件的部分似然

某教学 Cox 模型只有一个固定协变量 X。某事件时刻的 5 名风险集成员取值为 $0,0,1,1,1$，其中 $X=0$ 和 $X=1$ 各有 1 人发生事件，其余 3 人当时不退出。取 $\beta = \log 2$。按常规近似部分似然、不附加与 β 无关的排列常数，该时刻的 Breslow 与 Efron 贡献依次为（　）。

A. 1/8 与 1/8

B. 1/32 与 1/32

C. 1/64 与 1/52

D. 1/32 与 1/26

E. 1/26 与 1/32

题 5.43　变量检验与全局 PH 检验

一个含治疗、年龄和四水平细胞类型的 Cox 模型，其 PH 诊断表如下（为教学设定的输出结构，非真实数据的诊断结果）：

项	χ^2	df	P
治疗	8.41	1	0.0037
年龄	0.16	1	0.6892
细胞类型	0.49	3	0.9211
GLOBAL	9.06	5	0.1067

在 0.05 水平下，最适当的解释是（　）。

A. 治疗项提示时间相关效应，应结合残差图和科学问题进一步检查，不能被不显著的全局检验掩盖

B. 全局 $P > 0.05$ 已经证明全部变量均满足 PH 假设

C. 治疗项 $P = 0.0037$ 说明治疗对死亡结局的主效应一定显著

D. 年龄项 $P > 0.05$ 说明年龄与死亡风险没有关联，应从模型删除

E. 细胞类型有 4 个水平，所以其 PH 检验一定应使用 4 个自由度

题 5.44　分层 Cox 模型的解释

研究者不关心医院本身的效应，但怀疑两家医院的基线风险形态不同，拟合

$$h_s(t \mid Z) = h_{0s}(t)\exp(\beta Z), \qquad s = 1, 2,$$

其中 Z 表示治疗组。以下哪项正确（　）?

A. 两医院的基线风险必须相同，否则这个模型无法使用

B. 模型必然估计两个互不相关的治疗系数 β_1, β_2

C. 把医院作为分层变量后，仍可直接读出一个医院 2 相对医院 1 的固定 HR

D. 医院分层自动保证治疗满足 PH 假设，无需再检查

E. 允许医院有不同基线风险，在各层内使用共同治疗系数；模型本身不提供一个医院层间固定 HR

题 5.45　时间交互的代码判读

Z 是固定的治疗指示，时间单位为天，所有事件时刻均大于 0。研究者希望拟合

$$h(t \mid Z) = h_0(t)\exp\{\beta Z + \gamma Z \log(t/30)\},$$

其中 t 表示每个风险集共同的当前事件时刻。他准备采用以下 R 写法：

```
coxph(Surv(time, status) ~ Z + I(Z*log(time/30)),
      data=d)
```

d 中的 time 为每个人最终观察到的事件或删失时间。对这段写法的正确评价是（　）。

A. 公式包含 time，所以已经正确实现所要求的时变系数

B. 只要把最终 time 改为月份，问题即可解决

C. 右侧使用每人最终观察时间产生固定的新变量，不能代替事件时刻更新的交互，应使用正确的时间变换机制

D. 删去右侧 Z 主效应就会自动得到正确的时变系数模型

E. 必须把死亡者的 time 替换为 0，才能构造风险集共同时间

题 5.46　时依变量与分段记录

在每人最多一个终末事件的 Cox 分析中，判断以下命题：

I. 即使 $X_i(t)$ 随时间变化，只要 β 为常数，任意两人的风险函数之比就必定不随时间变化。

II. 一个未以事件结束的 (start, stop] 区间，仍可在其覆盖的其他人事件时刻参与部分似然分母。

III. 将同一受试者正确拆为不重叠区间时，他在任一风险集至多出现一次；相互重叠的重复区间可能把此人重复计入。

正确的组合是（　）。

A. 仅 I

B. 仅 II

C. I、II

D. II、III

E. I、II、III

简答、计算与案例分析

题 5.47　重新表达时间尺度

对同一份右删失资料，所有人从时刻 0 开始观察，模型只含固定协变量，没有协变量与时间的交互。将所有事件和删失时间按 $\tau = \log(1 + t)$ 重新表达，保留全部观测且不作四舍五入，并采用相同的并列事件处理。有人认为：“时间数值都变了，所以普通 Cox 部分似然、回归系数和 HR 也一定改变。”请说明该说法是否成立，并区分哪些量保持不变、哪些时间解释需要改变。若原模型含 $X \log t$ 项，可否机械地换成 $X \log \tau$？

题 5.48　分类变量的整体检验与指定对比

使用公开 `veteran` 完整 137 人资料（128 次死亡、9 例删失），拟合 Efron 并列处理的 Cox 模型：

$$h(t) = h_0(t) \exp\{\beta_Z Z + \beta_K K + \beta_S I_S + \beta_A I_A + \beta_L I_L\}.$$

时间单位为入组后天数，status 为死亡 1、右删失 0。$Z = 1$ 为试验治疗、0 为标准治疗；$K = (\text{karno} - 60)/10$；细胞类型以鳞状细胞为参照，S、A、L 分别指小细胞、腺癌和大细胞。按完整数据重算得到：

项	$\hat{\beta}$	$SE(\hat{\beta})$
试验治疗	0.261744	0.200923
K	−0.312713	0.051651
小细胞 vs 鳞状细胞	0.824980	0.268911
腺癌 vs 鳞状细胞	1.153994	0.295038
大细胞 vs 鳞状细胞	0.394625	0.282243

同一批 137 人、相同并列处理下，全模型的部分对数似然为 -474.914509；仅含 Z, K 的模型为 -483.965694。另有

$$\widehat{\mathrm{Var}}\begin{pmatrix}\hat\beta_{\mathrm{S}}\\ \hat\beta_{\mathrm{A}}\end{pmatrix} = \begin{pmatrix}0.072313 & 0.043484\\ 0.043484 & 0.087047\end{pmatrix}.$$

1) 构造细胞类型整体的似然比检验，写出约束、统计量和自由度，在 0.05 水平作结论。
2) 在治疗与 karno 相同的条件下，求腺癌相对小细胞的 HR 和 Wald 95% CI；计算对数 HR 的方差时应如何使用协方差?
3) 若整体检验显著而第（2）项区间包含 1，是否矛盾？这些汇总是否已经足以证明 PH 假设成立以及生存概率预测校准良好?

供查用：$\chi^2_{3,0.95} = 7.815$，$z_{0.975} = 1.96$。

题 5.49　时间更新用药状态的风险集

以下为新编教学资料。6 人均从 0 月进入，开始用药后持续用药；“未用药”指整个观察期未用药，开始时刻 0 指入组即已用药。用 $X_i(t)$ 表示事件发生前已知的当前用药状态。

对象	退出时间（月）	事件指示	开始用药时刻（月）
A	2	1	未用药
B	4	1	3
C	6	1	5
D	8	1	7
E	9	0	未用药
F	10	1	0

拟合 $h_i(t) = h_0(t)\exp\{\beta X_i(t)\}$，采用 $(\mathrm{start}, \mathrm{stop}]$ 记录。

1) 写出 B 的两段记录，包括区间、事件指示和 X。
2) 在 $\beta = 0$ 时，记 p_k 为第 k 个事件时刻风险集中已用药者的比例。列出各事件时刻的风险人数、p_k 及事件者 X，计算

$$U(0) = \sum_k (X_{\mathrm{event},k} - p_k), \qquad I(0) = \sum_k p_k(1-p_k), \qquad Q = \frac{U(0)^2}{I(0)}.$$

   仅按 χ^2_1 大样本近似、临界值 3.841 给出计算结论；这不是小样本精确检验。
3) 最后一次事件是否提供关于 β 的信息？如果把“随访中曾经用药”错当基线变量，2 月时的 p_k 会怎样改变，为什么这种改法不合适?

题 5.50　检验值更新能否使用未来信息

以下示范记录改编自 survival 作者关于时依变量的教学文档，用于方法讨论，并非患者研究原始资料：某对象在第 0、90、120 天测得肌酐分别为 0.9, 1.5, 1.2 mg/dL，于第 185 天死亡。研究者提出以下处理：

1）在 0–90 天之间作线性插值，因此把第 45 天的协变量记为 1.2 mg/dL。

2）拆成多段后，将每一条分段记录计作一名新的独立受试者。

3）只有加入“肌酐 × 时间”交互才算处理了时依协变量。

4）如果以后拟合出的肌酐系数为正，即可断言降低肌酐本身一定降低死亡风险。

请逐项评议。采用“截至当前最后已知测量值”的约定，写出该对象可用于标准 Cox 时依协变量分析的三段记录，并说明这种约定仍有什么解释限制。

习题解析

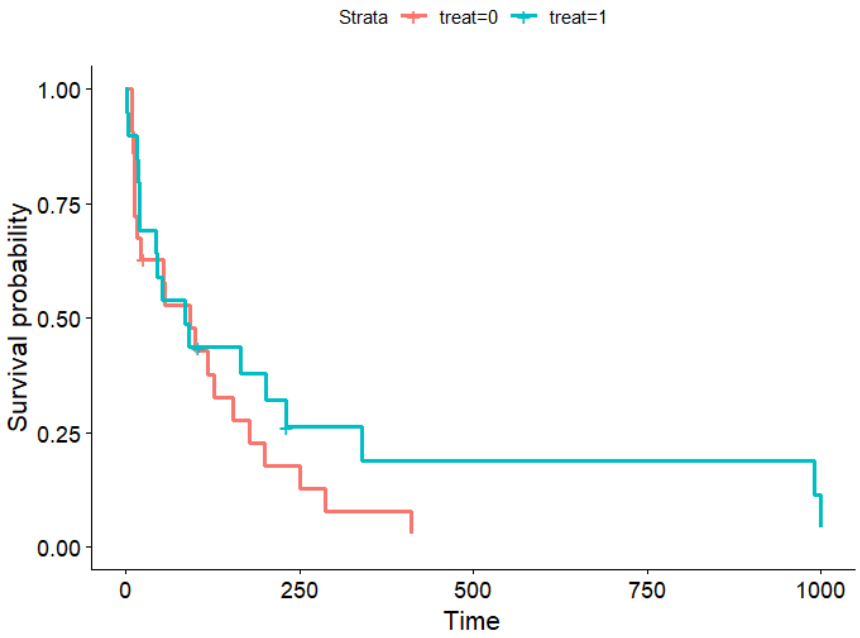
> **核对方式**
> 按题号核对。缺失选项的补写及新编练习均在对应解析末尾说明。

作业题

解析　题 5.1　肺癌治疗的生存分析

返回题目

(1) 绘制两组 Kaplan–Meier 曲线。标准组 21 人、20 个事件；试验组 19 人、17 个事件。Log-rank 检验 H_0：两组总体生存曲线相同；$\alpha = 0.05$。$\chi^2 = 1.22$，$df = 1$，$P \approx 0.27$（原稿四舍五入 0.3），尚不能拒绝 H_0。



(2) 用病理类型 1 作参照，令 $I_k = I(type = k)$：

$$h(t \mid X) = h_0(t)\exp\{-0.614\,treat - 0.001\,age + 0.017\,coursetime + 0.488 I_2 + 1.683 I_3 + 0.264 I_4\}.$$

变量	β	SE	P	HR（95% CI）
试验疗法	−0.614	0.408	0.132	0.541 (0.244–1.203)
年龄	−0.001	0.019	0.969	0.999 (0.963–1.037)
病程	0.017	0.013	0.179	1.017 (0.992–1.043)
类型 2 vs 1	0.488	0.532	0.358	1.630 (0.575–4.619)
类型 3 vs 1	1.683	0.615	0.006	5.384 (1.614–17.963)

变量	β	SE	P	HR（95% CI）
类型 4 vs 1	0.264	0.470	0.574	1.302 (0.518–3.273)

（3） 全模型中类型 3 与类型 1 的对比有统计学意义。但分类变量整体检验与单个哑变量检验不同，不能直接删除所有不显著项后沿用原系数，声称得到“最终模型”。研究关心的治疗因素应保留。

（4） PH 诊断：治疗项 Schoenfeld 检验 $P = 0.75$，全局 $P = 0.42$，未发现显著违反 PH 的证据。曲线相交只是提示；$P > 0.05$ 不是证明假定成立。全模型似然比 9.96（6 自由度，$P \approx 0.13$）、Wald10.28、Score11.23（原稿均约 0.1、0.1、0.08）。$C = 0.638$ 表示区分能力有限，C 指数不是完整的拟合/校准指标，亦非只在 0.5–1 之间取值。进一步检查函数形式、影响点、校准与内部验证。

（5） 调整后试验疗法的死亡瞬时风险点估计较低，但区间跨 1，未能证实疗效差异；不等于两种疗法等效。可能原因包括样本小、估计不精确、残余混杂或真实差异较小。解释病理类型时明确参照，不能把类型编码直接乘以哑变量系数。

解析 题 5.2　hsCRP 与死亡风险：文献分析

返回题目

科学问题。可疑急性冠脉综合征患者中，肌钙蛋白之外，轻度升高的 hsCRP 是否与短期和长期全因死亡相关，并改善预测？

变量。人口学：出生年份/年龄、性别、种族；临床：首次测量血红蛋白、白细胞、血小板、肌酐、肌钙蛋白、hsCRP 等连续指标，以及 ICD 诊断等分类指标；身份标识：脱敏 NHS 号、医院号；结局：时间起点、死亡/随访结束时间、死亡状态。**原稿“死亡日期转换为当日生存率”不准确：个体原始结局应为随访时间和事件指示，生存率是群体估计量**。

设计与分析。回顾性队列。原评分稿记述 5 家英国心血管中心源人群 257,948 人，分析 102,337 人，中位随访 3.3 年。hsCRP 分为 < 2、2–4.9、5–9.9、10–15 mg/L，以 < 2 为参照。多变量 Cox 模型估计 30 天和 3 年死亡关联的 HR 及 95% CI。模型 1 调整年龄、性别、血红蛋白、肌酐；模型 2 再加肌钙蛋白；模型 3 再加 hsCRP。

原文对 PH 不成立采用分时段效应：< 1、1–3、3–6、6–12、12–24、24–36 个月；连续变量可用限制性立方样条处理非线性。比较区分度、AUROC、NRI、IDI 和阴性预测值时，应按原文处理删失与预测时间窗。模型和变量要对应到研究问题，不能只翻译摘要。

往年题

解析 题 5.3　乘积极限法的计算

返回题目

答案：C。

条件生存概率连乘：$\hat{S} = (1 - 2/5)(1 - 1/3) = \frac{3}{5} \times \frac{2}{3} = 0.40$。

补写说明。原稿第 13 题整题缺失；本题为新编练习，并非恢复的往年原题。

解析　题 5.4　事件与删失的排序　　返回题目

答案：A。

A 项错误。同一记录时点同时有事件和右删失时，常规 KM 约定先计事件，后移除删失者；在事件时刻的风险集中包含同刻删失者。

补写说明。原稿只记一个错误选项，其内容保留为 A；提问句及 B—E 为补写。

解析　题 5.5　生存曲线检验的权重　　返回题目

答案：B。

按课程相对比较口径，通常选 **B**：Breslow 以风险集人数加权，相对更强调早期；Log-rank 相对于 Breslow 对后期差异保留更多权重。严格地说，不能保证 Log-rank 总对任意“远期效应”最敏感；其效能取决于生存差异形式，PH 下表现良好。

补写说明。原有五个选项保留；提问句根据回忆内容补全。此处“远期”是相对于 Breslow 的课程比较。

解析　题 5.6　比例风险与时间　　返回题目

答案：D。

根据本题已明确的个体风险函数，在共同基线、PH 成立且比较的协变量不随时间变化时，$h(t \mid x_a)/h(t \mid x_b) = \exp\{\beta^T(x_a - x_b)\}$，与时间无关。若严格指同一模型的共同基线风险函数，其比值就是 1。分层 Cox 不同层基线可不同，不能套用同一结论。

补写说明。原稿未记选项，并写作“基线风险函数之比”；此处按通常考点将提问对象明确为个体风险函数。

解析　题 5.7　删失与终点事件　　返回题目

答案：A。

研究终点为肝癌死亡时，**A**为观察到的事件。B、E 属于竞争事件；在原因别风险分析的传统编码中常在竞争死亡时删失，但估计肝癌累计发生概率时需要竞争风险方法。若研究终点为全因死亡，分类会不同。

补写说明。题干明确了肝癌死亡终点，五个选项保留。

解析　题 5.8　比例风险假设　　返回题目

固定协变量的两个个体，其风险函数之比不随时间改变：$HR = \exp\{\beta^T(x_a - x_b)\}$。允许共同的基线风险 $h_0(t)$ 随时间变化，并不要求每个人的风险本身恒定。

解析　题 5.9　删失数据　　返回题目

事件时间只被部分观察到的数据。右删失知道事件时间大于最后观察时间；左删失知道小于某时间；区间删失知道落在某区间。随访结束未发生事件、失访可产生右删失。常规生存估计需适当的非信息性删失假定。

解析 题 5.10　删失数据 / 截尾数据（Censored data）　返回题目

事件时间只获得部分信息。原汇总给的是右删失定义：只知道真实事件时间超过最后观察时间。更一般还包括左删失和区间删失。

解析 题 5.11　比例风险假设（PH Assumption）　返回题目

固定协变量个体间的 HR 不随时间改变；基线风险本身可随时间变化。

解析 题 5.12　风险比（Hazard Ratio, HR）　返回题目

同一时刻两种条件下瞬时风险函数之比。Cox 模型在 PH 成立时 $HR = e^{\beta^T \Delta x}$；HR 不等于累计风险比或 OR。

解析 题 5.13　乘积极限法　返回题目

有个体事件/删失时间的未分组资料可采用 Kaplan–Meier 法，不限于小样本。将每个不同事件时刻视为分割点，按条件生存概率连乘：

$$\hat{S}(t) = \prod_{t_i \le t} \left(1 - \frac{d_i}{n_i}\right),$$

其中 n_i 为事件前风险人数，d_i 为该时刻事件数。可充分利用删失前的信息，不需指定生存时间分布，也不需人为分组；尾部风险人数很少时不稳定，应展示风险人数和区间。

解析 题 5.14　Cox 系数与用途　返回题目

其他协变量固定、PH 成立时，X_j 增加 1 单位，瞬时风险乘以 e^{β_j}；β_j 为对应 HR 的自然对数。分类变量相对参照水平解释，交互项存在时需条件化。用于分析生存时间的关联因素、调整混杂、比较治疗/暴露，以及在模型验证和基线风险估计后预测生存概率。

解析 题 5.15　删失的常见原因　返回题目

右删失表示只知道事件时间晚于观察截止。例：随访结束未发生事件、随访期间失访、以特定死因为终点时发生其他死因死亡。第三种同时涉及竞争风险，分析需与目标估计量一致。

解析 题 5.16　KM 法与寿命表法　返回题目

KM 法适用于掌握个体事件/删失时间的原始资料，以每个事件时刻划分风险集，大小样本均可。寿命表法适用于按时间区间汇总的资料，通常需区间内删失分布的近似。原汇编只强调“小样本/大样本”过于简化，关键在记录精度和分组形式。

解析 题 5.17　两种生存曲线检验　返回题目

二者比较各组生存经验中的观察/期望事件差异，通常以生存分布相同为无效假设。Log-rank 对各事件时刻采用常规等权的观察减期望贡献；Breslow 广义 Wilcoxon 用风险集人数加权，更强调早期。原汇编 “Log-rank 对远期更敏感” 应理解为相对 Breslow 的课程表述，非普遍定律。

解析 题 5.18　PH 假设及其评价

返回题目

HR 不随时间改变。可看对数负对数生存曲线是否大致平行、检验/绘制缩放 Schoenfeld 残差，以及检验协变量与时间交互。需同时关注每个变量与全局检验；未拒绝 PH 不等于证明 PH。

解析 题 5.19　删失、非比例风险与交互作用

返回题目

“截尾”在本课程语境中指删失，即事件时间只有部分信息，右删失时知道 $T > C$。严格术语中 truncation（截断）涉及样本被观察到的选择机制，与 censoring 不同。

PH 不成立可考虑时变系数（协变量与时间交互）、分时段效应、对不关注其系数的变量分层，或根据科学问题改用其他生存模型。应先核对函数形式、异常点及诊断证据。

同时吸烟饮酒与均不者相比，$HR = e^{0.693+1.099+0.405} \approx 9$；饮酒者中吸烟与不吸烟相比，$HR = e^{0.693+0.405} \approx 3$。原表写 RR，但 Cox 的指数系数应解释为瞬时风险比 HR，不是累计发病概率之比。

解析 题 5.20　心肌梗死风险因素的性别差异

返回题目

可能使用 Cox 比例风险模型，以随访时间和心肌梗死事件指示共同构成生存结局；可处理右删失，无需指定基线风险函数的参数形式，但须检查 PH 等前提。仅凭 HR 标签不能排除其他生存模型，应与文献方法核对。

按男女分别报告 HR、95% CI、参照及调整变量。判断性别差异应用性别 × 因素交互作用或等价异质性检验；“男性显著、女性不显著”不等于两者效应差异显著。原图缺失，不能补造具体结论。

解析 题 5.21　戒毒方式与复吸时间

返回题目

整理者复算。以 $(time, censor)$ 构成生存结局，模型纳入 treat、age、ndrugtx、site、herco；site、herco 按分类变量处理。628 条原始记录，完整记录 610 条，495 次复吸。长期相对短期：$\hat{\beta} = -0.2546$，HR=0.7752，95% CI 0.6486–0.9266，$P = 0.00515$。调整其他变量后，长期方案与较低的复吸瞬时风险相关。

年龄每增 1 岁 HR=0.9765；既往戒毒每增 1 次 HR=1.0354。herco=2 相对 1 的 HR=1.2806 $(P = 0.0439)$；site 与 herco=3 对比未达到 0.05 水平。PH 全局检验 $P = 0.318$，治疗项 $P = 0.092$，未发现明显违反证据；仍应观察残差图。模型 $C = 0.581$，预测区分度有限。不要将名为 censor 的列再次反转编码。

解析 题 5.22　冠心病数据分析（2020）

返回题目

先明确结局。原数据的 Status 只有 Alive/Dead，没有死亡原因。因此不能从现有数据直接识别“冠心病特异死亡”。原材料将已确诊冠心病的 1449 人留下，按确诊后生存时间建模，实际得到的是**冠心病确诊者后续全因死亡**的分析，不等同于原题的病因特异结局。

可复现的示范。明示把随访结束近似为基线后 32 年，确诊者中死亡者时间为“死亡年龄减确诊年龄”，存活者时间为 $32 - (AgeCHDdiag - AgeAtStart)$。该时间近似用于复现教学分析；若需精确分析，应补齐日期。使用确诊年龄、性别、体重状态、吸烟状态、血压状态、胆固醇状态的 Cox 模型，参照组为女性、正常体重、不吸烟、理想血压、适宜胆固醇。两年原始表排序不同，但本设定复算均为 1405 条完整记录、865 个死亡事件。

报告系数、HR、95% CI、PH 和共线性诊断；R 程序随包提供。原答卷的年龄 HR 约 1.07、男性约 1.67、高血压约 1.77 属于上述全因死亡示例，不能挪作冠心病特异死亡结果。原答卷“偏瘦 HR=1.31”与其表中 1.98 不符；表中 BP 的 PH 检验 $P = 0.040$ 也不能被全局 $P = 0.07$ 掩盖。

若严格回答原题。需要死因或可靠冠心病死亡标志，之后构造病因特异事件、明确竞争事件处理；如果目标是从基线开始的风险分析，亦不能事后仅保留最终确诊者而改变目标人群。

解析 题 5.23　冠心病数据分析（2021）

返回题目

先明确结局。原数据的 Status 只有 Alive/Dead，没有死亡原因。因此不能从现有数据直接识别“冠心病特异死亡”。原材料将已确诊冠心病的 1449 人留下，按确诊后生存时间建模，实际得到的是**冠心病确诊者后续全因死亡**的分析，不等同于原题的病因特异结局。

可复现的示范。明示把随访结束近似为基线后 32 年，确诊者中死亡者时间为“死亡年龄减确诊年龄”，存活者时间为 $32 - (AgeCHDdiag - AgeAtStart)$。该时间近似用于复现教学分析；若需精确分析，应补齐日期。使用确诊年龄、性别、体重状态、吸烟状态、血压状态、胆固醇状态的 Cox 模型，参照组为女性、正常体重、不吸烟、理想血压、适宜胆固醇。两年原始表排序不同，但本设定复算均为 1405 条完整记录、865 个死亡事件。

报告系数、HR、95% CI、PH 和共线性诊断；R 程序随包提供。原答卷的年龄 HR 约 1.07、男性约 1.67、高血压约 1.77 属于上述全因死亡示例，不能挪作冠心病特异死亡结果。原答卷“偏瘦 HR=1.31”与其表中 1.98 不符；表中 BP 的 PH 检验 $P = 0.040$ 也不能被全局 $P = 0.07$ 掩盖。

若严格回答原题。需要死因或可靠冠心病死亡标志，之后构造病因特异事件、明确竞争事件处理；如果目标是从基线开始的风险分析，亦不能事后仅保留最终确诊者而改变目标人群。

补充练习

解析 题 5.24　时段生存概率与累计生存率

返回题目

答案：C。因为 $\{T > 5\} \subset \{T > 2\}$，

$$P(T > 5 \mid T > 2) = \frac{S(5)}{S(2)} = 0.75.$$

这是已生存满 2 年者继续生存至 5 年的条件概率。$F(5) = 1 - S(5) = 0.40$；瞬时风险 $h(5)$ 不是 $1 - S(5)$，仅凭两个生存率不能确定。

解析 题 5.25　中位生存期

返回题目

中位生存期是生存分布的第 50 百分位数，即生存函数降至 0.5 所对应的时间。对阶梯状 KM 估计，取 $\inf\{t : \hat{S}(t) \le 0.5\}$，即首次降至 0.5 或以下的事件时刻。若随访内未降至 0.5，应报告“中位生存期尚未达到 / 在本观察期内不可估计”，不能用最长随访时间或死亡者生存时间的中位数代替。寿命表的分组估计可按正文作线性内插。

解析 题 5.26　删失者如何参与部分似然

返回题目

说法错误。删失者在删失之前仍在风险集中，会参与此前事件时刻的分母。

时刻 1 前，风险集为 {甲、乙、丙、丁}；时刻 3 前，甲已发生事件、乙已删失，风险集为 {丙、丁}。没有并列事件，故

$$L_p(\beta) = \frac{1}{2 + 2e^{\beta}} \times \frac{e^{\beta}}{1 + e^{\beta}}.$$

例如 $\beta = 0$ 时，两个贡献为 $1/4$、$1/2$，乘积为 $1/8$。乙、丁虽没有独立的事件分子，仍提供有效信息。

在同一时刻给定风险集中有人发生事件，某个体的贡献为 $h_i(t) / \sum_{l \in R(t)} h_l(t)$。各人的共同因子 $h_0(t)$ 约去，从而只剩协变量与 β。

解析 题 5.27　有并列时间的 KM 计算

返回题目

(1) 事件时刻只有 1、2、4 月：

t_i	n_i	d_i	$\hat{S}(t_i)$
1	8	1	$7/8 = 0.875$
2	7	1	$(7/8)(6/7) = 0.750$
4	4	2	$(3/4)(2/4) = 0.375$

2 月的风险集包含同刻删失者；2 月后余 5 人，3 月再删失 1 人，所以 4 月前余 4 人。

(2) $\hat{S}(3) = 0.750$、$\hat{S}(4) = 0.375$。首次降至 0.5 以下为 4 月，中位生存期为 4 月。删失不会直接使曲线下降，而会改变之后的风险人数；5、6 月的删失也不会把末尾生存率降为 0。

(3)

$$SE\{\hat{S}(4)\} = 0.375\sqrt{\frac{1}{8\times 7} + \frac{1}{7\times 6} + \frac{2}{4\times 2}} = 0.2025.$$

不能把已删失者一开始就剔除，也不能在 2 月先移除删失者再计算死亡概率。

解析 题 5.28　寿命表与中位生存期的内插

返回题目

(1) 有效人数为 $n_i = n_i' - c_i/2$，条件生存概率为 $p_i = 1 - d_i/n_i$：

区间	有效人数	p_i	区间末 $\hat{S}$
0–1	90	0.80	0.80
1–2	50	0.80	0.64
2–3	28	0.75	0.48

期初人数递推也自洽：$100 - 18 - 20 = 62$，$62 - 10 - 24 = 28$。

(2) 0.5 位于 2 年和 3 年的生存率之间，内插为

$$\hat{t}_{0.5} = 2 + \frac{0.64 - 0.50}{0.64 - 0.48}(3 - 2) = 2.875\text{年}.$$

这是分组资料下的近似，不能当作精确事件时刻。

（3） 0.75 的条件是已经生存至第 3 个区间开始，而 3 年生存率须累乘前面各区间，得到 $0.8 \times 0.8 \times 0.75 = 0.48$。原表缺少区间内事件、删失的确切时间与顺序，不能唯一还原 KM 曲线。

解析 题 5.29　从预后指数计算生存率

返回题目

（1） 基线对应 50 岁、标准疗法。60 岁试验组患者有

$$PI = \log 0.5 + \log 1.5 = \log 0.75 = -0.2877, \quad HR = e^{PI} = 0.75.$$

年龄是按每 10 岁进入方程，不能把 60 直接乘以年龄系数。

（2） 由正文公式 $\hat{S}(t \mid X) = \hat{S}_0(t)^{e^{PI}}$，得

$$\hat{S}(3 \mid X) = 0.64^{0.75} = 0.7155.$$

HR 作用于风险函数；在生存函数中进入**指数**，不能计算成 0.64×0.75。

（3） 相同年龄比较两疗法，$HR = 0.5$。60 岁标准组的 3 年生存率为 $0.64^{1.5} = 0.512$，故本例 3 年累计死亡概率之比为

$$\frac{1 - 0.7155}{1 - 0.512} \approx 0.5829,$$

与 0.5 不同。HR 是同一时刻瞬时风险之比，不是指定随访期限的累计死亡概率之比。

解析 题 5.30　体育活动、死亡终点与剂量反应

返回题目

（1） 个体结局由随访时间与事件指示共同构成。时间从规定基线至死亡、失访或随访截止；以全因死亡为终点，癌症死亡也记事件 1，而非删失 0。换成死因别终点时需重新定义事件及其他死因的处理。

（2） 在模型调整因素相同并满足其假定时，75–149 分钟/周组全因死亡瞬时风险为参照组的 0.81 倍，即相对低 19%；95% CI 为 0.76–0.87，未跨 1。心血管疾病死亡的 HR 为 0.69，即相应瞬时风险低 31%，95% CI 为 0.60–0.78。它们不表示 30 年死亡概率下降相同的百分点，也不能仅凭观察性关联断言运动干预造成同样幅度的下降。

（3） 限制性立方样条用于描述连续运动时长与对数风险之间可能的**非线性剂量反应关系**。PH 关注效应是否随随访时间变化，是另一项问题，仍需另行评价。高运动量端趋平提示增加运动时长的额外关联可能减弱；还应结合置信区间和该段数据量，不能只凭曲线宣布某一剂量绝对最优。

本次补充习题解析

第 4 章补充解析

解析　题 5.31　延迟入组与风险集

返回题目

答案：C。 根据 $a < u \le t$ 逐人判断：A 已于 2 月发生事件；B 在 4 月发生事件，仍在当时风险集中；C 已于 3 月进入且到 5 月才删失；D 的进入时刻恰为 4，按题设左开右闭的区间约定不属于该时刻的风险集。因此 $R(4) = \{\mathrm{B}, \mathrm{C}\}$。不能把尚未进入观察的人当作已经随访，也不能提前移除本时刻的事件者。

来源与改编：知识点配套。题干与设问为新编；参考依据[19]、[20]。

解析　题 5.32　独立删失的条件

返回题目

答案：B。 独立性依赖于所条件化的信息。严重程度同时关联事件时间与删失时间时，混合两个组可以使 T 与 C 在总体中相关，即使在每一组内独立。按基线严重程度分别估计生存曲线较符合题设；若要描述目标总体，还需按该总体的组别构成进行恰当汇总，并有相应随访范围的支持。两组样本量相等不消除这种关联；把删失当事件或预先删除删失者都会改变资料含义。

来源与改编：知识点配套。题干与设问为新编；参考依据[19]。

解析　题 5.33　分组记录与区间内顺序

返回题目

答案：E。 若 10 例删失全部早于 5 例死亡，死亡前只剩 10 人，KM 估计为 $(10-5)/10 = 0.50$；若死亡全部早于删失，则为 $(20-5)/20 = 0.75$。把删失逐个移到死亡之前会减少后续风险人数，从而降低 KM 乘积，所以这两个顺序给出端点。寿命表采用 $n' = 20 - 10/2 = 15$，得 $1 - 5/15 = 2/3$，依赖区间内删失分布的近似；它不能替代已经丢失的精确顺序信息。

来源与改编：知识点配套。题干与设问为新编；参考依据[19]。

解析　题 5.34　生存率区间的反变换

返回题目

答案：D。 由题给公式，$g = -2.2504$、$SE(g) = 1.0005$。反变换 $S = \exp\{-\exp(g)\}$ 是单调递减函数，因此下限对应变换尺度的上限：

$$\left[e^{-\exp\{g+1.96SE(g)\}}, e^{-\exp\{g-1.96SE(g)\}}\right] = (0.4730,\ 0.9853).$$

不能保持变换前的端点次序。普通 Wald 区间为 $0.90 \pm 1.96(0.09487)$，约 $(0.7141, 1.0859)$；B 不是本题指定变换的结果。

来源与改编：知识点配套。题干与设问为新编；参考依据[19]、[21]。

解析　题 5.35　并列事件时的期望与方差

返回题目

答案：A。 A 组占风险集的比例为 $6/10$，故 $E_A = 3(6/10) = 1.8$。给定总事件数的分配采用超几何方差，含有限总体修正：

$$V_A = \frac{6 \times 4 \times 3 \times (10-3)}{10^2(10-1)} = 0.56.$$

$3(0.6)(0.4) = 0.72$ 漏掉了 $(10-3)/(10-1)$；也不能把方差直接取为期望事件数。并列事件越多，这项修正越不宜省略。

来源与改编：知识点配套。题干与设问为新编；参考依据[19]。

解析　题 5.36　检验权重与软件选项

返回题目

答案：C。I、III 正确。普通 logrank 取 $w_i = 1$，Breslow 广义 Wilcoxon 按课程定义取 $w_i = n_i$，后者相对更强调风险人数较多的早期。R 的 `survdiff(rho=1)` 属于 Peto–Peto 修正，使用相应生存估计的权重，不能一般地当作 n_i 加权的 Breslow 检验；在特殊删失结构下二者可以一致，仍不能推出“任何资料都相同”。检验选择应对应预先确定的问题，不能事后只保留较小的 P 值。

来源与改编：知识点配套。题干与设问为新编；参考依据[19]、[22]。

解析　题 5.37　相同中位数能说明什么

返回题目

中位数只给出生存曲线首次达到 0.5 的位置，不能概括整条曲线。这里两组在 12 月都为 0.5，但 6 月 B 组估计较高，24 月 A 组估计较高，说明样本中的时间变化形态不同。由这张汇总表本身还不能判定总体差异是否显著。

logrank 通常检验两组总体生存分布相同，涉及整个观察过程中的风险集与事件分配；它并不专门检验中位数相等。因此相同的样本中位数与显著的全曲线检验可以同时出现，逻辑上并不矛盾。曲线交叉时，logrank 贡献可能抵消，未拒绝也不代表等效。

若问题预先限定在 24 月，应把目标写为 $H_0 : S_A(24) = S_B(24)$，使用该时点生存率之差及相应标准误或区间，并说明删失假定和该时点风险人数。不能用全曲线检验的 P 值直接替代这个固定时点的检验。

来源与改编：知识点配套。题干与设问为新编；参考依据[19]。

解析　题 5.38　公开肺癌资料的生存输出

返回题目

(1) H_0 为四种细胞类型的总体生存分布相同，自由度 $4 - 1 = 3$。$\chi^2 = 25.4037$ 对应 $P \approx 1.27 \times 10^{-5}$，拒绝 H_0；只能说明至少存在生存分布差异，不能把总体检验当作六个两两比较均显著的证据。

(2) 预先指定的 90 天生存率之差为

$$0.740741 - 0.291667 = 0.449074, \qquad SE_{\text{diff}} = 0.106850,$$

所以 $Z = 4.2029$，双侧 $P \approx 2.64 \times 10^{-5}$。大细胞组 90 天生存率的点估计较高约 44.9 个百分点。这是一个特定组别对比、特定时间点的检验；总体 logrank 则利用四组完整随访过程，二者不能互相替代。

(3) 365 天前仅余 0–6 人在风险集中，远期估计缺少支持，应同时呈现风险人数和区间，避免把曲线尾部或零风险人数解读成稳定的总体规律。虽然原研究的治疗分配是随机化的，细胞类型本身不是随机分配的；这里的比较也未调整其他预后因素，不能直接称为治疗的因果效应。

来源与改编：案例改编。材料及改编范围见[19]、[23]、[24]、[21]、[22]。

解析　题 5.39　两种生存检验的计算

返回题目

(1) A 组的期望事件数为 10, 7.5, 6, 9，故 $O - E$ 依次为

$$10, \quad 4.5, \quad -6, \quad -9.$$

四个方差贡献约为 4.040404, 3.560127, 2.847458, 2.538462，因此

$$U = -0.5, \quad V = 12.986450, \quad \chi^2 = 0.019251 \quad (P \approx 0.890).$$

（2） 权重为 $100, 80, 60, 40$，加权贡献为 $1000, 360, -360, -360$：

$$U_w = 640, \quad V_w = 77501.236450, \quad \chi^2_w = 5.285077 \quad (P \approx 0.0215).$$

方差应乘权重的平方，不能只乘一次，也不能只改分子。

（3） 普通 logrank 未拒绝 H_0，Breslow 检验在 0.05 水平拒绝。普通贡献中的正负项几乎抵消，而风险人数加权保留了较强的早期差异。30 天 $\hat{S}_A = 0.60$、$\hat{S}_B = 1.00$；270 天分别为 0.36、0.04，优劣方向已经反转。检验差异不矛盾，也不能推出一组在各时刻均占优；更不能事后只保留显著的检验来宣称整体疗效。

来源与改编：知识点配套。题干与设问为新编；参考依据[19]。

解析 题 5.40　诊断后登记的生存报告

返回题目

纳入条件已经筛掉确诊后 6 个月内死亡者，现有资料首先描述的是“活过 6 个月且进入登记者”。把进入观察前的时间补成完整随访，会把入组所要求的存活经历当作已经观察到的风险过程，不能据此报告所有初诊患者的生存率。

应保存确诊日、登记日及事件/删失日，明确采用确诊时间轴的延迟入组，或明确从 6 个月界标开始描述后续条件生存。由于本例所有人最早都在 6 个月进入，即使正确使用 $(a, t]$ 格式，仍没有前 6 个月死亡过程的信息，不能仅凭这些人估计 $S(6)$，也不能据 $S(t \mid T > 6)$ 自动得到总体 $S(t)$。若坚持原目标，需补充从确诊起的完整登记及早期死亡资料。

因恶化而停止来院使独立删失假定受到质疑，应补查生存状态、记录失访原因并检查其与预后的关联。尾部只剩 3 人在风险集中，平坦段仅表示未再观察到事件，不能证明真实风险为 0；报告应展示风险人数、区间、可支持的随访范围及上述限制。

来源与改编：知识点配套。题干与设问为新编；参考依据[19]、[20]。

第 5 章补充解析

解析 题 5.41　改变协变量的参照点

返回题目

答案：B。 因为 $A - 60 = (A - 70) + 10$，

$$h_0(t)e^{0.04(A-60)} = \{h_0(t)e^{0.4}\}e^{0.04(A-70)}.$$

所以新的基线风险是 $e^{0.4}h_0(t) \approx 1.4918h_0(t)$，现在对应 70 岁，而原基线对应 60 岁。改变参照点只是同一拟合风险的重新表示，不改变每个年龄的预测风险，也不改变相同年龄差对应的 HR。变量仍按“岁”计量，系数无需乘 10；基线含义发生变化，应随结果一并说明。

来源与改编：知识点配套。题干与设问为新编；参考依据[25]、[28]。

解析 题 5.42　并列事件的部分似然

返回题目

答案：D。风险评分总和为 $S_R = 2+3e^{\beta} = 8$，两名事件者的风险评分之和为 $S_D = 1+e^{\beta} = 3$，分子为 $e^{0\beta+1\beta} = 2$。Breslow 对两次事件均使用完整风险评分总和：

$$L_B = \frac{2}{8^2} = \frac{1}{32}.$$

Efron 的第二个分母扣除事件者总评分的一半：

$$L_E = \frac{2}{8(8 - 3/2)} = \frac{1}{26}.$$

它不是任意指定哪名事件者先退出；这种扣除处理的是并列事件近似。没有并列事件时，两种写法才自动相同。

来源与改编：知识点配套。题干与设问为新编；参考依据[25]、[26]。

解析　题 5.43　变量检验与全局 PH 检验

返回题目

答案：A。 表中的检验针对效应是否随所选时间尺度改变，而非协变量主效应是否为 0。治疗项给出了违反 PH 的证据，应检查其缩放 Schoenfeld 残差形态，并考虑合适的时间交互或分段表达。全局检验同时涉及 5 个参数，其不显著结果不能覆盖单个治疗项的诊断信号。年龄或细胞类型诊断不显著只表示未检出相应偏离，不代表它们与结局无关，更不证明 PH 成立。四水平分类变量以三个独立对比表示，故表列 3 个自由度。

来源与改编：知识点配套。题干与设问为新编；参考依据[25]、[27]。

解析　题 5.44　分层 Cox 模型的解释

返回题目

答案：E。 分层 Cox 允许 $h_{01}(t)$ 与 $h_{02}(t)$ 分别变化，部分似然在各层内比较风险集。题给模型只有一个 β，所以假定各医院内的治疗 HR 同为 e^{β}，仍需检查这个治疗效应的形式是否合适。医院作为分层变量并没有估计一个普通医院回归系数，两个基线风险之比也不被约束为常数，因此不能报告一个由本模型给出的固定“医院 HR”。若治疗效果本身在医院间不同，还需另行设置并评价相应交互或不同系数。

来源与改编：知识点配套。题干与设问为新编；参考依据[25]、[26]。

解析　题 5.45　时间交互的代码判读

返回题目

答案：C。 右侧的 `time` 仍是数据行中该对象的最终观察时间，生成的是一个依赖未来结局过程的固定值，不能充当所有风险集成员共享的当前时钟。正确思路是在每一事件时刻计算 $Z_i \log(t/30)$，例如：

```
coxph(Surv(time, status) ~ Z + tt(Z), data=d,
      tt=function(x, t, ...) x*log(t/30))
```

此时 β 是第 30 天治疗对比的对数 HR，γ 描述其随 $\log(t/30)$ 的变化。改变时间单位、删除主效应或重编码死亡时间都不能纠正原来的未来信息使用问题。

来源与改编：知识点配套。题干与设问为新编；参考依据[25]、[29]、[26]。

解析　题 5.46　时依变量与分段记录

返回题目

答案：D。 II、III 正确。两人的即时风险比为

$$\exp\{\beta[X_i(t) - X_j(t)]\},$$

即使 β 固定，协变量差也可能随时间改变，因此 I 错误。区间是否有自己的事件分子，与它能否出现在此前风险集分母中是两件事；没有事件的区间仍携带有效风险集信息。分段是同一个人的观察轨迹表示，不能把多行自动当成多名独立受试者，且需核对区间衔接与重叠。

来源与改编：知识点配套。题干与设问为新编；参考依据[25]、[29]、[26]。

解析　题 5.47　重新表达时间尺度

返回题目

该说法不成立。$\log(1+t)$ 严格单调递增，事件与删失的先后顺序、并列关系以及每个事件时刻的风险集都保持不变。固定协变量的普通 Cox 部分似然只使用这些集合中的风险评分及事件者，因此作为 β 的函数不变；对应的估计系数、标准误及 HR 也保持不变。

改变的是时间坐标及其解释。原来第 t 天的生存概率对应新尺度上的 $\tau=\log(1+t)$，时间分位数按同一函数变换；基线生存函数应写作 $S_0^*(\tau)=S_0(e^\tau-1)$。不能把新尺度的一个单位继续叫作“一天”，也不能把基线风险数值直接照搬。

若模型已有 $X\log t$，该项本身依赖具体时间函数。保持原模型需将其改写成 $X\log(e^\tau-1)$；直接改成 $X\log\tau$ 通常是另一个模型，前述普通固定协变量模型的不变性结论不能机械套用。

来源与改编：知识点配套。题干与设问为新编；参考依据[25]、[26]。

解析　题 5.48　分类变量的整体检验与指定对比

返回题目

(1) 整体原假设为 $H_0:\beta_S=\beta_A=\beta_L=0$，包含 3 个独立约束。

$$LR=2\{-474.914509-(-483.965694)\}=18.10237.$$

取 $df=3$，$P\approx0.000419$，拒绝 H_0。这是在给定治疗和 karno 后，对细胞类型整体贡献的检验。

(2) 指定对比的对数 HR 是系数之差：

$$b=1.153994-0.824980=0.329014.$$

两项由同一模型估计，不能忽略协方差：

$$\widehat{\mathrm{Var}}(b)=0.087047+0.072313-2(0.043484)=0.072392,\quad SE(b)=0.269058.$$

因此 $HR=e^b=1.3896$，

$$95\%\ \mathrm{CI}=\exp\{b\pm1.96SE(b)\}=(0.8201,\ 2.3546).$$

它是模型内、治疗与 karno 相同时的腺癌对小细胞瞬时风险比。

(3) 不矛盾。整体检验可由某些类型相对参照组的差异驱动，并不要求每个指定的两两对比都显著。上述输出还没有 PH 诊断、函数形式检查或校准评价，不能据此保证恒定 HR 解释适用，更不能把显著的整体检验当作预测准确的证据。

来源与改编：案例改编。材料及改编范围见[25]、[23]、[24]、[30]、[26]。

解析　题 5.49　时间更新用药状态的风险集

返回题目

(1) B 应分成 $(0,3]$、事件 0、$X=0$；$(3,4]$、事件 1、$X=1$。第一段没有终末事件，但仍可参与该段内其他事件时刻的风险集。

(2) 逐时刻使用当前状态，而不是未来是否用过药：

事件时刻	风险人数	已用药人数	p_k	事件者 X
2	6	1	1/6	0
4	5	2	2/5	1
6	4	2	1/2	1
8	3	2	2/3	1
10	1	1	1	1

$$U(0)=-\frac{1}{6}+\frac{3}{5}+\frac{1}{2}+\frac{1}{3}=\frac{19}{15}=1.266667,$$

$$I(0)=\frac{5}{36}+\frac{6}{25}+\frac{1}{4}+\frac{2}{9}=\frac{383}{450}=0.851111.$$

所以 $Q=1.88512<3.841$，按题设近似未拒绝 $\beta=0$；$P\approx 0.170$。只有 6 人，不能把这个近似判断称作精确的小样本结论。

(3) 10 月风险集中仅剩 F，事件发生于他本人是给定风险集下的必然结果，贡献为 1，得分与信息贡献均为 0。若用“曾经用药”作基线，2 月会把 B、C、D 尚未开始的用药提前计入，比例由 1/6 变为 4/6，使用了未来信息并错误重分配了风险时间。

来源与改编：知识点配套。题干与设问为新编；参考依据[25]、[29]、[26]。

解析　题 5.50　检验值更新能否使用未来信息

返回题目

第（1）项使用了未来信息：在 45 天尚不知道 90 天会测得 1.5，不能把它用于之前风险集中的协变量。按最后已知值，三段记录应为：

start	stop	事件	肌酐（mg/dL）
0	90	0	0.9
90	120	0	1.5
120	185	1	1.2

按 $(\text{start},\text{stop}]$ 约定，新测量值从下一段开始使用。这个对象在 45 天贡献的已知值为 0.9，而不是 1.2。

第（2）项把数据行数当成了受试者数；这里仍然只有一个人、一次终末事件，在每个风险集只取其适用的一行。第（3）项混淆了 $X(t)$ 与 $\beta(t)$：肌酐测量值更新属于时依协变量，系数仍可为常数；与时间交互才另外描述效应系数的变化。

第（4）项把关联作了因果解释。肌酐可与病情、治疗和其他预后因素共同变化，正系数本身不足以识别降低肌酐这一干预的效果。最后已知值约定只避免使用未来观测，并不证明区间内真实肌酐恒定，也不自动解决测量误差、漏测或随病情变化的混杂。

来源与改编：案例改编。材料及改编范围见[25]、[29]。

第 6 章

对数线性模型

logistic 回归与 Cox 回归均区分结局变量与自变量。对数线性模型分析多个分类变量交叉构成的列联表，各变量地位相同，研究目的是描述变量间的关联结构，即哪些变量之间存在关联，以及这种关联在第三个变量的不同水平上是否相同。

对数线性模型将各格频数视为 Poisson 变量，将期望频数的对数表示为各变量主效应与交互项之和。两个变量相互独立对应于模型中不含二者的交互项，变量间关系的判断由此转化为一系列嵌套模型偏差的比较。本章要求能够将模型中的交互项转换为关联结构，例如含 u_{12}、u_{13} 而不含 u_{23}，表示给定变量 1 时变量 2 与变量 3 条件独立。

本章开头的辛普森悖论表明，将多维列联表随意合并为二维表进行 χ^2 检验，结论可能完全相反。

6.1 问题提出

例 1 宫颈癌。变量包括肤色、收入、分娩次数。

表 1　宫颈癌患病情况

肤色	家庭收入	少（0–1 次）	中等（2–3 次）	多（4 次及以上）
白人	低收入	67	143	43
	中收入	36	78	16
	高收入	3	9	12
有色人种	低收入	77	94	25
	中收入	87	70	18
	高收入	14	8	14

常见的数据整理方式：合并、压缩维度。

按肤色列表（合并收入后：肤色 × 分娩次数）

肤色	少（0–1 次）	中等（2–3 次）	多（4 次及以上）
白人	106*	230	71
有色人种	178	172	57

按收入列表（合并肤色后：收入 × 分娩次数）

家庭收入	少（0–1 次）	中等（2–3 次）	多（4 次及以上）
低收入	144	237	68
中收入	123	148	34
高收入	17	17	26

* 原表印作 160；$67+36+3=106$，白人合计 $106+230+71=407$，与有色人种合计 407 相同。第一个表的行变量是肤色，原表头误作“家庭收入”。

采用 χ^2 检验对上述 $R\times C$ 列联表分析任意两因素之间的关系，做法正确吗？混杂因素？

6.1.1 辛普森悖论（Simpson's paradox）

将高维列联表压缩为多个二维列联表进行分析时候，可能会出现奇怪的结果。

给定 C 的情况下，A 与 B 之间存在正相关关系

C_1	B_1	B_2
A_1	60	80
A_2	60	90

$\widehat{\mathrm{OR}}=1.13$

C_2	B_1	B_2
A_1	60	220
A_2	30	120

$\widehat{\mathrm{OR}}=1.09$

C_3	B_1	B_2
A_1	40	170
A_2	60	270

$\widehat{\mathrm{OR}}=1.06$

C_4	B_1	B_2
A_1	40	430
A_2	30	330

$\widehat{\mathrm{OR}}=1.02$

合并 C 的两个类别之后，A 与 B 存在负相关关系

C_1+C_2	B_1	B_2
A_1	120	300
A_2	90	210

$\widehat{\mathrm{OR}}=0.93$

C_3+C_4	B_1	B_2
A_1	80	600
A_2	90	600

$\widehat{\mathrm{OR}}=0.89$

合并 C 的所有类别之后，A 与 B 不存在相关关系

$C_1+C_2+C_3+C_4$	B_1	B_2
A_1	200	900
A_2	180	810

$\widehat{\mathrm{OR}}=1.0$

> **批注** 研究 A 和 B 的关系，C 因素有 4 个层次，分层分析结果显示 A 和 B 正相关。研究 A 和 B 的关系，将 C 因素合并为仅有 2 个层次，分层分析结果变为 A 和 B 负相关。

例 2：癌症数据 生存状态(A)：$A_1=$死亡，$A_2=$存活；治疗方案(B)：$B_1=$常规疗法，$B_2=$新疗法。

重症 C_1

C_1	B_1	B_2	合计
A_1	950	9000	9950
A_2	50	1000	1050
合计	1000	10000	11000

$$P(A_2 \mid B_1) = 0.05, \qquad P(A_2 \mid B_2) = 0.10.$$

非重症 C_2

C_2	B_1	B_2	合计
A_1	5000	5	5005
A_2	5000	95	5095
合计	10000	100	10100

$$P(A_2 \mid B_1) = 0.50, \qquad P(A_2 \mid B_2) = 0.95.$$

合并重症与非重症

$C_1 + C_2$	B_1	B_2	合计
A_1	5950	9005*	14955*
A_2	5050	1095	6145
合计	11000	10100	21100

$$P(A_2 \mid B_1) = 0.46, \qquad P(A_2 \mid B_2) = 0.11.$$

* 原表印作 9050、14995；按 $9000 + 5 = 9005$、$5950 + 9005 = 14955$ 更正（列合计 10100、总计 21100 不变）。新的治疗方案和普通治疗方案均更适合“非重症”的癌症病人。

> **批注** 以及无论对重症还是非重症都是新疗法好。分布不均！主要是重症患者用新疗法，即便新疗法好，本身重症就风险更大。

合并后，似乎新的治疗方案效果较普通治疗方案更差。为什么?

$$\text{对}B_1\text{ 而言，重症: 非重症} = 1000 : 10000,$$

$$\text{对}B_2\text{ 而言，重症: 非重症} = 10000 : 100.$$

两变量间相关关系的大小和方向可能取决于它们与第三个变量间的相关关系——第三个变量为混杂因素。

> **辛普森悖论的模型分析**
>
> 将癌症数据整理为 $2 \times 2 \times 2$ 频数表，分别估计未调整与调整病情时新疗法的存活 OR:

R

```r
ca <- expand.grid(A=c("死亡","存活"), B=c("常规","新"), C=c("重症","非重症"))
ca$n <- c(950,50,9000,1000, 5000,5000,5,95)
w  <- reshape(ca, idvar=c("B","C"), timevar="A", direction="wide")   # 改成宽格式
lc <- glm(cbind(n.存活,n.死亡)~B,   binomial, w)    # 不调整病情
lg <- glm(cbind(n.存活,n.死亡)~B+C, binomial, w)    # 调整病情
exp(coef(lc)["B新"]); exp(coef(lg)["B新"])
ll <- glm(n~A*B + A*C + B*C, poisson, ca)           # 无三阶交互的对数线性模型
coef(ll)[c("A存活:B新","A存活:C非重症")]; coef(lg)[c("B新","C非重症")]
```

```
      B新
0.1432702
    B新
3.38963
    A存活:B新 A存活:C非重症
     1.220721      3.405542
     B新   C非重症
1.220721 3.405542
```

未调整病情时，新疗法存活的 OR 仅为 0.14；调整病情后 OR 为 3.39，即在病情相同的患者中新疗法的效果明显较好。其原因在于新疗法主要用于重症患者（10000:100），而重症患者本身存活率较低。

输出的后两行表明：以生存状态 A 为结局的 logistic 回归 `A~B+C`，与含 AB、AC、BC 三个交互项的对数线性模型给出相同的系数。对数线性模型中 A 与 B 的交互项即 logistic 回归中 B 的对数 OR，BC 项相当于对自变量间的关联不加限制。因此，列联表中有一个变量为结局时，对数线性模型与 logistic 回归等价，后者更为直接；各变量地位相同、关注整体关联结构时，宜采用对数线性模型。

6.1.2 学习要点

1) 什么是高维列联表。
2) 将一个高维列联表转换为多个二维列联表，并对每个二维列联表采用 χ^2 检验进行分析的做法并不总是合适的。
3) 什么是对数线性模型，如何解释模型结果。
4) 分类变量何时可以合并处理，何时不能。

6.2 对数线性模型

对数线性模型（Log-linear model）通常用于分析高维列联表数据。

1) 描述和确定高维列联表中分类变量间的相关关系。
2) 可在不歪曲变量间相关关系的情况下探讨合并列表数据的可能性。

6.2.1 四格表资料的对数线性模型

四格表的频数与概率

	B_1	B_2	合计
A_1	n_{11}	n_{12}	$n_{1\cdot}$
A_2	n_{21}	n_{22}	$n_{2\cdot}$
合计	$n_{\cdot 1}$	$n_{\cdot 2}$	$n_{\cdot\cdot}$

	B_1	B_2	合计
A_1	p_{11}	p_{12}	$p_{1\cdot}$
A_2	p_{21}	p_{22}	$p_{2\cdot}$
合计	$p_{\cdot 1}$	$p_{\cdot 2}$	1

> **批注** n_{ij} 为观察频数，p_{ij} 为格子概率；下标中的“$\cdot$”表示对该下标求和，$n_{i\cdot}$、$p_{i\cdot}$ 为行合计，$n_{\cdot j}$、$p_{\cdot j}$ 为列合计。i 是第一个变量（A）的第 i 个水平，j 是第二个变量（B）的第 j 个水平。

三种抽样方式　同一张四格表可以来自不同的抽样：

- **独立 Poisson 抽样**：观察一段时间，各格频数 $n_{ij} \sim \text{Poisson}(\mu_{ij})$ 相互独立，总数不固定；
- **多项抽样**：固定总样本量 n，每人独立落入 4 个格子之一，各格频数服从多项分布 $\text{Multinomial}(n; p_{11}, \dots, p_{22})$；
- **乘积多项抽样**：固定行合计（如按暴露分组抽样）或列合计（如病例对照），每行（列）内部是独立的多项（二项）分布。

独立 Poisson 频数给定总数后服从多项分布

假设　$N_c \sim \text{Poisson}(\mu_c)$，$c = 1, \dots, C$ 相互独立，$\mu = \sum_c \mu_c$。

关键等式　独立 Poisson 变量之和仍服从 Poisson 分布，$N = \sum_c N_c \sim \text{Poisson}(\mu)$。对 $\sum_c n_c = n$，

$$P(N_1 = n_1, \dots, N_C = n_C \mid N = n) = \frac{\prod_c e^{-\mu_c} \mu_c^{n_c} / n_c!}{e^{-\mu} \mu^n / n!} = \frac{n!}{\prod_c n_c!} \prod_c \Big(\frac{\mu_c}{\mu}\Big)^{n_c}.$$

结论　给定总数后，频数服从多项分布，格子概率 $p_c = \mu_c / \mu$。

解释　Poisson 似然可分解为“总数 N 的 Poisson 似然”乘“给定 N 的多项似然”，且只要模型含常数项 u，前者只与 μ 有关。因此用 Poisson 对数线性模型（含常数项）得到的关联参数估计和拟合优度统计量，与多项抽样下完全相同；乘积多项抽样下，只要模型包含被固定边际对应的项（如固定行合计时含 u_1），结论也相同。这是可以统一用 Poisson GLM 拟合列联表的理由。

对数线性模型的分解　记期望频数 $F_{ij} = np_{ij}$。常见的写法是

$$F_{ij} = np_{ij} = n \frac{p_{i\cdot} p_{\cdot j}}{p_{i\cdot} p_{\cdot j}} p_{ij} = n p_{i\cdot} p_{\cdot j} \frac{p_{ij}}{p_{i\cdot} p_{\cdot j}},$$

$$\ln F_{ij} = \ln n + \ln p_{i\cdot} + \ln p_{\cdot j} + \ln \frac{p_{ij}}{p_{i\cdot} p_{\cdot j}}.$$

这个恒等式说明了 $\ln F_{ij}$ 可分为“样本量、A 的边际、B 的边际、A 与 B 的关联”四部分，但不能直接令 $u_1(i)=\ln p_{i\cdot}$ 等，因为 $\ln p_{i\cdot}$ 之和不为 0（各项都为负），不满足下面的零和约束；$\ln\{p_{ij}/(p_{i\cdot}p_{\cdot j})\}$ 对 i 或 j 求和一般也不为 0。正确的定义是对 $\ln F_{ij}$ 作“均值分解”（类似两因素方差分析）：

$$\begin{aligned}\ln F_{ij} &= u + u_1(i) + u_2(j) + u_{12}(ij),\\ u &= \overline{\ln F}_{\cdot\cdot},\quad u_1(i)=\overline{\ln F}_{i\cdot}-\overline{\ln F}_{\cdot\cdot},\quad u_2(j)=\overline{\ln F}_{\cdot j}-\overline{\ln F}_{\cdot\cdot},\\ u_{12}(ij) &= \ln F_{ij}-\overline{\ln F}_{i\cdot}-\overline{\ln F}_{\cdot j}+\overline{\ln F}_{\cdot\cdot},\end{aligned}$$

其中 $\overline{\ln F}_{i\cdot}$ 为第 i 行 $\ln F_{ij}$ 的算术均数，其余类推。2×2 表中 $u_{12}(11)=\frac{1}{4}\ln\dfrac{F_{11}F_{22}}{F_{12}F_{21}}=\frac{1}{4}\ln \mathrm{OR}$，$u_{12}=0$ 当且仅当 $\mathrm{OR}=1$，即 A 与 B 独立。

> **批注** 理论频数由样本量（常数项）、A 变量、B 变量、A 和 B 交互作用决定。

$$\sum_i u_1(i)=\sum_j u_2(j)=0,\qquad \sum_i u_{12}(i,j)=\sum_j u_{12}(i,j)=0.$$

约束与可识别性　不加约束时，u、$u_1(1),u_1(2)$、$u_2(1),u_2(2)$、$u_{12}(11),\dots,u_{12}(22)$ 共 9 个参数只对应 4 个格子，可以互相加减常数而不改变 F_{ij}，参数不可识别。零和约束（或“参照水平取 0”的约束，软件中更常用）使 u_1、u_2、u_{12} 各只剩 1 个自由参数，加上 u 共 4 个，与 4 个格子一一对应，即饱和模型。约束只是选定一种参数化，不影响拟合值和检验；但参数的数值与约束有关，解释参数时必须先说明用的是哪种约束。在多项抽样下总数 n 固定，u 由 $\sum F_{ij}=n$ 决定，固定总数的四格表只有 3 个自由的概率参数（如 p_{11},p_{12},p_{21}），分别对应 u_1、u_2、u_{12}。

6.2.2 三维列联表的对数线性模型

F_{ijk}：格子 (i,j,k) 的期望频数，其中 $i=1,\dots,r$；$j=1,\dots,c$；$k=1,\dots,l$。（列合计）×（行合计）/总数。

饱和模型（Saturated model）

$$\begin{aligned}\ln F_{ijk} = u &+ u_1(i)+u_2(j)+u_3(k)\\ &+ \underbrace{u_{12}(i,j)+u_{13}(i,k)+u_{23}(j,k)}_{\text{一阶交互作用}} + \underbrace{u_{123}(i,j,k)}_{\text{二阶交互作用}}.\end{aligned}$$

- u：$\ln F_{ijk}$ 的总体均值。
- $u_1(i)$：变量 1 第 i 级的主效应。
- $u_2(j)$：变量 2 第 j 级的主效应。
- $u_3(k)$：变量 3 第 k 级的主效应。

$$\sum_i u_1(i)=\sum_j u_2(j)=\sum_k u_3(k)=0.$$

$u_{12}(i,j)$：变量 1 第 i 级与变量 2 第 j 级的一阶交互效应。类似地，$u_{13}(i,k)$：变量 1 第 i 级与变量 3 第 k 级的一阶交互效应；$u_{23}(j,k)$：变量 2 第 j 级与变量 3 第 k 级的一阶交互效应。

$$\sum_i u_{12}(i,j) = \sum_j u_{12}(i,j) = 0.$$

$u_{123}(i,j,k)$：变量 1 第 i 级与变量 2 第 j 级以及变量 3 第 k 级的二阶交互效应。

$$\sum_i u_{123}(i,j,k) = \sum_j u_{123}(i,j,k) = \sum_k u_{123}(i,j,k) = 0.$$

> **批注** 饱和模型包含所有主效应和各阶交互项，独立参数个数等于列联表的格子数。零和约束：任一交互项对它的任何一个下标求和都等于 0。

注意 对一个三维列联表拟合一个“饱和模型”会产生一系列的理论频数估计值。这些理论频数将会与观测频数完全一致。尽管此时模型完美拟合数据，也毫无意义。

> **批注** 这并非我们的目的。我们的目的是用最少的参数完成模型拟合，有些交互项可能可以删去。

层次模型（Hierarchical models）

> **批注** 嵌套：从饱和模型扣除最高阶交互，进行模型简化。条件独立模型、部分独立模型、互相独立模型。

1. 两两关联模型 如果 $u_{123} = 0$，则提示不存在二阶交互效应。

$$\ln F_{ijk} = u + u_1(i) + u_2(j) + u_3(k) + u_{12}(i,j) + u_{23}(j,k) + u_{13}(i,k).$$

其表明每一对变量均存在相关关系（两两关联模型，homogeneous association model）。

2. 条件独立 如果 $u_{123} = 0$、$u_{12} = 0$、$u_{23} \neq 0$、$u_{13} \neq 0$：

$$\ln F_{ijk} = u + u_1(i) + u_2(j) + u_3(k) + u_{23}(j,k) + u_{13}(i,k).$$

则表明变量 1 和变量 2 条件独立（Conditional Independence）。类似地，$u_{123} = 0, u_{23} = 0$，或 $u_{123} = 0, u_{13} = 0$，均为条件独立。

> **批注** 变量 1 与 3、变量 2 与 3 都可以有关联，但在变量 3 的每一层内，变量 1 与 2 独立，故称“给定变量 3 时条件独立”，记作 $1 \perp 2 \mid 3$。此时把变量 3 合并后，1 与 2 在边际表中一般仍会表现出关联（由它们共同与 3 相关所致）。

层次模型的约束与条件独立、同质关联

假设　三维表的格子概率 $p_{ijk} > 0$，$F_{ijk} = np_{ijk}$。

结论 1　$u_{12} = u_{123} = 0 \iff$ 变量 1 与 2 在给定变量 3 时条件独立，即 $p_{ijk} = p_{i\cdot k}\, p_{\cdot jk} / p_{\cdot\cdot k}$。

推导　(⇐) 若条件独立，取对数 $\ln F_{ijk} = \ln n + \ln p_{i\cdot k} + \ln p_{\cdot jk} - \ln p_{\cdot\cdot k}$，右边是一个只含 (i,k) 的函数加一个只含 (j,k) 的函数，按均值分解后只会产生 $u, u_1, u_2, u_3, u_{13}, u_{23}$ 项，不含 u_{12}、u_{123}。(⇒) 若 $\ln F_{ijk} = a(i,k) + b(j,k)$，则 $F_{ijk} = A_{ik}B_{jk}$，于是在第 k 层

$$P(1=i, 2=j \mid 3=k) = \frac{A_{ik}B_{jk}}{\sum_{i'} A_{i'k} \sum_{j'} B_{j'k}} = \frac{A_{ik}}{\sum_{i'} A_{i'k}} \cdot \frac{B_{jk}}{\sum_{j'} B_{j'k}},$$

层内联合概率可分解为两个边际概率之积，即条件独立。

结论 2　$u_{123} = 0 \iff$ 各层的条件 OR 相同（同质关联）。以 $2 \times 2 \times K$ 表为例，第 k 层的条件对数 OR

$$\ln \mathrm{OR}_{12(k)} = \ln \frac{F_{11k}F_{22k}}{F_{12k}F_{21k}} = 4u_{12}(11) + 4u_{123}(11k),$$

主效应和 u_{13}、u_{23} 在这个交叉比中全部相消。故 $\mathrm{OR}_{12(k)}$ 不随 k 变化 $\iff u_{123}(11k)$ 对所有 k 相同；又 $\sum_k u_{123} = 0$，即 $u_{123} \equiv 0$。

解释　两两关联模型（$u_{123} = 0$）允许每一对变量都有关联，只要求任一对变量的条件 OR 在第三个变量各层相同；它不强制关联存在，某个 u_{12} 是否为 0 要由数据检验。模型从高阶交互项开始逐步删除，并保持层次性：含有某交互项时，必须同时含有它的所有低阶项。

3. 部分独立 如果 $u_{123} = 0$、$u_{12} = u_{13} = 0$、$u_{23} \neq 0$：

$$\ln F_{ijk} = u + u_1(i) + u_2(j) + u_3(k) + u_{23}(j,k).$$

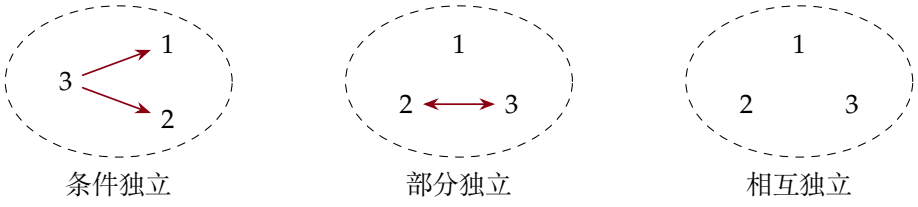
部分独立（Partial independence）。类似地，$u_{123} = 0, u_{12} = u_{23} = 0, u_{13} \neq 0$；$u_{123} = 0, u_{13} = u_{23} = 0, u_{12} \neq 0$。

4. 相互独立 如果 $u_{123} = u_{12} = u_{13} = u_{23} = 0$：

$$\ln F_{ijk} = u + u_1(i) + u_2(j) + u_3(k).$$

相互独立（Mutual independence），或完全独立（Complete independence）。

批注　只有主效应和常数项，没有任何交互作用。



条件独立、部分独立与相互独立

表 2、表 3　对宫颈癌数据拟合所有层次模型的结果

模型	包含效应	df	LR 卡方	P	Pearson 卡方	P
完全独立	u_1, u_2, u_3	12	81.95	< 0.001	91.31	< 0.001
部分独立	u_1, u_{23}	8	46.01	< 0.001	44.62	< 0.001
	u_2, u_{13}	10	53.57	< 0.001	62.19	< 0.001
	u_3, u_{12}	10	65.62	< 0.001	73.45	< 0.001
条件独立	u_{12}, u_{13}	8	37.24	< 0.001	45.75	< 0.001
	u_{12}, u_{23}	6	29.67	< 0.001	29.02	< 0.001
	u_{23}, u_{13}	6	17.62	0.007	17.29	0.008
两两关联模型	u_{12}, u_{13}, u_{23}	4	3.22	0.522	3.15	0.534
饱和模型	u_{123}	0	0	—	0	—

变量 1 为肤色，变量 2 为家庭收入，变量 3 为分娩次数。

- 模型 u_{123}：该模型包含 u_{123} 及其所有下级效应。
- 模型 u_{23}, u_{12}：该模型包含 u_{23}, u_{12} 及其所有下级效应。
- 模型 u_3, u_{12}：该模型包含 u_3, u_{12} 及其所有下级效应。
- 模型 u_1, u_2, u_3：该模型仅包含 u_1, u_2, u_3。

> **批注** LR 卡方是候选模型相对饱和模型的偏差 G^2。饱和模型的独立参数个数等于格子数，所以自由度为 0。G^2 小、$P > 0.05$ 只说明未发现模型与资料有显著偏离，并不证明模型正确。本例只有两两关联模型的 $P > 0.05$（$G^2 = 3.22$，df $= 4$，$P = 0.52$），删去任何一个两因素交互项后拟合都明显变差（如删去 u_{12} 后 G^2 增至 17.62，$\Delta G^2 = 14.40$，Δdf $= 2$），因此选择两两关联模型：肤色、家庭收入、分娩次数两两之间都有关联，且每一对的关联强度不随第三个变量的水平改变。（以上 LR 和 Pearson 统计量已用 R 复算，与表一致。）

$$\text{自由度} = \text{总格子数} - \text{估计值个数}.$$

估计值个数

本例	项（Term）	估计值个数	包含
1	u	1	u
1	u_1	$I - 1$	$u_1(1)$
2	u_2	$J - 1$	$u_2(1), u_2(2)$
2	u_3	$K - 1$	$u_3(1), u_3(2)$
2	u_{12}	$(I-1)(J-1)$	$u_{12}(1,1), u_{12}(1,2)$
2	u_{13}	$(I-1)(K-1)$	$u_{13}(1,1), u_{13}(1,2)$
4	u_{23}	$(J-1)(K-1)$	$u_{23}(1,1), \ldots, u_{23}(2,2)$
4	u_{123}	$(I-1)(J-1)(K-1)$	$u_{123}(1,1,1), \ldots, u_{123}(1,2,2)$
18	合计	IJK	

$i = 1,2$；$j = 1,\ldots,3$；$k = 1,\ldots,3 \Rightarrow I = 2, J = 3, K = 3$；总格子数为 18。

> **批注** i：肤色；j：家庭收入；k：分娩次数（与表 2、表 3 中变量 1、2、3 的编号一致）。

饱和模型：估计参数的个数等于列联表的格子数。不饱和模型：估计参数的个数小于列联表的格子数，又称为退化模型（reduced model）。

> **批注** 自由度 =0，卡方 =0。

上表结果可用 Poisson GLM 复算，`drop1()` 给出由两两关联模型中逐一删除交互项的 ΔG^2 检验：

R

```r
cc <- expand.grid(分娩=c("少","中","多"), 收入=c("低","中","高"), 肤色=c("白人","有色"))
cc$n <- c(67,143,43, 36,78,16, 3,9,12, 77,94,25, 87,70,18, 14,8,14)
m0 <- glm(n~肤色+收入+分娩, poisson, cc)          # 完全独立
m2 <- glm(n~(肤色+收入+分娩)^2, poisson, cc)      # 两两关联
c(deviance(m0), df.residual(m0)); c(deviance(m2), df.residual(m2))
drop1(m2, test="LRT")
```

```
[1] 81.9585 12.0000
[1] 3.218893 4.000000

          Df Deviance    AIC    LRT  Pr(>Chi)
<none>         3.219 124.97
肤色:收入  2   17.620 135.37 14.401 0.0007463 ***
肤色:分娩  2   29.670 147.42 26.451 1.804e-06 ***
收入:分娩  4   37.237 150.99 34.018 7.389e-07 ***
```

删除任一交互项后偏差均显著增大，三对变量之间的关联均不能省略。模型的剩余偏差（3.22）即表中的 LR 卡方。采用 glm 拟合可同时得到参数估计、标准误与残差。

6.2.3 参数估计方法

迭代加权最小二乘法（Iteratively Reweighted Least Squares, IRLS）。基本思想：找到一组参数使得观测值与预测值的差异最小。极大似然估计。

> **批注** 把各格频数看作独立 Poisson 变量写出似然，用 IRLS 求极大似然估计（与第 2 章 Logistic 回归的算法相同，只是分布和连接不同）。每个变量的每个非参照水平都有一个估计值。

两两关联模型的参数估计值（参照水平：白人、中收入、分娩少）

效应	含义	估计值	标准误	Z	P
u	参照格的 $\ln F$	3.660	0.138	26.57	< 0.001
u_1	有色人种	0.773	0.152	5.075	< 0.001
u_2	低收入	0.475	0.157	3.025	0.002
u_2	高收入	−2.121	0.337	−6.292	< 0.001
u_3	分娩中等	0.647	0.158	4.103	< 0.001
u_3	分娩多	−0.829	0.231	−3.589	< 0.001
u_{12}	有色 × 低收入	−0.507	0.153	−3.320	0.001
u_{12}	有色 × 高收入	0.201	0.300	0.670	0.503
u_{13}	有色 × 分娩中等	−0.777	0.160	−4.852	< 0.001
u_{13}	有色 × 分娩多	−0.768	0.223	−3.444	0.001
u_{23}	低收入 × 分娩中等	0.217	0.165	1.315	0.189
u_{23}	高收入 × 分娩中等	−0.149	0.368	−0.404	0.686
u_{23}	低收入 × 分娩多	0.440	0.246	1.788	0.074
u_{23}	高收入 × 分娩多	1.747	0.371	4.703	< 0.001

说明 用 R 复算（`glm(n ~ (肤色 + 收入 + 分娩)^2, family=poisson)`，收入以中收入为参照）后，估计值、标准误与原表一致，但原表有三处需更正：(1) 有色 × 低收入、有色 × 高收入两行的 P 值互换了（$Z=-3.32$ 对应 $P=0.001$，$Z=0.67$ 对应 $P=0.503$）；(2) 原表标为“$u_2(2)u_3(3)$”的 −0.149 实为高收入 × 分娩中等，标为“$u_2(3)u_3(2)$”的 0.44 实为低收入 × 分娩多；(3) 这里采用参照水平约束（参照水平的参数取 0），$u=3.660$ 是参照格（白人、中收入、分娩少）的对数期望频数，不是零和约束下 $\ln F$ 的总均值。交互项的指数是条件 OR，例如 $\exp(-0.777)=0.46$：在同一收入层内，有色人种“分娩中等对分娩少”的优势是白人的 0.46 倍。

6.2.4 拟合优度检验

$$\text{LR chi-square} = 2\sum_{\text{all cells}} O\log\left(\frac{O}{E}\right), \qquad \text{Pearson chi-square} = \sum_{\text{all cells}} \frac{(O-E)^2}{E}.$$

当模型成立时，两个统计量均近似服从 χ^2 分布。如果 $\chi^2 > \chi^2_{\alpha(df)}$ 或者 $P<\alpha$，则拒绝该模型。

由 Poisson 似然推导偏差 G^2

假设　各格频数 O_c 为独立 Poisson 变量，均值 μ_c；候选模型的 MLE 拟合值为 $E_c=\hat\mu_c$。

关键等式　对数似然 $\ell(\boldsymbol\mu)=\sum_c(O_c\ln\mu_c-\mu_c-\ln O_c!)$。饱和模型的 MLE 为 $\hat\mu_c=O_c$。偏差

$$G^2 = 2\{\ell(\mathbf{O})-\ell(\mathbf{E})\} = 2\sum_c\left\{O_c\ln\frac{O_c}{E_c}-(O_c-E_c)\right\}.$$

若模型含常数项 u，常数项的得分方程为 $\sum_c (O_c - E_c) = 0$，线性项整体消去，得 $G^2 = 2\sum_c O_c \ln(O_c/E_c)$（$O_c = 0$ 的格子按 $0 \ln 0 = 0$ 计）。多项、乘积多项抽样下，只要模型含相应的固定边际项，同样成立。

结论　df = 格子数 − 独立参数个数。模型成立、格子数固定且期望频数足够大时，G^2 与 Pearson X^2 都近似服从 χ^2_{df}，两者也很接近。

解释　稀疏表（许多期望频数小于 5、甚至有 0 格）时，χ^2 近似不可靠，G^2 与 X^2 可能相差很大；这时比较嵌套模型的 ΔG^2 通常比单个模型的拟合优度检验更稳健，也可合并稀疏类别或用精确检验。

批注　拟合优度检验的 H_0 是“模型成立”。$P > 0.05$ 只说明证据不足以否定模型，不能证明模型正确；样本很大时，有实际意义很小的偏离也会被判为显著。模型选择应结合嵌套模型的 ΔG^2 与简约原则：本例选 u_{12}, u_{13}, u_{23} 两两关联模型。

6.2.5 残差分析

除卡方检验以外，残差分析也能用于评估模型拟合程度。

$$R_{\mathrm{P}} = \frac{O_{ijk} - E_{ijk}}{\sqrt{E_{ijk}}} \quad \text{(Pearson 残差)}, \qquad R_{\mathrm{adj}} = \frac{O_{ijk} - E_{ijk}}{\sqrt{E_{ijk}(1 - h_{ijk})}} \quad \text{(调整残差)}.$$

Pearson 残差的平方和就是 Pearson X^2。由于 E_{ijk} 是从同一资料估计的，$O - E$ 的方差小于 E，Pearson 残差的方差小于 1，并不服从 $N(0,1)$；除以 $\sqrt{1 - h_{ijk}}$（h_{ijk} 为该格的杠杆值）得到的调整（标准化）残差在模型成立时才近似服从 $N(0,1)$。如果存在调整残差超出 $(-2, 2)$ 的格子，提示该格拟合不好，应进一步检查。

批注　± 2 是筛查界限：格子很多时，即使模型正确，也约有 5% 的格子会超出 ± 2，不能因个别格子超出就否定模型；反过来，残差都在 ± 2 以内也不等于模型正确。残差的意义在于指出偏离出现在哪些格子、方向如何。

下面两表是完全独立模型 (u_1, u_2, u_3) 的期望频数和 Pearson 残差（已用 R 复算；本例两种肤色的合计都是 407，故该模型下两种肤色的期望频数相同）。

期望频数（完全独立模型）

肤色	家庭收入	少（0–1 次）	中等（2–3 次）	多（4 次及以上）
白人	低收入	78.34	110.87	35.3
	中收入	53.21	75.31	23.98
	高收入	10.47	14.82	4.72
有色人种	低收入	78.33	110.87	35.3
	中收入	53.21	75.31	23.98
	高收入	10.47	14.82	4.72

Pearson 残差（完全独立模型）

肤色	家庭收入	少（0–1 次）	中等（2–3 次）	多（4 次及以上）
白人	低收入	−1.3	3.1	1.3
	中收入	−2.4	0.3	−1.6
	高收入	−2.3	−1.5	3.4
有色人种	低收入	−0.2	−1.6	−1.7
	中收入	4.6	−0.6	−1.2
	高收入	1.1	−1.8	4.3

> **批注** 完全独立模型有多个格子的残差超出 ±2（最大 4.6），与它的 $G^2 = 81.96$、$P < 0.001$ 一致，说明完全独立模型不适用。原批注把这些残差当作两两关联模型的残差，结论“两两关联模型不太好”不成立。两两关联模型的结果见下表：调整残差绝对值都不超过 1.5，最小期望频数为 4.66，没有拟合不好的格子。

两两关联模型的期望频数与调整残差

		期望频数			调整残差		
肤色	家庭收入	少	中等	多	少	中等	多
白人	低收入	62.48	148.15	42.37	1.39	−1.50	0.26
	中收入	38.86	74.18	16.96	−0.89	1.15	−0.42
	高收入	4.66	7.67	11.67	−1.08	0.81	0.19
有色人种	低收入	81.52	88.85	25.63	−1.39	1.50	−0.26
	中收入	84.14	73.82	17.04	0.89	−1.15	0.42
	高收入	12.34	9.33	14.33	1.08	−0.81	−0.19

结论 模型“u_{12}, u_{13}, u_{23}”为最佳模型，表明任意两个变量间存在相关关系。

6.2.6 何时可以通过合并数据来简化高维列联表？

OR 可折叠性　对三维表中的变量 X、Y 和第三变量 Z，若各层的条件 OR 相同，且都等于把 Z 合并后的边际 OR，即 $\mathrm{OR}_{XY(k)} = \mathrm{OR}_{XY}$（$k = 1, \ldots, K$），则称 X、Y 的关联关于 Z 可折叠，此时合并 Z 不改变 X 与 Y 的关联。

充分条件　若两两关联模型成立（$u_{123} = 0$），且 Z 与 X、Y 中至少一个条件独立，即 $X \perp Z \mid Y$ 或 $Y \perp Z \mid X$，则 X 与 Y 的关联关于 Z 可折叠。有的资料称“当且仅当第三个变量独立于其中一个或两个时”，“当且仅当”过强：这是充分条件而非必要条件，在个别参数取值下，即使两个条件都不满足，各层 OR 与边际 OR 也可能恰好相等。

$X \perp Z \mid Y$ 时 OR 可折叠

假设　$2 \times 2 \times K$ 表，格子概率 $p_{ijk} > 0$，且 $X \perp Z \mid Y$：$P(Z = k \mid X = i, Y = j) = P(Z = k \mid Y = j) \equiv w_{jk}$。

关键等式　$p_{ijk} = p_{ij\cdot} P(Z = k \mid X = i, Y = j) = p_{ij\cdot} w_{jk}$，于是第 k 层的条件 OR

$$\mathrm{OR}_{XY(k)} = \frac{p_{11k}p_{22k}}{p_{12k}p_{21k}} = \frac{p_{11\cdot}w_{1k} \cdot p_{22\cdot}w_{2k}}{p_{12\cdot}w_{2k} \cdot p_{21\cdot}w_{1k}} = \frac{p_{11\cdot}p_{22\cdot}}{p_{12\cdot}p_{21\cdot}} = \mathrm{OR}_{XY}\,.$$

结论　各层条件 OR 相等，且等于边际 OR，合并 Z 不改变 X 与 Y 的关联。$Y \perp Z \mid X$ 时同理（权重换成 $P(Z = k \mid X = i)$）。

例 1 当变量 1 独立于其他所有变量时（$u_{13} = u_{12} = 0$），则可以完全删除变量 1 来构建列联表。

例 2 当 $u_{12} = u_{123} = 0$ 时，则可以把变量 1 的数据合并，得到变量 2 和变量 3 的二维列联表；且可以把变量 2 的数据合并，得到变量 1 和变量 3 的二维列联表。

> **批注**　这与流行病学中混杂的直观概念相呼应：第三变量要同时与两个变量都有关联，才可能使合并后的关联偏离分层关联；只要它与其中一个（条件）无关，合并就是安全的。但两个概念并不等同：混杂是因果概念，取决于变量间的因果结构；可折叠性只是统计性质。OR 本身还有不可折叠性：即使 Z 与 X 独立（无混杂），只要 Z 与 Y 有关，边际 OR 一般也会比条件 OR 更接近 1（见第 2 章的例子）。

如果 u_{13} 和 u_{23} 都不为 0（例如两两关联模型、饱和模型），合并变量 3 一般会改变变量 1 与 2 的关联，可能歪曲其大小甚至方向（辛普森悖论），此时应在分层或模型中保留变量 3；但这不是必然的，是否改变要比较边际 OR 与条件 OR。存在三因素交互（$u_{123} \neq 0$）时，各层 OR 本身不同，用一个合并后的 OR 概括没有意义，应分层报告。

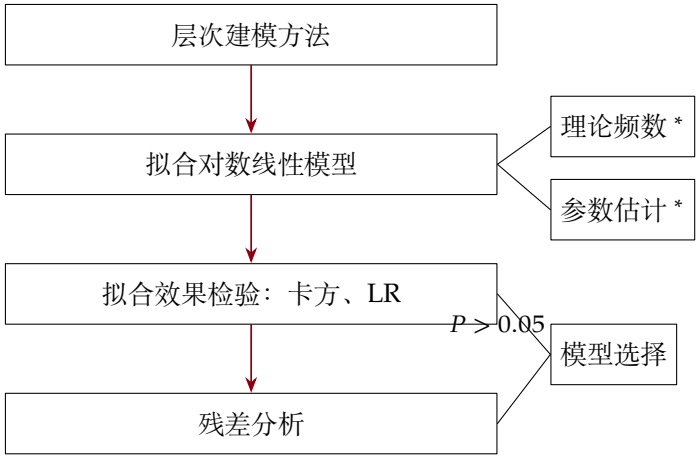
> **批注**　辛普森悖论（例 2 癌症资料）中：在重症和非重症两层内新疗法的存活率都更高（条件关联），合并后反而更低（边际关联），原因是治疗方案与病情严重程度强相关（新疗法多用于重症），而病情又与生存相关，病情在这里是混杂因素，应报告分层或调整后的结果。

对于高维列联表数据，切忌盲目合并某变量的各层数据，切忌对各个压缩的 2×2 列联表重复使用 χ^2 检验。正确的方法是采用对数线性模型进行分析。

> **批注**　最后可以得知哪些因素间存在关联，哪些因素可合并。

6.2.7 对数线性模型的分析步骤

饱和模型、两两关联模型、条件独立模型、部分独立模型、完全独立模型



在 $(-2, 2)$ 范围

对数线性模型的分析步骤

Ref1: Christensen (1997) for a numerical explanation of the iterative computation of estimates.
Ref2: Knoke and Burke, 1980。

模型不足 解释性；独立性；适合的样本量；理论频数的大小：1、20%。

> **批注** 解释性不好，需估计很多项的参数，不够直观，不如 Logistic 的参数直观。样本量要求较大，理论频数不能有小于 1 的，理论频数在 1–5 之间的不能超过 20%。

6.3 案例讨论

现有一批关于孕妇和新生儿的资料，包含四个变量：吸烟与否、怀孕前是否服用某种避孕药、新生儿情况正常与否、孕妇年龄。数据见下表。请分析吸烟和服用某种避孕药与是否有新生儿异常之间的关系。

表 5　5251 例新生儿情况与孕妇吸烟以及服用某种避孕药的关系

年龄（岁）W	吸烟 X	怀孕前服用某避孕药 Y	新生儿正常	新生儿不正常
≤ 29	是	是	204	58
	是	否	330	67
	否	是	1051	210
	否	否	1014	178
30–34	是	是	125	31
	是	否	180	42
	否	是	582	144
	否	否	489	85
≥ 35	是	是	35	20
	是	否	35	10
	否	是	158	53
	否	否	119	31

注：资料摘自李建立、史秉璋，中国卫生统计，1988，5(6)：33。原标题为 “5254 例”，表中各格合计为 5251 例（正常 4322 例、不正常 929 例）；以下全部结果均按表中数据复算，与课程作业评分标准中的拟合结果一致。

1）请采用对数线性模型分析该资料，并探讨变量之间的关系。

2）请问可否采用 Logistic 回归方法分析该资料并回答所提问题?

3）对数线性模型和 Logistic 回归分析方法在解决此问题上有何异同?

4 维列联表（年龄 W 3 个水平、吸烟 X、避孕药 Y、新生儿情况 Z 各 2 个水平），共 $3\times2\times2\times2=24$ 个格子，饱和模型有 24 个独立参数，任何模型的自由度都不超过 $24-1=23$。

对数线性模型的拟合结果表（R 复算）

模型（列出最高阶项）	df	LR 卡方 G^2	P	Pearson 卡方	P	对应的 Logistic 模型
W, X, Y, Z（完全独立）	18	107.05	< 0.001	110.51	< 0.001	—
WXY, Z	11	36.91	< 0.001	39.91	< 0.001	只含截距
WXY, XZ	10	31.49	< 0.001	33.70	< 0.001	X
WXY, YZ	10	27.01	0.003	29.02	0.001	Y
WXY, WZ	9	19.31	0.023	19.85	0.019	W
WXY, WZ, XZ, YZ	7	3.84	0.798	3.85	0.796	$W + X + Y$（选定）
WXY, WZ, XYZ	6	3.64	0.726	3.63	0.727	$W + X \times Y$
WXY, WYZ, XZ	5	2.99	0.701	2.99	0.701	$X + W \times Y$
全部三因素交互	2	2.30	0.317	2.29	0.318	—
$WXYZ$（饱和模型）	0	0	—	0	—	$W \times X \times Y$

说明 原表的自由度为 40、38、36、34、32，超过 24 个格子所能提供的最大自由度 23，G^2 也与表 5 数据不符，无法由本例资料得到，故按复算结果替换。本例关心的是 W、X、Y 对 Z 的作用，解释变量之间的关联（WXY）不是研究问题，故所有候选模型都保留 WXY 项（解释变量的边际取饱和）。从 WXY, Z 起逐步加入与 Z 有关的项：WZ、XZ、YZ 都使 G^2 显著下降；三项同时加入后 $G^2 = 3.84$，$\mathrm{df} = 7$，$P = 0.80$；再加入 XYZ（$\Delta G^2 = 0.20$，$\Delta\mathrm{df} = 1$）或 WYZ（$\Delta G^2 = 0.84$，$\Delta\mathrm{df} = 2$）都无明显改善。故选 WXY, WZ, XZ, YZ：年龄、吸烟、服药各自与新生儿异常有关，且未见交互作用。

6.3.1 变量定义

结局变量（Z）：二分类变量，$Z = 0$（新生儿正常）、$Z = 1$（新生儿不正常）。

自变量：年龄（W），有序分类，$W = 1$（≤ 29 岁）、$W = 2$（30–34 岁）、$W = 3$（≥ 35 岁）。设置为哑变量：以 $W = 1$ 为参照组，生成 $W2, W3$ 两个哑变量。吸烟（X）：二分类，$X = 0$（否）、$X = 1$（是）；避孕药（Y）：二分类，$Y = 0$（否）、$Y = 1$（是）。

Logistic 回归参数估计（分组二项资料，R 复算）

变量	回归系数 β	标准误	Z	P	结论
(Intercept)	−1.791	0.066	−27.04	< 0.001	参照组的基线对数优势
W2（30–34 岁）	0.095	0.080	1.19	0.235	无统计学意义
W3（≥ 35 岁）	0.489	0.119	4.12	< 0.001	有统计学意义
X1（吸烟）	0.227	0.086	2.65	0.008	有统计学意义
Y1（服药）	0.233	0.073	3.17	0.002	有统计学意义

偏差 $D = 3.84$，$\mathrm{df} = 12 - 5 = 7$，$P = 0.80$（12 个协变量组合）。

优势比与实际意义

变量	OR 值	95%CI（下限–上限）	实际意义
W2（30–34 岁）	1.100	0.940–1.286	吸烟、服药情况相同时，与 ≤ 29 岁相比，30–34 岁新生儿异常的优势未见显著差别（CI 包含 1）
W3（≥ 35 岁）	1.631	1.293–2.058	吸烟、服药情况相同时，≥ 35 岁新生儿异常的优势是 ≤ 29 岁的 1.63 倍（增加 63%）
X1（吸烟）	1.254	1.061–1.483	年龄、服药情况相同时，吸烟者新生儿异常的优势是不吸烟者的 1.25 倍
Y1（服药）	1.262	1.093–1.457	年龄、吸烟情况相同时，服药者新生儿异常的优势是不服药者的 1.26 倍

新生儿异常的比例为 929/5251 = 17.7%，不算罕见，OR 不能直接读作“风险增加的百分比”，上表的“增加 63%”指优势而非概率。

包含交互项的 Logistic 回归结果（R 复算）

变量	OR 值（95%CI）	P	结论
W2（30–34 岁）	1.04 (0.82–1.31)	0.770	主效应的含义变为“不服药者中”的年龄效应
W3（≥ 35 岁）	1.47 (1.01–2.12)	0.043	同上
X1（吸烟）	1.21 (0.96–1.53)	0.113	“不服药者中”吸烟的 OR
Y1（服药）	1.17 (0.95–1.44)	0.130	“≤ 29 岁、不吸烟者中”服药的 OR
X1:Y1（吸烟 × 服药）	1.08 (0.77–1.51)	0.660	未见吸烟与服药的交互作用
W2:Y1（30–34 岁 × 服药）	1.12 (0.82–1.53)	0.488	未见年龄与服药的交互作用
W3:Y1（≥ 35 岁 × 服药）	1.20 (0.74–1.93)	0.459	同上

说明　原有的三张 Logistic 结果表（如 X1 系数 0.278、Y1 系数 0.470，X1:Y1 的 OR 1.25、$P = 0.01$，W3:Y1 的 OR 1.50、$P < 0.001$）均无法由表 5 资料得到，按复算结果替换。三个交互项的联合似然比检验 $\chi^2 = 1.04$，$\mathrm{df} = 3$，$P = 0.79$，没有交互作用的证据，应报告不含交互项的模型。含交互项后主效应的含义改变（变为交互变量取参照水平时的效应），不能与无交互项模型的 OR 直接比较。

对数线性模型与 Logistic 模型的对应关系

假设　Z 为二分类结局，解释变量 W, X, Y；对数线性模型包含解释变量的全部交互 WXY（其边际为饱和）。

关键等式　在解释变量取值 $\mathbf{x} = (w, x, y)$ 的格子中，

$$\operatorname{logit} P(Z = 1 \mid \mathbf{x}) = \ln \frac{\mu_{\mathbf{x},1}}{\mu_{\mathbf{x},0}} = \ln \mu_{\mathbf{x},1} - \ln \mu_{\mathbf{x},0}.$$

相减时所有不含 Z 的项（λ、λ^W、λ^X、λ^Y 及 WXY 各项）全部相消，只剩含 Z 的项：λ^Z 成为 Logistic 的截距，λ^{WZ}、λ^{XZ}、λ^{YZ} 成为各自变量的系数，λ^{XYZ} 成为 $X \times Y$ 交互项的系数。

结论　Poisson 似然可分解为“各解释变量组合的总频数 $n_{\mathbf{x}}$”部分与“给定 $n_{\mathbf{x}}$ 时 Z 的条件二项似然”部分。当模型对解释变量的边际取饱和（含 WXY）时，前一部分只与 WXY 等项有关，两部分的参数互不相交，故对数线性模型中含 Z 项的 MLE 及其标准误，与条件二项似然（Logistic 回归）得到的结果完全相同，偏差和自由度也相同。本例 WXY, WZ, XZ, YZ 模型中 $\lambda^{XZ} = 0.227$、$\lambda^{YZ} = 0.233$ 等，与上面 Logistic 回归的系数逐一相等，$G^2 = 3.84$、$\mathrm{df} = 7$ 也与 Logistic 偏差相同。

解释　若对数线性模型没有包含 WXY，两者的估计一般不同，此时对数线性模型对解释变量之间的关联也作了限制。以结局为中心的问题用 Logistic 回归更直接；若所有变量地位平等，关心的是关联结构，则用对数线性模型。

对数线性模型与 Logistic 回归模型的比较

对比维度	对数线性模型	Logistic 回归模型
变量角色	所有变量地位平等，不区分因变量与自变量，聚焦变量间的关联结构	明确区分结局变量（Z，二分类）和自变量（W, X, Y），Z 是因变量，其余为自变量
分析视角	从频数分布出发，分析各变量组合下的单元格频数与变量间交互的关系	从结局风险出发，分析自变量对“新生儿不正常（$Z=1$）”发生概率的影响
模型核心	对单元格期望频数取自然对数，分解主效应和交互效应：$\ln(\mu_{wxyz}) = \lambda + \lambda_w^W + \lambda_x^X + \lambda_y^Y + \lambda_z^Z +$ 交互项	对结局发生的优势取自然对数，构建线性模型：$\ln \dfrac{P(Z=1)}{1-P(Z=1)} = \beta_0 + \beta_1 W + \beta_2 X + \beta_3 Y$
效应量化指标	效应参数（λ），反映频数的对数变化；含 Z 的两因素项取指数即条件 OR	优势比（OR），反映自变量对结局风险的影响程度（流行病学中更易解释）
交互效应分析	可分析任意维度的交互，适合探索变量间的复杂关联结构	自变量的主效应对应对数线性模型中与 Z 的两因素项，自变量之间的交互项（如 $X \times Y$）对应三因素项 XYZ；自变量之间本身的关联（WXY）被条件化，不需要建模
资料要求	适用于列联表汇总数据	个体资料与汇总资料均可：汇总资料以“异常数/总数”作分组二项响应（或以频数作权重），结果与个体资料相同

6.3.2 各自优势

对数线性模型与 Logistic 模型

对数线性模型	Logistic 模型
不区分因变量与自变量	区分因变量和自变量
探索复杂的交互作用	聚焦自变量对结局的影响，验证性
适合高维列联表汇总数据	危险度指标更易理解和直观，OR

两种方法结合使用，先用对数线性模型探索变量间的关联与交互，再用 Logistic 回归模型分析自变量对因变量的作用大小，将对数线性模型分析中发现的重要的交互作用项纳入模型，深入量化风险。

小结

对数线性模型：高维列联表资料、变量间的关系；饱和模型、层次模型；分析步骤：模型构建、参数估计、假设检验、拟合优度、残差分析、模型选择、结果解释、注意事项。

6.4 课后作业

现有一批关于孕妇和新生儿的资料，包含四个变量：吸烟与否、怀孕前是否服用某种避孕药、新生儿情况正常与否、孕妇年龄。数据见表 5。请分析这四个变量之间的关系，并探讨新生儿异常的危险因素。

补充练习（推导与诊断题）

问　对 $2\times 2\times K$ 表（X、Y 二分类，Z 有 K 层），(1) 用对数线性模型如何检验“给定 Z 时 X 与 Y 条件独立”？自由度是多少？(2) 若该检验 $P=0.40$，而把 Z 合并后的 $X\times Y$ 表 χ^2 检验 $P<0.001$，如何解释？

答　(1) 比较模型 (XZ,YZ) 与 (XY,XZ,YZ)，或直接看 (XZ,YZ) 相对饱和模型的 G^2。(XZ,YZ) 的自由度为 $4K-(1+1+1+(K-1)+(K-1)+(K-1))=K$，即每层一个条件对数 OR 为 0 的约束；它等价于 Cochran–Mantel–Haenszel 型的条件独立检验。(2) 分层后 X、Y 无关，合并后却有关，说明 Z 与 X、Y 都有关联（$u_{XZ}\neq 0$、$u_{YZ}\neq 0$），合并时产生了虚假的边际关联（辛普森悖论）。此时不能合并 Z；结论应是“控制 Z 后未见 X 与 Y 有关联”，但 $P=0.40$ 也不能证明条件独立。

6.5 附录：对数线性模型的软件实现

6.5.1 R 语言实现

R

```r
library(MASS)                                          #loglm在MASS包中
model <- loglm(Counts ~ A + B + C, data=data) #无交互项
model <- loglm(Counts ~ A + B + C + A*C + B*C, data=data) #1,3和2,3交互
model <- loglm(Counts ~ (A + B + C)^2, data=data) #两两交互
model <- loglm(Counts ~ A * B * C, data=data) #三项交互
mod1=loglin(data=mydata, margin=list(1,2,3)) #无交互项
mod2=loglin(data=mydata, margin=list(c(1,3),c(2,3))) #1,3和2,3交互
mod3=loglin(data=mydata, margin=list(c(1,2),c(1,3),c(2,3))) #两两交互
mod4=loglin(data=mydata, margin=list(c(1,2,3))) #三项交互
1 - pchisq(mod1$lrt, mod1$df)
```

根据似然比检验 χ^2（lrt）和自由度（df）输出与饱和模型差异性检验的 P 值。也可用 Poisson GLM 拟合，得到参数估计、标准误和残差：`glm(Counts ~ (A+B+C)^2, family=poisson, data=data)`，以 `anova(m1, m2, test="Chisq")` 比较嵌套模型；以宫颈癌资料验证，两两关联模型 $G^2=3.22$，df $=4$。

6.5.2 SPSS 软件实现

Analyze → Loglinear → Model Selection。Options：Display for Saturated Model，Parameter estimates、Association table；Display：Frequencies、Residuals；Model Criteria：Maximum iterations 20、Convergence Default、Delta .5。

Analyze → Loglinear → General。Specify Model：Custom。Build Term(s)：Interaction、Main effects、All 2-way、All 3-way、All 4-way、All 5-way。

6.5.3 SAS 实现

SAS

```
proc catmod;
  weight wt;                /* 频数变量 */
  model r1*r2=_response_;
  loglin r1|r2;             /* 饱和模型；若为独立模型，则 loglin r1 r2; */
run;
```

6.5.4 Stata 实现

Stata 中没有官方内置的 loglinear 模型函数，一般借用 Poisson 模型来实现，具体方法详见参考资料：http://repec.org/usug2015/buis_loglinear_uksug15.pdf。

Stata

```
poisson _freq i.变量1 i.变量2, irr nolog      // 独立模型
poisson _freq i.变量1##i.变量2, irr nolog     // 变量1和变量2的交互项
```

复习题

1) 三维列联表的模型含 u_{12}、u_{13}，不含 u_{23} 和 u_{123}，写出三个变量之间的关系。
   答：给定变量 1 时，变量 2 与变量 3 条件独立。
2) 写出层次模型原则。
   答：模型含某个高阶交互项时，必须包含它所涉及变量的全部低阶项。
3) $2\times3\times3$ 列联表拟合完全独立模型，计算剩余自由度。
   答：格子数 18 减去参数个数 $1+1+2+2=6$，为 12。
4) 解释偏差 $G^2=3.22$、df $=4$、$P=0.52$ 的含义。
   答：未发现该模型与资料有显著偏离，但不能据此证明模型正确；模型选择还应结合嵌套模型的 ΔG^2 与简约原则。
5) 写出可将三维表合并为二维表以分析两个变量关系的条件。
   答：被合并的变量与这两个变量中至少一个条件独立（如模型中无 u_{13} 或无 u_{23}）时，合并不改变二者之间的关联。

第7章

泊松回归与负二项回归

计数资料在公共卫生研究中十分常见，如某地每月发病数、队列中的死亡数、一年内哮喘发作次数、门诊就诊次数等。分析此类资料需考虑以下两点。

一是观察量的大小。死亡数较多，可能是死亡率较高，也可能是观察人数较多或观察时间较长。因此计数模型通常通过 offset 纳入人年数（或人口数），模型描述的是率，系数为率比（IRR）。

二是方差。Poisson 分布要求方差等于均数，而实际资料的方差常大于均数（过离散），原因包括个体易感性不同、事件呈聚集性发生等。此时 Poisson 回归的点估计通常仍可用，但标准误偏小，结论偏于乐观。负二项回归在 Poisson 回归的基础上增加一个离散参数，以反映额外的变异。两个模型的均值结构相同，方差假设不同。

7.1 泊松回归（Poisson Regression）

泊松回归：针对计数资料或列联表资料建模的一种回归分析方法。

- 假设 1：给定协变量 $\mathbf{x}_i$ 时，计数 Y_i 服从泊松分布，且各观察单位相互独立。
- 假设 2：条件均值的对数是协变量的线性组合，$\log \mu_i = \log \mathrm{E}(Y_i \mid \mathbf{x}_i) = \mathbf{x}_i^{\top}\boldsymbol{\beta}$（log 连接）。

> **批注** 连接函数作用于总体条件均值 μ_i，而不是拟合值 $\widehat{Y}$ 或观察值 Y；“$\log(\widehat{Y})$ 由线性组合拟合”的写法混淆了二者，且 $Y = 0$ 时 $\log Y$ 无定义，这也是不能简单地对 $\log Y$ 作线性回归的原因。泊松分布的均数和方差都为 λ；在回归中，“均数等于方差”指的是给定协变量后的条件分布，$\mathrm{Var}(Y_i \mid \mathbf{x}_i) = \mu_i$，而不是全部观察值的总方差等于总均数。

7.1.1 泊松分布（Poisson Distribution）

一种离散概率分布，用于描述固定时间、空间或人群范围内稀有独立事件的发生次数。二项分布的极限形式（当试验次数 $n \to \infty$、$P \to 0$，且均值 $\lambda = nP$ 恒定）。核心关注“事件发生的次数”，而非“单次试验的成败”。

泊松分布的概率函数：

$$P(Y = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \qquad k = 0, 1, 2, \ldots.$$

均值与方差相等（若方差远大于均值，存在过离散）；事件独立性；稀有事件假设。

> **批注** k 是发生次数。三个量要区分：计数 Y（随机变量，取非负整数）；条件均值 $\mu = \mathrm{E}(Y \mid \mathbf{x})$（期望发生数）；发生率 $r = \mu/t$（单位观察时间或单位人群的期望发生数，如每千人年死亡数）。发生率不是概率，可以大于 1。

医学中的例子 罕见遗传病的出生数：某地区每年新生儿中苯丙酮尿症（PKU）、先天性聋哑等罕见遗传病的病例数；癌症的年发病数；药物不良反应的报告数；某地区每月的食物中毒事件数。

7.1.2 例题：职业暴露

一项回顾性队列研究，收集了湖北省某工厂 1966 年 8 月 18 日至 1991 年 12 月 31 日全部工人（共 9572 人）的有关信息，欲研究职业暴露与死亡情况的关系。该项研究总的观察人年数为 114488 人年，共有 159 名工人发生死亡结局。研究目的：推断职业暴露和年龄是否为死亡率的影响因素。

> **批注** 罕见事件。

表 4　湖北省某工厂全死因死亡情况（死亡率单位：每千人年）

年龄组（岁）	非暴露组			暴露组		
	死亡数	人年数	死亡率	死亡数	人年数	死亡率
< 40	39	59141	0.659	30	34995	0.857
40–49	14	6621	2.114	33	9241	3.571
50–59	3	650	4.615	25	3115	8.026
60–69	0	54	0	12	595	20.168
≥ 70	0	9	0	3	67	44.776

Data from Yu Z and Yu S, et al., Chinese Health Statistics, 1996;13(1):6.

假设不同个体间死亡的发生是相互独立的，则死亡数将服从泊松分布。泊松回归借助对数线性模型在泊松分布的前提假设下，分析结局发生数量及结局发生率与协变量之间的关联。

$$\ln r_{ij} = \ln \frac{\mu_{ij}}{n_{ij}} = \lambda + \lambda_i^X + \lambda_j^Y.$$

λ 为常数项；λ_i^X 表示变量 X 第 i 个水平效应值的大小；λ_j^Y 表示变量 Y 第 j 个水平效应值的大小；μ_{ij} 为 $X = i, Y = j$ 时死亡数的期望频数；n_{ij} 为观察人年数；$r_{ij} = \mu_{ij}/n_{ij}$ 为死亡率（有的资料记作 P_{ij}，但它是发生率而非概率）。

$$\ln \mu_{ij} = \lambda + \lambda_i^X + \lambda_j^Y + \underbrace{\ln n_{ij}}_{\text{偏移量（offset）}}.$$

offset 的来历与率比的解释

假设　第 i 个观察单位（个体或一组人）的观察时间（人年）为 $t_i > 0$，在观察期内事件发生率恒为 r_i，$\ln r_i = \mathbf{x}_i^\top \boldsymbol{\beta}$；事件数 $Y_i \sim \text{Poisson}(\mu_i)$，$\mu_i = t_i r_i$。

关键等式

$$\ln \mu_i = \ln t_i + \ln r_i = \ln t_i + \mathbf{x}_i^\top \boldsymbol{\beta}.$$

$\ln t_i$ 是已知量，作为线性预测量中系数固定为 1 的项进入模型，即偏移量（offset），不需要估计。

结论　(1) 系数解释为率比：其他协变量不变，x_j 增加 1 单位，r 乘以 e^{β_j}，即 RR $= e^{\beta_j}$（rate ratio，或称 IRR）。(2) 时间单位改变（如人年改为千人年，$t_i' = t_i/c$）只改变截距：$\beta_0' = \beta_0 + \ln c$，其余系数不变。本例截距为 -7.390（每人年），换算为每千人年是 $-7.390 + \ln 1000 = -0.483$。(3) 若把 $\ln t_i$ 当作普通协变量估计系数，就是在检验“事件数与观察时间成正比”这一假设；系数应接近 1，本例约为 1.29（只有 10 个格子，估计很不精确）。

解释　offset 使不同观察时间、不同人数的单位可以比较：模型描述的是率而不是计数。若不加 offset 而直接对死亡数建模，暴露组人年较多本身就会使死亡数较多，系数混入了人年差异。

批注　本例关心职业暴露的作用，同时把年龄作为协变量加以调整（各年龄组的人年构成在两组间不同）。

$$P(Y = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \qquad \lambda_i = \exp(X_i \beta).$$

据此可以写出似然函数、对数似然函数，采用极大似然估计方法估计模型参数。

批注　未知的是系数 $\boldsymbol{\beta}$；估计步骤（写似然、求得分方程、IRLS 迭代）与 Logistic 回归相同，只是 Y 的分布和连接函数不同。

表 5　泊松回归模型的拟合优度检验结果

Model	df	G^2	P-value	Pearson χ^2	P-value
λ	9	167.034	< 0.001	409.636	< 0.001
$\lambda + \lambda_i^X$	5	7.810	0.167	6.269	0.281
$\lambda + \lambda_j^Y$	8	133.450	< 0.001	258.986	< 0.001
$\lambda + \lambda_i^X + \lambda_j^Y$	4	2.475	0.649	1.542	0.819
$\lambda + \lambda_i^X + \lambda_j^Y + \lambda_{ij}^{XY}$	0	0		0	

R 复算（`glm(y ~ ..., family=poisson, offset=log(人年))`）。原表的 G^2 为 167.607、7.862、133.976、2.493，比复算值大 0.02–0.57，原因不明（可能是所用软件对 0 格的处理或人年数的舍入不同）；Pearson χ^2 与原表一致，结论不变。

其中 X 和 Y 分别表示年龄和职业暴露。

$$\Delta G^2 = 7.810 - 2.475 = 5.335, \qquad \Delta df = 5 - 4 = 1, \qquad P = 0.021.$$

（原表为 $7.8617 - 2.4927 = 5.3690$，$P = 0.0205$。）

批注　第一行是只含常数项的模型（各格死亡率相同），最后一行是饱和模型。G^2 检验的 H_0 是“模型成立”，$P > 0.05$ 只说明未发现模型与资料有显著偏离。年龄 + 暴露模型 $G^2 = 2.48$，df $= 4$，$P = 0.65$，可以接受，说明在对数尺度上年龄与暴露的作用可相加（未见年龄与暴露的交互作用）。只含年龄的模型与年龄 + 暴露模型嵌套，$\Delta G^2 = 5.34 > 3.84$，说明调整年龄后，职业暴露对死亡率的作用有统计学意义。本例有两个格子的死亡数为 0、期望数小于 1，χ^2 近似只是粗略的。

参数解释

$$\ln r = \beta_0 + \beta_1 \text{expose} + \beta_2 \text{age4} + \beta_3 \text{age5} + \beta_4 \text{age6} + \beta_5 \text{age7}.$$

$$\mathrm{RR} = \frac{r_{i2}}{r_{i1}} = \frac{\exp(\lambda + \lambda_i^X + \lambda_2^Y)}{\exp(\lambda + \lambda_i^X + \lambda_1^Y)} = \exp(\lambda_2^Y - \lambda_1^Y).$$

> **批注**　年龄分为 5 组，以 <40 岁为参照组，age4–age7 依次为 40–49、50–59、60–69、≥ 70 岁的哑变量。RR $= \exp(\beta)$ 是死亡率之比（率比），同一年龄组内比较暴露组与非暴露组。

表 6　回归系数及 RR 估计值

变量	参数	估计值 $\hat\beta$	SE($\hat\beta$)	Wald χ^2	P-value	RR (95%CI)
expose	β_1	0.409	0.179	5.230	0.022	1.50 (1.06, 2.14)
age4	β_2	1.311	0.193	46.293	<0.001	3.71 (2.54, 5.41)
age5	β_3	2.140	0.236	82.523	<0.001	8.50 (5.36, 13.49)
age6	β_4	3.020	0.324	86.882	<0.001	20.48 (10.85, 38.65)
age7	β_5	3.790	0.595	40.556	<0.001	44.26 (13.79, 142.12)

> **说明**　原表 6 的估计值依次为 0.35、1.17、1.90、3.40、4.10，RR 为 1.42、3.22、6.69、29.96、60.34，与同表的标准误、Wald χ^2 不相容（如 $(0.35/0.179)^2 = 3.82 \neq 5.230$），区间也不是 $e^{\hat\beta \pm 1.96\,\mathrm{SE}}$。用 R 对表 4 资料拟合年龄 + 暴露模型，标准误、Wald χ^2 与原表完全相同，表 7 的预测死亡率与标准化残差也逐一相同，可见原表只有估计值、RR 和区间一列有误，按复算值更正。解释：调整年龄后，暴露组的死亡率是非暴露组的 1.50 倍（95%CI 1.06–2.14）；死亡率随年龄组升高而急剧增加。

表 7　死亡率预测值（每千人年）及残差

年龄组（岁）	非暴露组			暴露组		
	观测值	预测值	标准化残差	观测值	预测值	标准化残差
<40	0.659	0.617	0.887	0.857	0.929	−0.909
40–49	2.114	2.29	−0.448	3.571	3.445	0.439
50–59	4.615	5.246	−0.254	8.026	7.894	0.248
60–69	0	12.641	−1.216	20.168	19.021	0.851
≥ 70	0	27.319	−0.735	44.776	41.106	0.512

> **批注**　表中残差为标准化偏差残差（偏差残差除以 $\sqrt{1-h}$，已用 R 复算）。表头单位原印作“‰”，应为每千人年。残差都在 ± 2 以内，未见拟合不好的格子；但格子只有 10 个、部分格子期望死亡数小于 1，残差检查的能力有限。

表 5 至表 7 的结果可由以下代码得到，人年数通过 `offset=log(py)` 进入模型：

R

```r
oc <- data.frame(age=factor(rep(c("<40","40-49","50-59","60-69",">=70"),2),
                            levels=c("<40","40-49","50-59","60-69",">=70")),
                 expose=rep(0:1,each=5), d=c(39,14,3,0,0, 30,33,25,12,3),
                 py=c(59141,6621,650,54,9, 34995,9241,3115,595,67))
fit <- glm(d~expose+age, family=poisson, offset=log(py), data=oc)
round(summary(fit)$coefficients,3)
exp(cbind(IRR=coef(fit), confint.default(fit)))["expose",]   # 调整年龄后的率比
```

R（续）

```r
c(deviance(fit), df.residual(fit))                                  # G^2与自由度
fit0 <- glm(d~expose, family=poisson, offset=log(py), data=oc)
exp(coef(fit0)["expose"])                                           # 不调整年龄
```

```
            Estimate Std. Error z value Pr(>|z|)
(Intercept)   -7.390      0.147 -50.315    0.000
expose         0.409      0.179   2.287    0.022
age40-49       1.311      0.193   6.804    0.000
age50-59       2.140      0.236   9.084    0.000
age60-69       3.020      0.324   9.321    0.000
age>=70        3.790      0.595   6.368    0.000
   IRR  2.5 % 97.5 %
 1.505  1.060  2.136
[1] 2.474513 4.000000
  expose
2.546529
```

粗率比与调整率比

未考虑年龄时，暴露组死亡率为非暴露组的 2.55 倍；调整年龄后为 1.50 倍。由表 4 的人年构成可知：非暴露组 86% 的人年集中在 40 岁以下（59141/66475），暴露组仅为 73%（34995/48013），暴露组中老年人的比例较高，而死亡率随年龄增长急剧上升。因此粗率比中有相当一部分来自两组年龄构成的差异。

这一问题与流行病学中的率的标准化相同。直接标准化法以共同的年龄构成重新加权；Poisson 回归则假定暴露的率比在各年龄组相同（模型不含交互项，$G^2 = 2.47$ 支持这一假定），利用全部资料估计共同的率比。两种方法估计的均为年龄构成相同时两组死亡率之比。

7.1.3 案例分析

案例介绍

Severe COVID-19 outcomes after full vaccination of primary schedule and initial boosters: pooled analysis of national prospective cohort studies of 30 million individuals in England, Northern Ireland, Scotland, and Wales。

Lancet. 2022 Oct 15;400(10360):1305–1320. doi:10.1016/S0140-6736(22)01656-7。

标题：全面接种初次疫苗和初始加强疫苗后的严重 COVID-19 结局：对英格兰、北爱尔兰、苏格兰和威尔士 3000 万人的全国前瞻性队列研究的汇总分析。

目的：在完成了 COVID-19 初次疫苗接种计划并接受了初始加强疫苗的人中确定严重 COVID-19 结局的风险因素。

研究设计

前瞻性队列研究。本文根据 Reporting of Studies Conducted using Observational Routinely-collected Data（RECORD）和 Strengthening the Reporting of Observational Studies in Epidemiology（STROBE）清单对各条目内容进行透明报告。

Table S2: STROBE and RECORD checklists

	Item No.	STROBE items	RECORD items	Location in manuscript where items are reported
Title and abstract				
Title and abstract	1	(a) Indicate the study's design with a commonly used term in the title or the abstract. (b) Provide in the abstract an informative and balanced summary of what was done and what was found.	RECORD 1.1: The type of data used should be specified in the title or abstract. When possible, the name of the databases used should be included. RECORD 1.2: If applicable, the geographic region and timeframe within which the study took place should be reported in the title or abstract. RECORD 1.3: If linkage between databases was conducted for the study, this should be clearly stated in the title or abstract.	p. 1–4
Introduction				
Background rationale	2	Explain the scientific background and rationale for the investigation being reported.		p. 5–6
Objectives	3	State specific objectives, including any prespecified hypotheses.		p. 5–6
Methods				
Study Design	4	Present key elements of study design early in the paper.		p. 6–7
Setting	5	Describe the setting, locations, and relevant dates, including periods of recruitment, exposure, follow-up, and data collection.		p. 6–10

	Item No.	STROBE items	RECORD items	Location in manuscript where items are reported
Participants	6	(a) Cohort study – Give the eligibility criteria, and the sources and methods of selection of participants. Describe methods of follow-up. Case-control study – Give the eligibility criteria, and the sources and methods of case ascertainment and control selection. Give the rationale for the choice of cases and controls.	RECORD 6.1: The methods of study population selection (such as codes or algorithms used to identify subjects) should be listed in detail. If this is not possible, an explanation should be provided. RECORD 6.2: Any validation studies of the codes or algorithms used to select the population should be referenced. If validation was conducted for this study and ...	p. 6–9
Results				
Participants	13	(a) Report the numbers of individuals at each stage of the study (e.g., numbers potentially eligible, examined for eligibility, confirmed eligible, included in the study, completing follow-up, and analysed). (b) Give reasons for non-participation at each stage. (c) Consider use of a flow diagram.	RECORD 13.1: Describe in detail the selection of the persons included in the study (i.e., study population selection) including filtering based on data quality, data availability and linkage. The selection of included persons can be described in the text and/or by means of the study flow diagram.	p. 10–11
Descriptive data	14	(a) Give characteristics of study participants (e.g., demographic, clinical, social) and information on exposures and potential confounders. (b) Indicate the number of participants with missing data for each variable of interest. (c) Cohort study – summarise follow-up time (e.g., average and total amount) ...		p. 10–11

	Item No.	STROBE items	RECORD items	Location in manuscript where items are reported
Discussion				
Key results	18	Summarise key results with reference to study objectives.		p. 11–14
Limitations	19	Discuss limitations of the study, taking into account sources of potential bias or ...	RECORD 19.1: Discuss the implications of using data that were not created or collected to answer the specific research question(s). Include discussion of ...	p. 12
Other Information				
Funding	22	Give the source of funding and the role of the funders for the present study and, if applicable, for the original study on which the present article is based.		p. 3410,14,15
Accessibility of protocol, raw data, and programming code	..	..	RECORD 22.1: Authors should provide information on how to access any supplemental information such as the study protocol, raw data, or programming code.	p. 14–15

数据来源 融合四个国家的全国医疗保健、RT-PCR 检测、疫苗接种、住院和死亡数据，构建了 3000 万人的前瞻性队列。在各国独立完成伦理审批。

研究对象 纳入：在 2020 年 12 月 8 日至 2022 年 2 月 28 日期间完成了初级疫苗接种计划（两针 BNT162b2 或 ChAdOx1 nCoV-19 疫苗），或后续进行了加强接种（BNT162b2 或 mRNA-1273 疫苗）的 18 岁及以上的个体。随访至：出现与 COVID-19 相关的住院、死亡结局，或研究结束。

分析计划 研究团队在开始进行分析之前，制定了一份统计分析计划，并发布在 EAVE II 网站上：Protocol: Common protocol for validation of the QCOVID algorithm across the four UK nations。

数据特点

结局变量

- 主要结局：Omicron 在 2021 年 12 月 14 日之后占据主导地位。研究结局为纳入对象在 2021 年 12 月 20 日至 2022 年 2 月 28 日之间发生严重 COVID-19 结局事件。即在完成初级疫苗接种或加强接种后的 14 天及以上的时间发生与 COVID-19 相关的住院或死亡。

- 与 COVID-19 相关的住院：在入院前 14 天内 SARS-CoV-2 RT-PCR 检测呈阳性并因任何入院原因，或 COVID-19 不是入院原因但在入院期间 SARS-CoV-2 RT-PCR 检测结果呈阳性。
- 与 COVID-19 相关的死亡：在 SARS-CoV-2 RT-PCR 检测呈阳性后的 28 天内因任何原因死亡，或者在死亡证明上 COVID-19 被记录为死亡的主要原因。

人口特征和协变量

- 年龄、性别、种族、BMI、居住地（城市或农村）。
- 医疗保健行政区域、社会经济状况。
- 首次接种疫苗前的 SARS-CoV-2 感染情况（接种疫苗前 $<$ 3 个月、3–5 个月、6–8 个月和 $\geq$ 9 个月）。
- 是否属于高危职业人群（根据既往 RT-PCR 检测次数定义，0、1、2、3–4、5–9 和 $>$ 10 次测试）。
- 第一次和第二次疫苗接种之间的间隔（3–6 周、7–8 周、9–10 周、11–12 周和 $>$ 13 周）。
- 先前已知与严重 COVID-19 结局相关的既有合并症的个数。

方法应用

描述性分析 针对所有人口统计和临床因素，对于“完成初级疫苗接种计划”及“后续也完成加强接种”两种人群，分别计算了每 1000 人年中严重 COVID-19 结局的发生率。

广义线性模型：泊松回归 得到各人口统计学和临床因素与 COVID-19 相关住院或死亡之间关联的 RR 及 95%CI。

荟萃分析 由于数据治理安排不允许在四个国家的数据存储之间共享个人层面的数据，因此本研究首先在每个国家单独进行分析，然后使用 Meta 分析——固定效应模型进行汇总分析。统计软件：R。

结果及解释

描述性分析：“完成初级疫苗接种计划”人群

Table 1　Both vaccines

Characteristic	Total vaccination, *n* (%)	Severe COVID-19 outcome, *n* (rate)
Urban-rural index		
Urban	12512340 (77.2%)	48140 (9.4)
Rural	3677090 (22.7%)	11340 (6.9)
Unknown	19150 (0.1%)	40 (3.0)
Interval between primary vaccine doses		
3–6 weeks	860170 (5.3%)	4030 (9.9)
7–8 weeks	3349850 (20.7%)	5820 (4.5)
9–10 weeks	5431620 (33.5%)	20080 (7.7)
11–12 weeks	5762820 (35.6%)	25460 (11.7)
≥13 weeks	804150 (5.0%)	4070 (14.2)
Number of previous RT-PCR tests		
0	13491070 (83.2%)	52490 (9.7)
1	1266650 (7.8%)	2430 (3.6)
2	821850 (5.1%)	1610 (4.2)
3–4	366830 (2.3%)	1340 (7.2)
5–9	125180 (0.8%)	960 (13.8)
≥10	137010 (0.8%)	680 (9.4)
History of SARS-CoV-2 infection		
No previous infection	15745170 (97.1%)	58920 (9.0)
<3 months	158740 (1.0%)	210 (3.0)
3–5 months	124400 (0.8%)	260 (4.1)
6–8 months	105030 (0.6%)	100 (1.8)
≥9 months	75250 (0.5%)	60 (1.8)

Table 1　ChAdOx1 nCoV-19

Characteristic	Total vaccination, *n* (%)	Severe COVID-19 outcome, *n* (rate)
Urban-rural index		
Urban	6517020 (75.6%)	28640 (10.7)
Rural	2093160 (24.3%)	6880 (7.5)
Unknown	9330 (0.1%)	20 (4.3)
Interval between primary vaccine doses		
3–6 weeks	137770 (1.6%)	840 (14.2)
7–8 weeks	1094000 (12.7%)	3280 (7.3)
9–10 weeks	3141610 (36.4%)	12410 (8.4)
11–12 weeks	3879580 (45.0%)	16380 (11.3)
≥13 weeks	366570 (4.3%)	2590 (17.5)
Number of previous RT-PCR tests		
0	7331710 (85.1%)	30730 (10.5)
1	644330 (7.5%)	1760 (5.0)
2	376790 (4.4%)	1090 (6.1)
3–4	173590 (2.0%)	920 (10.6)
5–9	59110 (0.7%)	640 (21.2)
≥10	33980 (0.4%)	410 (24.7)
History of SARS-CoV-2 infection		
No previous infection	8406910 (97.5%)	35170 (10.1)
<3 months	64310 (0.7%)	120 (4.1)
3–5 months	76610 (0.9%)	200 (5.4)
6–8 months	46120 (0.5%)	60 (2.4)
≥9 months	25550 (0.3%)	20 (1.9)

Table 1　BNT162b2

Characteristic	Total vaccination, *n* (%)	Severe COVID-19 outcome, *n* (rate)
Urban-rural index		
Urban	5995320 (79.0%)	19500 (8.0)
Rural	1583930 (20.9%)	4460 (6.1)
Unknown	9820 (0.1%)	10 (2.0)
Interval between primary vaccine doses		
3–6 weeks	722400 (9.5%)	3190 (9.1)
7–8 weeks	2255850 (29.7%)	2550 (3.1)
9–10 weeks	2290010 (30.2%)	7670 (6.7)
11–12 weeks	1883240 (24.8%)	9080 (12.4)
≥13 weeks	437580 (5.8%)	1480 (10.7)
Number of previous RT-PCR tests		
0	6159360 (81.2%)	21760 (8.8)
1	622320 (8.2%)	670 (2.0)
2	445060 (5.9%)	520 (2.6)
3–4	193240 (2.5%)	420 (4.2)
5–9	66080 (0.9%)	320 (8.2)
≥10	103030 (1.4%)	260 (4.8)
History of SARS-CoV-2 infection		
No previous infection	7338260 (96.7%)	23750 (7.7)
<3 months	94430 (1.2%)	90 (2.2)
3–5 months	47790 (0.6%)	60 (2.3)
6–8 months	58910 (0.8%)	40 (1.3)
≥9 months	49700 (0.7%)	40 (1.7)

Rates are per 1000 person-years. *England and Wales. †England, Scotland, and Wales. ‡Northern Ireland only.

Combined sample characteristics and rates of severe COVID-19 outcomes for individuals who received primary vaccine doses across England (N = 11.4 million), Northern Ireland (N = 40 000), Scotland (N = 3.1 million), and Wales (N = 1.6 million).

在 2020 年 12 月 8 日至 2022 年 2 月 28 日期间，共 16208600 名 18 岁及以上的人完成 COVID-19 初级疫苗接种计划并被随访，有 59510 人（0.4%）出现了严重 COVID-19 结局。在完成初级疫苗接种的人群中，与接种 BNT162b2 疫苗（7589080 人，发生率 7.5/1000 人年）的个体相比，接种 ChAdOx1 nCoV-19 疫苗（8619520 人，发生率 9.9/1000 人年）的个体的严重 COVID-19 结局发生率更高。针对各人口统计和临床因素的严重 COVID-19 结局发生率的信息如表所示。

描述性分析：“后续也完成加强接种”人群

Table 2　Both vaccines

Characteristic	Total vaccination, *n* (%)	Severe COVID-19 outcome, *n* (rate)
Number of risk groups by British National Formulary chapters		
0	8690 (36.1%)	90 (1.7)
1	4390 (18.2%)	80 (2.7)
2	3440 (14.3%)	150 (6.0)
3	2680 (11.1%)	160 (8.5)
4	1960 (8.1%)	170 (12.4)
5	1340 (5.6%)	180 (20.9)
≥6	1590 (6.6%)	280 (29.5)
Urban-rural index		
Urban	10519740 (76.0%)	20590 (7.9)
Rural	3301040 (23.9%)	5490 (6.5)
Unknown	15620 (0.1%)	30 (7.7)
Interval between primary vaccine doses		
3–6 weeks	737470 (5.3%)	1670 (9.3)
7–8 weeks	2744850 (19.8%)	2500 (4.2)
9–10 weeks	4824110 (34.9%)	9540 (7.3)
11–12 weeks	5147600 (37.2%)	11080 (8.6)
≥13 weeks	382380 (2.8%)	1160 (14.5)
Number of previous RT-PCR tests		
0	11642910 (84.1%)	22410 (7.7)
1	1046660 (7.6%)	1110 (4.6)
2	637420 (4.6%)	770 (5.1)
3–4	290460 (2.1%)	710 (10.6)
5–9	102110 (0.7%)	510 (18.9)
≥10	116830 (0.8%)	410 (12.6)
Previous history of SARS-CoV-2 infection		
No prior infection	13474880 (97.4%)	25820 (7.7)
<3 months	122150 (0.9%)	110 (4.3)
3–5 months	100480 (0.7%)	120 (4.7)
6–8 months	80580 (0.6%)	60 (3.6)
≥9 months	58310 (0.4%)	50 (4.1)

Table 2　mRNA-1273

Characteristic	Total vaccination, *n* (%)	Severe COVID-19 outcome, *n* (rate)
Number of risk groups by British National Formulary chapters		
0	2820 (37.4%)	20 (1.4)
1	1440 (19.1%)	20 (2.2)
2	1140 (15.1%)	20 (2.6)
3	830 (11.0%)	40 (7.0)
4	560 (7.4%)	30 (7.7)
5	350 (4.7%)	30 (14.3)
≥6	410 (5.4%)	50 (23.6)
Urban-rural index		
Urban	2662240 (78.4%)	1840 (3.0)
Rural	729930 (21.5%)	520 (2.9)
Unknown	4400 (0.1%)	10 (7.8)
Interval between primary vaccine doses		
3–6 weeks	92600 (2.7%)	50 (2.5)
7–8 weeks	816770 (24.0%)	340 (2.0)
9–10 weeks	1128170 (33.2%)	810 (2.9)
11–12 weeks	1252880 (36.9%)	1000 (3.4)
≥13 weeks	106150 (3.1%)	160 (7.7)
Number of previous RT-PCR tests		
0	2732530 (80.4%)	1800 (2.8)
1	340690 (10.0%)	190 (2.8)
2	193230 (5.7%)	130 (3.1)
3–4	86710 (2.6%)	110 (6.3)
5–9	25110 (0.7%)	80 (16.1)
≥10	18300 (0.5%)	40 (11.5)
Previous history of SARS-CoV-2 infection		
No prior infection	3280550 (96.6%)	2320 (3.0)
<3 months	34710 (1.0%)	20 (3.0)
3–5 months	31760 (0.9%)	20 (2.7)
6–8 months	33080 (1.0%)	20 (2.8)
≥9 months	16470 (0.5%)	10 (4.5)

Table 2　BNT162b2

Characteristic	Total vaccination, *n* (%)	Severe COVID-19 outcome, *n* (rate)
Number of risk groups by British National Formulary chapters		
0	5870 (35.5%)	70 (1.8)
1	2950 (17.8%)	60 (2.9)
2	2300 (13.9%)	130 (7.5)
3	1850 (11.2%)	130 (9.0)
4	1400 (8.5%)	140 (14.1)
5	990 (6.0%)	150 (23.2)
≥6	1190 (7.2%)	220 (31.4)
Urban-rural index		
Urban	7857490 (75.3%)	18750 (9.4)
Rural	2571110 (24.6%)	4970 (7.5)
Unknown	11220 (0.1%)	20 (7.6)
Interval between primary vaccine doses		
3–6 weeks	644860 (6.2%)	1620 (10.2)
7–8 weeks	1928080 (18.5%)	2170 (5.0)
9–10 weeks	3695940 (35.4%)	8730 (8.6)
11–12 weeks	3894720 (37.3%)	10070 (10.2)
≥13 weeks	276230 (2.6%)	1000 (16.8)
Number of previous RT-PCR tests		
0	8910380 (85.3%)	20610 (9.1)
1	705970 (6.8%)	920 (5.4)
2	444190 (4.3%)	640 (5.9)
3–4	203750 (2.0%)	610 (12.0)
5–9	77000 (0.7%)	430 (19.5)
≥10	98530 (0.9%)	370 (12.7)
Previous history of SARS-CoV-2 infection		
No prior infection	10194330 (97.6%)	23500 (9.0)
<3 months	87440 (0.8%)	90 (4.8)
3–5 months	68720 (0.7%)	100 (5.5)
6–8 months	47500 (0.5%)	40 (4.1)
≥9 months	41840 (0.4%)	40 (4.0)

Rates are per 1000 person-years. *England and Wales. †England, Scotland, and Wales. ‡Northern Ireland only.

Combined sample characteristics and rates of severe COVID-19 outcomes for individuals who received a booster dose, across England (N = 9.7 million), Northern Ireland (N = 24 000), Scotland (N = 2.7 million), and Wales (N = 1.4 million).

完成了疫苗初级接种计划加一剂加强针的人群的一系列样本特征（行）和严重 COVID-19 结局的发生率（列）。此外，也对加强针是 mRNA-1273 或 BNT162b2 的人群分别进行统计描述。

泊松回归与荟萃分析 “后续也完成加强接种”人群中，多种人口学及临床特征与严重 COVID-19 结局的关联：aRRs（95%CI）。此外，也分别对接种不同类型加强针（mRNA-1273 或 BNT162b2）的人群进行亚组分析。

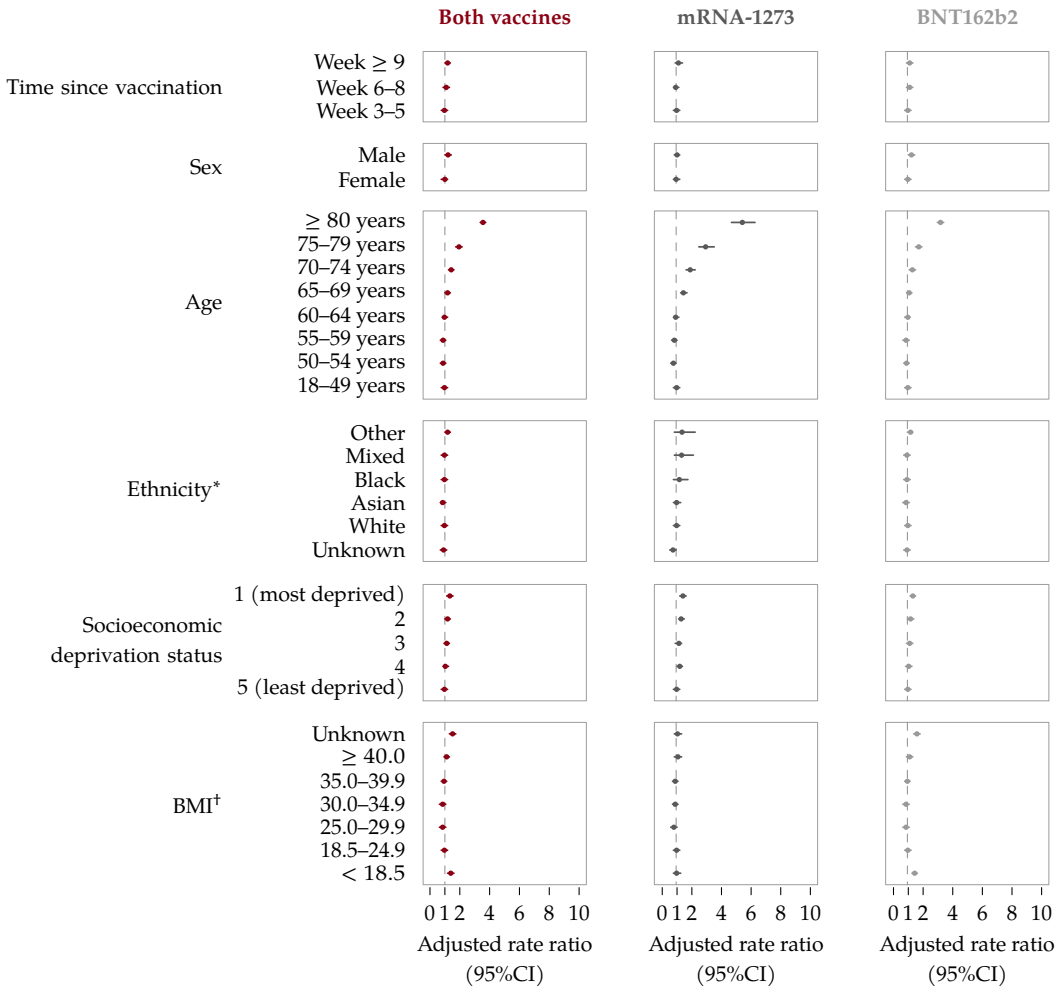


Figure 2. Pooled analyses of Poisson-adjusted rate ratios for demographic and clinical characteristics associated with COVID-19-related hospitalisation or death among individuals who received booster doses

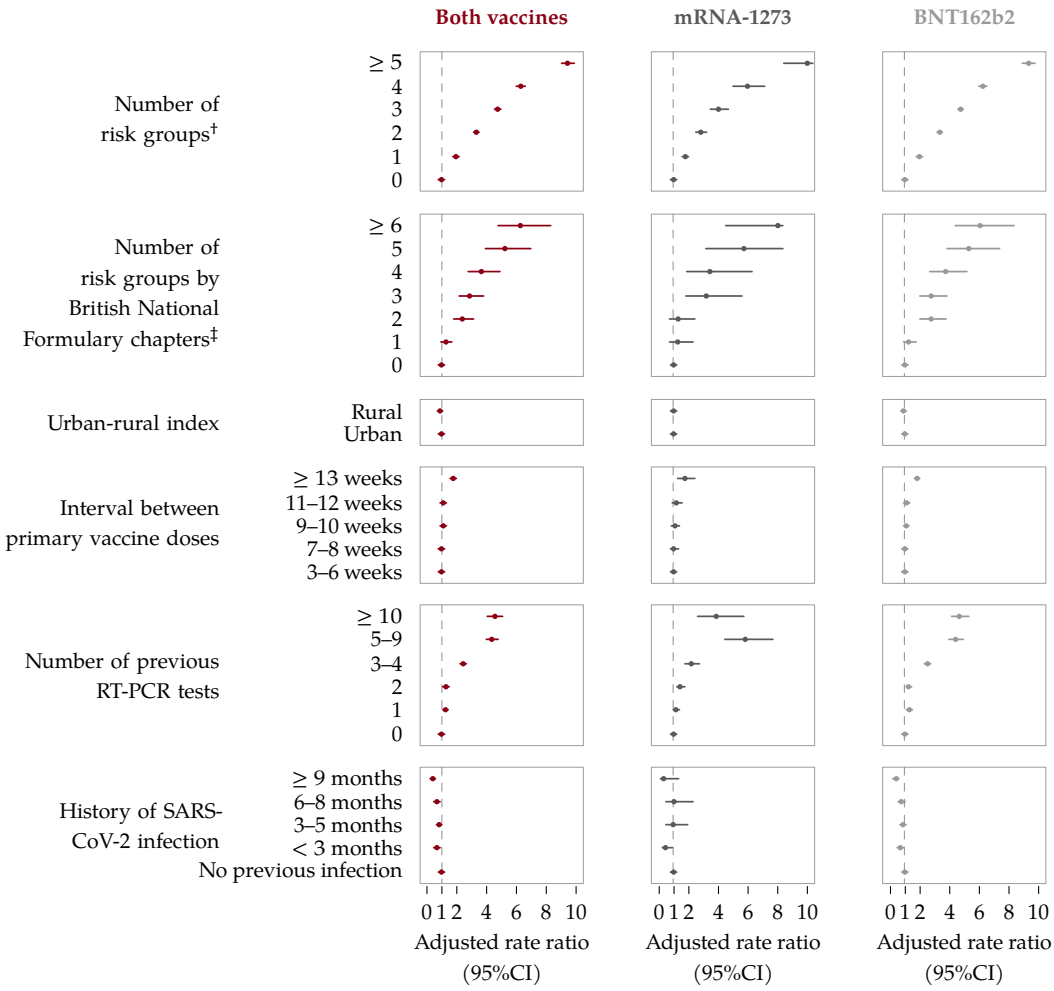


Figure 2（续）. Pooled analyses of Poisson-adjusted rate ratios for demographic and clinical characteristics associated with COVID-19-related hospitalisation or death among individuals who received booster doses

与女性相比，男性 aRR [95%CI]：1.23 [1.20–1.26]。与 18–49 岁者相比，≥ 80 岁者的 aRR [95%CI]：9.51 [9.07–9.97]。

> **批注** 男性容易严重新冠；老人容易严重新冠。

结果描述

Individuals with a greater number of comorbidities (≥ 5 comorbidities vs none; 9.51 [9.07–9.97]), who were older (aged ≥ 80 years vs 18–49 years; 3.60 [3.45–3.75]), or who were male (male vs female; 1.23 [1.20–1.26]) were also associated with increased risk of severe COVID-19 outcomes.

结果讨论 65 岁以上人群较 18–49 岁者发生严重结局的风险高，提示有必要在老年人中接种第二剂加强针。

英文表达

Methods

We used generalized linear models, assuming a Poisson distribution with person-time as an offset that represented the time at risk, as an approximation to a Cox proportional hazards

model to derive rate ratios (RRs) with 95% CIs for the association between demographic and clinical factors and COVID-19-related hospitalization or death. The adjusted RRs (aRRs) for time since receiving the vaccine dose were estimated for all vaccines combined, as well as for each vaccine separately.

The models were adjusted for age, sex, socioeconomic deprivation status, urban versus rural place of residence, BMI, number of pre-existing comorbidities....

All statistical analyses were done using the statistical software R.

注意事项

1) 前瞻性队列研究的报告依据：RECORD、STROBE。
2) 提前撰写统计分析计划。
3) 数据共享问题：对各国结果进行 Meta 分析。
4) 人年发病率：发生严重 COVID-19 结局的人数/总的随访人年数 ×1000。
5) 诸多人口统计学和临床特征的选取是基于研究团队在既往工作中确定的高风险因素，同时考虑到数据在每个国家的可用性而确定。

> **批注** 发病密度。

7.1.4 思考与练习

某疾控中心拟分析不同因素对儿童接种新型流感疫苗后 1 个月内发热次数的影响，为疫苗接种后的不良反应监测提供依据。选取 500 名 3–12 岁接种新型流感疫苗的儿童，随访 1 个月记录发热次数。分析年龄组、疫苗剂量、基础疾病对儿童接种疫苗后发热次数的影响。

儿童发热次数研究的变量定义

变量类型	变量名称	变量编码/说明
因变量	发热次数 Y	计数型变量，取值为 0、1、2、……（随访 1 个月内的发热次数）
自变量	年龄组 X_1	分类变量：1=3–6 岁（低龄组），2=7–12 岁（高龄组）
自变量	疫苗剂量 X_2	分类变量：1= 标准剂量，2= 高剂量
自变量	基础疾病 X_3	二分类变量：0= 无基础疾病，1= 有基础疾病（如哮喘、过敏性鼻炎）
偏移项	随访天数（offset）	连续型变量，取值为 28–31 天（因部分儿童随访天数略有差异，以 ln(随访天数) 作偏移项调整观测时间）

儿童发热次数的 Poisson 回归结果

变量	系数 β	标准误	Z	P	IRR $\exp(\beta)$
截距（β_0）	−2.50	0.12	−20.83	< 0.001	—
年龄组（$X_1 = 2$）	−0.35	0.10	−3.50	< 0.001	0.70
疫苗剂量（$X_2 = 2$）	0.42	0.11	3.82	< 0.001	1.52
基础疾病（$X_3 = 1$）	0.60	0.13	4.62	< 0.001	1.82
偏移项 ln(随访天数)	1（固定）	—	—	—	—

截距是参照组（低龄、标准剂量、无基础疾病）单位随访时间发热率的对数；系数取指数为发热率比（IRR）。

问题：可否采用 Logistic 回归模型分析此资料？

Logistic 回归与 Poisson 回归的结果比较

变量	Logistic 回归：系数 β	Poisson 回归（原结果）：IRR $\exp(\beta)$
截距（β_0）	-1.80（$P < 0.001$）	-2.50（$P < 0.001$）
年龄组（7–12 岁 vs3–6 岁）	-0.52(OR=0.59,95%CI 0.41–0.85,$P = 0.004$)	0.70（95%CI 0.57–0.86，$P < 0.001$）
疫苗剂量（高剂量 vs 标准剂量）	0.65（OR=1.92，95%CI 1.32–2.79，$P < 0.001$）	1.52（95%CI 1.22–1.89，$P < 0.001$）
基础疾病（有 vs 无）	0.88（OR=2.41，95%CI 1.56–3.72，$P < 0.001$）	1.82（95%CI 1.37–2.41，$P < 0.001$）

Logistic 回归与 Poisson 回归

对比维度	Logistic 回归	Poisson 回归
因变量	二分类	计数（次数）
危险度指标	OR	发病率之比
关注重点	发热有无（概率）	发热次数（计数率）
信息利用	少	多（次数）
结果趋势	一致	一致，估计值偏低
理论分布	二项分布	Poisson 分布（总体均数等于总体方差）

问题：可否采用 Cox 回归分析此资料？ 重复事件的生存分析方法，同时关注事件发生的次数和事件发生的时间。

7.2 负二项回归（Negative binomial regression）

7.2.1 负二项回归模型

医学研究中，很多事件的发生是非独立的（传染的、原因不明的聚集现象等），这种资料的特点是估计值的方差较 Poisson 分布的方差大（over-dispersion or extra-Poisson variation）。

> **批注** 此时若仍用 Poisson 回归，只要均值结构正确，系数的点估计仍然一致，但模型低估了方差，标准误偏小、置信区间偏窄、P 值偏小（见下文）。

Poisson 回归模型 Y 服从 Poisson 分布，λ 为相应的均数。

$$\lambda \longleftrightarrow \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_m x_m,$$

$$\ln\lambda = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_m x_m, \qquad \lambda = e^{\beta_0+\beta_1 x_1+\beta_2 x_2+\cdots+\beta_m x_m}.$$

> **批注** 连接函数。

Poisson 回归用于描述当观察结果变量服从 Poisson 分布时的资料，即事件的发生是独立的。但医学研究中，很多事件的发生是非独立的，这种资料可基于负二项分布用负二项回归分析。

负二项分布实际上是当 Poisson 分布中强度参数 λ 服从 Γ 分布时所得到的复合分布。在 Poisson 分布中，λ 是一常数；在负二项分布中是一随机变量，并服从 Γ 分布，因此负二项分布又称 Γ–Poisson 分布（Gamma–Poisson distribution）。

负二项回归模型 Y 服从负二项分布，均数为 μ（有的资料记作 λ）。

$$\ln \mu = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_m x_m, \qquad \mu = e^{\beta_0+\beta_1 x_1+\beta_2 x_2+\cdots+\beta_m x_m}.$$

Poisson 分布的方差 = 均数 $=\mu$。本书统一采用 NB2 参数化：负二项分布的均数 $= \mu$，方差 $= \mu + \alpha\mu^2 = \mu(1+\alpha\mu)$，$\alpha \geq 0$ 为过离散参数（有的资料记作 κ；Stata `nbreg` 输出的 alpha 即此参数，R `glm.nb` 输出的是 $\theta = 1/\alpha$）。有的资料写的“均数 $= (1+\kappa)\lambda$、方差 $= (1+\kappa)\lambda(1+\lambda)$”两式互相矛盾：若 λ 是均数，均数就不应再乘 $(1+\kappa)$；方差式也不是负二项分布的方差函数。下面给出推导。

NB2 模型的 Gamma–Poisson 推导

假设　$Y \mid U, \mathbf{x} \sim \text{Poisson}(\mu U)$, $\mu = \exp(\mathbf{x}^\top \boldsymbol{\beta})$；未观察到的异质性 $U \sim \Gamma$(形状 $= 1/\alpha$, 率 $= 1/\alpha$)，与 $\mathbf{x}$ 独立，$\mathrm{E}(U) = 1$，$\mathrm{Var}(U) = \alpha$。

概率函数　记 $\theta = 1/\alpha$。对 U 积分：

$$P(Y = y \mid \mathbf{x}) = \int_0^\infty \frac{(\mu u)^y e^{-\mu u}}{y!} \cdot \frac{\theta^\theta u^{\theta-1} e^{-\theta u}}{\Gamma(\theta)}\, du = \frac{\Gamma(y+\theta)}{y!\,\Gamma(\theta)} \left(\frac{\theta}{\theta+\mu}\right)^\theta \left(\frac{\mu}{\theta+\mu}\right)^y,$$

$y = 0, 1, 2, \ldots$（积分中出现 Gamma 函数 $\int_0^\infty u^{y+\theta-1} e^{-(\mu+\theta)u} du = \Gamma(y+\theta)/(\mu+\theta)^{y+\theta}$）。这是负二项分布。

均值与方差　由全期望公式与全方差公式：

$$\mathrm{E}(Y \mid \mathbf{x}) = \mathrm{E}\{\mathrm{E}(Y \mid U, \mathbf{x})\} = \mathrm{E}(\mu U) = \mu,$$

$$\mathrm{Var}(Y \mid \mathbf{x}) = \mathrm{E}\{\mathrm{Var}(Y \mid U, \mathbf{x})\} + \mathrm{Var}\{\mathrm{E}(Y \mid U, \mathbf{x})\} = \mathrm{E}(\mu U) + \mathrm{Var}(\mu U) = \mu + \alpha\mu^2.$$

结论　NB2 模型的均值结构与 Poisson 回归相同（$\ln \mu = \mathbf{x}^\top \boldsymbol{\beta}$，$e^{\beta_j}$ 仍是率比 IRR），只是方差多了 $\alpha\mu^2$。$\alpha \to 0$ 时 $\mathrm{Var}(U) \to 0$，U 退化为常数 1，负二项分布趋于 Poisson(μ)。有观察时间时同样加 offset：$\ln \mu_i = \ln t_i + \mathbf{x}_i^\top \boldsymbol{\beta}$。

> **批注**　U 代表协变量未能解释的个体间差异（如易感性不同），它使事件数在个体间比 Poisson 分布更分散。α 越大，过离散越严重。

7.2.2　例题：癫痫发作

为了解某抗癫痫药之作用，对 59 名癫痫病人进行临床试验。每个病人先观察 8 周，其间的发作次数作为基线（base line）。再将其随机分为 2 组，一组服用试验药，一组服用对照药，治疗 8 周，观察最后两周的发作次数 Y。

资料见下表。其中 Trt 表示治疗方法（0 为安慰剂，1 为试验药），Base 表示试验前 8 周的基线，Age 表示患者的实际年龄，Y 表示发作次数。

批注 分析单位是病人：每人一个计数（治疗期最后两周的发作次数 Y），每人一行，59 人共 59 个观察值，基线发作次数（8 周）作协变量。判断用 Poisson 回归还是负二项回归，一是依据专业知识（发作是否在个体内聚集、个体间易感性是否不同）；二是在拟合模型后检查条件过离散，即给定协变量后方差是否大于均值，而不是看 Y 的总方差与总均数（本例 Y 的均数 7.34、方差 92.9，其中很大一部分是基线差异造成的，调整 Base 后才能判断）。

59 个癫痫病人临床试验观察结果

编号	Y	Trt	Base	Age	编号	Y	Trt	Base	Age
1	3	0	11	31	31	4	1	19	18
2	3	0	11	30	32	3	1	24	24
3	5	0	6	25	33	16	1	31	30
4	4	0	8	36	34	4	1	14	35
5	21	0	66	22	35	4	1	11	57
6	7	0	27	29	36	7	1	67	20
7	2	0	12	31	37	5	1	41	22
8	12	0	52	42	38	0	1	7	28
9	5	0	23	37	39	0	1	22	23
10	0	0	10	28	40	3	1	13	40
11	22	0	52	36	41	15	1	46	43
12	5	0	33	24	42	8	1	36	21
13	2	0	18	23	43	7	1	38	35
14	14	0	42	36	44	4	1	7	25
15	9	0	87	26	45	8	1	36	26
16	5	0	50	26	46	0	1	11	25
17	3	0	18	28	*47	63	1	151	22
18	29	0	111	31	48	4	1	22	32
19	5	0	18	32	49	7	1	42	25
20	7	0	20	21	50	5	1	32	35
21	4	0	12	29	51	13	1	56	21
22	4	0	8	21	52	0	1	24	41
23	5	0	17	32	53	3	1	16	32
24	8	0	28	25	54	8	1	22	26
25	25	0	55	30	55	1	1	25	21
26	1	0	9	10	56	0	1	13	36
27	2	0	10	19	57	2	1	12	37
28	12	0	47	22	58	8	1	76	18
29	0	1	19	20	59	4	1	38	32
30	3	1	10	20					

批注 表中标“*”的 47 号（试验药组，Base=151，$Y = 63$）基线和随访发作次数都远高于其他人，原分析将其作为异常值剔除，分析集为 58 人。剔除需要有依据：若核实为记录错误，应更正或剔除；若是真实的极端病例，不应仅因数值大而剔除，至少要报告纳入与剔除两种结果（敏感性分析，见下

表）。另外，本表与公开的 Thall–Vail 癫痫资料（R `MASS::epil` 第 4 期）有 7 行在 Y 或年龄上略有出入（本表 12、26、30、35、41、44、49 号），本表 47 号即 `epil` 的 49 号受试者。下面的结果是按本表计算的，可以复现下表的模型 C、D。

癫痫病人临床资料的两种负二项回归比较

变量	模型 C				模型 D			
	系数	标准误	z	P	系数	标准误	z	P
Trt	−0.3003	0.1675	−1.793	0.073	−0.4001	0.1496	−2.675	0.007
Age	0.0190	0.0109	1.740	0.082	0.0176	0.0099	1.777	0.076
Base/log(Base)	0.0276	0.0040	6.929	0.000	0.9303	0.1081	8.604	0.000
常数项	0.4492	0.3723	1.206	0.228	−1.5978	0.4943	−3.232	0.001
κ	0.2053	0.07435	2.761	0.006	0.1280	0.0610	2.098	0.036

$$\text{模型 C：}\quad \log L = -146.71662,\quad \chi^2_G = 54.8151,\quad P = 0.4435.$$

$$\text{模型 D：}\quad \log L = -143.21707,\quad \chi^2_G = 62.4238,\quad P = 0.2018.$$

批注 模型 C 以 Base、模型 D 以 log(Base) 作协变量（58 人，剔除 47 号）。用 log(Base) 时，$\log\mu$ 与 log(Base) 呈线性，系数 0.93 接近 1，意味着发作次数与基线次数大致成比例，比 Base 的线性项更符合计数资料的特点；模型 D 的对数似然更大（−143.2 对 −146.7，参数个数相同），κ 也更小。Pearson χ^2_G 用于检查 NB 模型本身的拟合，两个模型的 P 值都大于 0.05。用 R `MASS::glm.nb` 复算，系数、κ 与上表相差不超过 0.03（Stata 与 R 的收敛精度不同），Pearson χ^2 为 54.80 和 62.36。

过渡离散检验（overdispersion test）

H_0：$\alpha = 0$（Poisson 模型足够）；H_1：$\alpha > 0$（需要负二项模型）。

检验统计量为 NB 与 Poisson 模型的似然比 $\mathrm{LR} = 2(\ell_{\mathrm{NB}} - \ell_{\mathrm{P}})$。$\alpha$ 不能为负，H_0 中 $\alpha = 0$ 位于参数空间的边界上，常规的“χ^2_1”参照分布不再适用；在 H_0 下 LR 的渐近分布是 $\frac{1}{2}\chi^2_0 + \frac{1}{2}\chi^2_1$ 的混合（一半概率恰为 0，一半服从 χ^2_1），所以正确的 P 值是按 χ^2_1 算出的 P 值的一半（Stata `nbreg` 输出的“chibar2(01)”即此）。

过离散检验与敏感性分析（R 复算）

分析集	模型	$\hat{\alpha}$	LR	P（边界校正）	Trt 系数（SE）	Trt 的 P
58 人（剔除 47 号）	C（Base）	0.205	30.50	< 0.001	−0.299（0.169）	0.076
	D（log Base）	0.127	12.74	< 0.001	−0.397（0.149）	0.008
59 人（全部）	C（Base）	0.193	27.18	< 0.001	−0.326（0.162）	0.044
	D（log Base）	0.173	32.53	< 0.001	−0.316（0.158）	0.045

说明 原分析称“模型 C 的卡方值为 27.1824，模型 D 为 32.8259”，但模型 C、D 是在 58 人中拟合的；按 58 人复算，过离散 LR 分别为 30.50 和 12.74。27.18 与 59 人模型 C 的结果相同，32.83 也接近 59 人模型 D 的 32.53，说明这两个值来自未剔除 47 号的分析，与上表的系数不是同一分析集。无论哪个分析集，过离散都非常明显（$P < 0.001$），宜采用负二项回归。是否剔除 47 号会改变治疗效应的大小和显著性（模型 D：58 人 $\mathrm{IRR} = e^{-0.397} = 0.67$，$P = 0.008$；59 人 $\mathrm{IRR} = 0.73$，$P = 0.045$），应同时报告。

> **批注** 拒绝 H_0，说明给定协变量后仍存在过离散。若仍用 Poisson 回归，系数的点估计变化不大，但标准误被低估：本例 58 人模型 C 中，Trt 的 Poisson 标准误为 0.111（$P = 0.008$），负二项为 0.169（$P = 0.076$）。Poisson 模型低估方差会使检验偏于宽松，第一类错误增大；负二项模型修正了方差，结论更可靠（并非单纯“更保守”）。

用 R 复算 58 人的模型 D，并比较 Poisson、准 Poisson 与负二项三种方法对治疗效应的估计：

R

```r
library(MASS)
ep <- data.frame(Y,Trt,Base,Age)[-47,]              # 59人资料按上表录入，剔除47号
nb <- glm.nb(Y~Trt+Age+log(Base), data=ep)          # 负二项（模型D）
round(summary(nb)$coefficients,4); c(theta=nb$theta, alpha=1/nb$theta)
po <- glm(Y~Trt+Age+log(Base), family=poisson,      data=ep)
qp <- glm(Y~Trt+Age+log(Base), family=quasipoisson, data=ep)
rbind(Poisson=coef(summary(po))["Trt",], quasi=coef(summary(qp))["Trt",],
      NB=coef(summary(nb))["Trt",])
sum(residuals(po,type="pearson")^2)/df.residual(po)  # Pearson卡方/自由度
```

```
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  -1.5978     0.4968 -3.2165   0.0013
Trt          -0.4001     0.1497 -2.6728   0.0075
Age           0.0176     0.0099  1.7829   0.0746
log(Base)     0.9303     0.1080  8.6133   0.0000
    theta      alpha
7.8115482 0.1280156

          Estimate Std. Error   z value     Pr(>|z|)
Poisson -0.3839868  0.1085021 -3.538981 0.0004016749
quasi   -0.3839868  0.1525623 -2.516918 0.0148403213
NB      -0.4001300  0.1497037 -2.672813 0.0075218248
[1] 1.977053
```

`glm.nb` 给出 $\theta = 7.81$，换算为 $\alpha = 1/\theta = 0.128$，与上表的 κ 一致。三种方法对 Trt 的点估计在 -0.38 至 -0.40 之间，差别在于标准误：Poisson 回归为 0.109，另两种方法约为 0.15。Pearson $\chi^2/\mathrm{df} = 1.98$，即实际方差约为 Poisson 假定的 2 倍，准 Poisson 法将标准误乘以 $\sqrt{1.98} = 1.41$。若采用 Poisson 回归，$P = 0.0004$ 会高估疗效证据的强度。负二项模型的 IRR 为 $e^{-0.400} = 0.67$，即调整年龄与基线后，试验药使发作次数平均减少约 33%。

过离散的来源与诊断

- **均值异质性（遗漏协变量）**：重要协变量没有进入模型，或函数形式不对（如本例 Base 与 log Base），会表现为过离散。先改进均值模型，再判断剩余的过离散。
- **条件过离散**：均值模型正确，但给定协变量后个体间仍有未观察到的差异，$\mathrm{Var}(Y \mid \mathbf{x}) > \mathrm{E}(Y \mid \mathbf{x})$，即 NB2 中的 Gamma 异质性。
- **观察不独立**：同一个体的重复计数、同一家庭或社区的成员彼此相关，也会使方差变大。这不是“过离散参数”能解决的问题，普通的独立 NB 模型仍把每条记录当作独立观察，标准误依然有偏；应使用 GEE、随机效应（混合）负二项模型，或以个体为单位汇总。
- **诊断**：拟合 Poisson 模型后看 Pearson χ^2/df 或偏差/df（远大于 1 提示过离散）、Pearson 残差对拟合值作图，并作上面的 LR 检验；只比较 Y 的总方差与总均数是不够的。

- **后果**：若均值模型设定正确，方差设定错误不影响系数估计的一致性，主要影响标准误和检验；此时也可保留 Poisson 点估计、改用稳健（夹心）标准误或准 Poisson 方法。

7.2.3 思考题

思考题 1 某疾控中心拟分析不同因素对儿童接种新型流感疫苗后 1 个月内发热次数的影响。选取 500 名 3–12 岁接种新型流感疫苗的儿童，随访 1 个月记录发热次数。分析年龄组、疫苗剂量、基础疾病对儿童接种疫苗后发热次数的影响。变量定义同前。

- 发热次数均值：0.826。
- 发热次数方差：1.485。
- 方差/均值：1.798（Poisson 分布时应约为 1.0；这是未调整协变量的总方差与总均数之比，只能作初步参考）。
- Poisson 回归过离散检验：残差偏差/残差自由度 =1.812（常用的经验界限约 1.5；这是调整协变量后的指标，更有参考价值）。
- 过离散存在。

Poisson 回归与负二项回归的比较

变量	Poisson_IRR	*P*	NB_IRR	*P*
年龄组	0.701 (0.550–0.894)	0.004	0.718 (0.552–0.934)	0.013
疫苗剂量	1.518 (1.190–1.939)	0.001	1.476 (1.135–1.919)	0.004
基础疾病	1.819 (1.403–2.359)	< 0.001	1.748 (1.317–2.323)	< 0.001

思考题 2 研究影响急诊科患者一年内住院次数的因素。自变量：年龄、慢性病数量、是否吸烟、性别；因变量：一年内的住院次数（计数数据）。如何分析？考虑负二项回归的理由？

7.2.4 案例分析

案例介绍

Impact and effectiveness of mRNA BNT162b2 vaccine against SARS-CoV-2 infections and COVID-19 cases, hospitalisations, and deaths following a nationwide vaccination campaign in Israel: an observational study using national surveillance data。

Lancet. 2021 May 15;397(10287):1819–1829. doi:10.1016/S0140-6736(21)00947-8. Epub 2021 May 5。

标题：在以色列开展全国疫苗接种运动后，mRNA BNT162b2 疫苗接种对 SARS-CoV-2 感染、与 COVID-19 相关的住院和死亡的影响和有效性：一项使用国家监测数据的观察性研究。

目的：对两剂 mRNA BNT162b2 疫苗接种对 SARS-CoV-2 感染的一系列结局的有效性进行全国性估计，并评估疫苗广泛接种后对全国公共卫生的影响。

研究设计

观察性研究。本文根据 Strengthening the Reporting of Observational studies in Epidemiology guidelines（STROBE）清单对各条目内容进行透明报告。

数据来源：2021 年 1 月 24 日至 4 月 3 日的全国监测数据。本分析仅使用了无个人身份识别信息的汇总数据，故没有必要进行全面的伦理审查。

研究对象：16 岁及以上的以色列居民（即普查人口）中，未接种疫苗或接种两剂疫苗者。如果只接受了一剂疫苗，或接受了两剂但距第二次接种不到 7 天，则研究对象被排除。

分析计划：本研究的统计分析计划由以色列卫生部公共卫生服务部门的高级管理人员进行内部审查。

数据特点

结局变量：SARS-CoV-2 感染后的 6 种结局。

1）所有 SARS-CoV-2 感染，包括有症状和无症状感染（all SARS-CoV-2 infections）。
2）有症状的 COVID-19 病例（symptomatic COVID-19 cases）。
3）与 COVID-19 相关的住院（COVID-19-related hospitalisations）。
4）与 COVID-19 相关的严重住院（COVID-19-related severe hospitalisations）。
5）与 COVID-19 相关的危重住院（COVID-19-related critical hospitalisations）。
6）与 COVID-19 相关的死亡（COVID-19-related deaths）。

协变量：年龄、性别、地区（Arab、Ultra-Orthodox、General Jewish [non-ultra-Orthodox]）、日历周（Jan 17 to 23, 2021–March 28 to April 3, 2021）。

研究对象：未接种疫苗，如果个人没有接受任何剂量的 BNT162b2，则他们被定义为未接种疫苗。完全接种疫苗，如果自接受第二剂 BNT162b2 以来至少已过去 7 天，则被定义为完全接种疫苗。

方法应用

描述性分析：以色列 16 岁及以上人口中完全接种 BNT162b2 疫苗的人数及比例。对“未接种疫苗”及“完全接种疫苗”两种人群，计算各年龄层的每种 SARS-CoV-2 结局的发生率（每 10 万人年）。

广义线性模型——负二项回归：使用比传统的泊松回归方法更适合于方差过离散的负二项回归模型，得到每种结局的发生率比（IRR）及其 95%CI。疫苗有效性估计值的计算公式为 $(1 - \text{IRR}) \times 100$。模型中调整了年龄、性别和日历周。

> **批注** 若接种疫苗相于未接种者，RR = 0.4，则保护率 =60%。

敏感性分析：分别将“完全接种疫苗”人群换成以下人群，用同样的方法进行疫苗有效性估计：接种了两剂 BNT162b2 且距第二次接种后至少 14 天；接种了一剂 BNT162b2 且距第一次接种后 14–21 天。统计软件：STATA。

结果及解释

描述性分析：“完全接种疫苗”的人数及比例。

Table 1. Numbers and proportions of people fully vaccinated with BNT162b2 in the Israel population aged 16 years and older (Jan 24 to April 3, 2021)

	Population	Fully vaccinated*
Age-groups, years		
16–44	3646848	2290820 (62.8%)
45–64	1764098	1408492 (79.8%)
≥65	1127965	1015620 (90.0%)
Sex		
Female	3337693	2398547 (71.9%)
Male	3201218	2310788 (72.2%)
Sector		
Arab	1226788	669542 (54.6%)
Ultra-Orthodox	534146	228479 (42.8%)
General Jewish (non-ultra-Orthodox)	4777977	3816911 (79.9%)
Calendar week in 2021		
Jan 17 to 23	..	248196
Jan 24 to 30	..	773331
Jan 31 to Feb 6	..	767416
Feb 7 to 13	..	285272
Feb 14 to 20	..	412001
Feb 21 to 27	..	443542
Feb 28 to March 6	..	408882
March 7 to 13	..	391983
March 14 to 20	..	415510
March 21 to 27	..	382569
March 28 to April 3	..	186230
Overall	6538911	4714932 (72.1%)

Data are *n* or *n* (%). *Defined as people for whom at least 7 days had passed after the second dose of BNT162b2 vaccine. †Sex was not recorded for 5597 fully vaccinated individuals.

总体而言，72.1% 的 16 岁及以上的以色列居民完全接种疫苗，90.0% 的 65 岁及以上的以色列居民完全接种疫苗。针对年龄、性别，各亚组人群中的疫苗完全接种率的具体信息见表。“完全接种疫苗”人群的中位随访时长为 48 天（IQR 30–60）。

描述性分析与负二项回归：两种人群中各结局的发生率及疫苗有效性估计。

Table 2. Estimated effectiveness of two doses of BNT162b2 (≥ 7 days after the second dose) against laboratory-confirmed SARS-CoV-2 outcomes by age group (Jan 24 to April 3, 2021)

Age (years)	Unvaccinated		Fully vaccinated*		Vaccine effectiveness, % (95%CI)	
	Cases	Incidence rate	Cases	Incidence rate	Unadjusted	Adjusted§
SARS-CoV-2 infection						
16–44	84611	95.1	1801	2.3	95.4 (94.0–96.5)	96.1 (95.7–96.5)
45–64	18579	86.1	2264	3.4	93.6 (91.4–95.3)	94.9 (94.2–95.5)
≥65	5686	67.7	2201	3.8	93.4 (91.3–95.0)	94.8 (93.9–95.5)
All ages	109876	91.5	6266	3.1	94.2 (93.2–95.1)	95.3 (94.9–95.7)
Asymptomatic SARS-CoV-2 infection						
16–44	40088	45.1	1174	1.5	92.8 (90.3–94.7)	93.6 (92.8–94.4)
45–64	7414	32.6	1343	2.0	89.1 (84.7–92.3)	90.8 (89.6–91.9)
≥65	1636	19.5	1115	1.9	85.9 (80.2–89.9)	88.5 (86.4–90.3)
All ages	49138	40.9	3632	1.8	90.1 (88.0–91.8)	91.5 (90.7–92.2)
Symptomatic COVID-19						
16–44	28196	31.7	352	0.5	97.8 (97.0–98.3)	97.6 (97.3–97.8)
45–64	7790	34.3	560	0.8	96.3 (95.0–97.3)	96.7 (96.3–97.0)
≥65	3079	36.6	780	1.4	96.1 (94.8–97.1)	96.4 (95.9–97.0)
All ages	39065	32.5	1692	0.8	96.6 (95.8–97.2)	97.0 (96.7–97.2)
COVID-19-related hospitalisation						
16–44	2043	2.3	33	<0.01	98.1 (97.1–98.8)	98.1 (97.3–98.7)
45–64	1687	7.4	112	0.2	97.6 (96.9–98.2)	97.6 (97.1–98.1)
≥65	1826	21.7	451	0.8	96.6 (95.3–97.6)	96.8 (96.2–97.3)
All ages	5526	4.6	596	0.3	96.7 (95.5–97.6)	97.2 (96.8–97.5)
Severe or critical COVID-19-related hospitalisation						
16–44	644	0.7	7	0.01	98.8 (97.3–99.5)	98.9 (97.6–99.5)
45–64	1132	5.0	62	0.1	98.1 (97.2–98.6)	98.1 (97.5–98.5)
≥65	1425	17.0	295	0.5	97.2 (95.9–98.1)	97.3 (96.8–97.8)
All ages	3201	2.7	364	0.2	97.2 (95.9–98.1)	97.5 (97.1–97.8)
COVID-19-related death						
16–44	36	0.04	0	0.0	100	100
45–64	125	0.5	14	<0.01	96.2 (92.6–98.0)	95.8 (92.6–97.6)
≥65	554	6.6	124	0.2	96.8 (94.6–98.1)	96.9 (96.0–97.6)
All ages	715	0.6	138	0.1	96.6 (93.9–98.1)	96.7 (96.0–97.3)

Numbers and incidence rates of outcomes are shown for unvaccinated and fully vaccinated individuals. Incidence rates are per 100000 person-days. Vaccine effectiveness estimates are % (95%CI).

*Defined as people for whom at least 7 days had passed after the second dose of BNT162b2 vaccine. †Total person-days for all outcomes were 88938455 for age 16–44 years, 22734025 for age 45–64 years, 8403760 for age ≥ 65 years, and 120076240 for all ages. ‡Total person-days for all outcomes were 77280720 for age 16–44 years, 67027505 for age 45–64 years, 57573640 for age ≥ 65 years, and 201881865 for all ages. §Model is adjusted for age group (16–24, 25–34, 35–44, 45–54, 55–64, 65–74, 75–84, and ≥ 85 years), sex, and calendar week. Includes asymptomatic and symptomatic infections, as well as cases with positive SARS-CoV-2 tests for which the symptom interview portion of the epidemiological investigation was not completed.

Table 3. Estimated effectiveness of two doses of BNT162b2 (≥ 7 days after the second dose) against laboratory-confirmed SARS-CoV-2 outcomes in the oldest age groups (Jan 24 to April 3, 2021)

	Vaccine effectiveness, % (95%CI)		
Outcome	Age ≥ 65 years	Age ≥ 75 years	Age ≥ 85 years
SARS-CoV-2 infection	94.8 (93.9–95.5)	95.1 (93.9–96.0)	94.1 (91.9–95.7)
Asymptomatic SARS-CoV-2 infection	88.5 (86.4–90.3)	87.5 (84.2–90.1)	83.2 (76.3–88.1)
Symptomatic COVID-19	96.4 (95.9–97.0)	96.7 (95.9–97.4)	96.6 (95.2–97.6)
COVID-19-related hospitalisation	96.8 (96.2–97.3)	97.0 (96.2–97.7)	96.9 (95.5–97.9)
Severe or critical COVID-19-related hospitalisation	97.3 (96.8–97.8)	97.6 (96.8–98.1)	97.4 (95.9–98.3)
COVID-19-related death	96.9 (96.0–97.6)	97.1 (96.0–97.9)	97.0 (94.9–98.3)

Estimates are % (95%CI). Model is adjusted for age group (16–24, 25–34, 35–44, 45–54, 55–64, 65–74, 75–84, and ≥ 85 years), sex, and calendar week. Includes asymptomatic and symptomatic infections, as well as cases with positive SARS-CoV-2 tests for which the symptom interview portion of the epidemiological investigation was not completed.

> **批注** 有效率/保护率。

结果描述

Adjusted vaccine effectiveness estimates against all COVID-19 outcomes were higher than 96% among people aged 75 years and older and people aged 85 years and older (table 3).

在老龄人群中，两剂疫苗接种对于各种 COVID-19 相关结局的有效性均较高（> 80%）。

英文表达

Methods

Using STATA (version 15), a negative binomial regression model (nbreg command), which is better suited for over-dispersion of variance than the traditional Poisson regression method, was used to derive incidence rate ratios (IRRs) with 95% CIs for each outcome adjusted for age group, sex, and calendar week. The exposure command was used to account for varying patient-days across strata.

Vaccine effectiveness estimates were calculated as $(1 - \text{IRR}) \times 100$.

In sensitivity analyses, vaccine effectiveness estimates were also calculated with the same method for people who had received two BNT162b2 doses and for whom at least 14 days had passed after the second dose, as well as for those who had received one dose and for whom 14–21 days had passed after the first dose.

注意事项

1）观察性研究的报告依据：STROBE。
2）提前撰写统计分析计划。
3）发病率：本研究以人日为分母，发生各 COVID-19 结局的人数/总的随访人日数 ×100000（表 2 注）。
4）在对“完全接种疫苗”人群的定义中，距第二次接种后的时间有不同的设定。本研究基于“距第二次接种后至少 7 天”这一定义进行主分析，同时基于“距第二次接种后至少 14 天”进行敏感性分析（见上文英文方法与表 2 标题；有的转述把主分析与敏感性分析写反了）。
5）数据存在过离散情况时，宜采用负二项回归，而非泊松回归。

7.2.5 练习与思考

1. 1977/1978 年澳大利亚健康调查共收集了 5190 人的就诊次数数据（DoctorVisits），该数据可直接在 R 中通过“AER”包获取。原题为使数据“满足泊松回归要求的等离散条件”，将就诊次数为 0 的观测行删除，只保留 1049 人（df.ps2）。这一处理不可取，见下文说明。数据获取、调整的命令及数据样例如下：

R

```r
#安装、加载AER包
install.packages("AER")
library(AER)
#读取DoctorVisits数据集
data("DoctorVisits")
#查看数据集中的变量描述
help("DoctorVisits")
#删除就诊次数为0的观测行（原题做法，不推荐，见下文）
df.ps2 <- DoctorVisits[which(DoctorVisits$visits>0), ]
```

说明 为了满足模型假设而删除观察值，会改变研究总体并造成选择偏倚。删除 visits = 0 后，研究总体变成“两周内至少就诊一次的人”，回答的是另一个问题；剩下的计数从 1 开始，不再是 Poisson 分布（而是零截断分布），仍用普通 Poisson 回归会得到有偏的系数。用 AER 包数据复算（自变量取 gender、age、income、illness、reduced、health）：

- 全部 5190 人：visits 均数 0.302、方差 0.637；Poisson 回归 Pearson $\chi^2/\mathrm{df} = 1.32$，负二项回归 $\hat{\alpha} = 1.08$，过离散 LR = 316.8；观察到的 0 次就诊 4141 人，Poisson 模型预测 4012 人、负二项模型预测 4171 人，说明零计数多于 Poisson 分布，负二项模型拟合更好。
- 只用 1049 名就诊者作普通 Poisson 回归：Pearson $\chi^2/\mathrm{df} = 0.60$，呈“欠离散”，并非等离散；例如 illness 的系数为 0.027，而零截断 Poisson 模型为 0.075、全样本 Poisson 为 0.198，三者差别很大。

建议：以全部 5190 人为研究总体，从 Poisson 回归开始，检查过离散后改用负二项回归，必要时考虑零膨胀或 hurdle 模型（`pscl` 包）。若研究问题确实只针对至少就诊一次的人，应明确说明研究总体，并使用零截断 Poisson 或零截断负二项模型（如 `countreg::zerotrunc`、`VGAM::vglm(..., family=pospoisson)`）。

DoctorVisits 数据样例

行号	visits	gender	age	income	illness	reduced	health
76	2	female	0.19	0.45	3	3	4
77	1	female	0.19	0.55	2	2	0
78	4	male	0.19	0.35	1	14	1
79	2	male	0.19	0.75	1	8	1
80	4	female	0.19	0.15	1	3	0
81	4	female	0.19	0.45	2	14	6
82	1	female	0.19	0.15	2	0	1
83	1	female	0.19	0.25	1	0	9

DoctorVisits 数据样例（续）

行号	private	freepoor	freerepat	nchronic	lchronic
76	no	no	no	no	no
77	yes	no	no	no	no
78	no	no	no	no	no
79	no	no	no	no	no
80	no	no	no	yes	no
81	yes	no	no	no	yes
82	no	yes	no	yes	no
83	no	no	yes	no	no

问题：请以全部 5190 人构建泊松回归模型，使用一个或多个解释变量来解释就诊次数的差异，检查过离散，并对模型结果进行解读。

2. 现有 10 个高等教育机构（学院或大学）的所在地区、学生数量及暴力犯罪数量等信息，具体数据如下：

高等教育机构的学生数量与暴力犯罪数量

Enrollment	type	nv	nvrate	enroll1000	region
5590	U	30	5.37	5.59	SE
1040	C	0	0	1.04	SE
35747	U	23	0.643	35.7	W
28176	C	1	0.0355	28.2	W
10568	U	1	0.0946	10.6	SW
3127	U	0	0	3.13	SW
20675	U	7	0.339	20.7	W
12548	C	0	0	12.5	W
30063	U	19	0.632	30.1	C
4429	C	4	0.903	4.43	C

- Enrollment = enrollment at the school。

- type = college (C) or university (U)。
- nv = the number of violent crimes for that institution for the given year。
- nvrate = number of violent crimes per 1000 students。
- enroll1000 = enrollment at the school, in thousands。
- region = region of the country (C = Central, MW = Midwest, NE = Northeast, SE = Southeast, SW = Southwest, and W = West)。

问题：请构建负二项回归模型，探究在控制学校类型差异的情况下，校园暴力犯罪是否存在地区差异。

补充练习（推导与诊断题）

问　上题中，研究者先用 `nvrate`（每千名学生暴力犯罪数）作因变量做线性回归，后改用 `nv` 作因变量、`log(enroll1000)` 作 offset 的 Poisson 回归，得到 Pearson $\chi^2/\mathrm{df} = 3.6$。(1) 说明 offset 的含义及其系数为何固定为 1；(2) 把学生数的单位由“千人”改为“人”，系数如何变化？(3) $\chi^2/\mathrm{df} = 3.6$ 说明什么？应如何处理？

答　(1) 设第 i 校学生数为 t_i（千人），犯罪率为 r_i，则期望犯罪数 $\mu_i = t_i r_i$，$\ln \mu_i = \ln t_i + \mathbf{x}_i^\top \boldsymbol{\beta}$。$\ln t_i$ 的系数为 1 表示犯罪数与学生数成正比，模型描述的是每千名学生的犯罪率；若不确定比例关系，可把 $\ln t_i$ 作为协变量估计系数来检验。(2) 只有截距改变，$\beta_0' = \beta_0 - \ln 1000$，其余系数（率比）不变。(3) 给定协变量后方差约为均值的 3.6 倍，存在明显过离散（或均值模型有遗漏）。先检查是否遗漏重要变量、观察是否独立，再改用负二项回归（加同样的 offset），以边界校正的 LR 检验 $\alpha = 0$，或至少使用稳健标准误；继续用 Poisson 回归会低估标准误。本例只有 10 所学校，各模型的估计都很不精确。

小结

Poisson 回归：泊松分布。负二项回归：非独立、过离散、负二项分布。分析步骤：模型构建、参数估计、假设检验、拟合优度、残差分析、模型选择、结果解释、注意事项。

7.3 附 1：泊松回归的软件实现

7.3.1 R 语言实现

R

```r
##模型拟合：Y为计数，观察时间t取对数作offset
fit <- glm(Y ~ X1+X2+X3 + offset(log(t)), family=poisson(link='log'), data=
   mydata)
summary(fit)                          ##模型拟合结果
exp(cbind(RR=coef(fit), confint.default(fit)))    ##率比及95%CI
##过离散检查：Pearson卡方/自由度
sum(residuals(fit, type="pearson")^2) / df.residual(fit)
##qcc包的检验只看Y本身的方差/均数，未调整协变量，仅供参考
library(qcc)
```

R（续）

```r
qcc.overdispersion.test(mydata$Y, type='poisson')
```

7.3.2 SPSS 软件实现

Analyze → Generalized Linear Models → Generalized Linear Models。

SPSS 泊松回归设置

选项卡/项目	设置及批注
Type of Model	Counts：Poisson loglinear；模型选择
Response	因变量
Predictors	因子型自变量、连续型自变量；Offset：偏移量
Model	Build Terms：Main effects；以主效应纳入模型；Include intercept in model
Statistics	Model Effects：Type III；Chi-square Statistics：Wald；Confidence Interval Type：Wald；Confidence Interval Level：95
Print	Case processing summary、Descriptive statistics、Model information、Goodness of fit statistics、Model summary statistics、Parameter estimates；Include exponential parameter estimates：输出 RR

7.3.3 SAS 及 Stata 实现

Stata 命令：

Stata

```
poisson y x1 x2 x3, irr exposure(t)      // t为观察时间，自动取对数作offset
poisson y x1 x2 x3, irr offset(ln_t)     // 等价写法：ln_t=ln(t)
```

SAS 软件：

SAS

```
data mydata; set mydata; ln_t = log(t); run;
proc genmod data=mydata;
  class x1 (ref='0') / param=ref;
  model y = x1 x2 x3 / dist=poisson link=log offset=ln_t
        lrci obstats residuals type1 type3;
run;
```

Poisson 回归的响应应是计数 `y`，观察时间（人年）取对数后以 `offset=` 指定。原代码的 `model y/n=...` 是二项资料的“事件/试验”写法，用于 Poisson 分布不正确；`offset=ln` 也需先在数据步算出 `ln_t=log(t)`。`scale=deviance` 会按偏差/df 放大标准误（准 Poisson），属于处理过离散的选项，不是标准 Poisson 模型的一部分。`class` 语句中用 `ref=` 明确参照组。以职业暴露资料验证：exposure 系数 0.409，RR 1.50。

7.4　附 2：负二项回归的软件实现

7.4.1　R 语言实现

过离散检验同 Poisson 模型对应代码。

R

```r
library(MASS)
fit <- glm.nb(Y ~ X1+X2+X3 + offset(log(t)), data=mydata)
summary(fit)           ##模型拟合结果；Theta = 1/alpha
1/fit$theta            ##过离散参数alpha
##过离散的似然比检验（边界问题：P值取一半）
fp <- glm(Y ~ X1+X2+X3 + offset(log(t)), family=poisson, data=mydata)
LR <- 2*(logLik(fit) - logLik(fp)); 0.5*pchisq(LR, 1, lower.tail=FALSE)
```

以癫痫资料（58 人）验证：`glm.nb(Y ~ Trt + Age + log(Base))` 得 Trt 系数 -0.397，$1/\theta = 0.127$，过离散 LR $= 12.74$，与正文表格一致。

7.4.2　SPSS 软件实现

Analyze → Generalized Linear Models → Generalized Linear Models；Type of Model → Counts → Negative binomial with log link。

7.4.3　Stata 及 SAS 实现

Stata 命令：

Stata

```
nbreg y x1 x2 x3, irr exposure(t)    // 输出alpha及 "LR test of alpha=0: chibar2
    (01)"
```

`exposure()` 接观察时间本身，`offset()` 接已取对数的观察时间，二者不能混用。加选项 `r`（稳健标准误）后，Stata 不再报告 alpha $= 0$ 的似然比检验。

SAS 命令：

SAS

```
proc genmod data=mydata;
  model y = x1 x2 / dist=negbin link=log offset=ln_t type3;   /* dist指定负二项分
   布 */
run;
```

SAS 输出的 "Dispersion" 即 NB2 的 α。

复习题

1）说明 Poisson 回归中加入 offset 的作用，以及其系数固定为 1 的含义。
答：使模型描述率而非计数；系数为 1 表示期望事件数与观察人年成正比。

2) 人年单位由“人年”改为“千人年”，说明系数的变化。
答：仅截距改变（增加 $\ln 1000$），率比不变。

3) 拟合 Poisson 回归后 Pearson $\chi^2/\mathrm{df} = 3.6$，说明其含义及对系数与标准误的影响。
答：存在过离散（或均值模型遗漏重要变量）；若均值结构正确，系数估计仍具一致性，但标准误被低估，P 值偏小。

4) 写出 NB2 负二项回归的方差函数，并说明 $\alpha \to 0$ 时的情形。
答：$\mathrm{Var}(Y) = \mu + \alpha\mu^2$；$\alpha \to 0$ 时退化为 *Poisson* 回归。

5) 说明过离散检验中 P 值取 χ^2_1 结果一半的原因。
答：$H_0 : \alpha = 0$ 位于参数空间边界，似然比统计量渐近服从 $\frac{1}{2}\chi^2_0 + \frac{1}{2}\chi^2_1$ 的混合分布。

6) 说明为满足等离散而删除计数为 0 的观察所存在的问题。
答：改变了研究总体，造成选择偏倚；剩余资料服从零截断分布，普通 *Poisson* 回归的系数有偏。

第 7 章　习题与解析

对数线性模型、泊松回归与负二项回归

作业题

数据分析题

题 7.1　新生儿情况的四维列联表

现有一批孕妇和新生儿资料，包含四个变量：吸烟与否、怀孕前是否服用某种避孕药、新生儿情况正常与否、孕妇年龄。分析吸烟和服用某种避孕药与是否有新生儿异常之间的关系。**共 6 分**。

年龄	吸烟	孕前用药	正常	不正常
≤ 29	否	否	1014	178
≤ 29	否	是	1051	210
≤ 29	是	否	330	67
≤ 29	是	是	204	58
30–34	否	否	489	85
30–34	否	是	582	144
30–34	是	否	180	42
30–34	是	是	125	31
≥ 35	否	否	119	31
≥ 35	否	是	158	53
≥ 35	是	否	35	10
≥ 35	是	是	35	20

1. 请采用对数线性模型分析该资料，并探讨变量之间的关系。（2 分）
2. 请问可否采用 Logistic 回归方法分析该资料并回答所提问题？（2 分）
3. 对数线性模型和 Logistic 回归分析方法在解决此问题上有何异同？（2 分）

题 7.2　就诊次数的泊松回归

1977/1978 年澳大利亚健康调查共收集了 5190 人的就诊次数数据（DoctorVisits），可在 R 中通过 AER 包获取。为使数据满足泊松回归要求的等离散条件，原题要求将就诊次数为 0 的观察行删除，最终得到 1049 人的数据 df.ps2。数据获取、调整命令如下：

```
install.packages("AER")
library(AER)
data("DoctorVisits")
help(DoctorVisits)
df.ps2 <- DoctorVisits[which(DoctorVisits$visits > 0), ]
```

原题数据样例字段：visits、gender、age、income、illness、reduced、health、private、freepoor、freerepat、nchronic、lchronic。

问题（2 分）： 请构建泊松回归模型，使用一个或多个解释变量来解释就诊次数的差异，并对模型结果进行解读。

本题保留原题的删零指令；方法适用性在章末说明。

题 7.3　校园暴力犯罪与地区差异

现有 10 个高等教育机构（学院或大学）的所在地区、学生数量及暴力犯罪数量等信息。**共 2 分**。

Enrollment	type	nv	nvrate	enroll1000	region
5590	U	30	5.37	5.59	SE
1040	C	0	0	1.04	SE
35747	U	23	0.643	35.7	W
28176	C	1	0.0355	28.2	W
10568	U	1	0.0946	10.6	SW
3127	U	0	0	3.13	SW
20675	U	7	0.339	20.7	W
12548	C	0	0	12.5	W
30063	U	19	0.632	30.1	C
4429	C	4	0.903	4.43	C

Enrollment 为在校人数；type 为 college(C) 或 university(U)；nv 为给定年份暴力犯罪次数；nvrate 为每 1000 学生犯罪次数；enroll1000 为千人单位在校数；region：C=Central，MW=Midwest，NE=Northeast，SE=Southeast，SW=Southwest，W=West。

问题： 请构建负二项回归模型，探究在控制学校类型差异的情况下，校园暴力犯罪是否存在地区差异。

往年题

单项选择题

题 7.4　饱和模型的残差自由度

对没有结构零的完整 $2 \times 2 \times 3$ 列联表拟合饱和对数线性模型。其残差自由度为多少?

A. 0。

B. 1。

C. 5。

D. 6。

E. 11。

题 7.5　发生率模型的偏移量

对事件次数 Y_i 建立对数连接的泊松回归，各观察单位的正暴露人时为 T_i。若目标是比较发生率，应如何处理暴露人时？

A. 将 T_i 作为结局。

B. 将 $\log T_i$ 作为系数固定为 1 的 offset。

C. 将 T_i 作为系数固定为 0 的 offset。

D. 将所有观察单位的 T_i 都改为 1。

E. 删除暴露人时不同的所有观察单位。

题 7.6　对数线性模型的变量

关于多维列联表的对数线性模型，下列说法错误的是：

A. 模型的自变量是每个格子的理论频数。

B. 模型可用格子的观测计数作为响应。

C. 对数连接作用于格子的期望频数。

D. 分类变量的主效应和交互项可用于描述联合关联结构。

E. 在适当抽样设定下，可以用泊松分布对格子计数建模。

题 7.7　列联表的折叠条件

对于对数线性模型的说法，错误的是：

A. 如果变量间的交互效应均不为 0，则合并某个变量构建压缩的列联表将歪曲变量间的关系。

B. 当变量 1 独立于其他所有变量时（$u_{13} = u_{12} = 0$），则可以完全删除变量 1 来构建列联表。

C. 当 $u_{12} = u_{123} = 0$ 时，可以把变量 1 的数据合并，得到变量 2 和变量 3 的二维列联表。

D. 当 $u_{12} = u_{123} = 0$ 时，可以把变量 2 的数据合并，得到变量 1 和变量 3 的二维列联表。

E. 当 $u_{12} = u_{123} = 0$ 时，可以把变量 3 的数据合并，得到变量 1 和变量 2 的二维列联表。

题 7.8　泊松与负二项分布

关于泊松分布与常用 NB2 参数化的负二项分布，下列哪项正确？设条件均值为 μ，负二项分布的形状参数为 $\theta > 0$。

A. 二者都只能用于均值严格小于 1 的计数。

B. 负二项分布允许响应取任意负整数。

C. 泊松条件方差为 μ；NB2 条件方差为 $\mu + \mu^2/\theta$。

D. 泊松分布的条件方差总是大于条件均值。

E. 无论 θ 如何变化，负二项分布都不可能趋近泊松分布。

名词解释

题 7.9　饱和模型（Saturated model）

名词解释：饱和模型（Saturated model）。

题 7.10　过离散（Overdispersion）

名词解释：过离散（Overdispersion）。

题 7.11　偏移量（Offset）

名词解释：偏移量（Offset）。

简答题

题 7.12　三类模型的区别与参数含义

比较 Logistic 回归模型、Poisson 回归模型、对数线性模型的区别，并说明其参数的意义。

题 7.13　Logistic 与对数线性模型的异同

比较 Logistic 回归模型与对数线性模型的异同，并说明其参数的意义。

题 7.14　对数线性模型与 Logistic

简述对数线性模型与 Logistic 回归模型的主要区别。

题 7.15　泊松过离散及处理

什么是泊松回归中的“过离散”？出现该情况应如何处理？

题 7.16　饱和模型与拟合检验

简述对数线性模型中“饱和模型”的含义及其在拟合优度检验中的作用。

计算与综合分析题

题 7.17　莱姆病、精神疾病与自杀行为

探究莱姆病与精神疾病及自杀行为之间的关联，报告 Model 1 和 Fully Model 的 IRR（incidence rate ratio）。

1. 研究采用了何种广义线性模型？基本假设是什么？（4 分）
2. 解释表格结果。（6 分）

原稿未附方法段、结果表与数值。

题 7.18　性别、年龄与饮酒年限：能否合并

原稿以男性、女性两个表分别展示青年、中年、老年和合并层中饮酒年限 A/B 与正常血压/高血压的频数。两张表结构相同，原稿以“频数 1—4”占位，未记实际数值：

性别	年龄层	A：正常/高血压	B：正常/高血压	检验
男	青年	频数 1 / 频数 2	频数 3 / 频数 4	卡方，$P < 0.001$
男	中年	频数 1 / 频数 2	频数 3 / 频数 4	卡方，$P > 0.05$
男	老年	频数 1 / 频数 2	频数 3 / 频数 4	卡方，$P > 0.05$
男	合并	频数 1 / 频数 2	频数 3 / 频数 4	卡方，$P < 0.001$
女	青年	频数 1 / 频数 2	频数 3 / 频数 4	卡方，$P < 0.001$
女	中年	频数 1 / 频数 2	频数 3 / 频数 4	卡方，$P > 0.05$
女	老年	频数 1 / 频数 2	频数 3 / 频数 4	卡方，$P > 0.05$
女	合并	频数 1 / 频数 2	频数 3 / 频数 4	卡方，$P < 0.001$

1. 根据表中结果，能否合并不同性别、不同年龄组的资料来探究饮酒年限与高血压间的关系？为什么？（3 分）
2. 可以用什么统计分析方法来判断是否可以合并？如何根据分析结果判断？（7 分）

补充练习

> **说明**
>
> 以下为配合正文新编的补充练习，按题型编排。教学设定的数据不代表真实研究结果；解析见章末。

单项选择题

题 7.19　从条件独立写出层次模型

对三个分类变量 A, B, C 建立层次对数线性模型。只要求 A 与 B 在给定 C 时条件独立，同时允许 A 与 C、B 与 C 有关。满足此要求的最一般模型应保留哪些最高阶项？各选项均默认包含所列项的全部低阶项及截距。

A. A, B, C。

B. AB, AC。

C. AB, BC。

D. AC, BC。

E. AB, AC, BC。

名词解释

题 7.20　层次模型

名词解释：层次模型（Hierarchical model）。以对数线性模型保留 ABC 交互项为例说明。

简答题

题 7.21　发热次数改为是否发热会改变什么

沿用正文“儿童接种疫苗后 1 个月发热次数”的研究。现有各儿童的发热次数及年龄组、剂量、基础疾病信息。研究者提出：“把所有正次数改为 1、零次记为 0，再做 Logistic 回归，与泊松或负二项回归得到的结论和效应指标相同；若原计数过离散，删去零次儿童即可解决。”请分两点评析。

计算与综合分析题

题 7.22　对数线性模型的自由度与筛选

正文宫颈癌病例资料中，A 为肤色（2 类）、B 为家庭收入（3 类）、C 为分娩次数（3 类）。考虑完整 $2\times3\times3$ 列联表，无结构零，使用 Poisson 抽样模型，且常规卡方近似可用。下表为正文列出的部分模型，均含相应低阶项。

模型	最高阶项	残差偏差 D
M_0	A, B, C	81.95
M_1	AC, BC	17.62
M_2	AB, AC, BC	3.22
M_S	ABC	0

1）计算各模型的自由参数个数和残差自由度。

2）以 M_S 为参照，M_2 有无明显失拟？M_1 能否代替 M_2？写出统计量、自由度及结论。

3）说明选择 M_2 的含义。是否意味着任意合并一个变量都不影响其余变量的关系？

可用 $\chi^2_{0.05,2}=5.991$、$\chi^2_{0.05,4}=9.488$。

数据分析题

题 7.23　人时、发生率与 offset 的单位

仿照正文职业暴露研究，某教学随访资料汇总如下。设不同观察单位相互独立，暂采用等离散 Poisson 模型。

年龄层	暴露	死亡数 Y	人年 T
较年轻（$A=0$）	未暴露（$E=0$）	10	1000
较年轻（$A=0$）	暴露（$E=1$）	40	2000
较年长（$A=1$）	未暴露（$E=0$）	40	2000
较年长（$A=1$）	暴露（$E=1$）	20	500

1）计算各组每千人年死亡率，并写出含年龄、暴露主效应的模型及 R 拟合语句。

2）本表恰能由主效应模型精确拟合。求截距、暴露和年龄系数；说明暴露指数系数的意义。

3）对较年长暴露组的 300 人年，模型预计有多少例死亡？若将 offset 的人时单位改为“千人年”，哪些系数改变？

文献分析题

题 7.24　负二项模型中的疫苗有效性

正文的以色列疫苗研究使用负二项回归，调整年龄、性别、日历周，并用各层实际观察人日处理暴露时间差异。疫苗有效性按 $VE=(1-IRR)\times 100\%$ 计算。

沿用这一方法，**另作教学设定**：完全接种相对未接种者的某结局调整后 $IRR=0.20$，95% CI 为 0.12–0.33；资料存在明显过离散。

1）说明选用负二项模型而非普通 Poisson 模型的理由，写出含人日 offset 的均值方程。

2）计算 VE 及其 95% 置信区间，说明为何上下限顺序需改变。

3）能否将结果表述为“每 100 名接种者必有 80 人被保护”？若把人日全部视为相同，会遗漏什么？

本次补充习题

本组按正文章节补充 20 题，题型沿用原笔记；解析及来源与新增题号对应。

第 6 章补充：对数线性模型

单项选择题

每题只有一个最佳答案，请从 A—E 中选择。

题 7.25　按层次原则删项

设 A,B,C,D 均为二分类变量，当前层次对数线性模型以最大生成项记为 $[ABC][AD][BD]$。现拟删除所有同时含 A 与 B 的交互项，并尽量保留其余原有项。应选哪一个模型？方括号内的生成项包括其全部低阶项。

A. $[ABC][AD]$。

B. $[AC][BD]$。

C. $[AB][AC][BC][AD][BD]$。

D. $[AC][BC][AD][BD]$。

E. $[A][B][C][D]$。

题 7.26　部分独立模型的拟合频数

教学设定的三维列联表拟合模型 $[AB][C]$，即 C 与 (A,B) 联合独立。已知 $n=200$，某一 $(A=i,B=j)$ 组合的边际频数 $n_{ij+}=20$，某层 $C=k$ 的边际频数 $n_{++k}=60$。各有关边际均为正，极大似然拟合频数 $\widehat{m}_{ijk}$ 为多少？

A. 1.5。

B. 6。

C. 12。

D. 20。

E. 60。

题 7.27　参数约束改变与优势比不变

在一个教学 2×2 表中，$A,B\in\{0,1\}$。采用零和约束时，拟合的交互参数为 $u_{AB}(0,0)=0.25$。改用参照水平编码，将同一组拟合频数写成 $\log m_{ab}=\gamma_0+\gamma_A a+\gamma_B b+\gamma_{AB}ab$。令 $\mathrm{OR}=m_{00}m_{11}/(m_{01}m_{10})$。正确的是哪一项？

A. $\gamma_{AB}=0.25$，$\mathrm{OR}=e^{0.25}$。

B. $\gamma_{AB}=1$，$\mathrm{OR}=e^{0.25}$。

C. $\gamma_{AB}=1$，$\mathrm{OR}=e$。

D. $\gamma_{AB}=0.25$，$\mathrm{OR}=e$。

E. $\gamma_{AB}=-1$，$\mathrm{OR}=e^{-1}$。

题 7.28　抽样零格的偏差贡献

某格为可能发生但本次未观察到的抽样零格，观察频数 $n_i = 0$，拟合频数 $\widehat{m}_i = 2.5$。采用完整的 Poisson 单格偏差贡献

$$d_i = 2\{n_i \log(n_i/\widehat{m}_i) - (n_i - \widehat{m}_i)\}, \qquad 0 \log 0 = 0,$$

及偏差残差 $r_{Di} = \operatorname{sign}(n_i - \widehat{m}_i)\sqrt{d_i}$。正确结果是哪一项？

A. $d_i = 0$，$r_{Di} = 0$。

B. $d_i = 2.5$，$r_{Di} = -\sqrt{2.5}$。

C. $d_i = 5$，$r_{Di} = \sqrt{5}$。

D. 因观察频数为零，该格必须从模型中删除。

E. $d_i = 5$，$r_{Di} = -\sqrt{5}$。

题 7.29　Logistic 交互项的对数线性对应

二分类结局 Y 与二分类预测变量 A, B, C 构成四维列联表，所有格均允许出现。拟合

$$\operatorname{logit} \Pr(Y = 1 \mid A, B, C) = \beta_0 + \beta_A A + \beta_B B + \beta_C C + \beta_{AB} AB.$$

若对预测变量 (A, B, C) 的联合边际不加限制，对应的层次对数线性模型最大生成项是哪一项？

A. $[ABC][ABY][CY]$。

B. $[AB][AC][BC][AY][BY][CY]$。

C. $[ABC][AY][BY][CY]$。

D. $[ABY][ACY][BCY]$。

E. $[ABCY]$。

题 7.30　同质关联与可折叠条件

对所有格频数均为正的 $2 \times 2 \times K$ 表，考虑 A, B 的优势比，C 为分层变量。判断下列命题。

I. 模型 $[AB][AC][BC]$ 不含三阶交互，因而各 C 层的 AB 条件 OR 相同。

II. 只要各层 AB 条件 OR 相同，折叠 C 后所得边际 OR 就一定等于该条件 OR。

III. 若 $A \perp C \mid B$，则可折叠 C 而不改变 AB 的 OR。

正确的组合是哪一项？

A. 仅 I。

B. 仅 II。

C. I、III。

D. I、II。

E. I、II、III。

简答、计算与案例分析

题 7.31　固定边际与 Poisson—二项联系

在按二分类预测变量 A,B 分成的四个组合内，研究者固定各组总数 n_{ab}，记录二分类结局 Y 的两格频数。目标模型为 $\operatorname{logit} p_{ab} = \beta_0 + \beta_A a + \beta_B b$。现分别拟合 Poisson 对数线性模型 $M_1 = [AB][AY][BY]$ 与 $M_2 = [A][B][AY][BY]$。

1) 哪个模型通常用于与上述二项 Logistic 分析对应？说明对固定边际所作的处理。
2) 用似然分解解释其依据。
3) 若 M_2 仍给出某次与 Logistic 相近的系数，能否据此认定两者在一般情形下等价？

题 7.32　整体失拟与局部残差

以下为教学构造的 $2\times2\times2$ 频数表，各格均可发生。拟合条件独立模型 $[AC][BC]$。

C	A	$B=0$	$B=1$
0	0	12	8
0	1	18	12
1	0	15	5
1	1	5	15

1) 求各格拟合频数，计算 Pearson 统计量 X^2、似然比统计量 G^2 与自由度。可用 $\Pr(\chi^2_2 \geq 10.465) = 0.00534$。
2) 计算 $C=1, A=0, B=0$ 格的 Pearson 残差 r_P。该格杠杆值为 $h = 0.75$，再求调整残差 $r_P/\sqrt{1-h}$。
3) 有人说“所有普通 Pearson 残差的绝对值都小于 2，因此模型拟合良好”，该说法是否成立？

题 7.33　官方内置教学列联表的输出阅读

R 内置 HairEyeColor 表为 $4\times4\times2$，总频数 592。发色 H 与眼色 E 的二维表源于学生调查；性别 S 分层由后续作者为教学补入并调整，因此这里的 32 格作为教学表使用。用完整表重新拟合 Poisson 对数线性模型，得到

模型	剩余自由度	G^2
$M_0 = [HE][S]$	15	19.8566
$M_1 = [HE][HS][ES]$	9	6.7613

M_0 中“金发、蓝眼、男性”格的观察频数为 30，拟合频数为 44.3007，杠杆值 $h = 0.555235$。已知 M_0 整体拟合检验 $P = 0.1775$；$\Pr(\chi^2_6 \geq 13.0953) = 0.04155$。

1) 写出 M_0 的独立性含义，比较两模型并说明差异自由度的来源。
2) 为什么 M_0 整体检验未拒绝，而 M_0 对 M_1 的比较可在 0.05 水平拒绝？
3) 计算指定格的调整 Pearson 残差，并说明从该格能得出什么结论。

题 7.34　录取数据中的折叠与同质性

以下为 R 内置 UCBAdmissions 记录的 1973 年加州大学伯克利分校六个大院系录取资料，共 4526 名申请者。A 表示录取，G 表示性别，D 表示院系。

院系	男录取	男未录取	女录取	女未录取
A	512	313	89	19
B	353	207	17	8
C	120	205	202	391
D	138	279	131	244
E	53	138	94	299
F	22	351	24	317

完整表重新拟合结果为：条件独立模型 $[AD][GD]$ 的 $G^2 = 21.7355$、剩余自由度 6；同质关联模型 $[AG][AD][GD]$ 的 $G^2 = 20.2043$、剩余自由度 5。两模型比较 $P = 0.2159$，而同质关联模型对饱和模型的拟合检验 $P = 0.00114$。某报告称：“控制院系后性别项不显著，说明各院系均不存在性别关联；粗 OR 可直接反映性别的因果影响。”

1）计算男性相对女性录取的粗 OR，以及 A 院系与 C 院系的条件 OR。

2）结合两个检验，评议报告关于同质性及无关联的说法。

3）说明这张观察性列联表支持怎样的结论，因果解释还缺少哪些信息。

第 7 章补充：泊松回归与负二项回归

单项选择题

每题只有一个最佳答案，请从 A—E 中选择。

题 7.35　事件率与至少一次事件的概率

教学设定某类可重复发生事件的恒定率为每人每月 1.5 次，个体间及不相交时段的计数独立。某人观察 2 个月，计数服从 Poisson 分布。以下哪一项正确？

A. 率为 1.5 大于 1，因此不可能建立 Poisson 模型。

B. 2 个月内至少发生一次事件的概率为 3。

C. 2 个月内计数均数为 1.5，至少发生一次的概率为 $1 - e^{-1.5}$。

D. 2 个月内计数均数为 3，至少发生一次的概率为 $1 - e^{-3} \approx 0.9502$。

E. 2 个月内计数均数为 3，至少发生一次的概率为 $e^{-3} \approx 0.0498$。

题 7.36　同协变量分组的合并率估计

教学设定两个独立观察组具有相同协变量和共同事件率 λ。第一组 100 人年内观察到 4 次事件，第二组 300 人年内观察到 3 次事件；计数分别服从均数 100λ 和 300λ 的 Poisson 分布。λ 的极大似然估计为多少次/人年？

A. 0.0175。

B. 0.0250。

C. 0.0350。

D. 0.0400。

E. 0.0100。

题 7.37　准 Poisson 的尺度调整

教学设定某 Poisson 拟合的一个系数估计为 $\hat{\beta} = -0.4$、模型标准误为 0.1；Pearson 统计量为 147.2，剩余自由度为 46。保持相同样本、公式、连接函数及权重，改用准 Poisson，按 $\widehat{\phi} = X_P^2/\mathrm{df}$ 估计尺度；按 R 的约定，估计尺度后的系数检验使用 t 分布。正确的结果是哪一项？

A. $\hat{\beta} = -1.28$，标准误为 0.32。

B. $\hat{\beta} = -0.4$，标准误约 0.1789，检验量约 -2.236，参照 t_{46}。

C. $\hat{\beta} = -0.4$，标准误仍为 0.1，检验量为 -4。

D. $\hat{\beta} = -0.125$，标准误约 0.0559。

E. $\hat{\beta} = -0.4$，标准误为 0.32，检验量为 -1.25。

题 7.38　总样本的方差均数比能说明什么

教学设定 X 以相同概率取 0 或 1，且 $Y \mid X = 0 \sim \mathrm{Poisson}(1)$、$Y \mid X = 1 \sim \mathrm{Poisson}(9)$。以下关于边际分布及条件模型的判断，哪一项正确？

A. $E(Y) = 5$、$\mathrm{Var}(Y) = 5$，边际分布必为 Poisson。

B. $E(Y) = 5$、$\mathrm{Var}(Y) = 16$，所以条件 Poisson 假定不可能成立。

C. $E(Y) = 10$、$\mathrm{Var}(Y) = 21$。

D. $E(Y) = 5$、$\mathrm{Var}(Y) = 21$，足以证明给定 X 后仍有过离散。

E. $E(Y) = 5$、$\mathrm{Var}(Y) = 21$；边际方差较大可由两组均数不同产生，不能据此否定已给定的条件 Poisson 模型。

题 7.39　NB2 与准 Poisson 的方差形状

教学设定采用 NB2 参数化 $\mathrm{Var}(Y \mid x) = \mu + \alpha\mu^2$，$\alpha = 0.5$。两种协变量组合的均数分别为 2 和 8。若试图用同一个准 Poisson 尺度 ϕ 使 $\mathrm{Var}(Y \mid x) = \phi\mu$ 在这两个均数处都相同，以下哪一项正确？

A. NB2 方差分别为 3 和 12，取 $\phi = 1.5$ 即可。

B. NB2 方差分别为 4 和 16，取 $\phi = 2$ 即可。

C. NB2 方差分别为 4 和 40，对应方差均数比分别为 2 和 5，不能用同一个 ϕ 精确匹配两处。

D. NB2 方差分别为 2 和 8，取 $\phi = 1$ 即可。

E. 只要 $\alpha = 0.5$，就总能取 $\phi = 0.5$ 使两种模型相同。

题 7.40　均值、相关性与零概率

判断以下命题。I 中的估计均假定存在唯一有限解；III 中 $\mu > 0, \alpha > 0$。

I. 相同样本、设计矩阵、权重与 log 连接下，Poisson 与准 Poisson 具有相同的回归系数估计。

II. 对同一受试者的多次计数直接拟合独立 NB2 模型，就自动处理了受试者内相关。

III. 在相同均数 μ 下，NB2 的零概率 $(1 + \alpha\mu)^{-1/\alpha}$ 大于 Poisson 的零概率 $e^{-\mu}$。

正确的组合是哪一项?

A. 仅 I。

B. 仅 II。

C. I、II。

D. I、III。

E. I、II、III。

简答、计算与案例分析

题 7.41　基线计数能否当作 offset

某重复事件研究中，所有患者基线观察 8 周，记录事件数 B_i；随后随访 T_i 周，记录事件数 Y_i。研究者希望估计随访期事件率。对 $B_i > 0$ 的患者，教学模型写为

$$\log E(Y_i \mid B_i, x_i, T_i) = \log T_i + \beta_0 + \gamma \log B_i + \beta_x x_i.$$

设 $\widehat{\gamma} = 0.8$。

1）在其他条件不变时，B_i 加倍与 T_i 加倍分别意味着怎样的均数变化?

2）能否仅因 B_i 是计数，就把 $\log B_i$ 也当成系数固定为 1 的 offset?

3）应如何看待基线 $B_i = 0$ 者，以及所有随访均为 2 周时的 $\log T_i$?

题 7.42　年龄交互与率比对比

以下为教学构造的独立 Poisson 组计数。$A = 1$ 为高年龄组，$E = 1$ 为暴露组，人时 T 的单位为人年。

A	E	事件数 Y	人时 T
0	0	20	1000
0	1	40	1000
1	0	60	1000
1	1	45	1000

拟合 $\log \mu = \log T + \beta_0 + \beta_E E + \beta_A A + \beta_{EA} EA$，重新计算得到 $\hat{\beta}_E = 0.693147$、$\hat{\beta}_{EA} = -0.980829$，以及

$$\mathrm{Var}(\hat{\beta}_E) = 0.075000, \quad \mathrm{Var}(\hat{\beta}_{EA}) = 0.113889, \quad \mathrm{Cov}(\hat{\beta}_E, \hat{\beta}_{EA}) = -0.075000.$$

1）求两个年龄层内暴露相对未暴露的发生率比，以及两层率比之比。

2) 求高年龄层率比的 95% Wald 置信区间，取 $z_{0.975} = 1.96$。

3) 预测高年龄暴露组 500 人年内的期望事件数。此四组资料能否检验该含交互模型的整体拟合优度?

题 7.43　完整就诊资料的计数模型输出

使用 AER 公开 DoctorVisits 全部 5190 人的资料，保留全部零就诊者。结局为过去两周就诊次数，其中 4141 人计数为 0。Poisson 和 NB2 均包含性别、年龄、年龄平方、收入、疾病数 illness、减少活动天数 reduced、健康评分、三种保险指标及两种慢病指标，共 13 个均数参数。基于完整数据的本次 Python 复算摘要如下；NB2 的标准误采用估计 α 下的 GLM 期望信息矩阵。

项目	Poisson	NB2
$\hat{\beta}_{\text{illness}}$	0.186948	0.214341
$\hat{\beta}_{\text{reduced}}$	0.126846	0.143754
$SE(\hat{\beta}_{\text{reduced}})$	0.005034	0.007311
Pearson 统计量 X^2_P	6873.982	5180.054
剩余自由度 $n-p$	5177	5177
$\hat{\alpha}$	0	1.077038
预测零就诊人数 $\sum_i \widehat{P}(Y_i=0)$	4013.761	4172.744

采用 NB2 方差 $\mu+\alpha\mu^2$，零概率 $(1+\alpha\mu)^{-1/\alpha}$。

1) 解释 NB2 中疾病数增加 1 的条件均数比，求减少活动天数增加 1 所对应均数比的 95% Wald 区间，取 $z_{0.975} = 1.96$。

2) 若仅在相同均数 $\mu = 0.5$ 下比较两种分布，求 NB2 方差与零概率，并与 Poisson 零概率比较。

3) 计算 Poisson 的 Pearson 尺度。结合观察与预测零人数，能否仅凭这些摘要认定必须采用零膨胀模型，或认定 NB2 已完全拟合资料?

题 7.44　校园犯罪案例的代码与版本审阅

教材作者公开的校园犯罪文件共有 81 校；其中 Enrollment = 5590、事件数 30 的一校每千人率为 5.3667，且这是唯一每千人率不低于 5 的学校。另一校原始在校人数为 540、事件数 0、enroll1000 = 0.54。其余 79 校的在校人数均大于 1000。按所核对的教材网页代码整理，先合并东南与西南地区，再保留每千人率小于 5 的学校，得到 80 行 `c.data`，随后执行:

```
c.data2 <- transform(c.data,
  enroll1000 = pmax(enroll1000, 1))
fit <- MASS::glm.nb(nv ~ type * region,
  offset(log(enroll1000)), data = c.data2)
```

本题提供现行函数形参次序 `glm.nb(formula,data,weights,...)`；R 先匹配有名字的实参，再把剩余未命名实参按位置匹配。

1) 说明这段处理中的 81 校、80 行数据及 540 人学校分别发生了什么，是否只是改变人数的计量单位。

2) 分析第二个未命名实参实际上匹配到什么；540 人学校在该调用中的数值权重是多少？$\log(0.54) < 0$ 本身是否妨碍它作为 offset？

3) 给出将原始每千人在校人数正确用作 offset 的核心公式，并说明删除高率学校后的分析应如何报告与核查。

习题解析

核对方式

按题号核对。缺失选项的补写及新编练习均在对应解析末尾说明。

作业题

解析　题 7.1　新生儿情况的四维列联表

返回题目

(1) 令 1= 新生儿情况、2= 孕前用药、3= 吸烟、4= 年龄，格子均数 m_{hijk}。四维饱和模型为

$$\log m = u + \sum_{a} u_a + \sum_{a<b} u_{ab} + \sum_{a<b<c} u_{abc} + u_{1234},$$

各项分别表示主效应、两变量、三变量和四变量交互；下标还包含对应水平，估计时需要识别约束。用层次模型逐步筛选并检验拟合。

模型	残差 df	G^2	P
仅主效应	18	107.051	< 0.001
所有两变量交互	9	6.884	0.649
所有三变量交互	2	2.299	0.317
保留 12、13、14、23、24	11	8.548	0.664

评分稿的选择过程：从独立模型依次增加 23、14、24、12、13，所得偏差依次约 57.045、39.440、24.229、15.602、8.548；残差自由度依次 17、15、13、12、11。最后加入 34 的改善为 $\Delta G^2 \approx 1.664$、$\Delta df = 2$、$P \approx 0.435$，无明确改善。原稿此处自由度写 1 有误。

所选模型保留新生儿与用药、吸烟、年龄的关联，以及用药与吸烟、年龄的关联；未保留吸烟—年龄的两变量项。Pearson 残差约在 -0.82 至 1.47 之间，未见明显异常格子，但残差小不能证明模型唯一最优。**未保留某交互项不自动允许任意折叠列联表，合并必须检查相应可折叠条件**。

(2) 令异常为 1、正常为 0，用药、吸烟为 0/1，以年龄 ≤ 29 为参照，$A_2 = I(30\text{–}34)$、$A_3 = I(\ge 35)$：

$$\operatorname{logit} p = -1.791 + 0.233\,drug + 0.227\,smoke + 0.095 A_2 + 0.489 A_3.$$

用药 OR=1.262（1.093–1.457），吸烟 OR=1.254（1.061–1.483），年龄 ≥ 35 OR=1.631（1.293–2.058），均有统计学证据；30–34 岁 OR=1.100（0.940–1.286），证据不足。解释为控制其他因素后的异常优势比，不是概率比。

(3) 都可用 GLM 框架与极大似然研究分类资料关联。对数线性模型拟合格子计数的均数、用 log 连接，研究分类变量的联合关联；Logistic 模型明确二分类结局、用 logit 连接，估计条件 OR，自变量亦可连续。二者在相容的模型设定下可对应，但不能把所有对数线性主效应都解释成 OR。关于稀疏格子的渐近检验要谨慎；“80% 期望频数大于 5” 不是一切建模情境的必要条件。

解析 题 7.2　就诊次数的泊松回归

返回题目

原评分口径。 删零后 1049 条记录，边际方差/均数比 0.921，过离散检验 $P = 0.968$；用原题筛选结果：

$$\log \mu_i = 0.340 - 0.177 income_i + 0.056 reduced_i - 0.092 I(freerepat_i = \text{yes}).$$

其中 $\mu_i = E(visits_i \mid X_i)$，不能写成 $\text{logit}(visits)$，也不能把左侧直接写成随机观测值的对数。

变量	系数	SE	P	e^{β}
income	−0.1768	0.0807	0.0284	0.8379
reduced	0.0557	0.0045	< 0.001	1.0573
freerepat=yes	−0.0922	0.0595	0.1212	0.9119

其他条件相同时，income 每增加数据所用 1 万货币单位（AER 文档称 dollars），预期两周就诊次数乘 0.838；减少活动天数每增加 1 天，预期就诊次数乘 1.057。freerepat 点估计低约 8.8%，但证据不足。原材料把 $e^{0.056}$ 写成 1.507，应为约 1.058（精确系数给 1.0573）。

方法校正。 删除 0 不是让一般计数资料满足泊松假定的标准方法：选择后分布为零截断分布，且把“是否就诊”的信息丢掉。等离散针对给定协变量后的条件均值和方差，不能只用原始边际方差/均数判定。若分析原 5190 人，可考虑完整计数模型；若仅分析正计数者，应考虑零截断泊松/负二项等与抽样机制相符的方法。课程复现与方法建议须分别报告。

解析 题 7.3　校园暴力犯罪与地区差异

返回题目

计数结局为 nv，暴露机会为 enroll1000：

$$Y_i \sim \text{NB}(\mu_i, \theta), \qquad \log \mu_i = \log(enroll1000_i) + \beta_0 + \beta_U I(U) + \sum_r \beta_r I(region = r).$$

以 college、Central 为参照，offset 系数固定为 1。正确 R 语法：

```
fit <- MASS::glm.nb(
  nv ~ type + region + offset(log(enroll1000)), data = campus)
```

原评分数值（仅供核对原稿）。 原材料给出截距 0.511、$U = 2.567$、SE = 0.318、SW = −3.472、$W = -0.397$，对应 U 的 13.026、SW 的 0.031。原材料的调用和输出显示 `weights = offset(log(enroll1000))`，实际把 offset 误传给权重；这些数值不可作为正确率模型的答案。原材料还误对 Enrollment 作“犯罪次数”的离散检验，并在文字中把 SW 写为 9.7%。

整理者复算。 按公式正确加入 offset，普通 `glm.nb` 迭代趋近泊松边界并发出收敛警告；固定离散参数后优化系数的剖面核对也显示似然趋向 $\theta \to \infty$ 的泊松边界，不能把原默认迭代当稳定的有限负二项估计。应检视剖面似然、不同初值、收敛状态，以及极小样本的推断稳定性；地区的整体效应应以含地区和不含地区的嵌套模型作联合检验。按 R 默认迭代的边界解，系数约 −2.037、1.743、1.942、−2.325、−0.423，仅作为故障复现，**不据此作最终显著性结论**。

原始 10 行数据与可运行代码均已附上。本题以正确模型形式、offset 和结果核验方法作为可靠解答；原评分的系数已明确标出算法错误来源。

边界模型的条件性结果。 泊松极限的系数为 −2.0373、1.7428、1.9426、−2.3251、−0.4230，对应同类型学校 SE/C 约 6.98、SW/C 约 0.098、W/C 约 0.655。该泊松模型中地区联合似然比

$G^2 = 85.18, df = 3, P < 0.001$，提示地区差异，但残差偏差 17.51/5 自由度、样本仅 10 个机构，不能将此当作通过诊断的稳健负二项推断。答题应说明这些条件和小样本限制。

往年题

解析 题 7.4　饱和模型的残差自由度

返回题目

答案：A。

饱和模型能逐格拟合全部 12 格计数，残差自由度为 0。固定总数约束会同时改变独立观测信息和参数自由度，不改变此残差自由度。

补写说明。原稿第 14 题整题缺失；本题为新编练习，并非恢复的往年原题。

解析 题 7.5　发生率模型的偏移量

返回题目

答案：B。

$\log E(Y_i \mid X_i) = \log T_i + X_i^T\beta$，等价于 $\log\{E(Y_i \mid X_i)/T_i\} = X_i^T\beta$。因此指数斜率对应发生率比。

补写说明。原稿第 15 题整题缺失；本题为新编练习，并非恢复的往年原题。

解析 题 7.6　对数线性模型的变量

返回题目

答案：A。

A 项错误。响应是各格观测计数，模型拟合其期望频数 m，log 连接作用于 m；解释项来自分类变量的主效应及交互。不能说理论频数是自变量。

补写说明。原稿仅记“自变量是每个格子的理论频数”，保留为 A；提问句及 B—E 为补写。

解析 题 7.7　列联表的折叠条件

返回题目

答案：E。

按回忆题的通常意图选 E：$u_{12} = u_{123} = 0$ 表示 1 与 2 给定 3 条件独立，但 1、2 都可能关联于 3；边际化 3 后可以出现 1 与 2 关联。C、D 保留的另两变量关系可按相应可折叠条件讨论。

原稿细节。B 文字说“变量 1 独立于其他所有变量”，这是充分条件；括号仅列 $u_{12} = u_{13} = 0$ 未列 $u_{123} = 0$，在一般饱和参数化下不完整。A 也属于课程概括，不能当不附条件的普遍定理。因回忆稿措辞不严谨，E 是命题意图下的答案。

解析 题 7.8　泊松与负二项分布

返回题目

答案：C。

二者均可描述非负整数计数。泊松条件均值和方差相等；常用 NB2 参数化为 $E(Y \mid X) = \mu$、$\mathrm{Var}(Y \mid X) = \mu + \mu^2/\theta$，$\theta > 0$，允许过离散；$\theta \to \infty$ 趋于泊松。不能仅凭边际样本方差大于均数就断言条件泊松回归必不适用。

补写说明。原稿只有比较主题；提问句及全部选项为补写。

解析 题 7.9　饱和模型（Saturated model）

返回题目

具有足够自由参数使每个独立观测单元的拟合均值与观测值相同的模型。在完整分类列联表中含所有主效应与各阶交互。其相对自身偏差为 0，残差自由度为 0，不能据此作常规卡方拟合检验。

解析 题 7.10　过离散（Overdispersion）

返回题目

相对于所指定分布的方差，实际条件变异更大。泊松情形指 $\mathrm{Var}(Y \mid X) > E(Y \mid X)$，应先检查遗漏因素、聚集和模型形式，再考虑负二项或准似然。

解析 题 7.11　偏移量（Offset）

返回题目

线性预测子中系数固定为 1 的已知项。发生率建模常将观察人时/暴露机会的对数作为 offset，使计数均值与暴露机会成比例。

解析 题 7.12　三类模型的区别与参数含义

返回题目

二项 Logistic：$Y_i \sim \mathrm{Binomial}(n_i, p_i)$，$\log[p_i/(1-p_i)] = X_i^T\beta$，$e^{\beta_j}$ 解释为控制其他变量后的 OR。

泊松回归：$Y_i \sim \mathrm{Poisson}(\mu_i)$，$\log \mu_i = X_i^T\beta$；同等暴露机会下指数系数为预期计数比。加入 $\log T_i$ 的 offset 后，为发生率比 IRR。

对数线性模型：对多维列联表各格计数建模，$\log m_{ijk} = u + u_i^A + u_j^B + u_k^C + \cdots$；研究分类变量联合分布中的关联/条件独立，原分类变量地位对称。主效应和交互项含义取决于编码；OR 由相应格子均数比或参数对比得到，不能一律对任何参数取指数就称 OR。

三者均可纳入 GLM 框架，常用极大似然估计。Logistic 明确指定结局，后两者使用 log 连接，分析单位、随机部分与参数解释不同。模型本身不保证因果关系。

解析 题 7.13　Logistic 与对数线性模型的异同

返回题目

二项 Logistic：$Y_i \sim \mathrm{Binomial}(n_i, p_i)$，$\log[p_i/(1-p_i)] = X_i^T\beta$，$e^{\beta_j}$ 解释为控制其他变量后的 OR。

泊松回归：$Y_i \sim \mathrm{Poisson}(\mu_i)$，$\log \mu_i = X_i^T\beta$；同等暴露机会下指数系数为预期计数比。加入 $\log T_i$ 的 offset 后，为发生率比 IRR。

对数线性模型：对多维列联表各格计数建模，$\log m_{ijk} = u + u_i^A + u_j^B + u_k^C + \cdots$；研究分类变量联合分布中的关联/条件独立，原分类变量地位对称。主效应和交互项含义取决于编码；OR 由相应格子均数比或参数对比得到，不能一律对任何参数取指数就称 OR。

三者均可纳入 GLM 框架，常用极大似然估计。Logistic 明确指定结局，后两者使用 log 连接，分析单位、随机部分与参数解释不同。模型本身不保证因果关系。

原材料关于“对数线性模型交互参数的指数必为 OR”的说法需要编码条件。例如二元变量采用参照编码时特定二阶交互系数可对应 log OR；一般多水平/效应编码下应计算适当线性对比。

解析 题 7.14　对数线性模型与 Logistic

返回题目

对数线性拟合列联表格子期望计数的 log，分析分类变量的联合关联；Logistic 指定二分类结局，拟合其条件概率的 logit，自变量可分类或连续，指数斜率解释为条件 OR。两种方法都不能仅靠模型建立因果关系。

解析 题 7.15　泊松过离散及处理

返回题目

给定协变量后的方差超过泊松条件均值。先检查遗漏的系统差异、相关性、零膨胀、暴露机会与异常点；再考虑负二项、准泊松、稳健方差或适合设计的相关资料模型。单纯删除零值不是标准处理办法。

解析 题 7.16　饱和模型与拟合检验

返回题目

完整列联表中含全部主效应和交互项，能拟合每格观测计数。待检验模型的偏差（总数匹配时）为：$D = 2(\ell_{\text{sat}} - \ell_{\text{fit}})$，是与饱和模型的似然比较。常规条件下可与相应自由度的卡方分布比较；较大 P 只表示失拟证据不足，不证明正确。

解析 题 7.17　莱姆病、精神疾病与自杀行为

返回题目

命题通常指泊松回归，用人时作为暴露机会，$\log E(Y \mid X) = \log T + X^T\beta$，$e^{\beta}$ 为发生率比。条件独立、均值模型正确、条件等离散为基本考虑；若过离散应考虑合适的扩展。**仅凭 IRR 不能唯一判断泊松或负二项模型**，需要原文方法。

解释须注明暴露/参照、具体结局、IRR 与 95% CI，并比较 Model 1 和 Fully Model 的调整变量及估计变化；区别调整后关联与因果效果。无原表不能补填“哪些结局显著”或给出数值。

解析 题 7.18　性别、年龄与饮酒年限：能否合并

返回题目

只比较各层 P 值不能决定是否合并。“青年显著、中老年不显著”并非效应存在异质性的充分证据；合并后的显著性也不能证明可以忽略年龄、性别。

可用分层 OR 及其齐性检验（如 Breslow–Day），或 Logistic 模型中的饮酒 × 年龄、饮酒 × 性别交互；也可采用四维列联表对数线性模型，保留层次结构，比较相关交互项模型。若效应有异质性，应报告分层/交互效应；若无明确异质性，再结合混杂、效应尺度和可折叠条件决定报告调整后的共同效应还是简单合并。统计“不显著”亦不证明等效。实际频数缺失，不能计算 OR、齐性检验或最终合并结论。

补充练习

解析 题 7.19　从条件独立写出层次模型

返回题目

答案：D。 该条件独立模型为

$$\log m_{ijk} = u + u_i^A + u_j^B + u_k^C + u_{ik}^{AC} + u_{jk}^{BC}.$$

删去 AB 与 ABC 项，允许 AC、BC 存在。A 项还额外要求三者相互独立，约束过强，因而不是题设“只要求”该条件独立时的最一般模型。条件独立亦不自动意味着边际表中 A 与 B 独立。

解析 题 7.20　层次模型

返回题目

层次模型遵循：保留一个高阶交互项时，必须同时保留由该项中变量构成的全部低阶项。若保留 ABC，应包含 AB, AC, BC、A, B, C 及截距；若仅以 AC, BC 作为最高阶项，则包含 A, B, C 及截距，但不必包含 AB 或 ABC。模型简化应保持这种层次结构，不能保留高阶交互却仅因某个主效应不显著而将其单独删去。

解析 题 7.21　发热次数改为是否发热会改变什么

返回题目

（1）研究问题和指标改变。 计数模型分析预期发热次数；同样观察期下，指数系数是预期计数比，也可解释为次数发生率比。二分类 Logistic 分析的是 $P(Y \geq 1)$，指数系数为至少发热一次的优势比。二分类化丢失多次发热信息，系数数值、显著性和结论不保证相同。

（2）删零不能作为纠正过离散的方法。 零次也是计数资料的合法结果。删去零次会把研究人群改为至少发热一次者，并改变抽样分布。应检查给定协变量后的变异、模型形式和异常记录，结合正文的过离散诊断考虑负二项回归。观察到原始方差大于均值只是线索，不能单凭这一点替代模型诊断。

解析 题 7.22　对数线性模型的自由度与筛选

返回题目

（1） 总格子数 18。截距 1 个；主效应各有 1, 2, 2 个参数；AB, AC, BC 项各有 2, 2, 4 个；ABC 项有 4 个。

模型	自由参数个数	残差自由度
M_0	6	12
M_1	12	6
M_2	14	4
M_S	18	0

（2） M_2 相对饱和模型的偏差 3.22，自由度 4，$P \approx 0.522$，没有明显失拟证据。由 M_2 删去 AB 得到 M_1，

$$\Delta D = 17.62 - 3.22 = 14.40, \quad \Delta df = 6 - 4 = 2.$$

$P \approx 0.00075$，删去 AB 造成明显拟合损失，故不宜以 M_1 替代 M_2。这里 AB 有 2 个自由参数，不能因“只删了一个交互项”就写 $df = 1$。

（3） M_2 为两两关联模型，保留三种两变量关联，未保留三变量交互；此选择兼顾简洁与拟合。允许某项存在不等于仅凭模型名称便完成该项的显著性检验，仍应看相应模型比较。没有三变量交互不代表无混杂或任意可折叠；保留两两关联时，不能直接忽略第三变量。

解析 题 7.23　人时、发生率与 offset 的单位

返回题目

（1） 四行死亡率依次为 10、20、20、40 例/千人年。

$$Y_i \sim \text{Poisson}(\mu_i), \qquad \log \mu_i = \log T_i + \beta_0 + \beta_E E_i + \beta_A A_i.$$

```
fit <- glm(Y ~ E + A + offset(log(T)),
           family = poisson(link = "log"), data = dat)
```

offset 作用于已知人时的对数，系数固定为 1；不要把人时对数误放进权重。

(2) 以人年计，$\hat{\beta}_0 = \log 0.01 = -4.6052$、$\hat{\beta}_E = \log 2 = 0.6931$、$\hat{\beta}_A = \log 2 = 0.6931$。控制年龄后，暴露者死亡发生率为未暴露者的 2 倍。不能仅比死亡**人数**；例如年轻层 40 与 10 之比为 4，但人时也相差 2 倍。

(3) 该组死亡率为 $0.01 \times 2 \times 2 = 0.04$ 例/人年，300 人年预计 $300 \times 0.04 = 12$ 例。若用 $T^* = T/1000$，

$$\log T = \log T^* + \log 1000,$$

新截距为 $\beta_0^* = \beta_0 + \log 1000 = \log 10 = 2.3026$，两个斜率、发生率比和预计死亡数均不变。本表为教学设定，精确拟合本身不证明真实数据必然满足等离散。

解析 题 7.24　负二项模型中的疫苗有效性

返回题目

(1) 负二项分布允许条件方差大于条件均值，可用于正文讨论的过离散计数。令 $V_i = 1$ 为完全接种、T_i 为人日、Z_i 为调整变量，

$$Y_i \sim \mathrm{NB}, \qquad \log \mu_i = \log T_i + \beta_0 + \beta_V V_i + \gamma^T Z_i.$$

e^{β_V} 为调整后的发生率比。是否适合仍须结合模型诊断，不能把负二项模型视为对一切依赖结构的自动修正。

(2) $\widehat{VE} = (1 - 0.20) \times 100\% = 80\%$。因 $1 - IRR$ 随 IRR 递减，区间应反向变换：

$$95\%\, CI = [(1 - 0.33) \times 100\%, (1 - 0.12) \times 100\%] = [67\%, 88\%].$$

(3) 不能。这是接种组相对参照组的发生率降低比例，不是每 100 人中受保护者的确定人数，也不是绝对风险下降 80 个百分点。忽略各组实际观察人日，会混淆暴露机会差异与发生率差异。以上 0.20 及其区间为本题教学数值，不能引用为原研究结论。

本次补充习题解析

第 6 章补充解析

解析　题 7.25　按层次原则删项

返回题目

答案：D。原模型包括 AB, AC, BC, ABC, AD, BD 及相应主效应。凡同时含 A, B 的项均须删除，故删去 AB 和 ABC；AC, BC, AD, BD 均可保留。删去 AB 却保留 ABC 不满足题意，也破坏层次原则；删除其他允许保留的交互项则额外施加了本题未要求的独立性约束。

来源与改编：知识点配套。题干与设问为新编；参考依据[31]、[32]。

解析　题 7.26　部分独立模型的拟合频数

返回题目

答案：B。模型允许 A, B 任意关联，但要求其联合分布与 C 独立，因此 $\hat{p}_{ijk} = (n_{ij+}/n)(n_{++k}/n)$，有

$$\widehat{m}_{ijk} = \frac{n_{ij+} n_{++k}}{n} = \frac{20 \times 60}{200} = 6.$$

不能把 $[AB][C]$ 误读为三个变量完全独立；拟合时保留的是 AB 联合边际和 C 边际。

来源与改编：知识点配套。题干与设问为新编；参考依据[31]、[32]。

解析　题 7.27　参数约束改变与优势比不变

返回题目

答案：C。零和约束下四个交互参数依次为 $0.25, -0.25, -0.25, 0.25$，故

$$\log \mathrm{OR} = 0.25 + 0.25 - (-0.25) - (-0.25) = 1.$$

参照编码下，同一个四格对数交叉差等于 γ_{AB}，所以 $\gamma_{AB} = 1$、$\mathrm{OR} = e$。约束改变了系数数值与解释方式，拟合频数和由其计算的 OR 保持不变。

来源与改编：知识点配套。题干与设问为新编；参考依据[31]。

解析　题 7.28　抽样零格的偏差贡献

返回题目

答案：E。代入得 $d_i = 2\{0-(0-2.5)\} = 5$，且观察值小于拟合值，所以 $r_{Di} = -\sqrt{5} \approx -2.2361$。在总拟合频数等于总观察频数时，整体偏差的线性项可相消；这种整体简化不能用于判定某一个零格的偏差贡献。抽样零格仍提供信息，不能与不可能发生的结构零格混同。

来源与改编：知识点配套。题干与设问为新编；参考依据[31]、[33]。

解析　题 7.29　Logistic 交互项的对数线性对应

返回题目

答案：A。与结局 Y 无关的 $[ABC]$ 饱和边际允许预测变量任意关联。Logistic 中的 AB 交互对应对数线性模型中的 ABY 三阶交互；C 主效应对应 CY。$[ABY]$ 还自动包含 AY, BY 及相关低阶项。选项 C 遗漏 Logistic 中的 AB 交互，选项 E 则额外允许 AC, BC, ABC 改变结局的对数优势。

来源与改编：知识点配套。题干与设问为新编；参考依据[31]。

解析　题 7.30　同质关联与可折叠条件

返回题目

答案：C。 I 正确：无三阶交互意味着 AB 对数 OR 不随 C 层改变。II 错误：同质性本身不足以保证可折叠。例如两层表分别为 $\left(\begin{smallmatrix}10 & 20\\ 30 & 120\end{smallmatrix}\right)$ 与 $\left(\begin{smallmatrix}10 & 80\\ 60 & 960\end{smallmatrix}\right)$，两层 OR 均为 2，合并后 OR 为 2.4。III 正确：$A \perp C \mid B$ 时，A 在给定 B 后的分布不随 C 变化，条件 OR 等于折叠后的 OR。这是可折叠的充分条件。

来源与改编：知识点配套。题干与设问为新编；参考依据[31]。

解析　题 7.31　固定边际与 Poisson—二项联系

返回题目

应选 M_1。其 AB 边际饱和，允许四个预测变量组合有各自的总均数，并使拟合的 AB 边际等于固定的 n_{ab}；与 Y 有关的项只形成 A, B 的 Logistic 主效应。令 $\tau_{ab} = m_{ab0} + m_{ab1}$、$p_{ab} = m_{ab1}/\tau_{ab}$，则每组两格 Poisson 似然可分解为

$$L_{ab} = \Pr\{N_{ab} = n_{ab}; \tau_{ab}\} \Pr\{N_{ab1} = n_{ab1} \mid N_{ab} = n_{ab}; p_{ab}\}.$$

M_1 下各 τ_{ab} 可自由拟合为 n_{ab}，与结局概率的参数分开优化，因而得到与条件二项分析相同的 Logistic 系数及相应检验。M_2 删去了 AB 项，额外约束了预测变量的联合边际，一般不能保证上述分离。某个样本中的数值接近或偶然相同不能建立模型等价；应先核对抽样方式、固定边际和生成项。

来源与改编：知识点配套。题干与设问为新编；参考依据[31]、[32]。

解析　题 7.32　整体失拟与局部残差

返回题目

条件独立模型在每个 C 层分别用行合计乘列合计除以层总数拟合。$C = 0$ 的拟合表仍为 $\left(\begin{smallmatrix}12 & 8\\ 18 & 12\end{smallmatrix}\right)$；$C = 1$ 四格拟合值均为 10。第一层对两种整体统计量贡献为 0，第二层给出

$$X^2 = 4\frac{5^2}{10} = 10, \qquad G^2 = 2\{2 \times 15 \log 1.5 + 2 \times 5 \log 0.5\} = 10.465.$$

8 格减去 6 个独立参数，自由度为 2，G^2 检验 $P = 0.00534$，提示条件独立模型失拟。指定格 $r_P = (15 - 10)/\sqrt{10} = 1.5811$，调整后为 $1.5811/\sqrt{0.25} = 3.1623$。

各普通残差绝对值小于 2 并非整体拟合优度检验；多个格子的偏离可以共同形成显著失拟，且拟合参数会影响各格残差的方差。调整残差有助定位偏离，但逐格筛查还涉及多重比较，不应只凭某一个阈值替代整体检验。

来源与改编：知识点配套。题干与设问为新编；参考依据[31]、[32]。

解析　题 7.33　官方内置教学列联表的输出阅读

返回题目

M_0 表示 $S \perp (H, E)$，同时允许 H, E 关联。M_1 增添 HS 的 3 个和 ES 的 3 个独立参数，故差异自由度为 6；

$$\Delta G^2 = 19.8566 - 6.7613 = 13.0953, \qquad P = 0.04155.$$

在预先指定的这次比较中，新增两组关联项改善了拟合。整体检验把 M_0 与饱和模型比较，考察 15 个方向；嵌套比较只考察新增的 6 个方向。原假设及检验针对的偏离不同，所得 P 值并不矛盾，整体检验未拒绝也不等于证明独立。

指定格 $r_P = (30 - 44.3007)/\sqrt{44.3007} = -2.1486$，调整残差为 $-2.1486/\sqrt{1 - 0.555235} = -3.2217$，提示该格比 M_0 所预期的少，可结合其他残差定位失拟。该格为事后查看，不能按一次预设检验解释；更不能把教学补入的性别分层作为真实人群性别差异的证据。

来源与改编：案例改编。材料及改编范围见[31]、[34]、[35]、[32]。

解析　题 7.34　录取数据中的折叠与同质性

返回题目

合并后男性录取/未录取为 1198/1493，女性为 557/1278，因此

$$\mathrm{OR}_{\mathrm{crude}} = \frac{1198 \times 1278}{1493 \times 557} = 1.8411.$$

A 院系条件 OR 为 $512 \times 19/(313 \times 89) = 0.3492$，C 院系为 $120 \times 391/(205 \times 202) = 1.1331$，方向与大小并不相同。两模型的 1 自由度比较是在同质关联框架内检验一个共同性别关联参数；$P = 0.2159$ 不能证明每层均无关联。尤其同质关联模型本身明显失拟，不能忽略院系间关联差异而只报告共同参数的显著性。

粗 OR 描述申请者混合各院系后的边际关联，院系分布及各院系录取难度会改变折叠结果；它也不是录取概率之比。这是观察性资料，表中没有申请资格、专业选择机制等信息，无法单凭性别项或模型拟合结果断言因果影响或“证明不存在歧视”。可报告分层关联及模型局限，并按事先明确的目标进一步收集、调整相关因素。

来源与改编：案例改编。材料及改编范围见[31]、[36]、[37]、[32]。

第 7 章补充解析

解析　题 7.35　事件率与至少一次事件的概率

返回题目

答案：D。事件率的量纲为“次/人月”，可大于 1；概率则位于 0 与 1 之间。观察 2 个月的均数为 $\mu = 1.5 \times 2 = 3$，所以 $\Pr(Y \geq 1) = 1 - \Pr(Y = 0) = 1 - e^{-3} = 0.9502$。率与时间相乘得到的是期望计数，不能把它直接解释为至少一次事件的概率。

来源与改编：知识点配套。题干与设问为新编；参考依据[38]、[39]。

解析　题 7.36　同协变量分组的合并率估计

返回题目

答案：A。共同率模型的对数似然中与 λ 有关的部分为 $7\log\lambda - 400\lambda$，求导得 $7/\lambda - 400 = 0$，所以 $\hat{\lambda} = 7/400 = 0.0175$。两组粗率 0.04, 0.01 不能直接作等权平均；在共同率假定下，合并率相当于按人时加权平均。

来源与改编：知识点配套。题干与设问为新编；参考依据[38]、[40]。

解析　题 7.37　准 Poisson 的尺度调整

返回题目

答案：B。$\widehat{\phi} = 147.2/46 = 3.2$。准 Poisson 在本题相同拟合设定下保留系数估计，但将协方差矩阵乘以 $\widehat{\phi}$，所以标准误乘以 $\sqrt{\widehat{\phi}}$：

$$SE_Q = 0.1\sqrt{3.2} = 0.1789, \qquad t = -0.4/0.1789 = -2.236.$$

按题定约定参照 t_{46}，双侧 $P \approx 0.03024$。不能把方差的放大倍数直接用作标准误倍数，也不能把尺度乘进回归系数。

来源与改编：知识点配套。题干与设问为新编；参考依据[38]、[3]、[41]。

解析　题 7.38　总样本的方差均数比能说明什么

返回题目

答案：E。由全期望与全方差公式，

$$E(Y)=\tfrac{1}{2}(1+9)=5,\qquad \mathrm{Var}(Y)=E\{\mathrm{Var}(Y\mid X)\}+\mathrm{Var}\{E(Y\mid X)\}=5+16=21.$$

边际方差均数比为 4.2，但给定 X 后的均数与方差均相等。回归的 Poisson 方差假定针对条件分布；合并不同均数组后的原始样本方差大于均数，不能直接作为条件过离散的充分证据。

来源与改编：知识点配套。题干与设问为新编；参考依据[38]、[39]。

解析　题 7.39　NB2 与准 Poisson 的方差形状

返回题目

答案：C。均数 2 处方差为 $2+0.5\times 2^2=4$，方差均数比为 2；均数 8 处方差为 $8+0.5\times 8^2=40$，方差均数比为 5。NB2 的方差均数比 $1+\alpha\mu$ 随均数改变；准 Poisson 的该比值为共同常数 ϕ。因此两者可在某个均数附近相近，不能仅靠一个常数尺度在不同均数处完全等同。

来源与改编：知识点配套。题干与设问为新编；参考依据[38]、[42]、[3]。

解析　题 7.40　均值、相关性与零概率

返回题目

答案：D。I 正确，准 Poisson 的共同尺度在均值估计方程中抵消，主要改变方差估计及推断。II 错误，NB2 改变单个观察的条件分布与方差关系；把各次记录仍视为独立，并不会消除或建模受试者内相关。III 正确，因为 $\log(1+x)<x$ 对 $x>0$ 成立，故 $-\log(1+\alpha\mu)/\alpha>-\mu$，两边取指数即可。零数较多可以来自普通 NB2 的异质性，不能只凭“零很多”判定必须另设零膨胀成分。

来源与改编：知识点配套。题干与设问为新编；参考依据[38]、[3]、[42]。

解析　题 7.41　基线计数能否当作 offset

返回题目

按给定均值模型，基线事件数加倍对应随访期均数乘以 $2^{0.8}=1.7411$；观察时间加倍则乘以 2，后者由 $\log T_i$ 的系数固定为 1 决定。基线事件数是患者既往状态的随机指标，且所有人基线观察长度相同；它不是随访暴露时间。只有研究目标和均值关系确实支持“随访均数与基线计数严格成正比”时，才可施加 $\gamma=1$ 这一额外限制，不能因为变量都是计数就把它们等同。

$B_i=0$ 是有意义的观察结果，$\log B_i$ 不可定义提示的是当前函数形式不适用，不能自动删除这些患者。应根据研究问题预先选择能处理零的基线调整方式，例如直接使用 B_i 或明确说明含零指示的模型；加常数也会改变模型含义。若所有 $T_i=2$，$\log 2$ 是常数，可吸收到截距中；拟合系数的其他部分不变，但解释截距和报告率时仍须说明两周的观察单位。

来源与改编：知识点配套。题干与设问为新编；参考依据[38]、[40]。

解析　题 7.42　年龄交互与率比对比

返回题目

低年龄层的率比为 $e^{\widehat{\beta}_E}=2$；高年龄层的率比为 $e^{\widehat{\beta}_E+\widehat{\beta}_{EA}}=e^{-0.287682}=0.75$。两层率比之比为 $e^{\widehat{\beta}_{EA}}=0.375$，反映年龄层之间的暴露效应差异。高年龄层对数率比的方差必须包括协方差：

$$V=0.075000+0.113889+2(-0.075000)=0.038889,\quad SE=0.197203.$$

因此 95% 区间为 $\exp\{-0.287682\pm 1.96(0.197203)\}=(0.5096,1.1039)$。忽略协方差会夸大此处对比的标准误。

高年龄暴露组的拟合率为 45/1000 = 0.045 次/人年，500 人年的期望计数为 22.5；期望计数可以是非整数。此模型有 4 个组均数参数，恰好拟合 4 个计数组，剩余自由度为 0，不能用这四个汇总计数对其整体拟合优度或过离散作有剩余自由度的检验。

来源与改编：知识点配套。题干与设问为新编；参考依据[38]、[40]。

解析　题 7.43　完整就诊资料的计数模型输出

返回题目

控制列出的其他变量后，疾病数每增加 1，NB2 的条件平均就诊次数乘以 $e^{0.214341} = 1.2390$，即约增加 23.9%；这是观察性回归关联。减少活动天数增加 1 的均数比为 $e^{0.143754} = 1.1546$，95% 区间为

$$\exp\{0.143754 \pm 1.96(0.007311)\} = (1.1382, 1.1713).$$

固定 $\mu = 0.5$ 时，NB2 方差为 $0.5+1.077038\times0.5^2 = 0.7693$，零概率约 0.6703；同均数 Poisson 零概率为 $e^{-0.5} = 0.6065$。这里是同均数的分布比较，不表示两个拟合模型对某人的预测均数必相同。

Poisson 的 Pearson 尺度为 6873.982/5177 = 1.3278，提示条件方差可能大于 Poisson 所规定的水平。NB2 预测零人数 4172.7 较接近观察到的 4141，说明普通过离散模型本身就能增加零概率；“零多”并不自动要求零膨胀模型。一个总零数或一个尺度也不能证明模型拟合充分，还应检查各协变量范围内的残差、计数尾部及均值形式。

来源与改编：案例改编。材料及改编范围见[38]、[44]、[45]、[42]、[43]。

解析　题 7.44　校园犯罪案例的代码与版本审阅

返回题目

原始文件为 81 校，按结局率阈值剔除 5590 人、30 事件的学校后剩 80 行；随后 `pmax` 把 540 人学校的暴露量由 0.54 改为 1，相当于把 540 人改成 1000 人，已改变资料而非换单位。根据给定签名和实参匹配规则，`data = c.data2` 先匹配 `data`；两个未命名实参依次匹配 `formula` 与 `weights`，故外置的 `offset(log(enroll1000))` 在此被作为权重。540 人学校变为 $\log 1 = 0$ 权重，不能把该调用直接解释为已按在校人数调整的计数率模型。

负的对数暴露量可以合法作为 offset，只需原暴露量为正。保留 80 行时应对未钳制的 `c.data` 写

```
MASS::glm.nb(nv ~ type * region +
  offset(log(enroll1000)), data = c.data)
```

报告须区分原始 81 校、明确排除后的 80 校和原笔记改动的 10 行表。按观察结局率删除异常值可能改变估计，应说明理由，并比较保留全部 81 校与排除该校的敏感性。这里的调用判断为依据公开签名及 R 规则的静态分析；本次 Python 只复核原数据、筛选与数值，未运行 R 或声称作者确认了代码问题。

来源与改编：案例改编。材料及改编范围见[38]、[46]、[47]、[48]、[49]、[43]、[50]、[40]。

第 8 章

总复习与模型比较

主要内容

广义线性模型概述、多重线性回归模型；Logistic 回归；生存分析与 Cox 回归；对数线性模型；Poisson 回归、负二项回归。

8.1 广义线性模型概述

GLM 是一般线性模型的推广、普遍化（generalized）。Nelder & Wedderburn 于 1972 年提出。

$$\text{随机部分（因变量部分）：}\quad Y_i \mid \mathbf{x}_i \text{ 相互独立，属于指数族，}\quad \mu_i = \mathrm{E}(Y_i \mid \mathbf{x}_i),$$

$$\text{系统部分（自变量部分）：}\quad \eta_i = \sum_{j=0}^{m} \beta_j x_{ij}, \qquad \text{连接函数：}\quad g(\mu_i) = \eta_i.$$

$\mathrm{E}(Y_i \mid \mathbf{x}_i) = b'(\theta_i)$，$\mathrm{Var}(Y_i \mid \mathbf{x}_i) = a_i(\phi)b''(\theta_i)$；拟合值 $\hat{\mu}_i = g^{-1}(\mathbf{x}_i^{\top}\hat{\boldsymbol{\beta}})$ 是条件均值的估计（见第 1 章）。连接函数：GLM 关心一组自变量的线性组合预测因变量的条件均数，或者条件均数的某种函数。连接函数连接因变量的均数与自变量的线性组合。连接函数是因变量均数的转化，转化后的变量为回归参数的一个线性函数。

几种常见分布的典型连接（$\eta = \theta$）

分布	取值集合	均数	方差函数 $V(\mu)$	自然参数 θ	典型连接
正态 $N(\mu, \sigma^2)$	$(-\infty, \infty)$	μ	1（方差 σ^2）	μ	恒等
二项计数 $B(n, \pi)$	$\{0, 1, \ldots, n\}$	$n\pi$	$\mu(1 - \mu/n)$	$\mathrm{logit}\,\pi$	$\log\{\mu/(n-\mu)\}$
二项比例	$\{0, \frac{1}{n}, \ldots, 1\}$	π	$\mu(1-\mu)$（再除以 n）	$\mathrm{logit}\,\pi$	$\mathrm{logit}(\pi)$
Poisson $P(\lambda)$	$\{0, 1, 2, \ldots\}$	λ	μ	$\log\lambda$	log

8.1.1 常用参数估计方法

最小二乘估计（least squared estimation, LS）、加权最小二乘估计（weighted least squared, WLS）、极大似然估计（maximum likelihood estimation, MLE）。

最小二乘估计

$$\sum_{i=1}^{n}(y_i-\hat{y}_i)^2 \;\longrightarrow\; \sum_{i=1}^{n}\left(y_i-\beta_0-\sum_{j=1}^{m}\beta_j X_{ij}\right)^2.$$

满足一般线性模型的条件（LINE）的资料，可以用最小二乘法估计参数：

$$\hat{\boldsymbol{\beta}}=(\mathbf{X}^{\top}\mathbf{X})^{-1}\mathbf{X}^{\top}\mathbf{y}.$$

Gauss–Markov 定理：在设计矩阵列满秩、$\mathrm{E}(\boldsymbol{\varepsilon}\mid\mathbf{X})=\mathbf{0}$、$\mathrm{Cov}(\boldsymbol{\varepsilon}\mid\mathbf{X})=\sigma^2\mathbf{I}$ 的条件下（不要求正态），LS 估计在线性无偏估计中方差最小（BLUE），且唯一。异方差时 OLS 仍无偏，但不再最有效，常规标准误也不正确。

加权最小二乘估计

其权重是方差的倒数，方差越大权重越小，方差越小权重越大。

$$\sum_{i=1}^{n}\frac{1}{V_i}(y_i-\hat{y}_i)^2,\qquad \hat{\boldsymbol{\beta}}_{\mathrm{WLS}}=(\mathbf{X}^{\top}\mathbf{W}\mathbf{X})^{-1}\mathbf{X}^{\top}\mathbf{W}\mathbf{y},\quad \mathbf{W}=\mathrm{diag}(1/V_i).$$

权重含未知参数时需迭代（IRLS）；四格表例中 WLS 与 MLE 一致，是因为模型饱和，不能推广。

极大似然估计

根据样本数据，极大似然估计会找到最有可能产生样本观察值的参数值。极大似然估计需要指明假设被用来描绘样本数据的一个概率密度函数。

我们可以估计最大化似然函数 $L(\boldsymbol{\beta},\sigma^2\mid\mathbf{y})$ 的回归参数 $\boldsymbol{\beta}$，以 $\hat{\boldsymbol{\beta}}$ 表示。似然函数 $L(\boldsymbol{\beta},\sigma^2\mid\mathbf{y})=f(\mathbf{y}\mid\boldsymbol{\beta},\sigma^2)$ 是把样本联合密度看作参数的函数，不是参数的概率密度。正态线性模型的对数似然为 $-\frac{n}{2}\ln(2\pi\sigma^2)-\frac{(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})^{\top}(\mathbf{y}-\mathbf{X}\boldsymbol{\beta})}{2\sigma^2}$，$\boldsymbol{\beta}$ 的 MLE 与 LS 估计相同，$\hat{\sigma}^2_{\mathrm{MLE}}=\mathrm{SSE}/n$，而无偏估计为 $\mathrm{SSE}/(n-p)$（p 含截距）。

8.2 Logistic 回归

Logistic 回归的基本概念、非条件 Logistic 回归；配比设计资料的条件 Logistic 回归分析；多分类结局资料的 Logistic 回归分析；有序分类结局资料的 Logistic 回归分析。

8.2.1 Logistic 回归模型

$$\begin{aligned}\ln\frac{P}{1-P}&=\beta_0+\beta_1x_1+\beta_2x_2+\cdots+\beta_mx_m,\\ \mathrm{logit}(P)&=\beta_0+\beta_1x_1+\beta_2x_2+\cdots+\beta_mx_m,\\ P&=\frac{e^{\beta_0+\beta_1x_1+\cdots+\beta_mx_m}}{1+e^{\beta_0+\beta_1x_1+\cdots+\beta_mx_m}}=\frac{1}{1+e^{-(\beta_0+\beta_1x_1+\cdots+\beta_mx_m)}}.\end{aligned}$$

分布族 family：二项分布 binomial。连接函数 link：logit。

$$\eta = g(\mu) = \text{logit}(P), \qquad \text{logit}(P) = \ln \frac{P}{1-P}.$$

参数的估计方法：因为资料不满足“方差齐性”的条件，故 LSE 不适宜。加权最小二乘估计，其权重是方差的倒数；极大似然估计，构建似然函数，根据样本数据，找到使似然最大的参数值。得分 $\mathbf{U} = \mathbf{X}^\top(\mathbf{y} - \boldsymbol{\pi})$，信息阵 $\mathbf{I} = \mathbf{X}^\top\mathbf{W}\mathbf{X}$，$\mathbf{W} = \text{diag}\{\pi_i(1-\pi_i)\}$，用 IRLS 求解；完全分离或准完全分离时有限的 MLE 不存在。

8.2.2 回归系数的意义与假设检验

β_i 表示当其它因素被控制后，X 每改变一个单位，优势比的对数值（LnOR）。

$$\beta = \ln\left[\frac{P(D=1 \mid X^*)/P(D=0 \mid X^*)}{P(D=1 \mid X)/P(D=0 \mid X)}\right] = \ln \text{OR}, \qquad e^{\beta} = \text{OR}.$$

OR 是条件 OR，对所有个体相同；概率的改变量 $\partial\pi/\partial x = \beta\pi(1-\pi)$ 随基线概率而变。病例对照抽样不改变斜率，只改变截距。

检验模型中一个或者几个总体回归系数是否等于 0：$H_0 : \beta_i = 0$。Wald 检验、似然比检验、比分检验，三者大样本下渐近等价，自由度等于独立约束个数。

8.2.3 拟合优度检验与建模策略

模型拟合结果与实际数据的比较分析（goodness of fit）。零模型（null model）：只包含一个参数（常数项）的模型，对应于 y 的均数。饱和模型（saturated model，也有称全模型的）：每个观察单位对应一个参数，估计值与观察值完全相等。好的模型应该是用尽量少的参数达到最大的拟合。偏差、Pearson χ^2 的 χ^2 近似只适用于分组资料；个体 Bernoulli 资料改用 Hosmer–Lemeshow 检验、校准与区分度。

1) 从单因素分析开始：统计描述、统计推断。
2) 部分多因素分析：变量的类型、变量的变换。
3) 多因素分析：自变量的筛选、模型的选择（通过对比、嵌套）。
4) 深入思考：交互作用项、共线性、条件的检验、拟合优度。

统计学意义与专业意义。最优模型：不同的角度、不同的目的、不同的条件。

8.2.4 条件 Logistic 回归

$$P(A_i\text{发生不良反应} \mid A_i\text{和}B_i\text{之一发生不良反应}) = \frac{1}{1+\exp[-\sum\beta_j(x_{jA_i} - x_{jB_i})]}.$$

模型为 $\text{logit}\,P = \alpha_i + \sum\beta_j x_j$，以“每对中恰有 1 例病例”为条件消去对子截距 α_i。只有暴露不一致的对子提供信息，对子内恒定的变量无法估计。用途：估计调整匹配因素后的 OR，不能直接估计绝对风险。优点：节约样本量，提高研究的效率。缺点：若需控制的因素较多，则实施难度大。

条件 Logistic 回归模型假设：自变量在各个配比组对结局变量（因变量）的作用是相同的，即自变量的回归系数与匹配组无关。模型中的常数项 β_{0i} 与该匹配组的因素有关，是该匹配组特有的，指该匹配组的自变量均为 0 时的基线风险。常数项对自变量的解释没有帮助，且不包含在似然函数中，故常不考虑。

8.2.5 多分类结局的 Logistic 回归模型

结局变量是无序多分类的情形。例如疾病的不同类型、同一种肿瘤的不同病理分型、一种病例与多种对照。Multinomial logistic model（Anderson，1972 年）。一般地：

$$\operatorname{logit} P_k = \ln \frac{P(y=k)}{P(y=0)} = \alpha_k + \beta_{k1}x_1 + \beta_{k2}x_2 + \cdots + \beta_{kp}x_p = g_k(\mathbf{x}),$$

$$P_k = \frac{\exp(g_k)}{1+\sum_{k=1}^{K}\exp(g_k)} = \frac{\exp(g_k)}{\sum_{k=0}^{K}\exp(g_k)}, \qquad g_0 = 0.$$

表 8　无序多分类结局 Logistic 回归分析结果

Variable	Parameter	估计值	Standard error	Wald χ^2	P-value	RRR $\exp(\beta)$
Intercept	$\hat{\beta}_0^{(1)}$	−0.9826	0.5707	2.96	0.0851	
	$\hat{\beta}_0^{(2)}$	−0.3461	0.5413	0.41	0.5226	
X_1	$\hat{\beta}_1^{(1)}$	0.6281	0.1799	12.19	0.0005	1.874
	$\hat{\beta}_1^{(2)}$	0.3454	0.1728	4.00	0.0456	1.413
X_2	$\hat{\beta}_2^{(1)}$	−0.6494	0.2833	5.26	0.0219	0.522
	$\hat{\beta}_2^{(2)}$	−0.6352	0.2725	5.43	0.0197	0.530

$$\ln\frac{P_1}{P_3} = -0.9826 + 0.6281x_1 - 0.6494x_2, \qquad \ln\frac{P_2}{P_3} = -0.3461 + 0.3454x_1 - 0.6352x_2.$$

$e^{\beta_{kj}}$ 是相对风险比（RRR）：其他协变量固定，x_j 每增加 1 个单位，“属于类别 k 与属于参照类别的概率之比” 乘以 $e^{\beta_{kj}}$。更换参照类别时系数相减。x_j 的总体作用应作跨方程的联合检验（$\mathrm{df} = K$）。注意事项：不同的回归方程，自变量的偏回归系数不同。多分类结局变量的 Logistic 回归（联合似然）与分别做两类比较的回归模型存在差异。

8.2.6 有序多分类结局的 Logistic 回归模型

结局变量是有序多分类的情形。例如临床疗效（无效、好转、显效、治愈）、疾病的严重程度（轻、中、重）、考试成绩的等级（A、B、C）。Cumulative logistic regression model。

$$\operatorname{logit} P_j = \operatorname{logit}(y>j) = \ln\frac{P(y>j)}{1-P(y>j)} = -\alpha_j + \sum_{i=1}^{m}\beta_i x_i, \quad j = 1,2,\ldots,K-1,$$

$$P(y\le j) = \frac{1}{1+\exp(-\alpha_j + \sum_{i=1}^{m}\beta_i x_i)}.$$

估计参数的个数：$(K-1)+m$。

$-\alpha_j$ 是自变量均为 0 时，“等级高于 j” 对 “不高于 j” 的对数优势，阈值满足 $\alpha_1 < \cdots < \alpha_{K-1}$。$\beta_i$：$x_i$ 每增加一个单位，对任一分界点 j，“等级高于 j” 相对于 “不高于 j” 的优势比的对数值。β_i 与 j 无关（比例优势假设，用平行线检验考察；$P > 0.05$ 只表示未发现违背的证据）。

表 10　儿童智力等级与母亲文化程度的累积优势 Logistic 回归

变量	回归系数	标准误	Z	P
x	0.6373	0.0934	6.824	0.000
常数项 α_1	−1.4578	0.1454		
常数项 α_2	1.2254	0.1358		
常数项 α_3	3.5630	0.1935		

$$\operatorname{logit} P_j = -\alpha_j + 0.6373x, \qquad \mathrm{OR} = e^{0.6373} = 1.89.$$

母亲的文化程度每提高一个等级，无论以哪个智商等级为分界，儿童智商等级高于该分界的优势均乘以 1.89（平行线检验 $P = 0.92$）。

8.3 生存分析

在许多医学研究中，我们不仅关心终点事件（terminal event）是否发生，还关心发生终点事件经历了多长时间。恶性肿瘤治疗随访：复发与否、死亡与否（5 年生存率）。生存分析（survival analysis）是将终点事件的发生与否和到达终点所经历的时间结合起来分析的一类统计方法。源于古老的寿命表，是现代统计学的一个重要分支。

主要内容：生存分析的目的、资料特点（删失）、基本概念（生存率、函数）；生存率的估计方法（寿命表法、Kaplan–Meier）；生存曲线比较的方法（log-rank 法）；多因素分析，Cox 回归。

要点：观察到的是 $\widetilde{T} = \min(T, C)$ 与 $\delta = I(T \le C)$；在独立删失下个体似然贡献为 $f(\tilde{t})^{\delta} S(\tilde{t})^{1-\delta}$。$h = f/S$，$H(t) = \int_0^t h(u)du$，$S = e^{-H}$，$F = 1 - e^{-H}$（$F$ 是累积发生概率，不是累积风险）。KM 估计 $\hat{S}(t) = \prod(1 - d_i/n_i)$，Greenwood 方差由 Delta 方法得到。log-rank 统计量 $(A_1 - T_1)^2 / \sum V_{1i}$ 来自各风险集的超几何分布，对各事件时点等权；曲线交叉时效能下降，但不是检验的禁忌。

8.3.1 Cox 回归

Cox 比例风险回归模型（Cox's proportional hazards regression model），简称 Cox 回归。以生存结局和生存时间为因变量，可同时分析众多因素对生存期的影响，分析带有删失生存时间的资料，且不要求资料服从特定的分布类型。英国统计学家 D. R. Cox 于 1972 年提出。

$$\underbrace{h(t)}_{t\text{时刻的风险函数}} = \underbrace{h_0(t)}_{t\text{时刻的基线风险函数}} \times \exp(\beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p).$$

半参数模型（semi-parametric model）。

$$h(t) = h_0(t) \times \exp(\beta_1 X_1) \exp(\beta_2 X_2) \cdots \exp(\beta_p X_p).$$

乘法模型。

任两个个体风险函数之比，即风险比（hazard ratio, HR；不同于固定时点累积风险之比 RR）。

$$\begin{aligned}\mathrm{HR} = \frac{h_i(t)}{h_j(t)} &= \frac{h_0(t)\exp(\beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip})}{h_0(t)\exp(\beta_1 X_{j1} + \beta_2 X_{j2} + \cdots + \beta_p X_{jp})} \\ &= \exp[\beta_1(X_{i1} - X_{j1}) + \beta_2(X_{i2} - X_{j2}) + \cdots + \beta_p(X_{ip} - X_{jp})].\end{aligned}$$

自变量的效应不随时间而改变，称为比例风险（proportional hazard）假定，简称 PH 假定。

$$\ln h_i(t) - \ln h_j(t) = \beta_1(X_{i1} - X_{j1}) + \beta_2(X_{i2} - X_{j2}) + \cdots + \beta_p(X_{ip} - X_{jp}).$$

β_j：在其它自变量不变条件下，变量 X_j 每增加一个单位所引起的风险比的自然对数。

$$\ln \mathrm{HR}_j = \beta_j, \qquad \mathrm{HR}_j = \exp(\beta_j).$$

参数用部分似然估计（风险集取事件前一瞬间，并列事件用 Breslow/Efron 近似），得分是“事件者协变量减风险集加权均值”之和。$S(t \mid \mathbf{x}) = S_0(t)^{\exp(\mathbf{x}^\top \boldsymbol{\beta})}$，绝对生存预测需要基线风险。PH 假定用 log–log 图与 Schoenfeld 残差检查；随访中发生的事件（如复发）应作时依协变量。竞争风险下，原因别 Cox 模型针对病因，Fine–Gray 模型针对累积发生率；1 − KM 会高估 CIF。

8.4 对数线性模型

对数线性模型（Log-linear model）通常用于分析高维列联表数据。描述和确定高维列联表中分类变量间的相关关系；可在不歪曲变量间相关关系的情况下探讨合并列表数据的可能性。

饱和模型（Saturated model）：

$$\begin{aligned}\ln F_{ijk} = {} & u + u_1(i) + u_2(j) + u_3(k) \\ & + u_{12}(i,j) + u_{13}(i,k) + u_{23}(j,k) + u_{123}(i,j,k).\end{aligned}$$

u：$\ln F_{ijk}$ 的总体均值；$u_1(i)$：变量 1 第 i 级的主效应；$u_2(j)$：变量 2 第 j 级的主效应；$u_3(k)$：变量 3 第 k 级的主效应。

$$\sum_i u_1(i) = \sum_j u_2(j) = \sum_k u_3(k) = 0.$$

层次模型（Hierarchical models）：如果 $u_{123} = 0$，则提示不存在二阶交互效应。

$$\ln F_{ijk} = u + u_1(i) + u_2(j) + u_3(k) + u_{12}(i,j) + u_{23}(j,k) + u_{13}(i,k).$$

其表明每一对变量均可存在相关关系，且任一对变量的条件 OR 在第三个变量各层相同（两两关联模型，homogeneous association model）。$u_{12} = u_{123} = 0$ 等价于给定变量 3 时 1 与 2 条件独立。条件独立模型、部分独立模型、互相独立模型。列联表可以来自 Poisson、多项或乘积多项抽样，含相应边际项时用 Poisson GLM 拟合结果相同。若 $X \perp Z \mid Y$ 或 $Y \perp Z \mid X$（且 $u_{123} = 0$），X 与 Y 的 OR 关于 Z 可折叠。偏差 $G^2 = 2\sum O \ln(O/E)$；调整残差超出 ± 2 用于筛查。解释变量边际取饱和时，对数线性模型中含结局的项与 Logistic 回归系数相同。

8.5 泊松回归（Poisson Regression）

泊松回归：针对计数资料或列联表资料建模的一种回归分析方法。假设 1：给定协变量时，计数 Y 服从泊松分布且相互独立；假设 2：条件均值的对数 $\log \mu$ 是协变量的线性组合。

$$\ln r_{ij} = \ln \frac{\mu_{ij}}{n_{ij}} = \lambda + \lambda_i^X + \lambda_j^Y.$$

λ 为常数项；λ_i^X 表示变量 X 第 i 个水平效应值的大小；λ_j^Y 表示变量 Y 第 j 个水平效应值的大小；μ_{ij} 为 $X = i, Y = j$ 时死亡数的期望频数；n_{ij} 为观察人年数。

$$\ln \mu_{ij} = \lambda + \lambda_i^X + \lambda_j^Y + \underbrace{\ln n_{ij}}_{\text{偏移量}}.$$

参数解释：

$$\ln r = \beta_0 + \beta_1 \text{expose} + \beta_2 \text{age4} + \beta_3 \text{age5} + \beta_4 \text{age6} + \beta_5 \text{age7},$$

（r 为发生率，不是概率；由 $\mu = tr$ 得 $\ln \mu = \ln t + \mathbf{x}^\top \boldsymbol{\beta}$，offset 系数固定为 1，时间单位改变只影响截距。职业暴露例：调整年龄后 RR $= e^{0.409} = 1.50$，95%CI 1.06–2.14。）

$$\text{RR} = \frac{r_{i2}}{r_{i1}} = \frac{\exp(\lambda + \lambda_i^X + \lambda_2^Y)}{\exp(\lambda + \lambda_i^X + \lambda_1^Y)} = \exp(\lambda_2^Y - \lambda_1^Y).$$

8.6 负二项回归模型

医学研究中，很多事件的发生是非独立的（传染的、原因不明的聚集现象等），这种资料的特点是估计值的方差较 Poisson 分布的方差大（over-dispersion or extra-Poisson variation）。存在过离散情况，负二项回归。

Y 服从负二项分布，μ 为相应的均数。

$$\ln \mu = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_m x_m, \qquad \mu = e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_m x_m}.$$

Poisson 分布的方差 = 均数 $= \mu$。NB2：$Y \mid U \sim \text{Poisson}(\mu U)$，$U \sim \Gamma(1/\alpha, \text{率} = 1/\alpha)$，得 $\text{E}(Y \mid \mathbf{x}) = \mu$，$\text{Var}(Y \mid \mathbf{x}) = \mu + \alpha\mu^2$；$\alpha \to 0$ 时退化为 Poisson。检验 $\alpha = 0$ 的似然比统计量服从 $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$。过离散可能来自遗漏协变量、个体异质性或观察不独立，后者需 GEE 或混合模型。不能为满足等离散而删除零计数。

> **模型选择的一般步骤**
>
> 针对具体研究问题选择分析模型时，可依次考虑以下几方面：
>
> 1) **结局变量的类型**。连续变量 → 线性回归；二分类 →logistic 回归；无序多分类 → 多项 logit 模型；有序分类 → 累积 logit 模型；计数（有观察人年）→Poisson 或负二项回归；生存时间与删失 →KM 法、log-rank 检验、Cox 回归；多个分类变量的关联结构 → 对数线性模型。

2) **观察的独立性**。配对或匹配设计 → 条件 logistic 回归；同一个体的重复测量 → 重复测量方差分析、混合模型或 GEE；家庭、社区等聚集资料同样需考虑观察间的相关。
3) **研究设计可估计的效应**。病例对照研究只能估计 OR，截距无实际意义；队列研究可估计率、RR 与 HR；横断面研究估计的是与患病率的关联。
4) **模型的主要假设**。logistic 回归：logit 尺度线性、无分离、事件数充足；有序 logit 模型：比例优势；Cox 回归：比例风险、独立删失；Poisson 回归：无过离散。
5) **效应量的解释**。写明效应指标为 OR、RR、HR 或 IRR，注明“其他因素相同的条件下”及自变量的单位，并给出 95% 置信区间。

综合分析题的作答可按以下顺序组织：研究设计、结局类型、模型（写出模型表达式与连接函数）、假设检查、结果解释、局限性。

8.7 模型比较总表

本课程各模型的比较

模型	分析单位	给定协变量的条件分布	连接与线性预测量	似然	效应量	主要假设
线性回归	个体	$N(\mu, \sigma^2)$	恒等：$\mu = \mathbf{x}^\top \boldsymbol{\beta}$	正态似然（$\boldsymbol{\beta}$ 的 MLE 即 LS）	均数差 β	独立、线性、同方差；精确推断需正态
二分类 Logistic	个体或协变量组合	$B(1, \pi)$ 或 $B(n, \pi)$	$\operatorname{logit} \pi$	二项似然	OR	独立；logit 尺度线性；无分离；EPV 足够
条件 Logistic	配对/匹配组	组内恰有 1 例病例的条件分布	$\operatorname{logit} \pi = \alpha_i + \mathbf{x}^\top \boldsymbol{\beta}$	条件似然（消去 α_i）	OR	各组 OR 相同；组间独立
多项 Logistic	个体	多项分布	$\ln(P_k/P_0) = g_k(\mathbf{x})$	多项似然	RRR	独立；IIA
累积 Logit	个体	有序多项分布	$\operatorname{logit} P(Y \le j) = \alpha_j - \mathbf{x}^\top \boldsymbol{\beta}$	多项似然	累积 OR	比例优势；阈值递增
Cox 回归	个体（时间、删失）	$h(t) = h_0(t) e^{\mathbf{x}^\top \boldsymbol{\beta}}$（半参数）	$\ln h - \ln h_0$ 线性	部分似然	HR	比例风险；给定协变量独立删失；协变量在起点已知
对数线性	列联表格子	Poisson（或多项）	$\ln \mu$ 为主效应与交互项之和	Poisson/多项似然	条件 OR（含交互项）	格子独立；层次性；期望频数不过小
Poisson 回归	个体或单位（有观察时间）	Poisson(μ)	$\ln \mu = \ln t + \mathbf{x}^\top \boldsymbol{\beta}$	Poisson 似然	率比 RR/IRR	独立；条件均值 = 条件方差；率在观察期内恒定
负二项回归	同上	NB2：均值 μ，方差 $\mu + \alpha\mu^2$	同 Poisson	负二项似然	IRR	独立；Gamma 异质性；均值结构正确

总结

多重线性回归模型、广义线性模型概述；Logistic 回归；生存分析与 Cox 回归；对数线性模型；Poisson 回归、负二项回归。

8.8 期末考试安排

期末考试

题型	题数	分值	总分
选择题（单选题）	15	2 分/题	30 分
名词解释	4	3 分/题	12 分
简答题	4		18 分
综合分析题	4	10 分/题	40 分

闭卷考试。时间：2025 年 1 月 8 日上午 8–10 点；地点。

8.8.1 样题

1. 进行生存分析时，下列情况不属于删失数据的是（　）。

A. 随访期内死于本病者。
B. 随访期内死于其他病因者。
C. 随访结束时仍存活。
D. 随访期内失访者。
E. 随访期内死于意外。

2. 假设有 M、N、P 三个分类变量，且 M 与 N 在给定 P 时条件独立，请问以下哪一对数线性模型可以描述上述三个变量之间的关系（　）？

A. $\ln F_{ijk} = u + u_{Mi} + u_{Nj} + u_{Pk}$。
B. $\ln F_{ijk} = u + u_{Mi} + u_{Nj} + u_{Pk} + u_{MNij} + u_{MPik}$。
C. $\ln F_{ijk} = u + u_{Mi} + u_{Nj} + u_{Pk} + u_{MPik} + u_{NPjk}$。
D. $\ln F_{ijk} = u + u_{Mi} + u_{Nj} + u_{Pk} + u_{MNij} + u_{NPjk}$。
E. $\ln F_{ijk} = u + u_{Mi} + u_{Nj} + u_{Pk} + u_{MNij} + u_{MPik} + u_{NPjk}$。

名词解释 加权最小二乘估计、中位生存期。

简答题 什么是连接函数（Link function）？它在广义线性模型中起到什么作用？**综合分析题** 在某农村队列研究团队发表的一篇文章中，研究者探讨了空气污染暴露、肥胖与中风的关联，结果如下表所示。请根据此结果回答下列有关问题。

Table 1. Combined associations of high exposure of ambient air pollutants and BMI with stroke

Air pollution	Normal BMI, OR (95%CI)	High BMI, OR (95%CI)
PM_1		
Low exposure	1	1.28 (1.13, 1.46)
High exposure	1.52 (1.39, 1.66)	2.23 (1.94, 2.55)
$PM_{2.5}$		
Low exposure	1	1.25 (1.09, 1.42)
High exposure	1.93 (1.75, 2.12)	3.08 (2.67, 3.54)

Models were adjusted for marital status, education level, average monthly income, drinking status, high fat diet, vegetables and fruits intake, and physical activity.

1）这个研究的设计类型是什么?

2）这个研究所用的统计分析方法是什么，并请写出其连接函数及表达式。

3）请解释表中关于 $PM_{2.5}$、肥胖与中风的分析结果。

样题答题要点

- **第 1 题**选 A。死于本病者观察到终点事件，属完全数据；死于其他病因、随访结束时仍存活、失访与死于意外均属删失（死于其他病因时，若关注实际累积发生率，应按竞争风险处理）。
- **第 2 题**选 C。M 与 N 在给定 P 时条件独立，模型应含 u_{MP}、u_{NP}，不含 u_{MN} 与三阶交互项。
- **名词解释**　加权最小二乘估计：以各观察值方差的倒数为权重，使加权残差平方和最小的估计方法，适用于方差不齐的资料；权重依赖未知参数时需迭代求解（IRLS）。中位生存期：生存率降至 50% 时对应的生存时间；有删失时由 KM 曲线读出，曲线未降至 0.5 时记为“未达到”。
- **简答题**　连接函数 g 将结局的条件均数 μ 变换至可与线性预测量相等的尺度，即 $g(\mu) = \mathbf{x}^\top\boldsymbol{\beta}$。其作用为：保证均数位于合理范围内（概率在 0 与 1 之间，计数为正数），并决定系数的含义（logit 连接 → 对数 OR，log 连接 → 对数 RR 或对数 IRR）。
- **综合分析题**　表中报告 OR，分析方法为二分类 logistic 回归，$\operatorname{logit} P = \beta_0 + \beta_1 E + \beta_2 B + \beta_3 E \times B + \boldsymbol{\gamma}^\top \mathbf{z}$。各 OR 以低暴露、BMI 正常组为共同参照：$PM_{2.5}$ 高暴露单独存在时 OR 为 1.93，BMI 偏高单独存在时 OR 为 1.25，二者同时存在时为 3.08。相乘尺度上 $3.08/(1.93 \times 1.25) = 1.28 > 1$；相加尺度上 $\text{RERI} = 3.08 - 1.93 - 1.25 + 1 = 0.90 > 0$，提示二者存在正向协同作用。判断交互作用是否有统计学意义，还需交互项的检验或 RERI 的置信区间。详细解答见第 3 章后习题与解析中的题 3.20。

8.8.2 严守考纪，诚信应考

医学部教育处，2024 年。

医学部考场守则

- 学生考试前要做好考前的一切准备，要按规定的考试时间提前 5 分钟到考场，服从监考人员的安排隔位就座，将学生证（校园卡）放在桌面，无学生证（校园卡）者不准参加考试。

迟到 15 分钟以上不得入场；与考试无关的人员不得进入考场。考试开始 30 分钟后方可交卷离场，未交卷擅自离开考场，不得重新进入考场继续答题，考生交卷后应离开考场，不得在考场内逗留或在考场附近高声交谈。

- 除必要的文具和主考教师允许的工具书、参考书、计算器以外，其它所有物品（包括空白纸张、手机、智能手表等）不得带入座位，已经带入考场的必须放在监考人员指定的位置，并关闭手机等一切电子设备。
- 考试使用的试题、答卷、草稿纸由监考人员统一发放，考试结束后收回，一律不准带出考场。考生在规定时间前答完试卷，应举手示意监考人员收卷后方可离开；考试结束监考人员宣布收卷时，考生应立即停止答卷，在座位上等待监考人员收卷清点后方可离开考场。
- 考生要严格遵守考场规则，应认真、诚实地在规定时间内独立完成答卷。凡违反考场纪律或作弊者，按学籍管理规定给予相应的纪律处分。

医学部对考试违纪零容忍！所有处分决定均放入学生个人档案！请同学们勤奋求实，严守考纪，诚信应考！

第 8 章　习题与解析

总复习与模型比较：补充习题

本组为第 8 章配套的 10 道综合练习，答案及来源在题目之后。

单项选择题

每题只有一个最佳答案，请从 A—E 中选择。

题 8.1　OR 改变一定说明混杂吗

在一个不存在混杂的教学随机分组总体中，X 与基线 Z 独立，且两暴露组内 $P(Z=0)=P(Z=1)=1/2$。结局概率如下：

	$X=0$	$X=1$
$Z=0$	$1/5$	$1/3$
$Z=1$	$3/5$	$3/4$

关于分层 OR 与边际 OR，下列哪项正确？

A. 分层 OR 与边际 OR 均为 2。

B. 只要两个 OR 不同，就推翻了题设的随机分组。

C. 分层 OR 均为 2，边际 OR 为 $39/22$；这种差别本身不证明混杂。

D. 分层 OR 均为 $39/22$，边际 OR 为 2。

E. 由于 $X \perp Z$，Z 不可能与结局有关。

题 8.2　过离散与重复观察是两个问题

教学研究对 400 名相互独立的受试者各观察 4 期，每期记录发作次数、实际观察人时和基线暴露。同一人的各期计数明显相关；目标是总体平均发作率与暴露的关系。即使采用 NB2 方差后过离散已有改善，下一步哪项最合适？

A. 只要 NB2 的离散参数显著，就可以忽略个体编号。

B. 将 1600 行随机打乱，相关性即可消除。

C. 删除每人所有零计数时期，使 Poisson 假定成立。

D. 按人指定相关簇，考虑总体均值的 GEE 及簇稳健推断，并保留人时信息。

E. 把人时作为频数权重即可同时处理相关性和暴露时间。

题 8.3　相同 AUC 不等于相同概率预测

同一验证集中，模型给出的事件概率满足 $0 < p_i < 1$。有人把全部预测改成 $q_i = p_i^2$，其中至少有一个 $p_i = 0.60$；仍以较大分数预测更可能发生事件。对普通经验 ROC/AUC 及 0.5 阈值分类，下列哪项必然正确？

A. AUC 也必然变为原值的平方。

B. ROC/AUC 保持不变，但 0.5 阈值的分类至少有一人改变。

C. AUC 不变，因此概率校准必定不变。

D. 所有预测仍在 0 与 1 之间，因此平方后的模型一定校准正确。

E. Brier 分数必定不变，因为排序没有变化。

题 8.4　合并二项数据后的似然常数

把独立 Bernoulli 记录按完全相同的设计行（含所有交互项和 offset）合并成‘事件数/总人数’。合并前后使用同一 logit 模型，且二项次数权重正确；模型有有限的内部 MLE。以下哪项正确？

A. 系数及通常模型协方差相同，但对数似然常数和饱和模型可能不同。

B. 只要系数相同，两份输出中的偏差数值就必定相同。

C. 合并后必须把每个总人数都改成 1，才能保留信息。

D. 合并后样本行数少了，所有标准误必定增大。

E. 任何协变量不同的受试者也可按结局相同而任意合并。

题 8.5　相同 LR 值与不同参照分布

教学比较中，检验甲是在普通 Logistic 模型中检验一个正则、可识别的斜率为 0；检验乙是在相同计数数据上比较 Poisson 与仅多一个常数离散参数 $\alpha \geq 0$ 的 NB2，$H_0 : \alpha = 0$。两项 LR 统计量均为 3.0。已知甲用 χ^2_1，乙用 $\frac{1}{2}\chi^2_0 + \frac{1}{2}\chi^2_1$，且 $P(\chi^2_1 \geq 3) = 0.0833$。在 $\alpha_{\text{test}} = 0.05$ 下，应作何判断？

A. 两项均不拒绝，因为 LR 值相同。

B. 两项均拒绝，因为都增加一个参数。

C. 甲拒绝，乙不拒绝。

D. 乙必须用两个自由度，所以两项均不拒绝。

E. 甲不拒绝，乙拒绝。

题 8.6　课程中的模型与 GLM 边界

判断以下命题：

I. 独立 Poisson 响应、log 连接及已知 offset 仍可构成普通 GLM。

II. Cox 式中出现 $\exp(X^T\beta)$，就足以把通常的 Cox 偏似然当作独立 Poisson 响应的完整似然。

III. 负二项形状参数固定已知时，可作为单参数指数族的 GLM；若另行估计该形状参数，应说明额外估计步骤。

哪些命题正确？

A. 仅 I。

B. 仅 II。

C. I 和 II。

D. I 和 III。

E. I、II 和 III。

简答、计算与案例分析

题 8.7　分析前先写清观察单位与目标参数

请分别为以下三份资料选择一个与研究目标相符的主要分析框架，并说明响应/数据结构、使用的似然或估计思想、指数化系数的含义及一项关键前提：

1) 每名病例匹配 2 名对照，关心组内变化的暴露与结局的关联。

2) 每个独立地区记录年度总事件数和总人时，关心调整协变量后的事件发生率。

3) 前瞻性队列记录首次事件时间或右删失时间，关心瞬时风险的相对大小。

不得只列出三个软件命令。

题 8.8　四个模型中哪些比较有效

以下是明确给定的教学模型摘要，不代表未提供个体数据的真实拟合。A、B、C 使用完全相同的 240 名受试者和二分类结局，均按个体 Bernoulli 完整似然计入同一常数；X, Z 连续。D 因新增标志物 M 缺失而只用其中 210 人。k 均为实际自由估计的参数数目。

模型	连接及线性预测子	n	k	$\ell_{\max}$
A	logit：截距、X, Z	240	3	-142.0
B	logit：A 加 XZ	240	4	-138.8
C	probit：截距、X, Z, XZ	240	4	-139.1
D	logit：B 加 M	210	5	-116.0

1) 计算四个 AIC；可以直接把哪几个放在一起比较？

2) 在通常正则条件下，用 LR 检验 A 与 B，给出原假设、统计量、自由度及结论。可用 $P(\chi^2_1 \geq 6.4) = 0.0114$。

3) B 与 C 能否直接作同样的卡方 LR 检验？两者 AIC 差为多少，能否据此宣称一个模型被‘证明正确’？

4) 若要判断加入 M 是否改善模型，至少需要如何重新组织拟合？统一分析样本是否已解决所有缺失数据问题？

题 8.9　同一队列表中的 OR、RR、IRR 与 HR

教学队列中，两组各 100 人，基线均未发生目标事件。每人均随访至首次事件或 5 年行政随访结束，无提前失访，也无竞争事件。汇总表中人时累计至首次事件或 5 年：

暴露	人数	5 年内事件	5 年内无事件	总人年
$X = 0$	100	20	80	420
$X = 1$	100	36	64	392

1) 计算 5 年累积风险、RR 和 OR。
2) 计算每 100 人年的发病密度及其比值 IRR，说明它为何不必等于 RR。
3) 仅凭这两行汇总表能否恢复通常 Cox 偏似然并求出 HR？还缺什么信息？
4) 另作一个明确的 PH 模型设定：$\mathrm{HR} = 2$ 且 $S_0(5) = 0.80$。这两个参数是本小问额外给定的假设，不声称由前表拟合而得。求 $S_1(5)$、暴露组 5 年风险及对应 RR；‘HR 为 2 就表示 5 年风险加倍’是否正确？

题 8.10　三种显著结果是否构成相同结论

以下为教学研究报告评议。观察性队列研究基线暴露 X 与住院的关联，各人实际观察 0.5 至 3 年；均有住院日期及随访结束原因。研究者调整了相同的基线协变量，给出三种分析。表中系数与标准误为教学设定：

分析	响应及模型	$\hat{\beta}_X$	SE
A	实际观察期内是否住院；普通二项 logit	$\log 2$	0.10
B	实际观察期内累计住院次数；Poisson log 连接，log 人时 offset	$\log 2$	0.12
C	首次住院时间及右删失；Cox PH	$\log 2$	0.15

作者写道：‘三种方法均显示风险加倍且显著，证明暴露导致 3 年住院风险增加 100%；只须选择三者中 AIC 最小者。’

1) 分别解释三种 $e^{\hat{\beta}_X}$，计算相应 95% Wald 区间，并说明 A 能否直接给出统一的 3 年 OR。
2) 对 B、C 各指出两项需要检查的模型或观察机制前提。
3) 评价作者关于因果关系、固定 3 年风险和跨模型 AIC 的结论，提出与你认为合适的研究目标相对应的修改。

参考答案与解析

解析　题 8.1　OR 改变一定说明混杂吗

返回题目

答案：C。两个 Z 层内 OR 均为 2：第一层优势比为 $(1/2)/(1/4)=2$，第二层为 $3/(3/2)=2$。按相同权重求边际概率得到 $p_0=2/5, p_1=13/24$，边际 OR 为 $(13/11)/(2/3)=39/22\approx 1.7727$。因此，混杂不存在时仍可因 OR 的不可折叠性而出现条件/边际差别。不能单以调整前后系数变化识别混杂；还需明确目标效应、设计和变量关系。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[52]。

解析　题 8.2　过离散与重复观察是两个问题

返回题目

答案：D。边际方差增大与同一个体内的协方差是不同结构。可按受试者指定簇，使用具有 log 均值、log 人时 offset 的 GEE 及适当的簇稳健推断等方法。题设给出 400 个独立簇，有利于常见大样本簇方差近似；仍需检查均值结构和数据质量。把 NB 分布换进普通独立似然，不会自动把 1600 行变为 1600 个独立人。若目标改为个体条件效应，可讨论随机效应模型，但目标解释也需相应改变。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[53]。

解析　题 8.3　相同 AUC 不等于相同概率预测

返回题目

答案：B。在 $(0,1)$ 上平方严格递增，所有病例与非病例之间的排序及并列关系保持不变，故经验 ROC 曲线和 AUC 相同。但 $0.60^2=0.36$，该人的 0.5 阈值分类会改变，概率校准和 Brier 分数也不受排序不变所保证。所附 8 条教学记录中，变换前后 AUC 均为 0.8125，而 Brier 分数从 0.175 变为 0.20885；这只是反例，不是对任意数据单调变换后 Brier 方向的断言。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[54]。

解析　题 8.4　合并二项数据后的似然常数

返回题目

答案：A。合并后的二项似然比个体 Bernoulli 似然多 $\prod_g \binom{n_g}{s_g}$，其对数与参数无关。因此得分、信息、回归系数与通常模型协方差相同，但最大对数似然的绝对值相差组合数常数。两种响应表示的饱和模型也不同，偏差及其自由度不能直接互当同一统计量；AIC 比较也要保证相同的响应表示和常数约定。若合并了不同设计行或漏掉试验次数权重，就不再有上述等价性。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[2]、[55]。

解析　题 8.5　相同 LR 值与不同参照分布

返回题目

答案：E。甲的 $P=0.0833$，不拒绝斜率为 0。乙统计量为正，零点质量不贡献尾概率，故 $P=0.5\times 0.0833=0.04165$，拒绝 $\alpha=0$。差别来自参数空间边界及相应的极限分布，不是模型名称决定 P 值大小。该半卡方结论限定于本题的单个常数 NB 离散参数检验，不能无条件扩展到所有边界问题。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[56]。

解析 题 8.6　课程中的模型与 GLM 边界

返回题目

答案：D。I 正确：offset 是线性预测子中系数固定为 1 的已知部分，不破坏 GLM 结构。II 错误：Cox 通常按风险集构造偏似然，保留未指定的基线风险；出现指数线性预测子并不能指定独立响应分布或完整似然。某些条件下可建立分段 Poisson 表示，但需要额外的数据和模型构造。III 正确：已知形状参数时负二项为单参数指数族；MASS 的 `negative.binomial(theta=...)` 给出固定参数的族，`glm.nb` 则还估计形状参数，不能把两种设置混为一谈。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[2]、[26]、[57]。

解析 题 8.7　分析前先写清观察单位与目标参数

返回题目

（1）匹配资料。 可用条件 Logistic：保留病例/对照状态、匹配组及组内暴露；条件于各组病例数构造条件似然，消去组特异截距。e^{β} 是控制匹配组和其他入模项后的条件 OR；须有组内暴露对比及合适的抽样/独立匹配组条件，不能从病例对照抽样比例直接恢复总体绝对风险。

（2）计数与人时。 可用 $Y_j \sim \text{Poisson}(\mu_j)$、$\log \mu_j = \log T_j + X_j^T \beta$，其中 T_j 为总人时，log 人时作为 offset。e^{β} 是给定其他变量后的率比；检查均值结构、地区独立性和条件离散程度。NB 或准 Poisson 需说明方差/估计方式的改变。地区层面结果也不能直接当作个体层面因果效应。

（3）生存资料。 可用 Cox PH 模型，响应为事件/删失时间及状态，按风险集的偏似然估计系数。e^{β} 是给定协变量后的 HR；需要适当的条件独立删失和比例风险等前提。三者的观察对象与条件化方式不同，不能仅因都能指数化系数就把 OR、IRR、HR 互换。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[2]、[26]。

解析 题 8.8　四个模型中哪些比较有效

返回题目

（1）AIC。 用 $-2\ell + 2k$ 得 A 为 290.0、B 为 285.6、C 为 286.2、D 为 242.0。A、B、C 具有相同观察和响应似然表示，可以比较；D 用了不同的人群子集，不能凭最小的 242.0 直接获选。

（2）A 对 B。 $H_0 : \beta_{XZ} = 0$，$\text{LR} = 2(-138.8 + 142) = 6.4$，参数差 1，$P = 0.0114$。在 0.05 水准拒绝 H_0，支持在这一设定下保留交互项；这不是证明整体拟合完全正确。

（3）B 对 C。 logit 与 probit 模型一般非嵌套，不能套用‘参数个数差’的普通卡方 LR。二者 AIC 差仅 $286.2 - 285.6 = 0.6$，B 在所列准则上略小，但差别很小，也不提供模型为真的证明；还需结合诊断、预测和专业解释。

（4）新增标志物。 至少先固定同一批 210 名完整记录，在其中重新拟合 B 和 D，再做有条件的嵌套比较。不能拿旧 B 的 240 人似然与 D 相减。完整记录分析还需考虑缺失机制及代表性；统一样本保证比较对象一致，并不自动消除缺失造成的选择偏倚。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[55]、[10]。

解析 题 8.9　同一队列表中的 OR、RR、IRR 与 HR

返回题目

（1）固定时点。 风险为 $p_0 = 0.20, p_1 = 0.36$，故 $\text{RR} = 0.36/0.20 = 1.8$；$\text{OR} = (36 \times 80)/(64 \times 20) = 2.25$。

（2）人时率。 非暴露组为 $100(20/420) = 4.7619$ 次/100 人年，暴露组为 $100(36/392) = 9.1837$ 次/100 人年，$\text{IRR} = (36/392)/(20/420) = 1.9286$。风险以基线人数为分母，发病密度以在险人时为分母，二者不是同一参数。

（3）信息不足。 通常 Cox 偏似然需要各事件时间及当时风险集。相同的事件数和总人时可由不同事件次序产生；表中没有每人的事件/删失时间、并列结构及必要的协变量记录，不能据此恢复通常的 Cox HR。

（4）额外 PH 设定。 $S_1(t) = S_0(t)^{\mathrm{HR}}$，所以 $S_1(5) = 0.8^2 = 0.64$，暴露组风险为 0.36，$\mathrm{RR}(5) = 0.36/0.20 = 1.8$。HR 为 2 比较的是瞬时风险，固定 5 年风险并未加倍；一般关系为 $[1 - S_0(t)^{\mathrm{HR}}]/[1 - S_0(t)]$，还依赖基线生存率。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[26]、[2]。

解析 题 8.10　三种显著结果是否构成相同结论

返回题目

（1）不同指标。 给定入模协变量，A 的指数系数为所编码二分类终点的 OR，B 为按人时标准化的计数率比，C 为首次住院 HR。用 $\exp\{\log 2 \pm 1.96\,\mathrm{SE}\}$ 得到 A 约 $(1.644, 2.433)$、B 约 $(1.581, 2.530)$、C 约 $(1.491, 2.684)$。各区间均不含 1，但不是同一种风险的三个重复估计。A 混合了不同长度的观察窗口，不能直接命名为统一的 3 年 OR；在 3 年前结束观察且未住院者也不能据此一概确认为‘3 年无住院’。

（2）需要检查。 B 至少检查均值与人时的比例结构、条件过离散、受试者间独立性，以及观察结束是否与发作过程有关；累计多次住院也须考虑重复事件机制，不能只凭 offset 保证 Poisson 分布。C 至少检查条件独立删失、PH、连续变量形式及记录正确性；分析首次住院与分析所有住院次数回答不同问题。

（3）重写结论与分析。 相同指数系数和显著性不能证明因果效应，观察性研究仍需依据设计和先验知识处理混杂、选择及测量问题。若目标是固定 3 年首次住院风险，应采用能处理删失的分析，报告该时点标准化风险、差或比及不确定性，并说明识别前提。若目标是反复住院负担，则以计数/重复事件和人时为中心重新确定模型。A、B、C 的响应及似然对象不同，C 又通常用偏似然，不能把三者原始 AIC 混排后宣称选出了同一终点的最佳模型。

来源与改编：知识点配套。题干与设问为新编；参考依据[51]、[26]、[55]、[2]。

附录　易错表述与更正

下表汇总学习中容易出现的不准确写法、记号或数据转录错误，并给出本书采用的写法，便于复习时对照。“位置”为本书的节号。

位置	易错写法或表述	本书采用	说明
1.1.1	组成表随机部分写作 $\mu = \hat{y}$	$\mu_i = \mathrm{E}(Y_i \mid \mathbf{x}_i)$；拟合值 $\hat{\mu}_i = g^{-1}(\mathbf{x}_i^\top \hat{\boldsymbol{\beta}})$	区分总体量与估计值
1.1.1	“systemic component”	systematic component	拼写
1.1.2	Cox 回归与 GLM 并列	注明是半参数生存回归模型	不属于标准 GLM
1.2	表 7 取值范围 $(0, n)$、$(0, \infty)$	$\{0, 1, \ldots, n\}$、$\{0, 1, 2, \ldots\}$；区分二项计数与比例	离散分布含端点
1.3.3	对数似然首项 $-\frac{1}{2}\log(2\pi\sigma^2)$	$-\frac{n}{2}\log(2\pi\sigma^2)$	n 个观察之和
1.3.3	“$f(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y})$：给定样本，参数的一个函数”	删去，只保留 $L(\boldsymbol{\beta}, \sigma^2 \mid \mathbf{y}) = f(\mathbf{y} \mid \boldsymbol{\beta}, \sigma^2)$	似然不是参数的密度
1.3.3	$\mathbf{X}$ 为 “$n(m+1)$ 的矩阵”	$n \times (m+1)$	
1.4	公式写作 `Y=X1+X2+X3`；`family=gaussion`	`Y ~ X1+X2+X3`；`gaussian`	公式符号与拼写
1.1，2.1.1	图横轴记为 y（logit 值）	η	线性预测量不是响应
2.1.4	$H_0 : \hat{\beta}_i = 0$	$H_0 : \beta_i = 0$	假设针对总体参数
2.1.4	比分检验批注：$U(\theta)$ 是“均数、对数似然函数”	U 为得分函数，I 为 Fisher 信息	
2.1.4	“Wald 检验未考虑各因素间的综合作用”	删去	多变量 Wald 检验同样是调整后的
2.1.4	“似然比检验结果最可靠”	三者渐近等价，小样本时似然比检验通常更可靠	
2.1.5	“全模型（full model）”	饱和模型（saturated model）	
2.1.5	λ “越小，拟合优度越好”	$\lambda \geq 1$，越接近 1 拟合越好	
2.1.5	广义 χ^2 分母 $\mathrm{Var}(\hat{y})$	模型方差 $n_g \hat{\pi}_g (1 - \hat{\pi}_g)$	
2.1.5	Pseudo R^2 未注明定义	McFadden 定义	
2.2.2	条件概率中的比值记作 $\mathrm{OR}_{B_i} / \mathrm{OR}_{A_i}$；未写对子截距	odds 之比；先引入 α_i 再消去	
2.2.2	表 5 批注：“用药天数越长，不良反应概率越大”	天数每增加 1 天，优势乘 0.478	与系数符号相反

位置	易错写法或表述	本书采用	说明
2.2.2	“合并药物每增加 1 个，发生概率增加 0.012”	优势乘 1.444	0.012 是 P 值
2.2.3	批注“暴露者 $X=0$”	非暴露者 $X=0$	
3.1.2	表 7（分化 2、染色 −、泡状细胞癌）36	26	用 26 才能精确复现表 8
3.1.2	表 8 末列“RR”	RRR（相对风险比）	
3.1.3	批注“分别比较：$P_1+P_3=1$，$P_2+P_3=1$”	分别拟合的是条件概率 $P_1/(P_1+P_3)$	
3.2	“等比例风险假设/假定”	比例优势假设	与生存分析的比例风险区分
3.2	“从 1 级升到 2 级、2 级升到 3 级作用相同”	任一分界点两侧的 OR 相同	前者是相邻类别模型
3.2	不平行时可改用“有序 Probit 模型”	有序 Probit 同样要求平行	
3.2	平行线检验 $P>0.05$“认为满足假定”	未发现违背假设的充分证据	
3.2	例 4：“提高一个及一个以上等级的可能性增加 0.89 倍”	任一分界点上“等级更高”的优势乘以 1.89	
3.3.1	多项 Logit“4 个级别是相互独立的类别”	不使用类别顺序	
3.3.1	累积 Logit“能回答病变进展速度”	横断面资料只能描述严重程度的关联	
3.3.1	“本案例不适合用多项 Logit 模型”	多项 Logit 仍有效；比例优势成立时累积 Logit 更有效率	
3.3.2	2848 个研究对象；1439 个“因痴呆死亡”的病例	1439 对共 2878 人；结局为新发痴呆	$1224+140+60+15=1439$
3.3.2	研究设计“病例对照研究”	双生子队列中的共同双生子配对分析	
3.3.2	TABLE 1：Male 1804；< 8 years 131,46	18,074；13,146	按百分比与合计核对
3.3.2	OR 2.36（95%CI 1.74–2.30）	1.74–3.20	与 TABLE 3 一致
3.4	样本量“变量个数的 20 倍”	事件数为参数个数的 10–20 倍	
3.6	`require(mass)`	`library(MASS)`；响应为有序因子	包名区分大小写
3.6	SAS 有序模型 `link=glogit`	`link=clogit`；`glogit` 用于无序多分类	
3.6	PROC LOGISTIC 未指定事件水平	`y(event='1')` 或 `descending`	否则系数符号相反
4.1.6	“假定观察对象在各个时段的生存事件独立”	由条件概率的乘法公式得到连乘	不需要独立性
4.1.6	$S(t)=$ 存活例数/观察总例数	仅为无删失时的估计	

位置	易错写法或表述	本书采用	说明
4.1.7	有的说法称 F 为“累积的风险函数”	F 为累积发生概率；$H=-\ln S$ 为累积风险	
4.2.1	“对数变换后 $G(t_i)$ 就服从正态分布”	近似服从正态；反变换递减，上下限互换	
4.2.2	KM 法“一般用于观察对象数目较少的资料”	删去	适用于有确切时间的资料
4.2.2	例 3 中 167 未标“+”	167^{+}	与图 9、表 2、表 5 一致
4.2.2	表 4（续）30 月：$0.5401\times0.7500=0.3240$；62 月：$0.2160\times0$	$0.4321\times0.7500=0.3241$；$0.1080\times0$	
4.3.1	表 5 第 3 行为删失时点 $t=3$（$T_{1i}=0.6071$）	只列事件时点	$d_i=0$ 时理论数为 0
4.3.1	表 5 合计死亡数 22	21	$11+10$
4.3.1	精确法：两组的 $(A_g-T_g)^2$ 各除以 6.7578 后相加	$(A_1-T_1)^2/\sum V_{1i}$，$V_1=3.378$	数值 6.772 不变
4.3.1	“分母经方差校正，卡方变大，更容易拒绝 H_0”	近似公式本身偏保守	
4.3.2	“Breslow 针对短期效应，log-rank 针对长期效应”	log-rank 等权，Breslow 以风险人数加权	
4.3.4	“各组生存曲线不能交叉，交叉提示混杂”	交叉使效能下降、提示非比例风险	
5.1.2	“风险比（risk ratio, RR；或 hazard ratio, HR）”；$\mathrm{RR}_j=\exp(\beta_j)$	HR；与固定时点的 RR 区分	
5.1.2	风险集：“在 t_k 时刻及之前仍未发生事件且未删失”	t_k 前一瞬间仍在观察（$\widetilde{T}\geq t_k$）	
5.1.2	表 8 第 5 行：id 8，PI 4.739，$S(t)$ 0.767	id 5，PI 6.174，$S(t)$ 0.899	与表 2 及同 PI 各行一致
5.1.2	“肿瘤分级每增加 1 级，死亡险变为 5.357 倍”	4.816 倍	$\exp(1.572)$
5.2.1	累积风险曲线“应大致平行或等距”	应成比例；$\ln H$（log–log 图）平行	
5.2.2	外在时依协变量：“取值不随时间改变，HR 随时间改变”	那是时变系数 $\beta(t)$；核辐射例归入时变系数	
5.2.2	“在 Cox 回归中，RR 和 HR 是一样的”	删去	
5.2.3	例 8：服药的标准差 0.8，$n\approx135$	0/1 变量标准差 ≤0.5；1 : 1 分配时 $D=241$，$n=344$	
5.2.4	图 2“复发累积风险率”	累积发生率（1 − KM 与 CIF）	
5.3.4	批注“高强度运动反而保护效果减弱”	按图读出 HR；VPA 约 150 min/wk 后趋平	

位置	易错写法或表述	本书采用	说明
5.5	`surv(time,status)`	`Surv(time, status)`	
5.5	Stata 代码以“#”作注释	“//”	
6.1	按收入合并后白人“少”为 160；表头“家庭收入”	106；表头“肤色”	$67+36+3$
6.1	癌症数据合并表：9050、14995	9005、14955	$9000+5$
6.2.1	直接令 $u_1(i)=\ln p_{i\cdot}$ 等；“四个独立参数，四个格子”	按均值分解定义；固定总数时 3 个自由概率参数	零和约束
6.2.2	u_{23}：“变量 2 第 j 级与变量 2 第 k 级”	变量 3 第 k 级	
6.2.2	批注“性别与自杀方式有关”	删去	与本例无关
6.2.2	i：人种；j：分娩次数；k：收入差异	j：收入；k：分娩次数	与表 2、表 3 一致
6.2.3	参数表：有色 × 低收入、有色 × 高收入的 P 值互换；两行 u_{23} 标签互换	已更正，并注明参照水平	
6.2.4	“$P>0.05$ 说明模型符合实际，模型好”	证据不足以否定模型	
6.2.5	$R_{\text{std}}=(O-E)/\sqrt{E}\sim N(0,1)$	Pearson 残差方差小于 1；调整残差近似 $N(0,1)$	
6.2.5	批注“最大 4.6 超过 2，两两关联模型不太好”	该残差表来自完全独立模型	
6.2.6	“当且仅当第三个变量独立于其中一个或两个时”	充分条件	
6.2.6	“交互效应均不为 0，合并将歪曲变量间关系”	一般会改变，但不是必然	
6.3	“5254 例”	5251 例	表中合计
6.3	模型拟合表（df 40、38、36、34、32）	按资料复算（最大 df 18）	
6.3	Logistic 回归及交互项结果（如 X1:Y1 OR 1.25，$P=0.01$）	按资料复算，未见交互作用	
6.3	“Logistic 无法分析自变量与结局的交互”“通常需要个体资料”	对应关系见补充推导；分组资料同样适用	
6.5	SAS、Stata 代码以“#”作注释	“/* */”、“//”	
7.1	“$\log(\widehat{Y})$ 可由线性组合拟合”	$\log \mathrm{E}(Y\mid \mathbf{x})=\mathbf{x}^{\top}\boldsymbol{\beta}$	
7.1.2	$\ln P_{ij}=\ln(\mu_{ij}/n_{ij})$	$\ln r_{ij}$	发生率不是概率
7.1.2	表 5：G^2 167.607、7.862、133.976、2.493	167.034、7.810、133.450、2.475	R 复算，结论不变
7.1.2	表 6：系数 0.35、1.17、1.90、3.40、4.10 及相应 RR、区间	0.409、1.311、2.140、3.020、3.790	与同表 SE、Wald 一致
7.1.2	表 7 单位“‰”	每千人年	

位置	易错写法或表述	本书采用	说明
7.2.1	负二项均数 $(1+\kappa)\lambda$，方差 $(1+\kappa)\lambda(1+\lambda)$	均数 μ，方差 $\mu+\alpha\mu^2$（NB2）	
7.2.2	过离散 χ^2：模型 C 27.1824、模型 D 32.8259（df = 1）	58 人分析集为 30.50、12.74；边界检验 P 值减半	原值来自 59 人
7.2.2	“负二项不容易犯假阳性错误，结果更保守”	Poisson 低估方差；NB 修正了方差	
7.2.4	主分析“至少 14 天”、敏感性分析“至少 7 天”；人年 ×1000	主分析至少 7 天、敏感性分析至少 14 天；人日 ×100000	与原文方法一致
7.2.5	删除就诊次数为 0 者以满足等离散	撤销；全样本用负二项，或零截断模型	
7.3	`offset=` 留空；用 qcc 包检验 Y 本身的过离散	`offset(log(t))`；以模型残差检查过离散	
7.3	SAS `model y/n=... offset=ln`	`model y=... offset=ln_t`	Poisson 响应为计数
7.3/7.4	Stata `exposure(offset)`、`offset(offset)`	`exposure(t)` 或 `offset(ln_t)`	
8	各章对应表述	按以上各条同步更正	

资料局限说明

- 第 5 章例 5：原资料只给出 30 例中的 11 例记录，表 9 无法复算；表 8 的 PI 列所用系数与表 9 略有出入，8 号患者记录与 5 号完全相同，原因不明。relapse 没有记录复发时间，无法检查是否引入了未来信息。
- 第 7 章癫痫例：本书所用资料与公开的 Thall–Vail 资料（R `MASS::epil`）有 7 行在发作次数或年龄上不同；本书按所列资料计算，可复现原分析的模型 C、D。
- 第 7 章职业暴露例：G^2 与原资料相差 0.02–0.57，原因不明；Pearson χ^2、系数标准误、Wald χ^2、预测值和残差均与原资料一致。
- 第 3 章案例 1、第 7 章儿童发热例的结果表为示意数据，没有原始资料，未作复算。

来源与选编依据

以下“来源”指数据、研究材料或知识点依据。除特别说明外，本册的问题、选项和解析均为配套编写；不将其标作教材原题或往年真题。各题后的编号链接到本节。公开网页核对日期为 2026 年 10 月 11 日。

[1] 用户原笔记：广义线性模型，第 1 章基本概念与方法

定位：指数分布族、三个组成部分、WLS、极大似然、IRLS 及 R 调用；对照 ex1.tex 的 19 道编号题。

课程范围和题型的首要依据。原章已有四格表似然、逆方差权重与 Poisson 指数族推导，本章补充比例权重、工作权重、非典型连接及一次 IRLS 更新等角度。

https://github.com/fxt-gw-pb/public-health-statistics-notes/blob/2d799e0af68ae6a472a44f25aefbeec8cb59a1e1/notes/glm/content/lec1.tex

[2] R stats 官方文档：glm；Dobson 教材第 93 页案例

定位：Details、Value；Examples 首例明确标注 Dobson (1990), p.93, Randomized Controlled Trial。

9 格频数及两个因子的生成方式均可直接核对。教材为 An Introduction to Generalized Linear Models；页码来自 R 官方示例注释，本次未把教材原页当作已直接取得。第 1 章补充题 8 保留数据，输出由 Python 独立拟合并核对解析解，设问重新编写。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/glm.html

[3] R stats 官方文档：family

定位：Arguments、Details 与 Value：分布、连接、二项响应表示及 mu.eta。

核对概率向量需给试验次数权重、二项可用 probit、方差函数与逆连接导数。题目中的 Gamma 累积量函数及教学参数为配套设定，不是此页原题。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/family.html

[4] R stats 官方文档：lm

定位：weights 参数与 Details 中方差权重和频数权重的区别。

第 1 章补充题 4 限定为未知共同尺度下的相对精度权重，避免与复制观测的频数权重混淆；不从该文档的复制权重解释推出同一标准误结论。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/lm.html

[5] R stats 官方文档：predict.glm

定位：Arguments 中的 type、se.fit 与 Value。

用于核对 link 尺度与 response 尺度；第 1 章补充题 8 只要求条件均值及模型条件方差，不把均值标准误当作个体响应标准差。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/predict.glm.html

[6] R stats 官方文档：Lognormal

定位：Details 中的均值、中位数与方差公式。

第 1 章补充题 10 为正值连续生物标志物的教学模型；所有参数均为新设定，重点是对数响应回归的反变换，并未虚构患者研究结果。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/Lognormal.html

[7] 原笔记：广义线性模型第 2 章《Logistic 回归模型（一）》

定位：非条件 Logistic：概率尺度、病例对照抽样、三种检验、函数形式与预测评价；条件 Logistic 及 1:M 匹配。

已全文通读本轮提供的 lec2.tex、lec3.tex 及 ex2.tex 全部 20 题与解析。这里的习题均为本次配套新编，未冒称找回的往年原题。

https://github.com/fxt-gw-pb/public-health-statistics-notes/blob/2d799e0af68ae6a472a44f25aefbeec8cb59a1e1/notes/glm/content/lec2.tex

[8] R datasets 官方文档：Smoking, Alcohol and (O)esophageal Cancer

定位：Description、Format、Source；Breslow 与 Day(1980)，Statistical Methods in Cancer Research, Vol.1。

官方文档明确为法国 Ille-et-Vilaine 食管癌病例对照资料，共 88 个年龄/饮酒/吸烟组合。第 08 题使用完整资料及原始饮酒标签，重新设计约束检验与非参照组对比；不使用原 H2-1 饮酒表头颠倒的粗合并表，不声称为 Breslow 与 Day 原题。

https://stat.ethz.ch/R-manual/R-devel/library/datasets/html/esoph.html

[9] R 源文件：esoph.R（固定版本）

定位：完整 agegp、alcgp、tobgp、ncases 与 ncontrols 五列。

通过 GitHub 读取完整 R 数据源，校验 blob SHA-1 为 547ef0de8ca3645858d078b189cbc430c341b812。脚本从该文件生成 esoph.csv，88 行合计 200 病例和 775 对照；未凭研究场景补造个体数据。

https://github.com/wch/r-source/blob/02e4ee85542c87153eab3bed860fdd6ffd9920be/src/library/datasets/data/esoph.R

[10] R stats 官方文档：anova.glm

定位：Details、Warning：嵌套模型、LRT/Rao 及同一分析集要求。

用于核对似然比与有效比分检验的实现范围；第 08 题三个模型均使用同一 88 行资料及同一分组二项似然。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/anova.glm.html

[11] R survival 官方文档：clogit

定位：Description、Details：条件似然、strata、每组 1 病例 +k 对照与权重限制。

第 05、06、09 题依条件似然原理新编。第 09 题 36 组资料为明确教学构造；R 脚本展开 108 个个体后按 strata(set_id) 拟合，不把模式频数塞入 exact 方法的 case weights。

https://stat.ethz.ch/R-manual/R-devel/library/survival/html/clogit.html

[12] 原笔记：广义线性模型第 3 章《Logistic 回归模型（二）》

定位：多项联合似然、参照变换、累积 logit 阈值与共同斜率、平行线检验、软件附录。

已全文通读 lec3、lec2 和 ex2 既有 20 题及解析；新增内容针对跨方程方差、概率方向、等级反向、频数权重和真实嵌套的平行线检验，不声称教材原题。

https://github.com/fxt-gw-pb/public-health-statistics-notes/blob/2d799e0af68ae6a472a44f25aefbeec8cb59a1e1/notes/glm/content/lec3.tex

[13] MASS 官方文档：Frequency Table from a Copenhagen Housing Conditions Survey

定位：Description、Format、Source 和 Examples 中的 multinom、polr。

72 行、5 变量；Freq 为人数频数，Sat 是低/中/高有序满意度。官方列出 Madsen(1976), Scandinavian Journal of Statistics 3:97–106；Cox 与 Snell(1984), Applied Statistics, Principles and Examples；Venables 与 Ripley(2002), Modern Applied Statistics with S 第 4 版。本章改写设问并复算公开数据，不冒称上述著作的原题号。

https://stat.ethz.ch/R-manual/R-devel/library/MASS/html/housing.html

[14] MASS 原始 housing 数据文件（固定版本）

定位：RDX2 序列化的 4 个因子和 Freq 列；完整 72 条记录。

以 base64 保存原始 rda，blob SHA-1 为 4c05ece13abe037bcd05378fd72b5d251e53aa1d。Python 将 4 列因子全部代码与标签、72 个频数逐格对照 CSV，360 个数据值一致。CSV 格式转换来源另列，不把格式转换站当作方法学证据。

https://github.com/cran/MASS/blob/3a2c25676400941722e79b5dd771785a6d678ea4/data/housing.rda

[15] Rdatasets：housing.csv 固定版本

定位：完整 72 行 CSV，另有 rownames 行号列。

仅用作公开 R 数据的 CSV 格式取得路径。全部实质数据已与 MASS 原始 rda 核验一致；方法解释引用 MASS/nnet 官方文档，不引用该镜像作技术依据。

https://github.com/vincentarelbundock/Rdatasets/blob/cc03c29690889dbe83089f5206e2422db8c3f71f/csv/MASS/housing.csv

[16] MASS 官方文档：polr

定位：Details：logit P(Y≤k)=zeta_k-eta；有序阈值、共同斜率；Arguments weights/Hess。

已核对正文方向与 MASS 参数化相同。第 09 题共同斜率模型用相邻累积概率之差构成联合似然；非平行模型由本次 Python 独立实现，不把 multinom 误作嵌套的平行线备择。R 脚本附完整复现方法但本环境未执行。

https://stat.ethz.ch/R-manual/R-devel/library/MASS/html/polr.html

[17] nnet 官方文档：multinom

定位：Arguments：首个类别参照、频数响应与 weights；Value：deviance、Hessian、edf。

用于核对联合多项 logit、类别参照和频数权重约定。第 08、10 题采用 housing 真实计数；跨方程对比和权重遗漏评议为本次新设问。

https://stat.ethz.ch/R-manual/R-devel/library/nnet/html/multinom.html

[18] Venables 与 Ripley：《Modern Applied Statistics with S》第 4 版作者网站

定位：Contents 第 7 章 Generalized linear models；Software and Datasets。

作者网站核实 2002 年第 4 版及随书 MASS/nnet 软件、数据的关系。本章只使用已核对的官方数据和方法，未声称取得 housing 在原书的精确页码或习题号。

https://www.stats.ox.ac.uk/pub/MASS4/

[19] 本仓库《广义线性模型》第 4 章：生存分析（一）

定位：右删失与独立删失；左截断/延迟入组；寿命表；KM 与 Greenwood、log–log 区间；logrank 及 Breslow 权重；固定时点比较。

范围依据。全文核对 lec4、lec5 和 ex3 的 30 题及解析；SUPG4 均为新增题，未冒称往年题或教材原题号。

https://github.com/fxt-gw-pb/public-health-statistics-notes/blob/2d799e0af68ae6a472a44f25aefbeec8cb59a1e1/notes/glm/content/lec4.tex

[20] R survival 官方手册：Surv

定位：Arguments 与 Details：事件指示、counting 格式和 (start,stop] 约定。
核对编码与观察区间的规则，不提供本题的教学数据。
https://stat.ethz.ch/R-manual/R-devel/library/survival/html/Surv.html

[21] R survival 官方手册：survfit.formula

定位：Details 及 conf.type、conf.lower、start.time 参数。
核对 KM 估计、log–log 区间和尾部支持。题内数值为本次计算；不把默认 log 区间误称 log–log 区间。
https://stat.ethz.ch/R-manual/R-devel/library/survival/html/survfit.formula.html

[22] R survival 官方手册：survdiff

定位：Description：G-rho 检验族，rho=0 为 logrank，rho=1 为 Peto–Peto 修正。
直接核对软件权重名称与检验用途。按课程定义计算的 Breslow 风险人数加权统计量另行编程，不冒充 rho=1 的输出。
https://stat.ethz.ch/R-manual/R-devel/library/survival/html/survdiff.html

[23] R survival 官方手册：Veterans' Administration Lung Cancer study

定位：Description、Format、Source。
官方说明为两种肺癌治疗方案的随机试验，列出细胞类型及变量，并追溯 Kalbfleisch 与 Prentice（1980）The Statistical Analysis of Failure Time Data。未核得或虚构教材习题编号；这里只作为数据案例来源。
https://stat.ethz.ch/R-manual/R-devel/library/survival/html/veteran.html

[24] Terry Therneau 维护的 survival 源码：cancer.rda 中的 veteran 对象

定位：原始 R 数据对象 veteran，完整 137 行、8 列。
已通过 GitHub 读取作者文件并解出 137 行、128 死亡、9 删失，保留全部变量及顺序。blob SHA1 ae84cad9d8ca02965e42a021c58415adec3eefd7 已由原字节复核。第 8 题表格是本次独立重算，不是缺失 40 例作业文件的还原。
https://github.com/therneau/survival/blob/645743ffb18180d16cdba7cb83cb71c4d4cfd448/data/cancer.rda

[25] 本仓库《广义线性模型》第 5 章：生存分析（二）

定位：Cox 部分似然及得分/信息；并列处理；基线参照；PH 评价；时依变量与时变系数；分段数据；模型诊断。
直接范围依据。已全文读取 lec4、lec5 及 ex3 全部 30 题/解析。新设问避开原无并列部分似然、简单交互 HR 及 PI 到生存率题。
https://github.com/fxt-gw-pb/public-health-statistics-notes/blob/2d799e0af68ae6a472a44f25aefbeec8cb59a1e1/notes/glm/content/lec5.tex

[26] R survival 官方手册：coxph

定位：ties；Details 的 (start,stop]；Special terms 的 strata 和 tt；Ties。
用于核对 Efron/Breslow 约定、分层及时间变换接口。题内统计量均自行计算，不冒称官方文档原练习。
https://stat.ethz.ch/R-manual/R-devel/library/survival/html/coxph.html

[27] R survival 官方手册：cox.zph

定位：terms、global 参数及 Details 中的缩放 Schoenfeld 残差/时间效应检验。

第 3 题为依据官方输出结构构造的教学表，四个 P 值经 χ^2 分布复算；不是对 veteran 实际运行 cox.zph 所得的结果。

https://stat.ethz.ch/R-manual/R-devel/library/survival/html/cox.zph.html

[28] R survival 官方手册：survfit.coxph

定位：Notes 中任意参照向量 z 的生存曲线转换关系；Details 中建议提供 newdata。

核对基线参照并非唯一、中心化应配合相应基线；第 1 题年龄参数为教学构造。

https://stat.ethz.ch/R-manual/R-devel/library/survival/html/survfit.coxph.html

[29] Therneau、Crowson、Atkinson：Using Time Dependent Covariates and Time Dependent Coefficients in the Cox Model

定位：§2（PDF 第 1–4 页）：当前协变量、不能使用未来、肌酐示范及分段记录；§4.2（PDF 第 21–22 页）：错误的最终 time 交互与 tt()。

作者官方 vignette，页面显示 2026-01-12。第 5 题按该接口错误新设问；第 10 题沿用其 0/90/120/185 天及 0.9/1.5/1.2 的教学示范记录并新增评议问题。该记录不称作真实患者研究数据。

https://stat.ethz.ch/R-manual/R-devel/library/survival/doc/timedep.pdf

[30] Terry Therneau：A Package for Survival Analysis in R

定位：PDF 第 70–71 页，使用 veteran 及 trt + celltype + karno 的 Cox 示例。

直接支持第 8 题所用公开案例及模型结构；本题将 karno 按每 10 分并中心化、治疗改为 0/1 以便解释，新增整体 LR 与腺癌对小细胞对比。文档未被当作本题新数表的现成输出。

https://stat.ethz.ch/R-manual/R-patched/library/survival/doc/survival.pdf

[31] 原笔记：广义线性模型——对数线性模型

定位：抽样方案与似然分解；参数约束；层次模型；独立性与折叠；拟合优度与残差；与 Logistic 的联系。

已通读 lec6 及 ex4 全部 24 题。设问均为本次新编或案例改编，不冒称原书习题；题 10 区分 1df 共同效应比较与多自由度整体拟合检验。

https://github.com/fxt-gw-pb/public-health-statistics-notes/blob/2d799e0af68ae6a472a44f25aefbeec8cb59a1e1/notes/glm/content/lec6.tex

[32] R stats 官方手册：loglin—Fitting Log-Linear Models

定位：Arguments margin；Details 中的 IPF 及最大生成边际；Value 中的 lrt、pearson、df。

算法和边际约束依据。数值由本次 Python IPF 与 GLM 复算；没有把官方示例中的文字标签替代实际模型生成项。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/loglin.html

[33] MASS 官方手册：loglm—Fit Log-Linear Models by Iterative Proportional Scaling

定位：Details：structural zeros 与自由度限制；Value：deviance。

用于结构零与抽样零的区别及建模限制；本次全部数值例表没有结构零。

https://stat.ethz.ch/R-manual/R-devel/library/MASS/html/loglm.html

[34] R datasets 官方手册：HairEyeColor—Hair and Eye Color of Statistics Students

定位：Description；Details；Source；References：Snee(1974)、Friendly(1992, 2000)。

Hair×Eye 二维表源于 Snee 1974 的 592 名学生调查；Sex 分层由 Friendly 1992 为教学补入，后有调整。因此题 9 明确为官方内置教学表，不能用于真实性别差异推断。

https://stat.ethz.ch/R-manual/R-devel/library/datasets/html/HairEyeColor.html

[35] R 官方源码镜像：HairEyeColor.R

定位：HairEyeColor 数组的 dim=c(4,4,2) 及 dimnames；快照 blob 04d6a3ead011911efab7979aa07214db15c0c85b。

已保存读取到的源文件及 32 格 CSV，总数 592。原文字面向量重复同一组 32 数，按数组指定维度提取；该重复经脚本核对，未计为 1184 人。

https://github.com/wch/r-source/blob/trunk/src/library/datasets/data/HairEyeColor.R

[36] R datasets 官方手册：UCBAdmissions—Student Admissions at UC Berkeley

定位：Description；Format；Details；References：Bickel, Hammel & O'Connell(1975), Science 187:398–404。

官方 24 格记录用于题 10；选题与模型输出为本次改编和复算。未把 OR 说成录取概率比，也未从观察表作因果断言。

https://stat.ethz.ch/R-manual/R-devel/library/datasets/html/UCBAdmissions.html

[37] R 官方源码镜像：UCBAdmissions.R

定位：Admit×Gender×Dept 数组；快照 blob 10be1b0b30af8f304ee47dc1b9a2200e22ac9d18。

已保存原始 R 数组及无删改 24 格 CSV，总数 4526；按文档水平排列重新拟合。

https://github.com/wch/r-source/blob/trunk/src/library/datasets/data/UCBAdmissions.R

[38] 原笔记：广义线性模型——泊松回归与负二项回归

定位：Poisson 均数与条件方差；发生率和 offset；过离散；NB2；准 Poisson；案例与应用限制。

已通读 lec7 和 ex4 全部 24 题。本章为配套新编/案例改编；完整 DoctorVisits 公式与原题的删零子集、校园完整 81 校与原笔记改动 10 行表明确分开。

https://github.com/fxt-gw-pb/public-health-statistics-notes/blob/2d799e0af68ae6a472a44f25aefbeec8cb59a1e1/notes/glm/content/lec7.tex

[39] R stats 官方手册：Poisson—The Poisson Distribution

定位：Details：Poisson 概率质量函数、均数与方差。

用于教学设定的计数均数、零概率及条件/边际分布推导，不提供任何研究原始计数。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/Poisson.html

[40] R stats 官方手册：offset—Include an Offset in a Model Formula

定位：Description；Usage；Details：已知系数固定为 1 的模型项。

区分真正暴露时间 offset 与随机基线事件数协变量；公式内 offset 位置用于校园代码审阅。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/offset.html

[41] R stats 官方手册：summary.glm—Summarizing Generalized Linear Model Fits

定位：Details：dispersion 的 Pearson 估计；t 或 z 参照分布；系数标准误。

题 3 给出教学摘要并按官方尺度和检验规则复算；其原始输出并非某真实研究。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/summary.glm.html

[42] R stats 官方手册：NegBinomial—The Negative Binomial Distribution

定位：Details：mu 与 size 参数化；variance=mu+mu^2/size；概率质量函数。

使用 alpha=1/size 的 NB2 参数化；方差、零概率与同均数比较均由本次脚本计算。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/NegBinomial.html

[43] MASS 官方手册：glm.nb—Fit a Negative Binomial Generalized Linear Model

定位：Usage：formula,data,weights 的形参次序；Arguments：排除 offset 形参但可在公式中用 offset()；Details。

提供 NB2 拟合方法及校园实参匹配的函数签名。题 9 为 Python 复算，不冒称本环境执行了 MASS；题 10 为独立静态代码审阅。

https://stat.ethz.ch/R-manual/R-devel/library/MASS/html/glm.nb.html

[44] AER 官方参考手册：DoctorVisits；CameronTrivedi1998

定位：DoctorVisits 数据说明与变量定义；CameronTrivedi1998 示例 Table 3.3 的 visits~.+I(age^2) 及 Table 3.4 的 NB 模型。

真实数据 5190 人，结局为过去两周就诊次数；官方示例明确完整变量加年龄平方。文献为 Cameron & Trivedi(1986), Journal of Applied Econometrics 1:29–53；(1998) Regression Analysis of Count Data, Cambridge University Press。题 9 为新设问和 Python 派生输出，不声称原书题号。

https://cran.r-project.org/web/packages/AER/refman/AER.html

[45] CRAN AER 源码镜像：DoctorVisits.rda

定位：官方数据对象 DoctorVisits；快照 blob 83b783952aa9b59b8b1c654897f9ef37e547b9a0。

已保存原始 R 数据对象并导出 5190×12 完整 CSV；无缺失，4141 个零就诊者全部保留。派生的逐人拟合均数与零概率另存 CSV。

https://github.com/cran/AER/blob/master/data/DoctorVisits.rda

[46] Roback & Legler：Beyond Multiple Linear Regression，Bookdown 版第 4 章

定位：4.5 Case Study: Campus Crime；4.8.3 Negative Binomial Modeling。

核对 81 校案例、合并 SE/SW、删除 nvrate>=5 学校及外置未命名 offset 调用。代码解释是本次根据函数签名/R 规则的分析，非作者已确认勘误；不把该调用输出当成正确 offset 模型结果。

https://bookdown.org/roback/bookdown-BeyondMLR/ch-poissonreg.html

[47] BeyondMLR PreTeXt 版：4.8 Overdispersion

定位：4.8.3 Negative Binomial Modeling；网页代码行 577–580（本次抓取）。

本次查看的 PreTeXt 网页仍展示同样的外置未命名 offset 调用，不能称其已修正；与 Bookdown 和 GitHub 源快照分别标注。未来更新须重新核对。

https://pretextbooks.github.io/BeyondMLR/sec-overdispPois.html

[48] 教材作者 GitHub：data/c_data.csv

定位：全部 81 行、6 变量；快照 blob 27d10d17d9aa46e80d9812eea4746d9e6f1572a4。

原第二行 Enrollment=540、enroll1000=0.54，不能与笔记的 1040/1.04 改动版混同。已保存完整 CSV，按源规则审计筛选，不追认改动版数值。

https://github.com/proback/BeyondMLR/blob/master/data/c_data.csv

[49] 教材作者 GitHub：04-Poisson-Regression.Rmd

定位：校园 c.data 预处理；nvrate<5 筛选；c.data2 的 enroll1000 下限钳制；modelinb 调用；快照 blob 347ccaba381f2f422b8f7151c1b18540cba83479。

已读取作者源码并记录链接与快照哈希；随包不附整章书籍源码。题 10 将原 mutate 钳制整理为等价 transform/pmax 以便独立阅读，属代码审阅改编；不声称在本环境实际运行了 R。

https://github.com/proback/BeyondMLR/blob/master/04-Poisson-Regression.Rmd

[50] R Core：The R Language Definition

定位：4.3.2 Argument matching：先名称精确/部分匹配，再位置匹配。

与 MASS 公开形参次序共同构成题 10 的静态分析依据；等价 R 脚本另给 match.call 检查语句，但本环境未运行 R。

https://stat.ethz.ch/CRAN/doc/manuals/r-devel/R-lang.html#Argument-matching

[51] 用户原笔记：广义线性模型，第 8 章总复习与模型比较

定位：各模型对照表、变量/似然/效应指标、模型诊断和综合案例；并回核第 2、5、7 章对应细节。

为 8 章正文中的复习章单独安排 10 题。数值均为教学构造，综合不同模型的估计目标与前提，不把本次问题冒充原考试题。

https://github.com/fxt-gw-pb/public-health-statistics-notes/blob/2d799e0af68ae6a472a44f25aefbeec8cb59a1e1/notes/glm/content/lec8.tex

[52] Greenland、Robins、Pearl（1999）：Confounding and Collapsibility in Causal Inference

定位：Statistical Science 14(1):29–46；第 4 节可折叠、第 5.1 节混杂与不可折叠的区别。

核对‘调整前后 OR 不同不等于一定存在混杂’的论证。第 8 章补充题 1 使用自行构造的概率表，并非复制论文 Table 1 或 Table 2。

https://www.stat.ubc.ca/~rollin/papers/GreenlandStatSci1999.pdf

[53] geepack 作者文档：On the usage of the geepack

定位：第 1.2 节与第 2–3 节：簇、相关结构、重复测量与 id/waves。

只用作复习章重复观察结构的选择依据，不引入超出原笔记要求的 GEE 估计推导。第 8 章补充题 2 的 400 人 ×4 期为教学设定。

https://cran.r-project.org/web/packages/geepack/vignettes/geepack-manual.pdf

[54] pROC 作者项目页与 Robin 等（2011）软件论文

定位：Description、Citation 及官方 ROC 分析文档入口。

支持 ROC/AUC 的评价对象；严格递增变换保持排序的结论由本题直接推导。附 8 条教学记录检查 AUC 相同而 Brier 分数不同，不借用作者临床数据。

https://xrobin.github.io/pROC/

[55] R stats 官方文档：AIC

定位：Description 与 Details：参数惩罚、相同数据、对数似然常数及不同响应尺度。

第 8 章补充题 8 的四行输出为明确给定的教学摘要；只复算 AIC 和合法的 LR 比较，不声称来自未提供的真实 240 人数据。

https://stat.ethz.ch/R-manual/R-devel/library/stats/html/AIC.html

[56] Stata 官方手册：nbreg

定位：第 9 页 Technical note：alpha=0 时的 50:50 混合卡方参照分布。

只核对一个常数 NB2 离散参数的边界检验。第 8 章补充题 5 的 LR=3.0 为教学数值；不能把该混合分布无条件推广到额外零膨胀参数或多参数离散模型。

https://www.stata.com/manuals/rnbreg.pdf

[57] MASS 官方文档：negative.binomial

定位：Description 与 theta 参数：已知 theta 的负二项 GLM 族。

区分固定形状参数时的指数族模型与 glm.nb 额外估计形状参数的交替迭代；本章不对未知离散参数作固定已知处理。

https://stat.ethz.ch/R-manual/R-devel/library/MASS/html/negative.binomial.html

按题号查看选编理由

第 1 章广义线性模型基本概念与方法

题 1.20 比例响应中的试验次数权重：承接原题的方差与权重辨析，加入‘人数不同但比例相同’的响应尺度问题。

题 1.21 线性预测子中的二次项：补充原章‘系统部分’定义的实际识别，并为后续非线性暴露效应和区间对比作准备。

题 1.22 由累积量函数恢复均值和方差：避开正文已有的 Poisson 推导，训练从给定累积量函数辨认均值、方差及典型连接。

题 1.23 统一缩放相对精度权重：由原题‘权重取方差倒数’推进到尺度识别，防止把归一化权重误当作增加信息量。

题 1.24 相同线性预测值与不同逆连接：从连接函数的名称辨认推进到实际概率尺度，并为后续系数解释限定条件。

题 1.25 含截距 Poisson 模型的得分性质：沿用原题的 I/II/III 组合形式，将极大似然思想落实到可检查的软件拟合性质。

题 1.26 先验权重与工作权重为何不同：补充 WLS 与 IRLS 之间最容易混淆的对象和方差关系，为下一道迭代计算题提供概念支撑。

题 1.27 Dobson 案例：由 glm 输出还原模型：沿用原作业的模型定义、软件系数和拟合解释题型；以能核对全数据的经典例子替代缺失数据依赖。

题 1.28 完成一次二项 IRLS 更新：原题侧重列举估计方法，本题补可手算的一轮 IRLS，并用得分而不是外观判断收敛。

题 1.29 对数响应回归与 log 连接 GLM：延续原脂联素作业的连续指标背景，增加对数尺度结果解释与模型选择依据的完整评议。

第 2 章 Logistic 回归模型（一）

题 3.21 同一 OR 与不同概率差：从原题的单个 OR 释义推进到同一模型下不同基线概率的比较，检验能否在优势与概率尺度之间正确转换。

题 3.22 病例对照抽样后的概率校正：原题多停留在病例对照不能直接给风险，本题在抽样比明确时要求完成可识别的截距校正。

题 3.23 分组二项响应的事件方向：补足原题没有直接考查的 R 二列响应方向，要求同时判断系数、概率与偏差三者。

题 3.24 三种检验分别需要哪些拟合：避开原题简单选择总体检验名称，改考干扰参数存在时三种检验的拟合位置。

题 3.25 1:2 匹配组的条件概率：由原题 1:1 配对扩展到正文已定义的 1:M 条件似然，要求正确使用组内全部候选病例。

题 3.26 条件 Logistic 可估计的内容：补足原匹配题只问没有截距的局限，区分组内恒定主效应与其可识别交互项。

题 3.27 二次项与指定区间的 OR：原题考两二分类暴露交互，本题考连续变量二次项的完整对比与联合检验，避免仅换交互题数字。

题 3.28 食管癌公开资料中的饮酒评分约束：在已定位 esoph 案例中新增四分类对线性评分的两个约束和非参照饮酒组对比，避免重做原 H2-1 表格、原有简单总体检验或二分类交互题。

题 3.29 1:2 匹配六种模式的完整条件似然：原有计算题只含 1:1 配对四格表。本题提供完整 1:2 匹配六模式，需使用两种不同分母并求解条件 MLE，新增信息量与区间。

题 3.30 平均预测正确是否足够：原题只笼统列拟合评价指标，本题给自足验证频数表，要求指出总量抵消、截距得分性质与分组校准之间的差别。

第 3 章 Logistic 回归模型（二）

题 3.31 跨方程对比的方差：原题已考换参照时系数相减，本题进一步考换参照后的不确定性与跨方程协方差。

题 3.32 正系数与类别概率的方向：原题只算给定点的三类概率，本题检验分母竞争如何使正的相对效应与负的类别概率变化同时出现。

题 3.33 有序等级反向编码：原有题目只解释给定阈值和斜率，本题要求同时处理结局顺序反转、阈值排序和符号。

题 3.34 累积概率的合法次序：补足从相邻累积概率还原类别概率时的基本合法性检查。

题 3.35 多类别预测因子的联合检验：在正文单个数值自变量的总体检验上加入多分类自变量，补足哑变量与多方程共同计数。

题 3.36 比例优势的比较对象：原题已有比例优势名词解释，本题用比较反向与相邻类别对比组合，检验能否识别定义不覆盖的结论。

题 3.37 分别二分拟合能做什么：正文提到分别二分可诊断平行性；本题补足同一结局重复编码的依赖、正式联合似然和诊断工具的边界。

题 3.38 住宅满意度多项模型的联合与跨方程检验：使用新公开案例考多水平预测因子的跨方程整体检验和直接差异推断，不重做原肿瘤题的单点概率与系数换参照。

题 3.39 住宅满意度的共同斜率模型：原有题目主要问共同 OR 及参数个数，本题新增有序类别概率、正共同斜率下中间类别的实际变化，以及真实嵌套备择的平行线检验。

题 3.40 遗漏频数权重后分析了什么：以完整公开 housing 的表结构构造分析错误，考频数权重与单位；评论是教学情境，不归于原论文或教材作者。

第 4 章生存分析（一）

题 5.31 延迟入组与风险集：补足原题未实际计算的左截断/延迟入组风险集，并明确边界约定。

题 5.32 独立删失的条件：原题多问删失定义，本题转向估计所需的条件，并区分条件独立与边际独立。

题 5.33 分组记录与区间内顺序：不再重复原寿命表内插题，而是从同一汇总表的极端顺序理解半数删失修正及信息损失。

题 5.34 生存率区间的反变换：在原有 Greenwood 标准误计算基础上，增加变换区间端点方向和概率边界的实操判断。

题 5.35 并列事件时的期望与方差：补充原选择题未覆盖的 logrank 方差构造，防止将并列事件按独立二项或 Poisson 计数处理。

题 5.36 检验权重与软件选项：原题已有权重的定性比较，本题补上软件实现的非等价性及检验选择程序。

题 5.37 相同中位数能说明什么：利用相同中位数但时间形态不同的自洽资料，补充原名词解释题未训练的统计目标区分。

题 5.38 公开肺癌资料的生存输出：采用作者公开完整 137 例资料，改问四种病理类型、固定时点与整体检验，不重复原缺数据 40 例作业的治疗曲线设问。

题 5.39 两种生存检验的计算：新增完整权重与方差计算，定量展示曲线交叉时贡献抵消；既有题只有检验名称及定性比较。

题 5.40 诊断后登记的生存报告：将左截断、目标人群与信息性失访结合成原练习没有的登记资料评议，强调正确软件不能恢复未观察的早期结局。

第 5 章生存分析（二）

题 5.41 改变协变量的参照点：避开已有 PI 计算题，改练基线风险对协变量中心化的依赖及模型表示不变性。

题 5.42 并列事件的部分似然：原练习的部分似然只有无并列例；本题直接比较两种常用并列处理，便于理解软件输出差异。

题 5.43 变量检验与全局 PH 检验：将原题的 PH 定义与检查方法推进到逐项/全局输出不一致的判断，避免把诊断 P 值当作效应 P 值。

题 5.44 分层 Cox 模型的解释：原题虽列分层 Cox 作为 PH 修正途径，但未考层内共同系数与层间效应不可直接读出的边界。

题 5.45 时间交互的代码判读：对应作者文档的常见实现错误，避免只会写 X×time 而没有理解每个风险集的当前时间。

题 5.46 时依变量与分段记录：用组合命题区分时依协变量、时变系数和分段数据，不重复原题的固定协变量 PH 定义。

题 5.47 重新表达时间尺度：从部分似然仅比较风险集的机制推导时间重标度不变性，超出原题的口头定义但不引入新模型。

题 5.48 分类变量的整体检验与指定对比：作者官方生存分析 vignette 使用 trt+celltype+karno 模型；本题保留该数据/模型结构，新增整体 LR 与两个非参照水平的协方差对比，避免重复原 40 例治疗作业。

题 5.49 时间更新用药状态的风险集：在原无并列部分似然例之外，增加实际变化的协变量、分段资料、得分/信息与末次无信息事件的完整计算。

题 5.50 检验值更新能否使用未来信息：保留作者文档的公开教学记录，新增分段样本量、X(t)/beta(t) 和内部变量解释的综合评议，未假造真实临床研究结果。

第 6 章对数线性模型

题 7.25 按层次原则删项：补充高阶模型的实际删项操作；原题主要考层次定义或三维模型识别。

题 7.26 部分独立模型的拟合频数：把最大生成项与所保留的边际联系起来，补充拟合频数而非只判读独立关系。

题 7.27 参数约束改变与优势比不变：针对笔记零和约束与软件参照编码的衔接，避免将两种参数值直接互换。

题 7.28 抽样零格的偏差贡献：补充零格的局部偏差计算和抽样零/结构零区别，原题未有此残差陷阱。

题 7.29 Logistic 交互项的对数线性对应：由明确的 Logistic 交互式反推四维生成项，区别原题一般性的两类模型比较。

题 7.30 同质关联与可折叠条件：把无三阶交互、同质 OR 及可折叠充分条件分开，补充可直接验证的反例。

题 7.31 固定边际与 Poisson—二项联系：把抽样方案、固定预测边际和 Logistic 联系连成完整论证，避免只背模型优缺点。

题 7.32 整体失拟与局部残差：补充逐层 MLE、整体检验和杠杆调整残差的一体化计算；区别原题仅由已有 G^2 比较模型。

题 7.33 官方内置教学列联表的输出阅读：完整使用官方教学表，新增不同检验原假设、局部诊断与数据来源边界；原练习未使用此数据。

题 7.34 录取数据中的折叠与同质性：采用真实完整院系表，补充同质模型仍失拟时不能仅看 1df 共同效应检验；与原折叠定义题不同。

第 7 章泊松回归与负二项回归

题 7.35 事件率与至少一次事件的概率：在已学 offset 与率解释之上补充可重复事件率和二分类发生概率的转换，非原 IRR 定义题。

题 7.36 同协变量分组的合并率估计：补充共同率的似然合并及不等人时权重，区别原 4 格 Poisson 回归精确 IRR 计算。

题 7.37 准 Poisson 的尺度调整：补充尺度与标准误的数量关系及 t 参照分布，区别原过离散名词解释或处理方法简答。

题 7.38 总样本的方差均数比能说明什么：补充条件分布与总体混合分布的区别，防止仅凭原始计数方差均数比选模型。

题 7.39 NB2 与准 Poisson 的方差形状：把过离散方差关系转成可比较的数值形状，区别原题只识别 NB2 方差公式。

题 7.40 均值、相关性与零概率：组合均值估计、相关结构和分布零概率，强化准似然/过离散/相关性三个层面的区别。

题 7.41 基线计数能否当作 offset：补充随机基线事件数与真正人时的区别及零值处理；区别原题只解释 offset 或对随访零计数截断。

题 7.42 年龄交互与率比对比：新增交互层内对比、负协方差与置信区间，区别原主效应 IRR 和单一 offset 计算。

题 7.43 完整就诊资料的计数模型输出：采用完整 5190 人和官方全变量加年龄平方公式，区别原题删除零后的 1049 人/简化公式；新增零概率与分布诊断而非 AIC 单选。

题 7.44 校园犯罪案例的代码与版本审阅：沿用已确认原教材完整 81 校，新增数据版本、依结局筛选及 R 实参匹配审阅；不重复原改动 10 校的类型系数或 Poisson/NB 边界检验。

第 8 章总复习与模型比较

题 8.1 OR 改变一定说明混杂吗：把 Logistic 章与对数线性章的可折叠概念放到同一概率表，训练区分统计参数变化和混杂偏倚。

题 8.2 过离散与重复观察是两个问题：综合原笔记关于独立性、计数方差与重复测量的提示，强调模型选择同时依赖观察单位和估计目标。

题 8.3 相同 AUC 不等于相同概率预测：用可验证的变换区分区分度、校准和分类阈值，补充原笔记对模型评价的综合要求。

题 8.4 合并二项数据后的似然常数：把二项表示与跨模型比较连接起来，补充‘系数一样但偏差不一样’的来源与判断。

题 8.5 相同 LR 值与不同参照分布：对照两个模型中的似然比检验，训练先核对自由度与正则条件，再使用同一个统计量。

题 8.6 课程中的模型与 GLM 边界：按照原复习章同时归纳 GLM、Cox 与负二项扩展，纠正仅凭回归式外观分类模型的做法。

题 8.7 分析前先写清观察单位与目标参数：将原题名词解释与模型选择合并为三个短场景，要求把设计、单位、估计及效应指标连成完整答案。

题 8.8 四个模型中哪些比较有效：沿用软件输出分析题，综合处理 AIC、嵌套检验、连接函数和缺失数据引起的不可比性。

题 8.9 同一队列表中的 OR、RR、IRR 与 HR：把各章常见指数化系数放在同一临床随访背景中比较，同时训练识别汇总信息不足。

题 8.10 三种显著结果是否构成相同结论：延续原题的文献评议结构，把模型输出、观察窗口、效应含义和研究结论放在同一份报告中审核。