

应用多元分析

Applied Multivariate Analysis



学习网站: <https://fxt-gw-pb.github.io/public-health-statistics-notes/>

2026 年 10 月

目录

第 1 章 主成分分析	1
1.1 主成分分析	1
1.2 主成分的计算方法	4
1.3 主成分的性质	6
1.4 主成分的几何意义	8
1.5 资料是否适合作主成分分析	10
1.6 主成分应用	12
习题与解析 主成分分析	17
第 2 章 因子分析	34
2.1 因子分析	34
2.2 因子模型	35
2.3 因子模型的估计方法	37
2.4 因子旋转	43
2.5 因子得分	45
习题与解析 因子分析	48
第 3 章 聚类分析	70
3.1 聚类分析	70
3.2 样品间相似性的度量	70
3.3 指标间相似性的度量	76
3.4 层次聚类法	78
3.5 大样本快速聚类	83
习题与解析 聚类分析	93
第 4 章 判别分析	106
4.1 判别分析	106
4.2 距离判别	106
4.3 Fisher 判别	112
4.4 Bayes 判别	116
习题与解析 判别分析	126

第 1 章

主成分分析

本书四章按研究目的可分为两类：主成分分析与因子分析以**变量**为对象，目的是将多个相关指标概括为少数几个综合指标；聚类分析与判别分析以**观察对象**为对象，目的是将个体（或样品）分类，或判定新个体所属的类别。

主成分分析是后续各章的基础。以 6 项智力测验得分为例，各项得分彼此相关，所含信息有重叠，主成分分析的任务是用一两个综合得分代替原有指标，并尽可能少地损失信息。这里的“信息”有明确的定义，即综合得分在个体间的方差，方差越大，区分个体的能力越强。本章的数学推导即求方差最大的线性组合，其解为协方差阵（或相关阵）的特征向量。

主成分分析属于数据变换与描述方法，不涉及统计模型，也不要求分布假设。它不假定数据背后存在潜在因子，这是它与第 2 章因子分析的根本区别。

1.1 主成分分析

主成分分析（principal component analysis, PCA）是利用多个数值变量的相关性，把它们变换成少数几个互不相关的综合指标（主成分），以反映多个变量所提供的信息。

批注 PCA 靠变量间的相关性来降维。若标准化后的变量近似互不相关，即相关阵接近单位阵，各特征值都接近 1，没有少数几个主成分能概括大部分方差，降维效果就差。用协方差阵分析时，即使变量互不相关，方差特别大的变量也会单独占据前几个主成分，但这只反映量纲或尺度的差异，并没有实现降维。

例 1 六项智力测量得分

寻找一个或几个综合指标，概括六项得分的信息。

表 1.1 某小学 10 名男学生六个项目的智力测量计分

编号	常识 X_1	算术 X_2	理解 X_3	填图 X_4	积木 X_5	译码 X_6
1	14	13	28	14	22	39
2	10	14	15	14	34	35
3	11	12	19	13	24	39
4	7	7	7	9	20	23
5	13	12	24	12	26	38
6	19	14	22	16	23	37
7	20	16	26	21	38	69
8	9	10	14	9	31	46
9	9	8	15	13	14	46
10	9	9	12	10	23	46

资料来源：余松林，《医学现场研究中的统计分析方法》，同济医科大学（内部教材），143 页。

1.1.1 六项得分的协方差阵和相关矩阵

```
1  # 按表1.1录入数据
2  d <- data.frame(
3    x1 = c(14, 10, 11, 7, 13, 19, 20, 9, 9, 9),
4    x2 = c(13, 14, 12, 7, 12, 14, 16, 10, 8, 9),
5    x3 = c(28, 15, 19, 7, 24, 22, 26, 14, 15, 12),
6    x4 = c(14, 14, 13, 9, 12, 16, 21, 9, 13, 10),
7    x5 = c(22, 34, 24, 20, 26, 23, 38, 31, 14, 23),
8    x6 = c(39, 35, 39, 23, 38, 37, 69, 46, 46, 46))
9  S <- cov(d)
10 S
11 cor(d)
12 diag(S)
13 sum(diag(S))
14 diag(cor(d))
```

表 1.2 协方差阵 S

	X_1	X_2	X_3	X_4	X_5	X_6
X_1	19.433333	10.722222	24.088889	13.877778	12.611111	27.466667
X_2	10.722222	8.500000	15.333333	8.722222	14.277778	15.444444
X_3	24.088889	15.333333	45.288889	17.200000	13.222222	35.266667
X_4	13.877778	8.722222	17.200000	12.988889	11.611111	27.022222
X_5	12.611111	14.277778	13.222222	11.611111	49.833333	41.555556
X_6	27.466667	15.444444	35.266667	27.022222	41.555556	138.400000

表 1.3 相关矩阵 R

	X_1	X_2	X_3	X_4	X_5	X_6
X_1	1.0000000	0.8342605	0.8119837	0.8734947	0.4052469	0.5296199
X_2	0.8342605	1.0000000	0.7815041	0.8301024	0.6937311	0.4502926
X_3	0.8119837	0.7815041	1.0000000	0.7091639	0.2783227	0.4454516
X_4	0.8734947	0.8301024	0.7091639	1.0000000	0.4563813	0.6373339
X_5	0.4052469	0.6937311	0.2783227	0.4563813	1.0000000	0.5003813
X_6	0.5296199	0.4502926	0.4454516	0.6373339	0.5003813	1.0000000

$\text{diag}(S) = (19.43333, 8.50000, 45.28889, 12.98889, 49.83333, 138.40000),$

$\text{tr}(S) = 274.4444, \quad \text{diag}(R) = (1, 1, 1, 1, 1, 1).$

实际分析一般调用 `prcomp()`。下面先列出结果，各数值的来源见后续各节。`prcomp()` 默认基于协方差阵，设定 `scale.=TRUE` 时基于相关阵：

```
1 pc <- prcomp(d)                # 协方差阵
2 summary(pc)
3 round(pc$rotation[,1:2],3)     # 前两个特征向量
```

```
Importance of components:
              PC1      PC2      PC3      PC4      PC5      PC6
Standard deviation 13.6558 6.6942 5.8888 2.53505 1.31898 0.55498
Proportion of Variance 0.6795 0.1633 0.1264 0.02342 0.00634 0.00112
Cumulative Proportion 0.6795 0.8428 0.9691 0.99254 0.99888 1.00000

      PC1      PC2
x1 -0.232  0.377
x2 -0.149  0.261
x3 -0.317  0.710
x4 -0.207  0.210
x5 -0.334  0.021
x6 -0.818 -0.491
```

`Standard deviation` 的平方为特征值，如 $13.6558^2 = 186.48$ ；`Proportion of Variance` 为贡献率，如 $186.48/274.44 = 0.6795$ 。特征向量整体变号不影响结果（见第1.3节后的说明），此处 R 给出的第一特征向量各分量均为负值，解释时可统一乘以 -1 。

第一主成分中译码 x_6 的系数达 0.818。六项测验的满分与分布不同，译码的方差 (138.4) 为算术 (8.5) 的 16 倍，因而在协方差阵分析中占主导地位。改用相关阵的结果如下：

```
1 pr <- prcomp(d,scale.=TRUE)    # 相关阵
2 summary(pr)
3 round(pr$rotation[,1:2],3)
```

```
Importance of components:
```

	PC1	PC2	PC3	PC4	PC5	PC6
Standard deviation	2.0364	0.9285	0.7759	0.50682	0.32673	0.1588
Proportion of Variance	0.6912	0.1437	0.1003	0.04281	0.01779	0.0042
Cumulative Proportion	0.6912	0.8348	0.9352	0.97800	0.99580	1.0000
	PC1	PC2				
x1	-0.450	0.289				
x2	-0.458	-0.005				
x3	-0.408	0.448				
x4	-0.453	0.119				
x5	-0.315	-0.747				
x6	-0.341	-0.379				

主成分的解释

基于相关阵时，第一主成分的六个系数同号且大小接近（0.32–0.46），可解释为总体智力水平，得分高者各项测验成绩均较好。它与六项标准化得分之和的相关系数为 0.9985（符号取正后），接近于标准化总分。其原因在于：六项指标两两正相关且程度相近时，方差最大的方向接近等权重方向。

第二主成分的系数有正有负：常识（0.289）、理解（0.448）为正，积木（-0.747）、译码（-0.379）为负。该主成分为一种对比，得分高表示言语类项目相对较好、操作类项目相对较差，反映能力结构的差异，与总体水平无关。

解释主成分时主要依据系数的符号与相对大小。第二主成分及以后的主成分常为此类对比，其专业意义需结合专业知识判断；难以解释时不必强行命名。

1.2 主成分的计算方法

设 p 个随机变量 $X = (X_1, \dots, X_p)^T$ 的总体均数为 μ 、协方差阵为 Σ 。总体主成分是中心化变量的线性组合 $z_i = a_i^T (X - \mu)$ 。实际计算时用样本均数 $\bar{x}$ 和样本协方差阵 S 代替 μ 和 Σ ，得到样本主成分，其方差为 S 的特征值 $\hat{\lambda}_i$ 。基于相关阵时，先把各变量标准化。样本形式为

$$z_i = a_{i1}(x_1 - \bar{x}_1) + a_{i2}(x_2 - \bar{x}_2) + \dots + a_{ip}(x_p - \bar{x}_p), \quad (1.1)$$

$$c_i = a_{i1}x_1^* + a_{i2}x_2^* + \dots + a_{ip}x_p^*, \quad x_j^* = \frac{x_j - \bar{x}_j}{s_j}. \quad (1.2)$$

前者基于协方差阵提取主成分，后者基于相关矩阵提取主成分。 p 个变量最多有 p 个主成分。 n 例样本的中心化数据阵秩不超过 $n - 1$ ，故 $\text{rank}(S) \leq \min(p, n - 1)$ ，方差非零的样本主成分不超过 $\min(p, n - 1)$ 个。

批注 要让主成分的方差最大，才更有代表性。

1.2.1 变量线性组合的性质

设 p 个随机变量 X 的均数为 μ ，协方差阵为 Σ 。 p 个变量的线性组合 $a^T X$ 的均数为 $a^T \mu$ ，方差为 $a^T \Sigma a$ 。

$$X = \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix}, \quad a = \begin{bmatrix} a_1 \\ \vdots \\ a_p \end{bmatrix}, \quad a^T X = \begin{bmatrix} a_1 & \cdots & a_p \end{bmatrix} X = a_1 X_1 + \cdots + a_p X_p.$$

1.2.2 用总分或平均分表示学生智力

以总分或平均分作为综合指标，是将各变量等同对待，赋予相同权。

$$a^T X = \begin{bmatrix} 1 & \cdots & 1 \end{bmatrix} \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} = X_1 + \cdots + X_p,$$

$$a^T X = \begin{bmatrix} 1/6 & \cdots & 1/6 \end{bmatrix} \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} = \frac{1}{6} X_1 + \cdots + \frac{1}{6} X_p.$$

批注 这样处理，还不能尽可能多地概括全部变量的信息。

下面比较等权组合与第一主成分的方差。为使比较对等，将等权重也标准化为单位长度， $a = (1/\sqrt{6}, \dots, 1/\sqrt{6})^T$ ：

```
1 a <- rep(1/sqrt(6),6)
2 c(t(a)%*%cov(d)%*%a, pc$sdev[1]^2) # 协方差阵：等权组合与第一主成分的方差
3 c(t(a)%*%cor(d)%*%a, pr$sdev[1]^2) # 相关阵
```

```
[1] 141.8815 186.4801
[1] 4.079090 4.146965
```

按原始分数等权相加，方差为 141.9，第一主成分为 186.5；按标准化分数等权相加，方差为 4.079，与第一主成分的 4.147 接近。第一主成分是所有单位长度权重中方差最大者，等权组合只是其中之一。相关阵下二者接近，原因如前所述；协方差阵下二者差距较大，因为各项方差不同，最优权重偏向方差较大的项目。

1.2.3 基于协方差阵提取第一主成分

$$z_1 = a_{11}(x_1 - \bar{x}_1) + a_{12}(x_2 - \bar{x}_2) + \cdots + a_{1p}(x_p - \bar{x}_p).$$

要求 $a_1^T a_1 = 1$ ，且第一主成分 z_1 的方差最大。若不加单位长度约束，把 a_1 乘以常数 c ，方差就变为原来的 c^2 倍，可以任意大。加上约束后，问题只比较组合的方向。

根据瑞利商性质,

$$\lambda_{\min} \leq \frac{x^T A x}{x^T x} \leq \lambda_{\max}. \quad (1.3)$$

当 $A = \Sigma$ 、 $x = e_1$ 时, 式子的值最大, 为 λ_1 。 e_1 是第一特征向量。

证明 由谱分解, $\Sigma = E \Lambda E^T$, 其中 $E = (e_1, \dots, e_p)$ 为正交阵, $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$, $\lambda_1 \geq \dots \geq \lambda_p \geq 0$ 。令 $b = E^T a$, 则 $b^T b = a^T a = 1$, 且

$$a^T \Sigma a = b^T \Lambda b = \sum_{j=1}^p \lambda_j b_j^2 \leq \lambda_1 \sum_{j=1}^p b_j^2 = \lambda_1,$$

当 $b = (1, 0, \dots, 0)^T$, 即 $a = e_1$ 时取等号。 $\square$

1.2.4 基于协方差阵提取第二主成分

如果 z_1 不能很好地概括原指标信息, 就继续提取第二主成分:

$$z_2 = a_{21}(x_1 - \bar{x}_1) + a_{22}(x_2 - \bar{x}_2) + \dots + a_{2p}(x_p - \bar{x}_p).$$

要求 $a_2^T a_2 = 1$ 、 $a_1^T a_2 = 0$, 且第二主成分 z_2 的方差次大。 e_2 是 z_2 表达式的系数, $\text{var}(z_2) = \lambda_2$ 。

证明 沿用上面的记号。约束 $a_2^T e_1 = 0$ 即 $b_1 = 0$, 于是 $a_2^T \Sigma a_2 = \sum_{j \geq 2} \lambda_j b_j^2 \leq \lambda_2 \sum_{j \geq 2} b_j^2 = \lambda_2$, 在 $a_2 = e_2$ 时取等号。依此类推, 要求与前 $i-1$ 个系数向量正交时, 第 i 个主成分的系数是 e_i , 方差为 λ_i 。 $\square$

批注 第二主成分与第一主成分两两不相关 (见1.3节性质2), 一般并不独立。最多有 p 个主成分, 本例即为6个。6个特征值之和等于协方差阵的迹 $\text{tr}(S) = 274.44$ 。原例标注的0.679是第一主成分的贡献率 $\hat{\lambda}_1 / \text{tr}(S)$ 。

1.2.5 基于相关矩阵计算主成分

对 $p \times p$ 相关矩阵求特征值 λ_i 和特征向量 e_i , $i = 1, 2, \dots, p$ 。

$$c_1 = a_{11}x_1^* + a_{12}x_2^* + \dots + a_{1p}x_p^*.$$

e_1 是第一主成分 c_1 表达式的系数 a_1 , $\text{var}(c_1) = \lambda_1$ 最大。 e_2 是第二主成分 c_2 表达式的系数, $\text{var}(c_2) = \lambda_2$ 次大, 以此类推。

批注 标准化变量的方差都是1, 总方差为 $\text{tr}(R) = p$ 。这里的“信息量”指方差。

1.3 主成分的性质

- 1) 主成分 c_i ($i = 1, 2, \dots, p$) 的均数为0。
- 2) 主成分 c_i 和 c_j ($i \neq j$) 两两不相关, $\text{cov}(c_i, c_j) = 0$ 。
- 3) $\text{var}(c_1) = \lambda_1$ 最大, $\text{var}(c_2) = \lambda_2$ 次大, 以此类推。

- 4) 总方差不增不减。协方差阵分析保留原变量的总方差 $\text{tr}(\Sigma)$, 相关阵分析保留标准化变量的总方差 $\text{tr}(R) = p$:

$$\sum_{i=1}^p \text{var}(z_i) = \sum_{i=1}^p \lambda_i = \text{tr}(\Sigma) = \sum_{i=1}^p \text{var}(x_i), \quad \sum_{i=1}^p \text{var}(c_i) = \text{tr}(R) = p.$$

- 5) 主成分与原始指标间的相关系数 (u_{i1} 为第一特征向量 e_1 的第 i 个分量):

$$\rho_{i1} = \frac{u_{i1}\sqrt{\lambda_1}}{\sigma_i} \quad (\text{基于协方差阵}), \quad \rho_{i1} = u_{i1}\sqrt{\lambda_1} \quad (\text{基于相关矩阵}).$$

这是因为 $\text{cov}(x_i, z_1) = (\Sigma e_1)_i = \lambda_1 u_{i1}$, 再除以 $\sigma_i \sqrt{\lambda_1}$ 。

证明 (性质 2) $\text{cov}(z_i, z_j) = \text{cov}(e_i^T X, e_j^T X) = e_i^T \Sigma e_j = \lambda_j e_i^T e_j = 0 \ (i \neq j)$ 。基于相关阵时把 Σ 换成 R 即可。□

不相关不等于独立。若 X 服从多元正态分布, 主成分是 X 的线性变换, 也服从联合正态分布, 这时不相关与独立等价, 总体主成分相互独立。样本主成分得分直接满足样本协方差为零: 得分阵 $Z = X_c E$ 的样本协方差阵为 $E^T S E = \hat{\Lambda}$, 为对角阵。

方差贡献率与累计贡献率 第 j 个主成分的方差贡献率为 $\lambda_j / \sum_{i=1}^p \lambda_i$, 前 k 个主成分的累计贡献率为 $\sum_{j=1}^k \lambda_j / \sum_{i=1}^p \lambda_i$ 。协方差阵分析的分母为 $\text{tr}(\Sigma)$, 相关阵分析的分母为 p 。例 1 基于协方差阵: 前两个主成分的贡献率分别为 67.9% 和 16.3%, 累计 84.3%。

例 2 29 名 13 岁男童的身高、体重和肺活量

表 1.4 某地 29 名 13 岁男童的身高、体重和肺活量

编号	身高/cm	体重/kg	肺活量/L	编号	身高/cm	体重/kg	肺活量/L
1	135.1	32.0	1.75	2	139.9	30.4	2.00
3	163.6	46.2	2.75	4	146.5	33.5	2.50
5	156.2	37.1	2.75	6	156.4	35.5	2.00
7	167.8	41.5	2.75	8	149.7	31.0	1.50
9	145.0	33.0	2.50	10	148.5	37.2	2.25
11	165.5	49.5	3.00	12	135.0	27.6	1.25
13	153.3	41.0	2.75	14	152.0	32.0	1.75
15	160.5	47.2	2.25	16	153.0	32.0	1.75
17	147.6	40.5	2.00	18	157.5	43.3	2.25
19	155.1	44.7	2.75	20	160.5	37.5	2.00
21	143.0	31.5	1.75	22	149.4	33.9	2.25
23	160.8	40.4	2.75	24	159.0	38.5	2.50
25	158.2	37.5	2.00	26	150.0	36.0	1.75
27	144.5	34.7	2.25	28	154.6	39.5	2.50
29	156.5	32.0	1.75				

资料来源: 陈峰主编, 《现代医学统计方法与 Stata 应用》, 中国统计出版社, 2000, 109 页。

1.3.1 协方差阵与相关阵的选择

协方差阵分析按各变量的方差赋权，方差大的变量在第一主成分中占主导，结果随测量单位改变。相关阵分析先把每个变量标准化，使各变量的初始方差都为 1，即在进入分析前赋予相同的方差权重，结果不随单位的线性变换而改变。用表 1.4 的数据复算：

分析方式	第一主成分贡献率	e_1 (身高, 体重, 肺活量)
协方差阵 (cm, kg, L)	89.3%	(0.865, 0.501, 0.031)
协方差阵 (m, kg, mL)	99.99%	(0.000, 0.009, 1.000)
相关阵 (任意单位)	79.3%	(0.565, 0.604, 0.563)

以 cm、kg、L 为单位时，身高方差最大，第一主成分主要反映身高；把身高改用 m、肺活量改用 mL 后，第一主成分几乎只剩肺活量。贡献率看似接近 100%，只是因为肺活量的数值方差被放大。相关阵分析在两种单位下完全相同。因此，变量单位不同或方差相差悬殊时宜用相关阵；只有各变量单位相同、方差大小本身有专业意义时（如例 4 的空气污染分指数），才用协方差阵。

1.4 主成分的几何意义

例 3 18 名学生的语文、数学成绩

从 18 名学生的语文、数学成绩中，基于协方差阵或相关阵提取主成分，进行综合评价。原始成绩即图 1.1 左图中各点的坐标。

```

1 d <- data.frame(
2   x1 = c(45, 48, 52, 61, 65, 67, 73, 75, 78, 81, 84, 88, 89, 93, 95, 98, 99,
3     98),
4   x2 = c(43, 53, 58, 70, 61, 70, 75, 78, 83, 88, 76, 92, 78, 82, 97, 95, 92,
5     89))
6 eigen(cov(d))
7 acos(0.7071068) * 180 / pi

```

$$\lambda_1 = 1.93200236, \quad \lambda_2 = 0.06799764, \quad \begin{bmatrix} e_1 & e_2 \end{bmatrix} = \begin{bmatrix} 0.7071068 & -0.7071068 \\ 0.7071068 & 0.7071068 \end{bmatrix}.$$

$$c_1 = 0.707x_1^* + 0.707x_2^*, \quad \text{var}(c_1) = \lambda_1 = 1.932, \quad \frac{\lambda_1}{p} = \frac{1.932}{2} = 96.6\%.$$




图 1.1 语文、数学成绩及其标化成绩




图 1.2 主成分坐标轴旋转

原坐标系中，语文与数学成绩有相关。基于二维相关阵作主成分分析，将坐标轴逆时针旋转 45° ，形成新坐标系。数据点在 c_1 轴上的投影最分散，即方差最大，在 c_2 轴上的投影相对紧密。 c_1 与 c_2 不相关， c_1 包含大量原始信息，可作进一步分析。

1.4.1 旋转矩阵

$$T_{\text{顺时针}} = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}, \quad T_{\text{逆时针}} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

1.4.2 保留主成分数与重构误差

设 X_c 为 $n \times p$ 的中心化（或标准化）数据阵， $S = X_c^T X_c / (n-1) = E \hat{\Lambda} E^T$ ，得分阵 $Z = X_c E$ 。只保留前 k 个主成分，记 $E_k = (e_1, \dots, e_k)$ ，用这 k 个得分重构原数据：

$$\hat{X}_c = Z_k E_k^T = X_c E_k E_k^T.$$

证明 记 $\tilde{E} = (e_{k+1}, \dots, e_p)$ 。由 $EE^T = I$ ， $X_c - \hat{X}_c = X_c(I - E_k E_k^T) = X_c \tilde{E} \tilde{E}^T$ ，于是

$$\|X_c - \hat{X}_c\|_F^2 = \text{tr}(\tilde{E}^T X_c^T X_c \tilde{E}) = (n-1) \text{tr}(\tilde{E}^T S \tilde{E}) = (n-1) \sum_{j>k} \hat{\lambda}_j.$$

再证这是最小值。任取 $p \times k$ 列正交阵 V ($V^T V = I_k$)，把数据投影到 V 张成的 k 维子空间，重构误差为 $(n-1)[\text{tr}(S) - \text{tr}(V^T S V)]$ 。令 $w_j = \|V^T e_j\|^2$ ，则 $0 \leq w_j \leq 1$ ， $\sum_j w_j = \text{tr}(V^T V) = k$ ，且 $\text{tr}(V^T S V) = \sum_j \hat{\lambda}_j w_j \leq \hat{\lambda}_1 + \dots + \hat{\lambda}_k$ 。当 $V = E_k$ 时取等号，故前 k 个主成分给出最小平方重构误差。对一般秩 k 近似阵，同样结论即 Eckart-Young 定理。□

因此

$$\frac{\|X_c - \hat{X}_c\|_F^2}{\|X_c\|_F^2} = \frac{\sum_{j>k} \hat{\lambda}_j}{\sum_{j=1}^p \hat{\lambda}_j} = 1 - \text{前 } k \text{ 个主成分的累计贡献率}.$$

累计贡献率就是前 k 个主成分重构出的那部分总方差（平方和）所占比例。碎石图把 $\hat{\lambda}_j$ 按 j 作图，曲线由陡变平的“拐点”之后，每多保留一个主成分，重构误差的减少都有限。常用的经验做法是取累计贡献率达到 70%~85%、碎石图拐点前的主成分，或在相关阵分析中保留特征值大于 1（即大于平均特征值）的主成分；几种准则应结合专业解释使用。例 3 只保留 c_1 ，相对重构误差为 $\lambda_2/2 = 3.4\%$ 。

1.5 资料是否适合作主成分分析

1.5.1 Bartlett 球形检验

零假设为总体相关阵是单位阵（球形假设）。若 $P < \alpha$ ，则认为指标间有一定相关性。

$$\chi^2 = -\left(n-1 - \frac{2p+5}{6}\right) \log |R| \sim \chi^2\left(\frac{p(p-1)}{2}\right). \quad (1.4)$$

批注 n 是总例数， p 是变量个数。检验要求各观测独立抽样、变量服从多元正态分布， χ^2 分布是大样本近似。

拒绝球形假设只说明变量间存在相关，并不说明相关强到足以有效降维：样本量大时，很弱的相关也会显著。降维效果仍要看特征值和累计贡献率。例 2（表 1.4）的 $\chi^2 = 41.60$ ， $df = 3$ ， $P < 0.001$ 。




图 1.3 Bartlett 球形检验：卡方值随相关阵行列式的变化（示意图）

1.5.2 KMO 统计量

$$KMO = \frac{\sum_{i \neq j} r_{ij}^2}{\sum_{i \neq j} r_{ij}^2 + \sum_{i \neq j} p_{ij}^2}. \quad (1.5)$$

其中 p_{ij} 为偏相关系数。令 $C = R^{-1}$, C_{ij} 为逆矩阵 C 的元素, 则

$$p_{ij} = -\frac{C_{ij}}{\sqrt{C_{ii}C_{jj}}}.$$

例 2 按表 1.4 复算, $KMO = 0.695$ (原例记为 0.69)。

KMO 范围	适合性评价
$KMO \geq 0.9$	极好 (Excellent)
$0.8 \leq KMO < 0.9$	好 (Good)
$0.7 \leq KMO < 0.8$	中等 (Fair)
$0.5 \leq KMO < 0.7$	勉强接受 (Poor)
$KMO < 0.5$	不可接受 (Unacceptable)

例 2 的两个统计量可直接按公式计算, 无需调用其他程序包:

```

1 # h、w、v: 例2表中29名男童的身高、体重、肺活量, 按例1的方式录入
2 X <- cbind(h,w,v); R <- cor(X); n <- nrow(X); p <- ncol(X)
3 chi <- -(n-1-(2*p+5)/6)*log(det(R))
4 c(chi=chi, df=p*(p-1)/2, P=pchisq(chi,p*(p-1)/2,lower.tail=FALSE))
5 C <- solve(R); P <- -C/sqrt(outer(diag(C),diag(C))) # 偏相关阵
6 diag(P) <- 0; R0 <- R; diag(R0) <- 0
7 sum(R0^2)/(sum(R0^2)+sum(P^2)) # KMO

```

```

      chi      df      P
4.159713e+01 3.000000e+00 4.884930e-09
[1] 0.6945357

```

KMO 需与 Bartlett 球形检验结合使用。KMO ≥ 0.7 且 Bartlett 检验 $P < 0.05$ 时，数据适合因子分析。

批注 KMO 比较简单相关与偏相关：若变量间的相关主要来自共同因子，控制其他变量后偏相关应很小，KMO 接近 1。因此上表的经验阈值主要用于评价共同因子结构，是因子分析的参考指标。PCA 只是对方差结构作正交变换，不以存在公因子为前提，KMO 不宜作为实施 PCA 的必要条件；PCA 是否有效，应直接看前几个主成分的累计贡献率及其可解释性。

1.6 主成分应用

1.6.1 综合评价

例 3 中，基于相关阵提取的第一主成分结构符合专业意义。假设成绩服从正态分布，可将主成分得分转化为百分位数（正态分布累积概率），获得较直观的解释。参照人群中 $c_1 \sim N(0, \lambda_1)$ ，故个体的百分位为

$$P = 100 \Phi\left(\frac{c_1}{\sqrt{\lambda_1}}\right),$$

即参照人群中得分低于该个体的百分比。这里的参照人群是估计均数、标准差和特征向量所用的人群，本例即这 18 名学生；换一个参照人群，百分位就要重新计算。特征向量的符号是任意的，应先把方向取成“得分越高越好”（若软件给出的 e_1 各分量为负，就用 $-c_1$ ）。例 3 中 $\lambda_1 = 1.932$ ：第 1 名学生 (45, 43) 的 $c_1 = -2.85$ ，百分位为 2.0；第 9 名 (78, 83) 为 0.33，百分位 59.3；第 17 名 (99, 92) 为 1.59，百分位 87.3。

批注 方差最大准则只保证 c_1 最能拉开个体间的差距，并不保证它就是专业上合理的综合评价。还要检查各变量的系数是否同号、大小是否合理；若有变量方向相反（如“越小越好”的指标），应先统一方向再分析。

例 4 空气污染加权指数

广州市某两个月空气污染数据包括二氧化硫 (SO_2)、氮氧化物 (NO_x) 和总悬浮颗粒物 (TSP) 三个原始浓度指标。各污染物分指数 ($i\text{SO}_2$ 、 $i\text{NO}_x$ 和 $i\text{TSP}$) 由浓度经非线性变换获得。 api (Air Pollution Index) 是当日三个分指数的最大值。

同样的分指数具有相同的医学意义和尺度，因此可以从协方差阵出发计算主成分，并构造空气污染加权指数 api.w : $\text{cor}(z_1, \text{api.w}) = 1$ 。

只看相关系数等于 1 并不能确定这个指数： z_1 的任何正线性变换 $az_1 + b$ ($a > 0$) 与 z_1 的相关系数都等于 1。课程程序（数据：广州某 2 个月空气污染指数.sav, $n = 32$ 天）的具体做法是：对三个分指数的协方差阵求第一特征向量 e_1 （第一主成分贡献率 76.4%），取各分量为正的方向，再除以分量之和，使权重之和为 1：

$$a = \frac{e_1}{\sum_j e_{1j}} = (0.322, 0.139, 0.540) \quad \text{对应 } (i\text{TSP}, i\text{SO}_2, i\text{NO}_x),$$

$$\text{api.w} = 0.322 i\text{TSP} + 0.139 i\text{SO}_2 + 0.540 i\text{NO}_x.$$

也就是不中心化的加权平均，与分指数处于同一尺度。它与第一主成分得分 $z_1 = e_1^T(x - \bar{x})$ 的关系为 $\text{api.w} = z_1 / \sum_j e_{1j} + \bar{x}^T a = 0.643 z_1 + 138.2$ ，即先缩放、再平移。 $i\text{NO}_x$ 的权重最大，是因

为它的方差最大；这是协方差阵分析按方差赋权的结果，并不表示它的健康效应最大。这个加权指数有无专业上的合理性，仍需结合污染物的健康效应来解释。




图 1.4 空气污染指数、加权指数与三个污染物分指数

1.6.2 主成分回归

22 例胎儿受精龄 (Y , 周) 与胎儿外型测量指标如下。试求由 X_1 、 X_2 、 X_3 推算 Y 的回归方程。

指标	均数	标准差
身高 (X_1 , cm)	33.05	9.71
头围 (X_2 , cm)	23.26	6.86
体重 (X_3 , g)	936.9	690.3

因自变量间高度共线性，导致 b_2 的符号异常，为负值：

$$\hat{Y} = 11.01 + 1.69X_1 - 2.16X_2 + 0.007X_3.$$

批注 主成分回归舍弃了部分主成分方向，一般是有偏估计；岭回归也是有偏估计。偏倚大小见下文推导。

主成分回归步骤：基于相关阵提取 1 至 2 个主成分 c_1 和 c_2 ，与 y 作回归 ($y \sim c_1 + c_2$)，再变形为 $y \sim x_1 + x_2 + x_3$ 。

$$\begin{aligned} \hat{Y} &= 23.73 + 3.88C_1 + 3.10C_2, \\ C_1 &= 0.58 \frac{X_1 - \bar{X}_1}{S_1} + 0.58 \frac{X_2 - \bar{X}_2}{S_2} + 0.57 \frac{X_3 - \bar{X}_3}{S_3}, \end{aligned}$$

$$C_2 = -0.42 \frac{X_1 - \bar{X}_1}{S_1} - 0.39 \frac{X_2 - \bar{X}_2}{S_2} + 0.82 \frac{X_3 - \bar{X}_3}{S_3}.$$

由主成分回归还原原始变量的回归式

$$\begin{aligned}\hat{Y} &= b_0^c + b_1^c C_1 + b_2^c C_2, \\ C_i &= a_{i1}x_1 + a_{i2}x_2 + a_{i3}x_3 \\ &= \frac{a_{i1}(X_1 - \bar{X}_1)}{S_1} + \frac{a_{i2}(X_2 - \bar{X}_2)}{S_2} + \frac{a_{i3}(X_3 - \bar{X}_3)}{S_3}, \quad i = 1, 2.\end{aligned}$$

b_i^c 为主成分回归系数, a_{ij} 为组合系数 (特征向量)。解得

$$\begin{aligned}\hat{Y} &= b_0 + \frac{b_1^c a_{11} + b_2^c a_{21}}{S_1} X_1 + \frac{b_1^c a_{12} + b_2^c a_{22}}{S_2} X_2 + \frac{b_1^c a_{13} + b_2^c a_{23}}{S_3} X_3, \\ b_0 &= b_0^c - \left[b_1^c \left(\frac{a_{11}\bar{X}_1}{S_1} + \frac{a_{12}\bar{X}_2}{S_2} + \frac{a_{13}\bar{X}_3}{S_3} \right) + b_2^c \left(\frac{a_{21}\bar{X}_1}{S_1} + \frac{a_{22}\bar{X}_2}{S_2} + \frac{a_{23}\bar{X}_3}{S_3} \right) \right] \\ &= b_0^c - (b_1\bar{X}_1 + b_2\bar{X}_2 + b_3\bar{X}_3).\end{aligned}\tag{1.6}$$

分析结果

$$\hat{Y}_{\text{Prin}}(2) = 10.44 + 0.10X_1 + 0.15X_2 + 0.007X_3.$$

附：本例岭回归分析结果

$$\hat{Y}_{\text{Ridge}}(0.1) = 8.12 + 0.21X_1 + 0.19X_2 + 0.005X_3.$$

截断主成分回归的偏倚与方差

设 X^* 为 $n \times p$ 标准化自变量阵, $y = \beta_0 \mathbf{1} + X^* \beta + \varepsilon$, $E\varepsilon = 0$, $\text{cov}(\varepsilon) = \sigma^2 I$ 。由 $X^{*\top} X^* = (n-1)E\Lambda E^\top$, 主成分得分 $Z = X^* E$ 各列两两正交, $Z^\top Z = (n-1)\Lambda$ 。记 $\gamma = E^\top \beta$, 即真回归系数在各主成分方向上的分量, 则 $X^* \beta = Z\gamma$ 。由于各列正交, y 对 Z 回归时各系数互不影响:

$$\hat{\gamma}_j = \frac{z_j^\top y}{(n-1)\lambda_j}, \quad E\hat{\gamma}_j = \gamma_j, \quad \text{var}(\hat{\gamma}_j) = \frac{\sigma^2}{(n-1)\lambda_j}.$$

只保留前 k 个主成分时, $\hat{\beta}_{(k)} = \sum_{j \leq k} \hat{\gamma}_j e_j$, 于是

$$E\hat{\beta}_{(k)} - \beta = - \sum_{j > k} \gamma_j e_j, \quad \text{cov}(\hat{\beta}_{(k)}) = \frac{\sigma^2}{n-1} \sum_{j \leq k} \frac{e_j e_j^\top}{\lambda_j}.$$

偏倚只取决于真回归系数在被舍弃方向上的分量 γ_j ($j > k$): 若 β 几乎与这些方向正交, 偏倚很小。被舍弃的小 λ_j 方向本会贡献很大的方差 $\sigma^2 / [(n-1)\lambda_j]$, 截断就是用偏倚换方差。保留全部非零主成分 ($k = \text{rank}(X^*)$) 时, Z_k 与 X^* 张成同一列空间, 主成分回归恢复最小二乘拟合; 本例 $k = 3$ 时还原得到的正是上面 $b_2 < 0$ 的最小二乘方程。

原例续算 本例（数据：princeple reg exp.sav）相关阵的特征值为 2.926、0.0714、0.0025，前两个主成分的累计贡献率达 99.9%。逐个加入主成分时， $\hat{\gamma}_1 = 3.88$ 、 $\hat{\gamma}_2 = 3.10$ 保持不变，与上面的推导一致。第三个主成分方差只有 0.0025，但 $\hat{\gamma}_3 = 22.16$ （标准误 5.11， $t = 4.34$ ， $P < 0.001$ ），即低方差方向仍含有关于 Y 的预测信息。自变量的累计贡献率只说明 X 的结构，不能代替对 Y 的预测评价。用留一法比较预测误差，每一折内都重新标准化、重新作 PCA：

```

1  dc <- foreign::read.spss("princeple reg exp.sav", to.data.frame = TRUE)
2  X <- as.matrix(dc[, c("x1", "x2", "x3")]); y <- dc$y
3  rmse <- sapply(1:3, function(k) {
4    e <- numeric(nrow(X))
5    for (i in seq_len(nrow(X))) {
6      pc <- prcomp(X[-i, ], scale. = TRUE)      # 训练折内标准化与PCA
7      Z <- pc$x[, 1:k, drop = FALSE]
8      fit <- lm(y[-i] ~ Z)
9      z0 <- predict(pc, X[i, ], drop = FALSE)[, 1:k, drop = FALSE]
10     e[i] <- y[i] - cbind(1, z0) %*% coef(fit)
11   }
12   sqrt(mean(e^2))
13 })
14 rmse

```

保留主成分数 k	1	2	3（即最小二乘）
留一法预测均方根误差（周）	1.867	1.732	1.483

本例保留全部 3 个主成分时预测误差最小，PCR(2) 虽然系数符号“合理”，预测反而较差。保留数应结合交叉验证的预测误差来选择；标准化和 PCA 都必须在训练折内估计，否则测试样品的信息会泄漏进模型。

最小二乘方程中 $b_2 = -2.16$ （标准误 0.54）是条件效应，表示身高、体重固定时头围每增加 1 cm， Y 的平均变化。 X_1 、 X_2 的方差膨胀因子约为 200 和 209，条件数 $\sqrt{2.926/0.0025} \approx 34$ ，严重共线。这时“身高、体重不变而头围变化”的组合在数据中几乎不存在，负号的大小和方向都很不稳定，不宜直接作专业解释，应结合标准误和共线性诊断来看。

主成分分析的几何概括

主成分分析相当于建立一组新的坐标轴：第一轴沿数据分散程度最大的方向，第二轴取与第一轴垂直的方向中分散程度最大者，依此类推。仅保留前几个轴，即以尽量少的维度保留尽量多的方差。

本章的主要结论均可由此得到：方差最大对应特征向量；坐标轴相互垂直对应主成分互不相关；坐标轴旋转不改变总方差；分散程度按原始尺度度量，故结果依赖单位，单位不同时需先标准化；变量间无相关时数据在各方向上分散程度相同，无法降维。

本章小结：主成分分析

研究目的	用少数互不相关的线性组合概括多个相关变量的方差，用于降维、综合评价、消除共线性
优化准则	在 $a^T a = 1$ 且与前面各主成分不相关的约束下，使 $\text{var}(a^T x)$ 最大；解为 S 或 R 的特征向量。等价于最小平方重构误差
主要条件	变量间有较强相关；单位不同时用相关阵；属于描述性方法，无分布假设（Bartlett 检验另需多元正态）
结果解释	特征值即主成分方差，累计贡献率即重构出的方差比例；载荷 $u_{i1} \sqrt{\lambda_1}$ 为变量与主成分的相关系数
常见误用	把“不相关”说成“独立”；单位不同仍用协方差阵；只凭累计贡献率决定主成分回归的保留数；把 KMO 当作 PCA 的必要条件；忽视特征向量符号的任意性

复习题

- 1) 对 6 个变量作主成分分析，分别写出基于相关阵与基于协方差阵时特征值之和。
答：相关阵为 6；协方差阵为各变量方差之和 $\text{tr}(S)$ 。
- 2) 解释“第一主成分的贡献率为 70%”的含义。
答：第一主成分的方差占总方差的 70%，即仅用第一主成分重构原数据（或标准化数据）时所保留的平方和比例。此处的“信息”专指方差。
- 3) 基于相关阵的分析中，第一特征向量为 $(0.58, 0.58, 0.57)$ ， $\lambda_1 = 2.926$ ，计算第一个变量与第一主成分的相关系数。
答： $0.58 \times \sqrt{2.926} = 0.99$ 。
- 4) 说明变量间互不相关时不宜作主成分分析的原因。
答：此时相关阵接近单位阵，各特征值均接近 1，每个主成分只代表一个原变量，无法降维。
- 5) 说明主成分回归缓解共线性的原理及其代价。
答：舍弃特征值很小的方向，消除这些方向上被放大的方差；若真实系数在被舍弃方向上有分量，估计将产生偏倚，预测效果也可能下降。

第1章 习题与解析

主成分分析

往年题

单项选择题

题 1.1 主成分分析与因子分析的关系

关于主成分分析与因子分析的关系，正确的是：

- A. 主成分分析法是提取公因子的常用方法之一。
- B. 主成分分析和因子分析的解均不是唯一的。
- C. 一般而言，主成分分析有利于变量关系解释，而因子分析有利于变量信息综合。
- D. 主成分分析和因子分析均含参数估计和假设检验两部分。
- E. 两者均要求数据来自正态分布，且变量间互不相关。

题 1.2 主成分与因子分析的异同

关于主成分分析与因子分析的关系，按课程惯用口径，错误的是：

- A. 主成分法是提取公因子的常用方法之一。
- B. 主成分分析和因子分析的解都不是唯一的。
- C. 通常主成分分析有利于变量信息综合，因子分析有利于变量关系解释。
- D. 因子旋转可以改变单个共同因子的解释方差百分比。
- E. 通常 PCA 用于描述；在适当模型条件下，可以对共同因子模型作假设检验。

题 1.3 主成分与因子分析的异同

关于主成分分析与因子分析的关系，按课程惯用口径，错误的是：

- A. 主成分法是提取公因子的常用方法之一。
- B. 主成分分析和因子分析的解都不是唯一的。
- C. 通常主成分分析有利于变量信息综合，因子分析有利于变量关系解释。
- D. 因子旋转可以改变单个共同因子的解释方差百分比。
- E. 通常 PCA 用于描述；在适当模型条件下，可以对共同因子模型作假设检验。

题 1.4 异常科目表现与方差解释率

姓名	语文	数学	英语
马云	84	88	80
方舟子	95	99	95
三毛	98	20	90
王宝强	60	45	55
赵薇	85	50	80

按特征值大于 1 保留单成分。若希望删除一条记录，使第一成分的方差解释比例更大，应删去谁？

- A. 马云。
- B. 方舟子。
- C. 三毛。
- D. 王宝强。
- E. 赵薇。

题 1.5 综合评价排序的稳定性

姓名	语文	数学	英语
马云	84	88	80
方舟子	95	99	95
三毛	98	20	90
王宝强	60	45	55
赵薇	85	50	80

关于使用题中主成分、两个旋转因子及总分进行评价，下列说法正确的是：

- A. 无论选用何种指标，方舟子永远第一。
- B. 无论选用何种指标，王宝强永远倒数第一。
- C. 无论选用何种指标，马云总比赵薇强。
- D. 无论选用何种指标，三毛总比王宝强强。
- E. 无论选用何种指标，赵薇总比王宝强强。

题 1.6 主成分的方差

若以协方差阵的单位特征向量 a_k 定义 $C_k = a_k^T(X - \mu)$, 则 $\text{Var}(C_k)$ 等于:

- A. 对应特征值 λ_k 。
- B. 总等于 1。
- C. 总等于 0。
- D. 所有特征值的乘积。
- E. 样本量。

题 1.7 相关阵 PCA 的总方差

对 p 个非恒定变量作标准化, 再对相关阵 PCA, 全部特征值之和为:

- A. 1。
- B. p 。
- C. p^2 。
- D. 样本数。
- E. 0。

题 1.8 量纲改变与 PCA

仅把一个变量的单位从米改为厘米, 且其他变量不变。关于 PCA, 通常正确的是:

- A. 协方差阵 PCA 和相关阵 PCA 都一定改变。
- B. 两者都一定不变。
- C. 相关阵 PCA 不受此正比例单位换算影响, 协方差阵 PCA 一般会改变。
- D. 协方差阵 PCA 不变, 相关阵一定改变。
- E. 所有特征值都必变为 100 倍。

题 1.9 完整变换与降维

保留全部单位正交主成分, 对中心化样本点作变换后, 下列哪项保持?

- A. 欧氏距离。
- B. 每个原坐标的数值。
- C. 每个坐标的方差都相等。
- D. 各主成分均值为原变量各自均值。
- E. 所有样本点变成同一点。

简答题

题 1.10 主成分变换与样本点的几何关系

主成分分析改变了原样本空间中样本点的关系吗？Z 变换会改变原样本空间中样本点的关系吗？为什么？

计算与分析题

题 1.11 三科成绩：协方差阵与相关阵

就下列成绩单，利用主成分分析计算加权平均分。共 20 分。

ID	语文	数学	英语
1	84	88	80
2	95	99	95
3	98	30	90
4	60	55	55
5	85	80	80

1. 对 3 科成绩做简单统计描述。(2 分)
2. 基于协方差阵计算 3 科权重及 5 人的加权平均分。(6 分)
3. 基于相关阵计算 3 科权重及 5 人的加权平均分。(6 分)
4. 比较第 3、4 号学生在两种方法下的得分，说明两种综合评分的关键区别。(6 分)

题 1.12 三科成绩与招生评价

利用下表做主成分分析（权重保留 3 位小数）。

ID	语文	数学	英语
1	84	88	80
2	95	99	95
3	98	20	90
4	60	45	55
5	85	80	80

1. 基于协方差阵计算 3 科权重。
2. 基于相关阵计算 3 科权重。
3. 一位同学的分数是.....，计算其两种加权平均分。
4. 若你是理院校招生人员，更愿采用哪种权重作为招生标准？说明理由。

原稿没有记下第 3 问的三科分数。

题 1.13 父母与子女身高的主成分回归

对父母与子女身高数据进行主成分分析。共 20 分。

1. 写出主成分与原变量的函数关系式。
2. 由主成分回归方程求原变量尺度的回归方程。

以父母身高为自变量、子女身高为结局。原题所指身高数据未随往年题附上。

题 1.14 从 SPSS 输出计算权重与主成分得分

下列为三科成绩的 SPSS 分析结果。采用相关阵主成分分析，提取 3 个成分，各变量提取共同度均为 1。共 20 分。

变量	均值	标准差	N
语文	79	12.4	5
英语	80	7.9	5
数学	67	18.2	5

主成分	特征值	贡献率%	累计%
1	2.634	87.789	87.789
2	0.308	10.272	98.061
3	0.058	1.939	100

变量	载荷 1	载荷 2	载荷 3	得分系数 1	得分系数 2	得分系数 3
语文	0.9	0.43	0.07	0.34	1.4	1.25
英语	0.93	-0.34	0.13	0.35	-1.11	2.23
数学	0.98	-0.07	-0.19	0.37	-0.23	-3.26

1. 计算权重之和为 1 的三科统计学权重。
2. 学生 A 语文 62、英语 79、数学 91，计算其简单平均分和加权平均分。
3. 计算学生 A 第一主成分得分。
4. 计算第一主成分得分与所求加权平均分的相关系数。

题 1.15 成绩综合评分及个体评价

成绩如下，数据作 Z 变换后，以主成分法提取两个公因子，并作 varimax 旋转。

姓名	语文	数学	英语
马云	84	88	80
方舟子	95	99	95
三毛	98	20	90
王宝强	60	45	55
赵薇	85	50	80

1. 用主成分分析获得 3 科加权平均分的权重，写出步骤。(Q6, 10 分)
2. A 同学语文 82、数学 63、英语 81，计算其加权平均分。(Q7, 5 分)
3. 根据主成分及因子分析，对 A 的学业水平作简要评价。(Q8, 5 分)

题 1.16 空气污染综合指数

下列为广州市某月 3 种空气污染物指数的主成分分析输出。共 20 分。

1. 分别从相关阵与协方差阵结果计算空气污染综合指数的统计学权重。
2. 哪种结果更符合实际？说明理由。

变量	均值	标准差	N
TSP	104.28	53.167	61
SO ₂	41.62	21.503	61
NO _x	183.26	68.898	61

成分	相关阵 λ	贡献%	累计%	协方差阵 λ	贡献%	累计%
1	2.169	72.306	72.306	6140.765	76.415	76.415
2	0.606	20.215	92.521	1722.108	21.43	97.845
3	0.224	7.479	100	173.167	2.155	100

相关阵：载荷与成分得分系数。

变量	载荷 1	载荷 2	载荷 3	得分 1	得分 2	得分 3
TSP	0.741	0.671	0.031	0.341	1.107	0.139
SO ₂	0.892	-0.316	0.324	0.411	-0.521	1.446
NO _x	0.909	-0.237	-0.344	0.419	-0.391	-1.532

协方差阵：原尺度载荷与重标度载荷。

变量	原 1	原 2	原 3	重标 1	重标 2	重标 3
TSP	39.208	35.906	-0.419	0.737	0.675	-0.008
SO ₂	16.883	-3.685	12.797	0.785	-0.171	0.595
NO _x	65.715	-20.476	-3.038	0.954	-0.297	-0.044

协方差阵输出的标准化成分得分系数:

变量	1	2	3
TSP	0.339	1.109	-0.129
SO2	0.059	-0.046	1.589
NOx	0.737	-0.819	-1.209

重标度后提取平方载荷和为 (2.070, 0.574, 0.356), 贡献率为 (69.001%,19.126%,11.873%), 累计为 (69.001%,88.127%,100%)。

题 1.17 用成绩因子分析结果评价新学生

某人的成绩为语文 70、数学 60、英语 90。根据下列分析输出，采用适当方法计算其加权平均分。

变量	均值	标准差	共同度
语文	82.2	11.946	0.978
数学	75.2	19.942	1
英语	80.2	7.95	0.979

成分	初始 λ	贡献%	累计%	旋转 λ	贡献%	累计%
1	2.223	74.109	74.109	1.912	63.736	63.736
2	0.734	24.462	98.57	1.045	34.835	98.57
3	0.043	1.43	100			

变量	初始 1	初始 2	旋转 1	旋转 2	得分 1	得分 2
语文	0.963	-0.225	0.959	0.24	0.525	-0.075
数学	0.632	0.775	0.208	0.978	-0.229	1.069
英语	0.947	-0.289	0.974	0.176	0.558	-0.155

补充练习

本节为配合正文新编的补充练习。除注明沿用正文例题外，数值与研究摘要均为教学设定。题型与作答方式沿用本章往年题，解析见章末。

单项选择题

题 1.18 特征向量、相关系数与标准成分得分

对 3 个标准化变量作相关阵主成分分析。第一特征值为 $\lambda_1 = 2.25$ ，相应单位特征向量中 Z_1 的系数为 $a_{11} = 0.50$ 。记 $C_1 = a_1^T Z$ ， $F_1 = C_1 / \sqrt{\lambda_1}$ 。下列哪组数值依次为 $\text{Corr}(Z_1, C_1)$ 和 F_1 中 Z_1 的系数？

- A. (0.50, 0.50)。
- B. (0.75, 1/3)。
- C. (1.125, 0.50)。
- D. (1/3, 0.75)。
- E. (0.75, 0.75)。

简答题

题 1.19 Bartlett 球形检验与 KMO 的联合判断

某研究拟将 6 项数值指标合成为一个综合指标，样本量 180。Bartlett 球形检验 $P < 0.001$ ，KMO 为 0.42。研究者称：“球形检验显著，说明非常适合作主成分分析，并且只需保留第一主成分。”请评价这段话，写出球形检验的零假设，并说明还需查看哪些正文所讲的信息。

计算与分析题

题 1.20 两科成绩的主成分与百分位评价

对语文 X_1 、数学 X_2 作相关阵主成分分析。两科均值分别为 70、80，标准差分别为 10、5，相关矩阵及单位特征向量如下：

$$R = \begin{pmatrix} 1 & 0.8 \\ 0.8 & 1 \end{pmatrix}, \quad a_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad a_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

学生 A 的语文、数学成绩为 90、85。共 15 分。

1. 写出两个主成分的表达式、方差及各自贡献率。(4 分)
2. 计算 A 的两个主成分得分，并解释两个得分分别反映什么。(4 分)
3. 若两科成绩联合服从二元正态分布，按正文方法将第一主成分得分换算为正态百分位。已知 $\Phi(1.5811) = 0.9431$ 。(4 分)
4. 只保留第一成分时，丢失了哪一方面的信息？能否根据“两个成分不相关”直接断言任意分布下二者独立？(3 分)

题 1.21 胎儿受精龄：还原主成分回归方程

沿用正文的胎儿外型测量例题： Y 为受精龄（周）， X_1 为身高（cm）， X_2 为头围（cm）， X_3 为体重（g）。已知样本量为 22，摘要如下。

指标	均值	标准差
X_1	33.05	9.71
X_2	23.26	6.86
X_3	936.9	690.3

令 $Z_j = (X_j - \bar{X}_j)/s_j$ ，正文给出的结果为

$$C_1 = 0.58Z_1 + 0.58Z_2 + 0.57Z_3,$$

$$C_2 = -0.42Z_1 - 0.39Z_2 + 0.82Z_3,$$

$$\hat{Y} = 23.73 + 3.88C_1 + 3.10C_2.$$

本题按以上已显示的系数精度计算。共 15 分。

1. 将回归式还原为 $\hat{Y} = b_0 + b_1X_1 + b_2X_2 + b_3X_3$ 。（8 分）
2. 某胎儿 $(X_1, X_2, X_3) = (40, 28, 1500)$ ，计算其预测受精龄。（4 分）
3. 为什么主成分回归可缓解自变量共线性？只保留部分成分是否保证预测误差一定更小？（3 分）

习题解析

核对方式

按题号核对。补写题目、原稿歧义及复算约定列在对应解析中。

解析 题 1.1 主成分分析与因子分析的关系

[返回题目](#)

答案：A。

按课程的“主成分法提取因子”口径选 A。PCA 通常用于综合与降维，共同因子模型偏重相关结构解释。须补充：PCA 特征向量有整体正负号任意性，重根时基底也不唯一；因此 B 若按严格数学意义理解有歧义。教材所称 PCA“唯一”通常已约定符号且特征根互异，不能忽略这些条件。

解析 题 1.2 主成分与因子分析的异同

[返回题目](#)

答案：B（课程口径）。

原卷以 PCA 在给定互异特征根、规范化和符号约定后确定，而因子模型仍有旋转不确定性为比较，预期选 B。但不加这些约定时，PCA 也有符号和重根基底的不唯一性，B 并非严格错误。保留原题用于识别考试口径，同时明确数学限制。

解析 题 1.3 主成分与因子分析的异同

[返回题目](#)

答案：B（课程口径）。

原卷以 PCA 在给定互异特征根、规范化和符号约定后确定，而因子模型仍有旋转不确定性为比较，预期选 B。但不加这些约定时，PCA 也有符号和重根基底的不唯一性，B 并非严格错误。保留原题用于识别考试口径，同时明确数学限制。

解析 题 1.4 异常科目表现与方差解释率

[返回题目](#)

答案：C。

分别删去每人后重新计算相关阵第一特征值与 3 的比值；三毛的数学与语文英语表现明显不一致，删除后综合相关结构更强。逐人删除结果已附。不能将此练习变成在实际研究中为了提高解释率任意删人。

解析 题 1.5 综合评价排序的稳定性

[返回题目](#)

答案：E（限题列指标及正向约定）。

按本题 4 种实际指标复算，方舟子第一主成分与数学因子最高，但第一语文英语因子最高的是三毛，所以 A 不成立；第二因子最差是三毛，B 不成立；马云第一因子低于赵薇，C 不成立；三毛第二因子低于王宝强，D 不成立。E 在本次正向因子约定及列举的 4 种指标中成立，可按命题意图选 E；但“何种指标”“永远”若按无限范围理解都过强，改变方向或评价目标可改变排序。

解析 题 1.6 主成分的方差[返回题目](#)

答案：A。

由特征方程，方差为 $a_k^T \Sigma a_k = \lambda_k$ 。

补写说明。2019 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 1.7 相关阵 PCA 的总方差[返回题目](#)

答案：B。

特征值之和等于迹，相关阵对角线共 p 个 1。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 1.8 量纲改变与 PCA[返回题目](#)

答案：C。

标准化消除了该正比例尺度变化，协方差阵则改变相应方差与协方差。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 1.9 完整变换与降维[返回题目](#)

答案：A。

正交变换保距；降维后该结论一般不再成立。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 1.10 主成分变换与样本点的几何关系[返回题目](#)

保留全部成分时，协方差阵 PCA 的中心化和正交旋转保留欧氏距离及夹角；若截取前几个成分，投影通常改变距离并丢弃信息。相关阵 PCA 先作 Z 标准化，各坐标按不同标准差缩放，一般会改变原空间的距离和角度；仅在各尺度相同等特殊条件下保留其相对形状。故须区分“完整正交变换”和“降维投影”。

解析 题 1.11 三科成绩：协方差阵与相关阵[返回题目](#)

权重约定。记最大特征值对应、整体正向的单位特征向量为 a_1 。按课程参考代码将 $w_j = a_{j1} / \sum_l a_{l1}$ 作为原分数的权重，计算 $W = \sum_j w_j X_j$ 。相关阵的主成分本身则是 $C_1 = \sum_j a_{j1} (X_j - \bar{X}_j) / s_j$ ，两者并不相同。如果要求原量纲综合分与相关阵第一主成分严格线性等价，应将 a_{j1} / s_j 再归一化作为权重，并说明约定。

统计描述。

统计量	语文	数学	英语
均值	84.400	70.400	80.000
标准差	14.943	27.790	15.411

权重（语文、数学、英语顺序）。协方差阵为 (0.107726, 0.718583, 0.173691)，相关阵为 (0.427731, 0.133767, 0.438502)。

ID	协方差加权分	相关阵加权分
1	86.1796	82.7811
2	97.8743	95.5351
3	47.7468	85.3958
4	55.5386	57.1387
5	80.5386	82.1387

协方差阵中数学的方差较大，权重约 71.9%，第 3 人数学低分受到更强惩罚，得分低于第 4 人；相关阵消除了各科尺度差异，第 3 人的语文、英语优势得以体现。由协方差阵还是相关阵出发，应根据评价目的、变量量纲和变异的实际含义选择，不宜仅凭哪种排序更合意。

解析 题 1.12 三科成绩与招生评价

[返回题目](#)

权重约定。记最大特征值对应、整体正向的单位特征向量为 a_1 。按课程参考代码将 $w_j = a_{j1} / \sum_l a_{l1}$ 作为原分数的权重，计算 $W = \sum_j w_j X_j$ 。相关阵的主成分本身则是 $C_1 = \sum_j a_{j1} (X_j - \bar{X}_j) / s_j$ ，两者并不相同。如果要求原量纲综合分与相关阵第一主成分严格线性等价，应将 a_{j1} / s_j 再归一化作为权重，并说明约定。

协方差阵权重为 (0.088, 0.767, 0.145)；相关阵权重为 (0.415, 0.159, 0.427)。实际计算宜保留未舍入权重。

第 3 问设语文、数学、英语为 (c, m, e) ：

$$W_S = 0.08766886c + 0.76723953m + 0.14509161e,$$

$$W_R = 0.4146077c + 0.1586438m + 0.4267485e.$$

原分数缺失，无法还原该人的唯一数值结果。

第 4 问可按课程意图选协方差权重，因为它在本样本中更强调数学。但这是数学分数变异较大的结果，不是 PCA 自动识别了“理科能力”。招生权重还应经过专业论证、效度与稳定性检验。

解析 题 1.13 父母与子女身高的主成分回归

[返回题目](#)

若从父母身高的相关阵求得特征向量 a_{jk} ，则

$$C_k = \sum_{j=1}^2 a_{jk} \frac{X_j - \bar{X}_j}{s_j}.$$

保留 r 个主成分后的回归式为 $\hat{Y} = \gamma_0 + \sum_{k=1}^r \gamma_k C_k$ 。代回可得

$$b_j = \frac{\sum_k \gamma_k a_{jk}}{s_j}, \quad b_0 = \gamma_0 - \sum_j b_j \bar{X}_j.$$

因此 $\hat{Y} = b_0 + b_1X_1 + b_2X_2$ 。若仅保留第一主成分，求和仅有 $k = 1$ 。协方差阵主成分只作中心化时，不除以 s_j 。原数据缺失，不能把“身高、头围、体重、孕周”的另一份数据当作本题身高数据。源码中附通用转换步骤；须用本题数据估计数值系数。

解析 题 1.14 从 SPSS 输出计算权重与主成分得分

[返回题目](#)

权重约定。 记最大特征值对应、整体正向的单位特征向量为 a_1 。按课程参考代码将 $w_j = a_{j1} / \sum_l a_{l1}$ 作为原分数的权重，计算 $W = \sum_j w_j X_j$ 。相关阵的主成分本身则是 $C_1 = \sum_j a_{j1}(X_j - \bar{X}_j)/s_j$ ，两者并不相同。如果要求原量纲综合分与相关阵第一主成分严格线性等价，应将 a_{j1}/s_j 再归一化作为权重，并说明约定。

按给出的第一列得分系数归一化， $w = (0.34, 0.35, 0.37)/1.06 = (0.320755, 0.330189, 0.349057)$ ；粗略写 $(0.32, 0.33, 0.35)$ 亦可，但结果须与精度一致。简单均分 $232/3 = 77.333$ ；按未再舍入权重得加权分约 77.736。

SPSS 得分系数列对应方差约为 1 的标准成分得分：

$$F_1 = .34 \frac{62 - 79}{12.4} + .35 \frac{79 - 80}{7.9} + .37 \frac{91 - 67}{18.2} \approx -0.02252.$$

若采用单位特征向量定义的、方差为 λ_1 的主成分，则 $C_1 = \sqrt{2.634}F_1 \approx -0.03655$ 。需说明得分采用哪种归一化。

第 4 问不能直接回答 1。 将相关阵特征向量归一化后乘原始成绩，得到的原分加权分一般不与标准化主成分完全相关。设原始协方差为 $S = D_s R D_s$ ， $b = D_s^{-1}a_1$ ，则

$$\text{Corr}(C_1, W) = \frac{b^T S w}{\sqrt{(b^T S b)(w^T S w)}}.$$

只有权重与 $D_s^{-1}a_1$ 成比例等相容条件下才为 1。原输出数值经过舍入，精确相关系数需完整协方差阵或原数据；也可明确改用与主成分等价的权重，再得到相关系数 1。

解析 题 1.15 成绩综合评分及个体评价

[返回题目](#)

权重约定。 记最大特征值对应、整体正向的单位特征向量为 a_1 。按课程参考代码将 $w_j = a_{j1} / \sum_l a_{l1}$ 作为原分数的权重，计算 $W = \sum_j w_j X_j$ 。相关阵的主成分本身则是 $C_1 = \sum_j a_{j1}(X_j - \bar{X}_j)/s_j$ ，两者并不相同。如果要求原量纲综合分与相关阵第一主成分严格线性等价，应将 a_{j1}/s_j 再归一化作为权重，并说明约定。

相关阵第一特征值为 2.055585，贡献率约 68.519%；第一特征向量取正向后为 (0.673130, 0.255288, 0.694063)，课程权重为 (0.414877, 0.157344, 0.427779)。A 同学加权分约 78.583。

A 的语文略低于样本均值 84.4，数学高于均值 60.4，英语高于均值 80；旋转后可用“语文英语”和“数学”二维描述，因子得分见配套计算结果。平均分、主成分、旋转因子衡量的方向不同；不要把仅 5 人的样本排序当稳定的能力评价。

解析 题 1.16 空气污染综合指数[返回题目](#)

权重约定。记最大特征值对应、整体正向的单位特征向量为 a_1 。按课程参考代码将 $w_j = a_{j1} / \sum_l a_{l1}$ 作为原分数的权重, 计算 $W = \sum_j w_j X_j$ 。相关阵的主成分本身则是 $C_1 = \sum_j a_{j1} (X_j - \bar{X}_j) / s_j$, 两者并不相同。如果要求原量纲综合分与相关阵第一主成分严格线性等价, 应将 a_{j1} / s_j 再归一化作为权重, 并说明约定。

相关阵第一载荷列具有共同的 $\sqrt{\lambda_1}$ 因子, 可用 (.741, .892, .909) 归一化, 约得 (0.2915, 0.3509, 0.3576)。协方差阵用原尺度载荷 (39.208, 16.883, 65.715) 归一化, 约得 (0.3219, 0.1386, 0.5395)。所附 61 日数据可复算更高精度结果。

不能直接归一化协方差阵输出的“标准化得分系数”(.339, .059, .737), 那是另一尺度。若希望消除不同污染物指数的波动尺度差异, 相关阵较合适; 若指数已按可比风险标准定义, 且绝对变异有实际意义, 可论证采用协方差阵。实际环境风险权重还涉及危害与政策目的, PCA 仅提供统计权重。

解析 题 1.17 用成绩因子分析结果评价新学生[返回题目](#)

权重约定。记最大特征值对应、整体正向的单位特征向量为 a_1 。按课程参考代码将 $w_j = a_{j1} / \sum_l a_{l1}$ 作为原分数的权重, 计算 $W = \sum_j w_j X_j$ 。相关阵的主成分本身则是 $C_1 = \sum_j a_{j1} (X_j - \bar{X}_j) / s_j$, 两者并不相同。如果要求原量纲综合分与相关阵第一主成分严格线性等价, 应将 a_{j1} / s_j 再归一化作为权重, 并说明约定。

若取相关阵第一主成分的统计权重, 可归一化第一初始载荷 (.963, .632, .947), 得权重约 (0.378835, 0.248623, 0.372541), 其原分加权平均约 74.965。

另一种是因子综合得分: 先根据本题均值和标准差求 Z , 再由得分系数得到 $\hat{F}_1 \approx 0.3262$ 、 $\hat{F}_2 \approx -0.9293$ 。按旋转后方差贡献比例加权,

$$F_{\text{comp}} = \frac{1.912}{1.912 + 1.045} \hat{F}_1 + \frac{1.045}{1.912 + 1.045} \hat{F}_2 \approx -0.1175.$$

这个结果是标准化综合得分, 不是百分制平均分; 若需转换回百分制, 需要另行规定基准和尺度。题目未唯一规定加权规则, 应明确所用方法。

补充练习解析**解析 题 1.18 特征向量、相关系数与标准成分得分**[返回题目](#)

答案: B。

相关阵 PCA 中, $\text{Corr}(Z_1, C_1) = a_{11} \sqrt{\lambda_1} = 0.50 \times 1.50 = 0.75$ 。把 C_1 除以其标准差后, Z_1 的系数为 $a_{11} / \sqrt{\lambda_1} = 1/3$ 。三种系数所对应的量不同, 读取输出时应先核对表名与得分的标准化方式。

解析 题 1.19 Bartlett 球形检验与 KMO 的联合判断[返回题目](#)

球形检验的零假设是总体相关矩阵为单位阵 $H_0: R = I_6$ 。显著结果说明有证据认为指标间并非完全不相关, 不能推出“非常适合”, 也不能确定只保留一个主成分。

KMO 比较简单相关平方和与偏相关平方和的相对大小。按正文参考标准, 0.42 低于 0.50, 适合性不足; 应检查所选指标的相关结构和测量内容。

保留成分还需查看特征值、各成分及累计方差贡献率,并结合综合指标的专业含义。若第一成分保留信息不足或难以作合理解释,就不能只因球形检验显著而采用单一综合分。

解析 题 1.20 两科成绩的主成分与百分位评价

[返回题目](#)

(1) 表达式与方差。令 $Z_1 = (X_1 - 70)/10$, $Z_2 = (X_2 - 80)/5$, 则

$$C_1 = (Z_1 + Z_2)/\sqrt{2}, \quad C_2 = (Z_1 - Z_2)/\sqrt{2}.$$

对应特征值为 1.8 和 0.2, 贡献率为 90% 和 10%, 两成分不相关。

(2) 个体评价。A 的标准分为 (2, 1), 故 $C_1 = 3/\sqrt{2} \approx 2.1213$, $C_2 = 1/\sqrt{2} \approx 0.7071$ 。第一成分反映两科的综合相对水平; 第二成分为正, 表示 A 的语文相对优势高于数学相对优势, 比较的是标准分。

(3) 百分位。第一成分的标准差是 $\sqrt{1.8}$, 不是 1。应先计算

$$F_1 = \frac{C_1}{\sqrt{1.8}} \approx 1.5811, \quad \Phi(F_1) \approx 0.9431.$$

即按该正态模型约处于第 94.31 百分位。这是模型给出的相对位置, 不是 A 的百分制成绩, 也不是直接数得的样本名次。

(4) 信息与条件。只保留第一成分会丢失占总标准化方差 10% 的科目相对差异。PCA 通常保证不相关; 本题因另加联合正态条件, 才可进一步说两个成分独立。部分资料所说的“独立”在一般资料中应按“不相关”理解。

解析 题 1.21 胎儿受精龄: 还原主成分回归方程

[返回题目](#)

(1) 先合并标准分系数, 再还原量纲。 $\hat{Y} = 23.73 + 0.9484Z_1 + 1.0414Z_2 + 4.7536Z_3$. 因此

$$b_1 = 0.9484/9.71 \approx 0.0976725,$$

$$b_2 = 1.0414/6.86 \approx 0.1518076,$$

$$b_3 = 4.7536/690.3 \approx 0.00688628,$$

$$b_0 = 23.73 - b_1(33.05) - b_2(23.26) - b_3(936.9) \approx 10.51912.$$

故按题给系数得到

$$\hat{Y} \approx 10.51912 + 0.0976725X_1 + 0.1518076X_2 + 0.00688628X_3.$$

还原截距时必须扣除各均值项。原例另列简写回归方程; 本题指定使用两位小数的成分系数, 复算时不要求与末页简写结果逐位一致。

(2) 代入计算。标准化后得到 $C_1 \approx 1.280864$ 、 $C_2 \approx 0.098807$, 故 $\hat{Y} \approx 29.0061$ 周, 约 29.01 周。用还原方程计算应得到相同结果。

(3) 方法含义。主成分彼此不相关, 以保留的成分作自变量可避免原自变量的强线性相关造成的系数不稳定。舍弃成分同时舍弃了其中的信息, 可能引入偏差; 解释自变量方差少的方向也可能对结局有用, 所以不能保证预测误差一定下降。

第2章

因子分析

因子分析与主成分分析在计算上相似，均需求解特征值，但二者的方向相反。主成分分析由变量构造综合指标， $c = a^T x$ ，主成分为变量的加权和，数据给定即可计算。因子分析由因子解释变量， $x = Lf + u$ ，假定存在不可观测的公因子，变量之间的相关源于公因子的共同作用。

因此，因子分析以一种解释为出发点：若干指标之间相关，是因为它们有共同的来源。这与流行病学中两个结局因共同危险因素而相关的思路一致。在心理测量中，言语能力、数学能力等不可直接观测，只能通过各科成绩加以推断，因子分析即用于此类推断。

本章的重点为：模型 $\Sigma = LL^T + \Psi$ 的由来；负荷、共性方差与因子贡献的含义；因子旋转不改变模型拟合而改变解释的原因。

2.1 因子分析

因子分析 (factor analysis) 探讨多个可观测变量间的相关性，解释相关阵或协方差阵为什么会分块。有研究者认为， p 个表型变量受少数 k 个 ($k < p$) 不可观测隐变量 (因子) 支配。因子分析的任务是探讨因子如何支配变量，还原它们之间的协方差结构。

批注 主成分分析是数学变换，目的为降维与信息浓缩。因子分析是统计模型，目的是寻找潜在变量 (公因子) 并解释它们的意义，且允许误差。

2.1.1 发展历程

1904 年，Charles Spearman 认为学生古典语、法语和英语三门成绩受公因子“语言能力”支配，用一个不可观测变量解释可观测变量间的相关性 (协方差结构)。

$$R = \begin{array}{l} \text{古典语} \\ \text{法语} \\ \text{英语} \end{array} \begin{bmatrix} 1.00 & 0.83 & 0.78 \\ 0.83 & 1.00 & 0.67 \\ 0.78 & 0.67 & 1.00 \end{bmatrix}.$$

单因子模型的相关结构

若三门成绩仅受一个公因子支配，由下一节的推导，任意两门课程的相关系数等于二者负荷的乘积： $r_{12} = l_1 l_2$ ， $r_{13} = l_1 l_3$ ， $r_{23} = l_2 l_3$ 。三个方程含三个未知数，可直接求解：

$$l_1^2 = \frac{r_{12} r_{13}}{r_{23}} = \frac{0.83 \times 0.78}{0.67} = 0.966, \quad l_1 = 0.983,$$

$$l_2 = \frac{0.83}{0.983} = 0.844, \quad l_3 = \frac{0.78}{0.983} = 0.793.$$

该结果与 `factanal(covmat=R3,factors=1,n.obs=100)` 给出的最大似然负荷 (0.983、0.844、0.793) 相同, 此时模型自由度为 0, 恰好拟合。变量多于 3 个时, 方程个数多于未知数, “相关系数等于负荷乘积” 成为可由数据检验的约束, 这是因子模型拟合优度检验的基础。

Spearman 正是根据相关系数之间的这种比例关系, 推断存在一个一般智力因子。

1930 年, Louis Thurstone 提出多因子理论, 并引入因子旋转技术。20 世纪 50 年代至今, 随着计算机发展, 因子分析应用于心理学以外的众多领域。

2.2 因子模型

2.2.1 单因子模型

学生古典语、法语和英语三门成绩受公因子 f (语言能力) 支配。 f 解释不了的部分称为特殊因子, 类似回归中的残差。

$$\begin{cases} x_1^* = l_1 f + u_1, \\ x_2^* = l_2 f + u_2, \\ x_3^* = l_3 f + u_3. \end{cases} \quad (2.1)$$

设随机变量 f 和 u_i 满足

$$E(f) = 0, \quad \text{var}(f) = 1, \quad E(u) = 0, \quad \text{cov}(u) = \Psi = \text{diag}(\psi_1, \psi_2, \psi_3), \quad \text{cov}(u, f) = 0.$$

批注 * 表示标准化处理, 也可用 $x_i - \bar{x}_i$ 进行中心化处理。 f 为隐变量或潜变量, 需估计 l_1, l_2, l_3 。 Ψ 是对角矩阵, 即三个特殊因子互不相关 (协方差为 0), ψ_i 表示各自的方差。互不相关只是二阶矩条件; 要说相互独立, 还需附加条件, 例如 (f, u) 服从联合正态分布。




图 2.1 单因子模型

2.2.2 正交多因子模型

课本例 5.8 中, Lawley 和 Maxwell 对 220 名男生的六门课成绩 (盖尔语、英语、历史、算术、代数、几何) 作因子分析, 可能存在两个公因子 f_1 和 f_2 。

$$\begin{aligned} x_1^* &= l_{11}f_1 + l_{12}f_2 + u_1, \\ x_2^* &= l_{21}f_1 + l_{22}f_2 + u_2, \\ &\vdots \\ x_6^* &= l_{61}f_1 + l_{62}f_2 + u_6. \end{aligned} \quad (2.2)$$

$$E(f) = 0, \quad \text{cov}(f) = I, \quad E(u) = 0, \quad \text{cov}(u) = \Psi = \text{diag}(\psi_1, \dots, \psi_6), \quad \text{cov}(u, f) = 0.$$

批注 正交两因子模型的 $\text{cov}(f)$ 为 2×2 单位阵。




图 2.2 正交两因子模型

2.2.3 矩阵表示

以正交两因子模型为例, $X = LF + u$, L 称为因子负荷系数矩阵 (loading matrix), 有 p 行 k 列。

$$X = \begin{bmatrix} x_1^* \\ \vdots \\ x_6^* \end{bmatrix}, \quad L = \begin{bmatrix} l_{11} & l_{12} \\ \vdots & \vdots \\ l_{61} & l_{62} \end{bmatrix}, \quad F = \begin{bmatrix} f_1 \\ f_2 \end{bmatrix}, \quad u = \begin{bmatrix} u_1 \\ \vdots \\ u_6 \end{bmatrix}.$$

$$X = LF + u = \begin{bmatrix} l_{11}f_1 + l_{12}f_2 + u_1 \\ \vdots \\ l_{61}f_1 + l_{62}f_2 + u_6 \end{bmatrix}.$$

批注 重点是估计出 L 。

2.2.4 负荷矩阵的作用

求出负荷系数矩阵, 就可以写出因子模型表达式。

$$R = R^* + \Psi, \quad R^* = LL^T. \quad (2.3)$$

约相关阵 R^* (Reproduced Correlation Matrix) 可还原指标间大部分相关性。

标化变量 X 的协方差阵 $\text{cov}(X)$ 即相关阵 R 。在模型假设下,

$$\begin{aligned}\text{cov}(X) &= E[(LF + u)(LF + u)^T] \\ &= E[LF F^T L^T + uu^T + LFu^T + uF^T L^T] \\ &= LE(FF^T)L^T + E(uu^T) + LE(Fu^T) + E(uF^T)L^T \\ &= LIL^T + \Psi + 0 + 0 = LL^T + \Psi.\end{aligned}$$

这是总体模型下的等式。样本中 L 、 Ψ 都要估计, 只能近似成立: $R \approx \hat{L}\hat{L}^T + \hat{\Psi}$ 。残差阵 $E = R - (\hat{L}\hat{L}^T + \hat{\Psi})$ 衡量模型对相关结构的拟合程度。

批注 R^* 为 6×6 矩阵。其第一项对角元素为 $l_{11}^2 + l_{12}^2$ 。标化后的方差为 1, 故 $1 - (l_{11}^2 + l_{12}^2) = \text{var}(u_1)$ 。
例 2 中, 0.634 为可被公因子解释的共性方差, 0.366 由特殊因子解释。

2.3 因子模型的估计方法

估计方法包括主成分法 (principal component, PC)、极大似然法 (maximum likelihood, ML)、主因子法 (principal factor)、迭代主因子法 (iterated principal factor) 等。

2.3.1 主成分法因子分析

例 1 三门语言成绩

从古典语、法语和英语三门成绩的相关矩阵出发, 用主成分法作因子分析。

$$X = \begin{bmatrix} x_1^* \\ x_2^* \\ x_3^* \end{bmatrix} = \begin{bmatrix} l_1 \\ l_2 \\ l_3 \end{bmatrix} f + u, \quad R = LL^T + \Psi = \begin{bmatrix} l_1 \\ l_2 \\ l_3 \end{bmatrix} \begin{bmatrix} l_1 & l_2 & l_3 \end{bmatrix} + \begin{bmatrix} \psi_1 & 0 & 0 \\ 0 & \psi_2 & 0 \\ 0 & 0 & \psi_3 \end{bmatrix}.$$

$$R = \begin{bmatrix} l_1^2 + \psi_1 & l_1 l_2 & l_1 l_3 \\ l_1 l_2 & l_2^2 + \psi_2 & l_2 l_3 \\ l_1 l_3 & l_2 l_3 & l_3^2 + \psi_3 \end{bmatrix}.$$

基本思想

根据矩阵谱分解, 相关阵可以用特征值 λ_i 和特征向量 e_i 表达:

$$R = \begin{bmatrix} 1 & r_{12} & r_{13} \\ r_{12} & 1 & r_{23} \\ r_{13} & r_{23} & 1 \end{bmatrix}, \quad A = \begin{bmatrix} \sqrt{\lambda_1} e_{11} & \sqrt{\lambda_2} e_{21} & \sqrt{\lambda_3} e_{31} \\ \sqrt{\lambda_1} e_{12} & \sqrt{\lambda_2} e_{22} & \sqrt{\lambda_3} e_{32} \\ \sqrt{\lambda_1} e_{13} & \sqrt{\lambda_2} e_{23} & \sqrt{\lambda_3} e_{33} \end{bmatrix}.$$

$$R = AA^T = \sum_{i=1}^3 \lambda_i e_i e_i^T. \quad (2.4)$$

视 A 为三因子模型的 L 矩阵, 则 $R = LL^T + 0$ 。本例仅一个特征值大于 1, 且贡献率为 84%, 故只保留 A 的第一列, 即为主成分分解。

因子分析过程

```
1 eigen(R)
2 2.5219123 / 3
```

$$(\lambda_1, \lambda_2, \lambda_3) = (2.5219123, 0.3341080, 0.1439797),$$

$$\begin{bmatrix} e_1 & e_2 & e_3 \end{bmatrix} = \begin{bmatrix} -0.5991079 & -0.1148613 & 0.7923867 \\ -0.5729499 & -0.6297937 & -0.5244885 \\ -0.5592836 & 0.7682231 & -0.3115046 \end{bmatrix}, \quad \frac{\lambda_1}{3} = 0.8406374.$$

$$L = \begin{bmatrix} \sqrt{\lambda_1} e_{11} \\ \sqrt{\lambda_1} e_{12} \\ \sqrt{\lambda_1} e_{13} \end{bmatrix} = \begin{bmatrix} 1.588 \times 0.599 \\ 1.588 \times 0.573 \\ 1.588 \times 0.559 \end{bmatrix} = \begin{bmatrix} 0.951 \\ 0.910 \\ 0.888 \end{bmatrix}.$$

$$x_1^* = 0.951f + u_1, \quad x_2^* = 0.910f + u_2, \quad x_3^* = 0.888f + u_3.$$

特殊方差与残差矩阵 主成分法令 $\hat{\psi}_i = 1 - \hat{l}_i^2$, 得 $\hat{\Psi} = \text{diag}(0.095, 0.172, 0.211)$ 。残差矩阵为

$$E = R - (\hat{L}\hat{L}^T + \hat{\Psi}) = \begin{bmatrix} 0 & -0.036 & -0.065 \\ -0.036 & 0 & -0.138 \\ -0.065 & -0.138 & 0 \end{bmatrix}.$$

以法语与英语为例: 观测相关系数为 0.67, 模型再现 $\hat{l}_2\hat{l}_3 = 0.910 \times 0.888 = 0.808$, 残差为 -0.138 。

与 Spearman 例中的最大似然解 (0.983, 0.844, 0.793) 相比, 主成分法的负荷 (0.951, 0.910, 0.888) 中后两个明显偏大。原因在于主成分法将对角线上的 1 全部作为待解释的方差, 其中本应属于特殊因子的部分也归入了公因子。最大似然解的残差阵为 0, 而主成分法将法语与英语的相关高估了 0.138。

两者反映不同的方面。84% 的贡献率 $\lambda_1/3$ 说明公因子解释了三个标准化变量总方差 (对角线) 的 84%。残差矩阵看的是非对角的相关系数被再现得怎样。主成分法为使对角线残差为 0, 且往往高估负荷, 本例三个非对角残差都为负, 即一个因子高估了变量间的相关, 法语与英语之间尤甚。贡献率高, 并不保证相关结构拟合得好。

SPSS 数据格式与语法

ROWTYPE_	VARNAME_	x_1	x_2	x_3
MEAN				
STDDEV				
N		100.00	100.00	100.00
CORR	x_1	1.00	0.83	0.78
CORR	x_2	0.83	1.00	0.67
CORR	x_3	0.78	0.67	1.00

```
1 FACTOR
2 /matrix in (cor = *)
3 /ANALYSIS x1 x2 x3
4 /EXTRACTION PC
5 /ROTATION NOROTATE
```

例 2 220 名男生六门课成绩（课本例 5.8）

要求：确定因子个数，并用主成分法作因子分析。

表 2.1 六门课成绩的相关矩阵

	盖尔语	英语	历史	算术	代数	几何
盖尔语	1.000	0.439	0.410	0.288	0.329	0.248
英语	0.439	1.000	0.351	0.354	0.320	0.329
历史	0.410	0.351	1.000	0.164	0.190	0.181
算术	0.288	0.354	0.164	1.000	0.595	0.470
代数	0.329	0.320	0.190	0.595	1.000	0.464
几何	0.248	0.329	0.181	0.470	0.464	1.000

因子负荷系数矩阵的性质

- 1) 行元素平方和即共性方差，说明变量主要受公因子还是特殊因子支配。
- 2) 列元素平方和即因子贡献。
- 3) 观测变量标准化 ($\text{var } X_i = 1$)、因子方差为 1 且因子正交 ($\text{cov}(F) = I$)、 $\text{cov}(F, u) = 0$ 时，负荷系数即因子与变量间的相关系数：

$$\text{cov}(X_i, F_j) = \text{cov}\left(\sum_{s=1}^k l_{is}F_s + u_i, F_j\right) = l_{ij}, \quad \text{corr}(X_i, F_j) = \frac{l_{ij}}{\sqrt{\text{var } X_i \text{ var } F_j}} = l_{ij}.$$

变量未标准化时，相关系数为 l_{ij}/σ_i ；因子斜交时， $\text{cov}(X_i, F_j)$ 为 $L\Phi$ 的元素 (Φ 为因子相关阵)，不再等于 l_{ij} 。

本例相关阵的特征值为 2.733、1.130、0.615、0.601、0.525、0.396，有两个大于 1，按“特征值大于 1”保留 2 个因子。这只是经验准则（Kaiser 准则），还应结合碎石图、拟合检验、残差和因子能否解释来定。

2.3.2 最大似然法因子分析

例 3 血压与体型指标

测定 742 名正常人的收缩压 (mmHg)、舒张压 (mmHg)、体重 (kg)、腰围 (cm) 和臀围 (cm) 五个指标。假设它们服从均数为 μ 、协方差阵为 Σ 的多元正态分布，要求从相关阵出发用最大似然法作因子分析。原始数据为课程文件 `exp2forMLE.sav`。

$$X = LF + u, \quad \Sigma = \text{cov}(X) = LL^T + \Psi, \quad \Psi = \text{diag}(\psi_1, \dots, \psi_5).$$

$$X \sim N_p(\mu, \Sigma), \quad \mathcal{L} = \prod_{i=1}^n f(x_i), \quad \log \mathcal{L} \text{ 含未知参数}.$$

批注 要求原变量符合多元正态分布。

正态分布

设 x 服从均数为 μ 、方差为 σ^2 的一元正态分布，则

$$f(x) = \frac{1}{(2\pi)^{1/2}\sigma} \exp\left[-\frac{1}{2}(x-\mu)(\sigma^2)^{-1}(x-\mu)\right] = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right].$$

设随机向量 $X = (x_1, \dots, x_p)^T$ 服从 p 元正态分布，则

$$f(X) = \frac{1}{(2\pi)^{p/2}|\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(X-\mu)^T\Sigma^{-1}(X-\mu)\right]. \quad (2.5)$$

μ 为均数向量， Σ 为 $x_1, \dots, x_p$ 的协方差阵， $|\Sigma|$ 为其行列式值。

一元最大似然估计

```
1 data <- rnorm(200, 10, 2)
2 nll1 <- function(params) {
3   mu <- params[1]
4   sigma <- exp(params[2]) # 对数尺度参数化, 保证 sigma > 0
5   -sum(dnorm(data, mean = mu, sd = sigma, log = TRUE))
6 }
7 fit <- optim(par = c(8, log(3)), fn = nll1, method = "BFGS")
8 c(mu = fit$par[1], sigma = exp(fit$par[2]))
```

估计值与闭式解 $\bar{x}$ 及 $\sqrt{\sum(x_i - \bar{x})^2/n}$ 一致（注意分母为 n ）。

多元最大似然估计

```

1 library(MASS) # mvnrm() 在 MASS 包中
2 library(mvtnorm) # dmvmnorm() 在 mvtnorm 包中
3 mu <- c(152, 38)
4 sigma <- matrix(c(70, 34, 34, 30), 2, 2)
5 da <- mvnrm(100, mu, sigma)
6 nll2 <- function(params) {
7   m <- params[1:2] # 均值向量
8   U <- matrix(c(exp(params[3]), 0, params[4], exp(params[5])), 2, 2)
9   S <- crossprod(U) # S = t(U) U, 必为正定
10  -sum(dmvmnorm(da, mean = m, sigma = S, log = TRUE))
11 }
12 U0 <- chol(cov(da)) # 以样本矩估计作初值
13 par0 <- c(colMeans(da), log(U0[1, 1]), U0[1, 2], log(U0[2, 2]))
14 mle_result <- optim(par = par0, fn = nll2, method = "BFGS")

```

二元正态有 2 个均值和 3 个协方差参数 ($\sigma_{11}, \sigma_{12}, \sigma_{22}$), 共 5 个未知参数。上面用 Cholesky 分解 $\Sigma = U^T U$ 参数化 (U 为上三角阵, 对角元取指数), 恰好 5 个自由参数, 且对任何参数值 Σ 都正定, 优化不会走到不合法的区域。

设 $x_1, \dots, x_n$ 独立同分布于 $N_p(\mu, \Sigma)$ 。不论 Σ 取何值, μ 的极大似然估计都是 $\bar{x}$; 代入后得到只含 Σ 的对数似然。记 $S_n = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})^T$ (分母为 n), 则

$$\begin{aligned} \log \mathcal{L}(L, \Psi) &= C - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \text{tr}(\Sigma^{-1} n S_n) \\ &= C - \frac{n}{2} \{ \log |LL^T + \Psi| + \text{tr}[(LL^T + \Psi)^{-1} S_n] \}. \end{aligned}$$

不加约束时, 最大值在 $\Sigma = S_n$ 处取得。因子分析是在 $\Sigma = LL^T + \Psi$ (L 为 $p \times k$ 阵, Ψ 为正对角阵) 的约束下求极大似然, 没有闭式解, 只能迭代。ML 估计具有尺度不变性, 从相关阵或协方差阵出发得到等价的解。

模型自由度

以 p 为变量数、 k 为因子数。 Σ (或 R) 有 $p(p+1)/2$ 个不同元素。模型参数为 L 的 pk 个元素和 Ψ 的 p 个对角元; 因子方差已固定为 1、因子间协方差固定为 0 ($\text{cov}(F) = I$), 不再计为参数。但对任意 $k \times k$ 正交阵 T , $L^* = LT$ 与 L 给出同一个 LL^T (见 2.4 节), 模型无法区分; $k \times k$ 正交阵有 $k(k-1)/2$ 个自由度, 必须扣除 (估计时常加 “ $L^T \Psi^{-1} L$ 为对角阵” 之类的约束来取定唯一解)。于是

$$df = \frac{p(p+1)}{2} - \left[pk + p - \frac{k(k-1)}{2} \right] = \frac{(p-k)^2 - p - k}{2}. \quad (2.6)$$

展开即可验证两式相等: $[p^2 + p - 2pk - 2p + k^2 - k]/2 = [(p-k)^2 - p - k]/2$ 。六门课例中 $p = 6$ 、 $k = 2$: $df = 21 - (12 + 6 - 1) = 4$ 。 $df > 0$ 时模型对 Σ 施加了实质约束, 才能检验拟合优度。

批注 有的资料把参数数记为 $p(k+1) + k$, 即把因子方差也算作参数, 且没有扣除旋转不确定性。按此计算六门课例得 $df = 21 - 20 = 1$, 与上式的 4 矛盾, 应以上式为准。

拟合优度检验

最大似然法因子分析，当模型自由度大于 0 时，可进行拟合优度检验。

$$H_0: \Sigma = LL^T + \Psi, \quad H_1: \Sigma \text{ 为其他正定矩阵}, \quad \alpha = 0.05.$$

$$\chi^2 = \left(n - 1 - \frac{2p + 4k + 5}{6} \right) \log \frac{|\hat{\Sigma}|}{|S_n|} \sim \chi^2(df), \quad (2.7)$$

df 按式(2.6)计算。从相关阵出发调用 `factanal()` 时，必须用 `n.obs` 给出样本量，否则无法计算检验统计量：

```
1  r <- c(.439, .410, .288, .329, .248, .351, .354, .320, .329, .164, .190,
        .181, .595, .470, .464)
2  R <- diag(6); R[lower.tri(R)] <- r; R <- R + t(R) - diag(6) # 表2.1
3  out1 <- factanal(covmat = R, factors = 2, n.obs = 220, rotation = "none")
4  out1$STATISTIC; out1$dof; out1$PVAL
```

完整输出如下（直接采用 `varimax` 旋转，旋转不影响检验结果）：

```
1  out2 <- factanal(covmat=R,factors=2,n.obs=220,rotation="varimax")
2  print(out2, cutoff=0)
```

```
Uniquenesses:
  Gaelic  English  History   Arith  Algebra Geometry
    0.510    0.594    0.644   0.377   0.431    0.628

Loadings:
          Factor1 Factor2
Gaelic    0.235   0.659
English   0.323   0.549
History    0.088   0.590
Arith      0.771   0.170
Algebra    0.724   0.213
Geometry  0.572   0.210

          Factor1 Factor2
SS loadings    1.612   1.203
Proportion Var  0.269   0.201
Cumulative Var  0.269   0.469

Test of the hypothesis that 2 factors are sufficient.
The chi square statistic is 2.33 on 4 degrees of freedom.
The p-value is 0.674
```

输出各项的含义：`Uniquenesses` 为特殊方差 $\hat{\psi}_i$ ， $1 - \hat{\psi}_i$ 为共性方差（如算术 $1 - 0.377 = 0.623$ ）；`Loadings` 为负荷矩阵；`SS loadings` 为各列平方和，即因子贡献；`Proportion Var` 为因子贡献除以变量数 6。最后两行为拟合优度检验。

仅取一个因子时,同一检验给出 $\chi^2 = 52.0$, $df = 9$, $P = 4.5 \times 10^{-8}$, 拒绝单因子模型。单一的一般能力因子不足以解释六门课程之间的相关,需区分数学与文史两个方面。此例说明拟合优度检验可辅助确定因子个数。

六门课例: $\chi^2 = 2.33$, $df = 4$, $P = 0.674$ 。 $P > 0.05$ 表示在 $\alpha = 0.05$ 水平上未拒绝两因子的协方差结构,并不等于证明模型正确。样本量大时微小偏离也会被拒绝,样本量小时检验效能又低。本例残差相关的最大绝对值为 0.030,各变量共性方差在 0.36 ~ 0.62 之间,两个因子(数学、文史)都能解释,几方面结合起来看,两因子模型是合适的。

2.3.3 主因子法与迭代主因子法

对例 3 的五项指标,从相关阵出发用主因子法作因子分析。

- 1) 估计共性方差初值。常用复相关系数平方 $h_i^{2(0)} = 1 - 1/r^{ii}$ (r^{ii} 为 R^{-1} 的第 i 个对角元,即 x_i 对其余变量回归的 R^2),也可用该变量与其他变量相关系数绝对值的最大值。
- 2) 用共性方差初值代替相关阵的主对角线,得到约相关阵 $R_h = R - \hat{\Psi}$ 。
- 3) 对约相关阵求特征值和特征向量,取前 k 个, $\hat{L} = (\sqrt{\lambda_1}e_1, \dots, \sqrt{\lambda_k}e_k)$, 即主因子解。
- 4) 迭代: 令 $h_i^2 = \sum_{j=1}^k \tilde{l}_{ij}^2$, $\hat{\psi}_i = 1 - h_i^2$, 回到第 2 步,直至相邻两次的 $\max_i |h_i^{2(t+1)} - h_i^{2(t)}|$ 小于容许误差(如 10^{-4})或达到最大迭代次数。

批注 迭代主因子法收敛时,等价于使非对角残差平方和最小的(未加权)最小二乘解。最大似然法则在正态似然下按 $1/\psi_i$ 加权。两者相似但不相同,都可能出现下述 Heywood 现象。

Heywood 现象

用最大似然法或主因子法作因子分析时,有时会出现共性方差 $h_i^2 \geq 1$ 的情况,称为 Heywood 现象,给解释带来困难。应区分两种情形。

- $\hat{\psi}_i = 0$ ($h_i^2 = 1$): 边界解,估计落在参数空间的边界上,该变量被公因子完全解释,相应的标准误和检验不可靠。R 的 `factanal()` 把 ψ_i 限制为不小于 0.005,遇到这种情形会停在下界。
- $\hat{\psi}_i < 0$ ($h_i^2 > 1$): 方差为负,已在参数空间之外,是不容许解(improper solution),不能解释。

常见原因有样本量小、因子数取得过多或过少、模型设定不当、个别变量与其他变量高度共线等。

批注 课本 72 页。

2.4 因子旋转

上述方法求出的是因子分析的初始解。有时初始因子不易解释,实际应用中常对负荷作正交变换,即旋转,以得到更简单的结构,便于因子解释。最常用的方法是方差最大(varimax)正交旋转。

在保持因子间正交、各变量共性方差不变的条件下,使负荷结构尽量简单:每一列的平方负荷尽量两极分化,接近 0 或接近 1。采用 Kaiser 标准化时,令 $h_i^2 = \sum_{j=1}^k \tilde{l}_{ij}^2$, 规范化负荷为 $\tilde{l}_{ij} = l_{ij}/h_i$, 即把每行化为单位长度。varimax 选择正交阵 T , 使各列规范化平方负荷的方差之和

$$V = \sum_{j=1}^k \left[\frac{1}{p} \sum_{i=1}^p \tilde{l}_{ij}^4 - \left(\frac{1}{p} \sum_{i=1}^p \tilde{l}_{ij}^2 \right)^2 \right]$$

达到最大,求得 T 后再把各行乘回 h_i 。R 的 `varimax()` 默认 `normalize = TRUE`,即采用 Kaiser 标准化。从几何观点看,正交旋转保持原坐标轴的正交性,对其进行旋转。

例 5 六门课成绩的方差最大正交旋转

利用 220 名男生六门课成绩的相关矩阵,用最大似然法作因子分析,并作方差最大正交旋转。

```
1 out1 <- factanal(covmat = R, factors = 2, n.obs = 220, rotation = "none")
2 loadings(out1)
3 out2 <- factanal(covmat = R, factors = 2, n.obs = 220, rotation = "varimax")
4 print(loadings(out2), cutoff = 0) # 默认 cutoff = 0.1 会隐藏小负荷
```

表 2.2 旋转前后的负荷矩阵及方差贡献

指标	初始 f_1	初始 f_2	旋转 f_1	旋转 f_2
盖尔语	0.553	0.429	0.235	0.659
英语	0.568	0.288	0.323	0.549
历史	0.392	0.450	0.088	0.590
算术	0.740	-0.273	0.771	0.170
代数	0.724	-0.211	0.724	0.213
几何	0.595	-0.132	0.572	0.210
载荷平方和	2.209	0.606	1.612	1.203
方差贡献比例	0.368	0.101	0.269	0.201
累积贡献比例	0.368	0.469	0.269	0.469

批注 旋转后, f_1 为数学因子, f_2 为文史因子。表中历史在旋转后 f_1 上的负荷 0.088, 在默认输出中因 `print()` 的 `cutoff = 0.1` 而显示为空白, 此处补出。

证明 (旋转不改变拟合) 设 T 为正交阵, $L^* = LT$, 则

$$L^*L^{*\top} = LTT^{\top}L^{\top} = LL^{\top}.$$

所以 $\hat{\Sigma} = LL^{\top} + \Psi$ 、残差阵、似然值和 χ^2 检验都不变; $LL^{\top}$ 的对角元即共性方差 h_i^2 , 也不变。□

各列平方和 (因子贡献) 则可以改变, 即公因子解释的方差在因子间重新分配。本例总共性方差 $2.209 + 0.606 = 1.612 + 1.203 = 2.815$ 保持不变, 旋转后两个因子的贡献更均衡。

因子旋转的依据

同一资料经旋转后负荷矩阵发生变化, 旋转前后的两组负荷均为同一模型的有效表示。

因子不可观测, 模型只规定了 $LL^{\top}$, 即变量间的相关结构, 而未规定坐标轴的方向。这与描述平面上点的位置类似: 采用东西-南北坐标或旋转 30° 后的坐标均可, 点的位置不变。本例旋转前, 第一因子是与所有课程相关的一般因子, 第二因子是文史与数学的对比; 旋转后, 两个因子分别对应数学课程与文史课程。两种表示的似然值、 χ^2 与残差完全相同, 选择的依据是何者更便于解释。

因子的名称由分析者依据负荷确定，具有一定的主观性。因子分析的结论宜通过新资料或专业理论加以验证。

求 varimax 的正交阵 T 一般只能用迭代法。当 $k = 2$ 时，可以精确求出 2×2 正交变换矩阵 T ：

$$T_{\text{顺时针}} = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}, \quad T_{\text{逆时针}} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

```
1 out2$rotmat
2 acos(0.8420397) / pi * 180
3 asin(0.5394156) / pi * 180
```

$$T = \begin{bmatrix} 0.8420397 & 0.5394156 \\ -0.5394156 & 0.8420397 \end{bmatrix}, \quad \theta = 32.64386^\circ \quad (\arccos), \quad 32.64387^\circ \quad (\arcsin).$$




图 2.3 六门课因子负荷与正交旋转 (32.64386°)

2.5 因子得分

公共因子的估计，即因子得分，是对不可观测、抽象但有实际意义的随机变量的估计。

2.5.1 估计方法

Bartlett 法 给定 L 和 Ψ ，把个体的因子值 f 当作待估参数，使加权残差平方和

$$Q(f) = (x^* - Lf)^T \Psi^{-1} (x^* - Lf)$$

最小，权重为特殊方差的倒数。一阶条件为 $\partial Q / \partial f = -2L^T \Psi^{-1}(x^* - Lf) = 0$ ，解得

$$\hat{f}_b = (L^T \Psi^{-1} L)^{-1} L^T \Psi^{-1} x^*. \quad (2.8)$$

这就是以 Ψ^{-1} 为权的加权最小二乘回归。若进一步假定 $x^* | f \sim N(Lf, \Psi)$ ， $Q(f)$ 就是 $-2 \times$ 对数似然（相差常数）， $\hat{f}_b$ 也是 f 的极大似然估计。这一“极大似然”解释仅限于给定 L 、 Ψ 的正态条件模型。它条件无偏： $E(\hat{f}_b | f) = f$ 。

Thomson 法（回归法） 把 f 当作随机变量， $Ef = 0$ ， $\text{cov}(f) = I$ ， $\text{cov}(f, x^*) = L^T$ ， $\text{cov}(x^*) = \Sigma = LL^T + \Psi$ 。使 $E\|f - Ax^*\|^2$ 最小的线性预测为 $A = \text{cov}(f, x^*) \text{cov}(x^*)^{-1} = L^T \Sigma^{-1}$ ，即

$$\hat{f}_t = L^T \Sigma^{-1} x^* = (I + L^T \Psi^{-1} L)^{-1} L^T \Psi^{-1} x^*. \quad (2.9)$$

证明（两种写法相等） $(I + L^T \Psi^{-1} L)L^T = L^T + L^T \Psi^{-1} LL^T = L^T \Psi^{-1}(\Psi + LL^T) = L^T \Psi^{-1} \Sigma$ 。左乘 $(I + L^T \Psi^{-1} L)^{-1}$ 、右乘 Σ^{-1} 即得。□

$\hat{f}_t$ 是最优线性预测；若 (f, x^*) 服从联合正态分布，它就是条件期望 $E(f | x^*)$ ，预测误差的协方差阵为 $\text{cov}(f - \hat{f}_t) = I - L^T \Sigma^{-1} L$ 。Thomson 得分向 0 收缩，条件有偏，但均方误差比 Bartlett 得分小；Bartlett 得分条件无偏，方差较大。

批注 可以使用旋转前或旋转后的因子。无论哪种方法，因子得分都只是预测值，含有预测误差，并不是个体真实的因子值；实际计算时 L 、 Ψ 又用估计值代替。把得分当作无误差的变量再放进回归等分析，会低估不确定性。

计算个体得分需要每个人的标准化观测值 x^* 。只有相关矩阵时，只能算出得分系数 $L^T R^{-1}$ ，算不出个体得分；R 中 `factanal(x = 原始数据, scores = "regression")` 可以给出得分，`factanal(covmat = R)` 则不能。

例 6 计算因子得分

测定 742 名正常人的收缩压、舒张压、体重、腰围和臀围五个指标，从相关阵出发用主成分法作因子分析，作方差最大正交旋转，并计算回归法因子得分。原始数据为课程文件 `exp2forMLE.sav` (742 行，变量 `ssy`、`szy`、`tz`、`yw`、`tw`)，例 3 也用这份数据。

```
1 da <- foreign::read.spss("exp2forMLE.sav", to.data.frame = TRUE)
2 R <- cor(da); e <- eigen(R) # 特征值 3.09, 1.25, 0.34, ...
3 L <- e$vector[, 1:2] %*% diag(sqrt(e$values[1:2])) # 主成分解
4 L <- unclass(varimax(L)$loadings) # 方差最大旋转
5 F <- scale(da) %*% solve(R) %*% L # 回归法：每行为 t(L) R^{-1} x*
```

旋转后第一因子在体重、腰围、臀围上的负荷为 0.93 ~ 0.95，为体型因子；第二因子在收缩压、舒张压上的负荷约 0.88 ~ 0.89，为血压因子。

本章小结：因子分析

研究目的	用少数不可观测的公因子解释多个观测变量之间的相关（协方差结构），并给公因子以专业解释
统计模型	$x^* = Lf + u$, $\text{cov}(f) = I$, $\text{cov}(u) = \Psi$ 为对角阵, $\text{cov}(f, u) = 0$; 于是 $\Sigma = LL^T + \Psi$
主要条件	变量间有相关且存在共同因子结构（KMO、Bartlett 检验作参考）；ML 法及其拟合检验要求多元正态、样本量足够； $df > 0$ 模型才可检验
结果解释	负荷（标准化、正交时即相关系数）、共性方差 h_i^2 、因子贡献、残差相关阵；旋转只重新分配贡献，不改变拟合
常见误用	把特殊因子“互不相关”说成“独立”；只凭特征值大于 1 或 $P > 0.05$ 定因子数；忽视 Heywood 解；把 84% 之类的贡献率当作相关结构拟合良好；以为只有相关矩阵也能算个体得分；把得分当作无误差的真值

复习题

- 1) 标准化变量的正交因子模型中，某变量在两个因子上的负荷为 0.6 和 0.5，计算其共性方差与特殊方差。
答：共性方差 $0.36 + 0.25 = 0.61$ ，特殊方差 0.39。
- 2) $p = 6$ 个变量取 $k = 2$ 个因子，计算最大似然因子分析拟合优度检验的自由度。
答： $[(6 - 2)^2 - 6 - 2]/2 = 4$ 。
- 3) 列出因子旋转前后保持不变的量与发生变化的量。
答：共性方差、 LL^T 、残差阵、似然值与 χ^2 检验不变；负荷矩阵和各因子贡献（列平方和）会变，总贡献不变。
- 4) 主成分法因子分析中第一因子的贡献率为 84%，说明这一数值能否用于判断单因子模型的拟合程度。
答：不能。贡献率反映对角线上的方差，拟合程度需看非对角线的残差相关是否足够小；采用最大似然法时还可作 χ^2 检验。
- 5) 比较主成分分析与因子分析的根本区别。
答：主成分分析是变量的线性变换，不设模型；因子分析是统计模型，假定公因子导致变量相关，并单独设特殊因子（误差）。

第2章 习题与解析

因子分析

往年题

单项选择题

题 2.1 正交旋转的不变量

对因子初始解作正交旋转，没有改变的是：

- A. 原变量共同度。
- B. 各个因子负荷。
- C. 因子得分系数。
- D. 单个共同因子的解释贡献。
- E. 共同因子与原变量的各个相关系数。

题 2.2 探索性因子分析

关于探索性因子分析，正确的是：

- A. 给定数据的共同因子解是唯一的。
- B. 因子旋转的目的就是获得因子间相关。
- C. 因子命名主要依据负荷大小及变量含义。
- D. 第一因子得分方差必不小于其余得分方差。
- E. 变量相关较强通常不利于因子分析。

题 2.3 探索性因子分析

关于探索性因子分析，正确的是：

- A. 给定数据的共同因子解是唯一的。
- B. 因子旋转的目的就是获得因子间相关。
- C. 因子命名主要依据负荷大小及变量含义。
- D. 第一因子得分方差必不小于其余得分方差。
- E. 变量相关较强通常不利于因子分析。

题 2.4 同一学生在不同指标下的排序

姓名	语文	数学	英语
马云	84	88	80
方舟子	95	99	95
三毛	98	20	90
王宝强	60	45	55
赵薇	85	50	80

数据作 Z 变换，以主成分法提取 2 因子并作 varimax 旋转。对马云较有利的综合评价指标是：I 第一因子得分；II 第二因子得分；III 第一主成分得分；IV 三科总分。

- A. 仅 I。
- B. 仅 II。
- C. I 与 III。
- D. II 与 IV。
- E. II 与 III。

题 2.5 因子提取与方差溢出

对正半定相关矩阵提取少于或等于全部成分时，下列哪种提取方式保证其提取共同度不超过 1，从而不会出现共同度大于 1 的 Heywood 现象？

- A. 主成分提取法。
- B. 不加约束的迭代主轴因子法。
- C. 不加约束的极大似然因子法。
- D. 任意指定负独特方差的模型。
- E. 把共同度初值全部设为 2 的方法。

题 2.6 因子模型中的系数

写标准化变量的因子模型 $Z_j = \sum_k l_{jk} F_k + \varepsilon_j$ 时， l_{jk} 应从哪项输出读取？

- A. 因子负荷矩阵（指定旋转阶段）。
- B. 因子得分系数矩阵。
- C. 各样本的因子得分矩阵。
- D. 原始观测数据矩阵。
- E. KMO 统计量。

题 2.7 保留因子数的基本考虑

选择因子数时，最合理的总体原则是：

- A. 无论资料如何都保留 2 因子。
- B. 只要第一特征值大于 1 就不再看其他信息。
- C. 用尽可能简洁且可解释的模型保留足够信息，并结合拟合和专业目的判断。
- D. 只比较变量原始均数。
- E. 因子数必须等于样本量。

题 2.8 正交因子共同度

两个标准正交因子对某变量的负荷为 0.6 和 0.3，共同度为：

- A. 0.90。
- B. 0.45。
- C. 0.18。
- D. 1.80。
- E. 0.30。

题 2.9 斜交旋转的模式与结构

斜交因子模型模式矩阵为 P 、因子相关矩阵为 Φ ，结构矩阵为：

- A. P 必定不变。
- B. $P\Phi$ 。
- C. $P + \Phi$ 。
- D. $P^T P$ 。
- E. Φ^{-1} 。

题 2.10 非迭代 SMC 初值

相关阵可逆。主轴因子法的 SMC 初始共同度应取：

- A. $1 - 1/(R^{-1})_{jj}$ 。
- B. $(R^{-1})_{jj}$ 。
- C. 任意大于 1 的值。
- D. 原变量均值。
- E. 全部取 0 且不再提取。

题 2.11 因子评分方法的识别

下式属于何种因子评分? $\hat{f} = (L^T \Psi^{-1} L)^{-1} L^T \Psi^{-1} z$ 。

- A. Bartlett 加权最小二乘评分。
- B. Thomson 回归评分。
- C. KMO 计算。
- D. Ward 更新公式。
- E. Bayes 后验概率。

题 2.12 KMO 的含义

KMO 较大通常意味着:

- A. 偏相关相对于简单相关较小, 资料更适于探索共享因子结构。
- B. 所有变量均独立。
- C. 模型已被证明正确。
- D. 因子数已经确定。
- E. 所有因子得分完全无误差。

简答题**题 2.13 因子负荷的行、列平方和**

什么是因子负荷? 其行平方和与列平方和各代表什么含义?

计算与分析题**题 2.14 戒毒者量表: 初始解与旋转解**

调查 20 名戒毒者的抑郁 X_1 、焦虑 X_2 、情绪管理 X_3 、情绪判读 X_4 、与他人关系 X_5 、社会满意度 X_6 、工作满意度 X_7 。用主成分法提取因子, 对初始模型作方差最大正交旋转。共 20 分。

1. 写出“焦虑 (X_3)”的共同度并说明含义 (原题名称与编号矛盾)。
2. 写出第四因子的贡献率并说明含义。
3. 写出累计贡献率并说明含义。
4. 写出焦虑 X_2 的因子模型及它与第一因子的相关系数。
5. 写出第三因子得分式, 求其均值、标准差及与第一因子的简单相关系数。

变量	初始共同度	提取共同度
X_1	1	0.911
X_2	1	0.902
X_3	1	0.803
X_4	1	0.723
X_5	1	0.72
X_6	1	0.913
X_7	1	0.896

初始与旋转后的方差解释表。

因子	初始 λ	贡献%	累计%	旋转 λ	贡献%	累计%
1	2.053	29.327	29.327	1.997	28.523	28.523
2	1.695	24.22	53.547	1.499	21.413	49.936
3	1.1	15.708	69.255	1.234	17.633	67.569
4	1.02	14.577	83.832	1.138	16.263	83.832
5	0.639	9.124	92.956			
6	0.385	5.494	98.45			
7	0.108	1.55	100			

初始载荷矩阵。

变量	1	2	3	4
X_1	0.902	-0.177	0.139	-0.217
X_2	0.886	-0.213	0.135	0.228
X_3	0.078	0.718	0.412	-0.334
X_4	0.203	0.774	0.088	-0.273
X_5	0.587	0.351	-0.258	0.431
X_6	-0.239	0.426	0.355	0.741
X_7	-0.07	-0.446	0.832	0.011

旋转载荷矩阵。

变量	1	2	3	4
X_1	0.878	0.13	0.082	-0.341
X_2	0.943	-0.098	0.028	0.034
X_3	-0.024	0.887	0.089	0.085
X_4	0.052	0.81	-0.248	0.041
X_5	0.553	0.09	-0.54	0.338
X_6	-0.114	0.111	0.053	0.941
X_7	0.116	-0.086	0.929	0.111

旋转后的成分得分系数矩阵（作用于标准化变量）。

变量	1	2	3	4
X_1	0.421	0.116	0.115	-0.248
X_2	0.49	-0.095	0.056	0.124
X_3	-0.025	0.626	0.189	-0.022
X_4	-0.003	0.532	-0.102	-0.057
X_5	0.285	-0.059	-0.407	0.329
X_6	0.021	-0.018	0.082	0.837
X_7	0.114	0.042	0.778	0.149

题 2.15 戒毒者量表：旋转后模型

调查 20 名戒毒者的抑郁 X_1 、焦虑 X_2 、情绪管理 X_3 、情绪判读 X_4 、与他人关系 X_5 、社会满意度 X_6 、工作满意度 X_7 。用主成分法提取因子，对初始模型作方差最大正交旋转。共 20 分。
1. 写出焦虑 X_2 的共同度及其含义。2. 写出旋转后第三因子的贡献率及其含义。3. 写出总累计贡献率及其含义。4. 写出焦虑 X_2 的因子模型及其与第一因子的相关系数。5. 写出旋转后第三因子得分式，求其均值、标准差及与第一因子得分的简单相关系数。

变量	初始共同度	提取共同度
X_1	1	0.911
X_2	1	0.902
X_3	1	0.803
X_4	1	0.723
X_5	1	0.72
X_6	1	0.913
X_7	1	0.896

初始与旋转后的方差解释表。

因子	初始 λ	贡献%	累计%	旋转 λ	贡献%	累计%
1	2.053	29.327	29.327	1.997	28.523	28.523
2	1.695	24.22	53.547	1.499	21.413	49.936
3	1.1	15.708	69.255	1.234	17.633	67.569
4	1.02	14.577	83.832	1.138	16.263	83.832
5	0.639	9.124	92.956			
6	0.385	5.494	98.45			
7	0.108	1.55	100			

初始载荷矩阵。

变量	1	2	3	4
X_1	0.902	-0.177	0.139	-0.217
X_2	0.886	-0.213	0.135	0.228
X_3	0.078	0.718	0.412	-0.334
X_4	0.203	0.774	0.088	-0.273
X_5	0.587	0.351	-0.258	0.431
X_6	-0.239	0.426	0.355	0.741
X_7	-0.07	-0.446	0.832	0.011

旋转载荷矩阵。

变量	1	2	3	4
X_1	0.878	0.13	0.082	-0.341
X_2	0.943	-0.098	0.028	0.034
X_3	-0.024	0.887	0.089	0.085
X_4	0.052	0.81	-0.248	0.041
X_5	0.553	0.09	-0.54	0.338
X_6	-0.114	0.111	0.053	0.941
X_7	0.116	-0.086	0.929	0.111

旋转后的成分得分系数矩阵（作用于标准化变量）。

变量	1	2	3	4
X_1	0.421	0.116	0.115	-0.248
X_2	0.49	-0.095	0.056	0.124
X_3	-0.025	0.626	0.189	-0.022
X_4	-0.003	0.532	-0.102	-0.057
X_5	0.285	-0.059	-0.407	0.329
X_6	0.021	-0.018	0.082	0.837
X_7	0.114	0.042	0.778	0.149

题 2.16 三科成绩因子模型与得分

下列为三科考试成绩的因子分析结果。所有初始共同度为 1；以主成分法提取，采用 Kaiser 标准化的 varimax 旋转，3 次迭代收敛。共 15 分。

- 1. 分析者选择了几个公因子？
- 2. 语文、数学的共同度各是多少？
- 3. 各公因子的方差贡献率各是多少？
- 4. 列出因子模型方程。
- 5. 列出因子得分模型方程。

变量	均值	标准差	共同度
语文	82.2	11.946	0.978
数学	75.2	19.942	1
英语	80.2	7.95	0.979

成分	初始 λ	贡献%	累计%	旋转 λ	贡献%	累计%
1	2.223	74.109	74.109	1.912	63.736	63.736
2	0.734	24.462	98.57	1.045	34.835	98.57
3	0.043	1.43	100			

变量	初始 1	初始 2	旋转 1	旋转 2	得分 1	得分 2
语文	0.963	-0.225	0.959	0.24	0.525	-0.075
数学	0.632	0.775	0.208	0.978	-0.229	1.069
英语	0.947	-0.289	0.974	0.176	0.558	-0.155

题 2.17 成绩分析：旋转载荷与因子命名

对下表进行主成分与因子分析，所有变量作 Z 变换，以主成分法提取 2 个公因子并作 varimax 旋转。

姓名	语文	数学	英语
马云	84	88	80
方舟子	95	99	95
三毛	98	20	90
王宝强	60	45	55
赵薇	85	50	80

1. 写出因子模型方程。(Q1, 5 分)
2. 给第 1、第 2 因子命名。(Q2, 5 分)

题 2.18 医院满意度：主成分提取与 Bartlett 得分

对基层医院医护人员满意度数据 (223 人、17 项指标) 进行因子分析：用主成分法提取 4 个因子，作正交旋转，用 Bartlett 法计算因子得分。共 20 分。变量如下。

变量	含义	变量	含义
X_1	业务用房	X_{10}	待遇公平
X_2	医疗设备	X_{11}	职工利益
X_3	技术水平	X_{12}	管理水平
X_4	办公条件	X_{13}	听取意见
X_5	报酬收入	X_{14}	社会尊重
X_6	发展信心	X_{15}	发展前途
X_7	住房分配	X_{16}	适应工作
X_8	住房现状	X_{17}	福利待遇
X_9	考评制度		

1. 写出 X_1 的因子表达式。
2. 参考各变量含义，给 4 个因子命名。
3. 给出 case100 的第二因子得分；若数据来自抽样调查，估计全人群第二因子维度满意度水平。

题 2.19 医院满意度：非迭代 SMC 与正交旋转

使用医院满意度 17 项数据做因子分析。共 20 分。

1. 计算 KMO 及各变量 MSA (原稿写 KMO/SMA)，判断适合度。(4 分)
2. 用主因子法中的 SMC 法，不迭代，提取 4 个共同因子，作 varimax 旋转。列出累计特征值、共同度和负荷矩阵。(8 分)
3. 依据第 2 问结果命名因子。(4 分)
4. 计算该 4 因子模型的 Thomson 回归法得分，列出前 5 个 case 的得分。(4 分)

变量含义与医院满意度数据表一致；数据文件已附。

题 2.20 医院满意度：Promax 斜交旋转

用主因子法的 SMC 法（不迭代）提取 4 个因子，作 promax 斜交旋转，幂指数为 4。

1. 按负荷与变量含义给 4 个共同因子命名。(4 分)
2. 填空（每空 1 分）：
 - 4 因子的累计特征值（以初始解或正交旋转解为准）。
 - X_1 的共同度。
 - X_2 在第二因子上的负荷。
 - 第一与第四因子的相关系数。
 - case2 在第一因子上的 Bartlett 得分。
 - case1 在第一因子上的 Thomson 回归得分。

文献分析题**题 2.21 文献中的两因子模型**

所指原始文献、图 1 及完整数据没有随题卷提供。以下保留设问；不能据此独立核验文献中的具体研究事实。1. 8 项指标得到两因子模型时，哪项共同度最小？2. 分析作者首先取两因子模型的可能理由。

题 2.22 文献复现与方法评价

请仔细阅读给出的文献，重复文献的分析结果，并作适当评价或改进。原题 35 分。
文献及其数据未附。

题 2.23 文献述评

请阅读所给文献，并作述评。原题 25 分。
文献未附。

补充练习

本节为配合正文新编的补充练习。除注明沿用正文例题外，数值与研究摘要均为教学设定。题型与作答方式沿用本章往年题，解析见章末。

单项选择题

题 2.24 最大似然因子模型的自由度

对 6 个指标拟合正交公因子模型。按正文公式 $df = [(p - m)^2 - p - m]/2$ ，其中 p 为指标数， m 为公因子数。以下正确的是：

- A. 两因子模型的自由度为 6。
- B. 三因子模型的自由度为 1。
- C. 两因子模型自由度为 4；三因子模型自由度为 0，后者不能按通常的正自由度卡方检验评价拟合。
- D. 公因子数越多，模型自由度越大。
- E. 自由度为 0 表明模型已被证明正确。

简答题

题 2.25 三种因子提取方法的区别

从相关矩阵出发时，主成分法、主因子法和最大似然法分别怎样获得初始因子解？说明主成分法与主因子法对相关矩阵对角线的处理差别，以及正文所述最大似然因子分析进行拟合优度检验的主要条件。

计算与分析题

题 2.26 体格指标的共同度与还原相关

以收缩压、舒张压、体重、腰围 4 个标准化指标拟合两因子模型。公因子均值为 0、方差为 1 且互不相关，特殊因子与公因子不相关，特殊因子之间也不相关。某次分析给出的正交旋转载荷如下（教学设定）。

变量	因子 1	因子 2
收缩压	0.8	0.2
舒张压	0.7	0.1
体重	0.1	0.8
腰围	0.3	0.7

共 15 分。

1. 写出收缩压的因子模型，并计算 4 个变量的共同度和特殊方差。（5 分）
2. 计算两个因子各自的贡献率及累计贡献率，给因子命名。（4 分）
3. 计算模型还原的收缩压与舒张压相关系数。若样本相关系数为 0.62，残差相关（样本值减模型还原值）是多少？（4 分）
4. 能否将载荷表的第一列直接乘以某人的 4 项标准分，称为其 Thomson 回归法因子得分？（2 分）

文献分析题

题 2.27 两因子模型的研究结果评议

以下为依据课堂方法编写的模拟研究摘要，全部评议所需结果已列出，不对应真实论文。

研究者测量 220 名受试者的 6 项数值指标，认为独立观测及多元正态等分析条件可以接受。最大似然提取 1 个因子时，拟合检验 $\chi^2 = 28.4$, $df = 9$, $P < 0.001$ ；提取 2 个因子时， $\chi^2 = 3.6$, $df = 4$, $P = 0.463$ 。两因子模型旋转前后列平方和如下。

阶段	因子 1	因子 2
旋转前	2.7	1.2
varimax 旋转后	2.05	1.85

作者写道：“两因子检验不显著，证明真实结构恰好只有两个因子。旋转后第二因子贡献增加，说明旋转提高了模型的总解释率。”共 15 分。

1. 写出拟合优度检验的零假设，在 $\alpha = 0.05$ 下比较这两个模型。(5 分)
2. 计算旋转前后各因子及累计贡献率，评价作者关于旋转的结论。(5 分)
3. 修正“证明真实结构恰好只有两个因子”的表述，并说明因子命名还需什么信息。(5 分)

习题解析

核对方式

按题号核对。补写题目、原稿歧义及复算约定列在对应解析中。

解析 题 2.1 正交旋转的不变量

[返回题目](#)

答案：A。

若 $L^* = LT$ 、 $TT^T = I$ ，则 $L^*L^{*T} = LL^T$ ，共同度不变；负荷和单列解释贡献一般会重新分配。

解析 题 2.2 探索性因子分析

[返回题目](#)

答案：C。

旋转追求更易解释的简单结构；正交旋转保持因子不相关，斜交旋转允许相关，但相关不是唯一目的。因子命名依赖负荷模式与测量内容，不能只机械选最大数值。

解析 题 2.3 探索性因子分析

[返回题目](#)

答案：C。

旋转追求更易解释的简单结构；正交旋转保持因子不相关，斜交旋转允许相关，但相关不是唯一目的。因子命名依赖负荷模式与测量内容，不能只机械选最大数值。

解析 题 2.4 同一学生在不同指标下的排序

[返回题目](#)

答案：D。

按语文英语为第一因子、数学为第二因子，马云的第二因子和总分均位列第2，第一因子较靠后，第一主成分约第3。判断“有利”必须与因子含义和排序相联系，不能只比较不同尺度的得分绝对值。

解析 题 2.5 因子提取与方差溢出

[返回题目](#)

答案：A。

PCA 保留的载荷行平方和不超过全部成分行平方和，而后者为相关阵对角元1。该结论针对有效正半定相关阵；缺失处理产生非正定矩阵等情况仍可能导致其他计算问题。

补写说明。2019 回忆稿只记录主题，没有完整题干与选项；本题依据该主题补写，不宣称恢复原选项。

解析 题 2.6 因子模型中的系数

[返回题目](#)

答案：A。

变量由因子表示使用负荷；估计个体因子得分使用得分系数，两者方向不同。斜交时应明确模式负荷与结构相关。

补写说明。2019 回忆稿只记录主题，没有完整题干与选项；本题依据该主题补写，不宣称恢复原选项。

解析 题 2.7 保留因子数的基本考虑[返回题目](#)

答案：C。

累计方差贡献率、碎石图、平行分析、模型拟合和可解释性均可作为依据。70% 或 80% 属于经验阈值，不是所有数据都适用的根本定律。

补写说明。2019 回忆稿只记录主题，没有完整题干与选项；本题依据该主题补写，不宣称恢复原选项。

解析 题 2.8 正交因子共同度[返回题目](#)

答案：B。

共同度为 $0.6^2 + 0.3^2 = 0.45$ ，独特方差为 0.55。

补写说明。2019 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 2.9 斜交旋转的模式与结构[返回题目](#)

答案：B。

结构矩阵给变量与因子的相关；因子相关不为单位阵时，通常不同于模式矩阵。

补写说明。2019 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 2.10 非迭代 SMC 初值[返回题目](#)

答案：A。

SMC 是第 j 个变量被其余变量线性解释的复相关系数平方。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 2.11 因子评分方法的识别[返回题目](#)

答案：A。

该式对独特误差方差加权，最小化给定共同因子模型中的加权残差平方和。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 2.12 KMO 的含义[返回题目](#)

答案：A。

KMO 比较简单相关平方与偏相关平方的相对大小；它是适合度诊断之一，不替代模型与测量论证。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 2.13 因子负荷的行、列平方和[返回题目](#)

因子负荷是共同因子模型中原始变量对共同因子的系数。标准化变量、单位方差且正交的因子下，负荷等于变量与因子的相关系数；第 j 行平方和为变量共同度 h_j^2 ，第 k 列平方和为该因子对全部标准化变量的解释方差，除以变量数得到贡献率。斜交旋转时，模式矩阵 P 一般不等于相关系数矩阵；结构矩阵为 $P\Phi$ ，共同度应取 $\text{diag}(P\Phi P^T)$ 。

解析 题 2.14 戒毒者量表：初始解与旋转解[返回题目](#)

令 $Z_j = (X_j - \bar{X}_j)/s_j$ 。共同度是所保留因子对某个标准化变量方差的解释比例。 X_2 为 0.902、 X_3 为 0.803。

初始第四因子贡献率为 14.577%；旋转后第三因子为 17.633%。各题要求的旋转阶段不能混用。总累计贡献率为 83.832%，正交旋转不改变这个总量。

焦虑的旋转模型为

$$Z_2 = .943F_1 - .098F_2 + .028F_3 + .034F_4 + \varepsilon_2,$$

其中独特部分方差约 $1 - .902 = .098$ ；共同因子标准化且正交时， $\text{Corr}(Z_2, F_1) = .943$ 。若用初始解，则相应系数为 $(.886, -.213, .135, .228)$ ，与第一初始因子相关为 .886。

第三得分表达式：

$$\begin{aligned} \hat{F}_3 = & .115Z_1 + .056Z_2 + .189Z_3 - .102Z_4 \\ & - .407Z_5 + .082Z_6 + .778Z_7. \end{aligned}$$

以本题主成分提取并标准化成分得分的正交旋转约定，其样本均值约 0、标准差约 1，与第一得分相关约 0；舍入后的系数会引起小偏差。一般共同因子模型的估计得分未必恰有单位方差或零相关，不能不加条件推广。

原题校正。第 1 问按变量编号 X_3 作答为 0.803，但其正确名称为情绪管理；若按名称“焦虑”即 X_2 作答应为 0.902。第 2 问未注明旋转后，原参考解按初始第四因子 14.577% 作答；旋转后第四因子实际为 16.263%。

解析 题 2.15 戒毒者量表：旋转后模型[返回题目](#)

令 $Z_j = (X_j - \bar{X}_j)/s_j$ 。共同度是所保留因子对某个标准化变量方差的解释比例。 X_2 为 0.902、 X_3 为 0.803。

初始第四因子贡献率为 14.577%；旋转后第三因子为 17.633%。各题要求的旋转阶段不能混用。总累计贡献率为 83.832%，正交旋转不改变这个总量。

焦虑的旋转模型为

$$Z_2 = .943F_1 - .098F_2 + .028F_3 + .034F_4 + \varepsilon_2,$$

其中独特部分方差约 $1 - .902 = .098$ ；共同因子标准化且正交时， $\text{Corr}(Z_2, F_1) = .943$ 。若用初始解，则相应系数为 $(.886, -.213, .135, .228)$ ，与第一初始因子相关为 .886。

第三得分表达式:

$$\hat{F}_3 = .115Z_1 + .056Z_2 + .189Z_3 - .102Z_4 \\ - .407Z_5 + .082Z_6 + .778Z_7.$$

以本题主成分提取并标准化成分得分的正交旋转约定, 其样本均值约 0、标准差约 1, 与第一得分相关约 0; 舍入后的系数会引起小偏差。一般共同因子模型的估计得分未必恰有单位方差或零相关, 不能不加条件推广。

解析 题 2.16 三科成绩因子模型与得分

[返回题目](#)

保留 2 个因子。语文、数学共同度分别 0.978、1.000。初始贡献为 74.109%、24.462%; 旋转后为 63.736%、34.835%, 累计均约 98.570%。

用标准化成绩 Z_1, Z_2, Z_3 表示旋转模型:

$$Z_1 = .959F_1 + .240F_2 + \varepsilon_1,$$

$$Z_2 = .208F_1 + .978F_2 + \varepsilon_2,$$

$$Z_3 = .974F_1 + .176F_2 + \varepsilon_3.$$

得分式为

$$\hat{F}_1 = .525Z_1 - .229Z_2 + .558Z_3,$$

$$\hat{F}_2 = -.075Z_1 + 1.069Z_2 - .155Z_3.$$

标准化必须使用题中各科均值和标准差。载荷矩阵用于“变量由因子表示”, 得分系数矩阵用于“因子得分由变量估计”, 不能交换, 也不应再把旋转载荷任意除以其列平方和的平方根。

解析 题 2.17 成绩分析: 旋转载荷与因子命名

[返回题目](#)

以“语文—英语”载荷为正统一因子方向, R 复算旋转载荷如下:

变量	因子 1	因子 2
语文	0.9990	0.0232
数学	0.0890	0.9960
英语	0.9804	0.1931

令各科标准分为 Z , 按每一行写 $Z_j = l_{j1}F_1 + l_{j2}F_2 + \varepsilon_j$ 。第一因子主要负荷在语文和英语, 命名为“语文英语表现”; 第二因子主要负荷在数学, 命名为“数学表现”。因子顺序和符号可随软件约定整体改变, 需连同载荷与得分一起调整。

解析 题 2.18 医院满意度：主成分提取与 Bartlett 得分[返回题目](#)

采用 varimax 正交旋转，以负荷总体正向为符号约定：

$$Z_1 = .0760F_1 + .8136F_2 + .0045F_3 + .2304F_4 + \varepsilon_1.$$

四因子可依次概括为“管理与职工利益”“硬件与工作条件”“发展及适应”“收入住房福利”；具体命名应参照完整载荷矩阵（随包附出）。前三个/第四个初始特征值为 7.0401、2.3927、1.3251、1.0165，累计解释约 69.261%。

固定载荷 L 和独特方差 Ψ ，Bartlett 估计为

$$\hat{f}_B = (L^T \Psi^{-1} L)^{-1} L^T \Psi^{-1} z.$$

按附数据复算，case100 第二因子得分约 **0.1331**。

若为简单随机样本且暂将评分规则视为固定，第二得分样本均值约 0，标准差 1.0032，SE 约 0.06718；均值的条件性 95% 区间约 $[-0.1324, 0.1324]$ 。该零点是样本标准化所设定的相对基准，不能据此说总体“满意度为 0”。要估计有实际量尺的总体满意度，应明确抽样权重、评分标定和测量含义；复杂抽样须按设计估计标准误，并考虑评分规则估计的不确定性。

解析 题 2.19 医院满意度：非迭代 SMC 与正交旋转[返回题目](#)

KMO 约 **0.8988**；整体适合，但仍应结合设计、测量和相关结构。各变量 MSA 与载荷、共同度合并列在下表。

SMC 以 $h_j^{2(0)} = 1 - 1/(R^{-1})_{jj}$ 替换相关阵对角线，进行一次特征分解，保留 4 个正特征根，不再更新共同度。4 个特征值为 6.630418、1.957903、0.810163、0.557710，和为 **9.956194**，相对 17 个标准化变量总方差的累计比例约 **58.566%**。

varimax 旋转载荷及共同度见下表。

变量	因子 1	因子 2	因子 3	因子 4	共同度	MSA
X_1	0.0867	0.7507	0.0240	0.2064	0.6143	0.8638
X_2	0.1417	0.7552	0.0080	0.1776	0.6221	0.8705
X_3	0.2941	0.4654	0.3543	0.0825	0.4354	0.9099
X_4	0.1173	0.7789	0.0150	0.2052	0.6628	0.8513
X_5	0.3246	0.2126	0.0560	0.5385	0.4436	0.9116
X_6	0.4781	0.2034	0.4752	0.1282	0.5122	0.9226
X_7	0.2461	0.4211	0.0883	0.6176	0.6272	0.8998
X_8	0.1185	0.4205	0.1224	0.6168	0.5863	0.8841
X_9	0.7285	0.1748	0.1976	0.1386	0.6194	0.9046
X_{10}	0.7189	0.0795	0.2500	0.2656	0.6561	0.9414
X_{11}	0.7894	0.1962	0.1275	0.3012	0.7686	0.9313
X_{12}	0.7651	0.1748	0.2797	0.1178	0.7080	0.9157
X_{13}	0.7970	0.1175	0.1544	0.2382	0.7297	0.9149
X_{14}	0.3537	-0.0878	0.5902	0.0541	0.4841	0.8496
X_{15}	0.4053	0.1370	0.5272	0.1418	0.4811	0.8895
X_{16}	0.0562	0.0259	0.6554	0.0649	0.4376	0.7173
X_{17}	0.4628	0.1031	0.1813	0.5568	0.5677	0.9156

因子可概括为管理/职工利益、硬件条件、发展与适应、待遇/住房福利。以样本相关阵作回归评分，得分系数为 $R^{-1}L$ ，得分矩阵为 $ZR^{-1}L$ ；前 5 人如下。

样本	因子 1	因子 2	因子 3	因子 4
1	-0.7550	-1.4696	-0.1482	-0.6744
2	-1.0415	-0.7428	-0.4462	-0.8914
3	0.0582	1.1280	0.0714	0.9176
4	-1.3451	0.6748	0.7096	-0.5116
5	0.0756	1.3890	0.8281	-0.8834

原解校正。原稿所列 $(L^T\Psi^{-1}L)^{-1}L^T\Psi^{-1}z$ 是 Bartlett 公式，不是 Thomson 回归公式。若使用拟合模型相关阵 $LL^T + \Psi$ 替代样本 R ，结果可能略有差异，必须标明。**factanal** 默认极大似然提取，不能代替题定的 SMC 不迭代提取。

解析 题 2.20 医院满意度：Promax 斜交旋转

[返回题目](#)

以随包代码的因子次序与符号约定，命名同正交模型大致为管理/职工利益、硬件条件、发展与适应、待遇/住房福利。斜交因子之间有相关，负荷的解释应区分模式矩阵 P 与结构矩阵 $P\Phi$ 。

各空依次为：**9.956194**；**0.614270**；**0.776717**；**0.592298**；**-1.447396**；**-1.149144**。前者除以 17 约 58.566%。完整模式矩阵、结构矩阵、因子相关矩阵及全部得分随包提供。

共同度采用 $h^2 = \text{diag}(P\Phi P^T)$ ；Bartlett 评分使用独特方差矩阵和模式矩阵；回归评分使用 $ZR^{-1}P\Phi$ 。

原解差异。原参考稿的 3.891 是模式负荷矩阵某一列的平方和，不是四因子累计特征值；0.5936 来自错误地对斜交模式矩阵直接作平方和。其 -1.4846、-1.1226 使用了另一次极大似然提取后的得分，未忠实于 SMC 不迭代模型，故与这里的复算值不同。

解析 题 2.21 文献中的两因子模型

[返回题目](#)

原汇编在第 1 空写 **mn-sod**，但载荷表和文献未附，无法复核。正交因子下应计算各变量两载荷平方和，取最小者；斜交因子使用 $P\Phi P^T$ 的对角元。

两因子选择可能根据特征根、碎石图、累计解释率、模型拟合和专业可解释性。应对照原文证据，不能把某个固定阈值当作者实际使用过的标准。

解析 题 2.22 文献复现与方法评价

[返回题目](#)

作答应包含研究问题与设计、测量和变量处理、所用多元方法、模型提取/选择步骤、结果复现，以及局限和改进。因子分析需核对提取与旋转方法、模式/结构矩阵、得分算法；预测模型需防止信息泄漏并进行验证。原文和数据缺失，本题不能完成数值复现；这不是补写题目选项能够解决的缺口。

解析 题 2.23 文献述评

[返回题目](#)

先明确研究目的、设计、人群和测量，再评估方法是否回答研究问题、假设与样本量是否合适、是否报告不确定性、变量筛选和验证是否规范。对结果解释区分关联、降维结构与预测能力。缺文献时只能给述评框架，不能编写文献实际结果。

补充练习解析

解析 题 2.24 最大似然因子模型的自由度

[返回题目](#)

答案：C。

两因子模型 $df = [(6 - 2)^2 - 6 - 2]/2 = 4$ ；三因子模型 $df = [(6 - 3)^2 - 6 - 3]/2 = 0$ 。增加公因子会减少剩余约束。正文的拟合优度检验要求模型自由度大于 0；零自由度不能作为“模型正确”的证据。

解析 题 2.25 三种因子提取方法的区别

[返回题目](#)

主成分法：对原相关矩阵（对角线为 1）作特征分解，用所保留特征向量乘相应特征值的平方根组成载荷矩阵。

主因子法：先估计各变量共同度，以共同度替换相关矩阵的对角线，得到约相关矩阵，再作特征分解。迭代主因子法会用新载荷重新估计共同度并继续更新；非迭代法只完成指定的一次提取。

最大似然法：按共同因子模型 $\Sigma = LL^T + \Psi$ 建立似然，估计载荷和特殊方差。正文采用多元正态模型；常规卡方拟合优度检验还要求独立观测、模型自由度大于 0 且估计满足通常的正则条件。若出现 Heywood 现象等异常估计，应先检查模型，不能机械解释检验结果。

因此，相关矩阵对角线均为 1 不能作为“主因子法已扣除特殊方差”的证据；软件默认的提取方法也必须与题意核对。

解析 题 2.26 体格指标的共同度与还原相关[返回题目](#)

(1) 模型与方差分解。令 Z_1 为标准化收缩压, 则

$$Z_1 = 0.8F_1 + 0.2F_2 + u_1.$$

共同度按行平方和计算, 特殊方差为 $1 - h_j^2$ 。

变量	共同度	特殊方差
收缩压	0.68	0.32
舒张压	0.5	0.5
体重	0.65	0.35
腰围	0.58	0.42

(2) 贡献率与命名。两列平方和分别为 1.23、1.18, 除以 4 得到 30.75%、29.50%; 累计贡献率为 60.25%。第一因子主要反映血压, 第二因子主要反映体格或体型。旋转后的列平方和是解释方差, 不应一概称为原相关矩阵的特征值。

(3) 还原相关。由 $R_{\text{model}} = LL^T + \Psi$, 非对角元的特殊因子协方差为 0, 故

$$\hat{r}_{12} = 0.8 \times 0.7 + 0.2 \times 0.1 = 0.58.$$

残差相关为 $0.62 - 0.58 = 0.04$ 。共同度描述一个变量的方差被解释多少; 还原相关描述两个变量的联系, 两者不能混用。一个残差较小也不足以单独判定整个模型拟合良好。

(4) 得分系数。不能直接这样做。载荷用于写“变量由因子表示”的模型; Thomson 法需计算得分系数。按正文的正交模型写法, $\hat{f} = L^T(LL^T + \Psi)^{-1}z$, 通常不等于 L^Tz 。

解析 题 2.27 两因子模型的研究结果评议[返回题目](#)

(1) 拟合检验。对给定因子数, H_0 是总体协方差矩阵可用该因子模型表示, 即 $\Sigma = LL^T + \Psi$ 。单因子模型被拒绝; 两因子模型未被拒绝。在这两个候选模型中, 两因子模型有更充分的拟合支持, 仍应检查载荷、共同度及专业解释。

(2) 旋转作用。旋转前贡献率为 45.00%、20.00%; 旋转后为 34.17%、30.83%。两者累计均为 $3.90/6 = 65.00\%$ 。正交旋转重新分配了单个因子的解释方差, 保持共同度及总解释方差不变。第二因子贡献增加不能推出总解释率增加。

(3) 结论修订。可写为: “在当前样本与模型条件下, 尚无充分证据否定两因子模型。” $P = 0.463$ 不是模型为真的概率, 也不能证明总体恰有两个因子。命名须结合旋转载荷矩阵与各指标的含义, 不能只依据因子序号或贡献率大小。

第 3 章

聚类分析

前两章以变量为分析对象，本章起以观察对象（样品）为分析对象。聚类分析的目的是按相似程度将观察对象归为若干类。它与第 4 章判别分析的区别在于事先是否已知类别：聚类分析没有已知的类别可供对照，类别由数据得出，属于探索性分析；判别分析中训练样品的类别已知，目的是建立判别新样品的规则。

聚类分析的每一步都涉及选择：纳入哪些变量、是否标准化、采用何种距离、类间距离如何定义、分为几类。每一项选择都会影响结果，且没有统计检验能够判定哪种选择正确。因此，学习本章应掌握各项选择的依据，以及改变选择对结果可能产生的影响。

此外，聚类算法对任何数据都会给出分类结果，即使数据中并不存在群组结构。聚类结果需 要结合专业知识解释，并宜通过稳定性分析或新资料加以验证。

3.1 聚类分析

聚类分析（cluster analysis）是一种探索性分析，将相似的观测或指标归类。分为 Q 型（样品）聚类和 R 型（指标）聚类两类。关键在于如何将相似性数量化，即相似系数。

测量尺度	英文	变量类型
间隔尺度	Scale	数值变量
有序尺度	Ordinal	有序变量
名义尺度	Nominal	无序分类变量

批注 默认采用间隔尺度。

3.2 样品间相似性的度量

每个样品可看成 p 维空间中的一个点，用距离度量样品间的相似程度。常用距离有欧氏距离、马氏距离、配合距离等。

3.2.1 明氏距离

$$d_{ij}(q) = \left[\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right]^{1/q}, \quad \text{明氏距离,} \quad (3.1)$$

$$d_{ij}(2) = \left[\sum_{k=1}^p (x_{ik} - x_{jk})^2 \right]^{1/2}, \quad \text{欧氏距离,} \quad (3.2)$$

$$d_{ij}(1) = \sum_{k=1}^p |x_{ik} - x_{jk}|, \quad \text{绝对值距离,} \quad (3.3)$$

$$d_{ij}(\infty) = \max_k |x_{ik} - x_{jk}|, \quad \text{切比雪夫距离.} \quad (3.4)$$

其中 $q \geq 1$ 。 $q < 1$ 时三角不等式不再成立，上式不是距离。

体重、胸围和往返跑数据

表 3.1 体重、胸围与往返跑数据

编号	tz	xw	wfp
1	72.0	87.0	14.5
2	63.4	81.0	11.4
3	54.1	82.5	12.2
4	79.9	95.0	10.9
5	74.8	88.9	13.9

```

1 da <- data.frame(tz = c(72.0, 63.4, 54.1, 79.9, 74.8),
2                   xw = c(87.0, 81.0, 82.5, 95.0, 88.9),
3                   wfp = c(14.5, 11.4, 12.2, 10.9, 13.9))
4 x <- cbind(scale(da$tz), scale(da$xw), scale(da$wfp))
5 x

```

表 3.2 标化后的数据

编号	tz	xw	wfp
1	0.3103518	0.0215711	1.2273947
2	-0.5342765	-1.0569831	-0.7543363
3	-1.4476536	-0.7873446	-0.2429219
4	1.0862313	1.4596433	-1.0739704
5	0.5853470	0.3631132	0.8438339

```

1 d <- dist(x, "euclidean"); d
2 d <- dist(x, "manhattan"); d

```

```
3 d <- dist(x, "minkowski", p = 1); d
4 d <- dist(x, "maximum"); d
```

表 3.3 欧氏距离

	1	2	3	4	5
1	0.0000000				
2	2.4091355	0.0000000			
3	2.4303823	1.0809752	0.0000000		
4	2.8224673	3.0102525	3.4871433	0.0000000	
5	0.5825739	2.4133749	2.5763701	2.2652232	0.0000000

表 3.4 绝对值距离（同 $q = 1$ 的明氏距离）

	1	2	3	4	5
1	0.0000000				
2	3.9049135	0.0000000			
3	4.0372376	1.6944301	0.0000000		
4	4.5153168	4.4567682	5.6119212	0.0000000	
5	1.0000983	4.1378901	4.2702142	3.5152185	0.0000000

表 3.5 切比雪夫距离

	1	2	3	4	5
1	0.0000000				
2	1.9817310	0.0000000			
3	1.7580054	0.9133771	0.0000000		
4	2.3013651	2.5166265	2.5338848	0.0000000	
5	0.3835608	1.5981702	2.0330006	1.9178042	0.0000000

明氏距离的缺点

- 1) 未能去除量纲的影响。虽然可通过 Z 变换去除量纲影响，但 Z 变换相当于对空间按各维度的标准差进行压缩，改变原始变量的空间关系。
- 2) 未考虑变量间相关性。相关程度高的变量较多，会使计算距离夸大样本间的疏离程度。

批注 有的资料称“dist() 对数据中心化处理”，不确切。dist() 直接按输入数据计算距离，既不中心化也不标准化。中心化是各变量减去同一常数，样品间的差值 $x_{ik} - x_{jk}$ 不变，距离也不变；标准化则改变距离，需要事先用 scale() 完成，如本例。

标准化后的欧氏距离为

$$d_{ij}^* = \left[\sum_{k=1}^p \frac{(x_{ik} - x_{jk})^2}{s_k^2} \right]^{1/2},$$

相当于给第 k 个变量加权 $1/s_k^2$ ：方差大的变量被压低，方差小的变量被放大，使每个变量对平方距离的平均贡献相同（对所有样品对平均，每个变量的 $(x_{ik} - x_{jk})^2/s_k^2$ 都等于 2）。这种等权是否合理，要看各变量在专业上是否同等重要。

3.2.2 马氏距离

明氏距离特别是欧氏距离的缺点是未考虑指标间相关性。Mahalanobis 提出马氏距离。当指标间协方差阵为单位阵时，马氏距离即欧氏距离。

$$d_{ij}^2(M) = (X_i - X_j)^T \Sigma^{-1} (X_i - X_j). \quad (3.5)$$

马氏距离去除量纲影响的同时，也去除变量间相关性的影响。各坐标差的权重由协方差阵的逆矩阵 Σ^{-1} 确定的二次型给出，交叉项也参与加权，不是简单地以某个相关系数的倒数加权。但马氏距离也改变了样本间的空间关系。

要求 Σ 正定， Σ^{-1} 和对称平方根 $\Sigma^{-1/2}$ 才存在。

证明（马氏距离即白化后的欧氏距离） 令 $Z = \Sigma^{-1/2}(X - \mu)$ ，则 $\text{cov}(Z) = \Sigma^{-1/2} \Sigma \Sigma^{-1/2} = I$ ，各分量方差为 1 且互不相关。对两个样品， $Z_i - Z_j = \Sigma^{-1/2}(X_i - X_j)$ ，故

$$\|Z_i - Z_j\|^2 = (X_i - X_j)^T \Sigma^{-1/2} \Sigma^{-1/2} (X_i - X_j) = (X_i - X_j)^T \Sigma^{-1} (X_i - X_j) = d_{ij}^2(M).$$

□

实际计算用样本协方差阵 S 代替 Σ 。变量完全共线，或样本量不足 ($n-1 < p$) 时， S 不可逆，马氏距离无法计算；样本量小时即使可逆， S^{-1} 也很不稳定。本例 $n=5$ 、 $p=3$ ，仅供演示。

```

1  # mahalanobis distances
2  n <- nrow(da); S <- cov(da)
3  d <- matrix(NA, n, n)
4  for (i in 1:n) {
5    for (j in 1:n) {
6      a <- as.matrix(da[i, ] - da[j, ])
7      d[i, j] <- a %*% solve(S) %*% t(a)
8    }
9  }
10 d

```

表 3.6 平方马氏距离

	1	2	3	4	5
1	0.0000000	6.3819087	6.0675602	7.0421877	0.2554311
2	6.3819087	0.0000000	7.9860571	7.9139379	5.7172888
3	6.0675602	7.9860571	0.0000000	7.8307143	6.0601518
4	7.0421877	7.9139379	7.8307143	0.0000000	4.7447623
5	0.2554311	5.7172888	6.0601518	4.7447623	0.0000000

3.2.3 配合距离

对于分类变量，尤其是无序分类变量，使用配合距离度量样品间相似度。设两样品都有 5 个指标值：

$$S_1 = (V, Q, S, T, K), \quad S_2 = (V, M, S, F, K).$$

二者的配合相似度为

$$s_{ij} = \frac{m_{ij}}{p} = \frac{3}{5} = 0.6, \quad \text{配合距离 } d_{ij} = 1 - s_{ij} = \frac{2}{5} = 0.4,$$

其中 m_{ij} 为两样品取值相同的指标数， p 为指标数；配合距离即取值不同的指标所占比例。

3.2.4 二分类变量的样本间距离

	Case $j = 1$	Case $j = 0$
Case $i = 1$	(1, 1): A	(1, 0): C
Case $i = 0$	(0, 1): B	(0, 0): D

简单配合 (simple matching) 相似度：

$$s_{ij} = \frac{1}{p} \sum_{k=1}^p [L(A) + L(D)]. \quad (3.6)$$

$L(\cdot)$ 为逻辑变量，取值 0 或 1。

Jaccard 配合相似度 (R 中的 `binary`) :

$$s_{ij} = \frac{\sum L(A)}{\sum L(A) + \sum L(B) + \sum L(C)} = \frac{\sum L(A)}{p - \sum L(D)}. \quad (3.7)$$

若两样品所有指标都为 0 ($p = \sum L(D)$)，Jaccard 系数为 0/0，没有定义；R 的 `dist(..., "binary")` 此时把距离记为 0 (见下表样本 9 与 10)。样本间距离为 $d_{ij} = 1 - s_{ij}$ 。

Jaccard 距离

用于不对称的二值变量：1 表示具有某种特征 (阳性、出现某症状)，0 表示不具有。两个样品都为 0，并不能说明它们相似，例如两人都没有某种罕见症状。Jaccard 系数把 (0,0) 配对排除在外。

表 3.7 十个样本的二值指标

指标	1	2	3	4	5	6	7	8	9	10
x_1	0	1	0	0	0	1	1	0	0	0
x_2	0	1	0	1	0	0	1	1	0	0
x_3	1	0	1	0	1	1	1	0	0	0
x_4	1	1	1	0	0	0	0	0	0	0

```

1 db <- cbind(x1 = c(0,1,0,0,0,1,1,0,0,0), x2 = c(0,1,0,1,0,0,1,1,0,0),
2           x3 = c(1,0,1,0,1,1,1,0,0,0), x4 = c(1,1,1,0,0,0,0,0,0,0))
3 t(db)                                     # 行为样本，列为指标
4 d <- dist(db, "binary")
5 round(d, 3)

```

表 3.8 Jaccard 距离

	1	2	3	4	5	6	7	8	9	10
1	0.000									
2	0.750	0.000								
3	0.000	0.750	0.000							
4	1.000	0.667	1.000	0.000						
5	0.500	1.000	0.500	1.000	0.000					
6	0.667	0.750	0.667	1.000	0.500	0.000				
7	0.750	0.500	0.750	0.667	0.667	0.333	0.000			
8	1.000	0.667	1.000	0.000	1.000	1.000	0.667	0.000		
9	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	0.000	
10	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	0.000	0.000

简单配合距离

用于对称的二值变量：0 和 1 两种取值地位相当，如性别、城乡，此时 (0,0) 与 (1,1) 同样是相似的证据。选择简单配合还是 Jaccard，依据是共同取 0 能否作为相似的证据，而不是 0、1 的比例是否均衡。

```

1 n <- nrow(db); p <- ncol(db)
2 d <- matrix(NA, n, n)
3 for (i in 1:n) {
4   for (j in 1:n) {
5     L <- as.numeric(db[i, ] == db[j, ])
6     d[i, j] <- 1 - sum(L) / p
7   }
8 }
9 d.dist <- as.dist(d); d.dist

```

表 3.9 简单配合距离

	1	2	3	4	5	6	7	8	9	10
1	0.00									
2	0.75	0.00								
3	0.00	0.75	0.00							
4	0.75	0.50	0.75	0.00						
5	0.25	1.00	0.25	0.50	0.00					
6	0.50	0.75	0.50	0.75	0.25	0.00				
7	0.75	0.50	0.75	0.50	0.50	0.25	0.00			
8	0.75	0.50	0.75	0.00	0.50	0.75	0.50	0.00		
9	0.50	0.75	0.50	0.25	0.25	0.50	0.75	0.25	0.00	
10	0.50	0.75	0.50	0.25	0.25	0.50	0.75	0.25	0.00	0.00

3.2.5 无序多分类变量的样本间距离

简单配合相似度为

$$s_{ij} = \frac{1}{p} \sum_{k=1}^p \kappa(x_{ik}, x_{jk}), \quad \kappa(x_{ik}, x_{jk}) = \begin{cases} 1, & x_{ik} = x_{jk}, \\ 0, & x_{ik} \neq x_{jk}. \end{cases}$$

样本间距离 $d_{ij} = 1 - s_{ij}$ 。

3.2.6 有序变量的样本间距离

先对有序变量作 $[0, 1]$ 区间变换。设有序变量 x 取值为 $1, 2, \dots, M$ ，标准化变换为

$$y = \frac{x - 1}{M - 1}.$$

变换后按数值变量计算距离。这种等距映射隐含一个计分约定：相邻等级之间的差异都相等（如“轻一中”与“中一重”的差距相同）。若专业上不能接受，应另行指定各等级的得分。

3.3 指标间相似性的度量

常用夹角余弦、相关系数等。指标 s 与 t 的夹角余弦和 Pearson 相关系数分别为

$$\cos \theta_{st} = \frac{\sum_{i=1}^n x_{is} x_{it}}{\sqrt{\sum_{i=1}^n x_{is}^2 \sum_{i=1}^n x_{it}^2}}, \tag{3.8}$$

$$r_{st} = \frac{\sum_{i=1}^n (x_{is} - \bar{x}_s)(x_{it} - \bar{x}_t)}{\sqrt{\sum_{i=1}^n (x_{is} - \bar{x}_s)^2 \sum_{i=1}^n (x_{it} - \bar{x}_t)^2}}. \tag{3.9}$$

批注 夹角余弦使用原始指标，Pearson 相关使用中心化后的指标。思考二者的关系。

证明（中心化向量的夹角余弦等于 Pearson 相关系数） 把 x_{is} 换成 $x_{is} - \bar{x}_s$ 、 x_{it} 换成 $x_{it} - \bar{x}_t$ 代入夹角余弦公式，所得正是 r_{st} 。□

原始指标都取正值且均数远大于变异时，夹角余弦主要反映均数，几乎都接近 1（如下例三个指标两两在 0.987 以上），不能反映变量间的共变；中心化后的相关系数才能。

变量间距离： $c_{st} = r$ ， $d_{st} = \sqrt{1 - c_{st}^2}$ 。三种常用的相关型距离对负相关的处理不同：

距离	$r = 0.9$	$r = 0$	$r = -0.9$
$\sqrt{1 - r^2}$	0.436	1	0.436
$1 - r $	0.1	1	0.1
$1 - r$	0.1	1	1.9

前两种把强负相关与强正相关同样看作“相近”，适合以信息冗余为目的的变量聚类，例如“往返跑时间”越短越好，与其他体能指标负相关，但反映的是同一种能力。 $1 - r$ 则把强负相关看作最远，适合方向本身有意义的情形。下例用 $\sqrt{1 - r^2}$ ；服装标准例用 $1 - |r|$ （其相关系数全为正，与 $1 - r$ 结果相同）；体质数据练习用 $1 - r$ ：往返跑、反应时等计时指标与纵跳、肺活量、俯卧撑负相关（如往返跑与纵跳 $r = -0.36$ ），用 $1 - r$ 时距离都大于 1，会被分开。若关心的是信息冗余，应改用 $1 - |r|$ 。

```
1 a <- as.matrix(da); p <- ncol(a); s <- matrix(NA, p, p)
2 for (i in 1:p) {
3   for (j in 1:p) {
4     s[i, j] <- a[, i] %*% a[, j] /
5       sqrt((a[, i] %*% a[, i]) * (a[, j] %*% a[, j]))
6   }
7 }
8 colnames(s) <- colnames(da); rownames(s) <- colnames(da)
9 s
10 d <- sqrt(1 - s^2)
11 d.dist <- as.dist(d); d.dist
12 # 变量的距离, Pearson r
13 d <- sqrt(1 - cor(da)^2)
14 d.dist <- as.dist(d); d.dist
```

表 3.10 夹角余弦相似系数

	tz	xw	wfp
tz	1.0000000	0.9963195	0.9869652
xw	0.9963195	1.0000000	0.9918570
wfp	0.9869652	0.9918570	1.0000000

表 3.11 夹角余弦对应的距离

	tz	xw	wfp
tz	0.00000000		
xw	0.08571709	0.00000000	
wfp	0.16093352	0.12735628	0.00000000

表 3.12 Pearson 相关对应的距离

	tz	xw	wfp
tz	0.0000000		
xw	0.4799079	0.0000000	
wfp	0.9932792	0.9981048	0.0000000

对等级资料可用 Spearman 相关系数，对分类资料可用列联系数

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}$$

表示相似程度。

3.4 层次聚类法

层次聚类即系统聚类，是最常用的样品或变量聚类方法。

- 1) 构造 n 个类，每类仅包含一个样品或指标。
- 2) 计算 n 个类两两间的距离，构成距离矩阵。
- 3) 合并距离最近的两类为一新类，此时剩 $n - 1$ 类。
- 4) 计算新类与当前各类的距离，重复上一步，直至只剩一类。

3.4.1 类间距离的计算方法

每类含一个样品时，类间距离即样品间距离。否则采用最短距离法、最长距离法、类平均法、重心法、Ward 法等。




图 3.1 类间距离的四种计算方法

类平均法对输入的相异度取所有跨类样品对的平均：

$$D_{12} = \frac{1}{n_1 n_2} \sum_{i \in G_1} \sum_{j \in G_2} d_{ij}.$$

若输入的是平方欧氏距离, 则得到常见的平方距离平均式 (本图 $n_1 = 3$ 、 $n_2 = 2$):

$$D_{12}^2 = \frac{1}{6}(d_{14}^2 + d_{15}^2 + d_{24}^2 + d_{25}^2 + d_{34}^2 + d_{35}^2).$$

两种输入的合并顺序一般不同, 应在报告中写明。

类平均法 (average)

平均距离最小的类被合并。利用所有跨类样品对的信息, 性质介于最短与最长距离法之间。

重心法 (centroid)

两类间距离为两类均值向量 (重心) 之间的距离。新类重心按样品数加权, 大类与小类合并后重心几乎不动; 合并高度可能不单调, 聚类树出现“倒置”。用递推公式计算时, 输入应为平方欧氏距离。

最短距离法 (single)

两类间距离取跨类样品对距离的最小值。只要有一对样品相近, 两类就合并, 容易产生链式效应, 把细长或首尾相连的点串成一类; 能识别非椭圆形的类, 但对两类之间的“桥接”点敏感。

最长距离法 (complete)

两类间距离取跨类样品对距离的最大值。合并高度就是新类的类内最大差异 (直径), 倾向于得到紧凑、直径相近的类, 对离群值敏感。(在 Lance-Williams 的术语中, 最短距离法是“空间压缩”的, 最长距离法是“空间扩张”的。)

Ward 法

每一步合并使类内离差平方和 W 增加最少的两类。合并 G_a 、 G_b 的增量为

$$\Delta W = \frac{n_a n_b}{n_a + n_b} \|\bar{X}_a - \bar{X}_b\|^2.$$

系数 $n_a n_b / (n_a + n_b)$ 在一类样品很少时较小, 因此小类倾向于先被合并, 各类样品数较均衡, 形状接近球形。分类效率高, 对极端值敏感。R 中 `hclust(dist(x), method = "ward.D2")` 以未平方的欧氏距离为输入实现该准则; "ward.D" 则须输入平方欧氏距离 `dist(x)^2` 才与之对应。

证明 (Ward 合并增量) 记 $n = n_a + n_b$, 合并后重心 $\bar{X} = (n_a \bar{X}_a + n_b \bar{X}_b) / n$ 。由平方和分解,

$$W_{a \cup b} = \sum_{i \in G_a \cup G_b} \|X_i - \bar{X}\|^2 = W_a + W_b + n_a \|\bar{X}_a - \bar{X}\|^2 + n_b \|\bar{X}_b - \bar{X}\|^2,$$

其中交叉项 $\sum_{i \in G_a} (X_i - \bar{X}_a) = 0$ 而消失。又 $\bar{X}_a - \bar{X} = \frac{n_b}{n} (\bar{X}_a - \bar{X}_b)$ 、 $\bar{X}_b - \bar{X} = \frac{n_a}{n} (\bar{X}_b - \bar{X}_a)$, 故

$$\Delta W = W_{a \cup b} - W_a - W_b = \frac{n_a n_b^2 + n_b n_a^2}{n^2} \|\bar{X}_a - \bar{X}_b\|^2 = \frac{n_a n_b}{n_a + n_b} \|\bar{X}_a - \bar{X}_b\|^2.$$

□

类间距离定义对聚类结果的影响

对前文体重、胸围、往返跑的 5 人资料 (标准化后的欧氏距离), 分别用四种方法作系统聚类:

```
1 x <- scale(da); d <- dist(x)
2 for(m in c("single", "complete", "average", "ward.D2")){
3   h <- hclust(d, method=m)
```

```

4   cat(m,"： 合并高度",round(h$height,3)," | 分2类:",cutree(h,2),"\n")
5 }

```

```

single : 合并高度 0.583 1.081 2.265 2.409 | 分2类: 1 2 2 1 1
complete : 合并高度 0.583 1.081 2.576 3.487 | 分2类: 1 1 1 2 1
average : 合并高度 0.583 1.081 2.457 2.896 | 分2类: 1 1 1 2 1
ward.D2 : 合并高度 0.583 1.081 2.936 3.725 | 分2类: 1 2 2 1 1

```

四种方法的前两步完全相同：先合并距离最近的 1 号与 5 号 (0.583)，再合并 2 号与 3 号 (1.081)，因为每类仅含一个样品时，类间距离即样品间距离。自第三步起结果出现分歧：最短距离法与 Ward 法分为 {1,4,5} 与 {2,3} 两类，最长距离法与类平均法分为 {1,2,3,5} 与 {4} 两类。

仅 5 人、3 个变量的资料，分类结果即随方法而变，样本较大时更是如此。实际分析中可比较多种方法的结果：主要类别在不同方法下稳定出现时，结果较为可信；结果随方法变化较大时，表明数据中的类别结构不清晰。

3.4.2 类的个数

给定阈值 T ，在聚类树上“切一刀”，较主观。也可观察样品散点图，但仅适合 2 至 3 个变量的情况。更客观的辅助指标（轮廓系数、重抽样稳定性）见 3.5.7 节。

3.4.3 系统聚类实例

例 1 Q 型系统聚类：细菌分类

用气相色谱法分析细菌全细胞脂肪酸含量，研究细菌分类与鉴定。24 株菌株包括空肠弯曲菌 8 株 (CJ1 至 CJ8)、结肠弯曲菌 3 株 (CC1 至 CC3)、幽门螺旋菌 9 株 (HP1 至 HP9) 及其他肠道杆菌 4 株 (XX1 至 XX4)。测得 12 种脂肪酸百分含量 (X_1 至 X_{12})，要求以此对 24 株菌株进行聚类分析。数据：bacteria.sav。

例 9.2 R 型系统聚类：服装标准

制定我国服装标准时，测量 3454 名成年女子的 14 个部位。根据相关系数矩阵，对变量进行聚类分析。采用距离

$$d_{ij} = 1 - |r_{ij}|.$$

表 3.13 3454 名成年女子 14 项身体测量指标的相关矩阵

	上体长	手臂长	胸围	颈围	总肩宽	前胸宽	后背宽	前腰节高	后腰节高	总体高	身高	下体长	腰围	臀围
上体长	1.000													
手臂长	0.366	1.000												
胸围	0.242	0.233	1.000											
颈围	0.280	0.194	0.590	1.000										
总肩宽	0.360	0.324	0.476	0.435	1.000									
前胸宽	0.282	0.263	0.483	0.470	0.452	1.000								
后背宽	0.245	0.265	0.540	0.478	0.535	0.663	1.000							
前腰节高	0.448	0.345	0.452	0.404	0.431	0.322	0.266	1.000						
后腰节高	0.486	0.367	0.365	0.357	0.429	0.283	0.287	0.820	1.000					
总体高	0.648	0.662	0.216	0.316	0.429	0.283	0.263	0.527	0.547	1.000				
身高	0.679	0.681	0.243	0.313	0.430	0.302	0.294	0.520	0.558	0.957	1.000			
下体长	0.486	0.636	0.174	0.243	0.375	0.290	0.255	0.403	0.417	0.857	0.852	1.000		
腰围	0.133	0.153	0.732	0.477	0.339	0.392	0.446	0.266	0.241	0.054	0.099	0.055	1.000	
臀围	0.376	0.252	0.676	0.581	0.441	0.447	0.440	0.424	0.372	0.363	0.376	0.321	0.627	1.000

资料来源：张尧庭、方开泰（1982），《多元统计分析引论》，北京：科学出版社，116 页。

裁判评分的相似度

SPSS 自带数据集 `judge.sav` 记录中、美、法等七国裁判及未经严格训练的体育爱好者对选手的评分。根据评分差异，将其分为适当的若干类。

练习 体质数据

使用 `体质数据.sav`，对 `x1` 至 `x12` 作 R 型聚类。

```
1 # 数据：体质数据.sav。课程版本第1列即脉搏mb，da[,
  # -1]会把它去掉，应按所用版本核对列名
2 rm <- cor(da[, -1]); rm
3 d <- as.dist(1 - rm); d          # 若关心信息冗余，改用 1 - abs(rm)
4 cv <- hclust(d); cv
5 plot(cv, hang = -1)
```

表 3.14 体质数据的变量信息

变量	指标	变量	指标
mb	脉搏	tjzs	台阶指数
ssy	收缩压	wl	握力
szy	舒张压	bl	背力
fhl	肺活量	tqq	体前屈
sg	身高	zt	纵跳
tz	体重	djzl	单脚站立
xw	胸围	wfp	往返跑
yw	腰围	fys	反应时 1
tw	臀围	fwc	俯卧撑

3.4.4 变量聚类用于变量优选

变量聚类是数据降维的简便方法，直接去掉某些变量。代表性指标的选择考虑：专业意义、易测性与经济性、统计代表性。

$$R_i^2(J) = \frac{\sum_{\substack{k \in J \\ k \neq i}} r_{ik}^2}{M_J - 1}. \quad (3.10)$$

第 J 类有 M_J 个变量 ($M_J > 1$)， $R_i^2(J)$ 是第 i 个变量与同类其余 $M_J - 1$ 个变量相关系数平方的平均值。它越大，该变量越能代表本类，可在专业意义、易测性相近时选 $R_i^2(J)$ 最大者作为代表性指标。

3.4.5 计算问题

聚类分析的计算量与样本量的平方或立方成正比，系统聚类不太适合大样本。快速聚类法需事先指定类的个数。

3.5 大样本快速聚类

K 均值聚类 (K-means clustering) 的分类思想:

- 1) 事先指定分类数 k 与初始点。
- 2) 样本依距离 (欧氏距离平方) 关系归入 k 类。
- 3) 以类均值向量为中心重新计算。
- 4) 重复上一步迭代, 直到分类不变。

分类数 k 按专业需要或数据探索确定。

3.5.1 目标函数与迭代

记分组为 $C_1, \dots, C_k$, 第 l 类样品数为 n_l 、中心为 c_l 。K 均值要最小化类内平方和

$$W = \sum_{l=1}^k \sum_{i \in C_l} \|x_i - c_l\|^2.$$

证明 (固定分组时, 均值使 W 最小) 对任一类 C_l 和任一向量 c ,

$$\sum_{i \in C_l} \|x_i - c\|^2 = \sum_{i \in C_l} \|x_i - \bar{x}_l\|^2 + n_l \|\bar{x}_l - c\|^2,$$

交叉项因 $\sum_{i \in C_l} (x_i - \bar{x}_l) = 0$ 而消失。右端在 $c = \bar{x}_l$ 时最小。□

固定各类中心时, 把每个样品分到最近 (欧氏距离平方最小) 的中心, 使 W 的每一项都最小。K 均值交替进行“分配”和“更新中心”两步, 每一步都不增大 W 。不同的分组只有有限多种, 算法在有限步内停止, 但停在的是局部最优, 不一定是全局最优, 结果依赖初始点。

停止条件与优化目标是两回事。常用的停止条件是: 分组不再改变 (或中心的变化小于容许误差), 或达到最大迭代次数 (R 中由 `iter.max` 控制, 默认 10)。R 的 `kmeans()` 默认用 Hartigan-Wong 算法, 按样品逐个调整, 同样使 W 单调不减。

证明 ($T = W + B$) 记总均值为 $\bar{x}$, $T = \sum_i \|x_i - \bar{x}\|^2$, $B = \sum_l n_l \|\bar{x}_l - \bar{x}\|^2$ 。则

$$T = \sum_l \sum_{i \in C_l} \|(x_i - \bar{x}_l) + (\bar{x}_l - \bar{x})\|^2 = W + B + 2 \sum_l (\bar{x}_l - \bar{x})^\top \sum_{i \in C_l} (x_i - \bar{x}_l) = W + B.$$

□

3.5.2 初始点的指定

初始点 (initial cluster centres) 是迭代开始时各类别的重心。不同的初始点可能导致不同结果。可以由程序随机指定, 也可人工选择 k 个典型个案、按频数分布划分区间、采用核密度法等。

耳朵测量数据

某医院康复专科门诊为修复耳缺损，测量 300 例患者正常侧耳朵的五项指标：耳长（EC）、耳宽（EK）、耳外展距（EZ）、耳型（EX）及耳垂型（ECX）。另计算两个指数：

$$EI = \frac{\text{耳宽}}{\text{耳长}} \times 100\%, \quad AI = \frac{\text{耳外展距}}{\text{耳宽}} \times 100\%.$$

要求以 EC、EK、EZ、EI、AI 五个变量为依据进行聚类，找出各类具有代表性的耳朵，供临床修复耳缺损参考。数据：ear.sav（300 例）。

批注 原例正文写作“EC、EX、EZ、EI、AI”，但结果表各列为 EC、EK、EZ、EI、AI。按数据文件的变量标签（EC 耳长、EK 耳宽、EZ 耳外展距、EI 耳指数、AI 外展指数、EX 耳型、ECX 耳垂型），并用课程数据复算，下列全部结果都由 EC、EK、EZ、EI、AI 得到，正文的 EX 应为 EK。EX、ECX 是分类变量，不宜直接放入 K 均值。

EI、AI 由 EC、EK、EZ 算出，并非独立的测量。标准化后每个变量在欧氏距离中权重相同，耳宽 EK 同时出现在 EK、EI、AI 三个变量里，“宽窄”和“外展”方面的形状差异实际上被加了权。若希望长、宽、外展距等权，可只用三个原始测量，或只用 EC 与两个指数；结果应结合聚类的目的来选择。

3.5.3 数据探索

```
1 da <- foreign::read.spss("ear.sav", to.data.frame = TRUE)
2 v <- c("EC", "EK", "EZ", "EI", "AI") # 按变量名选取，不同版本文件列序不同
3 # 检查方差，看是否需要标化
4 cov(da[, v])
5 db <- scale(da[, v])
```

表 3.15 耳测量数据的协方差阵

	EC	EK	EZ	EI	AI
EC	0.28571639	0.07537258	0.05918261	-1.10094177	0.42935444
EK	0.07537258	0.07985106	0.01307202	0.64979547	-1.14300482
EZ	0.05918261	0.01307202	0.08433935	-0.26581275	2.37003609
EI	-1.10094177	0.64979547	-0.26581275	19.15508520	-21.41800780
AI	0.42935444	-1.14300482	2.37003609	-21.41800780	96.96404680

批注 方差差异巨大（EI、AI 以%计，方差为 19 和 97；EC、EK、EZ 以 cm 计，方差不足 0.3），需要标化，否则距离几乎只由 AI 决定。

3.5.4 按百分位数指定初始点

```
1 c1 <- round(quantile(db[, 1], c(0.1, 0.25, 0.5, 0.75, 0.9)), 1)
2 c2 <- round(quantile(db[, 2], c(0.1, 0.25, 0.5, 0.75, 0.9)), 1)
3 c3 <- round(quantile(db[, 3], c(0.1, 0.25, 0.5, 0.75, 0.9)), 1)
```

```

4 c4 <- round(quantile(db[, 4], c(0.1, 0.25, 0.5, 0.75, 0.9)), 1)
5 c5 <- round(quantile(db[, 5], c(0.1, 0.25, 0.5, 0.75, 0.9)), 1)
6 ca <- cbind(c1, c2, c3, c4, c5); ca
7 kmeans(db, ca)

```

表 3.16 按百分位数指定的初始中心

百分位数	c1	c2	c3	c4	c5
10%	-1.1	-1.1	-1.3	-1.3	-1.2
25%	-0.6	-0.4	-0.7	-0.6	-0.8
50%	0.0	-0.1	0.0	0.1	0.0
75%	0.7	0.6	0.7	0.7	0.7
90%	1.1	1.0	1.1	1.1	1.2

3.5.5 分类结果

表 3.17 五类的样本数与标化中心

类别	例数	EC	EK	EZ	EI	AI
1	24	-0.68160270	-1.89445350	-0.02754703	-1.34450640	1.16177120
2	87	-0.37033670	0.08444380	-1.13378211	0.45323760	-1.10602880
3	73	-0.74930260	-0.31329150	0.26097356	0.42474140	0.38155090
4	50	0.76329530	1.37778440	0.48436869	0.60310020	-0.27338280
5	66	0.98654670	-0.11967680	0.84894952	-1.03522200	0.82057460

表 3.18 300 例样本的类别 (按观测顺序)

编号	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
1-15	4	3	3	5	5	3	3	2	3	4	2	1	3	5	5
16-30	3	3	5	2	5	3	5	4	2	3	3	1	5	1	3
31-45	4	1	3	5	1	5	3	3	3	4	2	5	1	3	5
46-60	5	1	1	4	1	5	5	5	1	5	3	3	5	2	3
61-75	4	2	5	2	4	5	2	1	1	2	2	3	3	5	4
76-90	2	2	3	3	5	1	2	3	3	3	5	2	2	3	2
91-105	3	2	4	3	2	5	5	4	1	3	3	4	5	4	4
106-120	2	2	4	2	5	3	5	3	4	2	4	3	3	5	2
121-135	3	4	2	4	5	3	5	2	2	4	5	4	2	2	2
136-150	2	3	2	3	4	4	3	4	3	5	4	3	3	3	4
151-165	2	4	5	2	3	5	3	3	2	5	5	2	2	3	3
166-180	3	4	2	2	2	2	3	2	3	2	2	5	1	2	3
181-195	2	4	2	5	1	3	2	5	5	4	4	2	2	2	4
196-210	4	4	3	5	3	5	5	5	2	2	4	4	3	5	2
211-225	2	2	2	3	4	2	5	2	3	2	2	5	2	4	4
226-240	2	4	2	2	2	3	3	3	5	4	3	5	2	1	5
241-255	4	2	5	2	5	3	5	2	5	5	2	2	1	5	5
256-270	2	5	2	3	2	5	2	4	5	1	2	1	3	4	2
271-285	2	2	1	5	2	1	5	3	2	5	2	4	4	3	4
286-300	4	4	3	3	5	2	3	1	3	5	1	4	2	2	2

3.5.6 优化目标与聚类效果评估

Within cluster sum of squares

类内离均差平方和, 等同于类内各样本点到类重心 (类别中心) 的欧氏距离平方和。

Total SS

总平方和, 同方差分析中的定义。

Between SS

类间离差平方和。

优化目标 (不是收敛准则): K 均值最小化 W 。总平方和 T 与分组无关, 由 $T = W + B$, 等价于

$$\min \left(\frac{\text{within_SS}}{\text{total_SS}} \right) \quad \text{或} \quad \max \left(\frac{\text{between_SS}}{\text{total_SS}} \right).$$

何时停止迭代由前述停止条件决定。

类别	类内平方和
1	87.57103
2	171.28537
3	110.39236
4	113.89450
5	127.54928

$$\frac{\text{between_SS}}{\text{total_SS}} = 1 - \frac{610.69}{1495} = 59.2\%.$$

标准化后 $T = (n-1)p = 299 \times 5 = 1495$ 。59.2% 只表示：在这 5 个变量、这种标准化方式、 $k = 5$ 和这组初始点之下，类间平方和占总平方和的比例。换一组变量、换尺度或换 k ，这个数都会变；它本身并不说明分类“好”或“正确”，还要结合各类的分离程度和专业意义来评价（见下文）。

3.5.7 类数的选择

对固定的数据，最优类内平方和随 k 增大而不增：把某一类再拆成两类， W 不会变大； $k = n$ 时 $W = 0$ 。因此 B/T 总是随 k 增大，不能单独用来确定类数，只能看曲线在哪里变平（“肘部”）。

轮廓系数 对样品 i ，记 $a(i)$ 为它到同类其他样品的平均距离， $b(i)$ 为它到其他各类样品平均距离中的最小值，

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1].$$

$s(i)$ 接近 1 表示分得清楚，接近 0 表示处在两类边界，为负表示可能分错。全部样品的平均轮廓系数可用来比较不同的 k ；经验上 0.26 ~ 0.50 表示结构较弱，0.51 以上表示结构合理。

重抽样稳定性 (1) 对样品作有放回重抽样（或随机抽取 80%）；(2) 在重抽样数据上用同样的变量、标准化和 k 重新聚类；(3) 把每个原始类与重抽样结果中最相似的类配对，计算 Jaccard 系数（或调整兰德指数）；(4) 重复多次（如 100 次）取平均。平均 Jaccard 系数低于 0.6 的类不稳定，不宜作专业解释。R 的 `fpc::clusterboot()` 可完成上述步骤。

耳测量例（标准化 5 变量，每个 k 用 50 套随机初始点）的复算结果如下：

k	2	3	4	5	6	7	8
W	1039.7	835.4	694.2	610.7	545.0	495.9	457.4
B/T	30.5%	44.1%	53.6%	59.2%	63.5%	66.8%	69.4%
平均轮廓系数	0.29	0.25	0.26	0.26	0.26	0.26	0.24

B/T 平稳上升，看不到明显的肘部；平均轮廓系数在 0.24 ~ 0.29 之间，说明耳朵形态更像一个连续分布，并没有界限分明的自然类别。按百分位数指定初始点的 $k = 5$ 解与 50 套随机初始点的最优解相同（ $B/T = 59.2\%$ ）。所以这里选 $k = 5$ ，主要依据是临床上需要几种代表性耳型，而不是数据中存在 5 个天然的类。

B/T 的参照：无结构数据的结果

在单位正方形内均匀生成 100 个点，此数据不含任何群组结构，同样用 K 均值法分为 3 类；另生成一份确有 3 个群组的数据作为对照：

```

1 library(cluster)
2 set.seed(3)
3 u <- matrix(runif(200),100,2) # 无结构：均匀分布
4 km <- kmeans(u,3,nstart=20)
5 km$betweenss/km$totss; mean(silhouette(km$cluster,dist(u))[,3])
6 v <- rbind(matrix(rnorm(70,0,.5),35), matrix(rnorm(70,3,.5),35),
7         cbind(rnorm(30,0,.5),rnorm(30,3,.5))) # 真有3个群
8 km2 <- kmeans(v,3,nstart=20)
9 km2$betweenss/km2$totss; mean(silhouette(km2$cluster,dist(v))[,3])

[1] 0.664
[1] 0.427
[1] 0.885
[1] 0.678

```

无结构数据的 B/T 达 66%，高于耳测量资料分 5 类时的 59.2%。原因在于 K 均值法本身以最大化 B/T 为目标，总能找到使类间差异显得较大的划分。因此，B/T 较高既不能说明分类效果好，也不能说明数据中存在真实的类别。

平均轮廓系数的区分能力较好：有真实结构时为 0.68，无结构时为 0.43。耳测量资料约为 0.26，与前文“耳朵形态接近连续分布”的判断一致。该分类在临床上仍有使用价值（提供若干代表性耳型），但应视为对连续分布的人为划分，而非发现了天然存在的耳型。

3.5.8 还原到原量纲：代表性耳朵

标准化中心不便临床使用。把中心乘回各变量的标准差、加上均数，即还原到原量纲；再在每类中找离中心最近的实际病例，作为该类的“代表性耳朵”：

```

1 km <- kmeans(db, ca)
2 mu <- attr(db, "scaled:center"); sdv <- attr(db, "scaled:scale")
3 sweep(sweep(km$centers, 2, sdv, "*"), 2, mu, "+") # 原量纲中心
4 rep.id <- sapply(1:5, function(l) {
5   idx <- which(km$cluster == l)
6   idx[which.min(rowSums(sweep(db[idx, , drop = FALSE], 2, km$centers[l,
7   ])^2))]
8   })
9 da[rep.id, v]

```

类	例数	原量纲类中心					编号	离中心最近的病例				
		EC	EK	EZ	EI	AI		EC	EK	EZ	EI	AI
1	24	5.94	2.68	1.88	45.3	70.6	68	6.1	2.8	1.9	45.9	67.9
2	87	6.11	3.24	1.56	53.2	48.2	260	6.2	3.3	1.6	53.2	48.5
3	73	5.91	3.13	1.97	53.1	62.9	84	5.9	3.1	2.0	52.5	64.5
4	50	6.71	3.61	2.03	53.9	56.4	93	6.9	3.7	2.0	53.6	54.1
5	66	6.83	3.18	2.14	46.7	67.2	15	6.7	3.2	2.1	47.8	65.6

EC、EK、EZ 单位为 cm，EI、AI 单位为%。各类大致为：1 类短而窄、外展较大；2 类中等大小、贴头（外展最小）；3 类短、宽度中等、外展中等；4 类长而宽；5 类长而窄、外展较大。编号 68、260、84、93、15 这 5 例的实际耳朵即可作为修复时参照的代表。

3.5.9 程序随机指定初始点

直接输入 k 值。每次运行的结果可能不同。

```

1 k <- 5
2 g <- kmeans(db, k)
3 g$centers
4 k <- 4
5 g <- kmeans(db, k)
6 g$centers

```

表 3.19 随机初始点得到的标化类别中心

设置/运行	类别	EC	EK	EZ	EI	AI
$k = 5$	1	-0.47173490	0.38037882	0.57018830	0.86005170	0.28540470
	2	-0.93000630	-0.13683475	-1.44698450	0.81911760	-1.29576260
	3	-0.66961030	-1.33867575	-0.04299810	-0.76302790	0.74908390
	4	0.47183800	0.66283512	-0.53548830	0.16830930	-0.81491080
	5	1.06647380	0.09343839	0.93191100	-0.90652000	0.78034750
$k = 4$, 第 1 次	1	1.23474240	1.00974607	0.23644540	-0.20020600	-0.30578870
	2	0.21512140	-0.86994045	0.55697720	-1.09478240	1.02540860
	3	-0.55779840	-0.07646648	-1.03017810	0.47655890	-0.92855330
	4	-0.33233610	0.41458886	0.71851850	0.74744290	0.40214590
$k = 4$, 第 2 次	1	-0.34752740	0.12352200	-1.13844679	0.46927834	-1.12862640
	2	-0.97562040	-0.96322620	0.06379143	-0.04123529	0.60274110
	3	0.92162320	-0.25996660	0.77040502	-1.11960365	0.83796470
	4	0.43309520	1.06931640	0.48417739	0.62832488	-0.12724190
$k = 4$, 第 3 次	1	0.73422560	1.18069880	0.61786590	0.44483660	-0.06691626
	2	-0.99670010	-0.64423310	0.13653890	0.32425000	0.47130587
	3	-0.30847770	0.12267940	-1.10264660	0.42611670	-1.09548297
	4	0.68654100	-0.56818940	0.66733310	-1.22008960	0.93892307

3.5.10 多套初始点

`nstart=n` 随机指定 n 套初始中心，每套分别迭代到收敛，取 W 最小的一套作为结果。

批注 “迭代 30 遍” 的说法不确切。`nstart = 30` 是用 30 套初始中心各运行一次再择优；每次运行的迭代次数上限由 `iter.max` 控制（默认 10）。

```
1 k <- 4
2 g <- kmeans(db, k, nstart = 30)
3 g$centers
```

表 3.20 nstart=30 的三次运行结果

设置/运行	类别	EC	EK	EZ	EI	AI
第 1 次	1	0.92162320	-0.25996660	0.77040502	-1.11960365	0.83796470
	2	-0.34752740	0.12352200	-1.13844679	0.46927834	-1.12862640
	3	0.43309520	1.06931640	0.48417739	0.62832488	-0.12724190
	4	-0.97562040	-0.96322620	0.06379143	-0.04123529	0.60274110
第 2 次	1	0.92162320	-0.25996660	0.77040502	-1.11960365	0.83796470
	2	-0.97562040	-0.96322620	0.06379143	-0.04123529	0.60274110
	3	0.43309520	1.06931640	0.48417739	0.62832488	-0.12724190
	4	-0.34752740	0.12352200	-1.13844679	0.46927834	-1.12862640
第 3 次	1	0.43309520	1.06931640	0.48417739	0.62832488	-0.12724190
	2	-0.34752740	0.12352200	-1.13844679	0.46927834	-1.12862640
	3	0.92162320	-0.25996660	0.77040502	-1.11960365	0.83796470
	4	-0.97562040	-0.96322620	0.06379143	-0.04123529	0.60274110

表3.20三次运行得到的是同一组 4 个中心，只是类别编号不同。例如中心 (0.92, −0.26, 0.77, −1.12, 0.84) 在第 1、2 次编为 1 类，在第 3 次编为 3 类。类别编号本身没有意义，对编号作置换不改变分组， W 与 B/T (53.6%) 也完全相同。比较不同运行的结果时，应按中心或成员配对，而不是按编号。相比之下，不设 `nstart` 的三次 $k = 4$ 运行中，只有第 2 次达到这一最优解，第 1、3 次停在了不同的局部最优。

本章小结：聚类分析

研究目的	在没有类别标签的情况下，把相似的样品（Q 型）或指标（R 型）归类，属于探索性分析
优化准则	层次聚类：按选定的类间距离逐步合并（Ward 法每步使 W 增加最少）；K 均值：最小化类内平方和 W ，等价于最大化 B/T
主要条件	相似性度量要与变量类型匹配；数值变量量纲不同须先标准化；马氏距离要求协方差阵可逆；K 均值适合大致球形、大小相近的类，须预先给定 k
结果解释	聚类树、类中心（应还原到原量纲）、各类代表个体；结合 B/T 曲线、轮廓系数、重抽样稳定性与专业意义判断类数和效果
常见误用	把相似度当距离（配合例 0.6 应为距离 0.4）；不分对称与不对称二值变量；以为 <code>dist()</code> 会自动标准化；只凭 B/T 定类数；按编号比较不同运行的结果；把任何数据都“分出来”的类当作天然存在的类别

复习题

- 1) 两个变量的单位分别为 cm 和 kg，说明直接计算欧氏距离存在的问题，以及标准化所隐含的假定。
- 答：方差大的变量主导距离；标准化后各变量对平方距离的平均贡献相同，即假定各变量同等重要。

2) 比较马氏距离与标准化欧氏距离。

答：标准化欧氏距离仅消除量纲（方差）的影响；马氏距离同时考虑变量间的相关，相当于先作白化变换再计算欧氏距离。

3) 两名患者均无某种罕见症状，比较简单配合系数与 Jaccard 系数对这一情况的处理。

答：简单配合系数将(0,0)计为相同；Jaccard 系数排除(0,0)，适用于仅阳性取值有意义的不对称二值变量。

4) 说明最短距离法容易出现的现象，以及 Ward 法所得类别的特点。

答：最短距离法易出现链式效应；Ward 法倾向于得到大小较均衡、近似球形的类。

5) 说明 K 均值聚类需尝试多套初始点的原因，以及 B/T 在确定类数中的作用。

答：K 均值法只能保证收敛到局部最优，结果依赖初始点。B/T 随 k 增大而不减，只能观察其“肘部”，类数应结合轮廓系数、稳定性与专业需要确定。

第3章 习题与解析

聚类分析

往年题

单项选择题

题 3.1 聚类分析的条件

关于聚类分析，错误的是：

- A. 系统聚类即层次聚类。
- B. 样本量很大时可考虑快速聚类。
- C. 必须预先指定层次聚类的类别数。
- D. Q 型与 R 型聚类都需要定义距离或相似性。
- E. 类平均法和 Ward 法都会受到极端值影响。

题 3.2 聚类结果与算法

关于聚类分析，正确的是：

- A. 需要已经明确分类的训练样本。
- B. 对变量的聚类分为系统聚类和快速聚类。
- C. 不同聚类方法可能得到很不相同的结果。
- D. 样本量超过 100 时，个体聚类应一律使用层次聚类。
- E. 要求聚类变量服从多元正态。

题 3.3 聚类方法与分布

关于聚类分析，正确的是：

- A. 需要已有分类的训练样本。
- B. 对变量聚类分为系统聚类和快速聚类。
- C. 不同聚类方法可能得到很不相同的结果。
- D. 样本量超过 100 时，个体聚类应一律用层次聚类。
- E. 聚类对变量分布无要求，但马氏距离要求变量正态。

题 3.4 K-means 的目标

通常 K-means 聚类最小化的是：

- A. 类内欧氏平方距离总和。
- B. 类间距离总和。
- C. 所有样本的最大相关系数。
- D. 类别先验概率的乘积。
- E. 标签的错误率，且必须有训练标签。

题 3.5 Jaccard 忽略什么

二元属性中，Jaccard 相似性不把哪一项计作相似证据？

- A. 共同阳性。
- B. 共同阴性。
- C. 单侧阳性。
- D. 所有阳性。
- E. 所有不一致。

题 3.6 随机初值与复现

为了复现使用随机初值的 K-means 结果，最应同时记录：

- A. 只记录变量数。
- B. 随机种子、标准化规则、k、重复初值次数与算法版本。
- C. 只记录最终标签的顺序。
- D. 只记录样本均值。
- E. 只记录显著性水平。

题 3.7 代表变量的选择方向

以类内平均平方相关作为代表性： $v_j = \sum_{l \neq j} r_{jl}^2 / (m - 1)$ 。应优先选择：

- A. v_j 最大者。
- B. v_j 最小者。
- C. 变量名最短者。
- D. 第 1 列且无需计算。
- E. 方差最大的变量且不考虑相关性。

简答题

题 3.8 Jaccard 与简单匹配距离

Jaccard 距离和简单匹配距离有何区别？何时适用 Jaccard 距离？

计算与分析题

题 3.9 运动生理数据的两种聚类输出

表 1—3 为运动生理实验数据的统计分析结果。

- 1. 表 1 属于何种分析？
- 2. 把表 1 的对象分为 4 类，写出分类结果。
- 3. 表 2 属于何种分析？
- 4. 根据表 2—3，运动水平高者在哪一类？
- 5. 列出最无分类价值的两个变量。

表 1:

表1 cluster recode																		
Number of clusters	Case																	
	决定距离	聚类距离	决定距离	聚类距离	决定距离	聚类距离	决定距离	聚类距离	决定距离	聚类距离	决定距离	聚类距离	决定距离	聚类距离	决定距离	聚类距离	决定距离	聚类距离
1	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
2	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
3	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
4	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
5	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
6	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
7	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
8	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X
9	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X	X

表 2：最终分类中心。

指标	第 1 类	第 2 类	第 3 类	第 4 类
年龄	33	31	28	36
身高	167	172	176	171
体重	62	75	69	66
安静心率	75	76	76	75
安静每分通气量	8.5	11.2	13.4	10.0
安静公斤摄氧量	4.4	5.8	6.8	5.0
安静摄氧量	0.269	0.386	0.464	0.326
安静呼吸商	0.86	0.83	0.84	0.85
安静能耗	1882	2686	3313	2278
安静公斤能耗	31	40	47	35

分类	样本数
1	78
2	67
3	14
4	97
有效	256
缺失	34

题 3.10 体质数据：Ward 变量聚类与代表变量

对体质数据进行变量聚类分析。共 20 分。

1. 用 Ward 法把变量分为 5 类，写出分类结果。
2. 按一定统计规则，在“往返跑”所在类别中选择最有代表性的变量。
3. 给出第 2 问的 R 代码，并解释变量及步骤含义。

体质数据含脉搏、血压、肺活量、身高、体重、胸腰臀围、台阶指数、握力、背力、体前屈、纵跳、单脚站立、往返跑、反应时与俯卧撑等 18 项。

题 3.11 夹角余弦与 Ward 变量聚类

对体质数据的收缩压、舒张压、身高、体重、握力、背力、腰围、胸围、臀围、台阶指数、脉搏、往返跑 12 个变量聚类，指定相似性为夹角余弦，聚类方法为 Ward 法。共 20 分。

1. 给出冰柱图。(6 分)
2. 分为 4 类时，写出分类结果。(6 分)
3. 在变量数最多的类别中选择一个代表变量：常用选择方法有哪些？若按统计代表性最佳原则，报告计算结果和选择。(3+5 分)

题 3.12 耳形数据：标准化与非标准化 K-means

使用 ear 数据做快速聚类，以 EC、EK、EZ、EI、AI 为变量，随机选 4 个初始中心，重复 50 次；按 EC 中心的升序将类别命名为 1—4 类。

1. 给出标准化聚类后第 2 类中心（还原到原量纲）。
2. 给出非标准化聚类后第 2 类中心；另一回忆版本写“第 3 类”，请一并计算。
3. 对 EC=5、EK=2、EZ=2、EI=40、AI=50 的待分类对象，用标准化聚类所获分类的类内协方差，列出到 4 类中心的马氏距离（取整数部分）和所属类别。

指数定义： $EI=100EK/EC$ ， $AI=100EZ/EK$ 。

补充练习

本节为配合正文新编的补充练习。除注明沿用正文例题外，数值与研究摘要均为教学设定。题型与作答方式沿用本章往年题，解析见章末。

单项选择题

题 3.13 有序变量的距离

两项有序指标分别有 4 级和 5 级，均按 1 开始编码。样品 A 的记录为 (2, 5)，样品 B 为 (4, 1)。按正文规定，对每项指标用其完整等级数 m 作 $y = (x - 1)/(m - 1)$ 变换，再计算欧氏距离。两样品距离为：

- A. $\sqrt{20}$ 。
- B. $\sqrt{5}/2$ 。
- C. $2/3$ 。
- D. $\sqrt{13}/3$ 。
- E. $5/3$ 。

题 3.14 负相关变量在 R 型聚类中的距离

对指标作 R 型聚类。 $r_{AB} = -0.90$ ， $r_{AC} = 0.50$ 。研究者明确采用正文中的距离 $d_{st} = \sqrt{1 - r_{st}^2}$ 。下列正确的是：

- A. A 与 B 的距离更小，该变换把较强的负相关也作为较强联系。
- B. A 与 C 的距离更小，因为负相关必定代表不相似。
- C. A 与 B 的距离为 1.90。
- D. A 与 B 的距离为 0.10。
- E. 改用 $d_{st} = 1 - r_{st}$ 后，两组距离的大小关系必定不变。

简答题

题 3.15 标准化欧氏距离与马氏距离

研究者先将体重、胸围等指标作 Z 变换，再计算欧氏距离，并称：“标准化已经消除了量纲和变量相关性的影响，所以所得距离就是马氏距离。”请判断并说明理由。若改为对这些指标作 R 型聚类，中心化后的夹角余弦又与哪个统计量相同？

计算与分析题

题 3.16 类间距离更新与两类划分

4 个样品在同一数值指标上的取值为 $A = 0$ 、 $B = 1$ 、 $C = 3$ 、 $D = 5.2$ ，无需标准化。采用欧氏距离作凝聚型系统聚类，分别使用最短距离法、最长距离法和类平均法。这里类平均法指两类间所有样品对距离的算术平均。共 15 分。

1. 写出第一步合并的两个样品。(2 分)
2. 对第一步形成的新类，分别按三种方法计算它到其余两个样品的类间距离。(6 分)
3. 写出三种方法各自保留两类时的成员，并说明为何结果可能不同。(5 分)
4. 本题属于 Q 型还是 R 型聚类？(2 分)

题 3.17 K-means 收敛与类内平方和

4 个样品有两个尺度可比的数值指标，坐标分别为 $A = (0,0)$ 、 $B = (0,2)$ 、 $C = (4,0)$ 、 $D = (4,2)$ ，本题不再标准化。取 $k = 2$ ，用平方欧氏距离分配，每轮以类内均值更新中心。初始中心为 A 、 B 。共 15 分。

1. 写出第一轮分配、更新后的两个中心，并判断下一轮分配是否变化。(5 分)
2. 计算该结果的类内平方和 W 、总平方和 T 、类间平方和 B_{SS} 及 B_{SS}/T 。(5 分)
3. 若换用初始中心 $(0,1)$ 、 $(4,1)$ ，求收敛后的 W ，与前一结果比较。能否由“分配不再变化”认定已经找到全局最优？正文建议怎样降低初值影响？(5 分)

习题解析

核对方式

按题号核对。补写题目、原稿歧义及复算约定列在对应解析中。

解析 题 3.1 聚类分析的条件

[返回题目](#)

答案：C。

层次聚类先形成整个层次结构，再按所需类别数或切割高度划分；K-means 等快速聚类通常需事先给定 k。大样本的算法选择还取决于规模、距离和计算成本，不应把某个固定样本量当硬阈值。

解析 题 3.2 聚类结果与算法

[返回题目](#)

答案：C。

聚类是无监督分析，结果依赖变量、预处理、相似性及连接算法。常规距离聚类没有通用正态性要求；基于概率模型的聚类则需要相应模型假设。

解析 题 3.3 聚类方法与分布

[返回题目](#)

答案：C。

普通距离聚类无需通用正态假定；E 的后半句错误，马氏距离作为度量不要求正态，使用其卡方分布进行推断才需要相应条件。回忆稿缺 C/D，参考答案稿提供了完整内容。

解析 题 3.4 K-means 的目标

[返回题目](#)

答案：A。

K-means 交替更新分配与均值中心，以类内平方和为目标，可能得到局部最优。

补写说明。2019 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 3.5 Jaccard 忽略什么

[返回题目](#)

答案：B。

Jaccard 将共同阴性从分母和相似分子中排除，适合共同缺失缺乏含义的属性。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 3.6 随机初值与复现

[返回题目](#)

答案：B。

随机起点、预处理和算法实现均会影响局部解；类别数字本身还可任意重新编号。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 3.7 代表变量的选择方向[返回题目](#)

答案：A。

该指标度量该变量与同类其余变量的平均联系强度；如果全部很小，还应质疑该类能否被单变量代表。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 3.8 Jaccard 与简单匹配距离[返回题目](#)

对二元变量，令 a 为共同阳性数， d 为共同阴性数， $b + c$ 为不一致数：

$$d_{SM} = \frac{b + c}{a + b + c + d}, \quad d_J = \frac{b + c}{a + b + c}.$$

简单匹配把共同阴性也作为相似证据；Jaccard 不计共同阴性。后者适用于“共同出现”有意义、共同缺失不足以说明相似的属性，如罕见特征或物种存在。并非只要阳性率不均衡就一定使用 Jaccard； $a + b + c = 0$ 时需约定空集合处理。

解析 题 3.9 运动生理数据的两种聚类输出[返回题目](#)

表 1 是变量的层次聚类冰柱图，不是对个体的聚类。切为 4 组：

1. 安静能耗、安静摄氧量、安静公斤能耗、安静公斤摄氧量、安静每分通气量。
2. 安静呼吸商。
3. 体重、身高。
4. 安静心率、年龄。

表 2 是个体快速聚类的最终中心。按题目原解释，第三类年轻、体格和摄氧相关指标较高，判作运动水平高者，人数 14。但仅凭安静代谢指标不能代替严格运动能力测量，应限定为本题表格的相对解释。

安静心率和安静呼吸商在四类中心间差别很小，按本表描述最缺乏分类价值；若需严格判定，还应结合组内变异及变量尺度，不能只比较不同量纲变量的绝对极差。

解析 题 3.10 体质数据：Ward 变量聚类与代表变量[返回题目](#)

沿用原参考解的相似性变换 $d_{ij} = \sqrt{1 - r_{ij}^2}$ 与 ward.D2，同课程体质数据复算分为：

- 脉搏、台阶指数、体前屈、纵跳、单脚站立、往返跑、反应时、俯卧撑。
- 收缩压、舒张压。
- 肺活量、身高。
- 体重、胸围、腰围、臀围。
- 握力、背力。

类别编号和叶序可不同，成员集合才是核对重点。定义类内代表性 $v_j = \sum_{l \neq j} r_{jl}^2 / (m - 1)$ ，取最大者。往返跑所在类各值：

变量	平均平方相关
wfp	0.04985
zt	0.04269
fwc	0.03007
fys	0.02388
djzl	0.01996
mb	0.01275
tjzs	0.00852
tqq	0.00840

故选 **往返跑** 本身 (约 0.04985), 但该类整体相关性偏弱, 代表性有限。

```
members <- names(cluster)[cluster == cluster['wfp']]
R <- cor(data[, members])
v <- (colSums(R^2) - 1) / (length(members) - 1)
names(which.max(v))
```


members 为该类变量名; **R** 为其相关阵; 去掉对角线自相关 1 后取平均平方相关。原代码循环始终用了同一列并使用 **which.min**, 不能据此选择最大代表性变量。

所用距离可理解为忽略相关符号的投影差异; 若改用其他距离/标准化方式, 须说明, 分类未必相同。

解析 题 3.11 夹角余弦与 Ward 变量聚类

[返回题目](#)

按原参考代码使用未中心化变量列的夹角余弦 $s_{ij} = x_i^T x_j / (\|x_i\| \|x_j\|)$, 转换 $d_{ij} = \sqrt{1 - s_{ij}^2}$, 然后用 **ward.D2**。下图按树叶次序排列; 同一行连续色块表示同一簇, 行号为簇数。



四类为: (1) 收缩压、舒张压、台阶指数; (2) 身高、体重、腰围、胸围、臀围; (3) 握力、背力; (4) 脉搏、往返跑。

代表变量可根据测量可靠性、成本、临床可解释性, 或类内平均相关/平方相关、接近类中心的程度选择。采用平均平方相关, 最多成员组的各值如下:

变量	平均平方相关
tz	0.58508
tw	0.52853
yw	0.52222
xw	0.51836
sg	0.07221

选 **体重**，代表性约 0.58508。注意夹角余弦不是中心化后的 Pearson 相关；改变预处理会改变结果。Ward 距离变换要与软件算法一致，ward.D2 会在更新前平方输入差异，不能无说明地重复平方。

解析 题 3.12 耳形数据：标准化与非标准化 K-means

[返回题目](#)

随机算法须给定种子，否则不能保证逐位复现。设置 `set.seed(20260907)`、`nstart=50`，对 5 项变量按样本标准差标准化；聚类中心还原并按 EC 升序排列后如下。

类别	EC	EK	EZ	EI	AI
1	5.7845	2.9465	1.9099	51.0349	65.0505
2	6.1202	3.2536	1.5607	53.2692	48.0017
3	6.5375	3.5208	2.0319	53.9653	57.8624
4	6.7986	3.1452	2.1151	46.3152	67.3668

非标准化结果：

类别	EC	EK	EZ	EI	AI
1	6.1566	3.3434	1.4925	54.4138	44.6115
2	6.2949	3.2980	1.8101	52.5118	54.8800
3	6.3204	3.1935	2.0355	50.7170	63.7853
4	6.4455	2.9982	2.1782	46.6423	72.8187

因此第 2 类中心为 (6.2949, 3.2980, 1.8101, 52.5118, 54.8800)；第 3 类为 (6.3204, 3.1935, 2.0355, 50.7169, 63.7853)。表格按 EC 升序重新标为 1—4 类。

严格代入原给定 5 维向量，距离为 (66.385, 117.129, 81.786, 109.530)，整数部分为 **66**、**117**、**81**、**109**，归入 **第 1 类**。原稿的 117、82、66、68 及“第 3 类”混用了随机类别标签，第四距离代码还误用了第三组协方差。

输入矛盾。按定义 $EZ=2$ 、 $EK=2$ 应有 $AI=100$ ，而非 50。若改用一致输入 (5, 2, 2, 40, 100)，距离为 (12.739, 82.287, 51.296, 28.815)，仍归第 1 类。两种输入结果应分开，不能静默更改题干。马氏距离是本题另加的分配规则；K-means 本身最小化欧氏平方距离。

补充练习解析

解析 题 3.13 有序变量的距离

[返回题目](#)

答案：D。

变换后 A 为 $(1/3, 1)$, B 为 $(1, 0)$, 故距离为 $\sqrt{(1/3 - 1)^2 + (1 - 0)^2} = \sqrt{13}/3 \approx 1.2019$ 。两个分母分别为 3、4, 应使用各指标的完整等级范围; 若求绝对值距离才是 $5/3$ 。

解析 题 3.14 负相关变量在 R 型聚类中的距离

[返回题目](#)

答案：A。

题定距离下, $d_{AB} = \sqrt{0.19} \approx 0.4359$, $d_{AC} = \sqrt{0.75} \approx 0.8660$, 所以 A、B 更接近。平方消除了相关符号。如果改用正文练习代码中的 $1 - r$, 两距离分别为 1.90、0.50, 次序会反转。是否将反向变化视为同类联系, 应服从变量优选的目的, 并在题目或报告中写明距离定义。

解析 题 3.15 标准化欧氏距离与马氏距离

[返回题目](#)

该说法不成立。Z 变换使各指标方差为 1, 但通常仍保留指标间相关性, 不能一般地把相关矩阵变为单位阵。设两个标准化观测之差为 Δz , 则

$$d_E^2 = \Delta z^T \Delta z, \quad d_M^2 = \Delta z^T R^{-1} \Delta z.$$

当 $R = I$ 时, 两种度量对所有样品对相同; 一般相关资料中二者不同。马氏距离利用逆协方差矩阵同时调整尺度和相关结构。

对两个非恒定指标列分别中心化后, 它们的夹角余弦等于 Pearson 相关系数。未中心化的夹角余弦一般不等于 Pearson 相关。

解析 题 3.16 类间距离更新与两类划分

[返回题目](#)

- (1) 第一次合并。初始最小距离为 $d(A, B) = 1$, 三种方法均先合并 A、B。
- (2) 更新距离。

方法	$d(AB, C)$	$d(AB, D)$	$d(C, D)$
最短	2.0	4.2	2.2
最长	3.0	5.2	2.2
类平均	2.5	4.7	2.2

例如类平均法 $d(AB, C) = [d(A, C) + d(B, C)]/2 = (3 + 2)/2 = 2.5$ 。

(3) 两类成员。最短距离法下一步合并 AB 与 C, 得到 $\{A, B, C\}$ 、 $\{D\}$ 。最长距离法与类平均法下一步均合并 C、D, 得到 $\{A, B\}$ 、 $\{C, D\}$ 。最短法只看最接近的跨类样品对, 最长法看最远样品对, 类平均法使用全部跨类样品对; 相同初始距离矩阵也可产生不同的后续合并。

- (4) 聚类对象。被归类的是 4 个样品, 因此是 Q 型聚类。

解析 题 3.17 K-means 收敛与类内平方和[返回题目](#)

(1) **第一套初值**。第一轮为 $\{A, C\}$ 、 $\{B, D\}$ ，中心更新为 $(2, 0)$ 、 $(2, 2)$ 。每个样品仍离所在类中心更近，下一轮分配不变，算法收敛。

(2) **平方和**。每个样品到其中心的平方距离为 4，故 $W = 16$ 。总中心为 $(2, 1)$ ，每个样品到总中心的平方距离为 5，故 $T = 20$ 。于是 $B_{SS} = T - W = 4$ ， $B_{SS}/T = 20\%$ 。

(3) **另一套初值**。得到 $\{A, B\}$ 、 $\{C, D\}$ ，中心为 $(0, 1)$ 、 $(4, 1)$ ，分配同样稳定；每个样品到其中心的平方距离为 1，故 $W = 4$ ， $B_{SS}/T = 80\%$ 。在相同变量、预处理和 k 下，第二套结果的目标函数更小。

分配稳定仅说明达到该迭代规则的稳定解，不保证全局最优。按正文可尝试多套随机初值，例如设置 `nstart`，在所得解中选择类内平方和最小者；多次起点也不构成全局最优的普遍保证。

第4章

判别分析

判别分析的思路与临床诊断相似：根据已确诊的胃癌、萎缩性胃炎和非胃病患者的若干生化指标建立判别规则，用于根据同样的指标判断新患者最可能所属的类别。

本章三种方法的基本思想如下：

- 距离判别：将样品判归距其最近的类别中心所对应的类。
- Fisher 判别：先求若干最能区分各类的综合指标（线性组合），再在这些指标上比较样品与各类中心的距离。
- Bayes 判别：计算样品属于各类的后验概率，判归后验概率最大的类；可同时考虑先验概率（人群中的患病比例）与误判代价。

在各类协方差阵相等、服从正态分布且先验概率相等的条件下，三种方法的判别结果完全相同，详见本章各节。

判别规则的评价应以新样品为对象。用建立规则的同一批样品进行检验（回代），正确率必然偏高；留一法与交叉验证估计的是规则用于新样品时的表现。这一原则适用于各类统计建模。

4.1 判别分析

判别分析（discriminant analysis）是在已知研究对象分为若干类型，并取得各类型一批已知样品观测数据的基础上，根据某准则建立判别式，对未知类型的新样品进行分类。常用方法有距离判别、Fisher 判别和 Bayes 判别。

批注 判别分析是有监督的，提前有训练样本。

4.2 距离判别

首先根据已知分类的数据，分别计算各类重心，即各类各指标均值。判别准则是就近归类：若某观测到第 k 类重心的距离（如马氏距离）最近，认为其来自第 k 类。这种做法即最近重心判别（nearest-centroid rule）。它与按最近的单个训练样品归类的最近邻法（ k -NN）不同。距离判别对各类总体分布无特定要求，但使用合并协方差阵时，隐含各类协方差阵相等。

胃癌鉴别数据

表 4.1 三类样本的四项生化指标

组别	编号	x_1	x_2	x_3	x_4
1	1	228	134	20	11
1	2	245	134	10	40
1	3	200	167	12	27
1	4	170	150	7	8
1	5	100	167	20	14
2	6	255	125	7	14
2	7	130	100	6	12
2	8	150	117	7	6
2	9	120	133	10	26
2	10	160	100	5	10
3	11	185	115	5	19
3	12	170	125	6	4
3	13	165	142	5	3
3	14	135	108	2	12
3	15	100	117	7	2

组 1: 胃癌; 组 2: 萎缩性胃炎; 组 3: 非胃病患者。

```

1 d <- data.frame(g = rep(1:3, each = 5), id = 1:15,
2   x1 = c(228, 245, 200, 170, 100, 255, 130, 150, 120, 160, 185, 170, 165,
3     135, 100),
4   x2 = c(134, 134, 167, 150, 167, 125, 100, 117, 133, 100, 115, 125, 142,
5     108, 117),
6   x3 = c(20, 10, 12, 7, 20, 7, 6, 7, 10, 5, 5, 6, 5, 2, 7),
   x4 = c(11, 40, 27, 8, 14, 14, 12, 6, 26, 10, 19, 4, 3, 12, 2))
attach(d)                                # 下文直接使用 g, id, x1--x4

```

4.2.1 具体步骤

推断各类总体协方差阵是否相等: $\Sigma_1 = \Sigma_2 = \Sigma_3 = \Sigma$ 。若 $P > \alpha$ (且专业上可以接受协方差阵相等), 用合并样本协方差阵 S 估计 Σ :

$$D_M^2(X_i, G_k) = (X_i - \bar{X}_k)^T S^{-1} (X_i - \bar{X}_k). \quad (4.1)$$

否则,

$$D_M^2(X_i, G_k) = (X_i - \bar{X}_k)^T S_k^{-1} (X_i - \bar{X}_k). \quad (4.2)$$

样本归入距离最小的类别。

4.2.2 总体协方差矩阵相等的检验

设有 K 组, p 个变量。

$$H_0: \Sigma_1 = \Sigma_2 = \cdots = \Sigma_K.$$

在 H_0 条件下, 合并样本协方差矩阵为

$$S = \frac{\sum_{i=1}^K (n_i - 1) S_i}{\sum_{i=1}^K n_i - K}.$$

令 $\nu_i = n_i - 1$, $\nu_e = \sum_{i=1}^K n_i - K$, 则

$$M = \nu_e \log |S| - \sum_{i=1}^K \nu_i \log |S_i|, \quad (4.3)$$

$$C = \frac{2p^2 + 3p - 1}{6(p+1)(K-1)} \left(\sum_{i=1}^K \frac{1}{\nu_i} - \frac{1}{\nu_e} \right), \quad (4.4)$$

$$\chi^2 = (1 - C)M \sim \chi^2 \left(df = \frac{p(p+1)(K-1)}{2} \right). \quad (4.5)$$

式(4.5)是近似分布。检验要求各组独立抽样、组内服从多元正态分布 (Box M 检验对非正态很敏感), 且每个 S_i 可逆, 即 $n_i - 1 \geq p$ 。 $n_i > 20$ 且 p, K 均不超过 5 时近似较好 (Box, 1949、1950)。

胃癌数据的 Box M 检验

```

1  p <- 4; K <- 3; n1 <- 5; n2 <- 5; n3 <- 5
2  n <- sum(n1 + n2 + n3)
3  nu1 <- n1 - 1; nu2 <- n2 - 1; nu3 <- n3 - 1
4  nue <- n - K
5  S1 <- cov(d[g == 1, 3:6])
6  S2 <- cov(d[g == 2, 3:6])
7  S3 <- cov(d[g == 3, 3:6])
8  S <- (nu1 * S1 + nu2 * S2 + nu3 * S3) / nue; S
9  M <- nue * log(det(S)) -
10   (nu1 * log(det(S1)) + nu2 * log(det(S2)) + nu3 * log(det(S3)))
11  C <- (2*p^2 + 3*p - 1) / (6*(p + 1)*(K - 1)) *
12   (1/nu1 + 1/nu2 + 1/nu3 - 1/nue)
13  chisq <- (1 - C) * M
14  df <- p * (p + 1) * (K - 1) / 2
15  P.value <- 1 - pchisq(chisq, df)

```

表 4.2 合并协方差阵 S

	x_1	x_2	x_3	x_4
x_1	2434.100000	-133.933333	-44.866667	145.333333
x_2	-133.933333	220.366667	14.200000	-7.000000
x_3	-44.866667	14.200000	14.066667	-6.833333
x_4	145.333333	-7.000000	-6.833333	95.933333

统计量	结果
M	43.62428
C	0.4777778
χ^2	22.78157
df	20
P	0.2996469

取 $\alpha = 0.2$, 不拒绝 H_0 。但本例每组仅 5 例、4 个变量, $n_i - 1 = 4 = p$, 各组 S_i 刚好可逆, 远没有达到上述 $n_i > 20$ 的条件, χ^2 近似不可靠, 检验效能也很低。 $P > \alpha$ 只表示未能拒绝 H_0 , 不能据此确认协方差阵相等。本例采用合并 S , 更多是因为每组 5 例估计的 S_i 极不稳定 (见下文)。

4.2.3 各组重心

```

1 m1 <- tapply(x1, g, mean)
2 m2 <- tapply(x2, g, mean)
3 m3 <- tapply(x3, g, mean)
4 m4 <- tapply(x4, g, mean)
5 ct <- rbind(m1, m2, m3, m4)
6 colnames(ct) <- c("ct1", "ct2", "ct3"); ct

```

	G_1	G_2	G_3
x_1	188.6	163.0	151.0
x_2	150.4	115.0	121.4
x_3	13.8	7.0	5.0
x_4	20.0	13.6	8.0

4.2.4 回代判别

```

1 d1 <- rep(NA, n); d2 <- rep(NA, n); d3 <- rep(NA, n)
2 g.p <- rep(NA, n); acc <- rep(NA, n)
3 dx <- cbind(x1, x2, x3, x4)
4 e.cov <- 1 # 本例用合并S; 若用各组S_k, 设 e.cov = 0

```

```

5  for (i in 1:n) {
6    if (e.cov == 1) {
7      d1[i] <- sqrt((dx[i, ] - t(ct[, 1])) %*% solve(S) %*%
8                  t(dx[i, ] - t(ct[, 1])))
9      d2[i] <- sqrt((dx[i, ] - t(ct[, 2])) %*% solve(S) %*%
10                 t(dx[i, ] - t(ct[, 2])))
11      d3[i] <- sqrt((dx[i, ] - t(ct[, 3])) %*% solve(S) %*%
12                 t(dx[i, ] - t(ct[, 3])))
13    } else {
14      d1[i] <- sqrt((dx[i, ] - t(ct[, 1])) %*% solve(S1) %*%
15                  t(dx[i, ] - t(ct[, 1])))
16      d2[i] <- sqrt((dx[i, ] - t(ct[, 2])) %*% solve(S2) %*%
17                  t(dx[i, ] - t(ct[, 2])))
18      d3[i] <- sqrt((dx[i, ] - t(ct[, 3])) %*% solve(S3) %*%
19                  t(dx[i, ] - t(ct[, 3])))
20    }
21    if (d1[i] == min(d1[i], d2[i], d3[i])) g.p[i] <- 1
22    if (d2[i] == min(d1[i], d2[i], d3[i])) g.p[i] <- 2
23    if (d3[i] == min(d1[i], d2[i], d3[i])) g.p[i] <- 3
24    if (g[i] == g.p[i]) acc[i] <- 1 else acc[i] <- 0
25  }
26  da <- cbind(g, id, d1, d2, d3, g.p, acc); da
27  sum(acc) / n

```

表 4.3 距离判别回代结果 (合并协方差阵 S)

	g	id	d_1	d_2	d_3	预测组	一致
	1	1	2.6818910	4.1849985	4.7923988	1	1
	1	2	2.3349370	3.4728157	4.1259777	1	1
	1	3	1.5155710	4.0602974	4.2105857	1	1
	1	4	2.4814910	2.5882443	2.0803232	3	0
	1	5	2.2571570	4.4643853	4.7368135	1	1
	2	6	2.6548380	2.2087790	2.4042689	2	1
	2	7	4.2606070	1.3462864	1.8054116	2	1
	2	8	3.3278160	0.8030230	0.7095564	3	0
	2	9	2.4831650	2.1894749	2.6906627	2	1
	2	10	4.1893900	1.1688083	1.5064565	2	1
	3	11	3.1370960	0.7547364	1.2791578	2	0
	3	12	3.2153310	1.4099995	0.7823324	3	1
	3	13	3.2632470	2.4654895	1.6570242	3	1
	3	14	4.4715170	1.6477411	1.3289560	3	1
	3	15	3.9721640	1.5859607	1.2449610	3	1

总一致率为 0.8。表 4.3 由合并协方差阵 S 得到 ($e.cov <- 1$)，回代正确率为 $12/15 = 80\%$ 。

批注 若设 $e.cov \leftarrow 0$, 改用各组自己的 S_k , 回代一致率为 14/15, 但这是假象。本例 $n_k - 1 = p = 4$, 每个样品到本组重心的平方马氏距离恒为 $(n_k - 1)^2 / n_k = 3.2$ (距离 1.789), 与数据无关; 它到其他组的距离则往往很大, 于是几乎总被判回本组。

4.2.5 判别效果的评价: 回代与留一法

回代 (resubstitution) 用建立判别规则的同一批样品来评价规则, 得到的正确率偏乐观; 预测误判率是规则用于新样品时的误判率, 应当用留一法、交叉验证或独立验证样本来估计。回代结果的混淆矩阵如下:

真实组别	回代判为			正确率
	G_1	G_2	G_3	
G_1	4	0	1	80%
G_2	0	4	1	80%
G_3	0	1	4	80%
合计	12/15 = 80%			

留一法 (leave-one-out): 每次删去一例, 用其余 14 例重新估计各组均值和合并协方差阵, 再判别被删去的这一例; 15 例轮流一遍。

```

1  pooled <- function(X, g) {                # 合并协方差阵
2    K <- sort(unique(g))
3    Reduce('+', lapply(K, function(k) cov(X[g == k, ]) * (sum(g == k) - 1))) /
4    (nrow(X) - length(K))
5  }
6  g.loo <- rep(NA, n)
7  for (i in 1:n) {
8    Xt <- dx[-i, ]; gt <- g[-i]
9    St <- pooled(Xt, gt)                    # 删去第i例后重新估计
10   ctt <- sapply(1:3, function(k) colMeans(Xt[gt == k, ]))
11   dd <- sapply(1:3, function(k) mahalanobis(dx[i, ], ctt[, k], St))
12   g.loo[i] <- which.min(dd)
13 }
14 table(g, g.loo); mean(g.loo == g)

```

真实组别	留一法判为			正确率
	G_1	G_2	G_3	
G_1	2	2	1	40%
G_2	2	1	2	20%
G_3	0	3	2	40%
合计	5/15 = 33.3%			

四个变量、固定等先验时, 回代正确率为 80%, 留一法只有 33.3%, 接近三组随机猜测的水平。15 例要估计 3 个均值向量和一个 4×4 协方差阵, 规则对训练样品“过拟合”, 回代正确率严重高估

了预测能力。`MASS::lda(..., prior = rep(1/3, 3), CV = TRUE)` 给出同样的 5/15。若需要筛选变量，筛选也必须在每一折的训练样品内完成，否则留一法的结果同样偏乐观。

4.2.6 应用

现有样本 $x_1 = 150$ 、 $x_2 = 140$ 、 $x_3 = 10$ 、 $x_4 = 10$ ，判定其类别。

```
1 dx0 <- c(150, 140, 10, 10)
2 d1 <- sqrt(t(dx0 - ct[, 1]) %*% solve(S) %*% (dx0 - ct[, 1]))
3 d2 <- sqrt(t(dx0 - ct[, 2]) %*% solve(S) %*% (dx0 - ct[, 2]))
4 d3 <- sqrt(t(dx0 - ct[, 3]) %*% solve(S) %*% (dx0 - ct[, 3]))
```

$$d_1 = 1.853082, \quad d_2 = 1.752024, \quad d_3 = 1.728286.$$

4.2.7 优缺点

- 1) 马氏距离不受量纲影响，排除变量间相关性的干扰。数据标化与否，马氏距离相同。
- 2) 方法较粗糙，未能评价各变量在分类中的作用大小，也未能去除与分类关系不大的变量。
- 3) 可能夸大方差很小的变量的作用。

4.3 Fisher 判别

Fisher 判别又称典则 (canonical) 判别，寻找 p 个指标的少数几个线性组合 (综合指标)，使同类的点尽可能聚在一起，不同类的点尽可能分开，即分离度尽可能大，从而达到分类目的。

$$y_1 = a_1^T x = a_{11}x_1 + \cdots + a_{1p}x_p, \quad y_2 = a_2^T x = a_{21}x_1 + \cdots + a_{2p}x_p, \quad \dots$$

设共 K 组，第 k 组有 n_k 例，组均值为 $\bar{x}_k$ ，总均值为 $\bar{x}$ 。组内离差阵与组间离差阵分别为

$$W = \sum_{k=1}^K \sum_{i \in G_k} (x_i - \bar{x}_k)(x_i - \bar{x}_k)^T, \quad B = \sum_{k=1}^K n_k (\bar{x}_k - \bar{x})(\bar{x}_k - \bar{x})^T.$$

对 $y = a^T x$ ，组间离差平方和为 $\sum_k n_k (\bar{y}_k - \bar{y})^2 = a^T B a$ ，组内离差平方和为 $\sum_k \sum_{i \in G_k} (y_i - \bar{y}_k)^2 = a^T W a$ 。分子、分母都用离差平方和，分离度定义为

$$J(a) = \frac{a^T B a}{a^T W a}.$$

(若分母改用合并组内方差 $a^T W a / (n - K)$ ， J 只差常数倍，最优方向不变。)




图 4.1 Fisher 判别的基本思想 (两类、两个判别指标)

4.3.1 判别函数系数

矩阵 $W^{-1}B$ 的第一特征向量是第一个判别函数 y_1 的系数, 其中 W 与 B 分别为原始数据的组内和组间离差阵。第一特征值为最大分离度 λ_1 。

同理, 第二特征向量是第二个判别函数 y_2 的系数, 第二特征值为次大分离度 λ_2 。

证明 设 W 正定 (要求 $n - K \geq p$ 且无完全共线)。 $J(a)$ 与 a 的长度无关, 可限定 $a^T W a = 1$, 求 $a^T B a$ 的最大值。令 $\mathcal{L} = a^T B a - \lambda(a^T W a - 1)$, 由 $\partial \mathcal{L} / \partial a = 2Ba - 2\lambda Wa = 0$ 得

$$Ba = \lambda Wa, \quad \text{即} \quad W^{-1}Ba = \lambda a,$$

且此时 $J(a) = a^T B a = \lambda$ 。故最大分离度是 $W^{-1}B$ 的最大特征值, 相应特征向量为 a_1 。第二个方向在 $a_2^T W a_1 = 0$ (W -正交, 即两个判别得分在组内不相关) 的约束下再求最大, 得到第二特征值和特征向量, 依此类推。 $\square$

4.3.2 判别函数的分类能力

判别函数 F_k 的分类能力由其对应的特征值 λ_k 占总特征值的比例给出:

$$\lambda_k = \frac{R_{k,\text{Can}}^2}{1 - R_{k,\text{Can}}^2}, \quad \text{Power}(F_k) = \frac{\lambda_k}{\sum_{i=1}^r \lambda_i} \times 100\%, \quad r = \min(K - 1, p). \quad (4.6)$$

批注 有的资料写作“分类数为 $\min(g - 1, m)$ ”, 应为: 非零判别函数最多有 $\min(K - 1, p)$ 个 (K 为组数, p 为变量数)。因为 B 是 K 个秩为 1 的矩阵之和, 且 $\sum_k n_k(\bar{x}_k - \bar{x}) = 0$, 所以 $\text{rank}(B) \leq K - 1$; 又 $\text{rank}(B) \leq p$ 。 $W^{-1}B$ 的非零特征值个数等于 $\text{rank}(B)$ 。

$R_{k,\text{Can}}$ 是第 k 个判别得分与组别之间的典型相关系数, $R_{k,\text{Can}}^2 = \lambda_k / (1 + \lambda_k)$ 是该得分的总离差平方和中组间部分所占的比例。本例 $K = 3$ 、 $p = 4$, 有 2 个判别函数: $\lambda_1 = 2.864$ 、 $\lambda_2 = 0.201$, 典型相关系数为 0.861 和 0.409, 贡献比例为 93.4% 和 6.6%。这些量描述各组在判别得分上分离的程度, 不是预测正确率; 后者要单独评价 (见 4.2.5 节)。

	LD1	LD2
Proportion of trace	0.9344	0.0656

4.3.3 判别函数与得分

```
1 library(MASS)
2 out <- lda(g ~ x1 + x2 + x3 + x4, data = d, prior = rep(1/3, 3))
3 out$scaling # 判别函数系数
4 out$svd^2 / sum(out$svd^2) # Proportion of trace
5 predict(out)$x # 判别得分
```

lda() 对系数的归一化约定是：每个判别得分的合并组内方差为 1，即 $a^T S a = 1$ ($S = W/(n-K)$)。判别得分是中心化后的得分，predict() 先减去按先验加权的各组均值之和；本例等先验、各组例数相等，即减去总均值，15 例得分的均数为 0。

表 4.4 Fisher 线性判别函数系数

变量	LD1	LD2
x_1	0.007438797	-0.000084246
x_2	0.038594818	-0.056251470
x_3	0.177856904	0.156929600
x_4	0.035595971	0.054214160

表 4.5 15 例样本的判别得分（中心化）

观测	LD1	LD2
1	2.5708732	1.343481860
2	1.9510469	1.344964476
3	2.7828962	-0.898467808
4	0.3380125	-1.754382482
5	2.9991242	-0.339390591
6	0.2190156	-0.029971738
7	-1.9247533	1.121487805
8	-1.1555844	-0.004827448
9	0.4842589	0.652748444
10	-1.9506383	0.853602512
11	-0.8653823	0.495651796
12	-0.9470988	-0.721882023
13	-0.5416337	-1.888879494
14	-2.2902284	0.043336480
15	-1.6699082	-0.217471790

4.3.4 回代分类与各类别重心

求各组在判别空间中的重心，按欧氏距离把每个样品归入最近的重心。

```
1 aggregate(predict(out)$x, by = list(g), mean)
```

组别	LD1	LD2
1	2.1283906	-0.06075891
2	-0.8655403	0.51860792
3	-1.2628503	-0.45784901




图 4.2 判别得分及各类重心

表 4.6 Fisher 回代判别结果与评价

观测	d_1	d_2	d_3	最小值	预测组
1	1.47230530	3.53402819	4.23582680	1.47230530	1
2	1.41686590	2.93530729	3.68500640	1.41686590	1
3	1.06307750	3.91397406	4.06966950	1.06307750	1
4	2.46451110	2.57196902	2.06003900	2.06003900	3
5	0.91422780	3.95876154	4.26362040	0.91422780	1
6	1.90962320	1.21540163	1.54240250	1.21540163	2
7	4.22204730	1.21876840	1.71243110	1.21876840	2
8	3.28445130	0.59842306	0.46554750	0.46554750	3
9	1.79227840	1.35644816	2.07022150	1.35644816	2
10	4.18025520	1.13563153	1.48086370	1.13563153	2
11	3.04504010	0.02295666	1.03302690	0.02295666	2
12	3.14574610	1.24316816	0.41159740	0.41159740	3
13	3.23590090	2.42917910	1.60249850	1.60249850	3
14	4.41984500	1.50187188	1.14310660	1.14310660	3
15	3.80153030	1.09033066	0.47273390	0.47273390	3

表4.6的判别结果与表4.3完全相同（误判第 4、8、11 例，回代正确率 12/15）。这不是巧合：使用全部 $\min(K - 1, p) = 2$ 个判别函数时，样品到各组重心在判别空间中的平方欧氏距离，与原空间中以合并 S 计算的平方马氏距离只差一个与组别无关的常数（各组均值之差全部落在判别空间内）。例如第 1 例， $2.682^2 - 1.472^2 = 4.185^2 - 3.534^2 = 5.02$ 。因此两者的回代与留一法正确率也相同。

4.4 Bayes 判别

4.4.1 Bayes 理论

经典统计学派：频率学派
代表人物为 R. A. Fisher、Karl Pearson。以抽样频率作为概率估计，通过样本统计量估计总体参数，总体参数为未知常数，用抽样分布评价估计的好坏。
Bayes 统计学派
把未知参数看作随机变量，用先验分布表达分析前对参数的不确定性，再结合数据得到参数的后验分布。

判别分析中的“先验概率” q_k 是另一回事：它是待判对象来自第 k 类的概率，即各类在目标人群中的构成比（如就诊人群中胃癌所占比例），可以按频率来理解。用 Bayes 公式把 q_k 与类条件密度结合得到后验概率，频率学派同样接受。本章的“Bayes 判别”指这种利用类别先验的判别；各类的参数 (μ_k, Σ) 直接用样本估计值代入，并没有对参数的不确定性建模。

批注 Bayes 分类对总体分布无硬性要求。正态分布与等协方差是为使判别函数线性且易算而额外增加的条件。

4.4.2 先验概率与后验概率

先验概率 (prior probability): 将 K 个总体完全混合后, 随机抽取一个观测, 来自第 k 个总体的概率 q_k , $q_1 + \dots + q_K = 1$ 。先验概率往往未知。缺乏目标人群构成的信息时常取等先验 $q_k = 1/K$, 此时最大后验判别就是按类条件密度 $f_k(x)$ 最大来判别。只有训练样本是目标人群的随机样本时, 才能用样本中各类的比例估计 q_k ; 若各类例数由研究设计决定 (如下例胃癌 46 例、非胃癌 94 例), 样本比例并不反映目标人群的构成, 不宜直接作先验。

后验概率 (posterior probability): 特定指标为 X 的观测属于第 k 个总体的概率 $P(k | X)$ 。

先验概率对判别结论的影响

以下文一元胃癌鉴别的参数 (非胃癌 $\mu_1 = 0.24$, 胃癌 $\mu_2 = 0.42$, 共同方差 0.025) 为例。两类均为正态分布且方差相等时, 判为胃癌的界值为

$$x^* = \frac{\mu_1 + \mu_2}{2} + \frac{\sigma^2}{\mu_2 - \mu_1} \log \frac{q_1}{q_2}.$$

```
1 mu1 <- 0.24; mu2 <- 0.42; s2 <- 0.025
2 cut  <- function(q2) (mu1+mu2)/2 + s2*log((1-q2)/q2)/(mu2-mu1)
3 post2 <- function(x,q2){ f1 <- dnorm(x,mu1,sqrt(s2)); f2 <- dnorm(x,mu2,
4                               sqrt(s2))
5                               q2*f2/(q2*f2+(1-q2)*f1) }
6 for(q2 in c(0.5,46/140,0.05))
  cat(sprintf("q2=%.3f  界值=%.3f  x=0.45时P(胃癌|x)=%.3f\n", q2,cut(q2),
    post2(0.45,q2)))
```

```
q2=0.500  界值=0.330  x=0.45时P(胃癌|x)=0.703
q2=0.329  界值=0.429  x=0.45时P(胃癌|x)=0.537
q2=0.050  界值=0.739  x=0.45时P(胃癌|x)=0.111
```

同一检测值 0.45, 等先验时胃癌的后验概率为 70%; 若用于胃癌仅占 5% 的门诊人群, 后验概率仅为 11%。这与筛检试验中阳性预测值依赖患病率的原理相同: 患病率低时, 即使指标偏高, 多数人仍未患病。

因此, 先验概率应反映判别规则拟应用人群的构成, 不能任意设定。训练样本按病例、对照分别收集时 (如本例 46 例与 94 例), 样本中的比例不代表目标人群的患病率。若漏诊的代价远高于误诊, 还应按 4.4.4 节的方法考虑误判代价, 此时界值将进一步降低。

4.4.3 贝叶斯判别准则

设 K 个总体 $G_1, \dots, G_K$ 的先验概率为 $q_1, \dots, q_K$, $q_k > 0$ 且 $\sum q_k = 1$, 各类的类条件密度为 $f_1(x), \dots, f_K(x)$ (不必是正态), 则

$$P(k | X) = \frac{q_k f_k(X)}{\sum_{j=1}^K q_j f_j(X)}, \quad k = 1, \dots, K. \quad (4.7)$$

若样品 X 属于第 g 类的后验概率最大, 判 X 属于第 g 类。再假定 f_k 为多元正态密度, 就得到下面的线性或二次判别函数。

4.4.4 误判代价与最小风险判别

不同的误判后果往往不同: 把胃癌判为非胃癌, 比反过来严重得多。记 $L(j, k) \geq 0$ 为真实类别为 k 的样品被判为 j 的损失, $L(k, k) = 0$ 。把 X 判为 j 的条件风险 (期望损失) 为

$$R(j | X) = \sum_{k=1}^K L(j, k) P(k | X),$$

最优判别把 X 判给使 $R(j | X)$ 最小的类别 j 。

证明 (0-1 损失下即最大后验准则) 取 $L(j, k) = 1 (j \neq k)$ 、 $L(k, k) = 0$, 则 $R(j | X) = \sum_{k \neq j} P(k | X) = 1 - P(j | X)$ 。使 $R(j | X)$ 最小, 就是使 $P(j | X)$ 最大。□

两类时, 判为 1 类的条件是 $R(1 | X) < R(2 | X)$, 即 $L(1, 2)P(2 | X) < L(2, 1)P(1 | X)$, 也即

$$\frac{f_1(X)}{f_2(X)} > \frac{q_2 L(1, 2)}{q_1 L(2, 1)}.$$

提高漏诊胃癌的损失, 判为胃癌的门槛就相应降低。

4.4.5 Bayes 线性判别函数

由后验概率公式取对数,

$$\log P(k | X) = \log q_k + \log f_k(X) - \log \sum_{j=1}^K q_j f_j(X).$$

最后一项对所有类别相同, 比较后验概率只需比较 $\log q_k + \log f_k(X)$ 。总体协方差阵相等时, 再舍弃对各类相同的项, 可得到线性判别函数。线性判别函数值最大的类别为判定类别。

多元正态密度的展开

$$\begin{aligned} f_k(x) &= \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{1/2}} \exp \left[-\frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) \right], \\ \log f_k(x) &= -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k), \\ G_k(x) &= \log f_k(x) + \log q_k \\ &= -\frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k| + \log q_k + C. \end{aligned}$$

$C = -\frac{p}{2} \log(2\pi)$ 为可忽略常数。展开平方项:

$$\begin{aligned} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) &= x^T \Sigma_k^{-1} x - 2\mu_k^T \Sigma_k^{-1} x + \mu_k^T \Sigma_k^{-1} \mu_k, \\ G_k(x) &= -\frac{1}{2} x^T \Sigma_k^{-1} x + \mu_k^T \Sigma_k^{-1} x - \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k - \frac{1}{2} \log |\Sigma_k| + \log q_k. \end{aligned}$$

协方差阵相等

若 $\Sigma_1 = \dots = \Sigma_K = \Sigma$, 则

$$G_k(x) = -\frac{1}{2}x^T\Sigma^{-1}x + \mu_k^T\Sigma^{-1}x - \frac{1}{2}\mu_k^T\Sigma^{-1}\mu_k - \frac{1}{2}\log|\Sigma| + \log q_k.$$

$-\frac{1}{2}x^T\Sigma^{-1}x$ 与 $-\frac{1}{2}\log|\Sigma|$ 对所有类相同, 在分类比较中抵消。

$$\begin{aligned} G_k(x) - G_j(x) &= \left(\mu_k^T\Sigma^{-1}x - \frac{1}{2}\mu_k^T\Sigma^{-1}\mu_k + \log q_k \right) \\ &\quad - \left(\mu_j^T\Sigma^{-1}x - \frac{1}{2}\mu_j^T\Sigma^{-1}\mu_j + \log q_j \right). \end{aligned}$$

判别函数简化为

$$G_k(x) = w_k^T x + w_{k0}, \quad w_k = \Sigma^{-1}\mu_k, \quad w_{k0} = -\frac{1}{2}\mu_k^T\Sigma^{-1}\mu_k + \log q_k. \quad (4.8)$$

在各类协方差矩阵相等、数据服从多元正态分布的假设下, 贝叶斯最优分类器为线性判别函数 (LDA)。

与距离判别的联系 协方差阵相等时, $G_k(x) = -\frac{1}{2}D_M^2(x, \mu_k) + \log q_k + (\text{与 } k \text{ 无关的项})$, 其中 $D_M^2(x, \mu_k) = (x - \mu_k)^T\Sigma^{-1}(x - \mu_k)$ 。再取等先验, 最大后验判别就是按马氏距离归入最近的重心, 也就是4.2节的距离判别 (合并 S)。先验不等时, 要在距离上加上 $-2\log q_k$ 的修正。

若 $\Sigma_k \neq \Sigma_j$, 二次项依赖类别, 无法抵消, 判别函数保留二次项, 形成二次判别分析 (QDA), 决策边界为二次曲面。此时除马氏距离外, 还要比较行列式项 $-\frac{1}{2}\log|\Sigma_k|$ 和先验项 $\log q_k$, 不能简单地用各组 S_k 算马氏距离、取最近者。

4.4.6 一元胃癌鉴别

例 10.2-1

某医院调查 140 例患者的生化指标吡啶乙酸 x_4 。46 名经临床确诊为胃癌, 94 名为非胃癌患者 (包括萎缩性胃炎患者)。两组指标均服从正态分布且方差齐性, 作 Bayes 判别, 先验概率暂取相等。

批注 本例和下一例中, 组 1 为非胃癌 (94 例), 组 2 为胃癌 (46 例), 与表 4.1 (组 1 为胃癌) 的编码不同。

批注 原例另标注 x_2 、 x_3 。

后验概率

$$f_i(x) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp \left[-\frac{1}{2} \left(\frac{x - \mu_i}{\sigma} \right)^2 \right], \quad i = 1, 2.$$

若两类总体方差相等, $\sigma^2 = MS_{\text{组内}} = 0.025$ 。两类指标分别服从 $N(0.24, 0.025)$ 与 $N(0.42, 0.025)$ 。

$$P(1|x) = \frac{q_1 f_1(x)}{q_1 f_1(x) + q_2 f_2(x)}, \quad P(2|x) = \frac{q_2 f_2(x)}{q_1 f_1(x) + q_2 f_2(x)}.$$

1 号观测 $x = 0.19$ 时, 按 $\mu_1 = 0.24$ 、 $\mu_2 = 0.42$ 、 $s^2 = 0.025$ 计算, $P(1|x) = 0.7326$ 、 $P(2|x) = 0.2674$, 判为组 1 (非胃癌)。原例的 0.72 来自软件按更高精度参数计算的结果, 见下文。

线性判别函数

$$\begin{aligned} u_i(x) &= \log q_i - \frac{1}{2} \mu_i^2 (\sigma^2)^{-1} + (\sigma^2)^{-1} \mu_i x, \\ \hat{u}_i(x) &= \log q_i - \frac{1}{2} \bar{x}_i^2 (s^2)^{-1} + (s^2)^{-1} \bar{x}_i x, \\ \hat{u}_1(x) &= \log \frac{1}{2} - \frac{1}{2} (0.24)^2 (0.025)^{-1} + (0.025)^{-1} 0.24x, \\ \hat{u}_2(x) &= \log \frac{1}{2} - \frac{1}{2} (0.42)^2 (0.025)^{-1} + (0.025)^{-1} 0.42x. \end{aligned}$$

分类函数系数	组 1	组 2
x_4	9.691	16.613
常数	-1.868	-4.145

按上面两位小数的参数, $\hat{u}_1(x) = -1.845 + 9.600x$ 、 $\hat{u}_2(x) = -4.221 + 16.800x$, $x = 0.19$ 时 $\hat{u}_1 = -0.0211$ 、 $\hat{u}_2 = -1.0291$ 。

SPSS 分类函数系数(上表)对应的参数精度更高: $\bar{x}_1 = 0.24239$ 、 $\bar{x}_2 = 0.41554$ 、 $s^2 = 0.025012$ 。 $x = 0.19$ 时 $u_1 = -0.0264$ 、 $u_2 = -0.988$, 与原例一致。两套参数都判为组 1 (非胃癌)。同一题中的参数、函数系数和后验概率应采用同一精度, 不宜混用。

转换为后验概率

令 $Y_1 = u_1(x)$ 、 $Y_2 = u_2(x)$ 、 $Y_c = \max(Y_1, Y_2)$, 则

$$P(1|x) = \frac{e^{Y_1 - Y_c}}{e^{Y_1 - Y_c} + e^{Y_2 - Y_c}}, \quad P(2|x) = \frac{e^{Y_2 - Y_c}}{e^{Y_1 - Y_c} + e^{Y_2 - Y_c}}.$$

按 SPSS 精度, 1 号观测的 $P(1|x) = 1/(1 + e^{-0.988+0.0264}) = 0.7235$; 按两位小数的参数为 0.7326。都判为组 1 (非胃癌)。

4.4.7 二元胃癌鉴别

例 10.2-2

140 例患者中, 46 名为胃癌, 94 名为非胃癌 (包括萎缩性胃炎患者)。两项生化指标为水试验 x_1 和吡啶乙酸 x_4 。两组指标服从二元正态分布, 总体协方差阵相等, 作 Bayes 判别, 先验概率暂取相等。组 1 为非胃癌, 组 2 为胃癌。

后验概率计算

$$\Sigma_1 = \Sigma_2 = \Sigma, \quad X | G_i \sim N_p(\mu_i, \Sigma), \quad P(i | X) = \frac{q_i f_i(X)}{q_1 f_1(X) + q_2 f_2(X)}.$$

用合并协方差阵 S_c 估计 Σ , 用各组样本均值向量 $\bar{X}_i$ 估计 μ_i 。

	组 1	组 2
x_1 均值	0.27660	2.96739
x_4 均值	0.24239	0.41554

$$S_c = \begin{bmatrix} 0.884 & 0.023 \\ 0.023 & 0.025 \end{bmatrix}, \quad df = 138.$$

```

1 library(mvtnorm)
2 m1 <- c(.2766, .24239)
3 m2 <- c(2.96739, .41554)
4 cov <- matrix(c(.884, .023, .023, .025), 2, 2)
5 X <- c(0, .19)
6 fx1 <- dmvtnorm(X, mean = m1, sigma = cov)
7 fx2 <- dmvtnorm(X, mean = m2, sigma = cov)
8 p1 <- fx1 / (fx1 + fx2); p1
9 p2 <- fx2 / (fx1 + fx2); p2

```

$$P(1 | X) = 0.9952562, \quad P(2 | X) = 0.004743808.$$

1 号观测 $X = (0, 0.19)^T$ 属于组 1 (非胃癌) 的概率约为 0.995。

线性判别函数

$$u_i(x) = \log q_i - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i + \mu_i^T \Sigma^{-1} x, \quad (4.9)$$

$$\hat{u}_i(x) = \log q_i - \frac{1}{2} \bar{X}_i^T S_c^{-1} \bar{X}_i + \bar{X}_i^T S_c^{-1} x. \quad (4.10)$$

```

1 log(0.5) - 0.5 * t(m1) %*% solve(cov) %*% m1
2 solve(cov) %*% m1
3 log(0.5) - 0.5 * t(m2) %*% solve(cov) %*% m2
4 solve(cov) %*% m2

```

R 计算系数	组 1	组 2
常数	-1.86987	-8.019123
x_1	0.06212183	2.996028
x_4	9.63844792	13.865254

按上面输入的参数,

$$\hat{u}_1(x) = -1.870 + 0.062x_1 + 9.638x_4,$$

$$\hat{u}_2(x) = -8.019 + 2.996x_1 + 13.865x_4.$$

SPSS 的系数与此略有差别, 是因为上面的 S_c 只保留了 3 位小数, SPSS 用的是全精度的合并协方差阵。

SPSS 分类函数系数	组 1	组 2
x_1	0.059	2.992
x_4	9.635	13.829
常数	-1.869	-8.006

4.4.8 三组胃癌数据的线性判别

回到表4.1的数据 (组 1 胃癌、组 2 萎缩性胃炎、组 3 非胃病者), 使用 x_2, x_3 两项指标, 各组先验概率为 1/3。

类别	先验概率	未加权例数	加权例数
胃癌	0.333	5	5.000
萎缩性胃炎	0.333	5	5.000
非胃病者	0.333	5	5.000
合计	1.000	15	15.000

```

1 d1 <- d[g == 1, c("x2", "x3")]; d2 <- d[g == 2, c("x2", "x3")]; d3 <- d[g ==
  3, c("x2", "x3")]
2 m1 <- colMeans(d1); m2 <- colMeans(d2); m3 <- colMeans(d3)
3 S <- (cov(d1)*4 + cov(d2)*4 + cov(d3)*4) / (15 - 3) # 合并协方差阵
4 solve(S) %*% m1; -0.5 * t(m1) %*% solve(S) %*% m1 + log(1/3)
5 solve(S) %*% m2; -0.5 * t(m2) %*% solve(S) %*% m2 + log(1/3)
6 solve(S) %*% m3; -0.5 * t(m3) %*% solve(S) %*% m3 + log(1/3)

```

系数	胃癌	萎缩性胃炎	非胃病者
x_2	0.6623687	0.52386820	0.5647306
x_3	0.3123956	-0.03120344	-0.2146332
常数	-53.06427	-31.11182	-34.84117

SPSS 分类函数系数:

	胃癌	萎缩性胃炎	非胃病者
x_2	0.662	0.524	0.565
x_3	0.312	-0.031	-0.215
常数	-53.064	-31.112	-34.841

后验概率

```

1 out <- lda(g ~ x2 + x3, data = d, prior = rep(1/3, 3)) #
  注意与Fisher例的 out 不同
2 predict(out)$posterior

```

表 4.7 三类后验概率 (x_2 , x_3 , 等先验)

观测	$P(1 X)$	$P(2 X)$	$P(3 X)$
1	0.9658451720	0.0297968387	0.0043579891
2	0.3526390520	0.3379283779	0.3094325701
3	0.9831064460	0.0049056704	0.0119878834
4	0.4572207440	0.1339336178	0.4088456380
5	0.9995009550	0.0003192242	0.0001798207
6	0.0485141560	0.4532963773	0.4981894665
7	0.0016103370	0.6767118343	0.3216778288
8	0.0193343320	0.5470700752	0.4335955932
9	0.3259334020	0.3587344893	0.3153321082
10	0.0010730780	0.6358308799	0.3630960417
11	0.0065175190	0.4836625296	0.5098199512
12	0.0316765680	0.4173256165	0.5509978157
13	0.1195197350	0.2107898241	0.6696904408
14	0.0007677290	0.4211022759	0.5781299951
15	0.0193343320	0.5470700752	0.4335955932

以 $x_2 = 134, x_3 = 20$ 为例:

```

1 f1 <- 0.6623687 * 134 + 0.3123956 * 20 - 53.06427
2 f2 <- 0.52386820 * 134 - 0.03120344 * 20 - 31.11182
3 f3 <- 0.5647306 * 134 - 0.2146332 * 20 - 34.84117
4 f <- max(f1, f2, f3) # 减去最大值, 防止 exp() 溢出
5 exp(f1 - f) / (exp(f1 - f) + exp(f2 - f) + exp(f3 - f))
6 library(mvtnorm) # m1--m3、S 沿用上文
7 S
8 X <- c(134, 20)
9 fx1 <- dmvtorm(X, mean = m1, sigma = S)
10 fx2 <- dmvtorm(X, mean = m2, sigma = S)

```

```

11  fx3 <- dmvnorm(X, mean = m3, sigma = S)
12  fx1 / (fx1 + fx2 + fx3)
13  fx2 / (fx1 + fx2 + fx3)
14  fx3 / (fx1 + fx2 + fx3)

```

$$S = \begin{bmatrix} 220.3667 & 14.20000 \\ 14.2000 & 14.06667 \end{bmatrix}.$$

线性判别函数计算得 $P(1 | X) = 0.965845$ 。正态密度计算得

$$P(1 | X) = 0.9658452, \quad P(2 | X) = 0.02979684, \quad P(3 | X) = 0.004357989.$$

判别效果 按表4.7中后验概率最大的类别回代，混淆矩阵如下（第8、15例的 x_2 、 x_3 完全相同，后验概率也相同）：

真实组别	回代判为			回代正确率	留一法正确率
	G_1	G_2	G_3		
G_1 胃癌	5	0	0	100%	60%
G_2 萎缩性胃炎	0	4	1	80%	60%
G_3 非胃病者	0	1	4	80%	40%
合计				13/15 = 86.7%	8/15 = 53.3%

留一法 (`lda(..., CV = TRUE)`) 的正确率比回代低了三分之一以上。与四变量模型（回代 80%，留一法 33.3%）相比，两变量模型的回代和预测正确率都更高，说明变量多并不一定判得更准。但若 x_2 、 x_3 是看过全部数据后挑出来的，53.3% 仍然偏乐观，变量选择应放在每一折的训练样品内完成。

4.4.9 Bayes 二次型判别函数

若各类总体协方差阵不相等，不能用 S_c 估计 Σ 。此时待判变量在判别函数中为二次型，称为二次型判别函数。记第 k 类的二次判别函数为 $Q_k(X)$ （教材式 10.12、10.13 记作 $Z^2(k | X)$ ，协方差阵记作 V_k ），实际计算时以各组 S_k 估计 Σ_k ：

$$Q_k(X) = \log q_k - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (X - \mu_k)^T \Sigma_k^{-1} (X - \mu_k) \quad (4.11)$$

$$= \log q_k - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} \mu_k^T \Sigma_k^{-1} \mu_k - \frac{1}{2} X^T \Sigma_k^{-1} X + X^T \Sigma_k^{-1} \mu_k. \quad (4.12)$$

$Q_k(X)$ 最大的类别为判定类别。与线性情形相比，多了随类别变化的二次项 $-\frac{1}{2} X^T \Sigma_k^{-1} X$ 和行列式项 $-\frac{1}{2} \log |\Sigma_k|$ ；先验项 $\log q_k$ 照样保留。若考虑误判代价，按4.4.4节以后验概率计算条件风险。QDA 每组要估计 $p(p+1)/2$ 个协方差参数，各组例数应明显多于 p ，本章三组各 5 例的数据不宜使用。协方差阵相等时的线性函数为

$$u_i(x) = \log q_i - \frac{1}{2} \mu_i^T \Sigma^{-1} \mu_i + \mu_i^T \Sigma^{-1} x.$$

本章小结：判别分析

	用已知类别的训练样本建立判别规则，对新样品归类（有监督）
研究目的	
优化准则或统计模型	距离判别：归入马氏距离最近的重心；Fisher 判别：最大化 $J(a) = a^T B a / a^T W a$ ，解 $W^{-1}B$ 的特征问题；Bayes 判别：最大后验概率，或一般地最小条件风险 $R(j x) = \sum_k L(j,k)P(k x)$
主要条件	用合并 S 时要求各组协方差阵相等（Box M 检验需多元正态、样本量足够）；正态 Bayes 判别要求组内多元正态；先验应反映目标人群构成； W 或 S_k 须可逆
结果解释	判别函数系数与得分、典型相关与特征根贡献比例（分离程度）、后验概率；用混淆矩阵、各类正确率和留一法/交叉验证的预测误判率评价效果
常见误用	只报告回代正确率；把 Box M 检验 $P > \alpha$ 当作协方差阵相等的证据；小样本用各组 S_k 造成“完美回代”；把判别函数个数说成 $\min(g - 1, m)$ 个“分类数”；用病例对照样本比例作先验；在全部数据上筛选变量后再做交叉验证

复习题

- 1) 比较聚类分析与判别分析的根本区别。
答：判别分析的训练样品类别已知（有监督），目的是建立规则判别新样品；聚类分析事先不知道类别（无监督），目的是从数据中发现分组。
- 2) 3 组、5 个变量作 Fisher 判别，写出判别函数的最大个数。
答： $\min(K - 1, p) = \min(2, 5) = 2$ 个。
- 3) 第一判别函数的特征值 $\lambda_1 = 2.864$ ，计算对应的典型相关系数。
答： $R^2 = \lambda / (1 + \lambda) = 0.741$ ， $R = 0.861$ 。
- 4) 写出 Bayes 判别与基于合并协方差阵的距离判别等价的条件。
答：各类多元正态、协方差阵相等、先验概率相等（且误判代价相等）。
- 5) 某判别规则的回代正确率为 80%，留一法正确率为 33%，解释这一结果。
答：规则对训练样本过度拟合，判别新样品的能力很差；应报告留一法或交叉验证的结果，并考虑减少变量或增加样本量。
- 6) 说明不宜直接以病例对照研究中病例所占比例作为先验概率的原因。
答：病例、对照的人数由研究设计决定，不反映判别规则将要使用的人群中的患病率。

第4章 习题与解析

判别分析

往年题

单项选择题

题 4.1 文献中的研究设计

所指原始文献、图 1 及完整数据没有随题卷提供。以下保留设问；不能据此独立核验文献中的具体研究事实。

从获取资料的方法看，该研究设计最接近哪一种？

- A. 病例对照设计。
- B. 队列设计。
- C. 横断面设计。
- D. 配对设计。
- E. 分层随机抽样设计。

题 4.2 利用文献指标建立诊断模型

所指原始文献、图 1 及完整数据没有随题卷提供。以下保留设问；不能据此独立核验文献中的具体研究事实。

若要利用该数据建立诊断模型，最好的做法是：

- A. 用原 15 项指标建立 Logistic 模型。
- B. 用 8 项指标建立 Logistic 模型。
- C. 用 8 项指标作 Fisher 线性判别。
- D. 寻找合适先验，用 8 项指标建立 Bayes 判别。
- E. 以所得第 1、第 2 因子为综合指标进行两类判别。

题 4.3 三类两指标的判别函数

类别数 $k = 3$ 、指标数 $m = 2$ ，以下哪项符合课程中的常见判别模型？

- A. 需建立 3 个 Bayes 类别判别函数。
- B. Bayes 线性判别应判入后验概率最小类。
- C. Bayes 判别无需对数据分布作任何假设。
- D. 需建立 3 个典型判别函数。
- E. 构造典型判别方向必须假定多元正态。

题 4.4 先验概率的解释与估计

关于判别分析的先验概率，说法错误的是：

- A. 先验概率既可以是主观的，又可以是客观的。
- B. 同一训练样本用于不同场景，可采用不同先验。
- C. 对于给定的样本，后验概率与先验概率成正比。
- D. 一般而言，用训练样本类别百分率代替先验概率是最佳的。
- E. 医生在诊断时可能自觉或不自觉使用先验概率。

题 4.5 判别考核的错判率

一般而言，三种判别考核的错判率由大到小排列为：

- A. 刀切法、回代法、前瞻性考核。
- B. 前瞻性考核、刀切法、回代法。
- C. 刀切法、前瞻性考核、回代法。
- D. 前瞻性考核、回代法、刀切法。
- E. 回代法、刀切法、前瞻性考核。

题 4.6 判别考核的错判率

一般而言，三种判别考核的错判率由大到小排列为：

- A. 刀切法、回代法、前瞻性考核。
- B. 前瞻性考核、刀切法、回代法。
- C. 刀切法、前瞻性考核、回代法。
- D. 前瞻性考核、回代法、刀切法。
- E. 回代法、刀切法、前瞻性考核。

题 4.7 判别函数的分类规则

关于判别函数，正确的是：

- A. 原变量足够多时，典型判别最多产生 k 个指标 (k 为类数)。
- B. 典型判别的新指标应使类内方差尽可能大。
- C. 典型判别时，应判入距离 $d(r)$ 最大的一类。
- D. Bayes 线性判别在等代价下应判入后验概率最大类。
- E. Bayes 线性判别只需建立 $k-1$ 个类别评分函数。

题 4.8 典型判别的类别判定

关于判别函数，正确的是：

- A. 原变量足够多时，典型判别最多产生 k 个指标 (k 为类数)。
- B. 典型指标的类间方差与类内方差之比应尽量小。
- C. 典型判别可按待判样品与类别中心的适当距离判断类别。
- D. Bayes 线性判别对数据分布没有任何要求。
- E. Bayes 线性判别需要 $k-1$ 个类别评分函数。

题 4.9 先验与后验的关系

判断下列说法：I. 先验可以来自主观和经验判断；II. 对于给定样本，后验与先验成正比；III. 医生诊断时可能自觉或不自觉使用先验。

按严格表述，哪些成立？

- A. 仅 I。
- B. 仅 II。
- C. 仅 III。
- D. I 与 II。
- E. I、II 与 III。
- F. I 与 III。

题 4.10 个体指标与总体关联指标

以下哪个指标与其余指标有明显不同？

- A. 主成分得分。
- B. 因子得分。
- C. 欧氏距离。
- D. 典型相关系数。
- E. 依据第一主成分计算的加权平均分。

题 4.11 一般 Bayes 判别的适用范围

对于一般 Bayes 判别原则，适用范围最全面的表述是：

- A. 仅适用于正态且协方差相等的总体。
- B. 仅适用于正态且协方差不等的总体。
- C. 仅适用于非正态且协方差相等的总体。
- D. 仅适用于非正态且协方差不等的总体。
- E. 不局限于正态；只要能合理建立类条件概率或密度，就可按后验风险决策。

题 4.12 判别正确率的经验排序

按教材的一般经验，回代、刀切和前瞻性考核的正确率常呈何种排序？

- A. 回代 > 刀切 > 前瞻性。
- B. 刀切 > 回代 > 前瞻性。
- C. 前瞻性 > 回代 > 刀切。
- D. 三者必然完全相同。
- E. 刀切一定等于 100%。

题 4.13 典型轴与 Bayes 类别函数

有 p 个指标、 k 类，且需要区分的方向满秩。下列关于指标数与分类规则的组合哪项正确？

- A. 典型轴最多 $\min(p, k-1)$ 个；通常有 k 个 Bayes 类别评分；等损失时取后验最大类。
- B. 典型轴最多 k 个；Bayes 取后验最小类。
- C. 典型轴总有 $p+k$ 个；Bayes 取距离最大类。
- D. 典型轴只有 1 个；Bayes 无需先验或损失。
- E. 典型轴和 Bayes 类别函数均固定为 $k-1$ 个。

题 4.14 后验概率与分类代价

两类后验概率为 0.6、0.4。把第 1 类错判为第 2 类损失 10，反向损失 1，正确分类损失 0。应判为：

- A. 第 1 类。
- B. 第 2 类。
- C. 任意一类，损失相同。
- D. 必拒绝分类。
- E. 仅依赖哪个训练样本数更少。

题 4.15 协方差不同的正态 Bayes 模型

各类均假定正态且协方差不同，一般形成哪种 Bayes 判别边界？

- A. 二次边界。
- B. 必为通过原点的直线。
- C. 只能使用一个阈值且不能有交叉项。
- D. 无法计算后验。
- E. 不受先验影响。

题 4.16 灵敏度的分母

二分类中以疾病为阳性，灵敏度等于：

- A. $TP/(TP + FN)$ 。
- B. $TN/(TN + FP)$ 。
- C. $TP/(TP + FP)$ 。
- D. $(TP + TN)/N$ 。
- E. $FP/(FP + TN)$ 。

题 4.17 回代正确率的局限

模型在训练数据上的回代正确率很高，最合理的判断是：

- A. 已经证明可以推广至所有人群。
- B. 可以省去任何外部验证。
- C. 可能有乐观偏倚，应使用不泄漏信息的交叉验证或独立验证。
- D. 模型必定有因果解释。
- E. 一定比其他模型临床收益更高。

简答题**题 4.18 典型判别、Bayes 判别与先验概率**

典型判别和 Bayes 判别有何区别？请谈谈先验概率在判别分析中的作用。共 20 分。

题 4.19 先验概率在医学实践中的作用

请结合医学实践谈谈先验概率的作用。共 20 分。

题 4.20 Bayes 先验概率的确定方法

写出 Bayes 判别时确定先验概率的几种主要方法。

计算与分析题

题 4.21 耳形的 Fisher 或 Bayes 判别

对 ear 数据作判别分析。Fisher 法与 Bayes 法任选其一，以 EX 为分组，以 EC、EZ、EK、EI、AI 为判别依据。共 20 分。

1. 若选择 Fisher 法，给出 4 个判别函数；若选择 Bayes 法，给出 5 个判别函数。
2. 给出各类别与总体判别正确率。
3. 某人的 EC、EZ、EK 分别为.....，请按方法判定耳型；EI 和 AI 需由公式计算。

$EI=100EK/EC$, $AI=100EZ/EK$ 。第 3 问的具体原始三项数值未被记录。

题 4.22 视网膜病变：变量筛选与 Bayes 判别

E23.1 数据研究糖尿病患者视网膜病变，分轻、中、重三型。指标为年龄 age、患病年数（题写 year，数据列名 time）、血糖 glucose、视力 vision、a 波峰时 at 及振幅 av、b 波峰时 bt 及振幅 bv、qp 波峰时 qpt 及振幅 qp v。前 131 行是训练记录，第 132 行为待判样本。1. 用所有指标求典型判别函数，按原变量“分类相对重要性 >5%”筛选，列出计算结果及保留变量。（4 分）2. 取训练样本率为先验，以保留变量进行 Bayes 判别；先排除末行待判样本。- 检验各总体协方差是否不等， $\alpha = 0.1$ ，报告统计量和结论。（4 分）- 列出 case1、case100、case130 的 Bayes 判别函数值。（4 分）- 回代判别并报告总体一致率。（4 分）- 判定第 132 行，列出函数值和分类。（4 分）

题 4.23 视网膜病变：典型相关与重要性

E23.1 数据研究糖尿病患者视网膜病变，分轻、中、重三型。指标为年龄 age、患病年数（题写 year，数据列名 time）、血糖 glucose、视力 vision、a 波峰时 at 及振幅 av、b 波峰时 bt 及振幅 bv、qp 波峰时 qpt 及振幅 qp v。前 131 行是训练记录，第 132 行为待判样本。用全部 10 个指标做典型判别分析，填写：

1. 两个典型相关系数。
2. 两个典型判别变量的相对重要性。
3. 按分类相对重要性从大到小排列的前 4 个原始变量。

题 4.24 血脂与心梗的 Bayes 二分类

根据血脂与心梗练习数据，作 Bayes 二分类；两类先验均 0.5，误判与漏判损失均 0.5。

1. 列出组内及合并协方差矩阵，检验总体协方差是否相等。
2. 计算回代总体一致率。
3. 计算灵敏度和特异度。

原 Excel 为左右并排的两组，各 30 人；请先转换为 60 行长表。本题按参考解答的组编码约定：左侧组记 0、右侧组记阳性 1。

文献分析题**题 4.25 诊断准确率 95.3% 的评议**

所指原始文献、图 1 及完整数据没有随题卷提供。以下保留设问；不能据此独立核验文献中的具体研究事实。

结合图 1，对作者所谓 95.3% 的准确率作剖析。

补充练习

本节为配合正文新编的补充练习。除注明沿用正文例题外，数值与研究摘要均为教学设定。题型与作答方式沿用本章往年题，解析见章末。

单项选择题

题 4.26 判别函数值换算后验概率

某三分类 Bayes 模型在一个待判样品上的类别评分为 $u_1 = 1000$ 、 $u_2 = 999$ 、 $u_3 = 998$ 。评分已包含先验项，且仅略去各类共同的项。按正文的指数归一化方法，第 1 类后验概率约为多少？已知 $e^{-1} = 0.3679$ ， $e^{-2} = 0.1353$ 。

- A. 1.0000。
- B. 0.3337。
- C. 0.5000。
- D. 0.2447。
- E. 0.6652。

简答题

题 4.27 最近马氏距离与最大后验的关系

在多元正态、误判代价相等的条件下，有人认为“到哪个类别中心的马氏距离最小，Bayes 判别就一定归入哪一类”。这句话在什么条件下成立？当各类协方差矩阵不相等时，只比较各类马氏距离漏掉了什么？

计算与分析题

题 4.28 先验概率改变后的判别界值

某数值指标 X 用于区分两个类别，教学设定为

$$X | G_1 \sim N(0, 1), \quad X | G_2 \sim N(2, 1),$$

其中正态分布的第二参数为方差。两种误判代价相等，正确分类代价为 0。共 15 分。

1. 当 $q_1 = q_2 = 0.5$ 时，写出两类线性 Bayes 评分，求分类界值。(5 分)
2. 对 $x = 1.2$ ，计算属于第 2 类的后验概率并分类。(4 分)
3. 保持两类条件分布不变，将先验改为 $q_1 = 0.8$ 、 $q_2 = 0.2$ 。重新计算界值及该样品的第 2 类后验概率，解释类别是否改变。(6 分)

可用 $\log 4 = 1.3863$ 、 $e^{0.4} = 1.4918$ 。

题 4.29 Fisher 方向与主成分方向的比较

有 3 个类别、2 个尺度可比的数值指标。组内离差阵 W 与组间离差阵 B 为

$$W = \begin{pmatrix} 100 & 0 \\ 0 & 1 \end{pmatrix}, \quad B = \begin{pmatrix} 25 & 0 \\ 0 & 4 \end{pmatrix}.$$

本题 Fisher 方向取普通欧氏长度为 1 的特征向量，首个非零系数取正。共 15 分。

1. 求两个 Fisher 判别方向及各自的分离度，并写出判别变量。(5 分)
2. 计算两个典型相关系数及按特征值定义的相对分类能力。(5 分)
3. 若对同一资料直接作协方差阵 PCA，第一主成分沿哪个原指标方向？为什么与第一 Fisher 方向不同？(5 分)

文献分析题

题 4.30 分类研究摘要与回代结果评议

以下为模拟研究摘要，不对应真实论文。研究者按已知类别各选取 30 例，共 90 例，建立三分类 Bayes 模型。使用同一批 90 例拟合并回代，得到下表。

实际类别	判为 1	判为 2	判为 3
1	27	2	1
2	3	24	3
3	0	6	24

作者称：“因三组人数相等，应用人群的先验概率必为各 $1/3$ ；回代总体正确率超过 80%，已证实本模型用于新对象时也有相同正确率。”共 15 分。

1. 计算三类各自的回代正确率及总体回代正确率。(5 分)
2. 评价先验概率的设定及其理由。(5 分)
3. 评价对新对象分类能力的结论，并写出一种更合适的考核办法。(5 分)

习题解析

核对方式

按题号核对。补写题目、原稿歧义及复算约定列在对应解析中。

解析 题 4.1 文献中的研究设计

[返回题目](#)

答案：原参考标 A，缺文献待核实。

若研究按是否患病选入病例、对照后比较既往暴露或指标，可属于病例对照设计；若按暴露随访则是队列。不能只凭其后用了判别分析决定研究设计。

解析 题 4.2 利用文献指标建立诊断模型

[返回题目](#)

答案：原参考标 E，缺文献待核实。

使用因子得分可能减轻共线性、降低维数，但也可能丢失有用判别信息。不存在脱离样本量、变量筛选与验证结果而永远最优的方法；应比较校准、区分度、内部/外部验证和临床代价。

解析 题 4.3 三类两指标的判别函数

[返回题目](#)

答案：A。

3 类通常对应 3 个类别评分函数；有效典型轴最多 $\min(2, 3 - 1) = 2$ 。等代价下取后验最大类。一般 Bayes 原则可以用于非正态模型，但仍需合理的类条件概率/密度，不能把“无需正态”误作“无需概率模型”。

解析 题 4.4 先验概率的解释与估计

[返回题目](#)

答案：原参考 C；严格看 C、D 均需修正。

后验满足 $P(G = k | x) = \pi_k f_k(x) / \sum_l \pi_l f_l(x)$ ，仅说与 π_k 成正比漏掉类条件密度及归一化。D 也不普遍成立：按类选样或病例对照数据的比例不代表目标总体。原单选题措辞不能保证严格唯一答案；不能为凑单选而认可 D 的“最佳”断言。

解析 题 4.5 判别考核的错判率

[返回题目](#)

答案：B（经验口径）。

回代使用训练过的样本，通常最乐观；刀切留一较接近样本外误差；前瞻性独立人群可能更难，教材常用 B 排序。有限样本下三者没有必然大小关系，实际误差受随机波动与人群漂移影响。原 2021 回忆标 C、参考解标 B，此处区分记录差异与统计事实。

解析 题 4.6 判别考核的错判率

[返回题目](#)

答案：B（经验口径）。

回代使用训练过的样本，通常最乐观；刀切留一较接近样本外误差；前瞻性独立人群可能更难，教材常用 B 排序。有限样本下三者没有必然大小关系，实际误差受随机波动与人群漂移影响。原 2021 回忆标 C、参考解标 B，此处区分记录差异与统计事实。

解析 题 4.7 判别函数的分类规则[返回题目](#)

答案：D。

有效典型轴最多 $\min(p, k-1)$ ，目的是增大类间相对类内变异；距离规则取距离小者。Bayes 按最大后验或最小期望损失决策。

解析 题 4.8 典型判别的类别判定[返回题目](#)

答案：C。

典型判别最大化类间/类内变异；最大轴数为 $k-1$ 与 p 的较小值。D 在参考答案稿中有记录，用该版本补齐回忆稿空白，不是新编。

解析 题 4.9 先验与后验的关系[返回题目](#)

答案：F。

II 遗漏类条件密度和归一化，不能孤立地断言后验只与先验成正比。I 与 III 成立。

补写说明。原题 A—E 未提供“I 与 III”组合；保留原有选项并补入 F，使修订题有严谨可选的答案。原稿曾标 E，另一参考稿也对 II 提出疑问。

解析 题 4.10 个体指标与总体关联指标[返回题目](#)

答案：D。

典型相关系数概括两组变量在样本/总体层面的线性关联，是整体分析量；得分与加权分对应个体，距离通常对应一对个体或个体与中心。严格说距离也与单个得分的索引结构不同，本题按原意选 D。

解析 题 4.11 一般 Bayes 判别的适用范围[返回题目](#)

答案：E。

一般 Bayes 决策原理不限正态；常用线性/二次正态判别只是其特例。不能说既与总体分布无关、又完全不需要概率模型。

补写说明。原稿 E 只记大意、C/D 重复且提问不全；补全“仅适用”表述并修复 D 为协方差相等，以区分一般 Bayes 原则与正态判别特例。

解析 题 4.12 判别正确率的经验排序[返回题目](#)

答案：A。

训练集回代一般最乐观；留一与前瞻性更接近样本外表现。但这不是任意样本中必成立的数学排序，独立验证的难度还与目标人群有关。

补写说明。2019 回忆稿只记录主题，没有完整题干与选项；本题依据该主题补写，不宣称恢复原选项。

解析 题 4.13 典型轴与 Bayes 类别函数[返回题目](#)

答案：A。

典型空间维数受变量数与组间秩限制；Bayes 可以写 k 个类别评分，也可用相对一个参照类的 $k-1$ 个差值，二者只是等价表达，不能混淆为典型轴个数。

补写说明。2019 回忆稿只记录主题，没有完整题干与选项；本题依据该主题补写，不宣称恢复原选项。

解析 题 4.14 后验概率与分类代价[返回题目](#)

答案：A。

判第 1 类的条件风险为 $1 \times 0.4 = 0.4$ ；判第 2 类风险为 $10 \times 0.6 = 6$ 。选择前者。

补写说明。2019 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 4.15 协方差不同的正态 Bayes 模型[返回题目](#)

答案：A。

高斯对数密度含类特定逆协方差的二次型；共同协方差时相同二次项才相消为线性规则。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 4.16 灵敏度的分母[返回题目](#)

答案：A。

灵敏度是在实际患病者中被判为阳性的比例；特异度是在实际无病者中被判为阴性的比例。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 4.17 回代正确率的局限[返回题目](#)

答案：C。

预处理、变量筛选、因子提取与拟合应在每个训练折内部完成，再对未参与这些步骤的验证折评估。

补写说明。2021 卷该部分仅有总题数和部分回忆，整题内容未记录。本题为按课程知识点新编的补充练习，不是恢复的往年原题；编号只用于本包覆盖核对。

解析 题 4.18 典型判别、Bayes 判别与先验概率[返回题目](#)

典型/Fisher 判别寻找使组间变异相对组内变异尽量大的线性组合，最多有 $\min(p, k-1)$ 个有效典型轴；分类可在典型空间按适当距离、共同协方差及规则处理。作为构造判别方向的方法，不必先假定正态，但某些显著性检验需要分布前提。

Bayes 判别先结合类条件分布与先验概率，计算后验概率或后验误判风险。等误判损失时取后验概率最大类；一般损失时取条件期望损失最小类。正态且共同协方差给出线性规则，正态且协方差不同通常给出二次规则；一般 Bayes 原理不只适用于正态。

先验概率描述应用人群中各类出现机会,可由代表性样本比例、外部流行病学资料、专业经验或明确的等先验假定给出。训练数据按类别人为平衡抽样时,其类别比例不应直接当人群先验。先验会改变判别边界,调整灵敏度与特异度的取舍,但并不保证两者同时提高。

解析 题 4.19 先验概率在医学实践中的作用

[返回题目](#)

典型/Fisher 判别寻找使组间变异相对组内变异尽量大的线性组合,最多有 $\min(p, k-1)$ 个有效典型轴;分类可在典型空间按适当距离、共同协方差及规则处理。作为构造判别方向的方法,不必先假定正态,但某些显著性检验需要分布前提。

Bayes 判别先结合类条件分布与先验概率,计算后验概率或后验误判风险。等误判损失时取后验概率最大类;一般损失时取条件期望损失最小类。正态且共同协方差给出线性规则,正态且协方差不同通常给出二次规则;一般 Bayes 原理不只适用于正态。

先验概率描述应用人群中各类出现机会,可由代表性样本比例、外部流行病学资料、专业经验或明确的等先验假定给出。训练数据按类别人为平衡抽样时,其类别比例不应直接当人群先验。先验会改变判别边界,调整灵敏度与特异度的取舍,但并不保证两者同时提高。

例如同一个检测结果用于普通筛查人群与高风险专科门诊时,患病先验概率不同,后验患病概率也不同;临床判断应结合检查结果、病史和人群背景。模型的先验应与实际使用场景一致。

解析 题 4.20 Bayes 先验概率的确定方法

[返回题目](#)

(1) 若训练样本能代表应用总体,可用类别样本率;(2) 利用外部患病率/登记资料或其他可靠总体资料;(3) 根据专业知识和经验指定;(4) 缺乏可用信息时明确采用等先验,并做敏感性分析。病例对照式按组抽样的比例通常不等于总体先验。

解析 题 4.21 耳形的 Fisher 或 Bayes 判别

[返回题目](#)

选择 Fisher/典型判别。训练样本 300 人,5 类。复算的 4 个线性方向系数如下,列为 4 个函数:

变量	函数 1	函数 2	函数 3	函数 4
EC	8.01625	-11.50316	-14.47448	4.53311
EK	-11.42975	7.19042	29.59817	-21.49590
EZ	-8.65812	23.51615	-2.27270	19.00190
EI	0.87494	-1.35891	-1.94492	0.44230
AI	0.31286	-0.68655	0.02237	-0.68256

因此 $u_1 = 8.01625EC - 11.42975EK - 8.65812EZ + .87494EI + .31286AI$, 其余依列写出。典型方向的整体符号可改变。predict(lda_fit) 还使用组中心和先验完成分类,不能只凭单个 u_1 大小决定 5 分类。

回代混淆矩阵(行真类、列预测类):

实际类别	1	2	3	4	5
1	0	0	0	10	2
2	0	16	0	27	2
3	0	6	0	52	3
4	0	7	0	108	5
5	0	4	0	44	14

各类正确率依次 0、35.556%、0、90.000%、22.581%；总正确率 $(0+16+0+108+14)/300 = 46\%$ ，为回代结果，不能当外部预测正确率。

第3问先按原始三项计算两个指数，再用包含相同变量名与顺序的一行数据框调用预测；因三项数值缺失，无法确定该新人的类别。原参考代码的 `predict(out,c(...))` 不是可靠的新样本数据结构，应用 `data.frame(EC=...,EK=...,EZ=...,EI=...,AI=...)`。

解析 题 4.22 视网膜病变：变量筛选与 Bayes 判别

[返回题目](#)

按课程算法，先求标准化典型系数矩阵，各典型轴的系数单位化，再将各原变量的行平方和占总行平方和之比作为“相对重要性”。这是一种课程规定的指标，不是唯一的变量重要性定义。

所有原变量的重要性百分比如下：

变量	重要性%
vision	37.8938
at	28.0556
age	21.1977
bv	7.8943
qpv	1.4588
time	1.1147
qpt	0.9059
glucose	0.7399
bt	0.5548
av	0.1844

保留 **vision**、**at**、**age**、**bv**。不要按固定列号误选变量。前三组样本数为 68、43、20，先验为这些数除以 131。

Box M: $M = 32.6304$ ，校正卡方 30.6765， $df = 20$ ， $P = 0.05961$ ；在 0.1 水平拒绝协方差相等，采用各类协方差的二次 Bayes 函数

$$\delta_k(x) = \log \pi_k - \frac{1}{2} \log |S_k| - \frac{1}{2} (x - \bar{x}_k)^T S_k^{-1} (x - \bar{x}_k).$$

case 指数据行序，不是可能重复的 id 字段。所求函数值为：

行序	类别 1	类别 2	类别 3
1	-8.8368	-22.3069	-22.6786
100	-6.7589	-7.1790	-13.4610
130	-25.2455	-22.0986	-8.6438

回代矩阵为

实际类别	1	2	3
1	65	3	0
2	4	39	0
3	1	1	18

总一致率 $122/131 = 93.1298\%$ 。第 132 行的三个函数值约 -9.0802 、 -15.2381 、 -11.1166 ，最大者为第 1 类，判为第 1 类。不同软件若整体加同一与类别无关的常数，函数值会不同，但类别不会变。

解析 题 4.23 视网膜病变：典型相关与重要性

[返回题目](#)

两个典型相关系数为 0.852131 、 0.645393 。令 $\lambda_j = \rho_j^2 / (1 - \rho_j^2)$ ，按 $\lambda_j / \sum \lambda$ 得典型变量重要性为 78.786% 、 21.214% 。

按课程的标准化典型系数单位化后行平方和方法，原变量前 4 名为 **vision**、**at**、**age**、**bv**，对应原指标序号 4、5、1、8，重要性分别约 37.894% 、 28.056% 、 21.198% 、 7.894% 。应使用实际 group 列，而不是未经核对地按行数手造分组。

解析 题 4.24 血脂与心梗的 Bayes 二分类

[返回题目](#)

两组及合并协方差如下（次序为 TC、HDL）：

第 0 组：

指标	TC	HDL
TC	1600.5851	33.4724
HDL	33.4724	47.3897

第 1 组：

指标	TC	HDL
TC	972.0966	-17.6966
HDL	-17.6966	170.8092

合并协方差：

指标	TC	HDL
TC	1286.3408	7.8879
HDL	7.8879	109.0994

原 Excel 的空分隔列不能作预测变量, 分组也不能按错误的列索引读取。Box M 为 13.42655, 校正卡方 12.92498, $df = 3$, $P = 0.004802$; 在常用 0.05 水平拒绝协方差相等, 采用二次 Bayes 判别。

回代矩阵 (行实际 0/1, 列预测 0/1) :

实际类别	0	1
0	26	4
1	6	24

总一致率为 $50/60=83.333\%$ 。以组 1 为阳性, 灵敏度 $24/30=80.000\%$, 特异度 $26/30=86.667\%$ 。若把另一组定义为阳性, 两项会交换。回代正确率有乐观偏倚, 实际预测应再做交叉验证或独立验证。

解析 题 4.25 诊断准确率 95.3% 的评议

[返回题目](#)

先查 95.3% 来自训练集回代、交叉验证还是独立样本; 若变量筛选、因子提取与评价在同一数据上完成, 可能有信息泄漏和乐观偏倚。报告分母、混淆矩阵、类别不平衡、灵敏度与特异度、置信区间, 以及先验和阈值选择。只有总体准确率不足以评价诊断价值; 原图缺失, 不能反推 95.3% 的真实计数或断言它必然错误。

补充练习解析

解析 题 4.26 判别函数值换算后验概率

[返回题目](#)

答案: E。

先把三个评分都减去最大值 1000, 得到 $(0, -1, -2)$, 再计算

$$P(1|x) = \frac{1}{1 + e^{-1} + e^{-2}} \approx 0.6652.$$

减去共同常数不改变后验概率, 可避免直接计算 e^{1000} 导致数值溢出。第 1 类虽评分最大, 其后验概率并非 1; 也不能把原始评分直接除以评分之和。

解析 题 4.27 最近马氏距离与最大后验的关系

[返回题目](#)

若各类使用共同协方差矩阵, 且先验概率相等, 则最大后验与最小马氏距离等价。设

$$D_k^2 = (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k),$$

略去与类别无关的共同项后, 正态 Bayes 评分为

$$\delta_k(x) = \log q_k - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} D_k^2.$$

共同协方差使行列式项对各类相同; 等先验又使先验项相同, 此时最大化评分等价于最小化距离。

协方差不等时, 即使先验相等, 也不能略去各类不同的 $-\frac{1}{2} \log |\Sigma_k|$ 。若先验也不等, 还需考虑 $\log q_k$ 。因此按各类协方差算出的最近马氏距离类别, 未必就是最大后验类别。

解析 题 4.28 先验概率改变后的判别界值[返回题目](#)

(1) 等先验。略去共同项后,

$$u_1 = \log q_1, \quad u_2 = \log q_2 - 2 + 2x.$$

等先验时, $u_2 - u_1 = 2x - 2$ 。故 $x > 1$ 判第 2 类, $x < 1$ 判第 1 类, $x = 1$ 时按预先约定处理平局。

(2) 待判样品。在 $x = 1.2$ 处, 评分差为 0.4, 故

$$P(G_2 | x) = \frac{e^{0.4}}{1 + e^{0.4}} \approx 0.5987,$$

判入第 2 类。

(3) 改变先验。此时评分差为

$$u_2 - u_1 = \log(0.2/0.8) + 2x - 2 = -\log 4 + 2x - 2.$$

界值变为 $x = 1 + \frac{1}{2} \log 4 \approx 1.6931$ 。同一个样品的后验概率为

$$P(G_2 | 1.2) = \frac{0.2e^{0.4}}{0.8 + 0.2e^{0.4}} \approx 0.2716,$$

因此改判第 1 类。第 2 类先验降低后, 需要更支持第 2 类的指标值, 才能使其后验超过第 1 类。改变的是使用场景的类别出现概率, 本题的两类均值和方差保持不变。

解析 题 4.29 Fisher 方向与主成分方向的比较[返回题目](#)

(1) 判别方向。

$$W^{-1}B = \begin{pmatrix} 0.25 & 0 \\ 0 & 4 \end{pmatrix}.$$

按特征值从大到小, $\lambda_1 = 4$ 、 $\lambda_2 = 0.25$ 。方向为 $a_1 = (0, 1)^T$ 、 $a_2 = (1, 0)^T$, 因此可写 $F_1 = X_2$ 、 $F_2 = X_1$; 统一中心化只会改变常数项, 不改变方向。有效典型轴最多为 $\min(2, 3 - 1) = 2$, 本题两个特征值均为正。

(2) 相关与相对分类能力。

$$R_{1,\text{Can}} = \sqrt{4/(1+4)} \approx 0.8944, \quad R_{2,\text{Can}} = \sqrt{0.25/(1+0.25)} \approx 0.4472.$$

按正文特征值比例, 两轴的相对分类能力分别为 $4/4.25 = 94.12\%$ 、 $0.25/4.25 = 5.88\%$ 。这些百分比不是回代分类正确率。

(3) 与 PCA 比较。总离差阵为 $W + B = \text{diag}(125, 5)$, 样本协方差阵与它只差同一个正比例因子, 所以第一主成分沿 X_1 。PCA 寻找总方差最大的方向; Fisher 寻找组间相对组内变异最大的方向。 X_1 总变异虽大, 但组内也很分散; X_2 的组间/组内比为 4, 明显大于 X_1 的 0.25。

解析 题 4.30 分类研究摘要与回代结果评议[返回题目](#)

(1) **正确率**。三类分别为 $27/30 = 90\%$ 、 $24/30 = 80\%$ 、 $24/30 = 80\%$ ；总体为 $(27 + 24 + 24)/90 = 83.33\%$ 。应按真实类别的行合计计算各类正确率。

(2) **先验**。研究者人为按类各抽 30 例，所以样本类别比例由抽样安排决定，不能据此断定应用人群先验相等。等先验可以作为明确的工作假定；若有目标人群的类别比例或可靠专业资料，应据此设定并说明来源。

(3) **考核**。回代使用参与建模的样品，容易高估新对象的分类效果，83.33% 不能直接视为新样品正确率。可按正文所述采用留一法（刀切法）考核：每次去掉一例，以其余样品重新拟合后判别该例，再汇总结果；更直接的办法是在独立取得、能代表使用场景的新样本上考核。不同考核得到的正确率可能不同，不存在任意样本下固定不变的大小关系。